REVISÃO DE PROCESSOS ESTOCÁSTICOS

O que é uma Variável Aleatória ?

O que é um Espaço de Probabilidade?

O que é um Processo Estocástico?

Definição: Um Processo Estocástico é uma coleção de variáveis aleatórias definidas num mesmo espaço de probabilidades.

Geralmente representamos um processo estocástico por $\{X(t) : t \in T\}$

O conjunto T é o conjunto de índices, ou espaço paramétrico do processo estocástico.

Se T é um subconjunto de $\mathbb{R}$, o processo estocástico será contínuo no tempo;

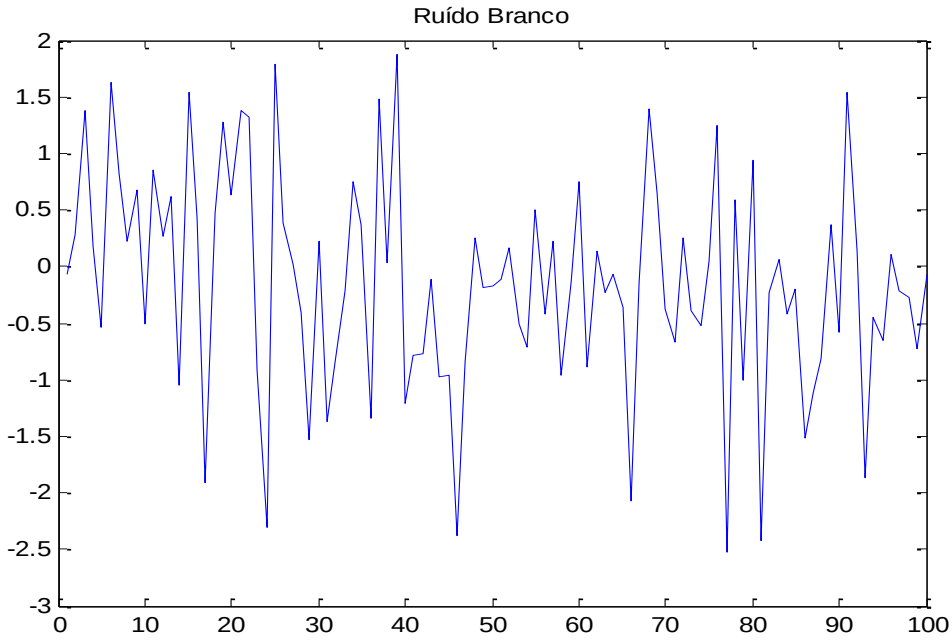
Se T é um subconjunto de $\mathbb{Z}$, o processo estocástico será discreto no tempo;

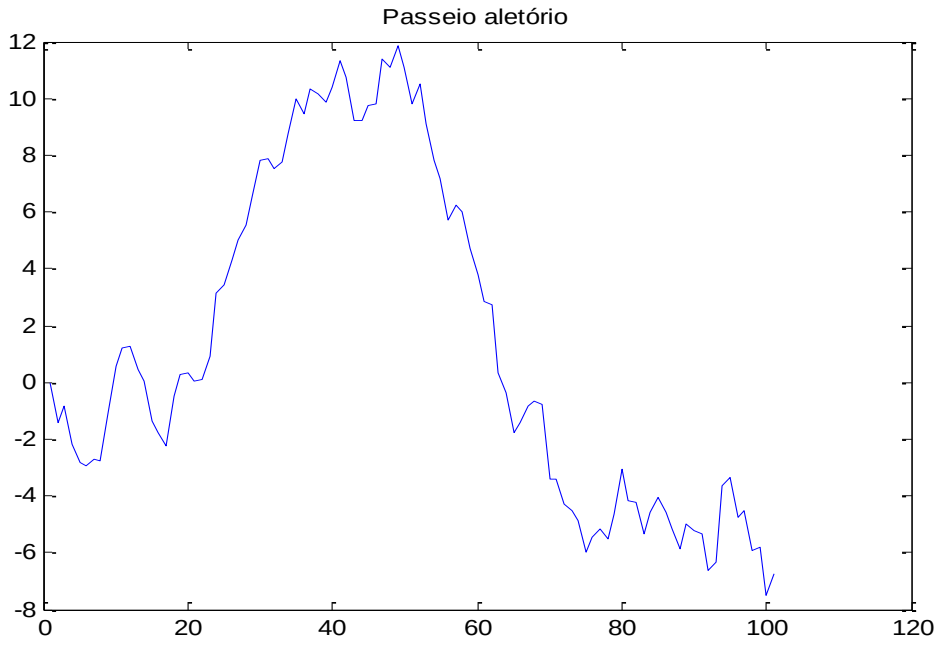
Para um dado $t \in T$, X(t) é uma variável aleatória. O conjunto de todos os valores possíveis que X(t) pode assumir é chamado de Espaço de Estado.

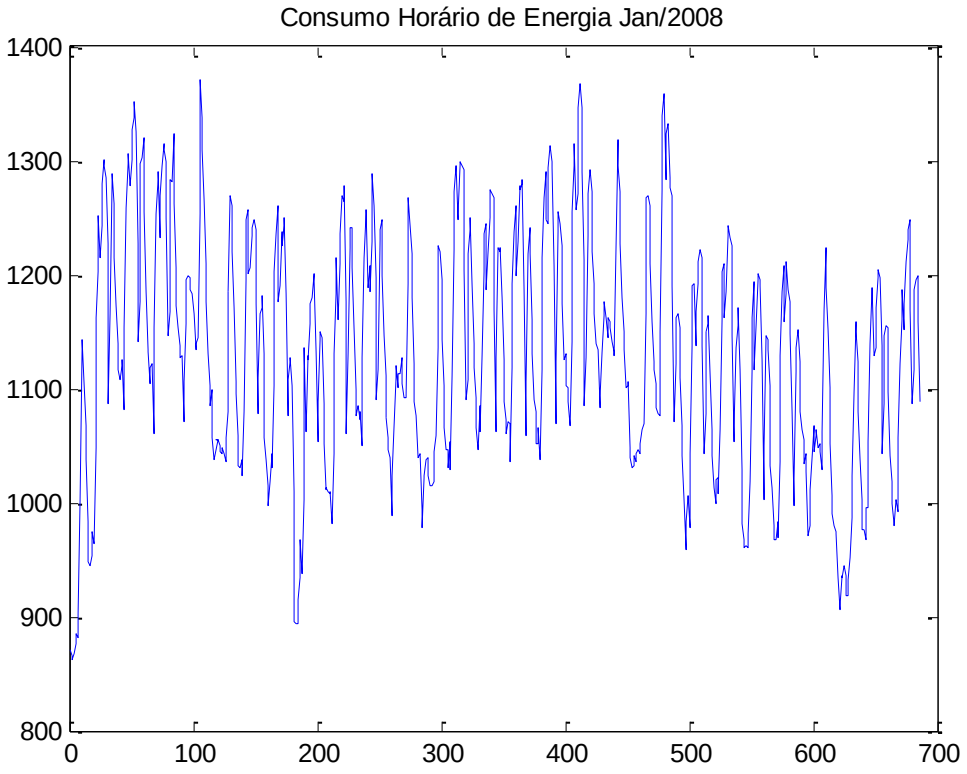
X(t) é uma Variável Aleatória Contínua se o Espaço de Estado for Contínuo; X(t) é uma Variável Aleatória Discreta se o Espaço de Estado for Discreto.

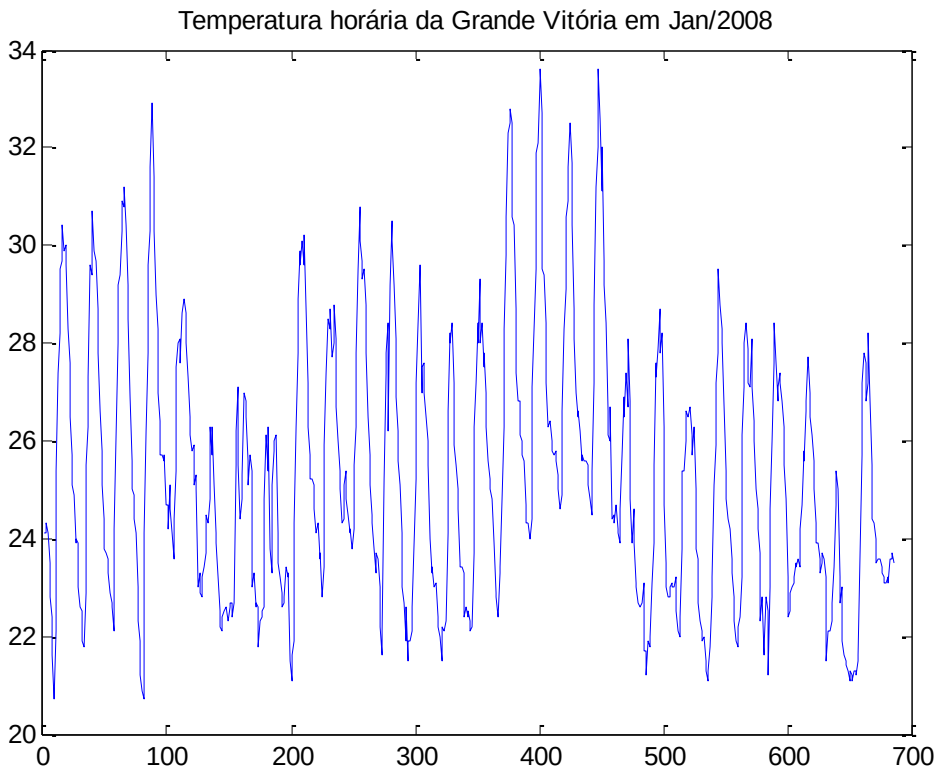
A Evolução no Tempo de Um Processo Estocástico é Chamado de Realização (ou Série Temporal)

Exemplos de Realizações de Processos Estocásticos Discretos no Tempo com Espaço de Estado Contínuo

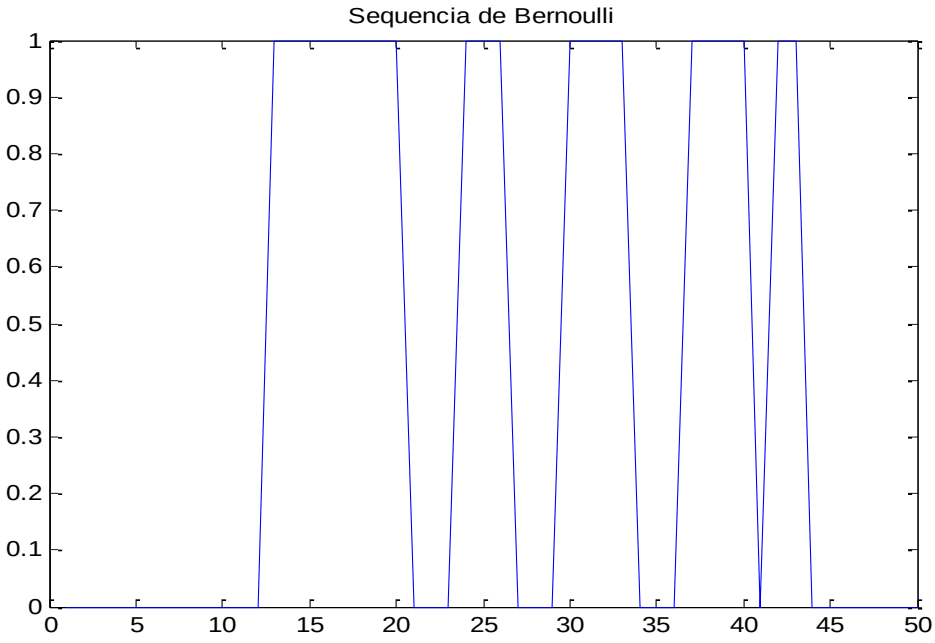



Passeio aletório
12
10
8
6
4
2
0
-2
-4
-6
-8
0
20
40
60
80
100
120


Consumo Horário de Energia Jan/2008
1400
1300
1200
1100
1000
900
800
0
100
200
300
400
500
600
700



Exemplo de Realização de Processos Estocásticos Discretos no Tempo com Espaço de Estado Discreto :



Um Processo Estocástico é Completamente Descrito Através da Densidade Conjunta das Variáveis Aleatórias

$$\{X(t_1), X(t_2), \ldots, X(t_n)\}$$

Uma maneira mais simples de descrever o processo é através dos momentos das variáveis aleatórias:

Média (momento de 1ª ordem) $\mu(t) = E(X_t)$

Variância (momento de 2ª ordem) $Var(X_t) = E\{(X_t - \mu_t)^2\}$

Autocovariância (momento de 2ª ordem) $\gamma(t_1, t_2) = E\{(X_{t_1} - \mu_{t_1})(X_{t_2} - \mu_{t_2})\}$

Autocorrelação (momento de 2ª ordem) $\rho(t_1, t_2) = E\{X_{t_1} X_{t_2}\}$

Revisão de Momento de Variáveis Aleatórias

Exemplo:

1 - $X_t = A\cos(2\pi t)$, onde A é V.A. Então:

$\mu(t) = E(X_t) = E(A)\cos(2\pi t)$;

$\rho(t_1, t_2) = E\{A\cos(2\pi t_1)A\cos(2\pi t_2)\} = E(A^2)\cos(2\pi t_1)\cos(2\pi t_2)$

2 - $X_t = A\cos(\omega t + \theta)$, onde θ é V.A uniformemente distribuída no intervalo $(-\pi, \pi)$

$$\mu(t) = E(X_t) = E[\cos(\omega t + \theta)] = \frac{1}{2\pi}\int_{-\infty}^{\infty} \cos(\omega t + \theta)d\theta = 0$$

$$\rho(t_1, t_2) = \frac{1}{2\pi}\int_{-\pi}^{\pi} \cos(\omega t_1 + \theta)\cos(\omega t_2 + \theta) = \frac{1}{2}\cos(\omega(t_1 - t_2))$$

3 – Ruído Branco:

$X_t = \varepsilon_t$, então $\gamma(t_1, t_2) = \text{var}(\varepsilon_t) = \sigma^2$ se $t_1 = t_2$ e $\gamma(t_1, t_2) = 0$ se $t_1 \neq t_2$

Obs: Uma sequência de V.A discretas $\{X_{t_1}, X_{t_2}, \ldots, X_{t_n}\}$, é uma sequência i.i.d se as variáveis $\{X_{t_1}, X_{t_2}, \ldots, X_{t_n}\}$, forem independentes entre si e possuírem a mesma distribuição de probabilidade.

3 – Passeio Aleatório:

$X_t = X_{t-1} + \varepsilon_t$, com $X_0 = 0$ onde ε_t é um ruído branco com média igual a μ.

Como $X_t = \sum_{i=1}^{t} \varepsilon_i$, temos que $\mu(t) = E(X_t) = E[\sum_{i=1}^{t} \varepsilon_i] = t\mu$ e $Var(X_t) = Var[\sum_{i=1}^{t} \varepsilon_i] = t\sigma^2$

Processos Estocásticos Gaussianos São Definidos pelos Momentos de Primeira e Segunda Ordem.

Definição: Um Processo Estocástico é dito estritamente estacionário se a distribuição conjunta de $\{X(t_1), X(t_2), \ldots, X(t_n)\}$ **é a mesma de** $\{X(t_{1+k}), X(t_{2+k}), \ldots, X(t_{n+k})\}$.

Portanto a média e a variância do processo é a mesma para todo o instante t e a função de Autocovariância só depende do lag k= $t_2 - t_1$.

Definição: Um Processo Estocástico é dito fracamente estacionário, ou estacionário de segunda ordem se a sua média é constante e se a sua função de Autocovariância depende apenas do lag k= $t_2 - t_1$.

A função de Autocovariância , $\gamma(k), k = t_1 - t_2$, de um processo estacionário discreto $\{X_{t_1}, X_{t_2}, \ldots, X_{t_n}\}$, com média zero, satisfaz as seguintes propriedades:

1 - $\gamma(0) > 0$

2 - $\gamma(-k) = \gamma(k)$

3 - $|\gamma(k)| \leq \gamma(0)$

OBS: PROCESSOS FRACAMENTE ESTACIONÁRIO SERÃO CHAMADOS, PARA SIMPLIFICAR, DE PROCESSOS ESTACIONÁRIOS

Teste de Estacionariedade: Traçar um gráfico onde o eixo das abscissas contém as médias de subconjuntos de observações e no eixo das ordenadas calculamos a amplitude de cada um destes subconjuntos . Se $S^k = \left\{X_1^k, X_2^k, \ldots, X_n^k\right\}, k = 1 \ldots m$ for um tal subconjunto de n observações, então

$\bar{X}_k = \frac{1}{n}\sum_{m=1}^{n} X_m^k, k = 1 \ldots M$ e

$$w_k = \max\left\{X_1^k, X_2^k, \ldots, X_n^k\right\} - \min\left\{X_1^k, X_2^k, \ldots, X_n^k\right\}$$

Se w_k independer de $\bar{X}_k$, obteremos N pontos espalhados ao redor de uma reta paralela ao eixo das abcissas

Caso contrário o processo não será estacionário, e devemos fazer algum tipo de transformação, como obter a diferença da série entre tempos consecutivos.

(Ver Exemplos)

ESTIMAÇÃO DOS PARÂMETROS DE UM PROCESSO ESTOCÁSTICO ESTACIONÁRIO

Na Prática não conhecemos os parâmetros que caracterizam o processo. Então devemos estimá-los:

$\bar{X} = \frac{1}{n}\sum_{t=1}^{n} X_t$ (média das amostras) $S = \frac{1}{n-1}\sum_{t=1}^{n} (X_t - \bar{X}_t)^2$ (Variância Amostral)

$\gamma(k) = \frac{1}{n-k-1}\sum_{t=k+1}^{T} (X_t - \bar{X})(X_{t-k} - \bar{X})$ (Autocovariância Amostral de Lag k)

$$r(k) = \frac{\frac{1}{n-k-1}\sum_{t=k+1}^{n} (X_t - \bar{X})(X_{t-k} - \bar{X})}{\sum_{t=k+1}^{n} (X_t - \bar{X})^2}$$ (Coeficiente de correlação de Lag k)

$\rho(k) = \frac{1}{n-k-1}\sum_{t=k+1}^{n} (X_t)(X_{t-k})$ (função de autocorrelação)

TEOREMA DA ERGODICIDADE: OS MOMENTOS DE 1ª E 2ª ORDEM DE UM PROCESSO ESTACIONÁRIO PODEM SER APROXIMADOS PELOS MOMENTOS AMOSTRAIS

QUANDO O NÚMERO DE AMOSTRAS n TENDE A INFINITO

E quando n é finito?

VARIÁVEL ALEATÓRIA GAUSSIANA

1 – Seja**:**

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-m)^2/2\sigma^2} \quad -\infty < x < \infty$$

1.1 $\int_{-\infty}^{\infty} f(x)dx$ =1

1.2 E[X] = m

1.3 Var[X] = σ

Nomeclatura: X $\rightarrow N(m,\sigma)$

2 Seja Y $\rightarrow N(m,\sigma)$. Como determina

$$\text{P}(Y \leq y) = \int_{-\infty}^{y} f(x)dx \ ?$$

Seja X $\rightarrow N(0,1)$ e Q(X) = 1 – P($X \leq x$), $x \geq 0$. Note que

Q(-x)=1-Q(x)

Q(x) é dado em Tabela. Considerando a transformação linear $Y = \sigma X + m$, temos que:

$$f_Y(y) = f_X(\frac{y-m}{\sigma})$$

Teorema do Limite Central

Seja $X_i, i = 1,2,\ldots,n$ for uma sequência i.i.d com

$E[X] = \mu$ e $Var[X] = \sigma$. Definindo :

$$Z_n = \frac{S_n - n\mu}{\sigma\sqrt{n}}$$

Onde S_n é a soma de v.a $X_i, i = 1,2,\ldots,n$

Então:

$\lim_{n\to\infty} P[Z_n \leq z]$ é uma v.a N(0,1).

Estatística

Ver a Transparência da Fucape (Prof. Fernando Caio Galdi)

INTERVALO DE CONFIANÇA

Seja o processo Estocástico Estacionário Gaussiano $\left\{X_{t_1}, X_{t_2}, \ldots, X_{t_n}\right\}$, com média μ e variância σ^2. Desejamos definir um intervalo I tal que a média de um número finito de amostras de X_t esteja próximo da média μ da sua população com uma determinada probabilidade.

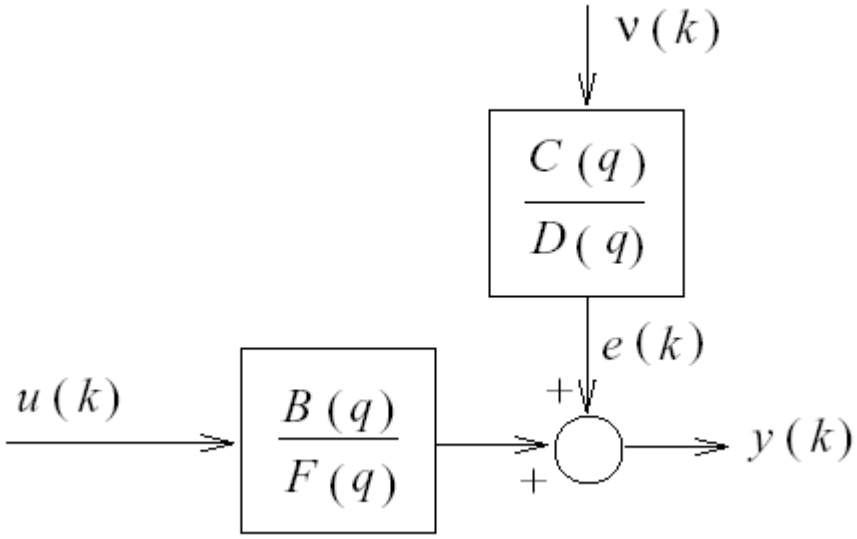
Teorema de Bartlett: A distribuição aproximada do coeficiente de correlação $r(k)$ de um sinal com **n** amostras é Normal com média zero e variância $\frac{1}{n}$. Logo a variável aleatória $\frac{r(k)-0}{\sqrt{\frac{1}{n}}}$ tem aproximadamente a densidade Normal com média zero e variância 1 e, por exemplo:

$$P\{-1,96 \leq \frac{r(k)-0}{\sqrt{\frac{1}{n}}} \leq 1,96\} = P\{\frac{-1,96}{\sqrt{n}} \leq r(k) \leq \frac{1,96}{\sqrt{n}}\} = 0,95$$

Para que o coeficiente de correlação amostral $r(k)$ seja estatisticamente diferente de zero, é necessário que esta função possua valores fora do intervalo $[\frac{-2}{\sqrt{n}}, \frac{2}{\sqrt{n}}]$.

Os softwares estatísticos geralmente exibem as correlações amostrais e os limites do intervalo de confiança, isto é, $[\frac{-2}{\sqrt{n}}, \frac{2}{\sqrt{n}}]$. Se uma auto correlação está dentro do intervalo, ela é estatisticamente nula, e se ela cai fora do intervalo dizemos que ela é estatisticamente diferente de zero.

Modelos Box-Jenkins



Usaremos a seguinte nomenclatura, também usada no livro da Profa Monica Barros: o tempo discreto será representado pela letra “t” e o ruído branco v_t será substituído por a_t. A autocorrelação amostral no livro da Mônica é chamado neste texto de coeficiente de correlação amostral. É bom lembrar que a autocorrelação amostral é a autocovariância amostral dividido pela variância. A autocorrelação neste texto é igual a autocovariância quando a média do processo é igual a zero em qualquer instante de tempo.

O operador atraso neste texto será representado por q^{-1}, que é a mesma nomenclatura usada no livro do Aguirre**,** ou seja, $q^{-K}X_t = X_{t-K}$**.** No livro da Monica Barros, o operador atraso é representado pela letra **"**B **".**

A seguir analisaremos as características estatísticas do sinal aleatório e_t, no modelo Box-Jenkis. Assumiremos que a entrada u é igual a zero e que a entrada aleatória a_t é um ruído branco com média zero e variância σ^2. Portanto, a componente determinística na saída y não será analisada devido a entrada u ser igual a zero.

OBS: C(q) é um polinômio de ordem nc e D(q) é um polinômio de ordem nd . Quando C(q) =1, o modelo de Box-Jenkis é chamado de Autoregressivo (AR) de ordem nd , e quando D(q) =1, o modelo de Box-Jenkis é chamado de Média Móvel (MA) de ordem nc .

Quando C e D são diferentes de 1, o modelo é chamado de ARMA de ordem nc e nd .

Teorema: O sinal e_t é estacionário se a equação D(q)=0 tiver raízes dentro do círculo unitário.

OBS: O Modelo Média Móvel é sempre estacionário**.**

Ex1: $e_t = -0.6e_{t-1} + a_t$. Então C(q) = 1 e D(q) = 1 +0.6q^{-1} e a equação D(q) = 0 possui uma raiz dentro do círculo unitário ($q = -0.6$)

Logo e_t é um processo estocástico AR(1) estacionário.

Ex2: $e_t = a_t + 0.8a_{t-1}$. Então C(q) = 1 + 0.8q^{-1} e D(q) = 1 e a equação D(q) = 0 e independe de q.

Logo e_t é um processo estocástico MA(1) estacionário.

Ex3: $e_t = 1.5e_{t-1} - 0.75e_{t-2} + a_t - 3a_{t-1} + 0.8a_{t-2}$. Então

C(q) = $C(q) = 1 - 0.3q^{-1} + 0.8q^{-2}$ e $D(q) = 1 - 1.5q^{-1} + 0.75q^{-2}$ e a equação D(q) = 0 possui raízes fora do círculo unitário.

Logo e_t é um processo estocástico ARMA(2,2) não-estacionário.

NO PROCESSO DE IDENTIFICAÇÃO DA SÉRIE TEMPORAL e_t, UMA FORMA DE VERIFICAR SE O MODELO ESCOLHIDO É ADEQUADO É FILTRAR e_t POR

UM FILTRO COM FUNÇÃO DE TRANSFERÊNCIA INVERSA $\frac{D(q)}{C(q)}$ AO MODELO DO ERRO. EM SEGUIDA, DEVE-SE OBSERVAR SE O SINAL DE SAÍDA É UM RUÍDO BRANCO. CASO NÃO SEJA, O MODELO DO ERRO NÃO REPRESENTA ADEQUADAMENTE O A SÉRIE TEMPORAL.

POR ISTO, É NECESSÁRIO VERIFICAR SE O MODELO BOX-JENKIS É INVERTÍVEL.

Teorema: O Modelo Box-Jenkis é invertível se C(q)=0 tiver raízes dentro do círculo unitário.

OBS: O Modelo Auto regressivo é sempre invertível**.**

AUTOCORRELAÇÃO DO MODELO AR(nd)

Multiplicando $e_t = d_1 e_{t-1} + d_2 e_{t-2} + \cdots + d_{nd} e_{t-nd} + a_t$ por e_{t-K} temos que:

$$e_t e_{t-K} = d_1 e_{t-1} e_{t-K} + d_2 e_{t-2} e_{t-K} + \cdots + d_{nd} e_{t-nd} e_{t-K} + a_t e_{t-K}$$

Aplicando o operador Valor Esperado (E) em cada um dos termos da equação acima e considerando que $E\{a_t\, e_{t-K}\} = 0$, para k diferente de zero, pois a_t é um ruído branco com média zero, concluímos que:

$$\gamma(k) = E[e_t e_{t-K}] = d_1\gamma(k-1) + d_2\gamma(k-2) + \cdots + d_{nd}\gamma(k-n_d)$$

Fazendo $k = 1 \cdots n_d$, e levando em conta que $\gamma(k) = \gamma(-k)$, obtemos o seguinte sistema de n_d equações com n_d incógnitas:

$$\begin{bmatrix} \gamma(0) & \gamma(1) & \cdots & \gamma(n_d-1) \\ \gamma(1) & \gamma(0) & \cdots & \gamma(n_d-2) \\ \vdots & \vdots & \ddots & \vdots \\ \gamma(n_d-1) & \gamma(n_d-2) & \cdots & \gamma(0) \end{bmatrix} \begin{bmatrix} d_1 \\ d_2 \\ \vdots \\ d_{n_d} \end{bmatrix} = \begin{bmatrix} \gamma(1) \\ \gamma(2) \\ \vdots \\ \gamma(n_d) \end{bmatrix}$$

O sistema de equações acima é chamado de (EQUAÇÃO DE YULE-WALKER). É usado para estimar os parâmetros $d_1, d_2 \cdots d_{nd}$ do processo AR, quando substituímos as autocorrelações teóricas ($\gamma(k)$) pelas respectivas autocorrelações estimadas:

$$r(k)=\frac{\frac{1}{T-k-1}\sum_{t=k+1}^{T}(X_t-\bar{X})(X_{t-k}-\bar{X})}{\sum_{t=k+1}^{T}(X_t-\bar{X})^2}$$

Terorema: A solução geral da equação:

$$\gamma(k)=d_1\gamma(k-1)+d_2\gamma(k-2)+\cdots+d_{nd}\gamma(k-n_d)$$

é: $$\gamma(k)=A_1\lambda_1^k+A_2\lambda_2^k+\cdots+A_{nd}\lambda_{nd}^k$$

onde $\lambda_1^k,\lambda_2^k\cdots\lambda_{nd}^k$ **são as raízes da equação D(q) = 0.**

OBS:

1 - Se λ_i for real, o termo $A_i\lambda_i^k$ decai geometricamente para zero se o processo AR for estacionário;

2 - 1 - Se λ_i for complexo, termos que $\gamma(k)$ é uma senóide amortecida se o processo AR for estacionário.

AUTOCORRELAÇÃO DO MODELO MA(nc).

Multiplicando $e_t=a_t+c_1a_{t-1}+c_2a_{t-2}+\cdots+c_{nc}a_{t-nc}$ por

$$e_{t-K}=a_{t-K}+c_1a_{t-K-1}+c_2a_{t-K-2}+\cdots+c_{nc-1}a_{t-nc-1}+c_{nc-2}a_{t-nc-2}$$

temos que:

$$E[e_t e_{t-K}] = \gamma(k) = c_K + c_1 c_{K+1} + \cdots + c_{nc} c_{nc-K}$$

, $k = 1, \cdots, n_c$ **e**

$\gamma(k) = 0$ para lags maiores que n_c

Observe que a função de autocorrelação pode ser usada para medir a ordem do modelo MA, pois esta função será igual a zero para lags maiores que n_c

No caso do modelo AR, a ordem do modelo será obtida através da **Função de Autocorrelação Parcial**, a qual é definida como a correlação entre e_{t-K} e e_t condicionada em relação às variáveis intermediárias $e_{t+K-1}, e_{t+K-2}, \ldots, e_{t+1}$, isto é,

$$E[e_t e_{t-K} \mid e_{t+K-1}, e_{t+K-2}, \ldots, e_{t+1}]$$

Pode-se mostrar que

$$d_k = E[e_t e_{t-K} \mid e_{t+K-1}, e_{t+K-2}, \ldots, e_{t+1}], k = 1, \ldots, n_d ,$$

onde, $d_1, d_2 \cdots d_{nd}$ são os coeficientes do modelo AR, os quais são obtidos resolvendo-se o sistema de equações de **YULE-WALKER** (observe que estes coeficientes podem ser estimados através da função de autocorrelação amostral $r(k)$)

A resolução deste sistema pode ser obtida Pela Regra de Cramer :

$$d_k = \frac{\det\begin{bmatrix} 1 & r(1) & r(2)\cdots & r(1) \\ r(1) & 1 & r(2)\cdots & r(2) \\ \vdots & \vdots & \ddots & \vdots \\ r(k-1) & r(k-2) & r(k-3)\cdots & r(k) \end{bmatrix}}{\det\begin{bmatrix} 1 & r(1) & r(2)\cdots & r(k-1) \\ r(1) & 1 & r(2)\cdots & r(k-2) \\ \vdots & \vdots & \ddots & \vdots \\ r(k-1) & r(k-2) & r(k-3)\cdots & 1 \end{bmatrix}} \cdots$$

Ou seja, a matriz do numerador é a mesma do denominador, exceto pela última coluna, que é substituída por

$$\begin{bmatrix} r(1) \\ r(2) \\ \vdots \\ r(k) \end{bmatrix}$$

Teorema: Num processo AR(n_d) , as autocorrelações parciais d_k são nulas para lags k maiores que a ordem n_d e num processo MA(nc), as autocorrelações parciais tem comportamento de exponenciais/senóides amortecidas, e então não apresenta corte brusco.

EXISTE UMA DUALIDADE NO COMPORTAMENTO DAS FUNÇÕES DE AUTOCORRELAÇÃO E AUTOCORRELAÇÃO PARCIAL NO MODELOS AR(n_d) E MA(nc), OU SEJA, O ASPECTO DA AUTOCORRELAÇÃO PARCIAL DO MODELO AR(n_d) TEM UM CORTE BRUSCO (ASSIM COM A AUTOCORRELAÇÃO DO MA(nc)), E A FUNÇÃO DE AUTOCORRELAÇÃO DE UM AR(n_d) TEM O MESMO FORMATO DA MA(nc).

Identificação não Paramétrica de Modelos ARMA com entrada U exógena (Métodos Estocásticos)

- Reduzindo o efeito do ruído no domínio do tempo

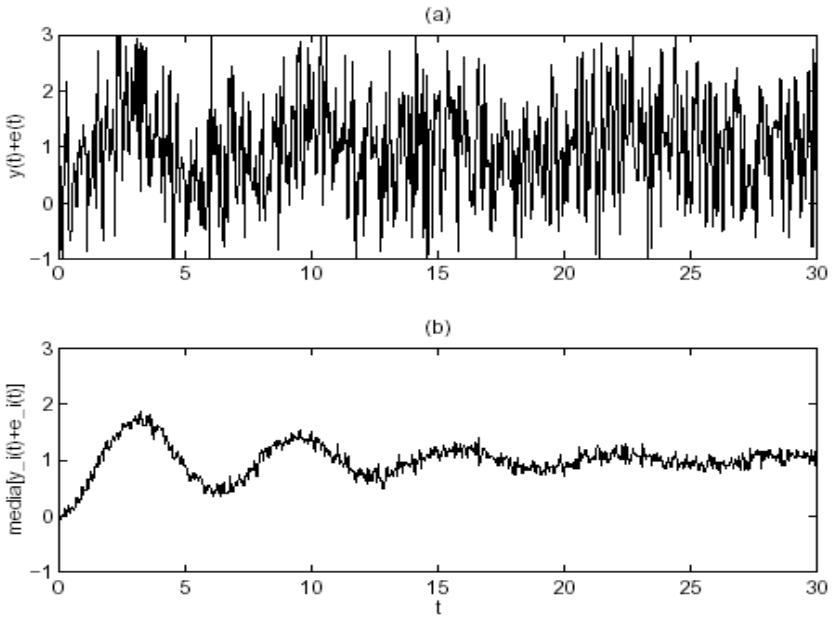


FIGURA 4.1: Redução do efeito de ruído aleatório ao se tirar a média de sinais de testes similares. (a) uma realização do teste, (b) média resultante de cem testes semelhantes ao mostrado em (a). Esse procedimento é também conhecido como acumulação de amostras.

Esse procedimento se baseia na pressuposição de que o ruído é aleatório com média zero, ou seja, o ruído é branco e, portanto, não consistente. Assume-se que o processo é ergódico. □

A justificativa para o aumento da relação sinal/ruído acima pode ser entendida da seguinte forma. Seja a k-ésima amostra do sinal com ruído $y(k)$ com desvio padrão σ. Um conjunto de N_s simulações dá origem a N_s amostras na posição k, $\{y_1(k), y_2(k), \ldots, y_{N_s}(k)\}$ com média $\underline{y(k)}$.

A média das N_S simulações é:

$$\underline{y(k)} = \frac{1}{N_s} \sum_{i=1}^{N_s} y_i(k), \;\; k = 1, ..., N,$$

sendo que N indica o número total de amostras.

$$\begin{aligned} \text{var}[\underline{y(k)}] &= \text{var}[\frac{1}{N_s}(y_1(k) + y_2(k) + \ldots + y_{N_s}(k))] \\ &= \frac{1}{N_s^2}\text{var}[y_1(k) + y_2(k) + \ldots + y_{N_s}(k)] \\ &= \frac{1}{N_s^2}\{\text{var}[y_1(k)] + \text{var}[y_2(k)] \ldots \text{var}[y_{N_s}(k)]\} \\ &= \frac{N_s\sigma^2}{N_s^2} = \frac{\sigma^2}{N_s}. \end{aligned}$$

Equação (4.1)

Portanto, (4.1) mostra que o desvio padrão da k-ésima amostra do sinal resultante do procedimento de média, $\sqrt{\text{var}[\underline{y(k)}]} = \sigma/\sqrt{N_s}$, é menor que o desvio padrão da respectiva amostra no sinal original.

Identificação baseada em Funções de correlação

A *função de correlação cruzada* (FCC) entre dois sinais $u(t)$ e $y(t)$ é definida como

$$\begin{aligned} r_{uy}(\tau, t) &= \mathrm{E}[u(t)y(t+\tau)] \\ r_{uy}(\tau) &= \lim_{T\to\infty} \frac{1}{2T} \int_{-T}^{T} u(t)y(t+\tau)dt. \end{aligned}$$

No caso discreto, a definição é

$$r_{uy}(k) = \lim_{N\to\infty} \frac{1}{2N+1} \sum_{i=-N}^{N} u(i)y(i+k).$$

A *função de autocorrelação* (FAC) de um sinal $u(t)$ pode ser estimada usando-se

$$r_{uu}(k) = \lim_{N\to\infty} \frac{1}{2N+1} \sum_{i=-N}^{N} u(i)u(i+k).$$

⇨As funções de correlação FCC e FAC são relativamente robustas a ruído devido ao "efeito de média" presente em suas definições.

Resposta ao impulso a partir de funções de correlação:

Seja o *somatório de convolução*

$$y(k+i) = \sum_{j=0}^{\infty} h(j)u(k+i-j).$$

Substituindo-se a equação acima em

$$r_{uy}(k) = \lim_{N\to\infty} \frac{1}{2N+1} \sum_{i=-N}^{N} u(i)y(i+k)$$

resulta na *equação de Wiener-Hopf*

$$r_{uy}(k) = \sum_{i=0}^{\infty} h(i)r_{uu}(k-i).$$

As funções de correlação $r_{uu}(k)$ e $r_{uy}(k)$ são relacionadas pela resposta ao impulso do sistema, $h(k)$, à semelhança de $u(k)$ e $y(k)$.

Usando a equação de Wiener-Hopf, um conjunto de equações pode ser escrito da seguinte forma:

$$
\begin{aligned}
r_{uy}(0) &= h(0)r_{uu}(0) + h(1)r_{uu}(-1) + \dots \\
r_{uy}(1) &= h(0)r_{uu}(1) + h(1)r_{uu}(0) + \dots \\
r_{uy}(2) &= h(0)r_{uu}(2) + h(1)r_{uu}(1) + \dots \\
&\vdots \quad \vdots \quad \vdots
\end{aligned}
$$

que pode ser expressa em forma matricial como se segue:

$$\begin{bmatrix} r_{uy}(0) \\ r_{uy}(1) \\ r_{uy}(2) \\ \vdots \end{bmatrix} = \begin{bmatrix} r_{uu}(0) & r_{uu}(-1) & \dots \\ r_{uu}(1) & r_{uu}(0) & \dots \\ r_{uu}(2) & r_{uu}(1) & \dots \\ \vdots & \vdots & \vdots \end{bmatrix} \begin{bmatrix} h(0) \\ h(1) \\ h(2) \\ \vdots \end{bmatrix},$$

$$\mathbf{r}_{uy} = R_{uu}\,\mathbf{h}.$$

Difícil solução, pois R_{uu} é de grande dimensão.

Se $u(k)$ for tal que $r_{uu}(k) = 0$, $\forall k \neq 0$, R_{uu} será diagonal e

$$\mathbf{r}_{uy} = r_{uu}(0) I\,\mathbf{h},$$
$$\mathbf{h} = \mathbf{r}_{uy}/\sigma_u^2,$$

- **Ruído de medição:**

Se, $y(k) = y^{\mathrm{i}}(k) + e(k)$, tem-se

$$\begin{aligned} r_{uy}(k) &= \lim_{N\to\infty} \frac{1}{2N+1} \sum_{i=-N}^{N} u(i)[y^{\mathrm{i}}(i+k) + e(i+k)] \\ &= \lim_{N\to\infty} \frac{1}{2N+1} \left[\sum_{i=-N}^{N} u(i) y^{\mathrm{i}}(i+k) + \sum_{i=-N}^{N} u(i) e(i+k) \right] \\ &= r_{uy^{\mathrm{i}}}(k) + r_{ue}(k). \end{aligned}$$

$$\mathbf{r}_{uy^{\mathrm{i}}} + \mathbf{r}_{ue} = r_{uu}(0) I\,\mathbf{h},$$
$$\mathbf{h} = \frac{\mathbf{r}_{uy^{\mathrm{i}}}}{\sigma_u^2} + \frac{\mathbf{r}_{ue}}{\sigma_u^2}.$$

- $\sigma_u^2 = r_{uu}(o)$ - variância do sinal u(k).
- Para eliminar o efeito do ruído:
  - aumentar a variância do sinal de entrada (aumentar a relação sinal/ruído)
  - garantir que $r_{ue}(k)=o$, $\forall$ k. Condição menos restritiva que no caso determinístico que exigia $e(k)=o$.
- A condição $r_{ue}(k)=o$, $\forall$ k será em geral observada em identificação de sistemas.
- É interessante saber quais sinais têm a propriedade $r_{uu}(k)=o$, $\forall$ $k\neq o$ $\rightarrow$ sinais aleatórios e pseudo-aleatórios.

- Sinais Pseudo-aleatórios
  - têm a propriedade $r_{uu}(k)\approx o$, $\forall$ $k\neq o$

- mais comum: sinais binários pseudo-aleatório (PRBS- pseudo random binary signal).

- Persistência de excitação

Um sinal u(k) é persistentemente excitante de ordem N ele for estacionário e se a matriz de autocorrelação amostral do sinal u (R_{UU}^N) for não singular para algum N, onde

$$R_U^N = \begin{bmatrix} r_{UU}(0) & r_{UU}(1) & \cdots & r_{UU}(N-1) \\ r_{UU}(1) & r_{UU}(2) & \cdots & r_{UU}(N-2) \\ \vdots & \vdots & \ddots & \vdots \\ r_{UU}(N-1) & r_{UU}(N-2) & \cdots & r_{UU}(0) \end{bmatrix}$$

A definição de sinal persistentemente excitante pode também ser feita no domínio da freqüência:

Um sinal $u(k)$ com espectro $\Phi_u(\omega)$ é *persis-*

tentemente excitante de ordem n se para todos os filtros do ti

$$M_n(q) = m_1 q^{-1} + \ldots + m_n q^{-n}$$

a relação

$$| M_n(e^{j\omega}) |^2 \Phi_u(\omega) \equiv 0$$

implica que $| M_n(e^{j\omega}) |^2 \equiv 0$.

O sinal tem potência espectral em n freqüências distintas.

⇨ Uma condição para se estimar n parâmetros é que o sinal de excitação deve ser persistentemente excitante (PE) pelo menos de ordem n.

EXEMPLO: Persistência de excitação de sinais

Seja $u(k)$ um pulso, $u(k) = 1,\ k = 0$ e $u(k) = 0,\ \forall k \neq 0$. Is
resulta em $R^n_{uu} = 0$. Ou seja, um pulso não é persistentemen
excitante de nenhuma ordem.

Se $u(k)$ for um degrau de amplitude a, então $r_{uu}(k) = a^2$ e
R^n_{uu} só não será singular para $n = 1$. Ou seja, o degrau é um
sinal persistentemente excitante de ordem 1. Assim sendo, em
regime permanente, a resposta ao degrau de um sistema só serve
para estimar um parâmetro, o ganho estático.

Se $\nu(k)$ for ruído branco com variância σ^2, então $r_{\nu\nu}(k) = \sigma^2\delta$
sendo δ a função delta de Dirac. Portanto, a matriz $R^n_{\nu\nu} = \sigma^2 I_n$
é não singular para qualquer valor de n. Conseqüentemente, o
ruído branco é persistentemente excitante de todas as ordens.

Alguns trechos destas transparências foram retirados das transparências disponíveis no site: http://www.cpdee.ufmg.br/~aguirre/livro/livro.htm