Processos Estocásticos

Mônica Barros

Mônica Barros é Professora Adjunta do DEE (Departamento de Engenharia Elétrica da PUC-Rio). Ela é graduada em Matemática pela University of Washington (Seattle, EUA), Mestre em Estatística pela University of Texas (Austin, EUA) e Doutora em Séries Temporais pela PUC-Rio.

Mônica tem um interesse especial nas aplicações de Estatística e Séries Temporais em Energia, Marketing e Finanças e também atua como consultora nestas áreas, tendo trabalhado em empresas brasileiras e estrangeiras de grande porte.

Em 1999, Mônica lançou seu primeiro livro, "Probabilidade: um curso introdutório", pela Papel Virtual Editora. Este livro tem sido usado em diversos cursos de Probabilidade para Engenharia desde então, além de servir como referência complementar em cursos de treinamento ministrados pela autora.

ISBN 85-7393-072-5
9 788574 930725

Processos Estocásticos

Mônica Barros

Processos Estocásticos

Mônica Barros

Papel Virtual EDITORA

Carlos Eduardo C. Melo

Copyright© 2000 por Mônica Barros

Editor: Tomaz Adour

Capa: Nelson Porto

Diagramação: Denise Reis

Revisão Técnica: Mônica Barros

BARROS, Mônica.
Processos Estocásticos. Rio de Janeiro.
Papel Virtual Editora, 2004
432 p.

1. Estatística

ISBN: 85.7493-072-5

Papel Virtual Editora
Rua Conde de Lages 44 sala 402
Glória, Rio de Janeiro, RJ, CEP: 20241-900
Tel: 21-2221-1121

E-mail: editor@papelvirtual.com.br
Endereço eletrônico: www.papelvirtual.com.br

.PAPEL & VIRTUAL.

Aos meus pais, Luís e Sônia Beatriz, que me têm apoiado ao longo da vida e foram grandes amigos em momentos difíceis. Com muito carinho da filha,

Mônica

Julho de 2004

ÍNDICE

Capítulo 1 - Revisão de Probabilidades 3
1.1. Para que serve probabilidade? 3
1.2. Experiências aleatórias e espaços amostrais 4
1.3. Definição axiomática de probabilidade 6
1.4. Probabilidade Condicional e independência 9
1.5. Teorema de Bayes 17
1.6. Variáveis Aleatórias, Funções Densidade de Probabilidade, Momentos de uma variável aleatória 22
1.7. Distribuições Conjuntas, Marginais e Condicionais 34
1.8. Independência de Variáveis Aleatórias 39
1.9. As principais distribuições discretas 42
1.10. As principais distribuições contínuas 51
1.11. O Teorema Central do Limite 70
1.12. Exercícios – Capítulo 1 78

Capítulo 2 - Introdução aos Processos Estocásticos 89
2.1. Introdução 89
2.2. Exemplos 99
2.3. Exercícios - Capítulo 2 107

Capítulo 3 - Cadeias de Markov 111
3.1. Introdução 111
3.2. Matrizes de Transição de Cadeias de Markov e as equações de Chapman e Kolmogorov 117
3.3. Análise do Primeiro Passo 127
3.4. Maiores Detalhes sobre o Passeio Aleatório 134
3.5. O Comportamento Limite de Cadeias de Markov 154
3.6. Classificação de Estados 162
3.7. O Teorema Básico de Limite para Cadeias de Markov 172
3.8. Cadeias de Markov Redutíveis 183
3.9. Exercícios - Capítulo 3 194

Capítulo 4 - Processos de Poisson 205
4.1. A Distribuição Poisson 205
4.2. Derivação do Processo de Poisson 208
4.3. Tempos de Espera e Tempos entre Ocorrências 213
4.4. Extensões do Processo de Poisson 220
4.5. Processos de Poisson não Homogêneos e Processos de Poisson Compostos 229
4.6. Exercícios - Capítulo 4 233

Capítulo 5 - Introdução às Séries Temporais 239
5.1. Introdução - algumas considerações sobre séries temporais 239
5.2. Métodos de Amortecimento Exponencial (séries não sazonais) 246
5.3. Métodos de Amortecimento Exponencial (séries sazonais) 262
5.4. Modelos ARIMA de Box e Jenkins não sazonais 271
5.5. Exercícios – Capítulo 5 327

Capítulo 6 - Crescimento Populacional, Processos de Ramificação ("BRANCHING PROCESSES") 335
6.1. Introdução e Exemplos 335
6.2. Probabilidades de extinção num processo de ramificação 339
6.3. Funções geradoras de probabilidades 340
6.4. Funções geradoras de probabilidades e somas de variáveis aleatórias independentes 347
6.5. Exercícios - Capítulo 6 353

Capítulo 7 - Processos Estocásticos em Finanças 355
7.1. Um Modelo para o Comportamento do Preço de Ações 355
7.2. Introdução aos Derivativos 362
7.3. O Lema de Itô 389
7.4. Modelo Binomial 392
7.5. O Modelo de Black e Scholes para o preço de uma opção 398
7.6. Parâmetros de Hedge 405

Apêndice: Alguns comentários sobre o valor do dinheiro no tempo 411
7.7. Exercícios – Capítulo 7 415

Bibiliografia 419

Prefácio

A intenção ao começar a escrever este livro era bastante despretensiosa: criar material de suporte para o meu curso de Processos Estocásticos na graduação do Departamento de Engenharia Elétrica da PUC-Rio. Ao longo do tempo, o meu próprio curso foi mudando, e o reflexo está aí, nesta enorme "lista telefônica" em que o livro se tornou.

Obviamente o livro contém mais do que poderia ser coberto num curso de um semestre, e a idéia é permitir que o professor (ou um leitor solitário) tenha bastante flexibilidade. A linguagem tende a ser coloquial sempre que possível, mas alguns formalismos são inevitáveis, embora eu tente mantê-los num nível mínimo.

Existem várias fontes de inspiração para este livro. O capítulo sobre Cadeias de Markov baseia-se muito em KARLIN, S. e TAYLOR, H. (1975) e ROSS, S.M. (2000). No capítulo sobre Séries Temporais, a influência (e inspiração) do Prof. Reinaldo Castro Souza é patente, e também recorro com freqüência ao famoso livro de BOX, G. E. P., JENKINS, G. M. e REINSEL, G. C. (1994). Finalmente, no capítulo 7 (Processos Estocásticos em Finanças), é impossível não citar HULL, J. C. (1993).

Um aviso: este é um livro feito PARA ESTUDANTES! Portanto, espero que a linguagem e os exemplos sejam esclarecedores (e até muitas vezes redundantes, pois prefiro pecar por excesso a pecar por falta) e até engraçados. Minha preocupação maior é didática, e assim muitas vezes a matemática mostrada aqui poderá ser cruelmente deselegante. O que me motivou foi criar um livro que os estudantes de graduação pudessem acompanhar.

Por fim, gostaria de agradecer a todos os alunos que contribuíram para que este projeto finalmente se realizasse, em especial à turma de Processos Estocásticos do semestre 2001.01 da PUC-Rio, que me deu "o maior gás" para levar o projeto do livro adiante e fez críticas, correções e sugestões importantes. É claro que, todos os erros que restaram são "mea culpa, mea culpa, mea culpa..."

Mônica Barros
Rio de Janeiro, Junho de 2002 (FINALMENTE!!!!!)

CAPÍTULO 1: REVISÃO DE PROBABILIDADES

Este capítulo contém uma breve revisão dos conceitos mais importantes da Teoria de Probabilidade. O objetivo é dar uma visão geral do assunto, sem grande profundidade. Algum conhecimento prévio da matéria é essencial para que você consiga aproveitar melhor esta revisão.

1.1. Para que Serve Probabilidade?

O estudo de probabilidades diz respeito a **experiências aleatórias**, cujo **resultado não pode ser conhecido a priori, antes que a experiência seja efetivamente realizada e o seu resultado observado**. Por exemplo, o lançamento de uma moeda ou de um par de dados e a retirada de uma carta de um baralho são experiências aleatórias.

O conceito de probabilidade surgiu a partir da experimentação da vida real, e as origens deste estudo começam no século XVII, a partir do estudo de jogos de azar (dados, cartas, jogos de cassino etc...). Entretanto, o uso de probabilidades é bem mais amplo e a idéia de um fenômeno aleatório é empregada em quase todos os ramos da ciência. **Embora o resultado de uma experiência aleatória seja imprevisível, existe um certo tipo de regularidade, presente neste tipo de experiência, e isto nos permite criar modelos para representar fenômenos aleatórios.**

Por exemplo, ao lançarmos uma moeda sabemos que, se ela não é viciada e a experiência for repetida um número grande de vezes, a proporção de "caras" deve ser igual à proporção de "coroas". Logo, podemos interpretar como probabilidade de "cara" o limite da proporção em que "cara" é observado num número grande de jogadas. Esta interpretação é chamada de "freqüência relativa" e é razoável em certas situações, como em jogos de azar. No entanto, esta maneira de pensar sobre probabilidades é muito restritiva, pois não inclui casos onde a experiência não pode ser repetida indefinidamente.

A interpretação de freqüência relativa não é a única e nem a mais completa interpretação de probabilidade. Por exemplo, como se poderia, a partir desta interpretação, representar a probabilidade de um bebê nascido hoje viver mais de 80 anos? Claramente, cada bebê é único, carrega o seu próprio código genetico e terá sua expectativa de vida afetada por fatores ambientais, entre outros. Neste caso não é possível repetir a experiência "vida" do bebê em condições sempre iguais e é necessário estender a idéia de probabilidade além de um simples limite de freqüências para poder encampar casos como este.
Este tipo de preocupação não será mais estudado aqui. Nós trabalharemos com

uma noção "matemática" de probabilidades, a partir da definição de uma estrutura precisa que inclui as diversas interpretações possíveis.

O objetivo principal do estudo de probabilidades é representar algum fenômeno físico de interesse através de um modelo probabilístico adequado. A partir da escolha deste modelo podemos realizar objetivos secundários, como o cálculo das probabilidades de certos eventos. O primeiro passo é identificar quais são os possíveis resultados da nossa experiência, ou seja, que tipo de resultados são decorrentes da especificação do nosso modelo probabilístico.

Exemplos de fenômenos aleatórios
1- Joga-se uma moeda 3 vezes. Quantas "caras" vão sair?
2- Joga-se um dado. Qual o número que vai sair?
3- O número de caminhões de cerveja que passam numa dada esquina num período qualquer de tempo é também uma experiência aleatória.
4- O número de assassinatos que ocorrem no Rio de Janeiro num fim de semana é um fenômeno aleatório também.
5- A temperatura máxima no Rio de Janeiro no dia 01/01/2100 é uma experiência aleatória.
6- O preço de uma ação no fechamento da bolsa de valores, num dia qualquer, é uma experiência aleatória.

Em todos estes casos, o resultado da experiência não pode ser conhecido antes da realização da própria experiência. No entanto, o fato de o fenômeno ser aleatório não quer dizer que ele seja totalmente desconhecido. Num exemplo muito simples, quando jogamos um dado comum sabemos que os resultados possíveis são 1, 2, 3, 4, 5 ou 6. No exemplo da temperatura, sabemos intuitivamente que faz calor no Rio em janeiro, e então a temperatura máxima deve ser superior, por exemplo, a 20 graus, e inferior a alto, como 50 graus.

1.2. Experiências Aleatórias e Espaços Amostrais

Nesta seção apresentamos algumas definições importantes e a terminologia que será usada no restante do capítulo. Os conceitos de operações com conjuntos (união, interseção e complemento) serão usados com freqüência a seguir.

Definição 1.2.1. Espaço Amostral
Considere uma experiência cujo resultado é aleatório, ou seja, não pode ser conhecido a priori, antes da realização da experiência.

Seja **S** o **conjunto de todos os resultados possíveis desta experiência**. O conjunto **S** é chamado de **espaço amostral**.

Exemplo 1.2.2.
1- Jogamos um dado, o espaço amostral é {1, 2, 3, 4, 5, 6}, ou seja, o número que aparece na face do dado.
2- Uma moeda é jogada 3 vezes e observamos a seqüência de caras (H) e coroas (T). O espaço amostral é o conjunto de seqüências possíveis de caras e coroas, isto é: **S** = {HHH, THH, HTH, HHT, TTH, THT, HTT, TTT}
3- Uma lâmpada é fabricada e testada até queimar e registra-se o tempo de ocorrência deste evento. O espaço amostral é S = {x: x ≥ 0}, o conjunto dos números reais não negativos.
4- Um aluno permanece por 3 horas na porta de um estacionamento de shopping center e registra o número de carros importados que entram no shopping. O espaço amostral é {0, 1, 2, 3...}.
Nos casos 1 e 2 o espaço amostral é finito. No exemplo 3 o espaço amostral é infinito não enumerável e no exemplo 4 é infinito enumerável.

Características de experiências aleatórias
- podem ser repetidas indefinidamente sob as mesmas condições,
- embora não possamos dizer qual resultado em particular vá ocorrer, podemos descrever o conjunto de todos os resultados possíveis (espaço amostral).

Definição 1.2.3. Evento
Um **evento** A é qualquer subconjunto do espaço amostral **S**. Ou seja, um evento é apenas um conjunto de resultados possíveis. Dizemos que um evento A **ocorreu** se o resultado da experiência é um ponto do espaço amostral que é elemento do conjunto A.

Da definição segue diretamente que ambos ∅ e **S** são eventos. Note que, se o espaço amostral é finito e possui n elementos, então existem 2^n subconjuntos deste espaço amostral, isto é, existem 2^n eventos. É claro que não podemos dizer quantos eventos existem associados a um espaço amostral infinito.

Resultado 1.2.4. Propriedades de Eventos
Sejam A e B eventos definidos num espaço amostral **S**.
Então: $A \cup B$, $A \cap B$, A e B são eventos.
Sejam A_1, A_2..., A_n... eventos. Então, uniões e interseções finitas ou infinitas dos A_i's também são eventos.

Definição 1.2.5. Eventos Mutuamente Exclusivos
Dois eventos A e B são mutuamente exclusivos se $A \cap B = \emptyset$. No caso de mais de 2 eventos (A_1, A_2..., A_n) requer-se que todas as interseções entre os A_i sejam vazias, e também precisamos que $A_1 \cap A_2 \cap ... \cap A_n = \emptyset$.

Ou seja, A e B são mutuamente exclusivos se a ocorrência de um deles impede a ocorrência do outro. Por exemplo, se jogamos um dado uma vez e "saiu" o número 5, então certamente não "saiu" qualquer outro número (por exemplo, o 4), e os eventos {sair o número 5} e {sair o número 4} são mutuamente exclusivos.

1.3. Definição Axiomática de Probabilidade

Nesta seção definimos "probabilidade" como uma função com certas características, cujo domínio é o espaço amostral.

Seja A um subconjunto qualquer do espaço amostral **S**. Podemos definir uma função P(.) tal que, se $A \subseteq \mathbf{S}$, então P(A) é a probabilidade de que o resultado da experiência aleatória seja um elemento de A. Esta função P(.) "pega" elementos do espaço amostral e os leva num subconjunto dos reais, o intervalo [0,1].

Definição 1.3.1. Probabilidade
Seja **S** o espaço amostral e A um subconjunto qualquer deste espaço. Uma função de probabilidade que atua sobre este espaço amostral satisfaz:

i) $0 \leq P(A) \leq 1$ para todo $A \subseteq \mathbf{S}$ (1.3.1)
ii) $P(\mathbf{S}) = 1$ (1.3.2)
iii) $P(A_1 \cup A_2 \cup A_3 \cup ...) = P(A_1) + P(A_2) + P(A_3) + ...$ (1.3.3)
onde os A_i são mutuamente exclusivos.

Note que esta última propriedade é válida em particular quando existe um número finito de termos na união.

Estas três propriedades definem o tipo de função que pode ser chamada de "probabilidade". Então, uma probabilidade é uma função que mapeia elementos do espaço amostral em [0,1] tal que a probabilidade do espaço amostral inteiro é um; a probabilidade da união de eventos mutuamente exclusivos é a soma das probabilidades de cada um dos conjuntos na união; e, finalmente, a probabilidade de qualquer subconjunto do espaço amostral é um número no intervalo [0,1].

Resultado 1.3.2. Propriedades das Probabilidades
Seja A um subconjunto qualquer de **S** e $\overline{A}$ o complemento de A. Seja Pr (.) uma probabilidade definida no espaço amostral **S**. As seguintes propriedades são válidas e decorrem da definição de probabilidade:

i) $Pr(\varnothing) = 0$ (1.3.4)
ii) $\forall A \subseteq \mathbf{S} \Rightarrow Pr(\overline{A}) = 1 - Pr(A)$ onde $\overline{A}$ é o complemento de A (1.3.5)
iii) $\forall A \subseteq \mathbf{S} \Rightarrow P(A) \leq P(\mathbf{S})$
iv) $\forall A \subseteq \mathbf{S} \Rightarrow 0 \leq Pr(A) \leq 1$
v) $\forall A_1, A_2 \subseteq \mathbf{S}$ tais que $A_1 \subseteq A_2 \Rightarrow Pr(A_1) \leq Pr(A_2)$ (1.3.6)

As expressões anteriores são bastante utilizadas na prática.

A expressão (1.3.6) resulta num certo tipo de "ordem" dentro do espaço amostral e diz simplesmente que, se um evento A_1 está contido noutro, a probabilidade de A_1 é menor ou igual à probabilidade do evento que o contém.

A propriedade a seguir é uma das mais importantes na prática e nos permite calcular a probabilidade da união de eventos que não são disjuntos.

vi) $\forall A_1, A_2 \subset \mathbf{S}$ então $Pr(A_1 \cup A_2) = Pr(A_1) + Pr(A_2) - Pr(A_1 \cap A_2)$ (1.3.7)

Em particular, se A_1 e A_2 são conjuntos disjuntos, então:

$Pr(A_1 \cup A_2) = Pr(A_1) + Pr(A_2)$.

vii) Para quaisquer 3 eventos A_1, A_2 e A_3 em **S** temos:

$Pr(A_1 \cup A_2 \cup A_3) = Pr(A_1) + Pr(A_2) + Pr(A_3) - Pr(A_1 \cap A_2) -$

$- Pr(A_1 \cap A_3) - Pr(A_2 \cap A_3) + Pr(A_1 \cup A_2 \cup A_3)$

Exemplo 1.3.3.
Suponha que A e B são eventos mutuamente exclusivos e Pr (A) = 0.20 e Pr (B) = 0.30. Então:

i) $Pr(\overline{A}) = 1 - 0.20 = 0.80$
ii) $Pr(\overline{B}) = 1 - 0.30 = 0.70$
iii) $Pr(A \cup B) = 0.2 + 0.3 = 0.50$ (pois A e B mutuamente exclusivos)
iv) $Pr(A \cap B) = 0$ (pois A e B mutuamente exclusivos)
v) $Pr(\overline{A} \cap \overline{B}) = Pr(\overline{A \cup B}) = 1 - Pr(A \cup B) = 1 - \{Pr(A) + Pr(B)\} = 1 - 0.5 = 0.5$ (usando as leis de DeMorgan e o fato de A e B serem mutuamente exclusivos)

Exemplo 1.3.4.
Suponha que A e B **não são** mutuamente exclusivos e Pr (A) = 0.20, Pr (B) = 0.30 e $Pr(A \cap B) = 0.10$. Então:

i) $Pr(\overline{A}) = 1 - 0.20 = 0.80$
ii) $Pr(\overline{B}) = 1 - 0.30 = 0.70$
iii) $Pr(A \cup B) = Pr(A) + Pr(B) - Pr(A \cap B) = 0.2 + 0.3 - 0.1 = 0.40$
iv) $Pr(A \cap B) = 0.10$ (dado)
v) $Pr(\overline{A} \cap \overline{B}) = Pr(\overline{A \cup B}) = 1 - Pr(A \cup B) =$
$= 1 - \{Pr(A) + Pr(B) - Pr(A \cap B)\} = 1 - 0.4 = 0.6$

Muito bem...

Agora temos uma definição do tipo de função que pode ser chamada de probabilidade, mas isto não resolve inteiramente nosso problema. Como é que, na prática, estabelecemos valores para probabilidades.
Em outras palavras, o que nos leva a dizer que a probabilidade de "sair" o número 2 na jogada de um dado é 1/6?

Na prática, probabilidades são estabelecidas com base em: experiências ou observações prévias, considerações analíticas ou experimentais ou "chutes educados".

A idéia de estabelecer probabilidades a partir de experiências prévias está intimamente relacionada com a noção de **freqüência relativa**.

Seja E uma experiência aleatória e supomos que a experiência pode ser repetida n vezes, sempre nas mesmas condições. Sejam A e B eventos quaisquer, e sejam n_a e n_b os números de ocorrências dos eventos A e B nas n repetições da experiência E.

Por exemplo, suponha que E é a experiência: jogar um dado e observar o número que saiu. Seja A o evento: saiu um número par e B o evento: saiu o número 6. Joga-se o dado 20 vezes, e observam-se as seguintes freqüências para cada face do dado:

Face do dado	Freqüência
1	4
2	4
3	3
4	5
5	2
6	2

Então: $n_a = 11$ e $n_b = 2$, e $n = 20$ (número de repetições da experiência).
Intuitivamente, se tivéssemos jogado o dado um número bem maior de vezes, nós nos sentiríamos mais confiantes em afirmar que a probabilidade de uma das faces do dado seria igual ao número de vezes em que aquela face "saiu" dividido pelo número de repetições da experiência.

Definição 1.3.5. Freqüência Relativa
A freqüência relativa de um evento A, denotada por f_A é definida por:
$f_A = n_a / n$
onde n_a indica o número de ocorrências do evento A dentre as n repetições da experiência.

A partir da definição, vemos que as freqüências relativas dos eventos A e B são, respectivamente, 11/20 = 0.55 e 2/20 = 0.10.

Propriedades das Freqüências Relativas

1- $0 \leq f_A \leq 1$
2- $f_A = 0$ se, e somente se, o evento A não ocorre em nenhuma das n repetições da experiência.
3- $f_A = 1$ se, e somente se, o evento A ocorreu em todas as repetições da experiência.
4- Se A e B são eventos mutuamente exclusivos, então: $f_{A \cup B} = f_A + f_B$, isto é, as freqüências relativas se tornam aditivas neste caso.
5- Quando n (o número de repetições) tende a infinito, f_A tende a se estabilizar e converge para um número, que é a **probabilidade** do evento A.

Esta última propriedade é fundamental. É ela que nos permite intuir que a probabilidade de "sair" o número 2 numa jogada de um dado é 1/6.
Assim, a definição "clássica" da probabilidade de um evento é: Pr (A) é o limite da freqüência relativa do evento A quando o número de repetições tende a infinito.

1.4. Probabilidade Condicional e Independência

Como será que a probabilidade de um evento muda após sabermos que um outro evento ocorreu? Isso nos leva à idéia de probabilidade condicional, uma das mais importantes da teoria de probabilidades. Esta noção está intimamente relacionada ao fato da ocorrência de um evento afetar, em certos casos, a probabilidade de ocorrência de outro evento.

Uma probabilidade condicional nada mais é do que uma probabilidade calculada não a partir do espaço amostral inteiro S, mas a partir de um subconjunto de S.

Considere o seguinte exemplo: um grupo de 50 pessoas inclui 40 com diploma de curso superior, 20 microempresários e 10 que são, ao mesmo tempo, portadores de diploma do curso superior e microempresários.

Sejam os eventos:
A = {pessoa tem diploma de curso superior}
B = {pessoa é um microempresário}

Podemos escrever então que a probabilidade de uma pessoa neste grupo ter diploma de curso superior é Pr (A) = 0.40, a probabilidade de alguém ser microempresário é Pr (B) = 0.20 e a probabilidade de uma pessoa ser ambas as coisas é Pr ($A \cap B$) = 0.10.

Agora suponha que consideramos o seguinte evento: a pessoa é microempresá-

ria **sabendo-se que** ela tem diploma de curso superior. A probabilidade deste evento deve ser diferente da probabilidade de a pessoa ser microempresária, porque agora o espaço amostral não consiste mais nas 50 pessoas que existiam no total, mas apenas naquelas que possuem diploma de curso superior. Como calcular esta probabilidade condicional? Examine agora apenas o subgrupo de 40 pessoas que têm diploma universitário. Neste subgrupo, existem 10 que são também microempresários. Logo, a nossa intuição diz que a probabilidade condicional de alguém ser microempresário, sabendo que esta pessoa tem diploma universitário, é 10/40 = 25%. A próxima definição confirma esta intuição!

Definição 1.4.1. Probabilidade Condicional

A probabilidade condicional do evento A dado o evento B é definida como:

$$\mathbf{Pr(A \mid B) = Pr(A \cap B) / Pr(B)} \quad (1.4.1)$$

desde que Pr (B) > 0

A probabilidade condicional $Pr(A \mid B)$ **não é definida** se Pr (B) = 0.

Ao reordenarmos a expressão anterior encontramos:

$Pr(A \cap B) = Pr(A \mid B)\ Pr(B)$ se Pr (B) > 0

e

$Pr(A \cap B) = Pr(B \mid A)\ Pr(A)$ se Pr (A) > 0

Exemplo 1.4.2.

Jogam-se 2 dados. Observou-se que a soma dos 2 dados é um número menor que 8. Qual a probabilidade de que a soma dos 2 dados seja um número ímpar?

Solução

As probabilidades das somas dos dados estão na próxima tabela.

Soma dos dados	Probabilidade
2	1/36
3	2/36
4	3/36
5	4/36
6	5/36
7	6/36
8	5/36
9	4/36
10	3/36
11	3/36
12	1/36

Seja T a soma dos dados, e A e B os seguintes eventos: A = {T é ímpar} e B = {T < 8}.

$A \cap B$ é o evento {T é ímpar e < 8}, ou seja, é o evento {T = 3 ou T = 5 ou T = 7}.

Também, os eventos {T = 3}, {T = 5} e {T = 7} são disjuntos, logo a probabilidade da sua união é a soma das probabilidades de cada um dos eventos.

$Pr(A \cap B) = Pr(T = 3) + Pr(T = 5) + Pr(T = 7) = 2/36 + 4/36 + 6/36 = 12/36 = 1/3$

$Pr(A) = Pr(T \text{ ímpar}) = Pr(T = 3) + Pr(T = 5) + Pr(T = 7) + Pr(T = 9) + Pr(T = 11)$
$= 2/36 + 4/36 + 6/36 + 4/36 + 2/36 = 18/36 = ½$

$Pr(B) = Pr(T < 8) = Pr(T=2) + Pr(T=3) + \ldots + Pr(T=7) = 21/36 = 7 / 12$

$Pr(A \mid B) = Pr\{T \text{ ímpar} \mid T < 8\} = Pr(T \text{ ímpar e } T < 8) / Pr(T < 8) =$
$(1/3)/(7/12) = 4/7$

Note que Pr (A) = Pr (T ímpar) = 1/2 é diferente da probabilidade condicional $Pr(A \mid B) = 4/7$. Logo, a informação de que o evento B ocorreu é relevante para a probabilidade do evento A. Em outras palavras: **saber que B ocorreu, modifica a probabilidade de A.**

Probabilidades condicionais são "realmente" probabilidades, isto é, satisfazem todas as propriedades de uma função que possa ser chamada de "probabilidade". Então:

1) $0 \leq Pr(A \mid B) \leq 1$
2) $Pr(\mathbf{S} \mid B) = 1$ onde **S** é o espaço amostral
3) Se $A_1, A_2, A_3 \ldots$ é uma seqüência enumerável de eventos **disjuntos** então:
$Pr(A_1 \cup A_2 \cup A_3 \cup \ldots) = Pr(A_1) + Pr(A_2) + Pr(A_3) + \ldots$

Note que, se A e B são **mutuamente exclusivos,** então $Pr(A \cap B) = 0$ e $Pr(A|B) = Pr(B|A) = 0$.

Mas, nem sempre a ocorrência de um evento afeta a probabilidade de outro. Podemos pensar numa coleção de situações inusitadas. Por exemplo, será que a probabilidade de chover hoje afeta a minha probabilidade de ganhar na loteria? Intuitivamente, NÃO! Todo mundo diria que uma coisa não tem nada a ver com a outra. Isso nos leva à idéia de independência entre eventos, mostrada a seguir.

Definição 1.4.3. Eventos Independentes

Dois eventos A e B são **independentes** se, e somente se:

$$Pr(A \cap B) = Pr(A).\ Pr(B) \quad (1.4.2)$$

Independência é uma propriedade muito forte e tem um impacto direto sobre as probabilidades condicionais, como veremos.

Resultado 1.4.4. Probabilidade Condicional de Eventos Independentes
Se A e B são eventos independentes, então, pela definição de independência:

$Pr(A \cap B) = Pr(A).Pr(B)$. Assim, da definição de probabilidade condicional

$$Pr(A \mid B) = \frac{Pr(A \cap B)}{Pr(B)} = \frac{Pr(A).Pr(B)}{Pr(B)} = Pr(A)$$

Analogamente, se A e B são independentes, $Pr(B|A) = Pr(B)$.

Ou seja, quando os eventos A e B são **independentes**, a probabilidade **condicional** de A quando sabemos que B ocorreu, **é a mesma** que a probabilidade **incondicional** de A. Em outras palavras, se A e B são independentes, saber que B ocorreu **não altera** a probabilidade de A.

A independência de dois eventos A e B tem conseqüência também para os complementos destes eventos. Se A e B são independentes, os seus complementos também são independentes.

Muitas vezes é interessante reescrever a expressão da probabilidade condicional para calcular a probabilidade de ocorrência de ambos A e B.

Pela definição: $Pr(A|B) = \frac{Pr(A \cap B)}{Pr(B)}$

e por simetria: $Pr(B|A) = \frac{Pr(A \cap B)}{Pr(A)}$

Logo:

$$Pr(A \cap B) = Pr(A)\,Pr(B|A) = Pr(B)\,Pr(A|B) \qquad (1.4.3)$$

Em particular podemos utilizar a expressão (1.4.3) na definição das probabilidades condicionais, de forma a relacionar as probabilidades condicionais $Pr(B|A)$ e $Pr(A|B)$. Esta regra é útil em casos onde é difícil calcular uma das probabilidades condicionais, mas é fácil calcular a probabilidade condicional "inversa".

$$Pr(A \mid B) = \frac{Pr(A \cap B)}{Pr(B)} = \frac{Pr(B \mid A).Pr(A)}{Pr(B)} \qquad (1.4.4)$$

e,

$$Pr(B|A) = \frac{Pr(A \cap B)}{Pr(A)} = \frac{Pr(A \mid B).Pr(B)}{Pr(A)} \qquad (1.4.5)$$

Estas duas fórmulas são na verdade a forma mais simples de expressar o Teorema de Bayes, que será estudado na próxima seção.

Exemplo 1.4.5.
Uma caixa contém R bolas vermelhas e B bolas azuis. Vamos tirar 2 bolas da caixa sem repô-las. Qual a probabilidade p de a primeira bola ser vermelha e a segunda, azul?

Solução
Sejam A e B os eventos: A = {1ª bola é vermelha}, B = {2ª bola é azul}. Se o evento A ocorreu, uma bola vermelha foi tirada da caixa. Como não há reposição, a probabilidade de obter uma bola azul na 2ª retirada é:

$$Pr(B|A) = \frac{R}{R+B-1}$$

O evento $(A \cap B)$ é o evento: {1ª bola é vermelha e a 2ª bola é azul},
e sua probabilidade é:

$$Pr(A \cap B) = p = Pr(A)\,Pr(B \mid A) = \frac{R}{R+B}.\frac{B}{R+B-1}$$

Exemplo 1.4.6.
Usando um baralho comum, com 52 cartas, qual a probabilidade de que a primeira e a segunda cartas selecionadas sem reposição sejam ases?

Solução
Existem quatro ases no baralho. Sejam A e B os seguintes eventos: A = {primeira carta é ás} e B = {segunda carta é ás}. Desejamos calcular a probabilidade da interseção de A e B e podemos fazer isso de uma maneira natural, condicionando o evento à ocorrência de um ás na primeira retirada.

$Pr(A) = 4/52$ (pois existem ainda 52 cartas no baralho, e 4 delas são ases).
$Pr(B|A) = 3/51$, que é a razão entre o número de ases restantes pelo número de cartas restantes. A partir destas probabilidades encontramos facilmente a probabilidade da interseção de A e B: $Pr(A \cap B) = Pr(A) \cdot Pr(B|A) = (4/52) \cdot (3/51) = 1/221$.

Exemplo 1.4.7.
Tomou-se uma amostra de 1000 pessoas num shopping center com o objetivo de verificar a relação entre o número de cartões de crédito e a renda familiar (em salários mínimos). Os resultados obtidos estão na tabela a seguir.

Número de cartões → Renda ↓	Não tem cartão de crédito	1 cartão de crédito	Mais de 1 cartão de crédito
até 10 S. M.	250	80	20
10 a 20 S. M.	100	200	40
20 a 30 S. M.	50	40	60
mais de 30 S. M.	20	40	100

Note que a tabela anterior nos dá as contagens, isto é, o número de pessoas em cada categoria. Por exemplo, das 1000 pessoas amostradas, 100 têm mais de 1 cartão de crédito e renda familiar superior a 30 salários mínimos. Logo, neste caso, podemos supor que a probabilidade de um indivíduo ter renda familiar acima de 30 S. M. e mais de 1 cartão é 1000/1000=0.10.

Uma pessoa é escolhida ao acaso. Calcule as seguintes probabilidades:
a) De que a pessoa tenha renda em cada uma das 4 categorias.
b) Qual a probabilidade de uma pessoa não ter cartão de crédito? Ter 1 cartão de crédito? Ter mais de 1 cartão de crédito?
c) Dado que a pessoa tem renda entre 10 e 20 S. M; qual a probabilidade de que ela não tenha cartão de crédito?
d) Dado que uma pessoa tem mais de 1 cartão de crédito, qual a probabilidade de sua renda familiar estar acima de 30 S. M?
e) Existe independência entre faixa de renda e o número de cartões de crédito? Por quê?

Solução

a) Pr (renda até 10 S. M.) = (250+80+20)/1000 = 350/1000 = 0.35
Pr (renda entre 10 e 20 S. M.) = 340/1000 = 0.34
Pr (renda entre 20 e 30 S. M.) = 150/1000 = 0.15
Pr (renda acima de 30 S. M.) = 160/1000 = 0.16

b) Pr (não ter cartão de crédito) = 420/1000 = 0.42
Pr (1 cartão de crédito) = 0.36
Pr (mais de 1 cartão de crédito) = 0.22

Nos itens c) e d) a seguir, lembre-se da definição de probabilidade condicional de um evento A dado um evento B, que é: Pr (A|B) = Pr (A ∩ B)/Pr (B) (desde que o denominador não seja zero!).

c) Pr (não ter cartão | renda entre 10 e 20 S. M.) = 100/340 = 0.29
d) Pr (renda acima de 30 S. M. | mais de um cartão) = 100/220 = 0.45.
e) Lembre-se da definição de independência entre dois eventos: A e B são independentes se, e somente se: Pr (A ∩ B) = Pr (A).Pr (B). Neste caso, para provar que renda familiar e número de cartões de crédito são independentes, precisamos verificar (para **todas** as células) que a probabilidade de cada célula na tabela dada é igual ao produto das probabilidades da respectiva linha e coluna em que a célula está situada. Mas, isso claramente não é verdade. Por exemplo, ao olharmos para a célula do canto inferior direito da tabela, observamos que:

Pr (mais de um cartão e renda acima de 30 S. M.) = 0.10, o que é claramente diferente do produto: Pr (mais de um cartão).Pr (renda acima de 30 S. M.) = (0.22).(0.16) = 0.035.

Logo, renda familiar e número de cartões de crédito são **dependentes**.

A esta altura deve estar claro que as noções de independência e probabilidade condicional estão intimamente ligadas. O efeito da independência de A e B é tornar as probabilidades incondicionais iguais às respectivas probabilidades condicionais. A definição de independência deve ser estendida a mais de 2 eventos e para que n eventos sejam independentes não basta que eles sejam independentes dois a dois.

Independência para mais de 2 eventos

A idéia de independência pode (e deve) ser estendida para mais de dois eventos e diversas condições devem ser satisfeitas, como mostrado a seguir.

Definição 1.4.8. Independência Para Mais de Dois Eventos

Sejam $A_1, A_2..., A_n$ eventos, onde $n \geq 3$. Estes n eventos são independentes se, e somente se:

i) $Pr(A_1 \cap A_2 \cap ... \cap A_n) = Pr(A_1).Pr(A_2)...Pr(A_n)$ e

ii) Toda subcoleção de eventos contendo mais de 2 e menos de n eventos é independente.

Podemos escrever a probabilidade da interseção de n eventos como um produto de probabilidades condicionais e incondicionais. Este resultado é mostrado no próximo teorema.

Teorema 1.4.9. Probabilidades de Interseções de Eventos

Sejam $A_1, A_2..., A_n$ eventos quaisquer tais que:

$Pr(A_1) > 0$,

$Pr(A_1 \cap A_2) > 0$,

.....

$Pr(A_1 \cap A_2 \cap ... \cap A_n) > 0$. Então:

$Pr(A_1 \cap A_2 \cap ... \cap A_n) = Pr(A_1).Pr(A_2 | A_1).Pr(A_3 | A_1 \cap A_2)...Pr(A_n | A_1 \cap A_2 \cap ... \cap A_{n-1})$

Demonstração - omitida

Em particular, o teorema nos diz que:

$$Pr(A_1 \cap A_2) = Pr(A_1).Pr(A_2 | A_1) \text{ e} \quad (1.4.6)$$

$$Pr(A_1 \cap A_2 \cap A_3) = Pr(A_1).Pr(A_2 | A_1).Pr(A_3 | (A_1 \cap A_2)) \quad (1.4.7)$$

Exemplo 1.4.10.

Uma caixa contém 8 bolas brancas e 6 bolas azuis. Uma bola é selecionada aleatoriamente e então é jogada fora e substituída por uma bola da cor oposta.
a) Qual a probabilidade de que a segunda bola selecionada seja branca?
b) Qual a probabilidade de que a segunda bola selecionada seja azul?

Solução

a) Seja A_i o evento: {bola azul encontrada na i-ésima retirada}. Note que o evento B_i = {bola branca encontrada na i-ésima retirada} é apenas o complemento de A_i. Pela composição inicial das bolas na caixa, é claro que: $Pr(A_1) = 6/14$ e $Pr(B_1) = 8/14$.

O evento B_2 (bola branca na 2ª retirada) pode ser escrito como:
$B_2 = (B_2 \cap A_1) \cup (B_2 \cap B_1)$ onde $(B_2 \cap B_1)$ é o evento {bolas brancas nas 2 primeiras retiradas} e $(B_2 \cap A_1)$ indica {bola azul na 1ª retirada e branca na 2ª retirada}. Também é importante notar que $(B_2 \cap A_1)$ e $(B_2 \cap B_1)$ são mutuamente exclusivos, o que facilita o cálculo da probabilidade desejada. As probabilidades dos eventos $(B_2 \cap A_1)$ e $(B_2 \cap B_1)$ podem ser encontradas a partir das probabilidades condicionais do que aconteceu na 2ª retirada dado o que foi observado na 1ª retirada.

Suponha que a 1ª retirada seja de uma bola azul. Então, ANTES da 2ª retirada, a caixa contém 9 bolas brancas e 5 bolas azuis. Se a 1ª retirada consistiu numa bola branca, ANTES da 2ª retirada, a caixa contém 7 bolas brancas e 7 bolas azuis.

Então, as probabilidades condicionais de uma bola branca na 2ª retirada sabendo o que aconteceu na 1ª retirada são trivialmente fáceis de calcular, basta apenas pensar na composição da caixa após a 1ª retirada (mas antes da 2ª retirada). Especificamente: $Pr(B_2 \mid A_1) = 9/14$ e $Pr(B_2 \mid B_1) = 7/14$.

Pela definição de probabilidade condicional:

$$Pr(B_2 \cap B_1) = Pr(B_2|B_1).\ Pr(B_1) = \frac{7}{14}.\frac{8}{14} = \frac{56}{196} = 28.57\%$$

e também:

$$Pr(B_2 \cap A_1) = Pr(B_2|A_1).\ Pr(B_1) = \frac{9}{14}.\frac{6}{14} = \frac{54}{196} = 27.55\%$$

Finalmente:

$$Pr(B_2) = Pr(B_2 \cap A_1) + Pr(B_2 \cap B_1) = \frac{56+54}{196} = 56.12\%$$

b) O evento A_2 (bola azul na 2ª retirada) pode ser escrito como:
$A_2 = (A_2 \cap A_1) \cup (A_2 \cap B_1)$ onde $(A_2 \cap A_1)$ representa o evento {bolas azuis nas 2 primeiras retiradas} e $(A_2 \cap B_1)$ significa {bola branca na 1ª retirada e azul na 2ª retirada}. Pelos mesmos argumentos do item anterior: $Pr(A_2 \mid A_1) = 5/14$ e $Pr(A_2 \mid B_1) = 7/14$. Logo, a probabilidade de uma bola azul na 2ª retirada é:

$$Pr(A_2) = Pr(A_2 \cap A_1) + Pr(A_2 \cap B_1) = Pr(A_2 \mid A_1).\ Pr(A_1) + Pr(A_2 \mid B_1).\ Pr(B_1)$$

$$= \frac{5}{14}.\frac{6}{14} + \frac{7}{14}.\frac{8}{14} = \frac{86}{196} = 43.88\%$$

Neste caso, existe uma solução MUITO MAIS FÁCIL. Como só existem bolas de 2 cores, então é óbvio que a probabilidade de uma bola azul na 2ª retirada é apenas 1 menos a probabilidade de uma bola branca na 2ª retirada, ou seja:
1 – 110/196 = 86/196!

1.5. Teorema de Bayes

O Teorema de Bayes é um resultado fundamental em probabilidade com inúmeras aplicações na prática. Em linhas gerais, sempre que pudermos "dividir" inteiramente o espaço amostral em classes mutuamente exclusivas, podemos calcular a probabilidade condicional de um evento qualquer sabendo que estamos numa destas subclasses. É conveniente definir antes o que é uma partição do espaço amostral, que será usada para obter o teorema de Bayes.

Definição 1.5.1. Partição do Espaço Amostral
Os eventos $B_1, B_2..., B_k$ formam uma **partição** do espaço amostral **S** se:
1) $B_i \cap B_j = \varnothing$ para todo $i \neq j$
2) $\cup B_i = \mathbf{S}$
3) $Pr(B_i) > 0$ para todo i
Por exemplo, na figura a seguir o retângulo representa o espaço amostral e os conjuntos $B_1, B_2..., B_8$ formam uma partição do espaço amostral.

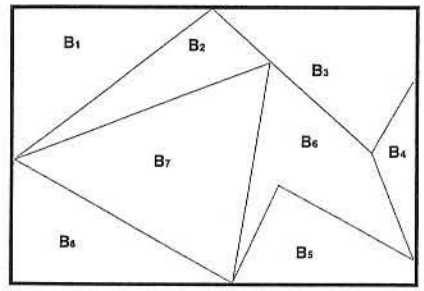

Em outras palavras, quando a experiência aleatória é realizada, apenas um dos B_i ocorre. Em geral podemos escrever qualquer evento no espaço amostral em termos das suas interseções com os conjuntos que formam uma partição do espaço amostral.

Por exemplo, se A é um evento qualquer em **S** e $B_1, B_2..., B_k$ formam uma partição de **S** então:
$A = (A \cap B_1) \cup (A \cap B_2) \cup (A \cap B_3) \cup ... (A \cap B_k)$
onde os $(A \cap B_i)$ são disjuntos, o que resulta em:
$Pr(A) = Pr(A \cap B_1) + Pr(A \cap B_2) + Pr(A \cap B_3) + ... + Pr(A \cap B_k)$

Por exemplo, na figura a seguir A é a elipse e $B_1, B_2..., B_8$ formam uma partição do espaço amostral, como já indicado.

Então:

$$Pr(A) = Pr(A \cap B_1) + Pr(A \cap B_2) + Pr(A \cap B_3) + ... + Pr(A \cap B_8)$$

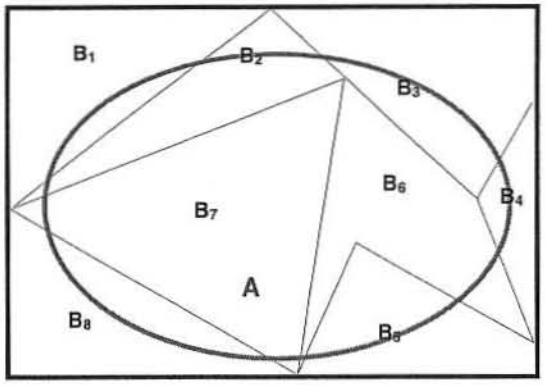

Teorema 1.5.2. Teorema da Probabilidade Total
Sejam $B_1, B_2..., B_k$ uma partição de **S** e A um evento qualquer em **S**. Então:

$$\mathbf{Pr(A) = Pr(B_1) \cdot Pr(A|B_1) + Pr(B_2) \cdot Pr(A|B_2) + ... + Pr(B_k) \cdot Pr(A|B_k)}$$

(1.5.1)

A demonstração deste resultado decorre diretamente do que já foi exposto nas seções anteriores, lembrando apenas que $Pr(A \cap B_i) = Pr(B_i) \cdot Pr(A|B_i)$ para i =1, 2..., k.

Um caso particular importante ocorre quando consideramos apenas 2 eventos, B e B^* (o complemento de B), como uma partição do espaço amostral. Neste caso: $Pr(A) = Pr(B) \cdot Pr(A|B) + Pr(B^*) \cdot Pr(A|B^*)$

Teorema 1.5.3. Teorema da Multiplicação
Já foi enunciado antes. É apenas a definição de probabilidade condicional expressa de outra maneira.

$$\mathbf{Pr(A \cap B) = Pr(A|B) \cdot Pr(B) = Pr(B|A) \cdot Pr(A)} \qquad (1.5.2)$$

O próximo resultado é um dos mais importantes da teoria das probabilidades e generaliza o teorema da multiplicação, permitindo que se "invertam" probabilidades dada uma partição do espaço amostral.

Teorema 1.5.4. Teorema de Bayes
Suponha que $B_1, B_2..., B_k$ formam uma partição de **S** e A um evento qualquer em **S**. Então:

$$Pr(B_i|A) = \frac{Pr(A|B_i) \cdot Pr(B_i)}{\sum_{j=1}^{n} Pr(A|B_i) \cdot Pr(B_j)} \qquad (1.5.3)$$

Demonstração

$$Pr(B_i|A) = \frac{Pr(B_i \cap A)}{Pr(A)} = \frac{Pr(B_i \cap A)}{\sum_{j=1}^{n} Pr(A|B_j) \cdot Pr(B_j)}$$

Onde a segunda desigualdade foi obtida aplicando-se o teorema da probabilidade total à probabilidade do evento A.

O teorema de Bayes é importante porque nos permite inverter probabilidades condicionais. Às vezes é fácil calcular Pr (A|B), mas o que desejamos conhecer é Pr (B|A). O teorema de Bayes nos permite calcular Pr (B|A) em termos de Pr (A|B).

O teorema de Bayes nada mais é do que a "mistura" dos teoremas da probabilidade total e da multiplicação.

A grande dificuldade encontrada ao tentar resolver problemas envolvendo probabilidades condicionais é "montar" o problema - escreva explicitamente todos os possíveis eventos de interesse.

Exemplo 1.5.5.
Os funcionários de uma empresa se dividem em 3 grupos: economistas, engenheiros e analistas de sistemas. Estes funcionários podem ocupar cargos técnicos ou gerenciais. Sabemos que:

40 % dos funcionários são economistas,
30 % dos funcionários são engenheiros e
30 % dos funcionários são analistas de sistemas.

O percentual de cada grupo ocupando cargos gerenciais é: 30 % dos economistas, 40 % dos engenheiros, 10 % dos analistas de sistemas. Seleciona-se um funcionário aleatoriamente. Qual a probabilidade de que ocupe um cargo gerencial?

Solução
Considere os eventos:
A_1 = {economistas}, A_2 = {engenheiros}, A_3 = {analistas de sistemas},
G = {cargo de gerência}. Sabemos que:

$Pr(A_1) = 0.40$, $Pr(A_2) = 0.30$, $Pr(A_3) = 0.30$.

Também é dado que:
$Pr(G|A_1) = 0.30$, $Pr(G|A_2) = 0.40$ e $Pr(G|A_3) = 0.10$

Desejamos encontrar Pr (G). Mas:

$$Pr(G) = Pr(G \cap A_1) + Pr(G \cap A_2) + Pr(G \cap A_3) =$$
$$= Pr(A_1).\ Pr(G|A_1) + Pr(A_2).\ Pr(G|A_2) + Pr(A_3).\ Pr(G|A_3)$$

A substituição dos valores dados resulta em:
$Pr(G) = (0.40)(0.30) + (0.30)(0.40) + (0.30)(0.40) = (0.30)(0.90) = 27\%$

Exemplo 1.5.6.
Considere a situação do exemplo anterior. Seleciona-se uma pessoa ao acaso na empresa e sabe-se que ela ocupa um cargo de gerência. Qual a probabilidade dela ter vindo de cada um dos 3 grupos, ou seja, **dado que** a pessoa é um gerente, qual a probabilidade dela ser economista, engenheiro ou analista de sistemas?

Solução
Queremos descobrir $Pr(A_i|G)$ para i = 1, 2, 3. Isto é uma aplicação direta do teorema de Bayes, já facilitada por que conhecemos o denominador (Pr (G)). Note que a probabilidade de ocupar um cargo de gerência é: Pr (G) = 0.27 (já calculado no exemplo anterior). Então:

$Pr(A_1|G) = Pr(G|A_1).\ Pr(A_1)/0.27 = (0.30)(0.40)/0.27 = 44.4\%$
$Pr(A_2|G) = Pr(G|A_2).\ Pr(A_2)/0.27 = (0.40)(0.30)/0.27 = 44.4\%$
$Pr(A_3|G) = Pr(G|A_3).\ Pr(A_3)/0.27 = (0.30)(0.10)/0.27 = 11.2\%$

Exemplo 1.5.7. Identificando a Fonte de um Item com Defeito
Três máquinas M_1, M_2, M_3 são usadas para fabricar o mesmo tipo de produto. Suponha que 20% dos itens foram produzidos por M_1, 30% dos itens foram produzidos por M_2 e 50% dos itens foram produzidos por M_3. Suponha também que:

1% dos itens fabricados por M_1 têm defeito,
2% dos itens fabricados por M_2 têm defeito e
3% dos itens fabricados por M_3 têm defeito

Um produto é selecionado aleatoriamente e é defeituoso. Qual a probabilidade de que este produto tenha sido fabricado por M_2?

Solução
Considere os eventos: A_i = {o item foi fabricado pela máquina M_i}, i = 1, 2, 3 e B = {o item é defeituoso}. Queremos achar $Pr(A_2|B)$. Por hipótese:
$Pr(A_1) = 0.2$, $Pr(A_2) = 0.3$, $Pr(A_3) = 0.5$

Também:

$Pr(B|A_1) = 1\% = 0.01$
$Pr(B|A_2) = 0.02$
$Pr(B|A_3) = 0.03$

Do teorema de Bayes:

$$Pr(A_2|B) = \frac{Pr(A_2).\ Pr(B|A_2)}{\sum_{j=1}^{3} Pr(A_j).\ Pr(B|A_j)}$$

$$Pr(A_2|B) = \frac{(0.3)(0.02)}{(0.2)(0.01)+(0.3)(0.02)+(0.5)(0.03)} = 0.20$$

No exemplo anterior, $Pr(A_i)$ é chamado **probabilidade a priori** de que o item selecionado tenha sido produzido pela máquina M_i, pois é a probabilidade deste evento **antes** de selecionarmos o item e descobrirmos se ele tem defeito ou não. As probabilidades $Pr(A_i|B)$ são chamadas **probabilidades a posteriori,** pois representam a probabilidade de o produto ter sido fabricado pela máquina M_i **depois** de sabermos que o produto é defeituoso.

Exemplo 1.5.8.

Uma empresa de crédito precisa saber como a inadimplência está distribuída entre seus clientes. Sabe-se que:

10% dos clientes pertencem à classe A.
20% dos clientes pertencem à classe B.
30% dos clientes pertencem à classe C.
40% dos clientes pertencem à classe D.

Dentre os clientes da classe A, 5% estão inadimplentes.
Dentre os clientes da classe B, 8% estão inadimplentes.
Dentre os clientes da classe C, 10% estão inadimplentes.
Dentre os clientes da classe D, 2% estão inadimplentes.

Um cliente é escolhido aleatoriamente e está inadimplente. Qual a probabilidade dele pertencer a cada uma das classes?

Solução
Esta é também (vide exemplo anterior) uma aplicação direta do Teorema de Bayes. A partição é, neste caso, formada pelas classes sócio-econômicas. Seja I o evento: {o cliente está inadimplente}. Então procuramos encontrar Pr (A| I), Pr (B| I), Pr (C| I) e Pr (D| I).

$$Pr(A \mid I) = \frac{Pr(I \mid A).\ Pr(A)}{Pr(I \mid A).\ Pr(A) + Pr(I \mid B).\ Pr(B) + Pr(I \mid C).\ Pr(C) + Pr(I \mid D).\ Pr(D)} =$$

$$= \frac{(5\%)\ (10\%)}{(5\%)\ (10\%) + (8\%)\ (20\%) + (10\%)\ (30\%) + (2\%)\ (40\%)} =$$

$$\frac{50/10000}{(50+160+300+80)/10000} = \frac{50}{590} = 8.47\%$$

Analogamente:

$$Pr(B|I) = \frac{160/10000}{(50+160+300+80)/10000} = \frac{160}{590} = 27.12\%$$

$$Pr(C|I) = \frac{300/10000}{(50+160+300+80)/10000} = \frac{300}{590} = 50.85\% \text{ e}$$

$$Pr(C|I) = \frac{80/10000}{(50+160+300+80)/10000} = \frac{80}{590} = 13.56\%$$

Obviamente, a soma destas probabilidades condicionais é 100%. Também, no processo de cálculo, indiretamente calculamos que a probabilidade de uma pessoa escolhida aleatoriamente dentro do conjunto de clientes estar inadimplente é 320/10000 = 3.2%.

1.6. Variáveis Aleatórias, Funções Densidade de Probabilidade, Momentos de uma Variável Aleatória

Seja **S** o espaço amostral. Muitas vezes este espaço não consiste num conjunto de números. Por exemplo, se jogamos uma moeda 2 vezes, o espaço amostral é **S** = {HH, HT, TH, TT}, onde cada resultado tem a mesma probabilidade. No entanto, é difícil lidar com espaços amostrais desta maneira, é muito mais fácil trabalhar com quantidades numéricas. Neste exemplo específico poderíamos estar interessados no número de "caras" nas 2 jogadas, e seria interessante definir uma função que associasse um número a cada resultado no espaço amostral.

Seja **S** o espaço amostral e X uma função que "pega" elementos deste espaço (resultados da experiência) e os leva num subconjunto de números reais. Esta função X é chamada de **variável aleatória**.

Definição 1.6.1. Variável Aleatória
Considere uma experiência aleatória com espaço amostral **S**. Seja c um elemento de **S**. Uma **variável aleatória** X é uma função que associa um único número real X(c) = x a cada elemento do espaço amostral **S**. O espaço de X é o conjunto de números reais: $\aleph = \{x: x = X(c)\ \forall\ c \in \mathbf{S}\}$, ou seja, o espaço de todos os x's, tais que X=X(c) e c é um elemento do espaço amostral S.

Seja X uma variável aleatória definida num espaço amostral **S** e seja $\aleph$ o espaço de X. Seja A um subconjunto de $\aleph$ e S um subconjunto de **S**. Já definimos a probabilidade de um evento $S \subseteq \mathbf{S}$, e agora gostaríamos de estender esta definição e falar da probabilidade de um evento $A \subseteq \aleph$.

Ou seja, o nosso objetivo agora é definir probabilidades a partir de valores possíveis da variável aleatória, sem referência explícita aos pontos do espaço amostral que deram origem àqueles valores da variável aleatória.

> Na verdade, o estudo de probabilidades começa a se aprofundar com a definição de variável aleatória, que será o objeto principal das nossas atenções a partir de agora. A noção de variável aleatória é tão importante que freqüentemente nem nos preocupamos com o que está "por trás" delas, isto é, na prática muitas vezes ignoramos o espaço amostral.

Como definir Pr (X∈ A)? A maneira mais natural de fazer isso é associar a probabilidade do evento X ∈ A à probabilidade do evento S no espaço amostral **S**. Ou seja, se $A \subseteq \aleph$, definimos:

Pr (X∈A) = Pr (S) onde S = {c∈ **S**: X(c) ∈ A}

Assim, a variável aleatória X é uma função que "transporta" a probabilidade de um espaço amostral **S** para um espaço $\aleph$ de números reais.

> **Notação:**
> **X (maiúscula) = variável aleatória**
> **x (minúscula) = valor numérico da variável aleatória**

Definição 1.6.2. Variável Aleatória Discreta, Densidade de Probabilidade Discreta

Seja X uma variável aleatória cujo espaço é o conjunto unidimensional $\aleph$. Dizemos que X é uma variável aleatória discreta se o número de valores possíveis de X é finito ou contável.

Por exemplo, se os valores possíveis de X são {0, 1, 2...} ou {2, 4, 6, 8...}, ou ainda {1/3, 1/4, 1/5..., 1/n...}, X é uma variável aleatória discreta. A partir da

definição de variável aleatória discreta podemos definir a densidade de probabilidade discreta, que é uma função da variável aleatória X que nos permite calcular probabilidades para todos os valores de X.
Seja f(x) uma função tal que:

i) $f(x) \geq 0 \ \forall \ x \in \aleph$

ii) $\sum f(x) = 1$ onde o somatório se estende para todo x em $\aleph$

iii) $\forall \ A \subseteq \aleph$, $Pr(A) = Pr(X \in A) = \sum f(x)$ onde o somatório refere-se a todos os $x \in A$.

Esta última propriedade nos permite calcular a probabilidade de qualquer evento envolvendo a variável aleatória X. Para qualquer evento A definido no espaço da variável aleatória X, a probabilidade de A é apenas o somatório de todos aqueles valores de x que compõem A.

f(x) é chamada **densidade de probabilidade** da variável aleatória X e dizemos que X é uma **variável aleatória discreta**.

> **Nota:**
> Muitos livros reservam a expressão "densidade de probabilidade" para o caso contínuo. Aqui, uma densidade de probabilidade será definida para variáveis aleatórias contínuas ou discretas. Muitas vezes, a nossa "densidade de probabilidade" para variável aleatória **discreta** é chamada de função de freqüência, **função de probabilidade** ou função de massa de probabilidade.

A função densidade de probabilidade simplesmente diz como se distribuem as probabilidades dos diversos valores da variável aleatória X.

Exemplo 1.6.3.
Uma fábrica produz fusíveis. A probabilidade de um fusível produzido ser defeituoso é 10%. Testam-se fusíveis, encerrando o teste assim que o primeiro fusível defeituoso é encontrado. Seja X o número de testes realizados até encontrar o primeiro fusível defeituoso. Ache a densidade de X.

Solução
O primeiro passo é definir o espaço amostral, que é constituído por seqüências do tipo:

D
BD
BBD
BBBD
BBBBD
...

onde B indica que o fusível está perfeito, e D indica que o fusível tem defeito.

Logo, os valores possíveis de X são: 1, 2..., n... (não há um valor máximo). Mas, X = n se, e somente se, os (n-1) primeiros fusíveis testados estão OK e o n-ésimo tem defeito. Isto é, X = n corresponde à seqüência:
BBBBB...BD
Na qual existem n-1 fusíveis OK e 1 com defeito.

Se o estado de um fusível não afetar a condição do próximo podemos supor que: $f(n) = Pr(X = n) = (0.9)^{n-1}.(0.1)$ para n = 1, 2...

Note que f(n) > 0 para todo n e também:

$$\sum_{n=1}^{\infty} f(n) = \sum_{n=1}^{\infty} (0.9)^{n-1}.(0.1) = 0.1 \sum_{n=1}^{\infty} (0.9)^{n-1} = 0.1\left\{1 + 0.9 + (0.9)^2 + \ldots\right\} = 0.1\left\{\frac{1}{1-0.9}\right\} = 1$$

e então f(n) é realmente uma densidade de probabilidade discreta.

Esta função de probabilidade é bastante importante, e chama-se **função de probabilidade Geométrica** com parâmetro p (neste exemplo, p = 10%).

Definição 1.6.4. Variável Aleatória Contínua, Densidade de Probabilidade Contínua

Seja X uma variável aleatória com espaço $\aleph$ tal que:

i) $f(x) \geq 0$ para todo $x \in \aleph$

ii) f (x) tem no máximo um número finito de descontinuidades em qualquer subintervalo finito de $\aleph$.

iii) Seja A um subconjunto qualquer de $\aleph$. A probabilidade de X estar em A é:

$Pr(X \in A) = Pr(A) = \int_A f(x)\,dx$.

A variável aleatória X é uma **variável aleatória contínua** e f(x) é sua **densidade de probabilidade.**

> **Logo, os requisitos fundamentais para que uma função f (.) seja uma densidade de probabilidade são:**
>
> **i) f integra (ou soma) a 1 quando a integral (somatório) é tomada sobre todos os valores possíveis da variável aleatória.**
>
> **ii) f é uma função não negativa.**
>
> **iii) f(x) é a probabilidade do valor x da variável aleatória discreta X ou, quando X é variável aleatória contínua, a integral de f sobre um conjunto A fornece a probabilidade da variável aleatória X estar neste conjunto. Uma conseqüência importante deste último fato é: se X é uma variável aleatória contínua, a probabilidade de qualquer valor é zero, pois a integral usada para calcular esta probabilidade tem limite inferior igual ao limite superior.**

Muitas vezes X é uma variável aleatória contínua definida no intervalo (a, b), sem menção explícita a outros subintervalos dos números reais. Neste caso está implícito que a densidade f(x) é nula para $x \notin (a,b)$.

Nota:
Seja f(x) a densidade de probabilidade de uma variável aleatória **contínua** X.
Seja A o conjunto: A = {x: a < x < b}. Então:

$$Pr(A) = Pr(X \in A) = \int_a^b f(x)\,dx$$

Suponha agora que A consista num único ponto: A = {x: x = a}. Por cálculo:

$$P(A) = Pr(X = a) = \int_a^a f(x)\,dx = 0.$$

Moral da história:

Se X é uma variável aleatória contínua, a probabilidade de qualquer conjunto consistindo num único ponto é zero. Logo, segue que, se X é uma variável contínua:

$Pr(a < X < b) = Pr(a \leq X \leq b) = Pr(a < X \leq b) = Pr(a \leq X < b)$

Exemplo 1.6.5.
Seja Y uma variável aleatória contínua com densidade: $f(y) = 2.e^{-2y}$ onde y > 0. Mostre que f(y) é realmente uma densidade (integra a 1) e calcule Pr (Y > 1).

Solução

$$\int_{-\infty}^{\infty} f(y)dy = \int_0^{\infty} f(y)dy = \int_0^{\infty} 2.e^{-2y}dy = -e^{-2y}\Big|_0^{\infty} = -0 + 1 = 1$$

$$Pr(Y > 1) = \int_1^{\infty} f(y)dy = \int_1^{\infty} 2.e^{-2y}dy = \frac{2.e^{-2y}}{(-2)}\Big|_1^{\infty} = -e^{-2y}\Big|_1^{\infty} = -0 + e^{-2} = 0.135$$

Definição 1.6.6 Função de Distribuição ou Função de Distribuição Cumulativa
Seja X uma variável aleatória qualquer (contínua ou discreta). A **função de distribuição** da variável aleatória X é definida como: **$F(x) = Pr(X \leq x)$**

Seja f(x) a densidade de probabilidade de X. Então:

$F(x) = \sum_{w \leq x} f(w)$ se X é variável aleatória discreta

ou

$F(x) = \int_{-\infty}^{x} f(w)\,dw$ se X é variável aleatória contínua

Teorema 1.6.7. Propriedades da Função de Distribuição

i) $0 \leq F(x) \leq 1$ pois $0 \leq Pr(X \leq x) \leq 1$

ii) F(x) é uma função **não decrescente**

iii) $\lim_{x \to \infty} F(x) = 1$

iv) $\lim_{x \to -\infty} F(x) = 0$

v) Se X é uma variável aleatória contínua, sua função de distribuição é contínua. Se X é discreta, F(x) é uma função contínua à direita, isto é, a função de distribuição apresenta "pulos" (descontinuidades) que só são "sentidos" quando nos aproximamos do ponto onde existe o "pulo" pela esquerda.

Exemplo 1.6.8.
Seja X uma variável aleatória com função de distribuição definida por:

$$F(x) = \begin{cases} 0 & \text{se } x \leq 0 \\ 1 - e^{-x} & \text{se } x > 0 \end{cases}$$

F(x) assim definida é uma função não decrescente que satisfaz as propriedades de uma função de distribuição.

O gráfico desta função de distribuição é mostrado a seguir.

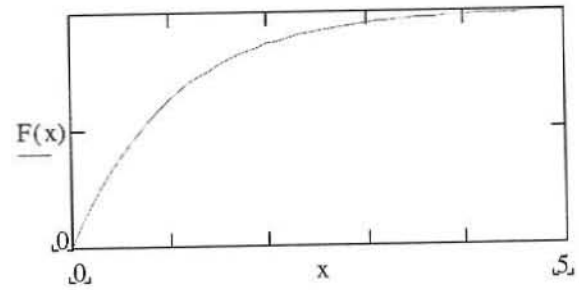

Exemplo 1.6.9.
Considere uma variável discreta com a seguinte função de probabilidade:

$$f(x) = \frac{4}{x!(4-x)!}\left(\frac{1}{2}\right)^4 \quad x = 0,1,2,3,4$$

A função de distribuição é:

$$F(x) = Pr(X \leq x) = \sum_{k=0}^{x} \frac{4}{k!(4-k)!}\left(\frac{1}{2}\right)^4 = \sum_{k=0}^{x} \frac{3}{2}\left(\frac{1}{k!(4-k)!}\right) = \frac{3}{2}\sum_{k=0}^{x} \frac{1}{k!(4-k)!}$$

Assim:
F (0) = 1/16 = 0.0625 = Pr (X ≤ 0) = Pr (X = 0)
F (1) = 5/16 = 0.3125 = Pr (X ≤ 1) = Pr (X = 0) + Pr (X = 1)

$F(2) = 11/16 = 0.6875 = Pr(X \leq 2) = Pr(X=0) + Pr(X=1) + Pr(X=2)$
$F(3) = 15/16 = 0.9375$
$F(4) = 1$

Resultado 1.6.10. - Relação entre a Função Densidade e a Função de Distribuição

Considere uma variável aleatória contínua com densidade f(x) e função de distribuição F(x). Então:

$$Pr(a < X < b) = \int_a^b f(x)dx$$

Mas:

$$F(a) = Pr(X \leq a) = \int_{-\infty}^{a} f(x)dx \quad e$$

$$F(b) = Pr(X \leq b) = \int_{-\infty}^{b} f(x)dx$$

Então:

$$Pr(a \leq X \leq b) = \int_a^b f(x)dx = F(b) - F(a)$$

Pelo teorema fundamental do cálculo:

$$f(x) = \frac{dF(x)}{dx}$$

Ou seja, a densidade é a derivada da função de distribuição.

Definição 1.6.11. Valor Esperado de uma Função de uma Variável Aleatória

Seja X uma variável aleatória com densidade f(x) e seja u(X) uma função qualquer tal que:

$$\int_{x=-\infty}^{\infty} u(x)\, f(x)\, dx$$

ou

$$\sum_{x=-\infty}^{\infty} u(x)\, f(x) = \sum_{x=-\infty}^{\infty} u(x) Pr(X = x) \qquad (1.6.1)$$

existe, se X é uma variável aleatória contínua ou discreta. Então, a integral (ou somatório) (1.6.1) é chamado de **valor esperado de u(X), esperança de u(X), ou expectância de u(X)**. Os casos particulares mais importantes desta expressão ocorrem quando u(X) é um polinômio em X, o que nos leva às definições dos momentos da variável X, como descrito a seguir.

Teorema 1.6.12. Linearidade do Valor Esperado

Sejam a e b constantes e u, v funções quaisquer de X. Então:

E [a.u(X) + b.v(X)] = a.E[u(X)] + b.E[v(X)]

A demonstração deste fato é bastante fácil, e segue diretamente da linearidade das integrais ou somatórios. Em particular, se a é uma constante, E (a) = a.

Valores Esperados Especiais

Alguns valores esperados são de importância fundamental em Probabilidade, como a média, a variância e a função geradora de momentos de uma variável aleatória.

Seja X uma variável aleatória (discreta ou contínua) com densidade f(x).

Definição 1.6.13. Média de uma Variável Aleatória, ou Média de uma Distribuição

$$\mu = E(X) = \begin{cases} \int_{-\infty}^{\infty} x.f(x)dx \\ \sum_{x=-\infty}^{\infty} x.f(x) = \sum_{x=-\infty}^{\infty} x.Pr(X = x) \end{cases}$$

A **média** de uma variável aleatória representa uma medida de **tendência central** da distribuição de probabilidade desta variável aleatória.

Uma conseqüência importante do teorema 1.6.12 é: se X e Y são duas variáveis aleatórias quaisquer com médias finitas, então:
E (a.X + b.Y) = a.E (X) + b.E (Y)

Definição 1.6.14. Variância de uma Variável Aleatória

A variância de uma variável aleatória é definida como:

$$\sigma^2 = VAR(X) = V(X) = E[(X-\mu)^2] =$$

$$= \begin{cases} \int_{-\infty}^{\infty} (x-\mu)^2 f(x)\, dx \\ \sum_{x=-\infty}^{\infty} (x-\mu)^2 f(x) = \sum_{x=-\infty}^{\infty} (x-\mu)^2 Pr(X = x) \end{cases}$$

onde novamente f(x) representa a densidade de probabilidade (ou função de probabilidade, se X é uma variável discreta) da variável aleatória X e μ é a média da variável aleatória. A variância é o segundo momento em torno da média, e corresponde ao **momento de inércia** em Mecânica.

Da própria definição segue que a variância é uma quantidade sempre maior ou igual a zero.

A **variância** de uma variável aleatória é uma medida da **dispersão** da distribuição de probabilidade.

Nota: Fórmula alternativa para o cálculo da variância

A fórmula de cálculo da variância dada pela definição 1.6.14. é, às vezes, bastante trabalhosa, e por isso é interessante encontrar uma forma de cálculo alternativa.

Pela definição de variância:

$\sigma^2 = VAR(X) = E(X - \mu)^2$ e expandindo o polinômio $(X - \mu)^2$ leva a:

$VAR(X) = E(X^2) - 2.\mu.E(X) + E(\mu^2)$ e pela linearidade do valor esperado:

$\sigma^2 = VAR(X) = E(X^2) - 2.\mu^2 + \mu^2 = E(X^2) - \mu^2$

Logo, podemos calcular a variância de X através da fórmula alternativa:

$$\sigma^2 = VAR(X) = E(X^2) - \mu^2 \qquad (1.6.2)$$

Esta fórmula é válida para qualquer variável aleatória X (contínua ou discreta), desde que a média de X seja finita.

Definição 1.6.15. Desvio Padrão

O **desvio padrão** da variável aleatória X é a raiz quadrada positiva da variância de X. Note que o desvio padrão σ tem as mesmas unidades de X. Assim, por exemplo, se X é expresso em metros, σ também é, e σ^2 (variância) é expresso em metros quadrados. Um valor pequeno do desvio padrão indica que existe pouca dispersão em torno da média. Se o desvio padrão é grande, os valores da variável aleatória estão muito dispersos em torno da média.

A média e a variância são casos particulares do que chamamos de **"momentos" de uma distribuição de probabilidade**. Os momentos de uma distribuição servem para caracterizar esta distribuição, não apenas no que se refere à sua centralidade e dispersão, mas também com relação a outras características, como a simetria ou assimetria da densidade de probabilidade.

Definição 1.6.16. K-ésimo Momento de uma Distribuição, K-ésimo Momento da Variável X

O k-ésimo momento da variável aleatória X é definido como:

$$E(X^k) = \begin{cases} \int_{-\infty}^{\infty} x^k . f(x)dx \\ \sum_{x=-\infty}^{\infty} x^k . f(x) = \sum_{x=-\infty}^{\infty} x^k . Pr(X = x) \end{cases} \qquad (1.6.3)$$

onde k =1, 2, 3...

Obviamente a definição não se aplica se $E(X^k)$ é infinito.

Definição 1.6.17. K-ésimo Momento Central ou K-ésimo Momento em Torno da Média

O k-ésimo momento central da variável aleatória X é definido como:

$$E(X-\mu)^k = \begin{cases} \int_{-\infty}^{\infty} (x-\mu)^k . f(x)dx \\ \sum_{x=-\infty}^{\infty} (x-\mu)^k . f(x) = \sum_{x=-\infty}^{\infty} (x-\mu)^k . Pr(X = x) \end{cases} \qquad (1.6.4)$$

Logo, a média e a variância são apenas casos particulares de momentos. A média é o primeiro momento (isto é, $\mu = E(X)$) e a variância é o segundo momento central, ou seja: $E(X - \mu)^2$. Note que o primeiro momento central é zero para qualquer distribuição, e isto decorre da linearidade do valor esperado.

A notação E (...) indica um valor esperado, e pode ser estendida para funções mais gerais que X^k ou $(X - \mu)^k$.

Definição 1.6.18. Função Geradora de Momentos

Seja X uma variável aleatória qualquer. Suponha que existe um número positivo h tal que, para $-h < t < h$ o valor esperado $E(e^{tX})$ existe. Este valor esperado é chamado de **função geradora de momentos** de X, e é denotado por M(t).

$$M(t) = E(e^{tX}) = \begin{cases} \int_{-\infty}^{\infty} e^{tx} . f(x)dx \\ \sum_{x=-\infty}^{\infty} e^{tx} . f(x) = \sum_{x=-\infty}^{\infty} e^{tx} . Pr(X = x) \end{cases} \qquad (1.6.5)$$

A função geradora de momentos é um dos objetos mais úteis que existem no estudo de probabilidade. O problema é que **a função geradora de momentos nem sempre existe**. Por isso, em cursos mais avançados apresenta-se a

função característica, que sempre existe. O uso da função característica é mais complicado que o da função geradora de momentos, pois envolve números complexos.

A função característica é definida como: $p(t) = E(e^{itx})$ onde i é, como sempre, a raiz quadrada de -1.

Nota:
Freqüentemente abreviaremos a expressão "função geradora de momentos" por fgm.

Teorema 1.6.19. - Propriedades da Função Geradora de Momentos

1) A **função geradora de momentos** é **única** e **determina completamente a distribuição** da variável aleatória. Assim, se duas variáveis aleatórias têm a mesma função geradora de momentos, elas têm a mesma distribuição. Logo, se você tiver uma tabela de funções geradoras de momentos, poderá identificar qual a densidade que corresponde a uma dada função geradora de momentos.

2) $M(0) = E(e^0) = E(1) = 1$

3) Se M(t) existe para t no intervalo (-h, h) então as derivadas de todas as ordens existem em t = 0.

$$M'(t) = \frac{dM(t)}{dt} = \begin{cases} \int_{-\infty}^{\infty} x.e^{tx}.\, f(x)dx \\ \sum_{x=-\infty}^{\infty} x.e^{tx}.\, f(x) \end{cases}$$

Fazendo t = 0 encontramos:

$$M'(0) = \frac{dM(t)}{dt}\Big|_{t=0} = \begin{cases} \int_{-\infty}^{\infty} x.\, f(x)dx \\ \sum_{x=-\infty}^{\infty} x.\, f(x) \end{cases} \quad E = (X) \qquad (1.6.6)$$

Derivando mais uma vez com relação a t e fazendo t = 0 notamos que:

$M''(0) = E(X^2)$

Em geral, para n inteiro e positivo: $E(X^n) = M^n(0) = \left.\frac{d^n M(t)}{dt^n}\right|_{t=0}$ (1.6.7)

$E(X^n)$ é chamado de **n-ésimo momento** da distribuição de X. A existência do n-ésimo momento da distribuição garante que os momentos de ordem menor que n também existem. Em particular, a existência da variância implica a existência da média, mas a recíproca não é verdadeira. Daí o nome função **geradora** de momentos deve ser claro, pois M (t) **gera** os momentos E (X), $E(X^2)$, $E(X^3)$...

A demonstração de que a função geradora de momentos gera momentos pode ser feita também sem menção explícita da densidade f(x). Este resultado pode ser comprovado diretamente através da expansão de Taylor de uma exponencial e das propriedades do valor esperado.

Exemplo 1.6.20.
Seja X uma variável aleatória discreta com função de probabilidade:
$f(x) = k.(0.5)^x$ onde x = 1,2,3
a) Encontre a constante k.
b) Ache a média e variância de X.
c) Calcule a função de distribuição de X.

Solução
a) Pela definição de função de probabilidade temos:

$$\sum_{x=1}^{3} k(0.5)^x = k\left\{0.5 + (0.5)^2 + (0.5)^3\right\} = 1 \Rightarrow k\{0.875\} = 1$$

$$\Rightarrow k = 1.1429$$

b) A média de X é:

$$E(X) = \sum_{x=1}^{3} k.x.(0.5)^x = k\left\{0.5 + 2(0.5)^2 + 3(0.5)^3\right\} = \frac{1}{0.875}\{1.375\} = 1.5714$$

O segundo momento de X é:

$$E(X^2) = \sum_{x=1}^{3} k.x^2.(0.5)^x = k\left\{0.5 + 4(0.5)^2 + 9(0.5)^3\right\} = \frac{1}{0.875}\{2.625\} = 3$$

Logo, a variância de X é:

$$VAR(X) = E(X^2) - \{E(X)\}^2 = 3 - (1.5714)^2 = 0.5306$$

O desvio padrão de X é apenas a raiz quadrada positiva da variância.

c) A função de distribuição (F(x)) de X é facilmente encontrada a partir da função de probabilidade (f(x)).

F(x) = Pr (X ≤ x) = 0 se x < 1
F(1) = Pr (X ≤ 1) = (0.5).k
F(2) = Pr (X ≤ 2) = k{0.5 + 0.25} = 0.75.k
F(3) = Pr (X ≤ 3) = k{0.5 + 0.25 + 0.125} = 0.875.k = 1
F(x) = 1 se x > 3

1.7. Distribuições Conjuntas, Marginais e Condicionais

Na prática, muitas vezes temos que lidar com diversas variáveis aleatórias simultaneamente. Por exemplo, tomamos uma amostra de vendas e preço de diversas marcas de margarina em uma cadeia de supermercados. As vendas e o preço das diversas marcas podem ser encarados como variáveis aleatórias, e a relação entre elas é importante para o controle de estoque do supermercado e a estratégia de marketing e promoções do supermercado, entre outras coisas.

Objetivos:

- **Encontrar distribuições de probabilidade conjuntas para expressar a relação entre 2 ou mais variáveis aleatórias.**
- **Encontrar distribuições de probabilidade condicionais que expressam o efeito de um subconjunto de variáveis sobre outro subconjunto de variáveis.**
- **Encontrar distribuições de probabilidade marginais que indicam o comportamento de uma única variável sem o efeito das outras.**
- **Definir e verificar as implicações da independência entre variáveis aleatórias.**
- **Definir medidas da associação entre 2 variáveis, como a covariância e o coeficiente de correlação.**

Definição 1.7.1. Vetor Aleatório
Seja E uma experiência aleatória com espaço amostral S. Sejam X_1, X_2..., X_k funções que associam números reais a cada resultado da experiência E. Então (X_1, X_2..., X_k) é um vetor aleatório de dimensão k.

Estaremos freqüentemente interessados no caso k = 2, e então (X_1, X_2) será chamado de vetor aleatório bidimensional ou variável aleatória bidimensional. Se X_1 e X_2 são variáveis discretas, dizemos que (X_1, X_2) é uma variável aleatória bidimensional discreta. Analogamente, se X_1 e X_2 são variáveis contínuas, dizemos que (X_1, X_2) é uma variável aleatória bidimensional contínua.

A seguir, definimos a densidade conjunta para duas variáveis X_1 e X_2 (contínuas ou discretas). A densidade conjunta nos permite encontrar probabilidades envolvendo ambas as variáveis aleatórias.

Definição 1.7.2. Densidade Conjunta
Sejam X_1 e X_2 variáveis aleatórias discretas. A densidade conjunta de X_1 e X_2 é uma função não negativa f (x_1, x_2) tal que: Pr ($X_1 = x_1$, $X_2 = x_2$) = f (x_1, x_2).

Analogamente ao caso unidimensional, o somatório da densidade conjunta para todos os valores de X_1 e X_2 deve ser 1. Logo:

$$\sum_{\text{todo } x_1} \sum_{\text{todo } x_2} f(x_1, x_2) = 1 \qquad (1.7.1)$$

Sejam X_1 e X_2 variáveis aleatórias contínuas. A densidade conjunta de X_1 e X_2 é uma função não negativa $f(x_1,x_2)$ tal que para qualquer subconjunto A de R^2:

$\Pr((X_1, X_2) \in A) = \iint_A f(x_1,x_2)\, dx_1\, dx_2$

Em particular, para calcularmos a probabilidade de X_1 e X_2 estarem em intervalos de números reais só precisamos calcular a integral dupla abaixo:

$$\Pr(a \le X_1 \le b, c \le X_2 \le d) = \int_a^b \int_c^d f(x_1, x_2)\, dx_2\, dx_1 \qquad (1.7.2)$$

A condição de normalização implica o fato de que a integral dupla da densidade para todos os valores de X_1 e X_2 deve ser um. Daí, no caso contínuo:

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x_1, x_2) dx_2 dx_1 = 1 \qquad (1.7.3)$$

Note que, no caso **discreto**, a densidade conjunta representa uma probabilidade envolvendo as variáveis X_1 e X_2. O mesmo **não ocorre** no caso **contínuo**, pois a probabilidade das variáveis X_1 e X_2 estarem em quaisquer pontos a e b, respectivamente, é zero!

Definição 1.7.3. Densidades Marginais
Seja $f(x_1, x_2)$ a densidade conjunta de X_1 e X_2. Uma pergunta que surge naturalmente é: qual a distribuição de X_1 sozinho? E a de X_2? Isto nos leva a definir as densidades marginais de X_1 e X_2. Definimos a densidade **marginal** de X_1 como a seguir:

$$f_1(x_1) = \int_{-\infty}^{\infty} f(x_1, x_2) dx_2 \qquad (1.7.4)$$

no caso contínuo e,

$$f_1(x_1) = \sum_{x_2=-\infty}^{\infty} f(x_1, x_2) \text{ no caso discreto.} \qquad (1.7.5)$$

A densidade marginal de X_2 é encontrada de maneira análoga, integrando-se ou somando-se a conjunta em X_1.

Probabilidades que envolvem apenas uma das variáveis (por exemplo, apenas X_1) são calculadas através das seguintes fórmulas:

$$\Pr(a < X_1 < b) = \int_a^b f_1(x_1)\, dx_1$$

ou:

$$\Pr(a < X_1 < b) = \sum_{a<x_1<b} f_1(x_1) = \sum_{a<x_1<b} \Pr(X_1 = x_1)$$

Definição 1.7.4. Densidade Condicional
A densidade condicional de X_2 dado X_1 é definida sempre que a densidade marginal de X_1 for maior que zero, e é dada por:

$$f(x_2 \mid x_1) = \frac{f(x_1, x_2)}{f_1(x_1)} \qquad (1.7.6)$$

Analogamente, a densidade condicional de X_1 dado X_2 é:

$$f(x_1 \mid x_2) = \frac{f(x_1, x_2)}{f_2(x_2)} \qquad (1.7.7)$$

sempre que $f_2(x_2) > 0$. Estas densidades nos permitem calcular probabilidades condicionais.

As densidades marginais e condicionais são densidades "propriamente ditas" e devem satisfazer:
1) O somatório (ou integral) sobre todos os valores possíveis da variável é 1.
2) As densidades condicionais ou marginais são sempre funções não negativas.

Exemplo 1.7.5.
Sejam X e Y variáveis aleatórias contínuas com densidade conjunta:

$$f(x,y) = c.e^{-x/2} \cdot e^{-y/3} \qquad \text{se } x > 0 \text{ e } y > 0$$

1) Encontre a constante c tal que f(x,y) seja uma densidade.
2) Calcule as densidades marginais de X e Y.
3) Calcule Pr (X > 2).
4) Calcule Pr (1 < Y < 3)

Solução
1) A constante é encontrada a partir da condição de normalização, isto é, fazendo a integral dupla sobre todos os valores de X e Y igual a um.

$$\int_0^\infty\int_0^\infty f(x,y)\, dxdy = 1 = \int_0^\infty\int_0^\infty c.e^{-x/2}.e^{-y/3}\, dxdy = \int_0^\infty c.e^{-y/3}\, dy \int_0^\infty e^{-x/2}\, dx =$$

$$\int_0^\infty c.e^{-y/3}.\left(0 - \frac{1}{(-1/2)}\right) dy = \int_0^\infty 2.c.e^{-y/3}\, dy = 2.c.\left(0 - \frac{1}{(-1/3)}\right) = 6.c$$

Então 6.c =1 e assim c = 1/6

2) A densidade marginal de X é:

$$f_x(x) = \int_0^\infty f(x,y)\, dy = \int_0^\infty \frac{1}{6}.e^{-x/2}.e^{-y/3} dy =$$

$$\frac{1}{6}.e^{-x/2}\int_0^\infty e^{-y/3}\, dy = \frac{e^{-x/2}}{6} \cdot \left(0 - \frac{1}{(-1/3)}\right) = \frac{e^{-x/2}}{2} \text{ se } x > 0$$

Ou seja, X tem densidade Exponencial com parâmetro $\lambda = 1/2$ (e média 2).
A densidade marginal de Y é obtida de maneira semelhante, integrando-se a densidade conjunta para todo valor de X:

$$f_y(y) = \int_0^\infty f(x,y)\, dx = \int_0^\infty \frac{1}{6}.e^{-x/2}.e^{-y/3}\, dx =$$

$$\frac{1}{6}.e^{-y/3}\int_0^\infty e^{-x/2}\, dx = \frac{e^{-y/3}}{6} \cdot \left(0 - \frac{1}{(-1/2)}\right) = \frac{e^{-y/3}}{3} \quad \text{se } y > 0$$

Isto é, Y tem densidade Exponencial com parâmetro $\lambda = 1/3$ (e média 3).

3) A probabilidade de X > 2 é obtida a partir da densidade marginal de X:

$$\Pr(X > 2) = \int_2^\infty \frac{e^{-x/2}}{2} dx = \frac{1}{2}.\left[0 - \frac{e^{-1}}{(-1/2)}\right] = e^{-1}$$

4) Pr (1<Y<3) é calculado a partir da marginal de Y integrada no intervalo (1,3).

$$\Pr(1 < Y < 3) = \int_1^3 \frac{e^{-y/3}}{3}\, dy = \frac{1}{3} \cdot \left(\frac{-1}{(1/3)}\right) \cdot \left(e^{-3/3} - e^{-1/3}\right) =$$

$$e^{-1/3} - e^{-1} = 0.7165 - 0.3679 = 0.3486$$

Exemplo 1.7.6.
Sejam X e Y variáveis aleatórias contínuas com densidade conjunta dada por:

$$f(x,y) = \frac{x.y}{3} + x^2 \quad \text{onde } 0 < x \le 1 \text{ e } 0 \le y \le 2$$

1) Calcule as densidades marginais de X e Y.
2) Encontre a densidade condicional de Y dado X = x.
3) Encontre a densidade condicional de X dado Y = y.

Solução
A densidade marginal de X é:

$$f_x(x) = \int_0^2 f(x,y)\, dy = \int_0^2 \left(\frac{xy}{3} + x^2\right) dy = 2.x^2.x^2 + \frac{2.x}{3}, \quad \text{onde} \quad 0 < x \le 1$$

A densidade marginal de Y é:

$$f_y(y) = \int_0^1 f(x,y)dx = \int_0^1 \left(\frac{xy}{3} + x^2\right) dx = \frac{1}{3} + \frac{y}{6}, \quad \text{onde } 0 \le y \le 2$$

Verifique que estas densidades integram a um!

2) A densidade condicional de Y dado X = x é dada por:

$$f(y \mid x) = \frac{f(x,y)}{f_x(x)} = \frac{\frac{xy}{3} + x^2}{\frac{2x}{3} + 2x^2} = \frac{1}{2}\left[\frac{x + y/3}{x + 1/3}\right], \quad \text{onde } x \in (0,1] \text{ e } y \in [0,2]$$

Note que existe um número infinito de densidades condicionais de Y dado X = x, cada uma para um valor de x diferente no intervalo (0,1). Por exemplo, se x = 1, a densidade condicional de Y dado X = 1 é:

$$f(y \mid x = 1) = \frac{1}{2}\left(\frac{1 + y/3}{1 + 1/3}\right) = \frac{1}{2}\left(\frac{3}{4}\right)\left(1 + \frac{y}{3}\right) = \frac{3}{8}\left(1 + \frac{y}{3}\right), \quad \text{onde } y \in (0,2]$$

Ao escrevermos explicitamente a densidade condicional para um valor específico de X (como acima) fica claro que os valores de X nos quais estamos condicionando se comportam como parâmetros da densidade condicional à medida que variamos estes parâmetros obtemos novas formas para a densidade.

As densidades condicionais são densidade "propriamente ditas". Mostre que f(y | x =1) indicada acima é sempre maior ou igual a zero e que a sua integral para todo valor de y é 1.

3) A densidade condicional de X dado Y = y é dada por:

$$f(x \mid Y = y) = \frac{f(x,y)}{f_y(y)} = \frac{x^2 + \frac{xy}{3}}{\frac{1}{3}\left(1 + \frac{y}{2}\right)} = \frac{3.x^2 + x.y}{1 + y/2}, \quad \text{onde } x \in (0,1] \text{ e } y \in [0,2]$$

Substituindo-se Y = 1 acima encontramos a densidade condicional de X dado Y = 1, que é:

$$f(x \mid Y = 1) = \frac{3.x^2 + x}{1 + 1/2} = \frac{2}{3}.\left(3.x^2 + x\right), \quad \text{onde } x \in (0,1]$$

Se agora o "parâmetro" é Y = 2, temos:

$$f(x \mid Y = 2) = \frac{3.x^2 + 2.x}{1 + 1} = \frac{\left(3.x^2 + 2.x\right)}{2}, \quad \text{onde } x \in (0,1]$$

Nota:
f(x | Y = y) é uma densidade onde a variável aleatória é X e Y = y representa um **parâmetro** da densidade. A condição de normalização é, neste caso:

$$\int_{-\infty}^{\infty} f(x \mid y)dx = 1$$

Note que a variável de integração é x, e não y!
De maneira análoga, f(y | X = x) é uma densidade para a variável aleatória Y usando como parâmetro X = x. A condição de normalização torna-se:

$$\int_{-\infty}^{\infty} f(y \mid x)dy = 1$$

Exemplo 1.7.7.
Considere a seguinte densidade conjunta:

$f(x, y) = \lambda^2.e^{\lambda y}$ onde $\lambda > 0$, $0 \le x \le y$

Calcule as densidades marginais de X e Y e a densidade condicional de X dado Y = y.

Solução
Neste caso devemos considerar, além da densidade conjunta, o domínio desta função, porque X e Y estão "misturados" neste domínio (note que temos a restrição $0 \le x \le y$).

A densidade marginal de X é obtida integrando-se a conjunta sobre y, e o intervalo de integração é (x, ∞) pois para que a densidade conjunta seja maior que zero precisamos de $0 \le x \le y$. Assim:

$$f_x(x) = \int_{-\infty}^{\infty} f(x,y)\,dy = \int_{x}^{\infty} f(x,y)\,dy = \int_{x}^{\infty} \lambda^2.e^{-\lambda y}dy = \lambda^2.\left(\frac{e^{-\lambda y}}{-\lambda}\right)\Bigg|_{y=x}^{\infty} = \lambda.e^{-\lambda x}$$

Isto é, a densidade marginal de X é Exponencial com parâmetro λ.
A densidade marginal de Y é encontrada a partir da integral da conjunta para todo X. Logo, os limites de integração são 0 e y. Assim:

$$f_y(y) = \int_{-\infty}^{\infty} f(x,y)\,dx = \int_{0}^{y} f(x,y)\,dx = \int_{0}^{y} \lambda^2.e^{-\lambda y}dy = \lambda^2.(y)\left(e^{-\lambda y}\right) \quad \text{onde } y \ge 0$$

Esta densidade é um caso particular da densidade Gama.

A densidade condicional de X dado Y = y é facilmente encontrada a partir de sua definição. Note que os valores possíveis de X estão no intervalo [0,y] para cada valor do "parâmetro" y.

$$f(x \mid y) = \frac{f(x,y)}{f_y(y)} = \frac{\lambda^2.\exp(-\lambda y)}{\lambda^2.y.\exp(-\lambda y)} = \frac{1}{y}, \quad \text{onde } 0 \le x \le y$$

Ou seja, dado um valor de Y = y, a densidade condicional de X é **Uniforme** no intervalo [0,y].

1.8. Independência de Variáveis Aleatórias

Sejam X_1 e X_2 variáveis aleatórias contínuas ou discretas. Dizemos que X_1 e X_2 são independentes se sua densidade conjunta puder ser fatorada como o produto das respectivas densidades marginais. Isto é, a definição de independência de 2 variáveis aleatórias é:

Definição 1.8.1.
X_1 e X_2 são variáveis aleatórias *independentes* se, e somente se:
$f(x_1, x_2) = f_1(x_1).\, f_2(x_2)$ para todos os valores possíveis de X_1 e X_2. (1.8.1)

Note que a definição de independência para variáveis aleatórias é muito parecida com a definição equivalente para eventos. No caso de eventos, a independência entre os eventos A e B ocorria se e somente se a probabilidade da interseção de A e B pudesse ser fatorada como o produto das probabilidades individuais de A e B. Variáveis aleatórias que **não são** estocasticamente independentes são chamadas de estocasticamente dependentes.

Resultado 1.8.2. Conseqüências da Independência de Variáveis Aleatórias
Se X_1 e X_2 são independentes então:

1) As densidades condicionais são iguais às densidades marginais correspondentes.
2) Os momentos (média, variância etc...) condicionais são iguais aos momentos correspondentes calculados a partir das densidades marginais.
3) Se X_1 e X_2 são **independentes** com densidades marginais $f_1(x_1)$ e $f_2(x_2)$ segue que:
$Pr(a < X_1 < b, c < X_2 < d) = Pr(a < X_1 < b).\ Pr(c < X_2 < d)$ para **quaisquer** $a < b$, $c < d$.
4) Sejam X_1 e X_2 variáveis aleatórias **independentes** com densidades marginais $f_1(x_1)$ e $f_2(x_2)$. Então, se todos os valores esperados abaixo existirem:

$$\mathbf{E\,[u\,(X_1)\ v\,(X_2)] = E\,[u\,(X_1)].\ E\,[v\,(X_2)]}$$

Logo, o valor esperado de um produto de funções de variáveis aleatórias onde cada função depende apenas de uma das variáveis aleatórias é igual ao produto dos valores esperados das funções individuais sempre que as variáveis aleatórias X1 e X2 forem independentes.

Exemplo 1.8.3.
Sejam X e Y variáveis discretas com a função de probabilidade conjunta dada abaixo.

Pr (X = x) → / Pr (Y = y) ↓	X = 0	X = 1	X = 2	X = 3
Y = 0	0.2	0.1	0.1	0
Y = 1	0.1	0.1	0.1	0.1
Y = 2	0	0.1	0.1	0

X e Y são independentes? Por quê?

Solução
Para que X e Y sejam independentes, a densidade conjunta deve ser o produto, das marginais para **todos os valores** de X e Y. Logo, para mostrar que as variáveis não são independentes, basta encontrar um par de valores de X e Y para o qual a fatorização da densidade conjunta não seja válida.
Por exemplo,

$f_X(0) = Pr(X=0) = 0.2 + 0.1 + 0 = 0.3$

e

$f_Y(0) = Pr(Y = 0) = 0.2 + 0.1 + 0.1 + 0 = 0.4$

Mas, $Pr(X = 0, Y = 0) = 0.2 \neq (0.3)(0.4)$.

Logo, X e Y não são independentes (são dependentes)!
Pode-se verificar também que as densidades condicionais não são iguais às marginais.
Exemplo: $f(0|0) = Pr(X = 0|Y = 0) = f(0,0)/0.4 = 0.2/0.4 = 0.5 \neq Pr(X = 0) = 0.3$

Covariância e Correlação
A covariância e o coeficiente de correlação são duas medidas da associação entre 2 variáveis aleatórias X_1 e X_2.

Definição 1.8.4. Covariância
A covariância entre duas variáveis aleatórias X_1 e X_2 é definida como:

$$COV\,(X_1,X_2) = E[(X_1-\mu_1)\,.\,(X_2-\mu_2)] = E\,[X_1.X_2 - \mu_1.X_2 - \mu_2.X_1 + \mu_1.\mu_2] =$$

$$[E(X_1.X_2) - \mu_1.\,E(X_2) - \mu_2.\,E(X_1) + \mu_1.\mu_2]$$

onde as médias de X_1 e X_2, isto é, $\mu_1 = E(X_1)$, $\mu_2 = E(X_2)$ são computadas a partir das densidades marginais. Note que a covariância é um valor esperado que envolve simultaneamente as duas variáveis, por isso ela deve ser calculada a partir da densidade conjunta de X_1 e X_2. Esta expressão produz uma maneira fácil de calcular a covariância. Em vez de calcularmos $E[(X_1 - \mu_1).(X_2 - \mu_2)]$ a partir da distribuição conjunta, podemos calcular uma coisa mais simples, $E\,(X_1.X_2)$, também a partir da conjunta. Para achar a covariância é só subtrair $\mu_1.\mu_2$ desta quantidade, onde os μ's foram calculados a partir das marginais de X_1 e X_2. Então:
$COV(X_1, X_2) = E[(X_1 - \mu_1).\,(X_2 - \mu_2)] = E\,(X_1.X_2) - \mu_1.\mu_2$

Definição 1.8.5. Coeficiente de Correlação
O coeficiente de correlação entre X_1 e X_2, denotado por ρ, é definido como:

$$\rho = \frac{COV(X_1,X_2)}{\sqrt{VAR(X_1)}.\sqrt{VAR(X_1)}}$$

Teorema 1.8.6.
Se X_1 e X_2 são independentes, então $\rho = 0$ (X_1 e X_2 são descorrelatados).
A recíproca deste fato não é verdadeira! É possível existirem X_1 e X_2 descorrelatados sem serem independentes. Na verdade, é possível até encontrar variáveis X_1 e X_2 tais que X_2 é uma função de X_1 (e então obviamente as variáveis são dependentes) mas tais que $\rho = 0$.

Independência é uma condição muito mais forte que covariância (ou correlação) igual a zero. A noção de independência envolve uma afirmação sobre a densidade conjunta das variáveis, enquanto covariância (ou correlação) igual a zero é apenas uma condição envolvendo os momentos das densidades de X_1 e X_2.

INDEPENDÊNCIA $\Rightarrow$ CORRELAÇÃO ZERO
CORRELAÇÃO ZERO $\not\Rightarrow$ INDEPENDÊNCIA

Isso já causou muita confusão por aí! Independência é uma propriedade muito mais "forte" de que correlação zero! O fato de duas variáveis aleatórias terem correlação zero não implica independência destas variáveis.

Teorema 1.8.7.
O coeficiente de correlação entre X_1 e X_2 é um valor entre -1 e +1. Além disso, $\rho = +1$ ou $\rho = -1$ se e somente se, X_2 é uma função linear de X_1.

A demonstração deste teorema será omitida.

Nota:
De acordo com o teorema anterior $| \rho | = 1$ se e somente se X_2 é uma função linear de X_1. Suponha que: $X_2 = a.X_1 + b$ onde $a > 0$. Então $\rho = +1$. Suponha que: $X_2 = a.X_1 + b$ onde $a < 0$. Então $\rho = -1$.
O coeficiente de correlação é um número adimensional. Por isso ele é interessante para comparar a associação entre variáveis medidas em escalas diferentes.

1.9. As Principais Distribuições Discretas

A Distribuição Binomial

A distribuição Binomial é uma das mais importantes em teoria da probabilidade. Ela surge como uma idealização matemática de diversas situações comuns na "vida real" e está intimamente ligada à amostragem com reposição.

A situação clássica em que usamos uma função de probabilidade Binomial é a seguinte:

- Uma experiência tem apenas 2 resultados possíveis: "sucesso" e "falha", onde a probabilidade de "sucesso" é p e a probabilidade de "falha" é q = 1- p.
- A experiência é repetida um número fixo (n) de vezes, sempre nas mesmas condições, de tal forma que as probabilidades de "sucesso" (p) e "falha" (q=1-p) se mantêm **inalteradas a cada repetição**. As diversas repetições da experiência são feitas de maneira independente, ou seja, o resultado de uma repetição não afeta o resultado das outras.
- A variável aleatória X que mede o **número de "sucessos" nas n repetições da experiência** é uma variável discreta, com valores possíveis 0, 1, 2..., n. Dizemos que esta variável tem distribuição Binomial com parâmetros n e p, e escrevemos $X \sim Bin(n, p)$.

Nota:
A escolha de um tipo de resultado como "sucesso" ou "falha" não implica qualquer julgamento sobre o resultado ser "bom" ou "ruim", é apenas uma questão de nomenclatura. Na verdade, a escolha do que é um "sucesso" ou "falha" depende da questão de interesse ao analisar o problema - o que é "sucesso" numa situação pode ser a "falha" num problema semelhante.

O próximo quadro exibe algumas situações onde a distribuição Binomial pode ser usada.

Experiência Aleatória	"sucesso"	"falha"	p = probabilidade de "sucesso"	n = número de repetições da experiência	X= variável aleatória Binomial
jogada de uma moeda	cara	coroa	1/2	número de jogadas da moeda	número de caras nas n jogadas da moeda
nascimento de uma criança numa família	menina	menino	1/2	número de crianças na família	número de meninas na família
jogada de um dado	sair o número 6	sair qualquer outro número	1/6	número de jogadas do dado	número de vezes em que saiu o número 6 nas n jogadas do dado
"chutar" a resposta numa prova de múltipla escolha onde cada questão tem 5 opções	acertar a resposta da questão	errar a resposta	1/5	número de questões da prova	número de respostas certas na prova
pegar uma bola numa caixa que contém r bolas vermelhas e b bolas azuis e devolvê-la à caixa, anotando a cor da bola selecionada	retirar bola vermelha da caixa	retirar bola azul da caixa	r/(r+b)	número de bolas retiradas da caixa com reposição	número de bolas vermelhas dentre as bolas retiradas com reposição
verificar se uma peça produzida numa fábrica tem defeito	peça tem defeito	peça não tem defeito	proporção de peças com defeito na população de peças	tamanho da amostra	número de peças com defeito na amostra

Na última situação deste quadro supomos que a amostra de peças é obtida **com reposição**, de tal forma que as probabilidades de seleção de uma peça com defeito sejam as mesmas para cada peça na amostra. É claro que esta situação não é realista, pois ninguém vai jogar de volta uma peça selecionada no lote de peças produzidas. No entanto, **se N (o tamanho da população) for muito maior que n (o tamanho da amostra), as amostragens com e sem reposição**

fornecem praticamente os mesmos resultados, e então o modelo Binomial torna-se útil na prática. Por exemplo, se foram produzidas 10000 peças e tomamos uma amostra de 50 peças para verificar a incidência de defeitos, tanto faz usar amostragem com ou sem reposição. Intuitivamente neste caso a importância das características de uma única peça é muito pequena no conjunto todo.

A função de probabilidade Binomial é expressa pela seguinte fórmula:

$$\Pr(X = x) = f(x) = \binom{n}{x} . p^x.(1-p)^{n-x}$$

$$= \binom{n}{x} . p^x.q^{n-x}$$

onde x = 0, 1, 2..., n (1.9.1)

Notação: X ~ Bin(n, p)

Exemplo 1.9.1.
Uma fábrica produz 40000 fornos de microondas, dos quais 80% (32000) estão perfeitos. O departamento de controle de qualidade não tem, entretanto, idéia da proporção de fornos com defeito na linha de produção, e toma uma amostra de 10 fornos. Qual a probabilidade de aparecerem exatamente 5 fornos defeituosos na amostra?

Solução
Seja X o número de aparelhos com defeito na amostra. Pelas considerações anteriores, o tamanho da população é muito maior que o da amostra, e em termos práticos podemos usar a distribuição Binomial para o cálculo das probabilidades. Então: X ~ Bin (10, 0.20) e

$$\Pr(X = 5) = \binom{10}{5} .(0.2)^5.(0.8)^5 \approx 2.6\%$$

Exemplo 1.9.2.
Numa eleição supõe-se que 30% dos eleitores são favoráveis a uma certa proposta. Toma-se uma amostra de tamanho 20 de eleitores da cidade do Rio de Janeiro. Calcular as probabilidades de 4, 5, 6, 7, 8, 9 ou 10 dos eleitores na amostra serem favoráveis à proposta.

Solução
Seja X o número de eleitores na amostra que são a favor da proposta. Então os valores possíveis de X são 0, 1, 2..., 20, e X tem distribuição Binomial com parâmetros n = 20 e p = 0.30. As probabilidades para os diversos valores de X são calculadas através da fórmula:

$$\Pr(X = x) = \binom{20}{x} .(0.30)^x.(0.70)^{20-x} = \frac{20!}{x!(20-x)!} .(0.30)^x.(0.70)^{20-x}$$

A tabela a seguir mostra os valores destas probabilidades para x = 4..., 10.

x	Pr (X=x)
4	0.1304
5	0.1789
6	0.1916
7	0.1643
8	0.1144
9	0.065
10	0.0308

A Distribuição Hipergeométrica
Esta distribuição surge no contexto de amostragem sem reposição. Suponha agora que a amostragem é feita **sem reposição** e que o tamanho da população não é muito maior que o da amostra, de tal forma que a distribuição Binomial não pode ser usada. Sejam N e n respectivamente os tamanhos da população e da amostra e suponha que na população existem r objetos do tipo A ("sucessos") e N - r objetos do tipo B ("falhas").

Seja X o número de objetos do tipo A na amostra. Então as probabilidades dos diversos valores de X são dadas pela seguinte fórmula:

$$f(x) = \Pr(X = x) = \frac{\binom{r}{x}\binom{N-r}{n-x}}{\binom{N}{n}}$$

onde x = 0, 1, 2..., mín(n,r). (1.9.2)

Esta função de probabilidade é chamada de Hipergeométrica com parâmetros N, n e r. Pode-se provar que f(x) acima definida integra a 1 (não é muito fácil).

Exemplo 1.9.3.
Uma empresa encomenda 50 placas fax modem de um fornecedor novo para montagem nos seus micros. A probabilidade de defeito numa placa é, segundo o fornecedor, 10 %. A empresa toma uma amostra de 10 micros sem reposição. Qual a probabilidade de quatro deles apresentarem uma placa fax modem com defeito?

Solução
X = número de micros com placa defeituosa na amostra. Os valores possíveis de X são 0, 1, 2, 3, 4, 5 = mín (5,10). Procuramos calcular Pr (X=4).

$$\Pr(X = 4) = f(4) = \frac{\binom{5}{4}.\binom{45}{6}}{\binom{50}{10}} = \frac{5.(45!).(10!).(40!)}{(6!)\,(39!)\,(50!)} =$$

$$= \frac{200\,(45!)\,(10!)}{(6!)\,(50!)} = \frac{200\,(45!)\,(10)\,(9)\,(8)\,(7)\,(6!)}{(6!)(50)(49)(48)(47)(46)(45!)} =$$

$$= \frac{200\,(10)\,(9)\,(8)\,(7)}{(50)\,(49)\,(48)\,(47)\,(46)} = 0.00396 = 0.396\%$$

Teorema 1.9.4.
Se X tem distribuição Hipergeométrica com parâmetros N, n e r então:

$$E(X) = n\left(\frac{r}{N}\right) \quad e \quad VAR(X) = n\left(\frac{r}{N}\right)\left(1-\frac{r}{N}\right)\left(\frac{N-n}{N-1}\right)$$

Note que, se N >> n, o valor esperado de X coincide com o valor esperado da distribuição Binomial com parâmetros n e p = r/N e também a variância é aproximadamente a mesma que a da distribuição Binomial, pois o termo (N - n)/(N - 1) é aproximadamente igual a 1.

Exemplo 1.9.5.
Você está numa sessão de cinema na qual ocorre uma promoção de um provedor Internet, que está dando 6 meses de acesso gratuito. Existem 80 pessoas no cinema, das quais apenas 30 possuem computador e, portanto, poderiam estar interessadas nesta promoção. O provedor seleciona aleatoriamente 5 espectadores. Qual a probabilidade de 3 ou mais espectadores se interessarem pela promoção (isto é, 3 ou mais terem computador)?

Solução
N = 80 pessoas = tamanho da "população"
r = 30 pessoas possuidoras de computador
n = 5 = tamanho da amostra
X = número de pessoas na amostra que possuem computador

Desejamos encontrar
Pr (X ≥ 3) = 1 - Pr (X < 3) =
1 - Pr (X = 0) - Pr (X = 1) - Pr (X = 2).
Note que a amostragem é sem reposição e, portanto, devemos calcular as probabilidades pela fórmula hipergeométrica. Neste caso:

$$Pr\,(X = x) = \frac{\binom{30}{x}\binom{50}{5-x}}{\binom{80}{5}}$$

e os valores destas probabilidades estão na próxima tabela:

x	Pr (X=x)
0	8,81%
1	28,74%
2	35,47%

Logo: Pr (X ≥ 3) = 1 - 73.02% = 26.98%

A Distribuição Multinomial
Uma das mais importantes distribuições discretas é a Multinomial, que é apenas uma extensão da Binomial quando existem mais que 2 resultados possíveis. Considere uma experiência com espaço amostral **S** onde existem k resultados

possíveis B_1, B_2, B_3..., B_k. Estes resultados são mutuamente exclusivos, e se B_i ocorre, nenhum outro B_j ocorreu.

Suponha que a experiência é repetida n vezes nas mesmas condições, e seja p_i = Pr (B_i). Suponha que p_i é constante para todo i (i = 1, 2, 3..., k) em todas as n repetições da experiência. Seja X_i a variável aleatória que representa o número de vezes em que o evento B_i ocorreu nas n repetições da experiência. Então, as variáveis X_1, X_2..., X_k satisfazem a relação: $X_1 + X_2 + ... + X_k = n$

Note que, por satisfazerem esta relação, os X_i 's **não são independentes.** A **função de probabilidade conjunta dos X_i 's** tem a forma:

$$f(x_1, x_2..., x_k) = Pr\,(X_1 = x_1, X_2 = x_2..., X_k = x_k) = \frac{n!}{x_1!x_2!..x_k!}\, p_1^{x_1} p_2^{x_2}..p_k^{x_k} \qquad (1.9.3)$$

Esta função de probabilidade conjunta é a distribuição Multinomial com parâmetros n, p_1, p_2..., p_k.

As seguintes restrições devem ser satisfeitas:
$x_1 + x_2 + ... + x_k = n$
Logo, a soma do número de vezes em que cada resultado "saiu" é igual ao número de repetições da experiência.
$p_1 + p_2 + ... + p_k = 1$
Isto é, a soma das probabilidades de cada resultado é igual a 1.

A partir destas 2 restrições podemos escrever qualquer X_i e qualquer p_i em termos dos outros X's (ou p's).

Teorema 1.9.6.
Se (X_1, X_2, X_3..., X_k) têm distribuição Multinomial com parâmetros n, p_1, p_2..., p_k então:
$E(X_i) = n.p_i$ e $VAR(X_i) = n.p_i.(1- p_i)$ para i =1, 2..., k
$COV(X_i, X_j) = - n.p_i.p_j$ para $i \neq j$

Nota:
A distribuição Binomial é apenas um caso particular da distribuição Multinomial quando existem apenas k =2 resultados possíveis da experiência. Neste caso, X_1 indica o número de "sucessos" nas n repetições da experiência, enquanto X_2 = n - X_1 é o número de "falhas" dentre as n repetições. A distribuição conjunta de X_1 e X_2 é:

$$\Pr(X_1 = x_1, X_2 = x_2) = \Pr(X_1 = x_1, n - X_1 = n - x_1) = \frac{n!}{x_1! x_2!} \cdot p_1^{x_1} . p_2^{x_2} =$$

$$\frac{n!}{x_1!(n-x_1)!} \cdot p_1^{x_1} \cdot (1-p_1)^{n-x_1} = \binom{n}{x_1} \cdot p_1^{x_1} \cdot (1-p_1)^{n-x_1}$$

Note que esta distribuição conjunta se reduz, na prática, a uma distribuição para apenas uma variável aleatória, por causa das restrições sobre os X's e p's.

Exemplo 1.9.7.
Os seguintes eventos podem acontecer com um pacote enviado pelo correio: chegar em perfeito estado, chegar danificado, perder-se pelo caminho. As probabilidades destes acontecimentos são, respectivamente, 0.7, 0.2 e 0.1.
Sua secretária enviou recentemente 10 pacotes pelo correio. Qual a probabilidade de que 6 chegaram corretamente ao destino, 2 foram perdidos e os outros 2 avariados?

Solução
Defina as seguintes variáveis aleatórias:
X_1 = número de pacotes que chegaram corretamente e sem danos
X_2 = número de pacotes que chegaram avariados
X_3 = número de pacotes que se perderam pelo caminho
Então: $X_1 + X_2 + X_3 = n = 10$ e $p_1 + p_2 + p_3 = 0.7 + 0.2 + 0.1 = 1$.

$$\Pr(X_1 = 6, X_2 = 2, X_3 = 2) = \frac{10!}{6!\,2!\,2!} \cdot (0.7)^6 \cdot (0.2)^2 \cdot (0.1)^2 = 0.059$$

Qual é a probabilidade de 6 pacotes chegarem corretamente e sem danos? Neste caso você teria que calcular a função de probabilidade marginal de X_1 ou então considerar um problema Binomial, onde n = 10 e a probabilidade de "sucesso" (chegar ao destinatário sem danos) é 0.7. Pode-se provar que os 2 "enfoques" são equivalentes, isto é, a função de probabilidade marginal de X_i é Binomial com parâmetros n e p_i.

Exemplo 1.9.8.
Uma pesquisa feita entre adolescentes revelou que:
60% abominam saladas e preferem comer hambúrguer com batatas fritas;
30% comem saladas, pois acham que é bom para a saúde;
10% adoram vegetais e para eles saladas são um prazer gastronômico.
Toma-se uma amostra de 8 adolescentes. Qual a probabilidade de que pelo menos 5 deles detestem saladas?

Solução
Este é tipicamente um problema da distribuição Multinomial, pois cada repetição da experiência (comer alguma coisa) resulta em mais de 2 tipos de resultados diferentes (comer hambúrguer, comer salada por obrigação, comer saladas por prazer). Sejam X_1, X_2 e X_3 respectivamente o número de adolescentes que abominam saladas, comem saladas por obrigação e por prazer. A probabilidade desejada é:

$\Pr\{X_1 \geq 5\} = \Pr\{X_1 = 5\} + \Pr\{X_1 = 6\} + \Pr\{X_1 = 7\} + \Pr\{X_1 = 8\}$, que envolve apenas X_1 e então neste caso podemos usar apenas a distribuição marginal de X_1, que é Binomial com n = 8 e p = 0.6. As probabilidades desejadas estão na próxima tabela:

x	Pr (X = x)
5	27,87%
6	20,90%
7	8,96%
8	1,68%
Soma:	**59,41%**

Exemplo 1.9.9.
Numa certa Universidade, as matérias são classificadas pelos alunos como: chatíssimas (10%), chatas (15%), regulares (25%), boas (30%) ou ótimas (20%). Você se matricula em 6 matérias.
a) Qual a probabilidade de 3 delas serem ótimas, 2 boas e 1 regular?
b) Qual a probabilidade de 2 delas serem ótimas, 2 boas e 2 regulares?
c) Qual a probabilidade de 3 delas serem chatíssimas, 2 chatas e 1 regular?

Solução
Este é também um problema Multinomial, mas agora estamos interessados na probabilidade conjunta. Sejam X_1, X_2, X_3, X_4 e X_5 respectivamente o número de matérias chatíssimas, chatas, regulares, boas e ótimas. Procuramos calcular as seguintes probabilidades:

a) $\Pr(X_1 = 0, X_2 = 0, X_3 = 1, X_4 = 2, X_5 = 3) =$
$$\frac{6!}{0!\,0!\,1!\,2!\,3!}(0.10)^0(0.15)^0(0.25)^1(0.30)^2(0.20)^3 = 1.08\%$$

b) $\Pr(X_1 = 0, X_2 = 0, X_3 = 2, X_4 = 2, X_5 = 2) =$
$$\frac{6!}{0!\,0!\,2!\,2!\,2!}(0.10)^0(0.15)^0(0.25)^2(0.30)^2(0.20)^2 = 2.03\%$$

c) $\Pr(X_1 = 3, X_2 = 2, X_3 = 1, X_4 = 0, X_5 = 0) =$
$$\frac{6!}{3!\,2!\,1!\,0!\,0!}(0.10)^3(0.15)^2(0.25)^1(0.30)^0(0.20)^0 = 0.03\%$$

A Distribuição Poisson
A distribuição de Poisson não está diretamente relacionada às tentativas de Bernoulli. Esta distribuição é usada principalmente para modelar o número de ocorrências de um evento "raro" (de probabilidade baixa) durante um intervalo de tempo especificado. Por exemplo, o número de acidentes numa estrada durante um fim de semana, o número de bactérias presentes numa solução após um certo período são, entre outros, eventos modelados pela distribuição de Poisson.
Além disso, a distribuição de Poisson surge como um caso limite da distribuição Bin(n,p) quando n é grande e p é pequeno (próximo de zero) e, neste contexto, é muito útil em aproximações numéricas. Considere uma seqüência de variáveis

Bernoulli independentes, todas com a mesma probabilidade de sucesso p, que é um valor pequeno. Por exemplo, X_i é 1 se eu vejo uma Ferrari circulando pelo centro do Rio de Janeiro num dia qualquer, e é zero do contrário (eu não vejo a Ferrari). Suponha que eu observe este evento durante n dias seguidos, onde n é um número grande de dias. Então Y, o número de vezes em que eu vi uma Ferrari passando no centro do Rio (nos n dias) é uma variável Binomial com parâmetros n e p, onde n é grande e p é pequeno. Neste caso, o número de Ferraris observadas nos n dias pode ser aproximado por uma variável Poisson com a mesma média (n.p). Esta aproximação da Binomial pela Poisson será examinada em maiores detalhes posteriormente. A distribuição Poisson está relacionada ao Processo de Poisson, que será estudado no capítulo 4. Por isso, omitimos agora a derivação desta distribuição.

Uma variável aleatória tem distribuição Poisson com parâmetro λ, e escrevemos $X \sim$ Poisson(λ) se sua função de probabilidade é dada por:

$$f(x) = Pr\ (X = x) = \frac{\lambda^x . e^{-\lambda}}{x!} \quad \text{onde} \quad x = 0,1,2,3,..... \qquad (1.9.4)$$

Teorema 1.9.10.
Se $X \sim$ Poisson(λ) então: $E(X) = \lambda$ e $VAR(X) = \lambda$.

A demonstração deste resultado será omitida.

Exemplo 1.9.11.
O número de assaltos a banco numa cidade é uma variável aleatória com distribuição Poisson com média $\lambda = 3$ assaltos por mês. Calcule as seguintes probabilidades:

a) Do número de assaltos num mês ser maior que 4.
b) Do número de assaltos num mês ser menor que 2.

Solução
a) A probabilidade do número de assaltos num mês exceder 4 é:

$$Pr\ (X > 4) = Pr\ (X = 5) + Pr\ (X = 6) + ... = 1 - Pr(X \le 4) = 1 - \sum_{x=0}^{4} \frac{e^{-3}(3)^x}{x!} =$$

$$= 1 - e^{-3}\left\{1 + 3 + \frac{9}{2} + \frac{27}{6} + \frac{81}{24}\right\} = 81.53\%$$

$$b)\ Pr\ (X < 2) = Pr\ (X = 0) + Pr\ (X = 1) = e^{-3}\{1 + 3\} = 4e^{-3} = 19.91\%$$

A Distribuição Poisson Como Aproximação da Binomial

Teorema 1.9.12.
Seja $X \sim$ Bin(n, p). Se n é grande e p está próximo de zero então probabilidades para valores de X podem ser calculadas usando-se a distribuição Poisson com parâmetro λ = n.p.

Exemplo 1.9.13.
Suponha que $X \sim$ Bin(n,p) onde n é "grande" e p é "pequeno". Então X é

aproximadamente Poisson com parâmetro λ = n.p. Num caso específico, seja n = 25 e p = 0.1. A seguir, comparamos as probabilidades de X = 0, 1, 2..., 4 para os modelos Bin(25, 0.1) e Poisson(2.5). A última coluna da tabela representa a diferença percentual entre as probabilidades calculadas segundo os 2 modelos.

X	Pr (X = x) via distribuição Bin(25, 0.1)	Pr (X = x) via distribuição Poisson (2.5)	Diferença percentual
0	0.0718	0.0821	-14.34
1	0.1994	0.2052	-2.91
2	0.2659	0.2565	3.53
3	0.2265	0.2138	5.62
4	0.1384	0.1336	3.48

Os valores estão bastante próximos em todos os casos. A diferença percentual é grande quando x = 0 por que o valor da probabilidade é muito pequeno.

1.10. As Principais Distribuições Contínuas

Até agora falamos principalmente sobre densidades discretas, onde o espaço da variável aleatória consiste num número finito ou contável de resultados. O objetivo agora é apresentar as mais importantes densidades contínuas, onde o espaço da variável aleatória é um subintervalo de números reais.

Densidade Uniforme

A densidade Uniforme serve para modelar o seguinte fenômeno: "escolhe-se um número aleatoriamente num intervalo dado", por exemplo, o intervalo (0,1). A função "random", presente na maioria das linguagens de computador, nada mais é do que um mecanismo para gerar números com distribuição Uniforme no intervalo (0,1).

Uma variável aleatória X tem densidade uniforme no intervalo (a,b), e escrevemos $X \sim$ Unif(a,b) se a sua densidade é:

$$f(x) = \begin{cases} \frac{1}{b-a}, x \in (a,b) \\ 0, x \notin (a,b) \end{cases} \qquad (1.10.1)$$

Uma variável aleatória X com densidade uniforme no intervalo (a,b) tem a seguinte propriedade: qualquer subintervalo de comprimento d localizado dentro do intervalo (a,b) tem a mesma probabilidade.

A função de distribuição de uma variável aleatória Unif(a,b) é:

$$F(x)=\begin{cases}0, x<a\\ \dfrac{x-a}{b-a}, x\in[a,b]\\ 1, x>b\end{cases}$$

A média, variância e função geradora de momentos de uma variável Unif(a,b) são:

i) $E(X) = (a + b)/2$

ii) $VAR(X) = (b-a)^2/12$

iii) $M(t)=\dfrac{e^{tb}-e^{ta}}{t(b-a)}$

Exemplo 1.10.1.
Um ponto é escolhido ao acaso no intervalo [0,2]. Qual a probabilidade do número escolhido estar entre 1 e 3/2?

Solução
Neste caso a = 0 e b = 2, e f(x) = 1/2 para $x \in (0,2)$, e f(x) = 0 fora deste intervalo.

$$\Pr(1<X<3/2)=\int_1^{3/2} f(x)dx=\int_1^{3/2}\frac{dx}{2}=\frac{1}{2}.\frac{1}{2}=\frac{1}{4}$$

Exemplo 1.10.2.
Seja X uma variável aleatória contínua com densidade Uniforme no intervalo $(-\theta, \theta)$. Em cada caso abaixo calcule θ de forma a satisfazer a condição dada.

a) Pr (X > 1/2) = 1/4
b) Pr (X < 1/4) = 3/4
c) Pr (X > 1/2) = 2. Pr (X < -1)

Solução
A densidade Uniforme $(-\theta, \theta)$ tem a forma:

$f(x)=\dfrac{1}{2\theta}$ se $-\theta<x<\theta$ e f(x) = 0 se x está fora do intervalo $(-\theta, \theta)$.

Em qualquer caso:

$$\Pr(X>x)=\int_x^{\theta}\frac{1}{2\theta}dt=\frac{1}{2\theta}(\theta-x) \quad \text{se } -\theta<x<\theta \text{ e então:}$$

$$\Pr(X\le x)=F(x)=1-\frac{1}{2\theta}(\theta-x)=\frac{(\theta+x)}{2\theta} \quad \text{se } -\theta<x<\theta$$

Podemos então tentar calcular θ em cada caso:

a) $\Pr(X>1/2)=\dfrac{1}{2\theta}\left(\theta-\dfrac{1}{2}\right)=\dfrac{1}{2}-\dfrac{1}{4\theta}=\dfrac{1}{4}\Rightarrow\dfrac{1}{4}=\dfrac{1}{4\theta}\Rightarrow\theta=1$

b) Pr (X < 1/4) = ¾

$$\frac{(\theta+1/4)}{2\theta}=\frac{3}{4}\Leftrightarrow 4\theta+1=6\theta\Leftrightarrow 2\theta=1\Leftrightarrow\theta=1/2$$

c) Pr (X > 1/2) = 2. Pr (X < -1)

$$\frac{1}{2\theta}\left(\theta-\frac{1}{2}\right)=2\left\{\frac{\theta-1}{2\theta}\right\}\Leftrightarrow\left(\theta-\frac{1}{2}\right)=2(\theta-1)\Leftrightarrow\theta-2\theta=-2+(1/2)$$

$$\Leftrightarrow -\theta=-3/2\Leftrightarrow\theta=3/2$$

A Densidade Exponencial
Uma variável aleatória com densidade Exponencial é usada para modelar tempos de duração de equipamentos. Na verdade, existem densidades mais apropriadas para modelar este fenômeno, pois, como veremos mais tarde, a densidade Exponencial não leva em conta o desgaste do equipamento ao longo do tempo. A densidade Exponencial é definida para variáveis contínuas e maiores que zero, e depende de um parâmetro **positivo**, λ.

A densidade Exponencial é dada pela fórmula:

$f(x)=\lambda e^{-\lambda x}, x\ge 0$ (1.10.2)

e f(x) = 0 se x < 0. Note que λ é um número positivo sempre.

Notação: X ~ Expo(λ)

A função de distribuição associada a esta densidade é dada por:

$$F(x)=\begin{cases}0, x<0\\ \displaystyle\int_0^x \lambda e^{-\lambda u}.du=-e^{-\lambda u}\Big|_0^x=1-e^{-\lambda x}, x\ge 0\end{cases}$$

Note que o limite da função de distribuição quando x tende a $+\infty$ é um!
O próximo gráfico apresenta as densidades Exponenciais com parâmetros λ = 2, 4 e 8. Note que a densidade decai mais rápido quando λ é grande.

Densidades Exponenciais

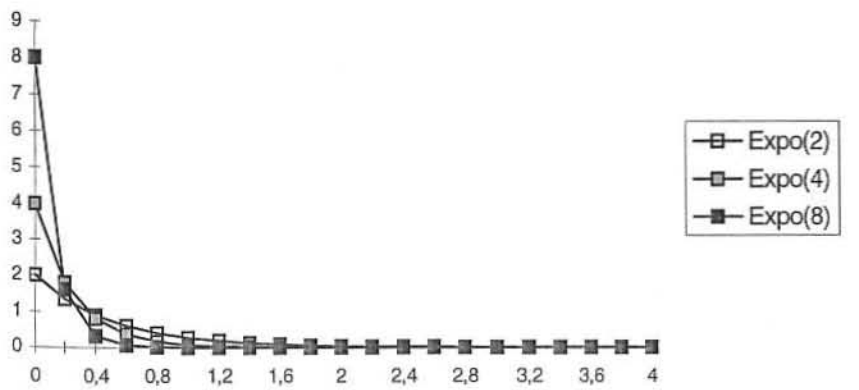

O próximo gráfico exibe a função de distribuição de uma variável aleatória com parâmetros $\lambda = 1$ e $\lambda = 2$.

Funções de Distribuição - Densidades Expo(1) e Expo(2)

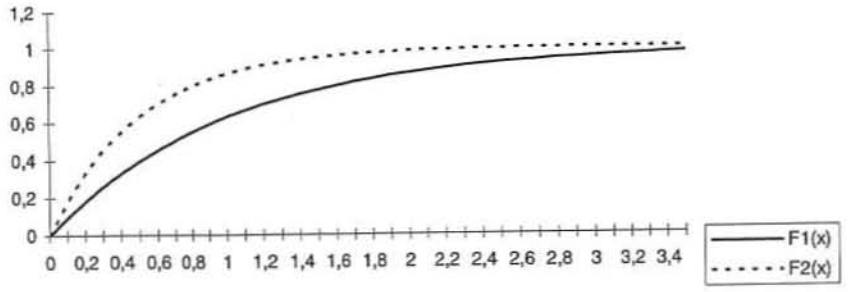

Existe uma parametrização alternativa da densidade Exponencial, dada por:

$$f(x) = \frac{1}{\lambda}.\exp\left(-\frac{x}{\lambda}\right) \text{ onde } x \geq 0 \text{ e } \lambda > 0 \qquad (1.10.3)$$

Nesta segunda parametrização, a média da variável aleatória é λ, e sua variância é λ^2, e a função geradora de momentos é $M(t) = \frac{1}{1-\lambda t}$, $\forall t < 1/\lambda$

Exemplo 1.10.3.
A duração de um componente eletrônico segue uma distribuição Exponencial com média λ. Encontre a probabilidade de que a duração do componente seja menor que a sua duração média. Calcule também a mediana da distribuição.

Solução
Queremos calcular $Pr(X < \lambda)$ onde X tem distribuição Exponencial com média λ.
$F(\lambda) = Pr(X \leq \lambda) = 1 - \exp(-\lambda/\lambda) = 1 - \exp(-1) = 0.6321$

Este resultado é válido para qualquer valor de $\lambda > 0$. por exemplo, se X tem distribuição Exponencial com média 2 então $Pr(X < 2) = 0.63212$, se X é Exponencial com média 1, $Pr(X < 1) = 0.63212$ etc.

Logo, a probabilidade de X durar menos que sua média é maior que 50%. A partir disso, concluímos que a mediana da densidade Exponencial deve estar abaixo da média, isto é, a mediana é um valor menor que λ (por quê?). Mas, a mediana é um valor $\underline{m}$ tal que:

$Pr(X \leq m) = Pr(X > m) = 0.50$

Isto é:

$$\int_0^m \frac{1}{\lambda}.\exp(-x/\lambda)\,dx = 0.50 \Rightarrow 1 - e^{-m/\lambda} = 0.50 \Rightarrow e^{-m/\lambda} = 0.50 \Rightarrow$$

$$\frac{-m}{\lambda} = \log(0.50) \Rightarrow -m = -\lambda.\log 2 \Rightarrow m = \lambda.\log 2 = 0.6931.\lambda$$

Esta última expressão indica que a mediana da densidade Exponencial pode ser escrita como múltiplo da média da mesma densidade.

Exemplo 1.10.4.
A duração de um fusível é uma variável aleatória com densidade Exponencial. Existem 2 processos de fabricação de um fusível: no primeiro, a vida média do fusível é de 100 horas, e no segundo processo a vida média do fusível é de 150 horas. No entanto, o custo de produção no primeiro processo é de C reais por fusível, enquanto no segundo processo o custo por fusível é 2.C. Se o fusível dura menos de 200 horas, o fabricante recebe uma multa de K reais.
Qual processo de fabricação deve ser usado?

Solução
A diferença entre os dois processos está na duração dos fusíveis. Para o processo I a duração média é $\lambda_1 = 100$ h e no caso do processo II temos uma duração média de $\lambda_2 = 150$ h. Qual o custo esperado segundo os dois processos?

No processo I:

$C_1 = C$ se $X > 200$ e
$= C + K$ se $X \leq 200$

$E(C_1) = C.\ Pr(X > 200) + (C+K).Pr(X \leq 200) =$

$C.e^{-2} + (C+K).\{1 - e^{-2}\} = K(1 - e^{-2}) + C$

No processo II:

$C_2 = 2.C$ se $X > 200$ e
$= 2.C + K$ se $X \leq 200$

onde agora X tem densidade Expo($\lambda = 150$). Logo:

$E(C_2) = 2C.\ Pr(X > 200) + (2C+K).Pr(X \leq 200) =$

$2C.e^{-4/3} + (2C+K).\{1 - e^{-4/3}\} = K(1 - e^{-4/3}) + 2C$

Comparando os custos médios segundo os 2 processos temos:

$E(C_2) - E(C_1) = K(1 - e^{-4/3}) + 2C - K(1 - e^{-2}) - C = C + K(e^{-2} - e^{-4/3}) \equiv$
$C + K(-0.1283) = C - 0.1283.K$

O processo a ser utilizado é o que tem menor custo esperado. Logo, o processo II será escolhido quando $C - 0.1283.K < 0$, isto é, quando $C < 0.1283.K$. Do

contrário, se C > 0.1283.K deve-se optar pelo processo I.
Por exemplo, se o custo unitário de produção é C = R$0.50 e a multa é K = R$5 devemos escolher o processo II pois C = 0.50 < 0.1283(5) = 0.64. Neste caso (custo unitário = C = 0.50) o processo II deverá ser escolhido sempre que a multa for maior que R$3.897. Do contrário devemos escolher o processo I.

A Falta de Memória da Densidade Exponencial
A densidade Exponencial é a única densidade contínua que possui a seguinte propriedade, conhecida como "falta de memória":

Pr (X > t + s | X > t) = Pr (X > s) onde s e t são números > 0.

Note que, se X ~ Expo(λ) então Pr (X > x) = exp(-x/λ). Logo,

$$\Pr(X > t+s \mid X > t) = \frac{\Pr(X > t+s)}{\Pr(X > t)} = \frac{e^{-(t+s)/\lambda}}{e^{-t/\lambda}} = e^{-s/\lambda} = \Pr(X > s)$$

Por exemplo, se a duração de uma lâmpada é modelada através da densidade Exponencial e observa-se que a lâmpada está funcionando no instante t então a probabilidade da lâmpada funcionar mais s horas é a mesma que a probabilidade de uma lâmpada nova funcionar s horas. Ou seja, não há desgaste com o passar do tempo, o que é irreal em muitas situações. Este fato torna o uso da densidade Exponencial pouco apropriado na modelagem de duração (ou vida) de muitos componentes eletrônicos ou seres vivos. A alternativa mais usual é a densidade Weibull.

A seguir, definimos a função Gama, que é uma generalização do fatorial para números não inteiros. Esta função servirá para definir uma densidade de probabilidade, a densidade Gama. A função Gama é extremamente útil quando desejamos encontrar momentos da densidade Exponencial.

Definição 1.10.5. Função Gama

A função Gama é definida como a seguinte integral:

$$\Gamma(\alpha) = \int_0^\infty y^{\alpha-1} e^{-y}\, dy \qquad \forall \alpha > 0$$

Teorema 1.10.6. Propriedades da Função Gama

i) Se $\alpha > 1$ então: $\Gamma(\alpha) = (\alpha-1)\,\Gamma(\alpha-1)$

ii) Se n é inteiro >1 então: $\Gamma(n) = (n-1)!$

iii) $\Gamma(1) = 0! = 1$

iv) $\Gamma(1/2) = \sqrt{\pi}$

Usando i) e iv) podemos concluir que:

$$\Gamma\left(\frac{3}{2}\right) = \frac{1}{2}\cdot\Gamma\left(\frac{1}{2}\right) = \frac{\sqrt{\pi}}{2}$$

$$\Gamma\left(\frac{5}{2}\right) = \frac{3}{2}\cdot\Gamma\left(\frac{3}{2}\right) = \frac{3\sqrt{\pi}}{4}$$

$$\Gamma\left(\frac{7}{2}\right) = \frac{5}{2}\cdot\Gamma\left(\frac{5}{2}\right) = \frac{15\sqrt{\pi}}{8}$$

etc...

Demonstração
iii) é direto (segue da definição e integrais por partes)
i) e ii) são provados via integração por partes
iv) é mais difícil (usa Jacobianos e coordenadas polares), existe uma demonstração simples, baseada na distribuição Normal.

A função Gama nos permite definir uma densidade contínua, válida para variável aleatória definidas no intervalo $(0,\infty)$.

Definição 1.10.7. Densidade Gama

Uma variável aleatória X tem densidade Gama com parâmetros α e β, e escrevemos:

X ~ Gama(α,β), se sua densidade é:

$$f(x) = \begin{cases} \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-x/\beta} & \text{se } x > 0, \alpha > 0 \text{ e } \beta > 0 \\ 0 & \text{do contrario} \end{cases} \qquad (1.10.4)$$

Os parâmetros α e β são números reais positivos. α é conhecido como parâmetro de forma, e β é o parâmetro de escala.

Teorema 1.10.8. Média, Variância e Função Geradora de Momentos de uma Variável Aleatória Gama

Se X ~ Gama(α, β) então:

i) $E(X) = \alpha.\beta$

ii) $VAR(X) = \alpha.\beta^2$

iii) $M(t) = \frac{1}{(1-\beta t)^\alpha}$, sempre que $t < 1/\beta$

Demonstração - omitida

Nota
Muitos livros escrevem a densidade Gama de uma maneira ligeiramente diferente desta. Em particular, esta nova parametrização é útil no contexto de Estatística Bayesiana.

A parametrização alternativa para a densidade Gama é:

$$f(x) = \frac{1}{\Gamma(\alpha)}\lambda^{\alpha}.x^{\alpha-1}.e^{-\lambda x} \quad \text{para } x > 0,\ \alpha > 0,\ \lambda > 0 \qquad (1.10.5)$$

Ou seja, $\lambda = 1/\beta$ onde β é o segundo parâmetro da densidade na forma antiga.

Neste caso é claro que:

$$E(X) = \frac{\alpha}{\lambda},\ VAR(X) = \frac{\alpha}{\lambda^2},\ M(t) = \left[\frac{\lambda}{\lambda - t}\right]^{\alpha} \text{ se } t < \lambda$$

A não ser que explicitamente digamos o contrário, a parametrização adotada aqui será a da definição 1.10.7.

O próximo gráfico exibe algumas densidades Gama com parâmetro de escala β=1.

Densidades Gama com parâmetro de escala igual a 1

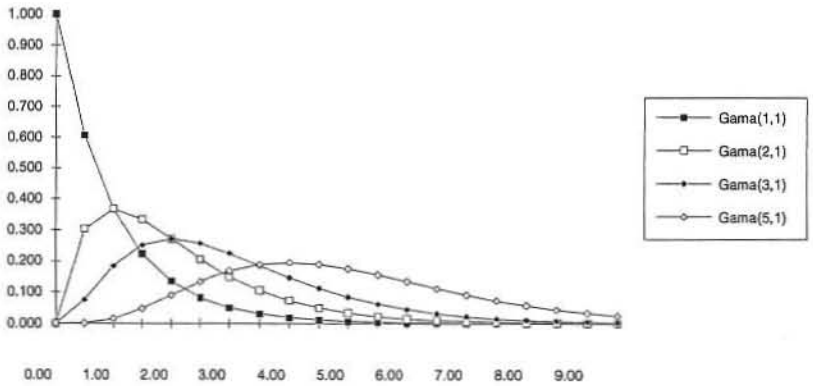

Definição 1.10.9. Densidade Qui-Quadrado
Dizemos que a variável aleatória X tem densidade Qui-Quadrado com r graus de liberdade, e escrevemos $X \sim \chi_r^2$ se a densidade de X é:

$$f(x) = \begin{cases} \frac{1}{\Gamma(r/2)2^{r/2}} x^{r/2-1} e^{-x/2} & x > 0,\ r \text{ inteiro} > 0 \\ 0 & \text{do contrário} \end{cases} \qquad (1.10.6)$$

Teorema 1.10.10. Média, Variância e Função Geradora de Momentos de uma Variável Aleatória Qui-Quadrado com r Graus de Liberdade

Se $X \sim \chi_r^2$ então:

i) $E(X) = r$
ii) $VAR(X) = 2r$
iii) $M(t) = (1-t)^{-r/2}$ e esta função geradora de momentos é definida para $t < 1/2$.

Isto é, a média de uma variável Qui-Quadrado corresponde número de graus de liberdade da distribuição, enquanto a variância é o dobro da média.

Observação
Os momentos de uma distribuição χ_r^2 são obtidos diretamente a partir do teorema 1.10.8. notando-se que a densidade χ_r^2 é um caso particular de uma densidade Gama, na qual fazemos $\alpha = r/2$ e $\beta = 2$.

A densidade Exponencial é também um caso particular da densidade Gama, onde $\alpha = 1$ e $\beta = \lambda$.

A densidade Qui-Quadrado está intimamente relacionada à densidade Normal, como veremos posteriormente.

A seguir, apresentamos o gráfico da densidade Qui-Quadrado para diversos graus de liberdade.

Densidades Qui-quadrado com 1, 2, 4 e 6 graus de liberdade

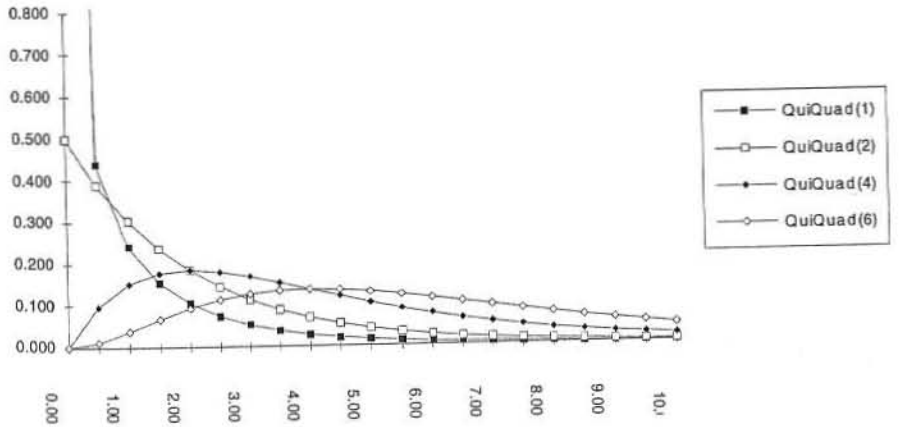

A densidade Qui-Quadrado é tabelada para diversos graus de liberdade. As tabelas geralmente fornecem o valor $x_{1-\alpha}$ tal que Pr $(X < x_{1-\alpha}) = 1 - \alpha$ para α = 1%, 5 %, 10 %. Também existem tabelas que apresentam o valor x_α tais que Pr $(X < x_\alpha) = \alpha$, isto é, Pr $(X > x_\alpha) = 1 - \alpha$.

Em resumo, as densidades Qui-Quadrado e Exponencial são apenas casos particulares da densidade Gama:

x^2_r = Gama(r/2,2)

Expo(λ) = Gama(1,λ)

A Distribuição Normal (Gaussiana)

Erros de mensuração de fenômenos físicos ou econômicos são freqüentemente modelados pela distribuição Normal, mas esta não é a única aplicação desta densidade. Por exemplo, a distribuição dos pesos, alturas e QI's das pessoas numa população também já foram modelados com sucesso por esta distribuição. A distribuição Normal tem a forma de um sino, e possui dois parâmetros, μ e σ^2.

A distribuição Normal é também chamada de Gaussiana em homenagem ao matemático Carl Friederich Gauss (1777-1855), que a utilizou pela primeira vez na modelagem de erros de medida.

A distribuição Normal também funciona como uma boa aproximação para outras densidades. Por exemplo, sob algumas condições pode-se provar que a densidade Binomial pode ser aproximada pela Normal.

Definição 1.10.11. Densidade Normal com Média μ e Variância σ^2
Seja X uma variável aleatória contínua definida nos números reais. Dizemos que X tem densidade Normal com média μ e variância σ^2 se a densidade de X é:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} . e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad \text{onde } \sigma^2 > 0 \text{ e } \mu \in R \qquad (1.10.7)$$

Notação: $X \sim N(\mu, \sigma^2)$
Note que o segundo parâmetro (σ^2) nesta notação é a **variância** de X.

A seguir, exibimos gráfico das distribuições Normais com média zero e variâncias 1, 2 e 4.

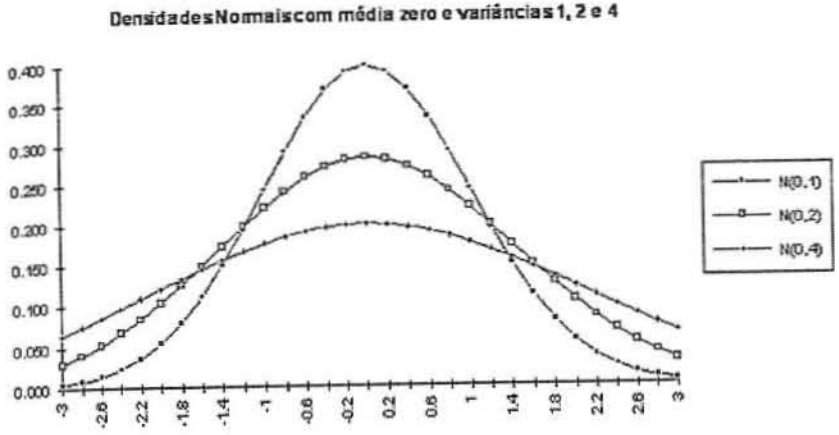

O máximo destas densidades é encontrado quando x = 0, isto é, quando x é igual à média da distribuição. Isto vale para qualquer distribuição Normal: o máximo de f(x) é obtido fazendo-se $x = \mu$, onde μ é a média da Normal.

Também, quanto maior o valor da variância σ^2, mais "espalhada" é a distribuição.

Propriedades da Distribuição Normal

1) f(x) dada por

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} . e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

integra a 1.

2) f(x) é sempre não negativa.
3) Os limites de f(x) quando x tende a $+\infty$ e $-\infty$ são iguais a zero.
4) A densidade $N(\mu, \sigma^2)$ é **simétrica em torno de μ**, ou seja:
$f(\mu + x) = f(\mu - x)$
5) O valor máximo de f(x) ocorre em $x = \mu$
6) Os pontos de inflexão de f(x) são $x = \mu + \sigma$ e $x = \mu - \sigma$

Teorema 1.10.12. Média e Variância da Distribuição Normal

Se $X \sim N(\mu, \sigma^2)$ então $E(X) = \mu$ e $VAR(X) = \sigma^2$

Demonstração
A média da densidade pode ser facilmente encontrada a partir da definição.

levantamento bibliográfico é obrigatório quando se pretende realizar uma pesqui

$$E(X) = \int_{-\infty}^{\infty} x.\left(\frac{1}{\sqrt{2\pi\sigma^2}}.\exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}\right)dx$$

Fazendo a mudança de variáveis $z = (x-\mu)/\sigma$ na integral acima obtemos:
$x = \mu + \sigma.z \Rightarrow dx = \sigma.dz$

$$E(X) = \int_{-\infty}^{\infty} (\mu+\sigma.z)\left(\frac{1}{\sqrt{2\pi\sigma^2}}.\exp\left\{-\frac{z^2}{2}\right\}\right)\sigma.dz =$$

$$= \mu\int_{-\infty}^{\infty}\frac{1}{\sqrt{2\pi}}.\exp\left\{-\frac{z^2}{2}\right\}dz + \sigma.\int_{-\infty}^{\infty}\frac{z}{\sqrt{2\pi}}.\exp\left\{-\frac{z^2}{2}\right\}dz$$

A primeira integral acima é apenas a integral de uma densidade N(0,1) e, portanto, é 1. A segunda integral é zero, como mostrado abaixo:

$$\int_{-\infty}^{\infty}\frac{z}{\sqrt{2\pi}}.\exp\left\{-\frac{z^2}{2}\right\}dz = \frac{-1}{\sqrt{2\pi}}.\exp\left\{-\frac{z^2}{2}\right\}\Bigg|_{-\infty}^{\infty} = 0$$

Logo:

$E(X) = \mu(1) + \sigma(0) = \mu$

A variância de X é, pela definição:

$$VAR(X) = E\left[(X-\mu)^2\right] = \int_{-\infty}^{\infty}\frac{(x-\mu)^2}{\sqrt{2\pi\sigma^2}}.\exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}dx$$

Fazendo novamente a mudança de variáveis $z = (x-\mu)/\sigma$ temos:

$$VAR(X) = \int_{-\infty}^{\infty}\frac{z^2.\sigma^2}{\sqrt{2\pi\sigma^2}}.\exp\left\{-\frac{z^2}{2}\right\}\sigma dz = \sigma^2.\int_{-\infty}^{\infty}\frac{z^2.}{\sqrt{2\pi}}.\exp\left\{-\frac{z^2}{2}\right\}dz =$$

$$= \sigma^2\left\{\frac{-ze^{-z^2/2}}{\sqrt{2\pi}}\Bigg|_{-\infty}^{\infty} + \int_{-\infty}^{\infty}\frac{1}{\sqrt{2\pi}}.\exp\left\{-\frac{z^2}{2}\right\}\sigma dz\right.$$

$$= \sigma^2(0+1) = \sigma^2$$

Função Geradora de Momentos da Distribuição Normal

Se $X \sim N(\mu, \sigma^2)$ então a sua função geradora de momentos é dada por:

$$M(t) = E(e^{tX}) = e^{\left(\mu t + \frac{\sigma^2 t^2}{2}\right)} \qquad (1.10.8)$$

A demonstração deste fato será omitida.

Função de Distribuição de uma Variável Normal

Se $X \sim N(\mu, \sigma^2)$ então a sua função de distribuição é dada por:

$$F(x) = Pr(X \le x) = \int_{-\infty}^{x}\frac{1}{\sqrt{2\pi\sigma^2}}\exp\left\{\frac{-(u-\mu)^2}{2\sigma^2}\right\}du$$

Esta integral **não pode** ser resolvida analiticamente. Entretanto, é possível transformar uma variável $N(\mu, \sigma^2)$ numa N(0,1) sem grandes dificuldades. Então podemos tabelar os valores da função de distribuição de uma N(0,1), e esta tabela pode ser usada para encontrar probabilidades envolvendo qualquer variável aleatória Normal.

O próximo teorema é muito importante, pois nos diz como podemos obter uma variável N(0,1) a partir de uma Normal qualquer. Isso nos permite usar uma única tabela para quaisquer cálculos probabilísticos envolvendo variáveis Normais.

Teorema 1.10.13.

Seja $X \sim N(\mu, \sigma^2)$. Então a variável $Z = (X - \mu)/\sigma$ tem distribuição Normal com média zero e variância um, isto é, $Z \sim N(0,1)$.

A demonstração deste fato é trivial e pode ser feita, por exemplo, através da função geradora de momentos.

Em resumo, para transformar uma variável aleatória Normal com quaisquer parâmetros numa Normal (0,1) você deve:
1- Subtrair a média μ
2- Dividir o resultado por σ, o desvio padrão.
A variável aleatória resultante deste procedimento é uma N(0,1).

A Densidade Normal Padrão (N(0,1))

Esta densidade é importante porque sua função de distribuição está tabelada e todas as outras Normais podem ser transformadas numa Normal padrão, de acordo com o teorema acima. Geralmente denotamos por Z uma variável aleatória N(0,1).

A densidade de Z, chamada de Normal padrão e denotada por $\varphi(.)$, é:

$$\varphi(z) = \frac{1}{\sqrt{2\pi}}.e^{-z^2/2} \qquad (1.10.9)$$

A função de distribuição associada à esta densidade é uma função tabelada, denotada por $\Phi(.)$.

$$\Phi(z) = Pr(Z \le z) = \int_{-\infty}^{z} \frac{1}{\sqrt{2\pi}} . e^{-u^2/2} du \qquad (1.10.10)$$

Note que a densidade é a derivada da função de distribuição, e assim:

$$\varphi(z) = \frac{d\Phi(z)}{dz}$$

Se $Z \sim N(0,1)$ então a sua função geradora de momentos é:

$$M(t) = \exp(t^2/2) \qquad (1.10.11)$$

No final do livro apresentamos uma tabela contendo alguns valores de $\Phi(z)$, a função de distribuição da Normal padrão. Em geral, para Z uma variável com distribuição N(0,1), a função tabelada é $\Phi(z) = Pr\ (Z \le z)$. Por exemplo, $\Phi(1.645) = 0.95$, $\Phi(1.96) = 0.975$ e $\Phi(2.36) = 0.99$. Diversos softwares (entre eles o Excel) já têm implementadas diversas funções de distribuição, entre as quais a Normal e a Qui-Quadrado.

Como calcular probabilidades para uma variável $N(\mu, \sigma^2)$ usando a tabela da função de distribuição da N(0,1)?

Teorema 1.10.14.

Seja $X \sim N(\mu, \sigma^2)$. Suponha que desejamos calcular $Pr\ (a \le X \le b)$. Então:

$$Pr\ (a \le X \le b) = Pr\left(\frac{a-\mu}{\sigma} \le \frac{X-\mu}{\sigma} \le \frac{b-\mu}{\sigma}\right) = Pr\left(\frac{a-\mu}{\sigma} \le Z \le \frac{b-\mu}{\sigma}\right) =$$

$$= \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right) \qquad (1.10.12)$$

onde $Z \sim N(0,1)$

O que este teorema nos dá é uma "receita" para o cálculo de probabilidades em termos da função de distribuição de uma variável aleatória N(0,1). A partir do resultado do teorema podemos calcular probabilidades para **qualquer** variável aleatória Normal a partir da função tabelada $\Phi(.)$.

A maioria das tabelas para a função de distribuição da N(0,1) só fornece os valores das probabilidades para valores de z positivos. Como encontrar probabilidades para outros valores de z? É só usar a simetria da densidade N(0,1).

Para todo z, o valor da função $\Phi(z)$ é a área hachurada na figura a seguir.

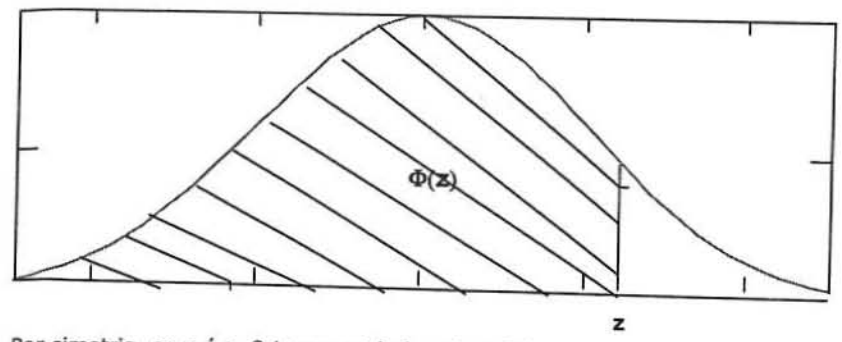

Por simetria, se z é > 0 temos: $\Phi(-z) = 1 - \Phi(z)$, o que nos permite calcular $\Phi(.)$ para valores negativos.

A seguir, apresentamos alguns exemplos do cálculo de probabilidades baseado numa tabela da função de distribuição N(0,1).

Probabilidade de um Intervalo Simétrico em Torno de Zero

Considere o cálculo de $Pr\ (-t < Z < t)$ onde $Z \sim N(0,1)$ e t é um número maior que zero. Então:

$$\mathbf{Pr\ \{-t < Z < t\} = 1 - 2\{\Phi(-t)\} = 1 - 2\ \{1 - \Phi(t)\} = 2.\Phi(t) - 1}$$

Exemplo 1.10.15.

Seja $X \sim N(\mu, \sigma^2)$ e $k > 0$. Mostre que $Pr\ \{\mu - k\sigma < X < \mu + k\sigma\}$ só depende de k (não depende de μ e σ).

Solução

Note que a probabilidade desejada é a probabilidade de X estar a uma distância menor ou igual a k desvios padrões da sua média.

$$Pr\ (\mu - k\sigma < X < \mu + k\sigma) = Pr\ (-k\sigma < X - \mu < +k\sigma) =$$

$$= Pr\left(-\frac{k\sigma}{\sigma} < \frac{X-\mu}{\sigma} < +\frac{k\sigma}{\sigma}\right) = Pr\left(-k < \frac{X-\mu}{\sigma} < k\right) = Pr\ (-k < Z < +k) =$$

$$= 2.\Phi\ (k) - 1$$

onde usamos o fato de que $Z = (X-\mu)/\sigma$ tem distribuição N(0,1) e as simetrias desta densidade indicadas anteriormente.

As probabilidades para alguns valores k estão abaixo:

$$\mathbf{Pr\ (\mu - \sigma < X < \mu + \sigma) = 2.\Phi(1) - 1 = 0.6826}$$
$$\mathbf{Pr\ (\mu - 1.645\sigma < X < \mu + 1.645\sigma) = 2.\Phi(1.645) - 1 = 0.90}$$
$$\mathbf{Pr\ (\mu - 1.96\sigma < X < \mu + 1.96\sigma) = 2.\Phi(1.96) - 1 = 0.95}$$
$$\mathbf{Pr\ (\mu - 2.57\sigma < X < \mu + 2.57\sigma) = 2.\Phi(2.57) - 1 = 0.99}$$

A grande "dica" em relação ao uso da tabela da N(0,1) é: faça um gráfico! No gráfico, indique a área que você deseja calcular e desta forma será quase impossível você errar para **qualquer** intervalo cuja probabilidade precise calcular

Exemplo 1.10.16.
Seja $X \sim N(3,4)$. Encontre o número c tal que $Pr(X > c) = 2.\ Pr(X \leq c)$

Solução
O primeiro passo é sempre transformar X numa variável N(0,1). Mas, Z = (X - 3)/2 tem distribuição N(0,1). Note que 2 é a raiz quadrada da variância, que é o parâmetro que aparece na notação da densidade Normal.

$$Pr(X > c) = Pr\left(\frac{X-3}{2} > \frac{c-3}{2}\right) = Pr\left(Z > \frac{c-3}{2}\right) = 1 - \Phi\left(\frac{c-3}{2}\right)$$

Analogamente:

$$Pr(X \leq c) = Pr\left(\frac{X-3}{2} \leq \frac{c-3}{2}\right) = Pr\left(Z \leq \frac{c-3}{2}\right) = \Phi\left(\frac{c-3}{2}\right)$$

Então, usando a condição $Pr(X > c) = 2.\ Pr(X \leq c)$ temos:

$$1 - \Phi\left(\frac{c-3}{2}\right) = 2.\Phi\left(\frac{c-3}{2}\right) \Rightarrow 3.\Phi\left(\frac{c-3}{2}\right) = 1 \Rightarrow \Phi\left(\frac{c-3}{2}\right) = \frac{1}{3}$$

Da tabela de $\Phi(.)$ temos:

$$\frac{c-3}{2} = -0.43 \Rightarrow c = 2.14$$

Exemplo 1.10.17.
A durabilidade de um pneu de certa marca é uma variável aleatória Normal com média 56000 km e desvio padrão 8000 km.
a) Qual a probabilidade de que um dado pneu dure mais de 60000 km?
b) Qual a probabilidade de que os 4 pneus de um carro durem mais de 6000 km? Escreva explicitamente as hipóteses que você usou para chegar a este número.

Solução
a) X = duração do pneu. $X \sim N(56000, (8000)^2)$. Então: Z = (X - 56000)/8000 tem distribuição N(0,1).

$$Pr(X > 60000) = Pr\left(\frac{X-56000}{8000} > \frac{60000-56000}{8000}\right) =$$

$$Pr(Z > 0.5) = 1 - \Phi(0.5) = 1 - 0.691 = 0.309$$

b) Suponha que as durações dos 4 pneus do carro são independentes. Então, podemos considerar as variáveis aleatórias independentes X_1, X_2, X_3, X_4 onde X_i = 1 ou 0, dependendo do fato do i-ésimo pneu ter durado ou não mais de 60,000 km. As variáveis X_1, X_2, X_3, X_4 são independentes com densidade de Bernoulli e parâmetro p = 0.309.

A variável de interesse é $Y = X_1 + X_2 + X_3 + X_4$, o número de "sucessos" (cada sucesso é equivalente ao pneu ter durado mais de 60000 km) em 4 tentativas (cada tentativa corresponde a um pneu do carro). O evento de interesse é Y = 4. Mas Y tem densidade Binomial com parâmetros n = 4 e p = 0.309, e assim:

$$Pr(Y = 4) = \frac{4!}{4!0!}(0.309)^4(0.691)^0 = (0.309)^4 = 0.912\%$$

A hipótese mais questionável nesta solução é a independência da durabilidade dos pneus. Uma solução mais realista levaria em conta que as durações dos pneus não são independentes, por exemplo, os pneus de um lado do carro poderiam durar mais que os do outro lado, ou os pneus do eixo dianteiro poderiam se desgastar mais rápido. Entretanto, não podemos levar em conta a dependência entre as variáveis, a não ser que ela esteja completamente especificada (em termos da densidade conjunta das variáveis).

Exemplo 1.10.18.
A linha de produção numa fábrica de refrigerantes é uma operação complicada. Sabe-se (por experiências anteriores) que o tempo necessário para consertar uma engarrafadora de bebidas é uma variável aleatória Normal com média 120 minutos e desvio padrão 4 minutos. A engarrafadora é essencial no processo, e se esta máquina fica parada por mais de 125 minutos todo o processo de fabricação tem que ser reiniciado e a produção deve ser jogada fora. O custo decorrente disso é R$10,000. O custo do reparo da máquina é RC_1$.

a) Qual a probabilidade da engarrafadora ficar parada por mais de 125 minutos?

b) Qual o custo esperado decorrente de uma interrupção no processo de fabricação de refrigerantes?

c) Suponha que a empresa consiga alterar o tempo médio de reparo da engarrafadora para 115 minutos se contratar mais uma equipe de manutenção. Entretanto, isso vai elevar o custo do reparo da máquina para RC_2$. Em que condições é vantajoso contratar a nova equipe de manutenção?

Solução
a) A probabilidade de a máquina ficar parada mais de 125 minutos é:

$$Pr(X > 125) = Pr\left(Z > \frac{125-120}{4}\right) = Pr(Z > 1.25) =$$

$$1 - \Phi(1.25) = 1 - 0.8944 = 0.1056$$

b) O custo esperado de interrupção do processo leva em conta o custo de reparo da máquina e um custo adicional relativo a uma eventual perda na produção. Se a máquina fica parada 125 minutos ou menos, o custo é C_1. No entanto, se a máquina fica parada mais de 125 minutos, o custo é 10,000 + C_1, pois a produção teve que ser jogada fora. Seja C o custo de interrupção. Daí:

$$E(C) = 0.1056.\{10000 + C_1\} + 0.8944.C_1 = 1056 + C_1$$

os cursos de graduação, já que deve ser o primeiro acadêmico [illegible]

c) Se agora o tempo médio de reparo foi reduzido para 115 minutos temos:
O valor esperado do custo de interrupção passa a ser:
$E(C) = 0.0062.\{10000 + C_2\} + 0.9938.C_1 = 62 + C_2$

A contratação da nova equipe de manutenção é vantajosa se:

$62 + C_2 < 1056 + C_1$, isto é, se $C_2 - C_1 < 994$.

Do contrário, é melhor não contratar a nova equipe e não aumentar os custos de manutenção.

Exemplo 1.10.19.
Seja X o diâmetro em mm de um bocal e suponha que X tem distribuição Normal com média μ e variância 1.
X deve seguir certas especificações (estar entre 10 e 12 mm), e se o diâmetro do bocal estiver fora das especificações o fabricante terá prejuízo. Seja T o lucro por bocal produzido e suponha que:

$$T = \begin{cases} C_1 & \text{se } 10 \le X \le 12 \\ -C_2 & \text{se } X < 10 \\ -C_3 & \text{se } X > 12 \end{cases}$$

Qual valor de μ resulta no maior lucro esperado?

Solução
O lucro esperado é:

$E(T) = C_1.Pr\ (10 \le X \le 12) - C_2.Pr\ (X < 10) - C_3.Pr\ (X > 12)$

Mas:

$$Pr\ (10 \le X \le 12) = Pr\left(\frac{10-\mu}{1} \le \frac{X-\mu}{1} \le \frac{12-\mu}{1}\right) = Pr\ (10-\mu \le Z \le 12-\mu) =$$

$$= \Phi\ (12-\mu) - \Phi\ (10-\mu)$$

Analogamente:
$Pr\ (X < 10) = \Phi(10-\mu)$ e,
$Pr\ (X > 12) = 1 - \Phi(12-\mu)$

Logo o lucro médio por bocal é:

$$E(T) = C_1[\Phi(12-\mu) - \Phi(10-\mu)] - C_2.\Phi\ (10-\mu) - C_3.[1 - \Phi\ (12-\mu)] =$$

$$= (C_1 + C_3).\Phi\ (12-\mu) - (C_1 + C_2).\Phi\ (10-\mu) - C_3$$

O lucro esperado por bocal é função da média (desconhecida) μ. Para encontrar o máximo do lucro esperado devemos diferenciar a expressão acima com relação a μ.

$$\frac{dE(T)}{d\mu} = (C_1 + C_3).(-1)\ \varphi\ (12-\mu) - (C_1 + C_2).(-1)\ \varphi\ (10-\mu)$$

Igualando-se esta derivada a zero temos:

$$\frac{dE(T)}{d\mu} = 0 \Rightarrow \frac{\varphi(12-\mu)}{\varphi(10-\mu)} = \frac{C_1 + C_2}{C_1 + C_3}$$

$$\Rightarrow \frac{(1/\sqrt{2\pi})\ \exp\left\{-(12-\mu)^2/2\right\}}{(1/\sqrt{2\pi})\ \exp\left\{-(10-\mu)^2/2\right\}} = \frac{C_1 + C_2}{C_1 + C_3}$$

$$\Rightarrow \exp\ \{22 - 2\mu\} = \frac{C_1 + C_3}{C_1 + C_2} \Rightarrow 22 - 2\mu = \log\left(\frac{C_1 + C_3}{C_1 + C_2}\right)$$

$$\Rightarrow \mu = 11 - \frac{1}{2}\log\left(\frac{C_1 + C_3}{C_1 + C_2}\right)$$

onde "log" indica o logaritmo natural.

Por exemplo, se $C_1 = 10$ e $C_2 = C_3 = 5$ então: $\mu = 11 - (1/2)\ \log(1.5) = 11 - 0.2027 = 10.7973$

Exemplo 1.10.20.
A velocidade (em km/h) dos carros num túnel do Rio de Janeiro num horário de pouco movimento é uma variável aleatória Normal com média 85 km/h e desvio padrão 10 km/h.

a) A que velocidade você deve trafegar para estar entre os 5% mais rápidos?
b) A velocidade máxima permitida no túnel é 80 km/h, mas há uma tolerância de 10% (e então, se você estiver a uma velocidade menor ou igual a 88 km/h não leva multa). Qual a probabilidade de um carro selecionado aleatoriamente ser multado?

Solução

a) Seja X a velocidade de um carro no túnel. Sabe-se que X tem distribuição N(85, 100). Para você estar entre os 5% mais rápidos, você deverá estar com velocidade acima do percentil 95% da distribuição de X. Mas, quem é este ponto? Basta olhar para o percentil correspondente da distribuição N(0,1), que é 1.645 e padronizar a variável X. Assim, a quilometragem tal que, 95% dos carros andam abaixo deste valor é um certo valor u que satisfaz:

$$\frac{u - 85}{10} = 1.645 \Rightarrow u = 101.45 \text{ km/h}$$

b) Agora precisamos encontrar Pr (X > 88). Novamente, basta padronizar a variável X e transformá-la numa N(0,1).

$$Pr(X > 88) = Pr\left(\frac{X - 85}{10} > \frac{88 - 85}{10}\right) = Pr(Z > 0.3) = 1 - \Phi(0.3) = 38.21\%$$

é a probabilidade de um carro ser multado.

os cursos de graduação, deveria ser um conhecimento adquirido dura

1.11. O Teorema Central do Limite

O teorema central do limite é um dos resultados fundamentais da teoria de probabilidades. Por que ele é tão importante? Em palavras, o teorema diz que toda soma de variáveis aleatórias independentes é aproximadamente Normal, desde que o número de termos na soma seja suficientemente grande.

Teorema 1.11.1.
Sejam $X_1, X_2..., X_n$ variáveis aleatórias **independentes** tais que $E(X_i) = \mu_i$ e $VAR(X_i) = \sigma_i^2$, ambas finitas. Seja $Y = X_1 + X_2 +... + X_n$. Então, sob condições bastante gerais podemos afirmar que:

$$Z = \frac{Y - \sum_{i=1}^{n} \mu_i}{\sqrt{\sum_{i=1}^{n} \sigma_i^2}} \qquad (1.11.1)$$

tem aproximadamente uma distribuição N(0,1). Esta aproximação torna-se cada vez melhor à medida que n cresce.

A importância do teorema decorre do fato da distribuição dos X_i's ser qualquer uma, desde que a média e a variância dos X_i´s sejam finitas!

O teorema central do limite pode ser escrito de maneira equivalente usando-se a média de variáveis aleatórias (ao invés da soma). Esta nova versão do teorema é especialmente importante quando os X_i 's são **identicamente distribuídos, além de independentes**, isto é, todos têm a mesma distribuição de probabilidade.

Nota:

Dizemos que $X_1, X_2..., X_n$ são *identicamente distribuídos* quando todos têm a mesma distribuição de probabilidade. Em particular neste caso, a média e a variância são as mesmas para todos os X_i, isto é, $E(X_i) = \mu$ e $VAR(X_i) = \sigma^2$ para i = 1, 2..., n.

Se, além de identicamente distribuídos, os X_i's são independentes, dizemos que eles são i.i.d. (independentes e identicamente distribuídos).

Uma versão simplificada do Teorema Central do Limite é mostrada a seguir.

Teorema 1.11.2. Teorema Central do Limite (Versão iid)
Sejam $X_1, X_2..., X_n$ variáveis aleatórias **independentes e identicamente distribuídas (iid)** tais que $E(X_i) = \mu$ e $VAR(X_i) = \sigma^2$, ambas finitas. Seja $Y = X_1 + X_2 +... + X_n$. Então, sob condições bastante gerais podemos afirmar que a variável:

$$Z = \frac{Y - n\mu}{\sqrt{n\,\sigma^2}} \qquad (1.11.2)$$

tem aproximadamente uma distribuição N(0,1). Esta aproximação torna-se cada vez melhor à medida que n cresce.

O teorema pode ser reescrito em termos da média amostral, $\overline{X}$, como a seguir.

Teorema 1.11.3. Teorema Central do Limite (versão iid em termos da média amostral)
Sejam $X_1, X_2..., X_n$ variáveis aleatórias **independentes e identicamente distribuídas (iid)** tais que $E(X_i) = \mu$ e $VAR(X_i) = \sigma^2$, ambas finitas. Seja $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$ a média amostral. Então, sob condições bastante gerais podemos afirmar que:

$$Z = \frac{\overline{X} - \mu}{\sqrt{\sigma^2/n}} = \sqrt{n}\left(\frac{\overline{X} - \mu}{\sigma}\right) \qquad (1.11.3)$$

tem aproximadamente uma distribuição N(0,1). Esta aproximação torna-se cada vez melhor à medida que n cresce.

Note que as expressões (1.11.2) e (1.11.3) são completamente equivalentes, pois:

$E(Y) = E(X_1 + X_2 +... + X_n) = n.\mu$

$E(\overline{X}) = E(Y/n) = \mu$

$VAR(Y) = n.\sigma^2$

$VAR(\overline{X}) = VAR(Y)/n^2 = \sigma^2/n$

E assim:

$$Z = \frac{Y - n\mu}{\sqrt{n.\,\sigma^2}} = \frac{(Y - n\mu)/n}{\left(\sqrt{n.\,\sigma^2}\right)/n} = \frac{\overline{X} - \mu}{\sqrt{\sigma^2/n}} = \sqrt{n}\left(\frac{\overline{X} - \mu}{\sigma}\right)$$

Na prática, o que é preciso supor para usar o teorema central do limite?

- o número de termos na soma é relativamente grande (n > 20 ou n > 30 costumam ser suficientes).
- a distribuição dos X_i's é "bem comportada", isto é, não é muito assimétrica. Em casos onde a distribuição de cada X_i é muito diferente de uma Normal geralmente é necessário aumentar n para garantir uma aproximação razoável.

os casos de graduação, já que deve ser o primeiro passo para qualquer ativi
acadêmica. Uma pesquisa de campo ou de

Note que o teorema central do limite é aplicado a uma transformação linear de Y, e não ao próprio Y. Para que serve esta transformação? O objetivo dela é padronizar Y, transformando-o numa variável aleatória com média zero e variância 1. Esta nova variável tem a "cara" de uma N(0,1).

Como transformar uma variável aleatória com média μ e variância σ^2 numa variável com média zero e variância um?

Suponha que W é uma variável aleatória qualquer com média E(W) = μ e variância VAR(W) = σ^2. Então:

$$Z = \frac{W - E(W)}{\sqrt{VAR(W)}} \qquad (1.11.4)$$

é uma variável aleatória com média 0 e variância 1.

Ou seja, para construir uma variável "padronizada" (com média zero e variância um) a partir de uma variável aleatória qualquer W devemos fazer:
Subtrair a média de W,
Dividir o resultado pelo desvio padrão de W.

Este tipo de transformação foi usado para gerar uma variável Z com média zero e variância 1 a partir da soma (ou média) de $X_1, X_2..., X_n$. Esta nova variável Z, dada pelas expressões (1.11.2) e (1.11.3), tem aproximadamente a densidade N(0,1) quando n é grande.

Exemplo 1.11.4.
Um teste padrão é aplicado a todos os formandos de Engenharia. Com base nos testes aplicados num passado recente sabe-se que a nota no teste é uma variável aleatória com média 60 e desvio padrão 8. A nota média dos 100 alunos da Universidade XYZ que fizeram o teste neste ano foi 58. Existe evidência para sugerir que a nota dos alunos da Universidade XYZ foi pior que a dos outros? Para verificar se isso é verdade, calcule a probabilidade de que a média amostral seja menor ou igual a 58 para uma amostra de tamanho 100.

Solução
A nota na população de alunos de Engenharia é uma variável com média 60 e desvio padrão 8. Seja $\overline{X}$ a nota média dos alunos da Universidade XYZ baseada numa amostra de n = 100 alunos. Desejamos calcular (aproximadamente, pois a distribuição das notas só tem média e variância conhecidas) Pr $\{\overline{X} \le 58\}$. Pelo Teorema Central do Limite, esta probabilidade pode ser aproximada usando-se uma distribuição Gaussiana, e então:

$$\Pr\{\overline{X} \le 58\} \approx \Pr\left\{\frac{\overline{X} - 60}{\sqrt{64/100}} \le \frac{58 - 60}{\sqrt{64/100}}\right\} = \Pr\{Z \le -2.5\} = \Phi(-2.5) = 0.0062$$

Exemplo 1.11.5.
O tempo médio de atendimento aos clientes numa cadeia de lanchonetes é uma variável aleatória com média de 1.5 minutos e desvio padrão de 1 minuto. Aproxime a probabilidade de que 100 clientes possam ser atendidos em menos de 2 horas. Suponha independência entre os tempos de atendimento aos clientes.

Solução
Seja X_i o tempo de duração do atendimento do i-ésimo cliente, i =1, 2..., 100.
Seja $Y = \sum_{i=1}^{100} X_i$. Note que E(Y) = 100(1.5) = 150 minutos e Var(Y) = 100.
Logo, pelo Teorema Central do Limite:

$\frac{Y - 150}{\sqrt{100}}$ é aproximadamente N(0,1) e então:

$$\Pr\{Y \le 120\} = \Pr\left\{\frac{Y - 150}{\sqrt{100}} \le \frac{120 - 150}{\sqrt{100}}\right\} \approx \Pr\left\{Z \le \frac{-30}{10}\right\} = \Phi(-3) = 0.0013$$

Logo, a probabilidade de que 100 clientes sejam atendidos em menos de 2 horas é muito pequena, é quase impossível que isto aconteça nas condições especificadas no problema.

Exemplo 1.11.6.
Uma caixa de madeira contém 250 peças pequenas. O peso de cada peça é uma variável aleatória com média 0.20 Kg e desvio padrão 0.08 kg. 20 caixas são colocadas num guindaste, que tem a capacidade de agüentar 1010 kg sem problemas. Acima deste peso recomenda-se o uso de outro equipamento. Qual a probabilidade da substituição por outro guindaste ser necessária?

Solução
Este exemplo é uma aplicação típica do teorema central do limite. Note que a distribuição dos pesos das peças não foi especificada, sabemos apenas a sua média e variância. O teorema central do limite pode ser usado porque estamos interessados no peso total, isto é, na soma dos pesos individuais, que são supostos independentes e identicamente distribuídos.

Seja X_i o peso em kg da i-ésima peça, onde i = 1, 2..., 5000. Então $Y = \Sigma X_i$ é o peso total das 20 caixas de peças (excluindo-se o peso das caixas propriamente ditas).

Note que E(Y) = n.(0.2) = 5000(0.2) = 1000 kg
e VAR(Y) = n.$(0.08)^2$ = 5000.$(0.08)^2$ e então o desvio padrão de Y é $0.08\sqrt{5000} \cong \sqrt{32} = 5.65$ kg.

Pelo teorema central do limite, a variável Z abaixo tem aproximadamente a distribuição N(0,1).

$$Z = \frac{Y - 5000(0.20)}{(0.08)\sqrt{5000}} = \frac{Y - 1000}{(0.08).\sqrt{5000}} = 0.1768\ (Y - 1000)$$

A probabilidade de interesse é:

$$Pr\ (Y > 1010) = Pr\ (Z > 0.1768(1010 - 1000)) =$$

$$= Pr(Z > 1.768) = 1 - \Phi\ (1.768) = 1 - 0.9615 = 0.0385 = 3.85\%$$

Aproximação da Binomial pela Normal

Um caso particular do Teorema Central do Limite é o **Teorema de DeMoivre e Laplace**, em que aproximamos uma distribuição Binomial pela Normal. Este teorema é apenas um caso particular do teorema central do limite, pois uma variável aleatória com distribuição Binomial pode ser encarada como a soma de n variáveis Bernoulli(p) independentes. Na verdade, o teorema de DeMoivre e Laplace foi formulado muito antes do teorema central do limite.

Já vimos que a distribuição Binomial com parâmetros n e p pode ser aproximada pela distribuição Poisson quando n é grande e p é pequeno. A aproximação da Binomial pela Normal (teorema de DeMoivre e Laplace) "funciona" quando n é grande e p não é necessariamente pequeno (por exemplo, p próximo de 1/2).

O fato de a distribuição Binomial ser discreta e da Normal ser contínua nos traz a necessidade de corrigir os valores das probabilidades encontrados via DeMoivre e Laplace. Esta correção será chamada de **correção de continuidade**.

Teorema 1.11.7. Teorema de DeMoivre e Laplace

Seja $Y \sim Bin(n, p)$ onde n é "grande" e p não está próximo de zero. Então:

$$Z = \frac{Y - E(Y)}{\sqrt{VAR(Y)}} = \frac{Y - np}{\sqrt{np\ (1-p)}}$$

tem aproximadamente uma distribuição N(0,1). Em particular, podemos calcular probabilidades de valores específicos da variável Y usando a tabela da distribuição Normal padrão.

Este resultado segue diretamente do teorema central do limite, pois Y pode ser encarado como a soma de n variáveis aleatórias iid, cada uma com distribuição Bernoulli(p).

Nota:

A aproximação Normal fornecida neste teorema funciona bem se n > 10 e p está próximo de 1/2.

Para outros valores de p é necessário aumentar o valor de n. Em geral o teorema de DeMoivre e Laplace produz resultados aceitáveis se n.p > 5 quando p < 1/2 e se n.(1-p) > 5 quando p > 1/2.

Exemplo 1.11.8.

Suponha que desejamos calcular $Pr\ (Y \le y)$, onde $Y \sim Bin(n, p)$. Como poderemos fazê-lo usando o teorema de DeMoivre e Laplace?

$$Pr\ (Y \le y) = Pr\left(\frac{Y - np}{\sqrt{npq}} \le \frac{y - np}{\sqrt{npq}}\right) = Pr\left(Z \le \frac{y - np}{\sqrt{npq}}\right) = \Phi\left(\frac{y - np}{\sqrt{npq}}\right)$$

O resultado desta aproximação pode ser sensivelmente melhorado com a correção de continuidade indicada a seguir.

Correção de Continuidade

Quantidade desejada na distribuição Binomial	Quantidade Calculada através da correção de continuidade	Expressão aproximada usando a densidade Normal
$Pr\ (Y = y)$	$Pr\ (y - 0.5 \le Y \le y + 0.5)$	$\Phi\left(\frac{y+0.5-np}{\sqrt{npq}}\right) - \Phi\left(\frac{y-0.5-np}{\sqrt{npq}}\right)$
$Pr\ (Y \le y)$	$Pr\ (Y \le y + 0.5)$	$\Phi\left(\frac{y+0.5-np}{\sqrt{npq}}\right)$
$Pr\ (Y < y) =$ $Pr\ (Y \le y-1)$	$Pr\ (Y \le y - 1 + 0.5)$	$\Phi\left(\frac{y-1+0.5-np}{\sqrt{npq}}\right) = \Phi\left(\frac{y-0.5-np}{\sqrt{npq}}\right)$
$Pr\ (Y \ge y)$	$Pr\ (Y \ge y - 0.5)$	$1 - \Phi\left(\frac{y-0.5-np}{\sqrt{npq}}\right)$
$Pr\ (Y > y) =$ $Pr\ (Y \ge y + 1)$	$Pr\ (Y \ge y + 1 - 0.5)$	$1 - \Phi\left(\frac{y+1-0.5-np}{\sqrt{npq}}\right)$
$Pr\ (a \le Y \le b)$	$Pr\ (a - 0.5 \le Y \le b + 0.5)$	$\Phi\left(\frac{b+0.5-np}{\sqrt{npq}}\right) - \Phi\left(\frac{a-0.5-np}{\sqrt{npq}}\right)$

Exemplo 1.11.9.

Uma fábrica produz amortecedores para carros, dos quais 20% são defeituosos. Uma amostra de 100 amortecedores é selecionada diariamente. Seja X o número de amortecedores defeituosos na amostra. Calcule a probabilidade de X ser menor ou igual a 15 usando a aproximação Normal com correção de continuidade.

Solução

Neste caso $X \sim Bin(100, 0.2)$ e então $E(X) = np = 20$, $VAR(X) = npq = 20(0.8) = 16$. Usando a correção de continuidade dada na tabela anterior encontramos:

os cursos de graduação, já que deve ser o primeiro passo para qualquer ativid acadêmica. Uma pesquisa de campo ou

$$\Pr(X \le 15) = \Phi\left(\frac{15+0.5-np}{\sqrt{npq}}\right) = \Phi\left(\frac{15.5-20}{\sqrt{16}}\right) = \Phi\left(\frac{-4.5}{4}\right) = \Phi(-1.125) = 0.1292$$

A aproximação **sem** a correção de continuidade seria:

$$\Pr(X \le 15) = \Phi\left(\frac{15-20}{\sqrt{16}}\right) = \Phi\left(\frac{-5}{4}\right) = \Phi(-1.25) = 0.1056$$

Note que o valor exato desta probabilidade seria calculado através da fórmula:

$$\Pr(X \le 15) = \sum_{x=0}^{15} \binom{100}{x} (0.2)^x . (0.8)^{100-x} = 0.1285$$

Nota-se que o resultado com a correção de continuidade é muito mais próximo do real do que o resultado sem a correção. A correção de continuidade geralmente serve para melhorar a "performance" da aproximação da Binomial pela Normal. Além disso, se desejamos calcular a probabilidade da variável Binomial ser igual a qualquer número, isto só pode ser aproximado por um intervalo no caso da distribuição Normal, já que esta última é uma distribuição contínua (e a probabilidade de qualquer valor é zero).

Exemplo 1.11.10.
Seja $X \sim Bin(20, 1/2)$. Calcule a probabilidade dos valores 5, 6...10 diretamente (usando a própria distribuição Binomial) e usando a aproximação Normal com correção de continuidade. Compare os resultados.

Solução
O cálculo exato é dado pela fórmula:

$$\Pr(X = x) = \binom{20}{x} \cdot \left(\frac{1}{2}\right)^x \cdot \left(\frac{1}{2}\right)^{20-x} = \binom{20}{x} \cdot \left(\frac{1}{2}\right)^{20}$$

O cálculo aproximado com correção de continuidade é:

$$\Pr(X = x) \approx \Phi\left(\frac{x+0.5-np}{\sqrt{npq}}\right) - \Phi\left(\frac{x-0.5-np}{\sqrt{npq}}\right) =$$

$$= \Phi\left(\frac{x+0.5-10}{\sqrt{5}}\right) - \Phi\left(\frac{x-0.5-10}{\sqrt{5}}\right)$$

A próxima tabela compara os resultados exato e aproximado:

X	Pr (X =x) exata	Pr (X =x) aproximada
5	0.01479	0.01513
6	0.03696	0.03668
7	0.07393	0.07301
8	0.12013	0.11939
9	0.16018	0.16036
10	0.17620	0.17694

Exemplo 1.11.11.
Na situação do exemplo anterior calcule Pr $(5 \le X \le 9)$ de 3 maneiras:

a) Exatamente,
b) Aproximadamente com correção de continuidade,
c) Aproximadamente sem correção de continuidade.

Solução

a) Cálculo exato

$$\Pr(5 \le X \le 9) = \Pr(X = 5) + \Pr(X = 6) + \ldots + \Pr(X = 9) = 0.40599$$

b) Aproximação com correção de continuidade

$$\Pr(5 \le X \le 9) = \Pr(4.5 \le X \le 9.5) = \Phi\left(\frac{9.5-np}{\sqrt{npq}}\right) - \Phi\left(\frac{4.5-np}{\sqrt{npq}}\right) =$$

$$= \Phi\left(\frac{9.5-10}{\sqrt{5}}\right) - \Phi\left(\frac{4.5-10}{\sqrt{5}}\right) = 0.41153 - 0.00695 = 0.40458$$

c) Aproximação sem correção de continuidade

$$\Pr(5 \le X \le 9) = \Phi\left(\frac{9-np}{\sqrt{npq}}\right) - \Phi\left(\frac{5-np}{\sqrt{npq}}\right) =$$

$$= \Phi\left(\frac{9-10}{\sqrt{5}}\right) - \Phi\left(\frac{5-10}{\sqrt{5}}\right) = 0.32736 - 0.01267 = 0.31469$$

Um resultado bem pior que a aproximação com correção de continuidade.

Uma variável de interesse quando lidamos com dados Binomiais é a freqüência relativa, $\hat{p} = Y/n$ onde $Y \sim Bin(n, p)$. A freqüência relativa serve como um estimador ("chute") da probabilidade de sucesso p, que é freqüentemente desconhecida. Pela lei dos grandes números, a freqüência relativa se aproxima de p quando n tende a infinito.

Podemos re-expressar o teorema de DeMoivre e Laplace em termos da freqüência relativa. Isto é equivalente ao teorema central do limite usando a média amostral. Especificamente:

Se $Y \sim Bin(n, p)$ e $\hat{p} = Y/n$ é a freqüência relativa (número de "sucessos" em n tentativas de Bernoulli independentes) então: $E(\hat{p}) = p$, $VAR(\hat{p}) = p(1-p)/n$ e

$$Z = \frac{\hat{p}-p}{\sqrt{\frac{pq}{n}}} = \sqrt{n}\left(\frac{\hat{p}-p}{\sqrt{pq}}\right)$$

tem aproximadamente uma distribuição N(0,1).

1.12. Exercícios - Capítulo 1

Problema 1
Os clientes de um banco têm como opção de investimento: poupança, CDB e fundos.
20% dos clientes do banco têm caderneta de poupança,
5% dos clientes do banco têm CDB,
25% dos clientes do banco têm aplicações em fundos.
Para simplificar, suponha que estas três modalidades de investimento são exclusivas, isto é, o cliente só pode ter 1 tipo de investimento no banco.
O banco realizou uma pesquisa entre seus clientes para avaliar o interesse pelo lançamento de um novo tipo de seguro de vida.
Dado que o cliente aplica em poupança, 10% destes se mostraram interessados no seguro. Dentre os clientes de CDB, 30% se interessaram pelo seguro, e dentre os clientes dos fundos, 40% demonstraram interesse pelo novo produto.

Um cliente do banco é selecionado aleatoriamente.
a) Qual a probabilidade dele se interessar pelo novo seguro de vida?
b) Dado que o cliente está interessado no novo seguro de vida, qual a probabilidade dele ser cliente em cada um dos 3 tipos de investimento (poupança, CDB e fundos)?

Problema 2
Tomou-se uma amostra de 1000 pessoas na faixa de 40 a 50 anos numa estação de metrô com o objetivo de verificar a relação entre a pressão sangüínea e o peso do indivíduo. Os resultados obtidos estão na tabela a seguir.

Pressão → Peso ↓	**Baixa**	**Normal**	**Alta**
Abaixo do normal	80	70	40
Normal	100	140	60
Até 5 kg em excesso	65	75	40
5.1 a 10 kg em excesso	25	65	70
Mais de 10 kg em excesso	20	60	90

Uma pessoa é escolhida ao acaso. Calcule:

a) A probabilidade de que a pessoa tenha pressão baixa, normal e alta.
b) Qual a probabilidade de uma pessoa ter peso abaixo do normal? Ter mais de 10 kg em excesso?
c) Dado que a pessoa tem mais de 10 kg em excesso, qual a probabilidade de que ela tenha pressão alta?
d) Dado que uma pessoa tem pressão alta, qual a probabilidade dela estar com 5.1 a 10 kg de excesso de peso?
e) Existe independência entre pressão sangüínea e excesso de peso? Por quê?

Problema 3
Uma empresa de telefonia quer saber se vale a pena disponibilizar Internet de banda larga para seus clientes e encomendou uma pesquisa de mercado, cujos resultados estão a seguir:

15% dos clientes usam a Internet mais de 30 horas por semana.
23% dos clientes usam a Internet entre 20 e 30 horas por semana.
28% dos clientes usam a Internet entre 10 e 20 horas por semana.
34% dos clientes usam a Internet menos de 10 horas por semana.
Dentre os clientes que usam Internet mais de 30 horas por semana, 90% estão interessados no acesso rápido (banda larga).
Dentre os clientes que usam Internet entre 20 e 30 horas por semana, 70% estão interessados no acesso rápido (banda larga).
Dentre os clientes que usam Internet entre 10 e 20 horas por semana, 45% estão interessados no acesso rápido (banda larga).
Dentre os clientes que usam Internet menos de 10 horas por semana, 25% estão interessados no acesso rápido (banda larga).

Um cliente é escolhido aleatoriamente e está interessado na Internet de banda larga. Qual a probabilidade dele pertencer a cada uma das classes de usuário (mais de 30 horas, 20 a 30 horas etc...)?

Problema 4
Seja X uma variável aleatória contínua com densidade Uniforme no intervalo $(-\theta, \theta)$. Em cada caso abaixo calcule θ de forma a satisfazer à condição dada.
a) $Pr(X > 1/2) = 1/4$
b) $Pr(X < 1/4) = 3/4$
c) $Pr(X > 1/2) = 2.\ Pr(X < -1)$
d) $Pr(X < 1/2) = 2.\ Pr(X > 1/4)$

Problema 5
O dono de uma festa encomendou a um buffet 200 empadinhas de frango e 100 de camarão.
Um convidado guloso "seqüestra" a bandeja do garçom, com 30 empadinhas. O convidado é, além de guloso, alérgico a camarão, e se comer mais de 3 empadas de camarão corre o risco de passar o resto da festa no hospital. Qual a probabilidade disto acontecer?

Problema 6
Um conjunto de 40 fusíveis é produzido e depois inspecionado usando-se o procedimento descrito a seguir: toma-se uma amostra aleatória de 5 fusíveis. Se pelo menos 4 destes fusíveis "desarmam" na amperagem correta, o lote de 40 fusíveis é aceito. Do contrário o lote é rejeitado.
Suponha que existem 8 fusíveis defeituosos dentre os 40 produzidos.
Qual a probabilidade do lote ser aceito:
a) Usando-se amostragem sem reposição (Hipergeométrica)
b) Usando-se amostragem com reposição (Binomial)

Problema 7
Uma fábrica de chips de computador considera aceitável que 3% dos chips produzidos sejam defeituosos. Para verificar se o processo de produção está

"sob controle" toma-se um lote de 30 chips e verifica-se o estado destes chips **a partir de uma amostra de 5 chips**. Se **no máximo 1 chip** na amostra apresenta defeito, a empresa admite que a produção dos chips está sob controle, e continua a produzi-los sem alterações. Do contrário, **se mais de um chip** na amostra apresenta defeito, a empresa pára a produção porque supõe que o controle de qualidade do processo produtivo não é adequado. **Suponha que existem, na verdade, 3 chips defeituosos no lote de 30 chips**. Qual a probabilidade de a empresa parar a produção, supondo que:

a) A amostragem é feita com reposição (Binomial).
b) A amostragem é feita sem reposição (Hipergeométrica).

Problema 8
Uma secretaria do governo examina por amostragem processos relativos a pagamento de impostos. Esta secretaria considera aceitável que 15% dos processos apresentem algum tipo de irregularidade no cálculo do imposto a pagar. Num certo período de tempo, esta secretaria recebeu **40 processos** para julgamento. Para verificar se o julgamento dos processos está acontecendo da maneira padrão, toma-se uma **amostra de 8 processos** e verifica-se se existe algum tipo de irregularidade tributária em cada um deles.
A **regra de decisão** é a seguinte: se **no máximo 2 processos** apresentam irregularidades, o procedimento de julgamento dos processos está "sob controle". Do contrário, se mais de 2 processos na amostra exibem irregularidades, uma demorada investigação interna é feita, pois supõe-se que os mecanismos de controle da secretaria não estão sendo obedecidos. Suponha que existam, na verdade, 6 processos com irregularidades no lote de 40 processos. Qual a probabilidade de ser necessária a investigação interna, supondo que:

a) A amostragem é feita com reposição.
b) A amostragem é feita sem reposição.

Problema 9
Uma empresa de telefonia celular precisa saber como é a relação entre a renda de seus clientes e o uso do telefone. Uma pesquisa anterior revelou que:

10% dos clientes pertencem à classe A.
25% dos clientes pertencem à classe B.
35% dos clientes pertencem à classe C.
30% dos clientes pertencem à classe D.

Dentre os clientes da classe A, 25 % usam telefone pré-pago.
Dentre os da classe B, 45% usam pré-pago.
Dentre os da classe C, 90 % usam pré-pago.
Dentre os da classe D, 95 % usam pré-pago.

Um cliente é escolhido aleatoriamente e usa o serviço pré-pago. Qual a probabilidade de ele pertencer a cada uma das classes?

Problema 10
0.1 % da população de uma cidade tem tuberculose. Um teste para detectar esta doença tem as seguintes propriedades:

- Se a pessoa **tem** tuberculose o resultado do teste é positivo com probabilidade 0.999 (o teste "acerta").
- Se a pessoa **não tem** tuberculose existe uma probabilidade de 0.002 do resultado do teste ser positivo e acusar a doença.

Uma pessoa é selecionada aleatoriamente na população e o resultado do teste é positivo, indicando a presença da doença. Qual a probabilidade de que a pessoa realmente tenha a doença.

Problema 11
Uma variável aleatória discreta X tem função de probabilidade dada por:

$f(x) = k.p^x$, onde $x = 1, 2, 3, \ldots$ e $0 < p < 1$

a) Encontre o valor da constante k que faz desta expressão uma função de probabilidade.
b) Encontre E(X)

Problema 12
Uma caixa contém 8 bolas brancas e 6 bolas azuis. Uma bola é selecionada aleatoriamente e então é jogada fora e substituída por uma bola da cor oposta.

a) Qual a probabilidade de que a segunda bola selecionada seja branca?
b) Qual a probabilidade de que a segunda bola selecionada seja azul?

Problema 13
Uma caixa contém 10 bolas brancas e 8 bolas azuis. Uma bola é selecionada aleatoriamente e então é jogada fora e substituída por **duas** bolas da cor oposta.
a) Qual a probabilidade de que a segunda bola selecionada seja branca?
b) Qual a probabilidade de que a segunda bola selecionada seja azul?

Problema 14
Num jogo de bingo eletrônico você joga com uma "cartela" de 8 números. A máquina seleciona aleatoriamente 13 números num conjunto de 21 números. Qual a probabilidade de "acertar" os 8 números? Se a máquina seleciona os seus 8 números, você ganha 3 fichas para cada ficha jogada. Isto é justo?

Problema 15
Uma jarra contém 10 biscoitos, 4 deles salgados e 6 doces. 3 biscoitos são selecionados. Seja X o número de biscoitos doces na amostra. Escreva a distribuição de probabilidade de X quando:

a) A amostragem é feita com reposição.
b) A amostragem é feita sem reposição.
c) Calcule E(X) e VAR(X) nos dois casos.

Problema 16
Um certo atacante da seleção brasileira acerta 80% dos pênaltis que cobra. Durante um treino antes de um jogo importante, o atacante treina cobranças de pênaltis. Suponha que todas as cobranças são independentes e calcule as seguintes probabilidades:

a) De que ele acerte o primeiro pênalti na 3ª tentativa.

b) De que o segundo gol ocorra na 4ª tentativa.

c) Suponha que o atacante cobre 10 pênaltis. Qual a probabilidade de ele acertar 7 gols? Qual a probabilidade dele fazer entre 6 e 8 gols (incluindo 6 e 8)?

Problema 17

Numa certa Universidade, os alunos fazem parte de 4 grupos mutuamente exclusivos: "nerds", "modernos", "contestadores" e "arrumadinhos". Na Engenharia, o grupo dos "nerds" representa 40% dos alunos; os "arrumadinhos" são 25% da turma; os "modernos" formam 20% do total e os "contestadores" são os 15% remanescentes. Existem 20 alunos numa certa classe de Engenharia. Calcule as seguintes probabilidades:

a) De que exatamente 8 sejam "nerds", 6 "arrumadinhos", 3 "modernos" e 3 "contestadores".

b) De que exatamente 8 sejam "nerds" e 6 "arrumadinhos".

c) De que existam menos de 4 "modernos" na turma.

Problema 18

O número de enchentes em cada verão no Rio de Janeiro é uma variável aleatória. Toma-se um período de 30 verões, e estamos interessados na variável X que representa o número total de enchentes nestes 30 verões. Suponha que a ocorrência de uma enchente num certo verão não afeta a probabilidade de ocorrência de enchentes em outros verões, e que a probabilidade de enchente em um verão qualquer é 4%. Qual a função de probabilidade de X?

a) Calcule a probabilidade de ocorrerem menos de 5 enchentes nestes 30 verões.

b) Aproxime a probabilidade do item a) usando uma distribuição de Poisson apropriada. Qual o erro percentual absoluto desta aproximação. Defina o erro percentual absoluto como:

$$\text{Erro} = \frac{100\left|\text{prob. real} - \text{prob. aproximada}\right|}{\text{prob. real}}$$

Problema 19

Você trabalha numa empresa que faz pesquisas de opinião pelo telefone. Apenas 8% das chamadas resultam numa pesquisa completa, isto é, apenas 8% dos entrevistados respondem todo o seu questionário. Calcule as seguintes probabilidades:

a) De que a primeira pesquisa completa será respondida na 5ª ligação telefônica.

b) De que a terceira pesquisa completa será respondida na 5ª ligação telefônica.

c) Se você faz exatamente 10 chamadas telefônicas, qual a probabilidade de completar exatamente 1 pesquisa?

d) Se você faz exatamente 20 chamadas telefônicas, qual a probabilidade de completar entre 2 e 4 entrevistas (inclusive 2 e 4)?

Problema 20

O preço de uma ação a cada dia é uma variável aleatória. Num dia qualquer, o preço da ação pode subir R$1.00 com probabilidade 40 % ou descer R$1.00 com probabilidade 60 %. As variações de preço a cada dia são independentes, e as probabilidades de aumento ou queda de preço se mantêm fixas. Considere o gráfico a seguir - no dia 1 o preço da ação é R$100.00. No dia 2, os preços possíveis são R$99.00 e R$101.00 e assim sucessivamente.

a) Calcule as probabilidades de cada um dos preços no dia 5. Qual é a densidade de probabilidade que representa estas probabilidades?

b) Calcule o preço médio da ação no dia 5.

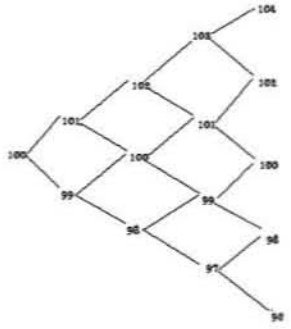

Problema 21

Seja X uma variável aleatória contínua com densidade

$$f(x) = \begin{cases} 3x^2 & 0 \le x \le 1 \\ 0 & \text{do contrario} \end{cases}$$

Faça o gráfico da densidade e da função de distribuição.

Problema 22

O tempo de duração (em centenas de horas) de um certo componente é uma variável aleatória Y com função de distribuição dada por:

$$F(y) = \begin{cases} 1 - \exp\left(-y^2\right) & \text{se } y \ge 0 \\ 0 & \text{do contrario} \end{cases}$$

a) Mostre que F(y) satisfaz as propriedades de uma função de distribuição.

b) Encontre a densidade de Y.

c) Ache a probabilidade de que o componente dure pelo menos 100 horas? E mais de 200 horas?

Problema 23

A idade dos assinantes de um jornal é uma variável aleatória com densidade Normal com média 38 anos e desvio padrão 12 anos. Calcule as seguintes probabilidades:

a) De que um assinante escolhido aleatoriamente tenha entre 30 e 40 anos;
b) De que um assinante escolhido aleatoriamente tenha mais que 40 anos;
c) Suponha que você toma uma amostra de 16 assinantes. Qual a probabilidade de que a idade média na amostra exceda 40 anos?

Problema 24
O consumo médio mensal de energia elétrica num certo bairro é aproximadamente uma variável aleatória Normal com média 180 kWh e desvio padrão 80 kWh. Calcule as seguintes probabilidades:

a) De que um domicílio escolhido aleatoriamente tenha consumo médio mensal entre 150 e 250 kWh;
b) De que um domicílio escolhido aleatoriamente tenha consumo médio mensal acima de 220 KWh;
c) De que um domicílio escolhido aleatoriamente tenha consumo médio mensal abaixo de 100 KWh;
d) De que um prédio com 20 apartamentos selecionado aleatoriamente no bairro tenha consumo médio mensal acima de 4000 kWh.

Problema 25
Uma empresa aérea precisa revisar os motores de seus aviões em intervalos regulares de tempo. Existem 2 opções - a revisão rápida e uma revisão mais detalhada e cara. O técnico encarregado da manutenção garante que na revisão rápida o funcionamento perfeito dos motores é uma variável Exponencial com média 200 horas. Após a revisão detalhada o funcionamento perfeito dos motores é uma variável Exponencial com média 600 horas. A revisão detalhada custa R$10.000,00 e a revisão rápida R$4.000,00. O avião precisa funcionar por 500 horas sem problemas de motor para que a operação da companhia seja economicamente viável. Do contrário, se o avião apresentar defeito antes das 500 horas, existe um custo adicional de R$20.000,00 devido ao tempo necessário para uma nova manutenção. Qual o custo esperado das duas revisões? Qual procedimento é mais vantajoso?

Problema 26
Considere a seguinte densidade conjunta:

$$f(x,y) = \frac{1}{4}.e^{-y/2}, x > 0, y > x$$

a) Ache a densidade marginal de X.
b) Ache a densidade marginal de Y.
c) Calcule Pr (X > 2)
d) Calcule Pr (X > 2 | Y > 4)
e) X e Y são independentes? Por quê? (Justifique!)

Dica:

$$\int u.e^{au}du = \frac{e^{au}}{a}.\left(u - \frac{1}{a}\right)$$

Problema 27
Sejam X_1 e X_2 variáveis aleatórias independentes, onde $X_1 \sim Bin(n_1, p)$ e $X_2 \sim Bin(n_2, p)$. Mostre (usando o método que você preferir) que a variável $Y = X_1 + X_2$ tem distribuição Binomial com parâmetros $n_1 + n_2$ e p.
Dica: dependendo do método que você decidir utilizar, o somatório a seguir pode ser útil, MAS A DEMONSTRAÇÃO É BEM MAIS FÁCIL SE VOCÊ USAR FUNÇÕES GERADORAS DE MOMENTOS).

$$\sum_{j=0}^{n} \binom{a}{j}\binom{b}{n-j} = \binom{a+b}{n}$$

Problema 28
Sejam X e Y variáveis aleatórias independentes com distribuição Exponencial com média 2. Seja Z = X + Y. Use a função geradora de momentos para mostrar que Z tem densidade Gama.

Problema 29
Seja X uma variável aleatória discreta com função de probabilidade:

$$f(x) = q.p^{x-1},\ x = 1,2,3...\ \text{ e }\ q = 1 - p \text{ onde } 0 < p < 1$$

a) Calcule a função geradora de momentos de X.
b) A partir da função geradora de momentos, encontre a média e a variância de X.

Problema 30
Sejam X e Y variáveis aleatórias discretas e independentes com funções de probabilidade marginais:

$$f_1(x) = Pr(X = x) = \frac{\lambda^x.e^{-\lambda}}{x!}\quad x = 0,1,2..... \text{ e}$$

$$f_2(y) = Pr(Y = y) = \frac{(2\lambda)^y e^{-2\lambda}}{y!}\quad y = 0,1,2..... \quad \text{onde } \lambda > 0$$

a) Calcule a função de probabilidade de Z = X + Y.
b) Mostre que a função de probabilidade condicional de X dado Z = z é:

$$f\ (x \mid Z = z) = Pr\ (X = x \mid Z = z) = \binom{z}{x}.\left(\frac{1}{3}\right)^x.\left(\frac{2}{3}\right)^{z-x} \quad \text{onde } x = 0,\ 1,\ 2,....,z$$

c) A partir da função de probabilidade encontrada em b), mostre que a média condicional de X dado Z = z é E(x|Z=z) = z/3.

Dica: no item b) utilize a definição de função de probabilidade condicional e note que o evento
{X = x, Z = z} é equivalente ao evento {X = x, X + Y = z}, e por substituição de X = x nesta última expressão podemos dizer que este último evento equivale a
{X = x, x + Y = z} = {X = x, Y = z - x}

Problema 31
Seja $X \sim N(\mu, \sigma^2)$.

a) Calcule a função geradora de momentos de X.
b) Mostre que, se $X \sim N(0,1)$ então $Y = X^2$ tem densidade Qui-Quadrado com 1 grau de liberdade.
c) Mostre que, se X e Y são iid $N(\mu, \sigma^2)$ então $Z = X + Y$ tem densidade $N(2\mu, 2\sigma^2)$ (Dica: use a função geradora de momentos).
d) Calcule a densidade condicional de X dado Z, onde Z foi definido no item c) acima.

Problema 32
Seja X uma variável aleatória com distribuição Poisson com parâmetro λ, onde λ é também uma variável aleatória, com distribuição Exponencial com média 1.

Mostre que, incondicionalmente: $\Pr(X = k) = \left(\frac{1}{2}\right)^{k+1}$ $k = 0, 1, 2, \ldots$

Problema 33
Um avião de carreira pode levar até 200 passageiros e suas bagagens. Suponha que o peso de um passageiro é uma variável aleatória com média 78 kg e desvio padrão 12 kg, e o peso da bagagem de cada passageiro é uma variável aleatória com média 44 kg e desvio padrão 6 kg. A carga total (passageiros + bagagem) na decolagem não deve exceder 28000 kg. Sob a hipótese de independência, calcule:

a) A probabilidade de que, com o avião totalmente cheio (200 passageiros), a carga total supere o limite de 28000 kg;
b) A probabilidade de que, com o avião totalmente cheio, a carga total esteja entre 27000 e 30000 kg.
c) Qual deveria ser a carga total permitida, de tal forma que, com o avião cheio, a probabilidade de ultrapassar este valor fosse apenas 1%?

Problema 34
Numa certa empresa de informática, o salário anual médio dos funcionários com menos de 5 anos de experiência é R$20000, com desvio padrão de R$1800. Toma-se uma amostra de 30 funcionários com menos de 5 anos de experiência. Qual a probabilidade do salário médio na amostra exceder R$21000?

Problema 35
O saldo devedor médio dos usuários de um certo cartão de crédito é uma variável aleatória com média R$112 e desvio padrão R$56. Toma-se uma amostra de 50 portadores do cartão. Qual a probabilidade do saldo devedor médio na amostra estar entre R$100 e R$130?

Problema 36
A probabilidade de uma pessoa com mais de 65 anos pegar uma gripe no outono é 75%. Toma-se uma amostra de 60 pessoas na 3ª idade e seja X o número destas pessoas com gripe na amostra. Calcule as seguintes probabilidades:

a) $\Pr\{X \geq 40\}$ aproximadamente pelo teorema de DeMoivre e Laplace **com** correção de continuidade.
b) $\Pr\{X \geq 40\}$ exatamente (só se você tiver acesso a um computador, pois do contrário será bastante trabalhoso!)
c) $\Pr\{45 \leq X \leq 50\}$ aproximadamente pelo teorema de DeMoivre e Laplace **com** correção de continuidade.

CAPÍTULO 2: INTRODUÇÃO AOS PROCESSOS ESTOCÁSTICOS

2.1. Introdução

A grande pergunta feita pela maioria dos alunos no início de um curso é: afinal de contas, para que estou estudando isso? Nos próximos parágrafos tentarei dar algumas respostas para a mais objetiva das questões!

A resposta mais honesta (e vaga!!) que eu posso dar é: os Processos Estocásticos têm inúmeras aplicações práticas! Isso torna a escolha dos tópicos a serem incluídos num curso bastante difícil, pois, dependendo do enfoque desejado, pode-se montar cursos completamente diferentes. Na verdade, para confirmar esta afirmação basta olhar para o índice de diversos livros de Processos Estocásticos - nem parece que a gente está falando do mesmo assunto!

Se você já deu uma olhada no índice deste livro, verá que o último capítulo é dedicado a um assunto bastante prático (e financeiramente muito rentável), que é a precificação (ou apreçamento) de uma Opção em Finanças. O problema é que para chegarmos até lá vamos ter um caminho mais ou menos longo pela frente, até porque os processos estocásticos envolvidos têm algumas características bem mais complicadas que os problemas mostrados nos capítulos iniciais.

Uma resposta um pouco menos vaga a esta pergunta fundamental é: processos estocásticos aparecem naturalmente em Engenharia, Economia, Física, Biologia, Finanças e outras áreas. Ao longo deste curso tentaremos enfatizar aplicações em diversas áreas de conhecimento.

Por que os processos estocásticos aparecem em tantas áreas? Porque os fenômenos na natureza têm muitas vezes **características aleatórias** que se **modificam ao longo do tempo ou do espaço**. Ou seja, em vez de tratarmos agora de variáveis aleatórias independentes, cuja densidade conjunta é apenas o produto das densidades marginais, estamos lidando com uma situação onde:

- não existe independência
- o que acontece no instante atual depende do que aconteceu no passado (analogamente, o que acontece num ponto no espaço depende do que acontece em pontos "próximos").

De maneira bastante geral podemos dizer que na teoria de processos estocásticos estudamos sistemas que evoluem no tempo ou no espaço de maneira aleatória.

Definição 2.1.1. Processo Estocástico
Um processo estocástico (ou processo aleatório) é uma coleção de variáveis aleatórias definidas num mesmo espaço de probabilidades. Geralmente representamos um processo estocástico por:

$\{X(t): t \in T\}$

onde t normalmente representa o tempo (ou, em alguns casos, espaço).

X(t) é chamado de **estado do processo** no instante t, e é uma variável aleatória. O conjunto T é o conjunto de índices, ou **espaço paramétrico** do processo estocástico. A "cara" deste espaço paramétrico nos permite separar os processos estocásticos em contínuos ou discretos, como na próxima definição.

Definição 2.1.2. Processos Contínuos e Discretos
Um processo estocástico $\{X(t): t \in T\}$ é um *processo contínuo* (ou processo com parâmetro contínuo) se o conjunto T é um intervalo (finito ou infinito) de números reais. Ao contrário, se o conjunto de índices T é um conjunto finito ou contável, por exemplo, $T = \{1, 2, 3...\}$ ou $T = \{1, 9, 43, 279\}$ dizemos que o processo estocástico é um *processo discreto* (ou processo com parâmetro discreto). Se o processo é discreto, freqüentemente mudamos a notação para X_t (em vez de X(t)).

Logo, um processo estocástico é uma coleção de variáveis aleatórias ordenadas no tempo.

Definição 2.1.3. Espaço de Estados
O espaço de estados de um processo estocástico é o conjunto de todos os valores possíveis da variável X(t). Ou seja, o espaço de estados descreve as características da variável aleatória cuja evolução no tempo estamos medindo.

Em resumo:
Um processo estocástico é uma família de variáveis aleatórias que descreve a evolução no tempo ou espaço de algum processo físico.

Mas, a distinção entre contínuo e discreto também pode ser aplicada ao estado do processo, isto é, à variável aleatória X(t). O espaço de estados de um processo estocástico pode ser discreto ou contínuo, se a variável aleatória X(t) for discreta ou contínua, ou seja, se os estados do processo forem discretos ou contínuos.

Logo, a combinação dos tipos de espaço paramétrico (discreto ou contínuo) e do espaço de estados (discreto ou contínuo) nos leva a 4 "classes" de processos estocásticos, como mostrado a seguir.

1. Espaço paramétrico **discreto** e espaço de estados **discreto** (processo discreto com espaço de estados discreto)
2. Espaço paramétrico **contínuo** e espaço de estados **discreto** (processo contínuo com espaço de estados discreto)
3. Espaço paramétrico **discreto** e espaço de estados **contínuo** (processo discreto com espaço de estados contínuo)
4. Espaço paramétrico **contínuo** e espaço de estados **contínuo** (processo contínuo com espaço de estados contínuo)

Exemplo 2.1.4. Processo Discreto com Espaço de Estados Discreto
Estamos interessados no comportamento dos consumidores de 3 marcas de sabão em pó: A, B e C. Para estudar este comportamento tomamos uma amostra de consumidores de sabão em pó e acompanhamos o seu padrão de consumo ao longo de um número qualquer de meses. Suponha que os consumidores podem, a cada mês, comprar o mesmo sabão que no mês anterior ou trocar de marca. Uma pesquisa de mercado revelou que, o comportamento dos consumidores, em termos de fidelidade às marcas, é o seguinte:

Mês t (qualquer)	Mês t + 1 (qualquer)
comprou a marca A	Pr (comprar a marca A) = 60% Pr (comprar a marca B) = 30% Pr (comprar a marca C) = 10%
comprou a marca B	Pr (comprar a marca A) = 50% Pr (comprar a marca B) = 30% Pr (comprar a marca C) = 20%
comprou a marca C	Pr (comprar a marca A) = 40% Pr (comprar a marca B) = 40% Pr (comprar a marca C) = 20%

O espaço paramétrico é, neste caso, discreto, e indica o mês em que foi realizada a compra, isto é,

$T = \{1, 2, 3...\}$. O espaço de estados também é discreto. Por exemplo, defina a variável aleatória de interesse como:

$$X_t = \begin{cases} 0 \\ 1 \\ 2 \end{cases}$$ se o consumidor comprou, no mês t, o sabão das marcas A, B ou C,

respectivamente. Note que aqui o espaço de estados é finito, consiste apenas no conjunto $\{0, 1, 2\}$.

Note que a variável X_t como definida acima não é a única variável de interesse num estudo deste tipo. Por exemplo, poderíamos definir como variável de interesse o número de pessoas que compram a marca A no mês t. Neste caso o processo é também discreto com espaço de estados discreto.

Num estudo como esse podem surgir diversas questões de interesse, tais como:
- qual o número de meses em que um consumidor mantém sua preferência por uma determinada marca?
- qual o produto preferido pela maioria dos consumidores num longo período de tempo?

Exemplo 2.1.5. Processo Contínuo com Espaço de Estados Discreto
Seja X_t o número de itens em estoque de um certo produto no instante $t \in T$. Considere como espaço paramétrico o intervalo $T = [a,b]$. Então o espaço paramétrico é contínuo e o espaço de estados é discreto. Este problema surge no caso de uma empresa onde o estoque de produtos é monitorado em tempo real. Uma possível questão de interesse é: qual o tamanho do estoque a ser mantido num dado intervalo de tempo de forma a minimizar a estrutura de custos da empresa?

Exemplo 2.1.6. Processo Discreto com Espaço de Estados Contínuo
Considere o exemplo anterior e suponha que X_t representa uma variável contínua (por exemplo, quilos de açúcar em estoque, quantidade de chuva medida num ponto da cidade etc...) e também suponha que a variável é monitorada apenas nos instantes de tempo $\{t_1, t_2...\}$. Claramente o espaço de estados é agora contínuo, enquanto o espaço paramétrico é discreto.

Exemplo 2.1.7. Processo Contínuo com Espaço de Estados Contínuo
No exemplo anterior, suponha que o espaço paramétrico é agora um intervalo real [a,b].

Exemplo 2.1.8. Processo Discreto com Espaço de Estados Discreto
Considere a seguinte situação: A e B participam de um jogo cujo resultado depende apenas do lançamento de uma moeda. Se der "cara", o jogador A paga ao jogador B 1 dólar. Do contrário, B paga a A a mesma quantia. Suponha que as jogadas da moeda são independentes, e que o resultado de uma jogada não afeta os resultados seguintes.

Defina S_n como a quantidade de dinheiro ganha pelo jogador A em n jogadas da moeda.

O espaço paramétrico é $T = \{n = 1,2...\}$ e indica o número de vezes em que os jogadores lançaram a moeda.

O espaço de estados é $\{..., -3, -2, -1, 0, 1, 2, 3...\}$. Note que ambos o espaço de estados e o espaço paramétrico são discretos.

Seja X_i a quantidade de dinheiro ganha pelo jogador A na i-ésima jogada ($i = 1, 2, 3..., n$). Para todo $i = 1, 2, 3..., n$ temos: $X_i = +1$ ou -1, ou seja, X_i é uma variável aleatória de Bernoulli. Se a moeda for honesta, $Pr(X_i = 1) = Pr(X_i = -1) = 0.5$. Sob esta hipótese (verifique!!!):

$E(X_i) = 0$ e $Var(X_i) = E(X_i^2) = 1$.

A quantidade de dinheiro ganha pelo jogador A em n jogadas é a soma das n variáveis aleatórias $X_1, X_2..., X_n$. Mas, $X_1, X_2..., X_n$ formam uma seqüência de variáveis independentes e identicamente distribuídas. Então, o ganho médio esperado pelo jogador A é:

$$E(S_n) = E\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} E(X_i) = 0$$

$$VAR(S_n) = VAR\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} VAR(X_i) = n$$

Note que a expressão para a variância decorre do fato dos X_i's serem independentes.

Ao simular o resultado deste jogo nota-se que, embora a média dos ganhos do jogador A seja zero para qualquer número de jogadas n, o caminho percorrido por S_n concentra-se acima ou abaixo da origem, dependendo do resultado das jogadas iniciais. A seguir, exibimos o resultado de 10 simulações diferentes de 20 jogadas da moeda e os caminhos percorridos por S_n em algumas das simulações. O valor de S_n a cada instante n é a soma dos ganhos nas jogadas 1,2..., n.

Ganho do Jogador A - simulações 1 e 2

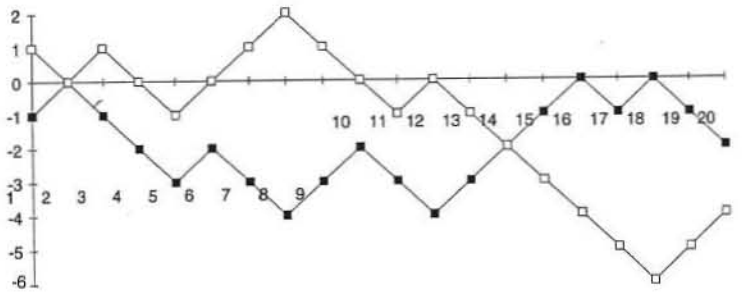

Ganho do Jogador A - simulações 5 e 6

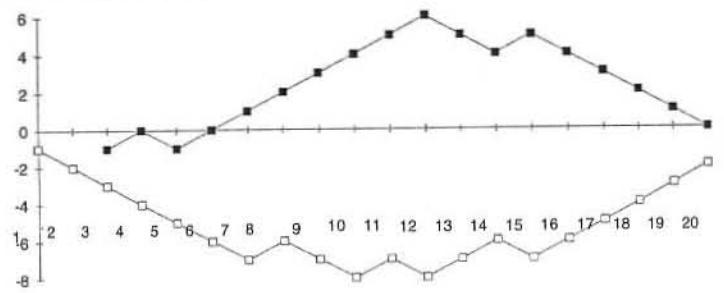

Os valores simulados estão na próxima tabela. Cada linha da tabela representa o resultado financeiro do jogador A numa jogada. Cada coluna indica uma simulação. O valor de S_n é obtido somando-se os elementos de cada coluna até a n-ésima jogada.

sim1	sim2	sim3	sim4	sim5	sim6	sim7	sim8	sim9	sim10
-1	1	-1	-1	-1	-1	1	-1	-1	-1
1	-1	1	1	-1	-1	-1	-1	-1	-1
-1	1	-1	1	1	-1	1	1	-1	-1
-1	-1	-1	-1	1	-1	1	1	1	-1
-1	-1	1	-1	-1	-1	1	1	1	-1
1	1	1	1	1	-1	1	1	-1	-1
-1	1	1	1	1	-1	1	-1	1	1
-1	1	1	-1	1	1	1	-1	1	1
1	-1	1	-1	1	-1	1	1	1	1
1	-1	-1	1	1	-1	1	1	1	-1
-1	-1	1	-1	1	1	1	1	-1	1
-1	1	1	-1	1	-1	-1	-1	-1	1
1	-1	-1	1	-1	1	-1	1	-1	-1
1	-1	1	1	-1	1	-1	1	1	1
1	-1	-1	1	1	-1	1	-1	-1	-1
1	-1	-1	-1	-1	1	-1	1	1	1
-1	-1	1	-1	-1	1	-1	1	1	1
1	-1	-1	-1	-1	1	-1	-1	-1	-1
-1	1	1	-1	-1	1	1	1	-1	-1
-1	1	1	1	-1	1	-1	-1	1	1

Cada seqüência de -1 e 1 obtida neste exemplo é uma **realização** de um processo estocástico, isto é, uma **possível trajetória** do processo. Pode-se pensar na relação entre realização e processo estocástico como análoga à relação entre amostra e população. O objetivo da nossa simulação foi obter 10 diferentes realizações do mesmo processo estocástico. Deve ficar claro pelos gráficos que a trajetória seguida pela variável de interesse pode ser radicalmente diferente a cada realização do processo.

Como descrever um processo estocástico?
Uma forma de descrever o processo X(t) é: para qualquer conjunto de índices de tempo, por exemplo: $\{t_1, t_2..., t_n\}$, encontre a densidade conjunta de $X(t_1)$, $X(t_2)..., X(t_n)$ para qualquer n. Na prática, isso é impossível, e devemos buscar uma alternativa viável. Também, alguns processos têm uma estrutura probabilística que permite que eles sejam caracterizados de uma maneira bem simples; uma classe importante destes são os processos Markovianos.

Uma maneira mais simples (embora incompleta) de descrever o processo é através dos **momentos** das variáveis aleatórias, em especial os dois primeiros momentos, que são a média, variância e autocovariância do processo. A seguir, definimos estas quantidades para um processo a tempo discreto, mas as definições são análogas para processos a tempo contínuo.

Séries Temporais e Processos Estocásticos

Uma série temporal é uma realização de um processo estocástico. Na prática, a não ser que estejamos lidando com séries simuladas, a série temporal que está sendo analisada é a única realização disponível do processo estocástico subjacente. Por exemplo, se X_t indica as vendas de sabão em pó da marca XXX no mês t, a série temporal $\{X_1, X_2..., X_T\}$ que contém os valores efetivamente observados das vendas é a única trajetória disponível do processo estocástico que gerou aquela série.

Definição 2.1.9. Média de um Processo Estocástico
A função média de um processo estocástico X_t é definida por:

$$\mu(t) = E(X_t)$$

Note que, da definição, **a média de um processo não é necessariamente uma constante**, e sim uma função do instante de tempo.

Definição 2.1.10. Variância de um Processo Estocástico
A variância de um processo estocástico X_t é a função definida por:

$$\sigma^2(t) = Var(X_t) = E\{(X_t - \mu(t))^2\}$$

Definição 2.1.11. Autocovariância de um Processo Estocástico
A autocovariância de um processo entre os instantes t_1 e t_2 é a função definida por:

$$\gamma(t_1, t_2) = Cov\{X_{t1}, X_{t2}\} = E\{(X_{t1} - \mu(t_1)).(X_{t2} - \mu(t_2))\}$$

Isto é, a autocovariância do processo é apenas a covariância entre instantes de tempo diferentes. A variância do processo (vide a definição anterior) é apenas um caso particular da autocovariância fazendo-se $t_1 = t_2$.

Momentos de ordem mais alta podem ser definidos de maneira semelhante, mas são pouco usados na prática.

Estas características de processos estocásticos estão intimamente ligadas à noção de **estacionariedade** de um processo, definida a seguir.

Em termos bastante genéricos, um processo é estacionário se não existem mudanças sistemáticas nas suas características, isto é, se aparentemente não existe uma tendência de subida ou queda e se o processo não exibe características de periodicidade.

Definição 2.1.12. Processo Estritamente Estacionário
Um processo estocástico é dito estritamente estacionário se a distribuição conjunta de $X(t_1)$, $X(t_2)$..., $X(t_n)$ é a mesma que $X(t_1 + k)$, $X(t_2 + k)$..., $X(t_n + k)$ para quaisquer t_1, t_2..., t_n, k e n.

Em particular, se n = 1, a definição 2.1.12. nos leva à seguinte conclusão: num processo estritamente estacionário, a média e variância do processo são constantes para todo tempo t. Também, se n = 2, a distribuição conjunta de $X(t_1)$ e $X(t_2)$ só depende da **defasagem (ou "lag")** $t_2 - t_1$ e a função de autocovariância só depende de $t_2 - t_1$. Assim, a função de autocovariância poderá ser escrita como: $\gamma(k) = E\{(X(t) - \mu).(X(t+k) - \mu)\}$

Note que, como o processo é estacionário, μ é a média constante do processo, isto é, $\mu = E\{X(t)\} = E\{X(t+k)\}$.

A função $\gamma(k)$ é chamada de função de **autocovariância de lag k**, e tem importância fundamental na modelagem ARIMA de Box e Jenkins, como veremos posteriormente neste curso. Note que, se k =0, $\gamma(0) = E\{(X(t) - \mu))^2\}$, que é a variância (constante) do processo.

Bem, pela definição anterior já podemos perceber que demonstrar a estacionariedade estrita de um processo é uma tarefa difícil (quase impossível em muitos casos!). Logo, nós vamos ter que nos contentar com um tipo de estacionariedade mais brando (menos restritivo), como mostrado na próxima definição.

Definição 2.1.13. Estacionariedade Fraca, Processo Fracamente Estacionário
Na prática definimos estacionariedade a partir de condições menos restritivas, que só envolvem os dois primeiros momentos do processo. Um processo é dito **fracamente estacionário, ou estacionário de segunda ordem** se sua média é constante e sua autocovariância depende apenas do lag.

Logo, num processo estacionário de 2ª ordem:

$E\{X(t)\} = \mu$ = constante
$Cov\{X(t), X(t+k)\} = \gamma(k) = E\{(X(t) - \mu).(X(t+k) - \mu)\}$
só depende de k
Em particular, se k = 0, $Var(X(t)) = \sigma^2$ = constante

A condição de estacionariedade de 2ª ordem é bem mais fraca que a estácionariedade estrita, pois estaremos impondo apenas condições sobre os dois primeiros momentos, em vez de impor condições sobre todos os momentos! Em apenas uma situação as duas definições (estacionariedade fraca e forte) são equivalentes, se o processo é Gaussiano. Do contrário, se a distribuição dos X's é qualquer outra, não Normal, as duas definições não são equivalentes.

Nota:
O uso de estacionariedade fraca é tão comum que muitas vezes, ao nos referirmos a um processo como estacionário, o que temos em mente é um processo **fracamente** estacionário. Logo, por convenção, se nada for dito a respeito do tipo de estacionariedade de um processo, suponha que ele é fracamente estacionário!

Definição 2.1.14. Função de Autocorrelação
Considere um processo estocástico fracamente estacionário X(t). A função de autocorrelação de lag k, denotada por $\rho(k)$, é definida como:

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)} = \frac{Cov\{X(t),\ X(t+k)\}}{Var(X(t))}$$

Esta definição é análoga à do coeficiente de correlação (como função da covariância).

Teorema 2.1.15. Propriedades da Função de Autocorrelação

i) $\rho(0) = 1$
ii) A função de autocorrelação é uma função par do lag k, isto é, $\rho(+k) = \rho(-k)$
iii) $-1 \le \rho(k) \le 1$ para qualquer lag k

A demonstração do teorema será omitida. Os itens i) e ii) são triviais, mas a demonstração de iii) é um pouco mais trabalhosa.

Estimação dos Parâmetros de um Processo Estocástico
Na prática, ao nos depararmos com uma realização do processo estocástico, não sabemos qual foi o mecanismo usado para gerá-lo, e também não conhecemos os parâmetros que caracterizam o processo, como a média, variância, autocovariância e autocorrelação.

Logo, este parâmetros devem ser "estimados" ("chutados") a partir dos dados que temos "na mão". A seguir, exibimos os estimadores usuais. Note que, se um processo **não é** estacionário, sua média e variância vão estar mudando ao longo do tempo e, portanto, a média e variância de "sub-blocos" da série devem ser (estatisticamente) diferentes. Ao contrário, num processo estacionário, a média e variância devem ser (estatisticamente) iguais ao longo dos diversos "sub-blocos".

Definição 2.1.16. Média Amostral

Seja $\{X_t: t = 1, 2, ..., T\}$ uma série temporal. A média amostral da série é definida como: $\overline{X} = \frac{1}{T}\sum_{t=1}^{T} X_t$.

$\overline{X}$ é o estimador usual de μ (a média do processo estocástico subjacente).

Definição 2.1.17. Variância Amostral
Seja $\{X_t: t = 1, 2,..., T\}$ uma série temporal. A variância amostral da série é definida como: $S^2 = \frac{1}{T-1}\sum_{t=1}^{T}(X_t - \overline{X})^2$.

S^2 é o estimador usual de σ^2 (a variância do processo estocástico subjacente).

Definição 2.1.18. Autocovariância Amostral de lag k
Seja $\{X_t: t = 1, 2,..., T\}$ uma série temporal. A autocovariância amostral de lag k é definida como: $C(k) = \frac{1}{T-k-1}\sum_{t=k+1}^{T}(X_t - \overline{X})(X_{t-k} - \overline{X})$.

C(k) é o estimador usual de $\gamma(k)$ (autocovariância de lag k do processo estocástico subjacente).

Definição 2.1.19. Autocorrelação Amostral de lag k
Seja $\{X_t: t = 1, 2,..., T\}$ uma série temporal. A autocorrelação amostral de lag k é definida como: $r(k) = \frac{\sum_{t=k+1}^{T}(X_t - \overline{X})(X_{t-k} - \overline{X})}{\sum_{t=k+1}^{T}(X_t - \overline{X})^2}$.

r(k) é o estimador usual de $\rho(k)$ (autocorrelação de lag k do processo estocástico subjacente).

O gráfico de r(k) versus k é chamado de correlograma amostral e é uma das nossas principais "armas" para identificar a estrutura de um processo ARIMA de Box e Jenkins, como veremos no capítulo 5.

Nota
$\overline{X}$, S^2, C(k) e r(k) são variáveis aleatórias e, portanto, têm as suas distribuições de probabilidade, que nos permitiriam calcular a probabilidade de intervalos desejados. Mas, a distribuição exata de C(k) e r(k) é difícil de obter, e na prática usamos as distribuições assintóticas, que são as distribuições aproximadas calculadas a partir da suposição de que o tamanho da série (T) é "grande". No caso particular de uma série estacionária e Gaussiana, a distribuição assintótica de r(k) é conhecida, o que nos leva ao próximo resultado, que é **muito** importante na prática.

Teorema 2.1.20. Anderson (1920), Bartlett (1946), Quenouille (1949)
A distribuição aproximada de r(k) é Normal com média zero e variância 1/T.

Logo, a variável aleatória $\frac{r(k)-0}{\sqrt{\frac{1}{T}}}$ tem aproximadamente a densidade Normal com média zero e variância 1 e, por exemplo:

$$\Pr\left\{-1.96 \le \frac{r(k)-0}{\sqrt{\frac{1}{T}}} \le +1.96\right\} = \Pr\left\{\frac{-1.96}{\sqrt{T}} \le r(k) \le \frac{+1.96}{\sqrt{T}}\right\} = 0.95 .$$

Podemos derivar uma regra empírica a partir desta probabilidade. Para que uma autocorrelação amostral r(k) seja estatisticamente diferente de zero, ela deve estar "fora" do intervalo $[-2/\sqrt{T}, +2/\sqrt{T}]$. Note que, à medida que o comprimento da série aumenta, este intervalo vai ficando cada vez mais curto. Logo, se estamos tratando de uma série de comprimento relativamente grande (100, 200 observações), a regra empírica acima só vai dizer que uma autocorrelação é nula se ela for "realmente" muito pequena em módulo.

Os softwares estatísticos geralmente exibem as autocorrelações amostrais e os limites do intervalo de confiança, isto é, $[-2/\sqrt{T}, +2/\sqrt{T}]$. Se uma autocorrelação está dentro do intervalo, ela é estatisticamente nula, e se ela cai fora do intervalo dizemos que ela é estatisticamente diferente de zero.

Por que usar simulação?
A resposta é bem simples: facilidade! Hoje em dia, já que os computadores e softwares estão cada vez mais baratos, acessíveis e poderosos, ficou muito fácil gerar um grande número de variáveis aleatórias e, portanto, pode-se criar grandes números de realizações de processos estocásticos. Assim, a gente pode investigar e fazer conjecturas a partir de uma coisa "palpável", em vez de lidar apenas com uma abstração matemática.

Na próxima seção e nos exercícios do capítulo fazemos uso intenso de simulações.

2.2. Exemplos

Nesta seção descrevemos alguns processos estocásticos especialmente úteis na prática. Nos próximos capítulos alguns destes exemplos serão revistos com maiores detalhes.

Definição 2.2.1. Ruído Branco
Um processo discreto X_t é chamado de processo puramente aleatório, ou processo ruído branco, se os X_t constituem uma seqüência de variáveis aleatórias independentes e identicamente distribuídas.

Logo, da definição segue que um ruído branco tem média e variância constantes e função de autocorrelação nula em todos os lags k > 0.

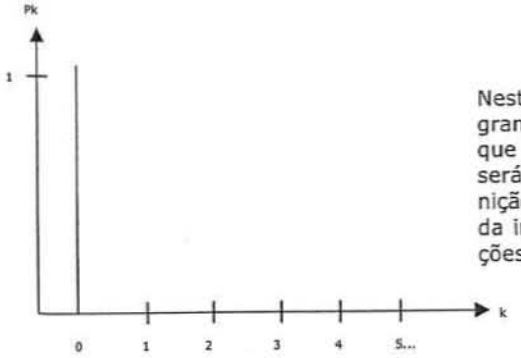

Neste gráfico exibimos o correlograma de um ruído branco – note que a autocorrelação no lag zero será sempre igual a um, por definição! Nos outros lags, por causa da independência, as autocorrelações são todas nulas.

Processos ruído branco são fundamentais, pois aparecem na construção de outros processos mais complicados e serão particularmente importantes ao estudarmos os modelos ARIMA de Box e Jenkins.

Exemplo 2.2.1.
Nos próximos gráficos exibimos 2 processos ruído branco com 50 observações. O processo I foi gerado a partir de uma seqüência de variáveis N(0,1) e o segundo a partir de uma seqüência de variáveis iid com distribuição Exponencial com média dois.

Ruído Branco Normal

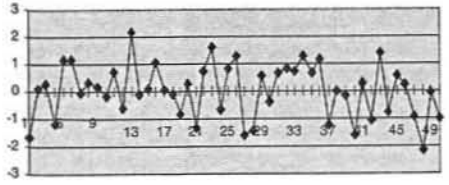

Ruído Branco Exponencial

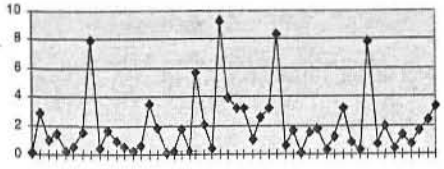

Note que, em ambos os processos, a média e a variância devem ser constantes. Então, por exemplo, a média e a variância das 25 primeiras observações não devem ser "muito diferentes" da média e variância na segunda metade dos dados. A próxima tabela exibe os valores calculados da média e variância para os dois processos usando todos os dados e, em seguida, os dois conjuntos de 25 observações.

	Processo 1 (Normal)		
	50 obs.	1ª metade	2ª metade
Média	0.028	0.169	-0.113
Variância	0.970	0.843	1.097
	Processo 2 (Exponencial)		
	50 obs.	1ª metade	2ª metade
Média	2.052	1.960	2.144
Variância	5.033	5.985	4.299

Também, por construção, ambos os processos são seqüências de variáveis independentes e, portanto, descorrelatadas. Assim, as autocorrelações estimadas para ambos os processos devem ser próximas de zero em todos os lags k > 0.

Autocorrelação do Processo I
(Ruído Branco Normal)

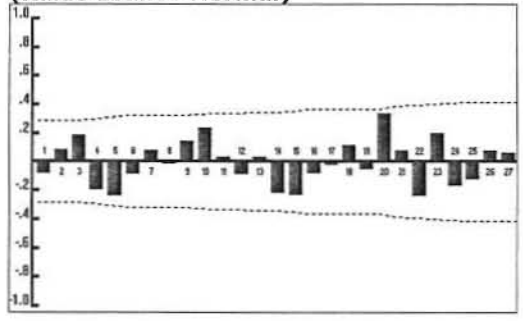

Autocorrelação do Processo II
(Ruído Branco Exponencial)

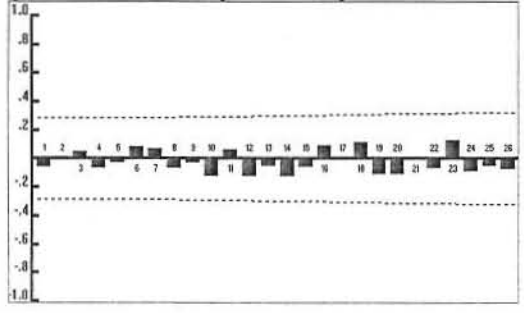

Nas figuras anteriores, note que as autocorrelações estão todas dentro dos limites tracejados, o que indica que elas **não são** estatisticamente **diferentes de zero.**

Exemplo 2.2.2. Passeio Aleatório ou "Random Walk"
Seja ε_t para t =1,2... um ruído branco com média μ e variância σ^2. Dizemos que o processo estocástico X_t é um passeio aleatório (ou "random walk") se:

$X_t = X_{t-1} + \varepsilon_t$ para t = 1, 2, 3...

Geralmente o processo é iniciado quando t =0 fazendo-se $X_0 = 0$ e então:

$X_1 = \varepsilon_1$

$$X_t = \sum_{i=1}^{t} \varepsilon_i$$

A média e variância do processo a qualquer instante são encontradas diretamente da definição, e podemos verificar que, para qualquer instante de tempo t:

$$E\{X_t\} = E\left(\sum_{i=1}^{t} \varepsilon_i\right) = t.\mu$$

$$VAR\{X_t\} = VAR\left(\sum_{i=1}^{t} \varepsilon_i\right) = t.\sigma^2$$

Logo, **a média e a variância do processo se alteram com o tempo**, e o passeio aleatório é um **processo não estacionário.** Em particular, como $\sigma^2 > 0$ sempre, a variância cresce à medida que o tempo passa, e quanto mais longe estamos da origem (t =0), mais dispersa será a distribuição de probabilidade no instante t.

Mas, é interessante notar que a primeira diferença do passeio aleatório é estacionária, pois $X_t - X_{t-1} = \varepsilon_t$ e os ε_t são uma seqüência de variáveis independentes e identicamente distribuídas.

Na prática, preços de ações freqüentemente se comportam como passeios aleatórios, e um modelo que aproxima bem os dados é, neste caso: $P_t = P_{t-1} + \varepsilon_t$ onde P_t e P_{t-1} indicam, respectivamente, os preços das ações nos instantes t e t-1, e ε_t é um erro aleatório.

Exemplo 2.2.3.
As figuras a seguir exibem um passeio aleatório (gerado por simulação) e a série de preços diários da ação Eletrobrás ON. Note que as duas séries têm comportamentos semelhantes e seria difícil dizer qual delas é a série real e qual é a série simulada apenas pela comparação dos gráficos.

Exemplo 2.2.4.
Considere o processo estocástico a tempo contínuo descrito por: $X(t) = A.\cos\left(\frac{2.\pi.t}{3}\right) + B.\sin\left(\frac{2.\pi.t}{3}\right)$ (t > 0), onde A e B são variáveis aleatórias Normais independentes com média zero e variância 1. Nas figuras a seguir, exibimos 4 realizações deste processo.

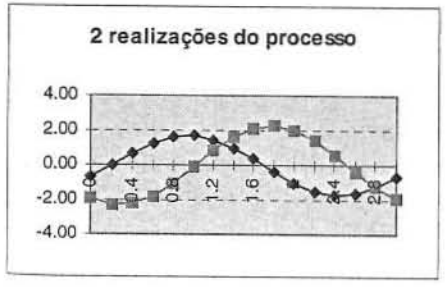

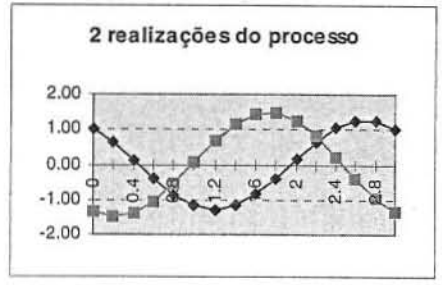

Exemplo 2.2.5. Outro Passeio Aleatório
No capítulo 3 definiremos um passeio aleatório de uma maneira ligeiramente diferente da apresentada no exemplo 2.2.2. A definição que será apresentada é, no entanto, equivalente à do exemplo 2.2.2, bastando redefinir as variáveis aleatórias ε_t como a seguir. Seja $X_t = X_{t-1} + \varepsilon_t$ para t = 1, 2, 3... onde $X_0 = 0$ e então:

$X_1 = \varepsilon_1$

$X_t = \sum_{i=1}^{t} \varepsilon_i$

Suponha que os ε_t são uma seqüência de variáveis aleatórias discretas, independentes e identicamente distribuídas com função de probabilidade dada por:

$$Pr\{\varepsilon_t = -1\} = p \quad \text{e} \quad Pr\{\varepsilon_t = +1\} = 1 - p = q$$

Isto é, os ε_t são um ruído branco binário. A média e variância de ε_t são:

$\mu = E(\varepsilon_t) = (-1).p + (+1).q = q - p = 1 - 2p$

$Var(\varepsilon_t) = (-1)^2.p + (+1)^2.q - (1 - 2p)^2 = p + q - (1 - 2p)^2 = 1 - 1 + 4p - 4p^2 =$

$= 4p(1-p) = 4.p.q$

A média e variância do processo são (vide exemplo 2.2.2):

$$E\{X_t\} = E\left(\sum_{i=1}^{t} \varepsilon_i\right) = t.\mu = t\,(1-2p)$$

$$VAR\{X_t\} = VAR\left(\sum_{i=1}^{t} \varepsilon_i\right) = t.\sigma^2 = 4.p.q.t$$

Logo, a média e a variância do processo se alteram com o tempo, e o passeio aleatório é um processo **não estacionário**. Note que a variância cresce à medida que t aumenta.

Exemplo 2.2.6.
Considere o processo $X_t = 0.8X_{t-1} + \varepsilon_t$ para t = 1, 2, 3... e suponha que em t = 0 fazemos $X_0 = 0$. Suponha também que os ε_t são um ruído branco Normal com média 0 e variância 1. Este processo é um exemplo de um **processo Autoregressivo de ordem 1**, denotado **AR(1)**.

Note que:

$X_1 = \varepsilon_1$
$X_2 = 0.8.X_1 + \varepsilon_2 = 0.8.\varepsilon_1 + \varepsilon_2$
$X_3 = 0.8.X_2 + \varepsilon_3 = \varepsilon_3 + 0.8(\varepsilon_2 + 0.8.\varepsilon_1) = \varepsilon_3 + 0.8.\varepsilon_2 + (0.8)^2\,\varepsilon_1$

Em geral...

$$X_t = \varepsilon_t + 0.8\varepsilon_{t-1} + (0.8)^2\varepsilon_{t-2} + (0.8)^3\varepsilon_{t-3} + \ldots + (0.8)^{t-1}\varepsilon_1 = \sum_{k=0}^{t-1}(0.8)^k\varepsilon_{t-k}$$

As figuras a seguir mostram duas realizações de um processo com estas características e suas autocorrelações estimadas. Você consegue obter uma expressão geral para a função de autocorrelação?

Realização 1
gráfico da série

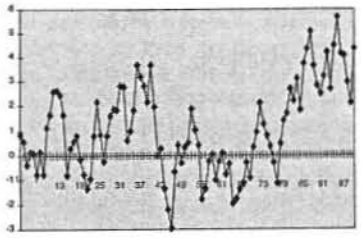

Realização 1
função de autocorrelação

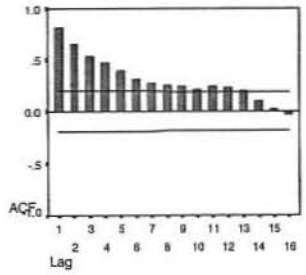

Realização 2
gráfico da série

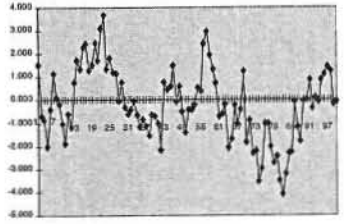

Realização 2
função de autocorrelação

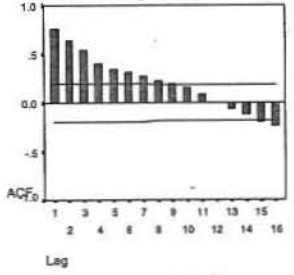

Média, Variância e Covariâncias de um Processo AR(1)
Considere o processo AR(1) dado por:
$X_t = aX_{t-1} + \varepsilon_t$ para t = 1, 2, 3..., onde $X_0 = 0$, os ε_t são iid N(0,1) e a constante a é menor que 1 em módulo.

Note que:

$$X_t = \sum_{k=0}^{t-1} (a)^k \varepsilon_{t-k} \Rightarrow Var\,(X_t) = \sum_{k=0}^{t-1} (a)^{2k}.Var\,(\varepsilon_{t-k}) =$$

$$\sum_{k=0}^{t-1} a^{2k} = \sum_{k=0}^{t-1} \left(a^2\right)^k = \frac{1-\left(a^2\right)^t}{1-a^2} = \frac{1-a^{2t}}{1-a^2}$$

Também:

$$E\,(X_t) = E\left(\sum_{k=0}^{t-1} (a)^k \varepsilon_{t-k}\right) = 0$$

Logo, o processo tem média constante, mas Var(X_t) depende de t, e a hipótese de que a variância do processo é constante realmente só é válida quando t tende a infinito, isto é, o processo já se encontra num estado de equilíbrio ("steady state"). Nestas condições, o que aconteceu nas iterações iniciais é irrelevante, e a variância de X(t) tende a $\gamma(0) = 1/(1-a^2)$.

As autocovariâncias do processo seguem a expressão recursiva:

$\gamma(k) = a.\gamma(k-1)$ onde $\gamma(k)$ é a autocovariância de lag k do processo X_t.

Isso pode ser facilmente mostrado a partir da definição do processo:

$\gamma(k) = COV\{X_t, X_{t-k}\} = E\{X_t.X_{t-k}\} = E\{(aX_{t-1} + \varepsilon_t)(aX_{t-k-1} + \varepsilon_{t-k})\} =$
$= a^2.E\{X_{t-1}.X_{t-k-1}\} + a.E\{X_{t-1}.\varepsilon_{t-k}\} + a.E\{X_{t-k-1}.\varepsilon_t\} + E\{\varepsilon_t.\varepsilon_{t-k}\}$

Para k =1

$\gamma(1) = E\{X_t.X_{t-1}\} = a^2.E\{X_{t-1}.X_{t-2}\} + a.E\{X_{t-1}.\varepsilon_{t-1}\} + a.E\{X_{t-2}.\varepsilon_t\} + E\{\varepsilon_t.\varepsilon_{t-1}\}$

Mas: $E\{\varepsilon_t.\varepsilon_{t-1}\} = 0$, $E\{X_{t-2}.\varepsilon_t\} = 0$ e $E\{X_{t-1}.\varepsilon_{t-1}\} = E\{(a.X_{t-2} + \varepsilon_{t-1})\varepsilon_{t-1}\} = Var(\varepsilon_{t-1}) = 1$

Também, $E\{X_{t-1}.X_{t-2}\} = \gamma(1)$, pois as covariâncias só dependem do lag (por hipótese). Daí:

$\gamma(1) = a^2.\gamma(1) + a \Rightarrow \gamma(1) = a/(1-a^2) = a.\gamma(0)$

Para k =2

$\gamma(2) = E\{X_t.X_{t-2}\} = E\{(aX_{t-1} + \varepsilon_t).X_{t-2}\} = a.E\{X_{t-1}.X_{t-2}\} = a.\gamma(1)$

Para k = 3

$\gamma(3) = E\{X_t.X_{t-3}\} = E\{(aX_{t-1} + \varepsilon_t).X_{t-3}\} = a.E\{X_{t-1}.X_{t-3}\} = a.\gamma(2) = a^2.\gamma(1)$.

Em geral, para k inteiro > 1 teremos:

$\gamma(k) = a.\gamma(k-1) = a^k.\gamma(0) = a^k/(1-a^2)$

Logo, as autocorrelações (teóricas) de lag k são:

$\rho(k) = \gamma(k)/\gamma(0) = a^k$ para k = 0, 1,2...

Note que, se k = 0, $\rho(0) = 1$, a autocorrelação de lag zero é sempre 1.

Então, o gráfico das autocorrelações teóricas versus k é apenas o gráfico de a^k versus k. Se a é positivo, as autocorrelações teóricas decrescem exponencialmente com o lag, sem mudar de sinal, mas se a for negativo o gráfico das autocorrelações teóricas vai oscilar entre valores positivos e negativos.

Na prática, você vai gerar uma série segundo um processo AR(1) com coeficiente a conhecido e o gráfico que você vai produzir é o das autocorrelações ESTIMADAS r(k), que servem como "chutes" para as autocorrelações teóricas $\rho(k)$. O que você espera encontrar? Gráficos com o mesmo aspecto dos gráficos teóricos acima indicados.

Bem, e qual o efeito se o processo não estiver "em equilíbrio", isto é, e se t não for grande? Note que a expressão recursiva $\gamma(k) = a.\gamma(k-1)$ ainda será válida, mas não teremos mais $\gamma(0) = Var\{X(t)\}$ = constante.

Na prática, a não ser que t e k sejam MUITO pequenos, a AUTOCORRELAÇÃO teórica $\rho(k)$ terá no denominador e no numerador a mesma "constante" $\gamma(0)$ e então haverá o cancelamento desta "constante".

Para evitar **problemas com os valores iniciais,** você deve proceder da seguinte forma: gere um certo número de X(t) de acordo com o processo AR(1) que você deve simular, jogue-os fora e considere como valores simulados apenas os valores depois que o processo já começou a "esquentar", isto é, depois que o processo entrou em equilíbrio.

Mas quantos valores você deve jogar fora? Depende... A resposta a esta questão é puramente empírica.

Note que:

$$Var(X_t) = \frac{1-a^{2t}}{1-a^2}$$

E $\gamma(0) = 1/(1-a^2)$ é a variância (constante) no estado de equilíbrio. Uma possível escolha é eliminar as t primeiras observações tais que $1 - a^{2t} < c$ onde c é uma constante escolhida pelo usuário.

Por exemplo, imagine que eu faça c = 0.95 e que o processo tenha a = 0.8. Então, devo resolver $1- (0.8)^{2t} < 0.95 \Rightarrow (0.8)^{2t} > 0.05 \Rightarrow (0.64)^t > 0.05$

Logo, $t.\log(0.64) > \log(0.05) \Rightarrow t > \{\log(0.05)\}/\{\log(0.64)\} = 6.71$.

Ou seja, você deve jogar fora as t = 7 primeiras observações. Se agora c = 0.99 e a = 0.8, então t deve ser maior que 10.32 (verifique) e jogamos fora as 11 primeiras observações. Se o processo agora tem parâmetro a = 0.2, e fazemos c = 0.99 acima então $t > \log(0.01)/\log(0.04) = 1.43$ e podemos eliminar apenas as 2 primeiras observações.

2.3. Exercícios - Capítulo 2

Nota: em todos os problemas de simulação a seguir, a variância σ^2 é suposta igual a 1/4. Nos problemas "algébricos" em que é necessário derivar uma expressão geral, considere σ^2 uma constante qualquer.

Problema 1

Considere o processo estocástico AR(1) dado por:

$X_t = a.X_{t-1} + \varepsilon_t$ onde os ε_t formam um ruído branco Normal com média zero e variância σ^2, a é uma constante cujo módulo é menor que um e o processo está inicialmente no estado $X_0 = 0$.

Derive analiticamente a expressão para a autocovariância e a autocorrelação de "lag" k, onde k = 0, 1, 2,... Compare o resultado encontrado com os gráficos das autocorrelações do exemplo 2.2.6.

Problema 2
Faça 5 simulações de 100 observações do processo AR(1) com a = + 0.5 e suponha que $\sigma^2 = 1$.

a) Faça o gráfico das 5 realizações ao longo do tempo.
b) Faça o gráfico das autocorrelações.
c) Divida cada uma das 5 séries simuladas em 2 blocos, O primeiro bloco contém as 50 primeiras observações, e o segundo bloco contém as 50 últimas observações. Calcule a média e o desvio padrão da série inteira e em cada um dos blocos de 50 observações. O que você pode dizer a respeito da estacionariedade das séries?

Problema 3
Repita o problema 2 fazendo agora a = - 0.5.

Problema 4
Considere agora o **passeio aleatório** $X_t = X_{t-1} + \varepsilon_t$ onde os ε_t formam um ruído branco Normal com média zero e variância σ^2, e o estado inicial $X_0 = 0$. Repita o problema 2 e comente sobre as diferenças encontradas entre este processo e os processos AR(1) dos problemas 2 e 3.

Problema 5
A partir do passeio aleatório $\{X_t\}$ gerado no problema 4 considere o processo: $\varepsilon_t = X_t - X_{t-1}$.

a) Faça o gráfico dos ε_t ao longo do tempo.
b) Divida as séries em 2 blocos com 50 observações cada e calcule a média e desvio padrão em cada bloco e para todas as observações. Compare os resultados encontrados.
c) Faça o gráfico das autocorrelações dos ε_t.

Problema 6
Considere o processo estocástico $X_t = \varepsilon_t + b.\varepsilon_{t-1}$ onde os ε_t formam um ruído branco Normal com média zero e variância σ^2, b é uma constante cujo módulo é menor que um e o processo está inicialmente no estado $X_0 = 0$.
Este processo é chamado de processo **Médias Móveis** (ou **"Moving Average"** de ordem 1), e denotado por MA(1).

a) Mostre que a média do processo é zero e a variância é constante, e então o processo é fracamente estacionário. Também, sob a hipótese de que os ε's são Normais, a estacionariedade fraca equivale à estacionariedade estrita.
b) Calcule a covariância do processo.
c) Mostre que a função de autocorrelação é dada por:

$$\rho(k) = \begin{cases} 1 & \text{se } k = 0 \\ \dfrac{b}{(1+b^2)} & \text{se } k = +1 \text{ ou } -1 \\ 0 & \text{do contrário} \end{cases}$$

Logo, a função de autocorrelação exibe um corte brusco no lag 1.

Nota: embora o processo seja sempre estacionário e, portanto, não é necessário impor qualquer condição sobre o parâmetro b para garantir a estacionariedade, é comum considerar apenas processos MA(1) **"inversíveis"** (vide capítulo 5), nos quais |b| < 1.

Problema 7
Considere um processo MA(1) com b = + 0.7.
Refaça o problema 2.

Problema 8
Considere um processo MA(1) com b = - 0.7.
Refaça o problema 2.

Problema 9
Veja o problema 4. Considere agora o **passeio aleatório** $X_t = X_{t-1} + \varepsilon_t$, mas agora suponha que os ε_t formam um ruído branco de uma distribuição discreta tal que Pr (ε_t = + 1) = 50% e Pr (ε_t = -1) = 50%. Suponha que o estado inicial é $X_0 = 0$. Este modelo representa um jogo no qual, a cada jogada, pode-se perder ou ganhar R$1 com probabilidade 50%. O processo X_t é a quantidade de dinheiro ganha por um jogador que inicialmente não tem dinheiro.

a) Calcule a média e a variância dos ε_t.
b) Faça 10 simulações de 20 jogadas, isto é, 10 simulações de cada série $\{X_1, X_2, ..., X_{20}\}$
c) Faça gráficos da evolução no tempo das 10 simulações do item b);
d) Considere o instante t = 4. Quais os valores de X_4 nas 10 simulações? Faça um gráfico de barras (ou outro tipo que você considere apropriado) para resumir a distribuição no instante t = 4.
e) Repita o item c) para o instante t = 18.

Problema 10
Considere o processo estocástico $X_t = 0.5X_{t-1} + \varepsilon_t + 0.8.\varepsilon_{t-1}$ onde os ε_t formam um ruído branco Normal com média zero e variância σ^2 e o processo está inicialmente no estado $X_0 = 0$. Este é um exemplo de um processo ARMA(1,1), que "mistura" os processos AR(1) e MA(1) definidos acima.
Faça 10 simulações de 100 observações deste processo.

a) Faça o gráfico das 10 realizações ao longo do tempo.
b) Faça o gráfico das autocorrelações de cada uma das 10 realizações. O que você conclui? Como as autocorrelações se comparam com as de um processo AR(1)? E em relação às autocorrelações de um processo MA(1)?

c) O processo gerado parece estacionário? Discuta a estacionariedade (ou não) do processo informalmente.

Problema 11
Considere o processo ARMA (1,1) (vide Problema 10) dado por: $X_t = 0.7X_{t-1} + \varepsilon_t - 0.4.\varepsilon_{t-1}$ onde os ε_t formam um ruído branco Normal com média zero e variância σ^2. Faça 5 simulações de 2000 observações deste processo.

a) Faça o gráfico das 5 realizações ao longo do tempo.
b) Faça o gráfico das autocorrelações de cada uma das 5 realizações. O que você conclui? Como as autocorrelações se comparam com as de um processo AR(1)? E em relação às autocorrelações de um processo MA(1)?
c) O processo gerado parece estacionário? Discuta a estacionariedade (ou não) do processo informalmente.

CAPÍTULO 3: CADEIAS DE MARKOV

Muitos sistemas têm a seguinte propriedade: conhecendo-se o seu estado, os estados passados não têm influência sobre os estados futuros. Esta propriedade é chamada de propriedade Markoviana, e sistemas com esta característica são descritos por processos estocásticos Markovianos.

Cadeias de Markov são casos particulares de processos estocásticos Markovianos, nas quais o número de estados possíveis é finito ou contável.

As cadeias de Markov são um dos tipos mais simples de processos estocásticos, bastante úteis na prática, e possuem características interessantes quando o número de transições cresce.

3.1. Introdução

Definição 3.1.1. Propriedade Markoviana, Processo Markoviano
Um processo estocástico é dito Markoviano se, dado o valor de X_t, o valor de X_s, onde $s > t$, não depende dos valores de X_u (onde $u < t$).

Ou seja, *um processo é Markoviano se o seu comportamento no futuro só depende de seu estado atual, e as probabilidades dos estados futuros não são alteradas pelo conhecimento adicional do comportamento passado do processo.* Um processo Markoviano exibe uma certa "falta de memória", pois a distribuição condicional do estado no futuro depende apenas da informação mais recente.

Em termos mais formais, um processo é Markoviano se a propriedade a seguir, conhecida como propriedade Markoviana, for satisfeita:

$$\Pr\left[a < X_t < b \middle| X_{t_1} = x_1, X_{t_2} = x_2, \ldots, X_{t_n} = x_n\right] = \Pr\left[a < X_t < b \middle| X_{t_n} = x_n\right]$$

para todos os instantes $t_1 < t_2 < \ldots < t_n$.

Definição 3.1.2. Cadeia de Markov
Uma cadeia de Markov é um processo de Markov com espaço de estados finito ou contável.

Na discussão a seguir, nós nos concentraremos em cadeias de Markov a tempo discreto, ou seja, cadeias nas quais o índice dos tempos (espaço paramétrico) é finito ou contável. Em geral consideraremos como espaço paramétrico o conjunto $t = 0, 1, 2\ldots$

Definição 3.1.3. Probabilidades de Transição de um Estágio
A probabilidade de transição do estado i para o estado j entre os instantes n e n+1 é denotada por:

$$P_{ij}^{n,n+1} = Pr\left[X_{n+1} = j \,\middle|\, X_n = i\right]$$

ou seja, esta probabilidade representa a passagem do estado i (no instante n) para o estado j (no instante n + 1). A notação usada enfatiza o fato de que esta probabilidade pode ser função dos instantes em que ocorre a transição.

Se as probabilidades $P_{ij}^{n,n+1}$ **independem dos instantes** em que os estados i e j são observados dizemos que a cadeia de Markov tem **probabilidades de transição estacionárias.**

Ao longo deste curso estudaremos **apenas** cadeias de Markov com **probabilidades de transição estacionárias**, e assim as **probabilidades de transição dependem apenas dos estados inicial e final.** Logo, a notação para as probabilidades de transição simplifica-se para:

$$P_{ij} = Pr\left[X_{n+1} = j \,\middle|\, X_n = i\right] \text{ para quaisquer instantes n e } n+1$$

Teorema 3.1.4. Propriedades das Probabilidades de Transição

$P_{ij} \geq 0$ para quaisquer estados i e j;
$P_{ij} \leq 1$ para quaisquer estados i e j;
$\sum_{j=0}^{\infty} P_{ij} = 1$ para todo $i = 0, 1, 2, \ldots$.

Esta última propriedade simplesmente diz que, a partir de qualquer estado i precisamos fazer uma transição para um estado j (não necessariamente diferente de i) e que a soma sobre todos os estados possíveis de chegada é 1.

Definição 3.1.5. Matriz de Transição
É a matriz (possivelmente de dimensão infinita) cujo ij-ésimo elemento é P_{ij}. A dimensão da matriz de transição é a mesma do espaço de estados da cadeia de Markov. Também, a matriz de transição é quadrada.

$$P = \begin{bmatrix} P_{00} & P_{01} & P_{02} & \ldots\ldots \\ P_{10} & P_{11} & P_{12} & \ldots\ldots \\ \ldots\ldots & & & \\ P_{i0} & P_{i1} & P_{i2} & \ldots\ldots \\ & \ldots\ldots & & \end{bmatrix}$$

é uma matriz de transição de dimensão infinita.

A i-ésima linha da matriz de transição é a distribuição de probabilidade dos valores de X_{n+1} dado que, no instante anterior (n), a cadeia estava no estado i, isto é, $X_n = i$.

A propriedade 3 do teorema 3.1.4. nos diz que **a soma dos elementos de cada linha da matriz de transição é um.**

Uma cadeia de Markov é completamente especificada pelo estado inicial X_0 e pela matriz de transição P.

É uma convenção dizermos que **uma transição ocorreu** mesmo que o processo tenha continuado no mesmo estado. Assim, P_{00}, P_{11}, P_{22}... são também chamadas de probabilidades de transição, embora o estado tenha se mantido inalterado na passagem de um instante para o próximo.

Exemplo 3.1.6.
Seja W uma variável aleatória discreta com valores possíveis 0, 1, 2... e suponha que $Pr\{W = i\} = p_i$ onde $0 \leq p_i \leq 1$ e $\sum_{i=0}^{\infty} p_i = 1$.

Sejam $W_1, W_2 \ldots, W_n \ldots$ observações independentes da variável aleatória W. Isto é, $W_1, W_2 \ldots, W_n \ldots$ formam uma seqüência infinita de variáveis aleatórias independentes e identicamente distribuídas.

A seguir, descrevemos duas cadeias de Markov relacionadas com a seqüência de W_i's.

- Considere o processo $X_n = W_n$ onde $n = 0, 1, 2 \ldots$ e $X_0 = W_0$ é dado. A matriz de transição desta cadeia de Markov é a seguinte matriz de dimensão infinita:

$$P = \begin{bmatrix} P_{00} & P_{01} & P_{02} & \ldots\ldots \\ P_{10} & P_{11} & P_{12} & \ldots\ldots \\ \ldots\ldots & & & \\ P_{i0} & P_{i1} & P_{i2} & \ldots\ldots \\ & \ldots\ldots & & \end{bmatrix} = \begin{bmatrix} p_0 & p_1 & p_2 & \ldots\ldots \\ p_0 & p_1 & p_2 & \ldots\ldots \\ \ldots\ldots & & & \\ p_0 & p_1 & p_2 & \ldots\ldots \\ & \ldots\ldots & & \end{bmatrix}$$

Note que todas as linhas da matriz de transição são iguais, expressando o fato de que X_{n+1} é independente de X_n para qualquer instante n. Ou seja, para quaisquer estados i e j temos, por causa da independência:

$$P_{ij} = Pr\left[X_{n+1} = j \,\middle|\, X_n = i\right] = Pr\left[X_{n+1} = j\right] = p_j$$

- Uma outra cadeia de Markov é formada tomando-se as somas parciais dos W_i's. Sejam $Y_0 = 0$, $Y_n = W_1 + W_2 + \ldots + W_n$ para $n = 1, 2 \ldots$ O processo $\{Y_n, n = 0, 1, 2 \ldots\}$ é uma cadeia de Markov cujas probabilidades de transição são dadas por:

$$P_{ij} = Pr\left[X_{n+1} = j \,\middle|\, X_n = i\right] = Pr\left[W_1 + W_2 + \ldots + W_{n+1} = j \,\middle|\, W_1 + W_2 + \ldots + W_n = i\right] =$$

$$= Pr\left[W_{n+1} = j - i\right] = \begin{cases} p_{j-i} & \text{se } j \geq i \\ 0 & \text{se } j < i \end{cases}$$

pois os W_i's são, por hipótese independentes e identicamente distribuídos e têm como valores possíveis os inteiros não negativos. A matriz de transição deste processo é:

$$P = \begin{bmatrix} P_{00} & P_{01} & P_{02} & \cdots\cdots \\ P_{10} & P_{11} & P_{12} & \cdots\cdots \\ \cdots\cdots & & & \\ P_{i0} & P_{i1} & P_{i2} & \cdots\cdots \\ & \cdots\cdots & & \end{bmatrix} = \begin{bmatrix} p_0 & p_1 & p_2 & \cdots\cdots \\ 0 & p_0 & p_1 & p_2 & \cdots\cdots \\ 0 & 0 & p_0 & p_1 & p_2 & \cdots\cdots \\ \cdots\cdots & & & & \\ \cdots\cdots & & & & \end{bmatrix}$$

Exemplo 3.1.7. Previsão do Tempo
Suponha como modelo para o clima num certo lugar uma variável aleatória com apenas 2 valores, 0 (chuva) e 1 (sol). Suponha também que, se chove hoje, choverá amanhã com probabilidade α, e se faz sol hoje, choverá amanhã com probabilidade β. Os dois únicos estados possíveis são 0 e 1, e o que aconteceu anteontem (e antes disso) não afeta o clima de amanhã. Assim, temos uma cadeia de Markov cuja matriz de transição é:

$$P = \begin{bmatrix} P_{00} & P_{01} \\ P_{10} & P_{11} \end{bmatrix} = \begin{bmatrix} \alpha & 1-\alpha \\ \beta & 1-\beta \end{bmatrix}$$

Podemos representar as transições entre os dois estados esquematicamente como no próximo diagrama. Por simplicidade, não escrevemos no diagramaa seguir, as probabilidades de permanecer no mesmo estado (P_{00} e P_{11}).

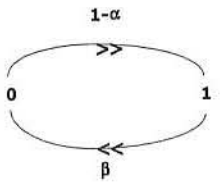

Exemplo 3.1.8.
O estado de espírito de uma pessoa hoje é determinado apenas pelo seu estado de espírito ontem, e existem apenas 3 estados possíveis: 0 (mau humor), 1 (indiferente) e 2 (bom humor).
Dado o mau humor de ontem, as probabilidades de mau humor, indiferença e bom humor hoje são, respectivamente: 0.2, 0.3 e 0.5. De maneira semelhante, se a pessoa estava indiferente ontem, as probabilidades de mau humor, indiferença e bom humor hoje são, respectivamente: 0.3, 0.4 e 0.3. Dado o bom humor de ontem as probabilidades de mau humor, indiferença e bom humor hoje são, respectivamente: 0.1, 0.4 e 0.5. A matriz de transição é:

$$P = \begin{bmatrix} P_{00} & P_{01} & P_{02} \\ P_{10} & P_{11} & P_{12} \\ P_{20} & P_{21} & P_{22} \end{bmatrix} = \begin{bmatrix} 0.2 & 0.3 & 0.5 \\ 0.3 & 0.4 & 0.3 \\ 0.1 & 0.4 & 0.5 \end{bmatrix}$$

Exemplo 3.1.9.
A evolução dos retornos de uma carteira de ações pode ser modelada, de forma simplificada, como uma Cadeia de Markov com 3 estados. Seja X_n o "estado" da carteira no instante n, onde $X_n = 0$ se o retorno da carteira foi negativo, $X_n = 1$ se o retorno foi nulo e $X_n = 2$ se o retorno foi positivo.

A matriz de transição pode ser escrita como:

$$P = \begin{bmatrix} P_{00} & P_{01} & P_{02} \\ P_{10} & P_{11} & P_{12} \\ P_{20} & P_{21} & P_{22} \end{bmatrix}$$

Exemplo 3.1.10.
Na tabela a seguir, exibimos os retornos de Petrobras PN baseados na cotação de fechamento no último dia do mês, no período Janeiro de 1997 a Dezembro de 1999. Seja X_n o estado da cadeia, e suponha que $X_n = 0$ se o retorno no mês foi negativo, e $X_n = 1$ se o retorno mensal foi zero ou positivo.

Data	Cotação	Retorno	Estado	Data	Cotação	Retorno	Estado
jan/97	0,185	19,43%	1	jul/98	0,247	17,06%	1
fev/97	0,198	6,73%	1	ago/98	0,116	-75,38%	0
mar/97	0,199	0,64%	1	set/98	0,118	1,64%	1
abr/97	0,212	5,99%	1	out/98	0,145	20,67%	1
mai/97	0,243	13,58%	1	nov/98	0,166	13,10%	1
jun/97	0,283	15,53%	1	dez/98	0,133	-22,17%	0
jul/97	0,312	9,56%	1	jan/99	0,132	-0,73%	0
ago/97	0,252	-21,26%	0	fev/99	0,156	16,94%	1
set/97	0,296	15,95%	1	mar/99	0,238	42,20%	1
out/97	0,194	-42,00%	0	abr/99	0,267	11,54%	1
nov/97	0,230	17,01%	1	mai/99	0,251	-6,02%	0
dez/97	0,247	7,15%	1	jun/99	0,275	8,94%	1
jan/98	0,227	-8,39%	0	jul/99	0,257	-6,73%	0
fev/98	0,243	6,45%	1	ago/99	0,257	-0,04%	0
mar/98	0,263	7,90%	1	set/99	0,287	11,04%	1
abr/98	0,281	6,78%	1	out/99	0,310	7,87%	1
mai/98	0,215	-26,72%	0	nov/99	0,389	22,41%	1
jun/98	0,208	-3,20%	0	dez/99	0,396	1,91%	1

Existem 36 observações (cada uma correspondente a um mês), e 35 transições entre estados. Podemos estimar as probabilidades de transição de estados de

maneira bem simples, através da proporção de ocorrências de cada transição. Note que, para respeitarmos a propriedade de que a soma dos elementos de cada linha de P seja 1, é necessário uma outra padronização, e precisamos dividir o número de ocorrências de cada transição pelo número de ocorrências do estado inicial.

Estado inicial (mês n)	Estado final (mês n +1)	Número de ocorrências	Prob. transição estimada
0	0	3	3/11
0	1	8	8/11
1	0	8	8/24
1	1	16	16/24

A matriz de transição estimada a partir destes dados é:

$$P = \begin{bmatrix} P_{00} & P_{01} \\ P_{10} & P_{11} \end{bmatrix} = \begin{bmatrix} \frac{3}{11} & \frac{8}{11} \\ \frac{1}{3} & \frac{2}{3} \end{bmatrix}$$

É claro que este exemplo é apenas uma simplificação grosseira da realidade, e pode-se até questionar a validade da hipótese Markoviana neste caso, por exemplo, será que o estado há 2 meses não afeta a transição atual?

Exemplo 3.1.11. O Passeio Aleatório
Considere uma cadeia de Markov cujo espaço de estados é o conjunto dos inteiros. Esta cadeia é um **passeio aleatório** se, para algum número $p \in (0,1)$:

$P_{i,i+1} = p$
$P_{i,i-1} = 1-p$
$P_{ij} = 0$ se $j \neq i+1, i-1$

Por que esta cadeia é chamada de passeio aleatório? Podemos pensar neste processo como a representação de uma pessoa andando numa linha reta onde, a cada instante de tempo, ocorre um passo para a direita com probabilidade p ou um passo à esquerda com probabilidade 1-p. Note que, a cada estado, a cadeia pode se mover apenas para o estado anterior ou para o próximo estado.

O passeio aleatório é um dos exemplos mais simples de um processo estocástico e será exaustivamente estudado neste capítulo.

Exemplo 3.1.12. Um Jogo
Considere um jogador que, a cada jogada ganha 1 real com probabilidade p ou perde 1 real com probabilidade 1-p. Este exemplo é basicamente o mesmo que o exemplo anterior, mas agora permitimos que as probabilidades de ganho ou perda sejam diferentes.

Suponha que o jogador pára de jogar quando fica sem dinheiro, ou quando consegue uma quantidade de N reais. A **fortuna do jogador** é uma cadeia de Markov cujas probabilidades de transição são:

$P_{i,i+1} = p$ (probabilidade de ganhar 1 real)
$P_{i,i-1} = 1 - p$ (probabilidade de perder 1 real) se $i = 1,2...,N-1$ e
$P_{00} = P_{NN} = 1$
Os estados 0 e N são chamados de **estados absorventes**, pois quando o processo entra neles não sai nunca mais (neste caso isso acontece porque o jogo acaba!).

Note que esta cadeia de Markov tem espaço de estados finito (os estados são 0, 1, 2..., N), e a matriz de transição é uma matriz quadrada de dimensão N +1. A matriz de transição é:

$$P = \begin{bmatrix} P_{00} & P_{01} & P_{02} & \cdots & P_{0N} \\ P_{10} & P_{11} & P_{12} & \cdots & P_{1N} \\ P_{20} & P_{21} & P_{22} & \cdots & P_{2N} \\ \cdots & & & & \\ P_{N0} & P_{N1} & P_{N2} & \cdots & P_{NN} \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & \cdots & 0 \\ (1-p) & 0 & p & \cdots & 0 \\ 0 & (1-p) & 0 & \cdots & 0 \\ \cdots & & & & \\ 0 & 0 & 0 & \cdots & 1 \end{bmatrix}$$

3.2. Matrizes de Transição de Cadeias de Markov e as Equações de Chapman e Kolmogorov

Uma cadeia de Markov é completamente especificada pela sua matriz de transição e pela distribuição de probabilidade no instante inicial. A análise de uma cadeia de Markov refere-se principalmente ao cálculo das probabilidades de possíveis realizações do processo. Para isso é necessário saber as probabilidades de transição entre n passos (ou instantes).

Seja P_{ij}^{n} a probabilidade de que o processo esteja no estado i num instante qualquer e no estado j após n transições consecutivas, isto é:

$$P_{ij}^{n} = Pr\left[X_{m+n} = j \;\middle|\; X_m = i\right] \quad m \geq 0, n \geq 0, i, j \geq 0$$

Teorema 3.2.1. Equações de Chapman e Kolmogorov
Numa cadeia de Markov a seguinte propriedade é válida:

$$P_{ij}^{n+m} = \sum_{k=0}^{\infty} P_{ik}^{n} . P_{kj}^{m} \quad \forall n, m \geq 0 \text{ e } \forall i, j \qquad (3.2.1)$$

Note que $P_{ik}^{n} . P_{kj}^{m}$ representa a probabilidade de começar no estado i e terminar no estado j em n + m transições através de um caminho que passa pelo estado k após n transições. A soma sobre todos os estados intermediários k nos fornece a probabilidade de ir do estado i ao estado j em n + m transições.

Demonstração

$$P_{ij}^{n+m} = Pr\left[X_{m+n} = j \mid X_0 = i\right] = \sum_{k=0}^{\infty} Pr\left[X_{m+n} = j, X_n = k \mid X_0 = i\right] =$$

$$= \sum_{k=0}^{\infty} Pr\left[X_{m+n} = j \mid X_n = k, X_0 = i\right].\ Pr\left[X_n = k \mid X_0 = i\right] = \sum_{k=0}^{\infty} P_{ik}^{n}.P_{kj}^{m}$$

Seja $P^{(n)}$ a matriz de transição de n estágios. A equação de Chapman e Kolmogorov escrita em forma matricial é:

$$P^{(n+m)} = P^{(n)}.P^{(m)}$$

Em particular: $P^{(2)} = P^{(1+1)} = P.P = P^2$

Continuando este raciocínio por indução leva a: $P^{(n)} = P^{(n-1+1)} = P^{n-1}.P = P^n$

Ou seja, a matriz de transição de n estágios é a n-ésima potência da matriz de transição de 1 estágio. Freqüentemente estaremos interessados no limite de P_{ij}^{n} quando n tende a infinito. É intuitivamente razoável supor que a influência do estado inicial diminua quando um número muito grande de transições é feito. Daí, espera-se que P_{ij}^{n} tenda a um limite que não depende do estado inicial i. Examinaremos esta questão em breve. Esta idéia está relacionada a uma certa noção de "equilíbrio" do sistema após muitas transições.

Exemplo 3.2.2.
Considere uma cadeia de Markov com matriz de transição:

$$P = \begin{pmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{pmatrix}$$

Calcule P^2, P^4, P^8, P^{20} e então faça uma conjetura sobre um possível limite para P^n quando n tende a infinito.

Solução

$$P^2 = \begin{pmatrix} 0.61 & 0.39 \\ 0.52 & 0.48 \end{pmatrix} \qquad P^4 = \begin{pmatrix} 0.5749 & 0.4251 \\ 0.5668 & 0.4332 \end{pmatrix}$$

$$P^8 = \begin{pmatrix} 0.5715 & 0.4285 \\ 0.5714 & 0.4286 \end{pmatrix} \qquad P^{20} = \begin{pmatrix} 0.5714 & 0.4286 \\ 0.5714 & 0.4286 \end{pmatrix}$$

Interessante, não? Parece que as potências da matriz de transição estão convergindo para a matriz: $\begin{pmatrix} 0.5714 & 0.4286 \\ 0.5714 & 0.4286 \end{pmatrix}$. Note que as duas linhas desta matriz são iguais, então o estado inicial é irrelevante para o limite quando n tende a infinito!

Até agora, todas as probabilidades consideradas aqui foram **probabilidades condicionais**. Por exemplo, P_{ij}^{n} é a probabilidade de estar no estado j no

instante n **dado que** o estado inicial (no instante zero) era i. Se estivermos interessados na distribuição **incondicional** do estado j no instante n precisaremos especificar a distribuição de probabilidade no instante inicial.

Suponha que no instante inicial a densidade de probabilidade é:
$p_j = Pr\{X_0 = j\}$ conhecida para todos os estados j.
Então, a probabilidade incondicional do sistema estar no estado k no instante n é dada por:

$$Pr\left[X_n = k\right] = p_k^{(n)} = \sum_{j=0}^{\infty} p_j.\ P_{jk}^{(n)} = \sum_{j=0}^{\infty} Pr\left[X_0 = j\right].\ Pr\left[X_n = k \mid X_0 = j\right]$$

No caso de uma cadeia com apenas dois estados, 1 e 2, estas probabilidades se reduzem a:

$$Pr\left[X_n = 1\right] = p_1^{(n)} = Pr\left[X_0 = 1\right].\ Pr\left[X_n = 1 \mid X_0 = 1\right] + Pr\left[X_0 = 2\right].\ Pr\left[X_n = 1 \mid X_0 = 2\right]$$

e

$$Pr\left[X_n = 2\right] = p_2^{(n)} = 1 - p_1^{(n)} = Pr\left[X_0 = 1\right].\ Pr\left[X_n = 2 \mid X_0 = 1\right] + Pr\left[X_0 = 2\right].Pr\left[X_n = 2 \mid X_0 = 2\right]$$

Neste caso, as probabilidades de estar nos estados 1 e 2 após n = 1 instantes são dadas por:

$$Pr\left[X_1 = 1\right] = p_1^{(1)} = Pr\left[X_0 = 1\right].\ Pr\left[X_1 = 1 \mid X_0 = 1\right] + Pr\left[X_0 = 2\right].\ Pr\left[X_1 = 1 \mid X_0 = 2\right] =$$
$$= p_1.P_{11} + p_2.P_{21}$$

$$Pr\left[X_1 = 2\right] = p_2^{(1)} = 1 - p_1^{(1)} = Pr\left[X_0 = 1\right].\ Pr\left[X_1 = 2 \mid X_0 = 1\right] +$$
$$Pr\left[X_0 = 2\right].\ Pr\left[X_1 = 2 \mid X_0 = 2\right] = p_1.P_{12} + p_2.P_{22}$$

Em termos matriciais, se $s_0 = (p_1, p_2)$ é o vetor linha de probabilidades dos estados iniciais, e se s_1 indica o vetor de probabilidades no instante 1, as equações anteriores fornecem: $s_1 = s_0.P$.
Levando-se em conta que a matriz de transição de n estágios é apenas P^n podemos concluir que, após n transições, o estado do sistema é $s_n = s_{n-1}.P = s_0.P^n$.

Exemplo 3.2.3.
Considere o seguinte problema: a companhia K fabrica um cereal de café da manhã e atualmente possui uma fatia de 25 % do mercado. Dados do ano anterior indicam que 88% dos consumidores permaneceram fiel à marca K, mas 12% trocaram de marca. Além disso, 85% dos clientes da marca concorrente continuaram leais à outra marca, mas 15% dos clientes da marca concorrente mudaram para o cereal da marca K. Supondo que esta tendência continue ao longo do tempo, determine o "market share" da marca K em:

a) 2 anos;
b) quando o número de anos tender a infinito.

Solução
Considere os seguintes estados:
estado 1 ⇒ consumidor compra o cereal K;
estado 2 ⇒ consumidor compra o cereal da marca concorrente.
A matriz de transição neste problema é:

$$P = \begin{pmatrix} P_{11} & P_{12} \\ P_{21} & P_{22} \end{pmatrix} = \begin{pmatrix} 0.88 & 0.12 \\ 0.15 & 0.85 \end{pmatrix}$$

A matriz de transição de 2 estágios é:

$$P^2 = \begin{pmatrix} 0.7924 & 0.2076 \\ 0.2595 & 0.7405 \end{pmatrix}$$

Os "market shares" do cereal K e do concorrente no instante inicial são 25% e 75% respectivamente. Isto pode ser representado por um vetor linha denotado por $s_1 = (0.25\ 0.75)$.

A teoria Markoviana nos diz que, no ano t, o estado do sistema é dado pelo vetor linha s_t que pode ser calculado recursivamente a partir da matriz de transição P da seguinte maneira:
$s_t = s_{t-1}.P = s_{t-2}.P^2 = \ldots = s_1.P^{t-1}$

Logo, o estado do sistema no segundo ano é:

$$s_2 = s_1.P = (0.25\ \ 0.75)\begin{pmatrix} 0.88 & 0.12 \\ 0.15 & 0.85 \end{pmatrix} = (0.3325\ \ 0.6675)$$

Logo, no 2º ano, 33.25% dos consumidores estarão comprando o cereal da marca K. Analogamente, no terceiro ano:

$$s_3 = s_2.P = (0.3325\ \ 0.6675)\begin{pmatrix} 0.88 & 0.12 \\ 0.15 & 0.85 \end{pmatrix} = (0.392725\ \ 0.607275)$$

Qual será o comportamento do "market share" do cereal K quando o tempo t tende a infinito? É razoável tentar calcular isso sob a hipótese de que, quando t é grande, o sistema alcança um certo grau de equilíbrio, no sentido que $s_t = s_{t-1}$, isto é, "depois de muito tempo" o estado do sistema não se altera com o passar do tempo. Como tentar encontrar os estados de equilíbrio? Existem dois "approaches": o primeiro é computacional, e simplesmente envolve o cálculo iterativo de $s_1, s_2 \ldots, s_t$ até um valor grande de t, esperando que estes estados "se estabilizem" para t suficientemente grande.

A segunda alternativa é combinar as expressões $s_t = s_{t-1}$ e $s_t = s_{t-1}.P$ e tentar resolvê-las algebricamente para o estado s_t. Pelo "approach" computacional:

$$P^2 = \begin{pmatrix} 0.7924 & 0.2076 \\ 0.2595 & 0.7405 \end{pmatrix}$$

$$P^3 = \begin{pmatrix} 0.7285 & 0.2715 \\ 0.3394 & 0.6606 \end{pmatrix}, \qquad P^5 = \begin{pmatrix} 0.6477 & 0.3523 \\ 0.4404 & 0.5596 \end{pmatrix},$$

$$P^{10} = \begin{pmatrix} 0.5747 & 0.4253 \\ 0.5317 & 0.4683 \end{pmatrix}$$

$$P^{20} = \begin{pmatrix} 0.5564 & 0.4436 \\ 0.5545 & 0.4455 \end{pmatrix}, \qquad P^{30} = \begin{pmatrix} 0.5556 & 0.4444 \\ 0.5555 & 0.4445 \end{pmatrix}$$

E assim parece que a probabilidade de ficar no estado 1 (comprar cereal da marca K) é 55.56% enquanto a probabilidade de optar pelo cereal concorrente é 44.44%.

A solução algébrica do mesmo problema parte das equações:

$s_t = s_{t-1}$ e
$s_t = s_{t-1}.P$

A primeira equação é apenas a nossa hipótese de equilíbrio. A segunda destas equações descreve a evolução no tempo dos "market shares" entre 2 anos consecutivos. Seja $s_t = [x_1, x_2]$. Então:

$$(x_1, x_2) = (x_1, x_2)P = (x_1, x_2)\begin{pmatrix} 0.88 & 0.12 \\ 0.15 & 0.85 \end{pmatrix}$$

Também: $x_1 + x_2 = 1 = 100\%$ (pois é a soma das participações de mercado da marca K e dos concorrentes) e esta restrição é fundamental para podermos resolver o problema. O sistema acima, em conjunto com a restrição, torna-se:

$$0.12x_1 - 0.15x_2 = 0$$
$$0.12x_1 - 0.15x_2 = 0$$
$$x_1 + x_2 = 1$$

Uma das equações acima é redundante, e por causa da restrição este sistema tem solução única, dada por: $x_1 = 0.5556$ e $x_2 = 0.4444$. Logo, se t é grande, a participação de mercado do cereal K tenderá a 55.56%.

Exemplo 3.2.4.
Uma empresa de TV por assinatura possui três tipos de pacotes de programação (em ordem crescente de preço): Standard, Plus e Premium. A proporção de clientes em cada uma destas categorias em 1999 era:

Pacote	1999
Standard	36%
Plus	46%
Premium	18%

A probabilidade de um cliente da categoria Standard permanecer neste estado num período de um ano é 60%. Analogamente, as probabilidades de permanência nos estados Plus e Premium são 70% e 78% respectivamente. As probabilidades de migração de estados são:

De	Para	Probabilidade
Standard	Plus	25%
Standard	Premium	15%
Plus	Standard	18%
Plus	Premium	12%
Premium	Standard	8%
Premium	Plus	14%

Suponha que os estados 0, 1 e 2 indicam, respectivamente, que o assinante tem um "pacote" Standard, Plus e Premium. A matriz de transição desta cadeia de Markov é dada por:

$$P = \begin{bmatrix} P_{00} & P_{01} & P_{02} \\ P_{10} & P_{11} & P_{12} \\ P_{20} & P_{21} & P_{22} \end{bmatrix} = \begin{bmatrix} 60\% & 25\% & 15\% \\ 18\% & 70\% & 12\% \\ 8\% & 78\% & 14\% \end{bmatrix}$$

Investigue o comportamento limite da matriz de transição (através do cálculo de potências "altas" de P) e calcule a proporção de clientes em cada categoria daqui a 3 anos e daqui a um número "grande" de anos.

Solução
Seja s_t o vetor que representa as proporções de clientes em cada "pacote" no instante t. Então, o market share inicial, s_0 é dado por: $s_0 = (0.36, 0.46, 0.18)$.

Após 1 ano, a proporção de clientes nas 3 categorias deverá ser $s_1 = s_0.P$:

$$(0{,}36 \quad 0{,}46 \quad 0{,}18) \cdot P = (0{,}313 \quad 0{,}552 \quad 0{,}134)$$

Após 2 anos teremos a seguinte distribuição de clientes ($s_2 = s_1 . P$):

$$s^2 = (0{,}298 \quad 0{,}57 \quad 0{,}132)$$

E depois de anos a distribuição de clientes será (calculada por $s_3 = s_2.P$):

$$s^3 = (0{,}292 \quad 0{,}576 \quad 0{,}132)$$

Algumas potências altas de P são:

$$P^{20} = \begin{matrix} 0{,}288 & 0{,}581 & 0{,}131 \\ 0{,}288 & 0{,}581 & 0{,}131 \\ 0{,}288 & 0{,}581 & 0{,}131 \end{matrix}$$

$$P^{50} = \begin{matrix} 0{,}288 & 0{,}581 & 0{,}131 \\ 0{,}288 & 0{,}581 & 0{,}131 \\ 0{,}288 & 0{,}581 & 0{,}131 \end{matrix}$$

E este parece ser o limite da matriz de transição quando o número de transições

tende a infinito. Em outras palavras, após um número grande de transições, a probabilidade de um assinante ser cliente Standard é 28.8%, de ser cliente Plus é 58.1% e de ser cliente Premium é 13.1%.

Em termos analíticos, para determinar quais as proporções de clientes nas 3 categorias após um número grande de transições devemos encontrar s = (x,y,z) tal que: s = s.P e os elementos de s satisfazem às condições:
- São números entre 0 e 1
- Sua soma é 1

Ou seja, se I denota a matriz identidade, devemos resolver o sistema: s(I – P) = 0 sujeito à condições acima especificadas.

Isto é:

$$(x, y, z) \begin{pmatrix} 0.40 & -0.25 & -0.15 \\ -0{,}18 & 0.30 & -0.12 \\ -0.08 & -0.78 & 0.86 \end{pmatrix} = (0,0,0) \qquad (3.2.2)$$

sujeito a: x + y + z = 1 e todos os x, y, z entre 0 e 1.

Podemos resolver um sistema equivalente, substituindo uma das colunas da matriz acima por (1, 1, 1) e também substituindo a coluna correspondente no lado direito da equação por 1.

Por exemplo, se substituirmos a 3ª. coluna na equação (3.2.2) acima leva a:

$$(x, y, z) \begin{pmatrix} 0.40 & -0.25 & 1 \\ -0.18 & 0.30 & 1 \\ -0.08 & -0.78 & 1 \end{pmatrix} = (0,0,1)$$

Cuja solução é:

(x, y, z) = (0.288, 0.581, 0.131).

O mesmo resultado é encontrado se substituirmos a 1ª ou 2ª colunas por $\begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$ (e

com as devidas modificações do lado direito da equação matricial).

Exemplo 3.2.5.
Uma certa máquina pode, no início de qualquer dia, estar em apenas duas condições: quebrada ou em funcionamento. Suponha que, se a máquina está quebrada no n-ésimo dia, a probabilidade de ela ter sido consertada e estar funcionando no (n+1)-ésimo dia é α. Suponha também que, se a máquina está funcionando no n-ésimo dia, a probabilidade de ela estar quebrada no (n+1)-

ésimo dia é β. Seja p_0 a probabilidade da máquina estar quebrada no instante inicial.

Seja: $X_n = \begin{cases} 0 & \text{máquina quebrada no instante n} \\ 1 & \text{maquina em funcionamento no instante n} \end{cases}$

Pela descrição acima:

$$\Pr\left[X_{n+1} = 1 \mid X_n = 0\right] = \alpha = P_{01}$$

$$\Pr\left[X_{n+1} = 0 \mid X_n = 1\right] = \beta = P_{10}$$

$$\Pr\left[X_0 = 0\right] = p_0$$

Como existem apenas 2 estados, segue que:

$$\Pr\left[X_{n+1} = 0 \mid X_n = 0\right] = 1 - \alpha = P_{00}$$

$$\Pr\left[X_{n+1} = 1 \mid X_n = 1\right] = 1 - \beta = P_{11}$$

$$\Pr\left[X_0 = 1\right] = p_1 = 1 - p_0$$

onde esta última probabilidade representa a máquina funcionando no instante inicial.

A matriz de transição desta cadeia de Markov é:

$$P = \begin{pmatrix} P_{00} & P_{01} \\ P_{10} & P_{11} \end{pmatrix} = \begin{pmatrix} 1-\alpha & \alpha \\ \beta & 1-\beta \end{pmatrix}$$

As probabilidades **incondicionais** $\Pr(X_n = 0)$ e $\Pr(X_n = 1)$ podem ser facilmente calculadas. Note que:

$$\begin{aligned} \Pr(X_{n+1} = 0) &= \Pr(X_n = 0 \text{ e } X_{n+1} = 0) + \Pr(X_n = 1 \text{ e } X_{n+1} = 0) = \\ &= \Pr(X_n = 0).\Pr(X_{n+1} = 0 \mid X_n = 0) + \Pr(X_n = 1).\Pr(X_{n+1} = 0 \mid X_n = 1) \\ &= \Pr(X_n = 0).P_{00} + \Pr(X_n = 1).P_{10} = (1-\alpha).\Pr(X_n = 0) + \beta.\Pr(X_n = 1) \end{aligned}$$

e como os únicos estados possíveis são 0 e 1 segue que $\Pr(X_n = 1) = 1 - \Pr(X_n = 0)$ para qualquer instante n. Logo:

$$\begin{aligned} \Pr(X_{n+1} = 0) &= (1-\alpha).\Pr(X_n = 0) + \beta.\{1 - \Pr(X_n = 0)\} \\ &= (1-\alpha-\beta).\Pr(X_n = 0) + \beta \end{aligned}$$

Podemos agora aplicar esta fórmula aos instantes iniciais e tentar encontrar uma fórmula geral para as probabilidades incondicionais. Note que $\Pr(X_0 = 0) = p_0$, um valor dado e então:

$\Pr(X_1 = 0) = (1-\alpha-\beta).\Pr(X_0 = 0) + \beta = (1-\alpha-\beta).p_0 + \beta$

$\Pr(X_2 = 0) = (1-\alpha-\beta).\Pr(X_1 = 0) + \beta = (1-\alpha-\beta)^2.p_0 + \beta(1+(1-\alpha-\beta))$

Se repetirmos este procedimento n vezes encontraremos:

$$\Pr(X_n = 0) = (1-\alpha-\beta)^n.p_0 + \beta\sum_{j=0}^{n-1}(1-\alpha-\beta)^j$$

Suponha que $0 < \alpha + \beta < 2$ (o que é óbvio, pois ambos representam probabilidades!). Pela fórmula da soma de uma progressão geométrica temos:

$$\sum_{j=0}^{n-1}(1-\alpha-\beta)^j = \frac{1-(1-\alpha-\beta)^n}{\alpha+\beta} \text{ e então:}$$

$$\Pr(X_n = 0) = (1-\alpha-\beta)^n.p_0 + \left(\frac{\beta}{\alpha+\beta}\right).\left(1-(1-\alpha-\beta)^n\right) =$$

$$= \left(\frac{\beta}{\alpha+\beta}\right) + (1-\alpha-\beta)^n.\left(p_0 - \frac{\alpha}{\alpha+\beta}\right).$$

Suponha que $0 < \alpha, \beta < 1$. Então $0 < \alpha + \beta < 2$ e daí $|1-\alpha-\beta| < 1$.
Neste caso, tomando o limite da expressão anterior quando n tende a ∞ leva a:

$$\lim \Pr(X_n = 0) = \left(\frac{\beta}{\alpha+\beta}\right)$$

Obviamente pode-se concluir também que:

$$\lim \Pr(X_n = 1) = 1 - \left(\frac{\beta}{\alpha+\beta}\right) = \frac{\alpha}{\alpha+\beta}$$

Vamos aplicar este resultado ao exemplo 3.2.3.

Exemplo 3.2.6.
Obtenha o limite das probabilidades incondicionais no exemplo 3.2.3. usando os resultados deduzidos no exemplo 3.2.5.

$$P = \begin{pmatrix} P_{11} & P_{12} \\ P_{21} & P_{22} \end{pmatrix} = \begin{pmatrix} 0.88 & 0.12 \\ 0.15 & 0.85 \end{pmatrix} = \begin{pmatrix} 1-\alpha & \alpha \\ \beta & 1-\beta \end{pmatrix}$$

Logo, o limite da probabilidade incondicional do estado do sistema ser 1 (isto é, consumidores comprarem a marca K) é: $\beta/(\alpha+\beta) = 0.15/(0.12+0.15) = 15/27 = 0.5556$, o que confirma o resultado encontrado anteriormente.

Exemplo 3.2.7.
Suponha que a indústria de biscoitos é controlada por 4 empresas: A, B, C e D. Se o consumidor compra biscoitos A ou B, nunca mudará de marca. Se o consumidor compra biscoitos da marca C, as probabilidades dele mudar para A, B ou D no próximo mês serão, respectivamente: 0.45, 0.40 e 0.10, e a probabilidade dele continuar comprando o biscoito C é 0.05. Analogamente, para

consumidores da marca D, as probabilidades de mudar para A, B, C serão, respectivamente 0.1, 0.2 e 0.3, enquanto ele permanecerá com a mesma marca com probabilidade 0.4.

Se os "market shares" iniciais das marcas A, B, C e D são, respectivamente, 20%, 30%, 30% e 20%, como estará a situação depois de 2 meses?

Solução

Defina como estados possíveis 1, 2, 3, 4 que correspondem às marcas A a D respectivamente. A matriz de transição é:

$$P = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0.45 & 0.40 & 0.05 & 0.10 \\ 0.10 & 0.20 & 0.30 & 0.40 \end{pmatrix}$$

A distribuição de estados no instante inicial (primeiro mês) é: s_1 = [0.2, 0.3, 0.3, 0.2]

Logo, o estado do sistema no segundo mês é: $s_2 = s_1.P$ = [0.355, 0.460, 0.075, 0.110]

Analogamente, o estado do sistema no terceiro mês é: $s_3 = s_2.P$ = [0.3998, 0.5120, 0.0368, 0.0515]

Note que as probabilidades de estar nos estados 3 e 4 (isto é, comprar os biscoitos C ou D) vão caindo com o tempo. Isto é razoável (por quê?????). Na verdade, se computarmos algumas potências "altas" da matriz de transição encontramos um resultado bem interessante...

Por exemplo:

$$P^5 = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0.5148 & 0.4772 & 0.0034 & 0.0047 \\ 0.4101 & 0.5559 & 0.0142 & 0.0199 \end{pmatrix}$$

$$P^{10} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0.5148 & 0.4814 & 0.0001 & 0.0001 \\ 0.4256 & 0.5737 & 0.0003 & 0.0005 \end{pmatrix}$$

$$P^{30} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0.5185 & 0.4815 & 0.0000 & 0.0000 \\ 0.4259 & 0.5741 & 0.0000 & 0.0000 \end{pmatrix}$$

Ou seja, após um número grande de transições, a probabilidade de "chegar" aos estados 3 ou 4 (biscoitos C ou D) é zero! Os estados 1 e 2 (biscoitos A e B) são "absorventes" (uma vez alcançados, é impossível sair deles), enquanto os estados 3 e 4 são "transientes". Estados "absorventes" e "transientes" serão estudados formalmente mais tarde neste capítulo.

3.3. Análise do Primeiro Passo

A análise do primeiro passo é uma técnica que nos permite descobrir uma série de fatos relacionados à evolução de uma Cadeia de Markov. A idéia geral do método é analisar as probabilidades que surgem no final da primeira transição para estabelecer relações entre as variáveis de interesse. Na verdade, esta análise já foi feita na seção anterior, no exemplo 3.2.4., e nos levou a descobrir as probabilidades incondicionais de dois estados em qualquer instante de tempo.

Exemplo 3.3.1.

Considere uma cadeia de Markov com 3 estados (1, 2 e 3) e a seguinte matriz de transição e diagrama dados a seguir:

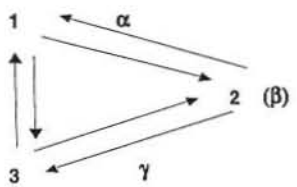

$$P = \begin{pmatrix} 1 & 0 & 0 \\ a & \beta & y \\ 0 & 0 & 1 \end{pmatrix} t$$

Os estados 1 e 3 são **absorventes**, pois **ao chegarmos neles não conseguimos mais sair**. Se a cadeia de Markov começa no estado 1 (ou no estado 3) permanece no mesmo estado indefinidamente. Ao contrário, se a cadeia de Markov começa no estado 2, fica neste estado por algum intervalo de tempo aleatório e daí eventualmente passa para o estado 1 ou 3, onde "fica presa".

Existem duas questões de interesse:

1) Em qual estado, 1 ou 3, a cadeia ficará "presa"?
2) Quanto tempo, em média, levamos até alcançar um dos estados absorventes?

Em termos formais, seja $T = \text{mín}\{n \geq 0 \text{ tal que } X_n = 1 \text{ ou } X_n = 3\}$. T indica o menor tempo até entrarmos num estado absorvente. As duas questões de interesse acima podem ser reescritas como:

1) Encontrar $u = Pr\{X_T = 1 \mid X_0 = 2\}$, a probabilidade de a cadeia chegar no estado absorvente 1 dado que ela começou no estado transiente 2.
2) Encontrar $v = E\{T \mid X_0 = 2\}$

Considere o que acontece no primeiro passo. Suponha que a cadeia está inicialmente no estado 2 (do contrário, não há transição, pois 1 e 3 são estados absorventes).

- Se $X_1 = 1$ (o que ocorre com probabilidade $P_{21} = \alpha$) então $T = 1$ e $X_T = 1$.
- Se $X_1 = 3$ (o que ocorre com probabilidade $P_{23} = \gamma$) então $T = 1$, mas $X_T = 3$.
- Se $X_1 = 2$ (o que ocorre com probabilidade $P_{22} = \beta$) o processo continua no estado transiente 2 e o problema se repete da mesma maneira que na primeira transição.

Então:

$\Pr\{X_T = 1 \mid X_1 = 1\} = 1$
$\Pr\{X_T = 1 \mid X_1 = 3\} = 0$
$\Pr\{X_T = 1 \mid X_1 = 2\} = u$

Logo:

$u = \Pr\{X_T = 1 | X_0 = 2\} =$

$$\sum_{k=1}^{3} \Pr\left\{ X_T = 1 | X_0 = 2, X_1 = k \right\} \Pr\left\{ X_1 = k | X_0 = 2 \right\}$$

E pela propriedade Markoviana:

$$\Pr\left\{ X_T = 1 \;\middle|\; X_0 = 2, X_1 = k \right\} = \Pr\left\{ X_T = 1 \;\middle|\; X_1 = k \right\}$$

Então:

$u = \Pr\{X_T = 1 \mid X_0 = 2\} =$

$$\sum_{k=1}^{3} \Pr\left\{ X_T = 1 \;\middle|\; X_1 = k \right\} \Pr\left\{ X_1 = k \;\middle|\; X_0 = 2 \right\} =$$

$$= 1\ (\alpha) + u\ (\beta) + 0\ (\gamma) = \alpha + u.\beta$$

Resolvendo esta última equação para u leva a:

$$u = \frac{\alpha}{1-\beta} = \frac{\alpha}{\alpha+\gamma}$$

Note que u representa a probabilidade condicional de uma transição para o estado 1 dado que o estado inicial era o estado transiente 2 (e, portanto, alguma transição para os estados 1, 2 ou 3 ocorreu na passagem do instante 0 para o instante 1).

Agora vamos olhar para o tempo médio até uma absorção. Note que $T \geq 1$ sempre e então $v = E\{T \mid X_0 = 2\}$ deve ser sempre ≥ 1 também. Também é importante notar que esta é uma média *condicional* dado um estado inicial X_0, e se o estado inicial tivesse sido outro, o valor da média condicional seria, a princípio, diferente.

Se $X_1 = 1$ ou $X_1 = 3$ então $T = 1$ e não precisamos fazer mais nada. Ao contrário, se $X_1 = 2$, o processo está nas mesmas condições que na transição inicial, e na **média** $v = E\{T \mid X_0 = 2\}$ passos adicionais são necessários para a absorção. Pesando estas ocorrências pelas suas probabilidades leva a:

$v = E\{T \mid X_0 = 2\} = 1 + \alpha(0) + \beta(v) + \gamma(0) = 1 + \beta.v$

Resolvendo esta equação para v leva a:

$$v = \frac{1}{1-\beta}$$

Exemplo 3.3.2.
Este é apenas o exemplo 3.3.1. reescrito com uma matriz numérica. Suponha que a matriz de transição é:

$$P = \begin{pmatrix} 1 & 0 & 0 \\ \alpha & \beta & \gamma \\ 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0.3 & 0.5 & 0.2 \\ 0 & 0 & 1 \end{pmatrix}$$

A probabilidade condicional de pararmos no estado 1 dado que a cadeia começou no estado transiente 2 é:

$$u = \Pr\{X_T = 1 \mid X_0 = 2\} = \frac{\alpha}{1-\beta} = \frac{\alpha}{\alpha+\gamma} = \frac{3}{5} = 60\%$$

O tempo médio até uma absorção é:

$$v = \frac{1}{1-\beta} = \frac{1}{0.5} = 2$$

Apenas como curiosidade, vamos olhar para algumas potências da matriz de transição:

$P^{20} = P^{50} = \begin{pmatrix} 1 & 0 & 0 \\ 0.6 & 0 & 0.4 \\ 0 & 0 & 1 \end{pmatrix}$. Logo, após "muitas" transições, a probabilidade de ficar no instante transiente 2 é nula. Note também que, a probabilidade de "cair" no estado 1 saindo do estado 2, após muitas transições, é 0.6, ou seja, é a probabilidade u já calculada.

Se agora a matriz de transição é:

$$P = \begin{pmatrix} 1 & 0 & 0 \\ \alpha & \beta & \gamma \\ 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0.1 & 0.8 & 0.1 \\ 0 & 0 & 1 \end{pmatrix}$$

$$u = \Pr\{X_T = 1 \mid X_0 = 2\} = \frac{\alpha}{1-\beta} = \frac{\alpha}{\alpha+\gamma} = \frac{0.1}{0.2} = 50\%$$

O tempo médio até uma absorção é:

$$v = \frac{1}{1-\beta} = \frac{1}{0.2} = 5$$

Uma potência "grande" da matriz de transição nos leva ao valor limite desta matriz.

$$P^{50} = \begin{pmatrix} 1 & 0 & 0 \\ 0.5 & 0 & 0.5 \\ 0 & 0 & 1 \end{pmatrix}$$

Note que a segunda linha desta matriz reflete a simetria das probabilidades de transição no instante inicial, ou seja, $P_{21} = P_{23} = 0.1$, e assim no limite, as probabilidades de cair em qualquer um dos estados absorventes são iguais.

Exemplo 3.3.3.
A situação dos exemplos anteriores fica sensivelmente mais complicada quando consideramos uma cadeia com 4 estados. Considere uma cadeia de Markov com estados 0, 1, 2 e 3 e a seguinte matriz de transição:

$$P = \begin{pmatrix} 1 & 0 & 0 & 0 \\ P_{10} & P_{11} & P_{12} & P_{13} \\ P_{20} & P_{21} & P_{22} & P_{23} \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

Os estados 0 e 3 são absorventes, os outros são transientes.

A probabilidade de uma eventual absorção no estado zero depende agora de **qual** estado transiente iniciou o processo.

Sejam:
$T = \min\{n \geq 0 \text{ tal que } X_n = 0 \text{ ou } X_n = 3\}$
$u_i = Pr\{X_T = 0 \mid X_0 = i\}$, $i = 1, 2$
$v_i = E\{T \mid X_0 = i\}$, $i = 1, 2$

Podemos estender as definições de u_i e v_i para todos os estados fazendo:
$u_0 = 1$, $u_3 = 0$, $v_0 = v_3 = 0$.

A análise do primeiro passo exige que consideremos separadamente os dois possíveis estados iniciais, $X_0 = 1$ e $X_0 = 2$.

Sob a hipótese de que o estado inicial é $X_0 = 1$ e aplicando a análise do primeiro passo temos:

$$u_1 = Pr\{X_T = 0 \mid X_0 = 1\} = \sum_{k=0}^{3} Pr\{X_T = 0 | X_1 = k\} Pr\{X_1 = k | X_0 = 1\} =$$

$$= P_{10}.u_0 + P_{11}.u_1 + P_{12}.u_2 + P_{13}.u_3 = P_{10} + P_{11}.u_1 + P_{12}.u_2 \text{ pois } u_3 = 0 \text{ e } u_0 = 1.$$

Analogamente, a expressão para u_2 é:

$$u_2 = Pr\{X_T = 0 \mid X_0 = 2\} = \sum_{k=0}^{3} Pr\{X_T = 0 | X_1 = k\} Pr\{X_1 = k | X_0 = 2\} =$$

$$= P_{20}.u_0 + P_{21}.u_1 + P_{22}.u_2 + P_{23}.u_3 = P_{20} + P_{21}.u_1 + P_{22}.u_2$$

Precisamos resolver simultaneamente para u_1 e u_2 as equações anteriores, isto é:

$$u_1 = P_{10} + P_{11}.u_1 + P_{12}.u_2$$
$$u_2 = P_{20} + P_{21}.u_1 + P_{22}.u_2$$

Daí:

$$u_2 = \frac{P_{20} - P_{11}.P_{20} + P_{10}.P_{21}}{1 - P_{11} - P_{22} + P_{11}.P_{22} - P_{12}.P_{21}}$$

$$u_1 = \frac{1}{1 - P_{11}} \left\{ P_{10} + P_{12}.u_2 \right\}$$

O **tempo médio de absorção** também depende do estado inicial. Sejam:
$v_i = E\{T \mid X_0 = i\}$, $i = 1, 2$. Então, analogamente ao exemplo anterior, temos:

$$v_1 = 1 + P_{11}.v_1 + P_{12}.v_2$$
$$v_2 = 1 + P_{21}.v_1 + P_{22}.v_2$$

A solução deste sistema é:

$$v_2 = \frac{1 - P_{11} + P_{21}}{1 - P_{11} - P_{22} - P_{12}.P_{21} + P_{11}.P_{22}}$$

$$v_1 = \frac{1 + P_{12}.v_2}{1 - P_{11}}$$

Exemplo 3.3.4.
Considere a situação do exemplo anterior e suponha que a matriz de transição é dada por:

$$P = \begin{pmatrix} 1 & 0 & 0 & 0 \\ P_{10} & P_{11} & P_{12} & P_{13} \\ P_{20} & P_{21} & P_{22} & P_{23} \\ 0 & 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0.4 & 0.3 & 0.2 & 0.1 \\ 0.1 & 0.3 & 0.3 & 0.3 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

Pelo exemplo anterior:

$$u_2 = \frac{0.1 - (0.3)(0.1) + (0.4)(0.3)}{1 - 0.3 - 0.3 + (0.3)(0.3) - (0.2)(0.3)} = \frac{0.19}{0.43} = \frac{19}{43}$$

$$u_1 = \frac{1}{1 - P_{11}} \{P_{10} + P_{12}.u_2\} = \frac{1}{0.7} \left\{ 0.4 + 0.2 \left(\frac{19}{43} \right) \right\} = \frac{30}{43}$$

Assim, podemos concluir que a probabilidade da cadeia ser absorvida pelo estado 3 dado que o estado inicial é o estado transiente 1 é:

$$Pr\{X_T = 3 \mid X_0 = 1\} = 1 - u_1 = 13/43$$

Seja $u_i = u_i(7)$ a probabilidade de absorção no compartimento de comida (compartimento 7) dado que o rato é inicialmente colocado no compartimento i.

Isto é:

$u_i = Pr\{\text{absorção pelo estado } 7 \mid X_0 = i\} =$

$= P_{i7} + \sum_{j=0}^{6} P_{ij}.U_{j7} = P_{i7} + \sum_{j=0}^{6} P_{ij}.u_j$, $i = 0,1\ldots, 6$

Os u_i são as soluções do sistema:

$$u_0 = \frac{1}{2}u_1 + \frac{1}{2}u_2$$

$$u_1 = \frac{1}{3} + \frac{1}{3}u_0 + \frac{1}{3}u_3$$

$$u_2 = \frac{1}{3}u_0 + \frac{1}{3}u_3$$

$$u_3 = \frac{1}{4}u_1 + \frac{1}{4}u_2 + \frac{1}{4}u_4 + \frac{1}{4}u_5$$

$$u_4 = \frac{1}{3} + \frac{1}{3}u_3 + \frac{1}{3}u_6$$

$$u_5 = \frac{1}{3}u_3 + \frac{1}{3}u_6$$

$$u_6 = \frac{1}{2}u_4 + \frac{1}{2}u_5$$

Por simetria deduzimos que:

$u_0 = u_6$

$u_1 = u_4$

$u_2 = u_5$

Também por simetria concluímos que $u_3 = 1/2$. Estes resultados nos levam a:

$u_0 = 1/2 \Rightarrow u_6 = 1/2$
$u_1 = 2/3 \Rightarrow u_4 = 2/3$
$u_2 = 2/3 \Rightarrow u_5 = 2/3$
$u_3 = 1/2$

Numa experiência real pode-se comparar estes valores teóricos com os observados na prática e tentar inferir se existe evidência de aprendizado.

Mostre empiricamente (através de potências "grandes" de P) que o limite de P^n é uma matriz onde apenas os elementos das últimas 2 colunas são diferentes de zero, e verifique que os elementos correspondentes à penúltima coluna (estado 7) são os encontrados na resolução do sistema acima.

3.4. Maiores Detalhes sobre o Passeio Aleatório

Nesta seção consideramos em maior profundidade o modelo de passeio aleatório descrito anteriormente.

Exemplo 3.4.1.
Considere uma cadeia de Markov com 2 estados (0 e 1) e a seguinte matriz de transição:

$$P = \begin{pmatrix} 1-a & a \\ b & 1-b \end{pmatrix} \quad 0 < a,b < 1$$

Se a = 1-b, as duas linhas da matriz de transição são idênticas, e os estados X_1, X_2... são variáveis aleatórias independentes e identicamente distribuídas com: $Pr\{X_n = 0\} = b$ e $Pr\{X_n = 1\} = 1 - b$.

Se $a \neq 1-b$, a distribuição de probabilidade de X_n varia de acordo com o estado no passo anterior.

Se $a \neq 1-b$, pode-se verificar (por indução) que:

$$P^n = \frac{1}{a+b}\begin{pmatrix} b & a \\ b & a \end{pmatrix} + \frac{(1-a-b)^n}{a+b}\begin{pmatrix} a & -a \\ -b & b \end{pmatrix}$$

Mas, por hipótese $0 < a,b < 1$ e então $a + b < 2$ e segue que o limite quando n tende a infinito de $(1 - a - b)^n$ é zero. Logo, a matriz de transição limite é:

$$\lim P^n = \frac{1}{a+b}\begin{pmatrix} b & a \\ b & a \end{pmatrix}$$

Ou seja, no limite (quando $n \to \infty$) o sistema estará no estado 0 com probabilidade b/(a+b) e no estado 1 com probabilidade a/(a+b) **independente do estado original**.

Exemplo 3.4.2.

Seja $P = \begin{pmatrix} 0.99 & 0.01 \\ 0.12 & 0.88 \end{pmatrix}$. Calcule P^2, P^4, P^{50} e o limite da matriz de transição usando o resultado do exemplo anterior.

Solução

$$P^2 = \begin{pmatrix} 0.9813 & 0.0187 \\ 0.2244 & 0.7756 \end{pmatrix},\ P^4 = \begin{pmatrix} 0.9671 & 0.0329 \\ 0.3942 & 0.6058 \end{pmatrix},\ P^{50} = \begin{pmatrix} 0.9231 & 0.0769 \\ 0.9222 & 0.0778 \end{pmatrix}$$

O limite da matriz de transição é, pelo exemplo anterior (fazendo a = 0.01 e b = 0.12):

$$\lim P = \begin{pmatrix} \frac{12}{13} & \frac{1}{13} \\ \frac{12}{13} & \frac{1}{13} \end{pmatrix} = \begin{pmatrix} 0.9231 & 0.0769 \\ 0.9231 & 0.0769 \end{pmatrix}$$

Exemplo 3.4.3. O Passeio Aleatório Simples e Irrestrito
Considere uma partícula que se move apenas em uma dimensão (eixo x). A

partícula está inicialmente localizada em x = 0 e, a cada instante de tempo, pode se mover uma unidade para a direita ou esquerda. A probabilidade de movimento para a direita é p, e para a esquerda é q = 1-p.

Seja X_n a posição da partícula no instante n. Os estados possíveis são {..., -2, -1, 0, 1, 2...}. As probabilidades de transição são:

$$P_{ij} = \begin{cases} p & \text{se } j = i+1 \\ q & \text{se } j = i-1 \\ 0 & \text{se } j \neq i-1, i+1 \end{cases}$$

Este passeio aleatório é chamado de **irrestrito** porque não existem limites impostos aos valores dos X_n. Podemos pensar neste processo como gerado por variáveis aleatórias independentes e identicamente distribuídas Z_n tais que:

$X_0 = 0$
$X_n = X_{n-1} + Z_n$ para n =1, 2, 3...

Onde os Z_n 's são independentes e identicamente distribuídos com valores + 1 e -1 e probabilidades associadas p e q.

A média e a variância dos X_n's podem ser facilmente calculadas se pensarmos em termos dos Z_n's.

Note que:

$E(Z_n) = +1(p) + (-1)q = p - q = p - (1-p) = 2p - 1$
$E(Z_n^2) = +1(p) + (-1)^2.q = p + q = 1$
E então: $Var(Z_n) = 1 - (2p-1)^2 = 1 - 4p^2 + 4p - 1 = 4p(1-p) = 4pq$ para todo n = 1, 2, 3...

Mas, note que, como $X_0 = 0$ por hipótese:

$X_1 = Z_1$
$X_2 = X_1 + Z_2 = Z_1 + Z_2$
$X_3 = X_2 + Z_3 = Z_1 + Z_2 + Z_3$
...
$X_n = Z_1 + Z_2 + Z_3 + ... + Z_n$

A média e variância de X_n são dadas por:

$E(X_n) = E\{Z_1 + Z_2 + Z_3 + ... + Z_n\} = n.E\{Z_1\} = n\{2p-1\}$

$Var(X_n) = Var\{Z_1 + Z_2 + Z_3 + ... + Z_n\} = n.Var\{Z_1\} = n\{4pq\} = 4npq$

Note que a média e a variância crescem linearmente com o tempo (n).

Nosso próximo objetivo é encontrar a distribuição de probabilidade de X_n. Suponha que estamos no instante n.

Seja $p_k^{(n)} = Pr\{X_n = k\}$ onde k é um número inteiro. Note que $p_k^{(n)} = 0$ se $n < |k|$ porque o processo não consegue chegar (partindo de zero) ao estado k em menos de |k| passos. Logo, dado que estamos no instante $\underline{n}$, é necessário que $n \geq |k|$ para que o estado tenha probabilidade não nula.

Podemos dividir os n passos em 2 tipos: os feitos na direção positiva do eixo x (denotados por N_n^+) e aqueles na direção negativa do eixo (indicados por N_n^-). Note que N_n^+ e N_n^- são também variáveis aleatórias.
Daí segue que:

$X_n = N_n^+ - N_n^-$ e
$n = N_n^+ + N_n^-$ (soma dos números de passos nas duas direções).

A soma destas duas expressões resulta em:

$N_n^+ = (X_n + n)/2$
Também, $X_n = k$ se, e somente se, $N_n^+ = (k+ n)/2$

Note que a distribuição de N_n^+ é uma **Binomial** com parâmetros $\underline{n}$ e $\underline{p}$ (por quê?).

Além disso, $2.N_n^+ = (k+ n)$ e $2.N_n^+$ é, necessariamente, um número par. Logo, **X_n precisa ser par se $\underline{n}$ é par, e X_n é ímpar se $\underline{n}$ é ímpar.**

Combinando todas estas considerações e usando o fato de que N_n^+ é uma variável Binomial temos:

$$p_k^{(n)} = Pr(X_n = k) = \binom{n}{\frac{(n+k)}{2}} . p^{\frac{n+k}{2}} . (1-p)^{\frac{n-k}{2}}$$ para $n \geq |k|$ e k, n ambos pares ou ambos ímpares.

Por exemplo, a probabilidade de a partícula estar no estado k = -2 após $\underline{n}$ = 4 transições é:

$$p_{-2}^{(4)} = \binom{4}{1} p^1 q^3 = 4pq^3$$

A probabilidade de a partícula estar no estado k = 3 após $\underline{n}$ = 5 transições é:

$$p_3^{(5)} = \binom{5}{4} p^4 q = 5p^4 q$$

Como exemplo, vamos calcular a distribuição de probabilidade no instante $\underline{n}$ = 5. Note que $p_k^{(n)} = 0$ se $|k| > 5$ e também k deve ser ímpar. Logo, os únicos valores para os quais existe probabilidade não nula são -5, -3, -1, 1, 3, 5 e as probabilidades associadas a eles são:

$$Pr\{X_5 = -5\} = \binom{5}{0} q^5 = q^5$$

$$Pr\{X_5 = -3\} = \binom{5}{1} pq^4 = 5pq^4$$

$$Pr\{X_5 = -1\} = \binom{5}{2} p^2 q^3 = 10p^2 q^3$$

$$\Pr\{X_5 = +1\} = \binom{5}{3} p^3q^2 = 10p^3q^2$$

$\Pr\{X_5 = +3\} = 5p^4q$ (já calculado)

$$\Pr\{X_5 = +5\} = \binom{5}{0} p^5 = p^5$$

Também, esta é uma função de probabilidade bem especificada, pois a soma das probabilidades é 1, e todas as probabilidades são não negativas.

Note que:
$q^5 + 5pq^4 + 10p^2q^3 + 10p^3q^2 + 5p^4q + p^5 = (p + q)^5 = 1$ (verifique!!!!)

Nos gráficos a seguir, exibimos estas probabilidades para p = 0.25, 0.5 e 0.75 e para X_n = -5, -3.., +5.

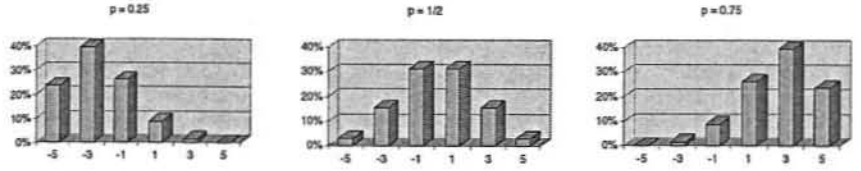

O Passeio Aleatório Unidimensional

Um passeio aleatório unidimensional é uma cadeia de Markov cujo espaço de estados é um subconjunto finito ou infinito {a, a+1..., b} dos inteiros. Isto serve para modelar a posição de uma partícula que, estando num estado i pode, numa única transição, ficar em i ou mover-se para os estados i -1 ou i +1.

Se o espaço de estados está restrito aos inteiros não negativos, a matriz de transição tem a forma:

$$P = \begin{bmatrix} r_0 & p_0 & 0 & 0 & \ldots\ldots \\ q_1 & r_1 & p_1 & 0 & \ldots\ldots \\ 0 & q_2 & r_2 & p_2 & \ldots \\ & & \ldots\ldots\ldots\ldots & & \end{bmatrix}$$

onde:
$p_i > 0$, $q_i > 0$, $r_i > 0$
$q_i + r_i + p_i = 1$ para i = 1, 2, 3...
$p_0 \geq 0$, $r_0 \geq 0$
$r_0 + p_0 = 1$

Especificamente, se $X_n = i > 0$ então:

$\Pr\{X_{n+1} = i + 1 \mid X_n = i\} = p_i$
$\Pr\{X_{n+1} = i - 1 \mid X_n = i\} = q_i$
$\Pr\{X_{n+1} = i \mid X_n = i\} = r_i$

Também, o passeio aleatório unidimensional é usado com freqüência para

modelar a "fortuna" de um jogador. Neste contexto, suponha que um indivíduo (jogador A) com fortuna k jogue contra um adversário infinitamente rico e tem probabilidade p_k de ganhar US$ 1 numa jogada, e probabilidade $q_k = 1 - p_k$ ($k \geq 1$) de perder US$1 em cada jogada. Suponha que o estado 0 é absorvente, e então $r_0 = 1$. Seja X_n a fortuna do jogador A após n jogadas. X_n é representado por um passeio aleatório unidimensional. O evento "alcançar o estado 0" é chamado de ruína do jogador.

Se ambos o jogador A e seu adversário (jogador B), começam o jogo com quantidades de dinheiro finitas, k e l respectivamente, ainda podemos considerar o processo X_n como a representação da fortuna do jogador A. Neste caso, os estados possíveis do processo são 0, 1,2..., N = k +l. Em cada jogada, N - X_n é a fortuna do jogador B. Os estados 0 e N são absorventes - alcançá-los implica o término do jogo, pois um dos jogadores não tem mais dinheiro.

Se admitirmos que, em qualquer jogada, é possível não ganhar nem perder, a matriz de transição é:

$$P = \begin{bmatrix} 1 & 0 & 0 & 0 & \ldots\ldots & 0 \\ q_1 & r_1 & p_1 & 0 & \ldots\ldots & 0 \\ 0 & q_2 & r_2 & p_2 & \ldots & 0 \\ & & \ldots\ldots\ldots\ldots & & & \\ 0 & 0 & 0 & 0 & \ldots\ldots & 1 \end{bmatrix}$$

- p_i indica a probabilidade do jogador A aumentar sua fortuna em US$ 1 quando a sua fortuna atual é i.
- q_i é a probabilidade do jogador A diminuir sua fortuna em US$ 1 quando a sua fortuna atual é i.
- r_i é a probabilidade do jogador A manter inalterada a sua fortuna quando a sua fortuna atual é i, isto é, é a probabilidade de nenhum jogador ganhar ou perder a jogada atual.

Um caso especial ocorre quando estas probabilidades não dependem do estado atual. O passeio aleatório com $p_i = p$ e $q_i = q = 1 - p$ para todo $i \geq 1$ e $r_0 = 1$ descreve a situação onde a probabilidade de ganho ou perda é fixa e constante a cada tentativa. Note que o jogador A tem uma vantagem sobre o jogador B se p > q, e o contrário acontece se p < q. Supondo que a quantidade de dinheiro total disponível é N (soma das "fortunas" dos jogadores A e B, seja X_n a fortuna do jogador A após n jogadas. A matriz de transição é:

$$P = \begin{bmatrix} 1 & 0 & 0 & 0 & \ldots\ldots & 0 \\ q & 0 & p & 0 & \ldots\ldots & 0 \\ 0 & q & 0 & p & \ldots & 0 \\ & & \ldots\ldots\ldots\ldots & & & \\ 0 & 0 & 0 & 0 & \ldots\ldots & 1 \end{bmatrix}$$

Seja u_i a probabilidade de eventual ruína do jogador A, dado que sua fortuna inicial era i. Então u_i é a probabilidade do passeio aleatório descrito alcançar o

estado zero antes de alcançar o estado N supondo que o estado inicial é $X_0 = i$. Note que, se as fortunas iniciais dos jogadores A e B são, respectivamente, i e (N-i) então u_i como definido acima indica a probabilidade do jogador A ser arruinado antes do jogador B. Dos resultados da seção anterior concluímos que:

$u_i = U_{i0}$ = Pr {alcançar o estado 0 antes do estado N | $X_0 = i$} =

$P_{i0} + \sum_{j=0}^{r-1} P_{ij} U_{j0}$ $i = 1,2,...,N-1$ onde os i's representam estados transientes.

Mas: $P_{ij} = 0$ se $j \neq i - 1$ ou $i + 1$. Logo:

$u_i = U_{i0} = P_{i,i+1}.U_{i+1,0} + P_{i,i-1}.U_{i-1,0}$

Mas, neste último exemplo as probabilidades são fixas para todas as transições e então $P_{i,i+1} = p$ e $P_{i,i-1} = q = 1-p$. Por substituição na equação acima temos:

$$u_i = p.\, u_{i+1} + q.\, u_{i-1} \quad \text{para todo } i = 1, 2,..., N-1 \qquad (3.4.1)$$
$$u_0 = 1 \quad e \quad u_N = 0$$

Note que os estados i = 1, 2..., N-1 são estados transientes, enquanto 0 e N são estados absorventes. Nosso objetivo ao resolver o sistema de equações acima é calcular a probabilidade de ruína do jogador A quando o estado inicial é i. Em outras palavras, os u_i's indicam a probabilidade de absorção pelo estado 0 quando a fortuna inicial é i. Mostraremos posteriormente que a solução destas equações é:

$u_i = U_{i0}$ = Pr {alcançar o estado 0 antes do estado N | $X_0 = i$} =

$$= \begin{cases} \dfrac{N-i}{N} & \text{se } p = q = 1/2 \\ \dfrac{\left(\frac{q}{p}\right)^i - \left(\frac{q}{p}\right)^N}{1 - \left(\frac{q}{p}\right)^N} & \text{se } p \neq q \end{cases} \qquad (3.4.2)$$

Se o jogador B é infinitamente rico ($N \to \infty$) e levando-se em conta que o limite quando $N \to \infty$ de $(q/p)^N$ é ∞ quando $q > p$ e zero quando $q < p$ podemos concluir que, se o jogador A joga contra um oponente infinitamente rico:

$$u_i = \begin{cases} 1 & \text{se } p \leq q \\ \left(\frac{q}{p}\right)^i & \text{se } p > q \end{cases}$$

Assim, a ruína do jogador é certa se ele joga em desvantagem ($p \leq q$) contra um adversário infinitamente rico. Se o jogo é favorável ao jogador A, a sua ruína ocorre com probabilidade $(q/p)^i$, e a probabilidade de ruína decresce quando a fortuna inicial cresce.

Exemplo 3.4.4.
Considere uma cadeia de Markov com estados possíveis 0, 1..., N onde 0 e N são absorventes e a fortuna inicial do jogador A é i. Também suponha que $P_{ii} = 0$, $P_{i,i+1} = p$ e $P_{i,i-1} = q = 1- p$ e $P_{00} = P_{NN} = 1$ (pois 0 e N são estados absorventes).

A probabilidade de ruína do jogador A partindo de uma fortuna inicial i é dada pelas equações 3.4.1., isto é:

$u_i = p.\, u_{i+1} + q.\, u_{i-1}$ para todo $i = 1,2,...,N-1$
$u_0 = 1$ e $u_N = 0$

A solução destas equações é simples, mas chata, mas o "algoritmo" usado na solução será usado outras vezes, por isso é importante estudar um método para a sua solução.

O primeiro passo é rearranjar (3.4.1), usando o fato: p + q = 1. Daí:

$(p+ q)u_i = u_i = p.u_{i+1} + q.u_{i-1} \Rightarrow 0 = p(u_{i+1} - u_i) - q(u_i - u_{i-1})$

Defina agora $x_i = u_i - u_{i-1}$ para todo i =1,2...,N. Logo: $0 = p.x_{i+1} - q.x_i$

Ao escrevermos esta última expressão para i = 1,2... N podemos resolver iterativamente para x_i e, conseqüentemente, para as probabilidades de ruína u_i. Assim:
$x_2 = (q/p)x_1$
$x_3 = (q/p)x_2 = (q/p)^2x_1$
$x_4 = (q/p)x_3 = (q/p)^3x_1$
e, de uma maneira geral: $x_i = (q/p)^{i-1} x_1$

Podemos agora reescrever estas expressões em termos dos u_i's, isto é, em termos das probabilidades de ruína do jogador A. Lembre-se que $u_0 = 1$ e $u_N = 0$. Daí:
$x_1 = u_1 - u_0 = u_1 - 1$
$x_2 = u_2 - u_1 \Rightarrow x_1 + x_2 = u_2 - 1$
$x_3 = u_3 - u_2 \Rightarrow x_1 + x_2 + x_3 = u_3 - 1$
...
$x_i = u_i - u_{i-1} \Rightarrow x_1 + x_2 + x_3 +...+ x_i = u_i - 1$
...
$x_N = u_N - u_{N-1} \Rightarrow x_1 + x_2 + x_3 +...+ x_N = u_N - 1 = - 1$, pois $u_N = 0$.

Então, para qualquer i = 1,2... temos:

$u_i = 1 + x_1 + x_2 + x_3 +...+ x_i = 1 + x_1 + (q/p)x_1 + (q/p)^2x_1 +...+ (q/p)^{i-1}.x_1$

Isto é:
$u_i = 1 + x_1\{1 + (q/p) + (q/p)^2 +...+ (q/p)^{i-1}\}$

Nesta última expressão estamos escrevendo a probabilidade de ruína u_i em termos da diferença (ainda desconhecida) $x_1 = u_1 - 1$. Mas, $u_N = 0$ e substituindo este resultado na expressão acima leva a:

$u_N = 0 = 1 + x_1\{1 + (q/p) + (q/p)^2 +...+ (q/p)^{N-1}\}$

E assim:

$$x_1 = \frac{-1}{\left\{1+\left(\frac{q}{p}\right)+\left(\frac{q}{p}\right)^2+\ldots+\left(\frac{q}{p}\right)^{N-1}\right\}}$$

Mas, a soma de uma série geométrica é:

$$\sum_{j=1}^{N-1} a^j = 1+a+a^2+\ldots+a^{N-1} = \begin{cases} N & \text{se } a=1 \\ \dfrac{1-a^N}{1-a} & \text{se } a\neq 1 \end{cases}$$

Empregando este resultado na expressão para x_1 leva a:

$$x_1 = \frac{-1}{\left\{1+\left(\frac{q}{p}\right)+\left(\frac{q}{p}\right)^2+\ldots+\left(\frac{q}{p}\right)^{N-1}\right\}} = \begin{cases} \dfrac{-1}{N} & \text{se } q=p=1/2 \\ \dfrac{-1}{\frac{1-(q/p)^N}{1-(q/p)}} & \text{se } q\neq p \end{cases}$$

A partir desta expressão encontramos (finalmente!!!) a *probabilidade de ruína de um jogador* cuja fortuna inicial é i, isto é:

$$u_i = 1 + x_1\{1 + (q/p) + (q/p)^2 + \ldots + (q/p)^{i-1}\}$$

$$u_i = 1 - \frac{\left\{1+\left(\frac{q}{p}\right)+\left(\frac{q}{p}\right)^2+\ldots+\left(\frac{q}{p}\right)^{i-1}\right\}}{\left\{1+\left(\frac{q}{p}\right)+\left(\frac{q}{p}\right)^2+\ldots+\left(\frac{q}{p}\right)^{N-1}\right\}} = \begin{cases} 1-\dfrac{i}{N}=\dfrac{N-i}{N} & \text{se } p=q=1/2 \\ 1-\dfrac{\left\{1-(q/p)^i\right\}}{\left\{1-(q/p)^N\right\}} = \dfrac{(q/p)^i-(q/p)^N}{1-(q/p)^N} & \text{se } p\neq q \end{cases}$$

Exemplo 3.4.5.
Considere a situação do exemplo anterior e suponha que os estados absorventes são 0 e 8 e que p = 0.6 e q = 0.4. A matriz de transição é:

$$P = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0.4 & 0 & 0.6 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0.4 & 0 & 0.6 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0.4 & 0 & 0.6 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0.4 & 0 & 0.6 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0.4 & 0 & 0.6 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0.4 & 0 & 0.6 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0.4 & 0 & 0.6 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

Após 200 transições encontramos a seguinte matriz:

$$p^{200} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0.6531 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0.3469 \\ 0.4219 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0.5781 \\ 0.2677 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0.7323 \\ 0.1649 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0.8351 \\ 0.0964 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0.9036 \\ 0.0508 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0.9492 \\ 0.0203 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0.9797 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

Note que a primeira coluna desta matriz representa as probabilidades de, após 200 transições, "chegar" no estado 0 (ruína do jogador A), enquanto a última coluna indica a probabilidade da cadeia "parar" (após 200 transições) no estado absorvente 8 (ruína do jogador B). Também, como a fortuna total em jogo é 8, quanto maior a fortuna inicial do jogador A, menor a probabilidade de, após muitas transições, este jogador ser arruinado. Um raciocínio análogo se aplica ao jogador B.

A probabilidade de ruína do jogador A para os diversos estados iniciais é dada a seguir:

$$u(i) = \frac{\left(\frac{4}{6}\right)^i - \left[\left(\frac{4}{6}\right)^8\right]}{\left[1-\left(\frac{4}{6}\right)^8\right]_j}$$

I	u(i)
0	1
1	0.6531
2	0.4219
3	0.2677
4	0.1650
5	0.0964
6	0.0508
7	0.0203
8	0

Note que estas probabilidades de ruína do jogador A são exatamente aquelas que aparecem na primeira coluna da matriz P^{200} calculada anteriormente.

Nota:

Apesar de toda a ênfase em jogos, o passeio aleatório é muito útil para modelar processos físicos, como o movimento de partículas. Se uma partícula está sujeita a colisões e a impulsos aleatórios, sua posição também se altera aleatoriamente. Se a posição futura da partícula depende apenas da posição atual, o processo que descreve a posição da partícula é Markoviano, e uma aproximação discreta do movimento contínuo da partícula é dada por um passeio aleatório.

Definição 3.4.6. Tempo de Alcance ou "Hitting Time"
Seja T uma variável aleatória que representa o tempo que o processo estocástico leva até alcançar pela primeira vez um dos estados absorventes ou N. Isto é: $T = \min\{n \geq 0: X_n = 0 \text{ ou } X_n = N\}$.

T é chamado de **tempo de alcance** de um estado absorvente.
Em termos desta variável T, a ruína do jogador A pode ser expressa como o evento $X_T = 0$. A probabilidade deste evento, dado que o estado inicial é i, é dada por:

$u_i = \Pr\{X_T = 0 \mid X_0 = i\}$ = probabilidade de ruína do jogador A quando a sua fortuna inicial é i.

O tempo médio até uma absorção é o valor esperado do tempo de alcance T. Analogamente ao que fizemos para derivar a probabilidade de ruína do jogador, podemos obter uma expressão geral para o tempo médio até uma absorção.

Note que o tempo médio até uma absorção depende, a princípio, do estado inicial, e é denotado por: $v_i = E\{T \mid X_0 = i\}$.

Suponha que desejamos encontrar v_i, o tempo médio até uma absorção. Analogamente ao que fizemos para deduzir a probabilidade de ruína do jogador, podemos dizer que o tempo T consiste num primeiro passo mais os passos adicionais.

Mas, com probabilidade p, o primeiro passo consiste na transição do estado i para o estado i + 1 e, na média, faltam v_{i+1} passos adicionais até cair num estado absorvente.

Com probabilidade q = 1- p, o primeiro passo leva a cadeia do estado i para o estado i -1 e na média são necessários v_{i-1} passos adicionais até a absorção. Logo:

$$v_i = E\{T \mid X_0 = i\} = 1 + p.v_{i+1} + q.v_{i-1} \text{ para } i = 1,2\ldots, N-1 \qquad (3.4.3)$$

As condições iniciais são óbvias: se o estado inicial é um estado absorvente (0 ou N) a absorção é imediata, e então $v_0 = v_N = 0$.
Vamos resolver a equação (3.4.3) quando p = q =1/2 e indicar a resposta no caso geral. A solução geral de (3.4.3) não é muito fácil de encontrar, por causa da presença do termo "1", que torna a equação não homogênea.

No caso particular p = q = 1/2, a expressão (3.4.3) torna-se:

$v_i = 1 + (1/2)v_{i+1} + (1/2)v_{i-1}$

Defina a diferença $x_i = v_i - v_{i-1}$ para i = 1, 2..., N e então:

$$v_1 = 1 + \frac{1}{2}v_2 + \frac{1}{2}v_0 \Rightarrow -1 = \frac{1}{2}(v_2 - v_1) - \frac{1}{2}(v_1 - v_0) \Rightarrow -1 = \frac{1}{2}(x_2 - x_1)$$

Analogamente:

$$-1 = \frac{1}{2}(x_3 - x_2)$$

...

$$-1 = \frac{1}{2}(x_N - x_{N-1})$$

Somando-se termo a termo para i = 1,2..., N -1 leva a:

$$-1 = \frac{1}{2}(x_2 - x_1)$$

$$-2 = \frac{1}{2}(x_3 - x_1)$$

$$-3 = \frac{1}{2}(x_4 - x_1)$$

...

$$-(N-1) = \frac{1}{2}(x_N - x_1)$$

Em geral: $x_i = x_1 - 2.(i-1)$ onde i = 2, 3..., N

Isto é, acabamos de encontrar uma expressão recursiva para as diferenças x_i. O próximo passo é reescrever esta expressão em termos das variáveis que realmente nos interessam, os v_i's. Por substituição acima:

$x_1 = v_1 - v_0 = v_1$, pois $v_0 = 0$.
$x_2 = v_2 - v_1 \Rightarrow v_2 = x_1 + x_2$
$x_3 = v_3 - v_2 \Rightarrow v_3 = x_1 + x_2 + x_3$
...
$v_i = x_1 + x_2 + x_3 + \ldots + x_i$ e substituindo a expressão para os x_i's leva a:

$$v_i = \sum_{j=1}^{i} x_j = \sum_{j=1}^{i}[x_1 - 2(j-1)] = i.x_1 - 2\sum_{j=1}^{i}(j-1) = i.x_1 - 2\left\{\sum_{j=1}^{i} j - (i)\right\} =$$

$$i.x_1 + 2i - 2\left\{\frac{i\,(i+1)}{2}\right\} = i.x_1 + 2i - i(i+1) = i.x_1 - i(i-1)$$

E como $x_1 = v_1$ segue que:

$$v_i = i.x_1 + 2i - i(i+1) = i.v_1 - i(i-1) \quad \text{para } i = 2,3,\ldots,N$$

Também por hipótese $v_N = 0$ e então:

$0 = N.v_1 - N(N-1) \Rightarrow v_1 = N - 1$

Logo, em geral, **o tempo médio de absorção partindo do estado inicial i** e quando **p = q = 1/2** é:

$$v_i = E\{T \mid X_0 = i\} = i.(N-1) - i(i-1) = i(N-i) \text{ para } i = 0, 1, 2..., N$$

Note que, se p = q = 1/2, a duração média do jogo é maior quando a fortuna inicial do jogador A está próxima de N/2, pois assim a chance de qualquer um dos jogadores ser arruinado é pequena.

No caso geral, $p \neq q$ e a solução da equação (3.4.3) é:

$$v_i = E\{T \mid X_0 = i\} = \frac{1}{q-p}\left\{ i - N\left[\frac{1-(q/p)^i}{1-(q/p)^N}\right]\right\} \quad \text{para } i = 0,1,2,...,N$$

v_i representa a duração média do jogo supondo que a fortuna inicial do jogador A é i e a fortuna total é N.

Exemplo 3.4.7.
Considere a situação do exemplo 3.4.5.
As probabilidades de ruína do jogador para diversas fortunas iniciais já foram calculadas. A duração média do jogo, como função da fortuna inicial do jogador A é dada por:

$$v_i = E\{T \mid X_0 = i\} = \frac{1}{q-p}\left\{ i - N\left[\frac{1-(q/p)^i}{1-(q/p)^N}\right]\right\} = \frac{1}{0.4-0.6}\left\{ i - 8\left[\frac{1-(4/6)^i}{1-(4/6)^8}\right]\right\}$$

O gráfico de v_i versus i (fortuna inicial do jogador A) é mostrado a seguir. Note que, como intuitivamente razoável, a duração média do jogo é maior quando as fortunas dos 2 jogadores são semelhantes, isto é, quando a fortuna do jogador A está próxima de N/2 = 4.

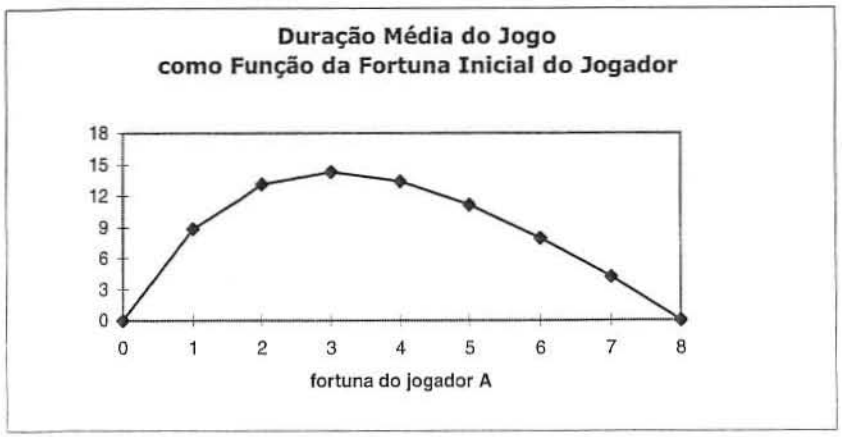

Exemplo 3.4.8.
Considere um passeio aleatório com estados absorventes 0 e 10. Seja i a fortuna inicial do primeiro jogador, e N - i = 10 - i a fortuna inicial do outro jôgador. Suponha que, a cada jogada, a probabilidade do jogador A ganhar é p, e a probabilidade dele perder é q = 1-p, ambas mantidas fixas em todas as jogadas. Os estados 0 e N(= 10) são absorventes, pois representam as ruínas dos dois jogadores. Então podemos resumir os resultados dos exemplos anteriores como:

- Probabilidade de ruína do jogador A quando a sua fortuna inicial é i

$$u_i = \begin{cases} \dfrac{10-i}{10} & \text{se } p = q = 1/2 \\ \dfrac{(q/p)^i - (q/p)^{10}}{1-(q/p)^{10}} & \text{se } p \neq q \end{cases}$$

As probabilidades de ruína do jogador para p = 0.2, 0.4 e 0.8 são mostradas no próximo gráfico.

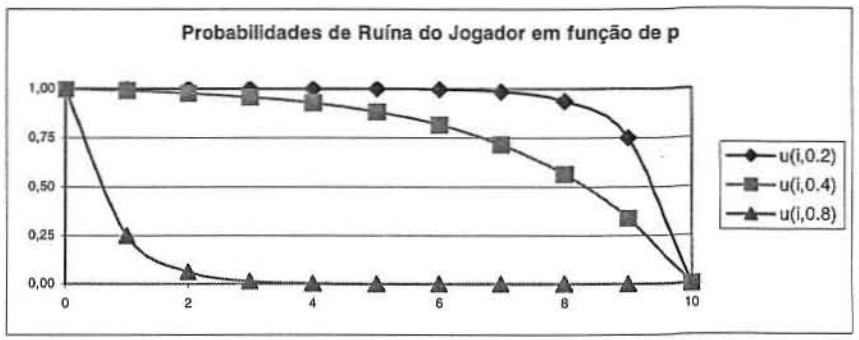

Note que, para uma fortuna inicial fixa i, a probabilidade de ruína do jogador A aumenta quando p diminui, ou seja, quando a probabilidade de ganho em qualquer jogada é pequena.

Para evitar ou adiar a sua ruína, o jogador A tem apenas duas alternativas possíveis: aumentar a sua probabilidade de ganhar cada jogada ou aumentar a sua fortuna inicial i.

- Duração média do jogo quando a fortuna inicial do jogador A é i

$$v_i = \begin{cases} i(10-i) & \text{se } p = q = 1/2 \\ \dfrac{1}{q-p}\left\{ i - 10\left[\dfrac{1-(q/p)^i}{1-(q/p)^{10}}\right]\right\} & \text{se } p \neq q \end{cases}$$

O próximo gráfico apresenta o tempo médio até a absorção (duração média do jogo) como função da fortuna inicial i e da probabilidade do jogador A ganhar qualquer jogada (p).

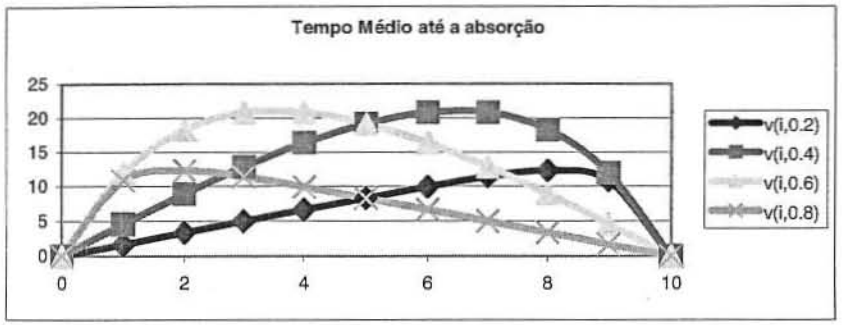

Pode-se provar que, quando $N \to \infty$ (o jogador A tem um adversário infinitamente rico) a duração média do jogo é:

$$v_i = \begin{cases} \dfrac{i}{q-p} & \text{se } p < q \\ \infty & \text{se } p \geq q \end{cases}$$

Até agora estudamos o passeio aleatório sob a perspectiva do jogador A. É claro que podemos estudar o passeio aleatório $Y_n = N - X_n$ que representa a fortuna do jogador B. A fortuna inicial de B é $Y_0 = N - i$ e se o jogador A é absorvido em N (ganha o jogo) então o jogador B é absorvido em zero (perde o jogo) e vice versa.

Seja w_j a probabilidade de ruína do jogador B quando sua fortuna inicial é j. Pode-se provar que:

$$w_j = \begin{cases} \dfrac{j}{N} & \text{se } p = q = 1/2 \\ \dfrac{(p/q)^{N-j} - (p/q)^N}{1-(p/q)^N} = \dfrac{1-(q/p)^j}{1-(q/p)^N} & \text{se } p \neq q \end{cases}$$

Note que, pelas definições de $u_i = Pr\{X_T = 0 \mid X_0 = i\}$ e $w_j = Pr\{N - X_T = 0 \mid N - X_0 = j\} = Pr\{X_T = N \mid X_0 = N-j\} = 1 - Pr\{X_T = 0 \mid X_0 = N-j\} = 1 - u_{N-j}$.

> Assim, as probabilidades de ruína dos jogadores A e B estão relacionadas através da expressão:
>
> $w_j = 1 - u_{N-j} \Leftrightarrow u_{N-j} + w_j = 1$
>
> onde N-j e j são, respectivamente, as fortunas iniciais dos jogadores A e B.

Esta última expressão afirma que a absorção por algum dos estados absorventes (0 ou N) é uma coisa certa, que ocorre com probabilidade 1. Este fato não é óbvio, pois poderíamos imaginar que o jogo poderia durar para sempre, com o jogador A ganhando uma jogada, B ganhando a próxima e assim sucessivamente, alternando um ganho e uma perda. A equação anterior, que relaciona u e w, nos diz que, mais cedo ou mais tarde, o passeio aleatório será absorvido, isto é, um dos jogadores será arruinado.

Exemplo 3.4.9. Modelo de Ehrenfest
É um passeio aleatório com número finito de estados {-a, -a +1..., -1, 0, 1...,a} e com as seguintes probabilidades de transição:

$$P_{ij} = \begin{cases} \dfrac{a-i}{2a} & \text{se } j = i+1 \\ \dfrac{a+i}{2a} & \text{se } j = i-1 \\ 0 & \text{do contrário} \end{cases}$$

Como surge este modelo na prática?

Considere duas caixas contendo, no total, 2a bolas. Na primeira caixa existem i bolas, e na segunda existem 2a - i bolas. Uma bola é selecionada aleatoriamente (isto é, todas as bolas têm probabilidades iguais) dentre as 2a bolas. Esta bola é então colocada na outra caixa.

Seja Y_n o número de bolas na primeira caixa após a n-ésima transição. Seja $X_n = Y_n - a$. Então X_n é uma cadeia de Markov com matriz de transição P dada acima. Cada seleção de uma bola gera uma transição do processo.

A ruína do jogador e a duração média do jogo num contexto mais geral
Considere um passeio aleatório no qual os estados 0 e N são absorventes e a matriz de transição é dada por:

$$P = \begin{bmatrix} 1 & 0 & 0 & 0 & \ldots.0 \\ q_1 & r_1 & p_1 & 0 & \ldots.0 \\ 0 & q_2 & r_2 & p_2 & \ldots.0 \\ & & & & \ldots. \\ 0 & 0 & 0 & 0 & \ldots.1 \end{bmatrix} \qquad (3.4.4.)$$

Suponha que as probabilidades q_i e p_i são estritamente maiores que zero para todos os estados transientes i = 1,2..., N-1.

Seja T o **tempo de alcance** até um estado absorvente, isto é, $T = \text{mín}\{n \geq 0: X_n = 0 \text{ ou } X_n = N\}$.

Exemplo 3.4.10.
Calcule, para a matriz de transição (3.4.4.) acima, a probabilidade de ruína do jogador A.

Solução
O mesmo resultado já foi obtido no caso particular q_i = constante para todo i = 1, 2..., N -1.

Exemplo 3.4.12.
Considere a matriz de transição do exemplo 3.4.11. e calcule W_{ik} para os estados transientes k =1, 2.

$W_{0k} = W_{3k} = 0$, pois os estados 0 e 3 são absorventes.

Da expressão (3.4.8.) acima temos:

$W_{12} = 0 + q_1.W_{02} + r_1.W_{12} + p_1.W_{22} \Rightarrow W_{12} = 0.6\ W_{22}$
$W_{22} = 1 + q_2.W_{12} + r_2.W_{22} + p_2.W_{32} \Rightarrow W_{22} = 1 + 0.2\ W_{12} + 0 + 0.8(0)$
$\Rightarrow W_{22} = 1 + 0.2\ W_{12} = 1 + 0.2\{0.6\ W_{22}\} \Rightarrow (1 - 12/100)W_{22} = 1$
$W_{22} = 100/88 = 50/44 = 25/22 = 1.1364$
$W_{12} = 0.6W_{22} = 60/88 = 0.6818$

Analogamente:

$W_{11} = 1 + q_1.W_{01} + r_1.W_{11} + p_1.W_{21}$
$\Rightarrow W_{11} = 1 + 0.4W_{01} + 0W_{11} + 0.6W_{21} \Rightarrow W_{11} = 1 + 0.6W_{21}$
$W_{21} = 0 + q_2.W_{11} + r_2.W_{21} + p_2.W_{31}$
$\Rightarrow W_{21} = 0.2W_{11} + 0.W_{21} + 0.8W_{31}$
$\Rightarrow W_{21} = 0.2W_{11} + 0.W_{21} + 0.8(0) \Rightarrow W_{21} = 0.2W_{11}$
$W_{21} = 0.2W_{11} = 0.2\{1 + 0.6W_{21}\} \Rightarrow (1 - 12/100)\ W_{21} = 2/10$
$W_{21} = 20/88 = 10/44 = 0.2273$
$W_{11} = 1 + 0.6W_{21} = 100/88 = 1.1364$

Exemplo 3.4.13.
Considere uma cadeia de Markov com estados 0, 1, 2... N e matriz de transição:

$$P = \begin{bmatrix} 1 & 0 & 0 & 0 & \ldots 0 \\ q & 0 & p & 0 & \ldots 0 \\ 0 & q & 0 & p & \ldots 0 \\ & & & & \ldots \\ 0 & 0 & 0 & 0 & \ldots 1 \end{bmatrix}$$

Seja $\theta = q/p$.

O número médio de visitas ao estado transiente k partindo do estado inicial i é dado por W_{ik} já definido, e que pode ser calculado pela expressão (3.4.9). O cálculo de W_{ik} deve ser feito considerando os casos $\theta = 1$ e $\theta \neq 1$ separadamente.

- Se $\theta = 1$ então $p = q = ½$ e

$\rho_j = \theta^j = 1$
$1 + \ldots + \rho_{i-1} = i$
$\rho_k + \rho_{k+1} + \ldots + \rho_{N-1} = N - k$

E a expressão (3.4.9.) torna-se:

$$W_{ik} = \begin{cases} \dfrac{i(N-k)}{Nq} & \text{se } 0 < i \leq k < N \\ \dfrac{1}{q}\left(\dfrac{i(N-k)}{N} - (i-k)\right) = \dfrac{k(N-i)}{Nq} & \text{se } 0 < k < i < N \end{cases}$$

- Se $\theta \neq 1$ então $p \neq q$ e então:

$\rho_j = \theta^j$
$1 + \rho_1 + \rho_2 + \ldots + \rho_{i-1} = 1 + \theta + \theta^2 + \ldots + \theta^{i-1} = (1-\theta^i)/(1-\theta)$
$\rho_k + \rho_{k+1} + \ldots + \rho_{N-1} = (\theta^k - \theta^N)/(1-\theta)$ e
$q.\rho_{k-1} = q.(q/p)^{k-1} = p.(q/p)^k = p\theta^k$ e assim:

$$W_{ik} = \begin{cases} \dfrac{1}{p\theta^k}\left\{\left(\dfrac{1-\theta^i}{1-\theta^N}\right)\left(\dfrac{\theta^k - \theta^N}{1-\theta}\right) - \dfrac{(\theta^k - \theta^i)}{1-\theta}\right\} & \text{se } 0 < k < i < N \\ \dfrac{1}{p\theta^k}\left(\dfrac{1-\theta^i}{1-\theta^N}\right)\left(\dfrac{\theta^k - \theta^N}{1-\theta}\right) & \text{se } 0 < i \leq k < N \end{cases}$$

Exemplo 3.4.14.
Considere a situação do exemplo 3.4.5. A matriz de transição é:

$$P = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0.4 & 0 & 0.6 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0.4 & 0 & 0.6 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0.4 & 0 & 0.6 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0.4 & 0 & 0.6 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0.4 & 0 & 0.6 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0.4 & 0 & 0.6 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0.4 & 0 & 0.6 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

$\theta = q/p = 4/6 = 2/3$, N = 8 e o número médio de visitas ao estado k partindo do estado i é dado por W_{ik} mostrado abaixo:

k	W_{1k}	W_{2k}	W_{3k}	W_{4k}	W_{5k}	W_{6k}	W_{7k}
1	1.63	1.05	0.67	0.41	0.24	0.13	0.06
2	1.58	2.64	1.67	1.03	0.60	0.32	0.13
3	1.51	2.51	3.18	1.96	1.15	0.60	0.24
4	1.39	2.32	2.94	3.35	1.96	1.03	0.41
5	1.22	2.03	2.58	2.94	3.18	1.67	0.67
6	0.96	1.61	2.03	2.32	2.51	2.64	1.05
7	0.58	0.96	1.22	1.39	1.51	1.58	1.63

Os gráficos para W_{ik} em termos de k são mostrados a seguir.

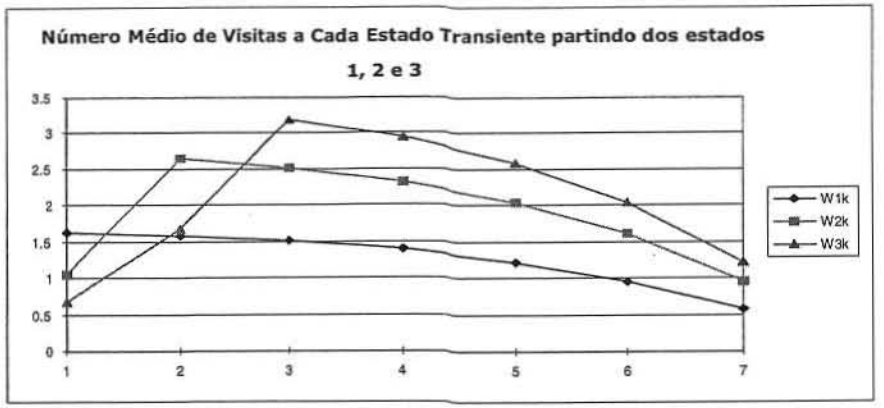

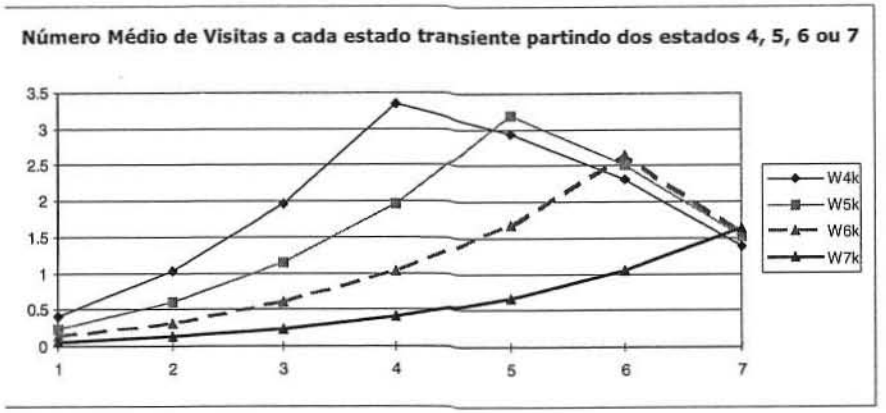

3.5. O Comportamento Limite de Cadeias de Markov

Nas seções anteriores olhamos com bastante atenção para o passeio aleatório, que é um caso particular de uma Cadeia de Markov. Calculamos quantidades como a probabilidade de ruína do jogador e a duração média do jogo, e verificamos que a probabilidade de ruína do jogador estava relacionada com o limite das potências da matriz de transição.

Aqui estudamos uma situação mais geral, em que procuramos estabelecer as condições necessárias para a existência do limite de P^n quando n tende a infinito.

Definição 3.5.1. Matriz de Transição Regular
Considere uma cadeia de Markov com um número finito de estados 0, 1,2..., N e seja P a sua matriz de transição. P é dita **regular** se P^k tem todos os seus elementos estritamente positivos para algum expoente k. Também, uma cadeia de Markov é regular se sua matriz de transição é regular.

Cadeias de Markov regulares são importantes porque apresentam uma distribuição de probabilidade limite, dada por:
$\pi = (\pi_0, \pi_1, \pi_2..., \pi_N)$ onde $\pi_j > 0$ para j = 0,1,2...N e $\Sigma\pi_j = 1$.

Além disso, a distribuição limite π é independente dos estados iniciais.

Mas, nem toda matriz de transição é regular, como veremos nos exemplos a seguir.

Teorema 3.5.2.
Seja P uma matriz de transição regular. Então:

$$\lim P_{ij}^{(n)} = \pi_j > 0 \quad \text{para } j = 0,1,2...,N$$

Onde o limite anterior é o limite quando n, o número de transições, tende a infinito. Escrevendo esta última expressão explicitamente em termos das probabilidades de transição de n estágios temos:

$$\lim \Pr[X_n = j | X_0 = i] = \pi_j > 0 \quad j = 0,1,2,...,N$$

Em outras palavras, para uma cadeia de Markov regular, quando n (o número de transições) é "grande", a probabilidade da cadeia estar no estado j é aproximadamente π_j, não importando o estado inicial.

Exemplo 3.5.3.
Considere uma cadeia com 2 estados (0 e 1) e matriz de transição dada por:

$P = \begin{bmatrix} 1-a & a \\ b & 1-b \end{bmatrix}$. P é regular se $0 < a,b < 1$ e, neste caso o limite da matriz P^n é: $\lim P^n = \frac{1}{a+b}\begin{bmatrix} b & a \\ b & a \end{bmatrix}$. Logo, a distribuição limite da cadeia é:

$\pi = (\pi_0, \pi_1) = \left(\frac{b}{a+b}, \frac{a}{a+b}\right)$.

Exemplo 3.5.4.

Seja $P = \begin{pmatrix} 0.33 & 0.67 \\ 0.75 & 0.25 \end{pmatrix}$. Na notação do exemplo anterior temos que a = 0.67 e b = 0.75 e concluímos que a distribuição limite é:

$$\pi = (\pi_0, \pi_1) = \frac{1}{1.42}\begin{pmatrix}0.75 & 0.67\\ 0.75 & 0.67\end{pmatrix} = \begin{pmatrix}0.5282 & 0.4718\\ 0.5282 & 0.4718\end{pmatrix}.$$

Isto pode ver verificado empiricamente (faça-o!!!!) através de potências crescentes de P.

Exemplo 3.5.5.
Considere uma modelo de mobilidade social, onde X_n representa a classe da n-ésima geração, e $X_n = 0, 1, 2$ se o indivíduo pertence, respectivamente, às classes baixa, média e alta. A matriz de transição P é uma matriz quadrada de dimensão 3 que relaciona as classes do pai e do filho. Suponha que P tenha a seguinte estrutura:

$$P = \begin{pmatrix}P_{00} & P_{01} & P_{02}\\ P_{10} & P_{11} & P_{12}\\ P_{20} & P_{21} & P_{22}\end{pmatrix} = \begin{pmatrix}0.40 & 0.50 & 0.10\\ 0.05 & 0.70 & 0.25\\ 0.05 & 0.50 & 0.45\end{pmatrix}$$

Qual é, aproximadamente, a proporção de pessoas na classe média, no limite quando n tende a infinito? Empiricamente isto pode ser visto tomando-se potências grandes de P. Por exemplo:

$P^{100} = \begin{pmatrix}0.0769 & 0.6250 & 0.2981\\ 0.0769 & 0.6250 & 0.2981\\ 0.0769 & 0.6250 & 0.2981\end{pmatrix}$. A segunda coluna desta matriz representa a probabilidade de uma pessoa pertencer à classe média, e é 62.5%.

Nota: Características de uma matriz de transição regular

Suponha que P é uma matriz de transição regular com N estados. Então:

1) P^{N^2} não tem elementos iguais a zero.

2) Se P^{N^2} não é estritamente positiva, então P não é regular.

3) Se P^k para algum $k > 1$ é estritamente positiva, então P^{k+n} para $n = 1,2,3...$ também tem apenas elementos estritamente positivos.

O próximo teorema é importante, pois caracteriza uma matriz regular.

Teorema 3.5.6.
Seja P uma matriz de transição nos estados 0,1,2..., N. Se P satisfaz as duas condições a seguir, P é uma matriz regular.

1) Para quaisquer 2 estados i e j existe um caminho $k_1, k_2..., k_r$ para o qual: $P_{ik1}.P_{k1,k2}...P_{kr,j} > 0$.

2) Existe pelo menos um estado i para o qual $P_{ii} > 0$.

Já que o teorema 3.5.6. nos permite identificar o que é uma matriz regular, como podemos encontrar a distribuição limite?

Teorema 3.5.7.
Seja P uma matriz de transição regular nos estados 0,1,2...,N. Então a **distribuição limite** $\pi = (\pi_0, \pi_1, \pi_2..., \pi_N)$ é a solução única e não negativa das equações:

$$\pi_j = \sum_{k=0}^{N} \pi_k.P_{kj} \quad \text{e} \quad \sum_{k=0}^{N} \pi_k = 1 \quad j = 0, 1, 2,..., N$$

Em termos matriciais, a distribuição limite π é o vetor linha de dimensão N+1 tal que $\pi = \pi.P$ onde P é a matriz de transição (de dimensão N+1 por N+1).

Exemplo 3.5.8.
Considere a matriz de transição do exemplo 3.5.5.. Calcule a distribuição limite e verifique que é a distribuição encontrada antes de maneira empírica.

$$P = \begin{pmatrix}P_{00} & P_{01} & P_{02}\\ P_{10} & P_{11} & P_{12}\\ P_{20} & P_{21} & P_{22}\end{pmatrix} = \begin{pmatrix}0.40 & 0.50 & 0.10\\ 0.05 & 0.70 & 0.25\\ 0.05 & 0.50 & 0.45\end{pmatrix}$$

Note que, pelo teorema 3.5.6., P é uma matriz de transição regular, e, portanto, a distribuição limite existe e é dada por $\pi = (\pi_0, \pi_1, \pi_2)$ onde $\pi_0 + \pi_1 + \pi_2 = 1$ e os π_j's devem satisfazer:

$$(\pi_0, \pi_1, \pi_2) = (\pi_0, \pi_1, \pi_2)\begin{pmatrix}0.40 & 0.50 & 0.10\\ 0.05 & 0.70 & 0.25\\ 0.05 & 0.50 & 0.45\end{pmatrix}$$

Ou, em notação matricial: $\pi = \pi.P \Rightarrow \pi.I - \pi.P = 0 \Rightarrow \pi.(I - P) = 0$, onde π é um vetor linha de dimensão N +1, I é a matriz identidade N+1 e P é uma matriz com a mesma dimensão que I e 0 é um vetor linha de zeros de dimensão N+1.

Seja V = I - P. Então, neste caso: $V = \begin{bmatrix}0.60 & -0.50 & -0.10\\ -0.05 & 0.30 & -0.25\\ -0.05 & -0.50 & 0.55\end{bmatrix}$. A distribuição limite é solução do sistema $\pi.V = 0$ sujeito à restrição $\pi_0 + \pi_1 + \pi_2 = 1$.

Uma das equações do sistema $\pi.V = 0$ é desnecessária, e podemos substituí-la por $\pi_0 + \pi_1 + \pi_2 = 1$.

Especificamente, devemos resolver:

$\pi_0 + \pi_1 + \pi_2 = 1$ (1)
$0.6\pi_0 = 0.05\pi_1 + 0.05\pi_2$ (2)
$0.3\,\pi_1 = 0.50\pi_0 + 0.50\pi_2$ (3)
$0.55\pi_2 = 0.10\pi_0 + 0.15\pi_2$ (4)

Suponha que eliminamos (4). De (2) temos:
$\pi_0 = (1/12)\{\pi_1 + \pi_2\}$ (5)

Substituindo (1) em (5) leva a:
$12\pi_0 = \pi_1 + 1 - \pi_0 - \pi_1 \Rightarrow 13\pi_0 = 1 \Rightarrow \pi_0 = 1/13 = 0.0769$ (6)

A substituição de (1) e (6) em (3) leva a:
$0.3\ \pi_1 = 0.50\{\pi_0 + \pi_2\} = 0.50\{(1/13) + 1 - (1/13) - \pi_1\}$
$(3/5)\ \pi_1 = 1 - \pi_1 \Rightarrow \pi_1 = 5/8 = 0.6250$ (7)

Jogando (6) e (7) em (1) leva a:
$\pi_2 = 31/104 = 0.2981$

Logo, a distribuição limite é: $\pi = (\pi_0, \pi_1, \pi_2) = (0.0769, 0.6250, 0.2981)$. Compare este números com os elementos de P^{100} no exemplo 3.5.5.!

Definição 3.5.9.
Uma matriz de transição é dita **duplamente estocástica** se suas colunas somam a um (além das suas linhas, que também somam a um porque estamos tratando de uma matriz de transição!).

Isto é, P é duplamente estocástica se:

$$\sum_{k=0}^{N} P_{ik} = \sum_{k=0}^{N} P_{kj} = 1 \quad \forall i, j$$

Teorema 3.5.10.
Seja P uma matriz de transição duplamente estocástica com estados 0, 1,2..., N. Então P é uma matriz regular e a distribuição de probabilidade limite é Uniforme discreta nos estados 0,1...,N, isto é: $\pi = (1/(N+1), 1/(N+1)..., 1/(N+1))$.

Exemplo 3.5.11.
Seja Y_n a soma do resultado de n jogadas de um dado. Suponha que desejamos determinar a probabilidade, quando n tende a infinito, de Y_n ser um múltiplo de 7. Note que trabalhar com Y_n definido desta forma não é conveniente, pois os estados possíveis dependem de n. Por exemplo, se $n = 2$ (jogamos o dado 2 vezes), os estados possíveis são $Y_2 = \{2, 3...,12\}$. Entretanto, se jogarmos o dado 10 vezes, $Y_{10} = \{10, 11, 12..., 60\}$.

Para evitar este problema, e lembrando que estamos interessados na probabilidade (quando n tende a infinito) de Y_n ser um múltiplo de 7, podemos dividir Y_n por 7 e olhar para o resto desta divisão.

Seja X_n o resto da divisão de Y_n por 7. X_n é uma cadeia de Markov com estados possíveis 0,1,2...6, cuja matriz de transição é dada por:

$$P = \begin{bmatrix} 0 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \\ 1/6 & 0 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \\ 1/6 & 1/6 & 0 & 1/6 & 1/6 & 1/6 & 1/6 \\ 1/6 & 1/6 & 1/6 & 0 & 1/6 & 1/6 & 1/6 \\ 1/6 & 1/6 & 1/6 & 1/6 & 0 & 1/6 & 1/6 \\ 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 0 & 1/6 \\ 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 0 \end{bmatrix}$$

Por exemplo, considere a soma de 2 dados. Então $Y_2 = \{2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12\}$ e os valores de X_2 correspondentes são $\{2, 3, 4, 5, 6, 0, 1, 2, 3, 4, 5\}$.

Considere a transição para X_3. Observou-se o resultado da jogada de mais um dado (agora são 3 dados!) e os resultados possíveis para Y_3 são {3,4,5..., 16, 17, 18}. Verifique que os X_3 também estão entre 0 e 6!

Por que a diagonal principal de P só contém zeros? Note que um elemento da diagonal principal representa a probabilidade de fazer uma transição para o mesmo estado. Suponha que $X_n = 2$. Logo, o resto da divisão de Y_n por 7 foi 2. Jogamos o dado mais uma vez e obtemos Y_{n+1}. Qual a relação entre eles? $Y_{n+1} = Y_n + r$ onde r é um dos números 1,2,3, 4, 5 ou 6 (pois r é o resultado da jogada de um dado). Qual o efeito sobre o resto da divisão por 7? Vai mudar, pois é impossível continuar sendo o mesmo valor ($X_n = 2$) já que não há possibilidade de somarmos 7 ao valor atual de Y_n (pois os valores possíveis da face do dado variam entre 1 e 6!!!).

E os elementos fora da diagonal? Pelo que já foi exposto, e supondo que o dado é honesto, a probabilidade de, a partir do estado atual X_n, fazer uma transição para qualquer outro estado é 1/6, correspondendo às probabilidades de cada face do dado.

P é uma matriz regular. Note que P^2 só tem elementos positivos, e é dada por:

$$P^2 = \begin{bmatrix} 0.1667 & 0.1389 & 0.1389 & 0.1389 & 0.1389 & 0.1389 & 0.1389 \\ 0.1389 & 0.1667 & 0.1389 & 0.1389 & 0.1389 & 0.1389 & 0.1389 \\ 0.1389 & 0.1389 & 0.1667 & 0.1389 & 0.1389 & 0.1389 & 0.1389 \\ 0.1389 & 0.1389 & 0.1389 & 0.1667 & 0.1389 & 0.1389 & 0.1389 \\ 0.1389 & 0.1389 & 0.1389 & 0.1389 & 0.1667 & 0.1389 & 0.1389 \\ 0.1389 & 0.1389 & 0.1389 & 0.1389 & 0.1389 & 0.1667 & 0.1389 \\ 0.1389 & 0.1389 & 0.1389 & 0.1389 & 0.1389 & 0.1389 & 0.1667 \end{bmatrix}$$

Logo, pelo teorema 3.5.11., a distribuição de probabilidade limite é:

$\pi = [1/7, 1/7, 1/7, 1/7, 1/7, 1/7, 1/7] = [0.1429..., 0.1429]$

De fato, se olharmos para P^{100} (faça-o!!!) encontramos uma matriz com todas as linhas iguais, onde todos os elementos são 1/7. Então, a probabilidade de que Y_n seja múltiplo de 7 (ou seja, o resto da divisão é zero) é 1/7.

Exemplo 3.5.12. Uma Cadeia de Markov em Genética
Suponha que existe uma população grande de indivíduos e cada um deles tem um par específico de genes. Cada gene é classificado como do tipo A ou a. Os pares possíveis de genes são AA, aa e Aa com probabilidades p_0, q_0 e r_0 respectivamente, onde $p_0 + q_0 + r_0 = 1$. Sejam p, q e r as probabilidades de que os indivíduos da próxima geração tenham os pares de genes AA, aa e Aa respectivamente.

Considere os seguintes eventos:

B_1 = ambos os pais são AA;
B_2 = um dos pais é AA, o outro é Aa;
B_3 = ambos os pais são Aa;
B_4 = pelo menos um dos pais é aa.

As probabilidades dos eventos B_1 a B_4 são calculadas facilmente.

$Pr(B_1) = p_0.p_0 = p_0^2$
$Pr(B_2) = 2p_0.r_0$
$Pr(B_3) = r_0^2$
$Pr(B_4) = 2p_0.q_0 + 2q_0.r_0 + q_0^2 = q_0(2p_0 + 2r_0 + q_0) = q_0(2p_0 + 2r_0 + 2q_0 - q_0) = q_0(2 - q_0)$, pois $p_0 + q_0 + r_0 = 1$.

Seja p a probabilidade (já definida) de que o filho seja AA. Então, pela definição de probabilidade condicional temos:

$p = Pr\{\text{filho AA}\} = Pr\{\text{filho AA}|\ B_1\}Pr(B_1) + Pr\{\text{filho AA}\ |\ B_2\}Pr(B_2) + Pr\{\text{filho AA}\ |\ B_3\}Pr(B_3) + Pr\{\text{filho AA}\ |\ B_4\}Pr(B_4)$

Mas:

$Pr\{\text{filho AA}|\ B_1\} = 100\% = 1$
$Pr\{\text{filho AA}|\ B_2\} = 50\%$
$Pr\{\text{filho AA}|\ B_3\} = 25\%$
$Pr\{\text{filho AA}|\ B_4\} = 0$

Logo:

$p = Pr\{\text{filho AA}\} = Pr(B_1) + (0.50)Pr(B_2) + (0.25)Pr(B_3) + (0)Pr(B_4)$

$p = Pr\{\text{filho AA}\} = p_0^2 + (0.50)(2p_0.r_0) + (0.25)(r_0^2) + 0 = \left(p_0 + \frac{r_0}{2}\right)^2$

Analogamente:

$q = Pr\{\text{filho aa}\} = \left(q_0 + \frac{r_0}{2}\right)^2$ e $r = Pr\{\text{filho Aa}\} = 2\left(p_0 + \frac{r_0}{2}\right)\left(q_0 + \frac{r_0}{2}\right)$

Note que $p + q + r = 1$.

Usando o mesmo tipo de argumento, mas agora fazendo a transição da geração dos filhos para a dos netos encontramos:

$$p^* = Pr\{\text{neto AA}\} = \left(p + \frac{r}{2}\right)^2 = \left(\left[p_0 + \frac{r_0}{2}\right]^2 + \frac{1}{2}\left[2\left(p_0 + \frac{r_0}{2}\right)\left(q_0 + \frac{r_0}{2}\right)\right]\right)^2 =$$

$$\left(\left(p_0 + \frac{r_0}{2}\right)^2 + \left(p_0 + \frac{r_0}{2}\right)\left(q_0 + \frac{r_0}{2}\right)\right)^2 = \left\{\left(p_0 + \frac{r_0}{2}\right)\left[p_0 + \frac{r_0}{2} + q_0 + \frac{r_0}{2}\right]\right\}^2 =$$

$$= \left\{\left(p_0 + \frac{r_0}{2}\right)[p_0 + q_0 + r_0]\right\}^2 = \left(p_0 + \frac{r_0}{2}\right)^2 = p$$

Analogamente, as probabilidades das próximas gerações terem genes Aa e aa se mantêm estáveis após a primeira transição. Isto é, a proporção de genes AA, Aa e aa na população se mantém estável.

Exemplo 3.5.13. Incluindo a História Passada na Descrição dos Estados
Freqüentemente um fenômeno que não é um processo de Markov pode ser modelado como tal, desde que se inclua parte da história passada do processo na descrição dos estados.

Por exemplo, suponha que, num certo dia, as condições do tempo dependem das condições nos dois dias anteriores. Seja X_n o tempo num dia qualquer n, que depende do que aconteceu nos 2 dias anteriores. O tempo no instante n depende das condições de tempo nos dias n-1 e n-2. Considere a seguinte tabela:

X_n (amanhã)	dia n - 1 (hoje)	dia n - 2 (ontem)
0	S (sol)	S
1	C (chuva)	S
2	S	C
3	C	C

A matriz de transição para X_n pode ser encontrada enumerando-se todas as combinações de tempo possíveis em 3 dias, como abaixo:

ontem	hoje	amanhã	X_n	X_{n+1}
S	S	S	0	0
S	S	C	0	1
S	C	S	1	2
S	C	C	1	3
C	S	S	2	0
C	S	C	2	1
C	C	S	3	2
C	C	C	3	3

Assim, a matriz de transição deste processo é:

$$P = \begin{bmatrix} P_{00} & P_{01} & 0 & 0 \\ 0 & 0 & P_{12} & P_{13} \\ P_{20} & P_{21} & 0 & 0 \\ 0 & 0 & P_{32} & P_{33} \end{bmatrix}$$

Suponha que $P_{00} = 0.8$, $P_{12} = 0.4$, $P_{20} = 0.6$ e $P_{32} = 0.1$. Determine a distribuição limite $\pi = (\pi_0, \pi_1, \pi_2, \pi_3)$. A matriz de transição é, neste caso:

$$P = \begin{bmatrix} 0.8 & 0.2 & 0 & 0 \\ 0 & 0 & 0.4 & 0.6 \\ 0.6 & 0.4 & 0 & 0 \\ 0 & 0 & 0.1 & 0.9 \end{bmatrix}$$

A distribuição limite é solução de:

$\pi_0 + \pi_1 + \pi_2 + \pi_3 = 1$ (1)

$\pi_0 = 0.8\,\pi_0 + 0.6\pi_1 + 0\pi_2 + 0\pi_3 \Rightarrow 0.2\pi_0 = 0.6\pi_1$ (2)

$\pi_1 = 0.2\pi_0 + 0.4\pi_2$ (3)

$\pi_2 = 0.4\pi_1 + 0.1\pi_3$ (4)

$0.1\pi_3 = 0.6\pi_1$ (5)

Eliminando arbitrariamente (4) temos:

$$\begin{pmatrix} 1 & 1 & 1 & 1 \\ 0.2 & 0 & -0.6 & 0 \\ -0.2 & 1 & -0.4 & 0 \\ 0 & -0.6 & 0 & 0.1 \end{pmatrix} \begin{pmatrix} \pi_0 \\ \pi_1 \\ \pi_2 \\ \pi_3 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

Cuja solução é:
$\pi_0 = 3/11 = 0.2727$, $\pi_1 = \pi_2 = 1/11 = 0.0909$, $\pi_3 = 6/11 = 0.5455$

Qual será o limite da porcentagem de dias de sol? Este é o limite, quando n tende a infinito, da probabilidade de $X_n = S$, que é o mesmo que:
$\lim\{Pr(X_n = S, X_{n+1} = S) + Pr(X_n = S, X_{n+1} = C)\} = \pi_0 + \pi_1 = 4/11$

3.6. Classificação de Estados

Nem todas as cadeias de Markov são regulares. A seguir, exibimos algumas matrizes de transição bastante simples e observamos o seu comportamento quando o número de transições cresce indefinidamente. Veremos que, em alguns casos o limite de P^n não existe ou, se existe, depende do estado inicial, o que não ocorre com matrizes de transição regulares.

Nos exemplos a seguir, suponha que as cadeias de Markov têm, como estados possíveis, apenas 0 e 1.

Exemplo 3.6.1.

Seja $P = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$, a matriz identidade de dimensão 2. Logo, $P^n = P$ para todo n = 1,2... Assim, esta cadeia tem distribuição limite (igual ao próprio P), mas a distribuição limite depende do estado inicial, pois as linhas da matriz limite são diferentes.

Exemplo 3.6.2

Seja $P = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$. A cadeia oscila de maneira determinística entre os dois estados. Se n é ímpar, $P^n = P$ e se n é par, P^n é a matriz identidade. Logo, a cadeia representada por esta matriz de transição é **periódica**, e **não existe distribuição limite.**

Exemplo 3.6.3.

Seja $P = \begin{bmatrix} 1/2 & 1/2 \\ 0 & 1 \end{bmatrix}$. Então a n-ésima potência desta matriz é: $P^n = \begin{bmatrix} (1/2)^n & 1-(1/2)^n \\ 0 & 1 \end{bmatrix}$ e o limite quando n tende a infinito é $\begin{bmatrix} 0 & 1 \\ 0 & 1 \end{bmatrix}$. O estado zero é **transiente**, isto é: se o processo começa no estado 0 existe uma probabilidade positiva de que o processo nunca mais retorne a este estado.

As matrizes de transição dos exemplos 3.6.1 a 3.6.3. ilustram três tipos de comportamento distintos além daquele observado para matrizes regulares. Combinações mais elaboradas destes comportamentos são possíveis, mas é importante ter em mente os exemplos do início desta seção, que funcionam como "tijolos" na construção de exemplos mais complicados.

As próximas definições e teoremas tratam da questão: quando é possível passar de um estado a outro numa cadeia de Markov, e qual o efeito disto para o limite da matriz de transição.

Definição 3.6.4. Estado Acessível
O estado j é acessível a partir do estado i se $P_{ij}^{(n)} > 0$ para algum inteiro positivo n. Ou seja, o estado j é acessível a partir do estado i se existe uma probabilidade maior que zero de chegar ao estado j a partir do estado i após um número finito de transições.

Definição 3.6.5. Comunicação de Estados
Dois estados i e j se comunicam, e escrevemos $i \leftrightarrow j$ se j é acessível a partir de i e também i é acessível a partir de j.

Assim, se 2 estados i e j **não se comunicam** segue que:
i) $P_{ij}^{(n)} = 0$ para todo n inteiro > 0 ou
ii) $P_{ji}^{(n)} = 0$ para todo n inteiro > 0
ou ambas i) e ii) acima são verdadeiras.

Em outras palavras: i e j **não se comunicam** se não é possível chegar a um deles a partir do outro num número finito de transições.

O conceito de comunicação entre estados tem importantes conseqüências, como veremos posteriormente.

Teorema 3.6.6.
O conceito de *comunicação* entre estados é uma *relação de equivalência*, pois satisfaz:

1) Reflexividade
   $i \leftrightarrow i$
2) Simetria
   Se $i \leftrightarrow j$ então $j \leftrightarrow i$
3) Transitividade
   Se $i \leftrightarrow j$ e $j \leftrightarrow k$ então $i \leftrightarrow k$.

O fato da comunicação entre estados ser uma relação de equivalência é muito importante porque nos permite repartir o conjunto de estados de uma cadeia de Markov em classes de equivalência. E, dentro de uma classe de equivalência, qualquer elemento é representativo, isto é, basta olhar para um elemento da classe (neste caso, um estado) e obtemos todas as características da classe.

Definição 3.6.7. Cadeia de Markov Irredutível
Uma Cadeia de Markov é chamada **irredutível** se todos os seus estados estão na mesma classe de equivalência, ou seja, **todos os estados se comunicam.**

Exemplo 3.6.8.
Algumas matrizes de transição para cadeias irredutíveis são mostradas a seguir.

$$P_1 = \begin{bmatrix} 0.6 & 0.2 & 0.2 \\ 0.4 & 0.2 & 0.4 \\ 0.2 & 0.4 & 0.4 \end{bmatrix}, \quad P_2 = \begin{bmatrix} 0.8 & 0.2 & 0 \\ 0.4 & 0.2 & 0.4 \\ 0.2 & 0.4 & 0.4 \end{bmatrix},$$

$$P_3 = \begin{bmatrix} 1/3 & 1/3 & 1/3 \\ 1/3 & 1/3 & 1/3 \\ 1/3 & 1/3 & 1/3 \end{bmatrix}, \quad P_4 = \begin{bmatrix} 0.5 & 0.5 & 0 \\ 0.5 & 0.25 & 0.25 \\ 0 & 0.4 & 0.6 \end{bmatrix}$$

Note que, embora o elemento 02 da matriz P_2 seja zero, o mesmo elemento em P_2^2 é diferente de zero (verifique!), e então o estado 2 é acessível a partir do estado zero. Um comentário análogo se aplica à matriz P_4.

Exemplo 3.6.9.
Considere uma cadeia de Markov nos estados 1, 2, 3, 4 e 5 com a seguinte matriz de transição:

$$P = \begin{bmatrix} P_1 & 0 \\ 0 & P_2 \end{bmatrix} \text{ onde } P_1 = \begin{bmatrix} 1/2 & 1/2 \\ 1/4 & 3/4 \end{bmatrix} \text{ e } P_2 = \begin{bmatrix} 0 & 1 & 0 \\ 1/2 & 0 & 1/2 \\ 0 & 1 & 0 \end{bmatrix}, \text{ isto é, P é a matriz:}$$

$$\begin{bmatrix} 1/2 & 1/2 & 0 & 0 & 0 \\ 1/4 & 3/4 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 1/2 & 0 & 1/2 \\ 0 & 0 & 0 & 1 & 0 \end{bmatrix}$$

Aqui claramente existem 2 classes, a primeira formada pelos estados {1,2} e a outra formada por {3,4,5}. Se o estado inicial X_0 pertence à classe {1,2} a cadeia ficará para sempre dentro desta classe. Ao contrário, se o estado inicial estiver na classe {3,4,5}, o processo permanecerá sempre dentro desta classe, e a porção relevante da matriz de transição é P_2.

Exemplo 3.6.10.
Considere um passeio aleatório nos estados 0, 1, 2..., N.

$$P = \begin{bmatrix} 1 & 0 & 0 & 0 & \ldots 0 \\ q & 0 & p & 0 & \ldots 0 \\ 0 & q & 0 & p & \ldots 0 \\ & & & & \ldots \\ 0 & 0 & 0 & 0 & \ldots 1 \end{bmatrix}$$

onde P é uma matriz quadrada de dimensão N+1.
Existem nitidamente três classes: {0}, {N} e {1,2..., N-1}. A partir da classe {1,2..., N-1} podemos alcançar as duas outras (que representam as ruínas dos dois jogadores), mas partindo de {0} ou {N} não conseguimos alcançar a classe {1,2..., N-1}.

Definição 3.6.11. Período de um Estado
Define-se d(i), o período do estado i, como "o maior divisor comum de todos os inteiros $n \geq 1$ tais que $P_{ii}^{(n)} > 0$". Isto é, se o período de um estado i é d(i) então $P_{ii}^{(n)} = 0$ se n não for divisível por d(i).

Se $P_{ii}^{(n)} = 0$ para todo $n \geq 1$ então o período do estado i é zero. Se $P_{ii} > 0$ para algum estado i, este estado tem período zero e a cadeia poderá permanecer neste estado por qualquer instante de tempo.

Se um estado tem período d(i) > 1, um retorno a ele só é possível após d(i), 2.d(i), 3.d(i), 4.d(i), ... passos e assim $P_{ii}^{(n)} = 0$ para todo n que não é divisível por d(i).

Note que o cálculo do período de um estado envolve apenas os elementos da diagonal da matriz de transição e de suas potências, e então o período de um estado está ligado à probabilidade de retorno ao mesmo estado.

Exemplo 3.6.12.
Considere o passeio aleatório do exemplo 3.6.10.. Cada estado transiente tem período 2, e os estados absorventes têm período 1.

Exemplo 3.6.13.
Considere a cadeia com matriz de transição:

$$P = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 1/2 & 0 & 1/2 & 0 \end{bmatrix}$$

Qual o período do estado zero? Examinando as potências de P notamos que: $P_{00} = P_{00}^{(2)} = P_{00}^{(3)} = P_{00}^{(5)} = 0$, mas $P_{00}^{(4)} = ½$, $P_{00}^{(6)} = ¼$, $P_{00}^{(8)} = 0.375$.

O conjunto dos inteiros para os quais $P_{00}^{(n)} > 0$ é n ={4, 6, 8...}. Logo, o período do estado zero é 2, que é o maior divisor comum deste conjunto.

Exemplo 3.6.14.
Investigue o período de todos os estados para a cadeia de Markov cuja matriz de transição é:

$$P = \begin{bmatrix} 0 & 0 & 0.8 & 0.2 \\ 0 & 0 & 0.4 & 0.6 \\ 0.7 & 0.3 & 0 & 0 \\ 0.2 & 0.8 & 0 & 0 \end{bmatrix}$$

Solução

Note que $P^2 = \begin{bmatrix} 0.6 & 0.4 & 0 & 0 \\ 0.4 & 0.6 & 0 & 0 \\ 0 & 0 & 0.68 & 0.32 \\ 0 & 0 & 0.48 & 0.52 \end{bmatrix}$, $P^3 = \begin{bmatrix} 0 & 0 & 0.64 & 0.36 \\ 0 & 0 & 0.56 & 0.44 \\ 0.54 & 0.46 & 0 & 0 \\ 0.44 & 0.56 & 0 & 0 \end{bmatrix}$,

$$p^4 = \begin{bmatrix} 0.52 & 0.48 & 0 & 0 \\ 0.48 & 0.52 & 0 & 0 \\ 0 & 0 & 0.62 & 0.38 \\ 0 & 0 & 0.58 & 0.42 \end{bmatrix}.$$

A forma de P^n oscila dependendo do fato de n ser par ou ímpar.

Na verdade, as potências pares de P têm a forma:

$P^{2n} = \begin{bmatrix} P_1^{2n} & 0 \\ 0 & P_2^{2n} \end{bmatrix}$ e as potências ímpares são $P^{2n+1} = \begin{bmatrix} 0 & P_1^{2n+1} \\ P_2^{2n+1} & 0 \end{bmatrix}$

onde 0 representa uma matriz 2 x 2 de zeros e P_1^{2n}, P_2^{2n}, P_1^{2n+1}, P_2^{2n+1} são blocos de dimensão 2 x 2 com elementos não nulos. Daí, por exemplo: $P_{00}^{2n} \neq 0$, mas $P_{00}^{2n+1} = 0$. Note também que todos os estados pertencem à mesma classe, e assim a cadeia é irredutível, e todos os estados têm período 2.

Teorema 3.6.15. Propriedades do Período de um Estado
1) Se 2 estados i e j se comunicam, então eles têm o mesmo período, isto é: se $i \leftrightarrow j$ então d(i)=d(j).

2) Se o estado i tem período d(i) então existe um inteiro N (que depende de i) tal que, para todos os inteiros $n \geq N$ temos $P_{ii}^{n.d(i)} > 0$. Ou seja, um retorno ao estado i pode ocorrer em instantes que são múltiplos suficientemente grandes do período d(i). Por exemplo, se o período é 2, existe algum n inteiro suficientemente grande tal que $P_{ii}^{2n} > 0$. Logo, neste último exemplo, é possível que P_{ii}^{2}, P_{ii}^{4}. P_{ii}^{6} sejam zero, mas $P_{ii}^{8,}$ P_{ii}^{10}, P_{ii}^{12}, P_{ii}^{14} e as probabilidades para todas as potências pares daí em diante sejam estritamente maiores que zero.

3) Se $P_{ji}^{(m)} > 0$ então $P_{ji}^{(m + n.d(i))} > 0$ para todo n inteiro positivo suficientemente grande.

Definição 3.6.16. Cadeia Aperiódica
Uma cadeia de Markov em que cada estado tem período 1 é chamada de aperiódica.

Em termos "práticos", numa cadeia aperiódica pode-se retornar a um estado qualquer em qualquer instante, não é preciso esperar um número mínimo de vezes até que se possa fazer uma transição de um estado para ele mesmo. Ao contrário, se um estado tem período 2, o processo só consegue entrar neste estado em instantes que são múltiplos de 2.

Definição 3.6.17.
Seja i um estado arbitrário fixo. Defina, para todo inteiro $n \geq 1$ a seguinte probabilidade:

$f_{ii}^{(n)} = Pr\{X_n = i, X_v \neq i \text{ para } v = 1,2...,n-1 | X_0 = i\}$

$f_{ii}^{(n)}$ é a probabilidade de que, começando no estado i, **o primeiro retorno** a este estado ocorre na n-ésima transição.

Note que, para qualquer estado i: $f_{ii}^{(1)} = P_{ii}$.

$f_{ii}^{(n)}$ pode ser calculado recursivamente através da seguinte expressão:

$$P_{ii}^{(n)} = \sum_{k=0}^{n} f_{ii}^{(k)} . P_{ii}^{(n-k)} \quad \text{onde } n \geq 1 \text{ e definimos } f_{ii}^{(0)} = 0 \text{ para qualquer i}$$

Esta última equação é obtida considerando-se o tempo decorrido até o primeiro retorno ao estado i.

Considere todas as realizações de uma cadeia de Markov na qual o estado inicial é i e a primeira volta ao estado i ocorre na k-ésima transição. Chame este evento de E_k. Os eventos E_1, E_2..., E_n são mutuamente exclusivos e a probabilidade do evento: {primeiro retorno ao estado i na k-ésima transição} é $f_{ii}^{(k)}$. Nas (n - k) transições restantes estamos interessados apenas naqueles em que $X_n = i$. Pela propriedade Markoviana:

$Pr\{E_k\} = Pr\{\text{primeiro retorno ao estado i na k-ésima transição} \mid X_0 = i\}$.
$.Pr\{X_n = i \mid X_k = i\} = f_{ii}^{(k)}.\ P_{ii}^{(n-k)}$ para $1 \le k \le n$.

Também $P_{ii}^{(0)} = 1$ e, por definição: $f_{ii}^{(0)} = 0$.

Logo:

$$P_{ii}^{(n)} = Pr\{X_n = i \mid X_0 = i\} = \sum_{k=1}^{n} Pr(E_k) = \sum_{k=1}^{n} f_{ii}^{(k)}.\ P_{ii}^{(n-k)} = \sum_{k=0}^{n} f_{ii}^{(k)}.\ P_{ii}^{(n-k)}$$

Se o processo começa no estado i, a probabilidade de que ele retorne a este estado num tempo finito é:

$$f_{ii} = \sum_{n=0}^{\infty} f_{ii}^{(n)} = \lim \sum_{n=0}^{N} f_{ii}^{(n)} \text{ onde o limite refere-se a } N \to \infty$$

f_{ii} é a probabilidade de retorno ao estado i num intervalo de tempo finito.

Exemplo 3.6.18.
Determine $f_{00}^{(n)}$ para n = 1,2..., 5 para a cadeia de Markov cuja matriz de transição é:

$$P = \begin{bmatrix} 0 & 0.5 & 0 & 0.5 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0.5 & 0 & 0 & 0.5 \end{bmatrix}$$

As 5 primeiras potências da matriz de transição são:

$$P^2 = \begin{bmatrix} 0.25 & 0 & 0.5 & 0.25 \\ 0 & 0 & 0 & 1 \\ 0.5 & 0 & 0 & 0.5 \\ 0.25 & 0.25 & 0 & 0.5 \end{bmatrix},\ P^3 = \begin{bmatrix} 1/8 & 1/8 & 0 & 3/4 \\ 1/2 & 0 & 0 & 1/2 \\ 1/4 & 1/4 & 0 & 1/2 \\ 1/4 & 1/8 & 1/4 & 3/8 \end{bmatrix}$$

$$P^4 = \begin{bmatrix} 3/8 & 1/16 & 1/8 & 7/16 \\ 1/4 & 1/4 & 0 & 1/2 \\ 1/4 & 1/8 & 1/4 & 3/8 \\ 3/16 & 1/8 & 1/8 & 9/16 \end{bmatrix},\ P^5 = \begin{bmatrix} 7/32 & 3/16 & 1/16 & 17/32 \\ 1/4 & 1/8 & 1/4 & 3/8 \\ 3/16 & 1/8 & 1/8 & 9/16 \\ 9/32 & 3/32 & 1/8 & 1/2 \end{bmatrix}$$

A rigor, não é necessário calcular toda a matriz P^n (n = 2, 3, 4, 5). Para resolver o problema proposto, devemos olhar apenas para o elemento 00 de cada matriz P^n acima. Especificamente, o que nos interessa é saber que:

$P_{00}^{(1)} = P_{00} = 0$, $P_{00}^{(2)} = 1/4$, $P_{00}^{(3)} = 1/8$, $P_{00}^{(4)} = 3/8$, $P_{00}^{(5)} = 7/32$.

Pela equação recursiva que relaciona $f_{ii}^{(n)}$ e $P_{ii}^{(n)}$ temos:

$$P_{ii}^{(n)} = \sum_{k=0}^{n} f_{ii}^{(k)}.P_{ii}^{(n-k)} \qquad \text{Logo: } 1 = P_{00}^{(0)}.$$

Também:

$P_{00}^{(1)} = P_{00} = 0 = f_{00}^{(0)} P_{00}^{(1)} + f_{00}^{(1)}.\ P_{00}^{(0)} \Rightarrow f_{00}^{(1)} = 0$ isto é, partindo do estado zero, a probabilidade de que o primeiro retorno a este mesmo estado ocorra em uma transição é zero, o que é óbvio, pois $P_{00} = 0$ (veja a matriz P).

$$P_{00}^{(2)} = f_{00}^{(0)} P_{00}^{(2)} + f_{00}^{(1)}.\ P_{00}^{(1)} + f_{00}^{(2)}.\ P_{00}^{(0)} \Rightarrow \frac{1}{4} = 0 + 0 + f_{00}^{(2)} \Rightarrow f_{00}^{(2)} = \frac{1}{4}$$

$$P_{00}^{(3)} = f_{00}^{(0)} P_{00}^{(3)} + f_{00}^{(1)}.\ P_{00}^{(2)} + f_{00}^{(2)}.\ P_{00}^{(1)} + f_{00}^{(3)}.\ P_{00}^{(0)} \Rightarrow \frac{1}{8} = 0 + 0 + 0 + f_{00}^{(3)} \Rightarrow f_{00}^{(3)} = \frac{1}{8}$$

$$P_{00}^{(4)} = f_{00}^{(0)} P_{00}^{(4)} + f_{00}^{(1)}.\ P_{00}^{(3)} + f_{00}^{(2)}.\ P_{00}^{(2)} + f_{00}^{(3)}.\ P_{00}^{(1)} + f_{00}^{(4)}.\ P_{00}^{(0)}$$

$$\Rightarrow \frac{3}{8} = 0 + 0 + f_{00}^{(2)}.\ P_{00}^{(2)} + f_{00}^{(4)}.\ P_{00}^{(0)} \Rightarrow \frac{3}{8} = \frac{1}{4}\left(\frac{1}{4}\right) + f_{00}^{(4)} \Rightarrow f_{00}^{(4)} = \frac{5}{16}$$

$$P_{00}^{(5)} = f_{00}^{(0)} P_{00}^{(5)} + f_{00}^{(1)}.\ P_{00}^{(4)} + f_{00}^{(2)}.\ P_{00}^{(3)} + f_{00}^{(3)}.\ P_{00}^{(2)} + f_{00}^{(4)}.\ P_{00}^{(1)} + f_{00}^{(5)}.\ P_{00}^{(0)}$$

$$\Rightarrow \frac{7}{32} = 0 + 0 + f_{00}^{(2)}.\ P_{00}^{(3)} + 0 + f_{00}^{(5)}.\ P_{00}^{(0)} \Rightarrow \frac{7}{32} = \frac{1}{4}\left(\frac{1}{8}\right) + \left(\frac{1}{8}\right)\frac{1}{4} + f_{00}^{(5)} \Rightarrow f_{00}^{(5)} = \frac{5}{32}$$

Apenas como comparação, exibimos a seguir os valores de $f_{00}^{(n)}$ e os $P_{00}^{(n)}$ correspondentes.

n	$f_{00}^{(n)}$	$P_{00}^{(n)}$
0	0	1
1	0	0
2	1/4	1/4
3	1/8	1/8
4	5/16	3/8
5	5/32	7/32

Note que os $f_{00}^{(n)}$ são sempre menores ou iguais aos $P_{00}^{(n)}$ correspondentes.

Definição 3.6.19. Estados Recorrentes e Transientes
Um estado i é chamado de recorrente se $f_{ii} = 1$. Do contrário, se $f_{ii} < 1$, o estado i é transiente.

Em outras palavras, um estado é recorrente se, começando neste estado, a probabilidade de retorno ao estado num intervalo finito de tempo é 100%. Isto é, um estado é recorrente se um eventual retorno a ele é um evento certo! Note que **todo estado absorvente é um estado recorrente.**

Por outro lado, **se um estado é transiente**, a probabilidade de um eventual retorno ao estado é menor que 1, e assim **existe uma probabilidade não nula** $1 - f_{ii}$ de **nunca mais retornar ao estado transiente** i.

Considere um estado **transiente** i. A probabilidade do processo começar no estado i e retornar a este estado pelo menos uma vez é $f_{ii} < 1$. Pela propriedade Markoviana, a probabilidade do processo retornar ao estado i pelo menos 2 vezes é $(f_{ii})^2$. Repetindo o mesmo argumento, a **probabilidade de que o processo retorne ao estado i pelo menos k vezes** é $(f_{ii})^k$ onde k =1,2,3...

Seja M a variável aleatória que conta o número de vezes em que o processo retornou ao estado i. M tem distribuição Geométrica com probabilidade f_{ii}, e então:

$\Pr\{M \geq k \mid X_0 = i\} = (f_{ii})^k$ para k =1,2,3...

Daí segue que:

$\Pr\{M \geq 1 \mid X_0 = i\} = f_{ii} \Rightarrow 1 - \Pr\{M = 0\} = f_{ii} \Rightarrow \Pr\{M = 0\} = 1 - f_{ii}$

$\Pr\{M \geq 2 \mid X_0 = i\} = (f_{ii})^2 \Rightarrow 1 - \Pr\{M = 0\} - \Pr\{M = 1\} = (f_{ii})^2$

$\Rightarrow \Pr\{M = 1\} = 1 - \Pr\{M = 0\} - (f_{ii})^2 = 1 - (1-f_{ii}) - (f_{ii})^2 = f_{ii} - (f_{ii})^2 = f_{ii}(1- f_{ii})$

$\Pr\{M \geq 3 \mid X_0 = i\} = (f_{ii})^3 \Rightarrow \Rightarrow 1 - \sum_{k=0}^{2} \Pr(M = k) = (f_{ii})^3 \Rightarrow \Pr(M = 2) = f_{ii}^2(1 - f_{ii})$

Em geral:

$\Pr\{M = k\} = f_{ii}^k.(1- f_{ii})$ para k = 0, 1,2...

Na verdade, estas probabilidades são condicionais dado $X_0 = i$, ou seja, em termos mais rigorosos, o que acabamos de mostrar é que:
$\Pr\{M = k \mid X_0 = i\} = f_{ii}^k.(1- f_{ii})$ para k = 0, 1,2...

O valor esperado de M é calculado diretamente a partir desta distribuição de probabilidade, como mostrado a seguir.

$$E[M \mid X_0 = i] = \sum_{m=0}^{\infty} m.\Pr[M = m] = \sum_{m=0}^{\infty} m.\, f_{ii}^m(1 - f_{ii}) = (1 - f_{ii}) \sum_{m=0}^{\infty} m.\, f_{ii}^m =$$

$$= (1 - f_{ii}) f_{ii} \sum_{m=0}^{\infty} m.\, f_{ii}^{m-1} = (1 - f_{ii}) f_{ii} \sum_{m=0}^{\infty} \frac{d\left(f_{ii}^m\right)}{df_{ii}} = f_{ii}(1 - f_{ii}) \frac{d}{df_{ii}} \left[\sum_{m=0}^{\infty} f_{ii}^m\right] =$$

$$= f_{ii}(1 - f_{ii}) \frac{d}{df_{ii}} \left[\frac{1}{1 - f_{ii}}\right] = f_{ii}(1 - f_{ii}) \left[\frac{1}{1 - f_{ii}}\right]^2 = \frac{f_{ii}}{1 - f_{ii}}$$

Note que, se i é um estado recorrente ($f_{ii} = 1$), este valor esperado é infinito. Do contrário, o estado é transiente e a média da variável M é finita.

O próximo teorema estabelece um critério para verificar se um estado é recorrente baseado nas probabilidades de transição P_{ii}^n.

Teorema 3.6.20.

Um estado i é recorrente se, e somente se, $\sum_{n=1}^{\infty} P_{ii}^{(n)} = \infty$. De maneira equivalente, um estado i é transiente se, e somente se $\sum_{n=1}^{\infty} P_{ii}^{(n)} < \infty$.

Demonstração
Suponha que i é um estado transiente. Por definição $f_{ii} < 1$. Seja M o número total de retornos ao estado i. Podemos escrever M em termos de indicadores como:

$$M = \sum_{n=1}^{\infty} I\{X_n = i\} \text{ onde } I\{X_n = i\} = \begin{cases} 1 & \text{se } X_n = i \\ 0 & \text{se } X_n \neq i \end{cases}$$

Mas,

$$E[M \mid X_0 = i] = \frac{f_{ii}}{1 - f_{ii}} < \infty \text{ pois i é um estado transiente. Logo:}$$

$$\infty > E[M \mid X_0 = i] = \sum_{n=1}^{\infty} E\left\{I(X_n = i) \;\middle|\; X_0 = i\right\} = \sum_{n=1}^{\infty} P_{ii}^{(n)}$$

Alternativamente suponha que $\sum_{n=1}^{\infty} P_{ii}^{(n)} < \infty$. Então M é uma variável aleatória com média finita e assim, a partir do estado i, voltamos a este mesmo estado um número finito de vezes. Logo, deve existir uma probabilidade positiva de que, partindo do estado i, o processo nunca mais voltará a este estado, ou seja, $1 - f_{ii} > 0 \Leftrightarrow f_{ii} < 1$ e, por definição, i é um estado transiente.

Teorema 3.6.21.
Se $i \leftrightarrow j$ e i é um estado recorrente, então j também é um estado recorrente.

Assim, recorrência (da mesma maneira que periodicidade) é uma propriedade de classe. Todos os estados na mesma classe são recorrentes (ou transientes).

Exemplo 3.6.22.
Considere um passeio aleatório definido nos números inteiros. Suponha que as probabilidades de transição são: $P_{i,i+1} = p$ e $P_{i,i-1} = 1 - p = q$.

Note que todos os estados se comunicam, e então existe uma única classe. Portanto, precisamos olhar para apenas um estado; se ele for recorrente, todos os outros também o serão (idem se o estado for transiente).

Considere o estado zero. A probabilidade de sair deste estado e retornar a ele num número **ímpar** de transições é dada por $P_{00}^{(2n+1)} = 0$ para n =0,1,2.. A probabilidade de sair e retornar ao estado zero num número **par** de transições é:

$$P_{00}^{(2n)} = \binom{2n}{n} p^n q^n = \frac{(2n)!}{n!n!} p^n q^n .$$

Suponha que n é grande. Podemos usar a Fórmula de Stirling para aproximar os fatoriais que aparecem no cálculo de $P_{00}^{(2n)}$. Especificamente, a **Fórmula de Stirling** nos dá: $n! \sim n^{n+1/2}.e^{-n}.\sqrt{2\pi}$.

Podemos usar esta fórmula também para aproximar (2n)!, o que resulta em: $(2n)! \sim (2n)^{2n+1/2}.e^{-2n}.\sqrt{2\pi} = \sqrt{2\pi}.e^{-2n}.2^{2n+1/2}(n)^{2n+1/2}$.

Logo:

$$P_{00}^{(2n)} \sim \frac{2^{2n}\sqrt{2}.n^{2n}\sqrt{n}.e^{-2n}\sqrt{2\pi}}{\left(n^n\sqrt{n}.e^{-n}.\sqrt{2\pi}\right)\left(n^n\sqrt{n}.e^{-n}.\sqrt{2\pi}\right)}(pq)^n = \frac{2^{2n}\sqrt{2}}{\sqrt{2\pi n}}(pq)^n = \frac{(4pq)^n}{\sqrt{\pi n}}$$

Mas $p.q = p(1-p) \leq \frac{1}{4}$ e $pq = \frac{1}{4} \Leftrightarrow p = q = \frac{1}{2}$. Logo: $\sum_{n=0}^{\infty} P_{00}^{(2n)} = \infty \Leftrightarrow p = 1/2$.

O passeio aleatório unidimensional com espaço de estados {..., -3, -2, -1, 0, 1, 2, 3...} é recorrente se, e somente se, $p = q = \frac{1}{2}$.

3.7. O Teorema Básico de Limite para Cadeias de Markov

Seja i um estado recorrente. Daí, a probabilidade de retornar a este estado num intervalo de tempo finito é 100% e, na notação da seção 3.6.

Temos: $f_{ii} = \sum_{n=0}^{\infty} f_{ii}^{(n)} = 1$.

O **primeiro instante de retorno** ao estado i é definido como:
$R_i = \min\{n \geq 1: X_n = i\}$, e $f_{ii}^{(n)}$ representa a distribuição de probabilidade de R_i. Em termos de R_i podemos reescrever as probabilidades $f_{ii}^{(n)}$ como: $f_{ii}^{(n)} = Pr\{R_i = n \mid X_0 = i\}$ para n = 1, 2, 3...

Mas, por hipótese, i é um estado recorrente e então $f_{ii} = \sum_{n=0}^{\infty} f_{ii}^{(n)} = 1$.

A **duração média entre visitas** ao estado i é:

$$m_i = E\{R_i \mid X_0 = i\} = \sum_{n=1}^{\infty} n.\ f_{ii}^{(n)} = \sum_{n=1}^{\infty} n.Pr\left\{ R_i = n \;\middle|\; X_0 = i \right\}$$

Isto é, ao iniciarmos o processo no estado i, a cadeia voltará ao mesmo estado i, **em média** uma vez a cada m_i unidades de tempo.

Seja $P_{ii}^{(n)}$ a probabilidade de estar no estado i após n transições (n = 0, 1, 2...) dado que o estado inicial da cadeia era $X_0 = i$. Por convenção fazemos $P_{ii}^{(0)} = 1$.

Seja $f_{ii}^{(n)}$ a probabilidade de que o primeiro retorno ao estado i aconteça na n-ésima transição, n = 0, 1,2... onde por definição $f_{ii}^{(0)} = 0$.

Teorema 3.7.1. O Teorema Básico de Limite das Cadeias de Markov

a) Considere uma cadeia de Markov **irredutível, aperiódica e recorrente.** Então o **limite** de $P_{ii}^{(n)}$ quando n tende a infinito **existe** e é dado por:

$$\lim P_{ii}^{(n)} = \frac{1}{\sum_{n=0}^{\infty} n.f_{ii}^{(n)}} = \frac{1}{m_i}$$

b) Sob as mesmas condições que em a): $\lim P_{ji}^{(n)} = \lim P_{ii}^{(n)}$ para qualquer estado j, ou seja, o **limite independe do estado inicial**!!!!!

> **Por que este teorema é importante?**
>
> 1) O teorema 3.7.1. nos dá as condições de existência do limite das probabilidades de transição;
> 2) O teorema nos permite encontrar o limite usando m_i, que é uma quantidade que pode ser calculada sem recorrer explicitamente ao cálculo das potências da matriz de transição P^2, P^3, P^4...

Seja C uma **classe recorrente** (então, todos os estados dentro desta classe são recorrentes). Assim, para todo número de transições n, $P_{ij}^{(n)} = 0$ para $i \in C$ e $j \notin C$, ou seja, $P_{ij}^{(n)} = 0$ para todos os estados i dentro da classe recorrente e estados j fora desta classe.

Em outras palavras: **uma vez dentro de uma classe recorrente C é impossível sair dela.** A submatriz P_{ij} onde ambos i e $j \in C$ é uma matriz de transição e a cadeia de Markov associada a esta submatriz é irredutível e recorrente. Logo, o teorema anterior se aplica a esta submatriz e assim o teorema pode ser usado quando em qualquer classe aperiódica e recorrente.

Logo, se estamos trabalhando com uma cadeia de Markov com "muitos" estados, que apresenta uma matriz de transição "grande", a idéia é dividir esta matriz de transição em pedaços correspondentes a classes aperiódicas e recorrentes, e estudar os limites das probabilidades de transição dentro destas classes.

Se $\lim P_{ii}^{(n)} > 0$ para algum i numa classe aperiódica e recorrente, então existe a probabilidade limite $\pi_j > 0$ para todo j na mesma classe que i. Neste caso chamamos a classe que contém os estados i e j de **classe positiva recorrente** e os estados dentro desta classe são chamados de positivo recorrentes. Se todo $\pi_j = 0$ e a classe é recorrente, dizemos que a **classe é nula recorrente**, e os seus estados são nulo recorrente.

Numa cadeia de Markov com espaço de estados finito não existem estados nulo recorrentes! Todos os estados são transientes ou positivo recorrentes! Também, como recorrência é uma propriedade das classes, para

qualquer uma classe numa cadeia de Markov com espaço de estados finito, todos os estados na classe são transientes ou positivo recorrentes.

A definição de estados positivo recorrentes e nulo recorrentes pode ser estabelecida em termos do **primeiro instante de retorno** $R_i = \min\{n \geq 1: X_n = i\}$.

O estado i é **positivo recorrente** se $m_i = E\{R_i \mid X_0 = i\} < \infty$ e o estado i é **nulo recorrente** se $m_i = \infty$. Isto decorre diretamente da igualdade: $\pi_i = \lim P_{ii}^{(n)} = \frac{1}{m_i}$

O próximo teorema apresenta um método alternativo para determinar a distribuição limite π_i para uma classe positiva recorrente e aperiódica.

Teorema 3.7.2.
Numa classe **positiva recorrente** e **aperiódica** com estados j = 0,1,2... temos:

$\pi_j = \lim P_{jj}^{(n)} = \sum_{i=0}^{\infty} \pi_i P_{ij}$ onde $\sum_{i=0}^{\infty} \pi_i = 1$ e os π's são **unicamente determinados** pelas equações:

1) $\pi_i \geq 0$ para todo i

2) $\sum_{i=0}^{\infty} \pi_i = 1$

3) $\pi_j = \sum_{i=0}^{\infty} \pi_i P_{ij}$ para j = 0, 1, 2...

Qualquer conjunto π_i satisfazendo as expressões 1) a 3) acima é chamado de **distribuição de probabilidade estacionária** da cadeia de Markov. A distribuição estacionária é também chamada de distribuição **invariante** ou de **equilíbrio**.

> Quando uma distribuição limite da cadeia de Markov existe, ela é uma distribuição estacionária. Mas, a **recíproca não é verdadeira**: pode existir uma distribuição estacionária que não é uma distribuição limite.
>
> Se a distribuição estacionária existe e é o limite de P^n então esta distribuição estacionária não depende do estado inicial da cadeia.

Definição 3.7.3.
Uma **cadeia de Markov** é **estacionária** se ela começa com uma certa distribuição de probabilidade e continua com a mesma distribuição para todo instante n. Logo, a cadeia é estacionária se: $Pr\{X_0 = i\} = \pi_i$ implica $Pr\{X_n = i\} = \pi_i$ para todo instante n = 1,2, 3...

Se a distribuição de probabilidade do estado inicial é estacionária, a densidade conjunta de X_n e X_{n+1} é: $Pr\{X_n = i, X_{n+1} = j\} = \pi_i . P_{ij}$.

Exemplo 3.7.4.

Considere a cadeia de Markov com matriz de transição $P = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$. No exemplo 3.6.2 vimos que esta cadeia oscila de maneira determinística entre os dois estados. Se n é ímpar, $P^n = P$ e se n é par, P^n é a matriz identidade. Logo, a cadeia representada por esta matriz de transição é **periódica**, e **não existe distribuição limite**.

No entanto, pode-se provar que **π = (1/2, 1/2) é uma distribuição estacionária** pois:

$\pi_1 = 1/2 \geq 0$,
$\pi_2 = 1/2 \geq 0$, $\pi_1 + \pi_2 = 1$ e π_1, π_2 são soluções do seguinte sistema:

$\pi_1 = \pi_1 . P_{11} + \pi_2 . P_{21} = \pi_1.(0) + \pi_2.(1) \Rightarrow \pi_1 = \pi_2 = 1/2$
$\pi_2 = \pi_1 . P_{12} + \pi_2 . P_{22} = \pi_1.(1) + \pi_2.(0) \Rightarrow \pi_2 = \pi_1 = 1/2$

Exemplo 3.7.5.
Considere o passeio aleatório com a seguinte matriz de transição:

$$P = \begin{bmatrix} 0 & 1 & 0 & 0 & .... \\ q_1 & 0 & p_1 & 0 & .... \\ 0 & q_2 & 0 & p_2 & .... \\ & & & & .... \end{bmatrix}$$

Esta cadeia de Markov tem **período 2** e, portanto, **não satisfaz** as condições do **teorema 3.7.2.** Entretanto, mesmo que não exista uma distribuição de probabilidade limite, é possível em muitos casos encontrar as probabilidades estacionárias, dadas pela solução do sistema:

$x_i = \sum_{j=0}^{\infty} x_j P_{ji} = p_{i-1}x_{i-1} + q_{i+1}x_{i+1}$ i = 0, 1, 2...

Sujeitas à condição de normalização $\sum_{i=0}^{\infty} x_i = 1$. Note que $p_{-1} = 0$ e $p_0 = 1$.

Então, das equações acima:
$x_0 = q_1.x_1 \Rightarrow x_1 = x_0/q_1$

$x_1 = p_0x_0 + q_2x_2 \Rightarrow x_1 = x_0 + q_2x_2 \Rightarrow x_2 = \frac{p_1}{q_1q_2}x_0$

$x_2 = p_1x_1 + q_3x_3 \Rightarrow x_3 = \frac{p_1p_2}{q_1q_2q_3}x_0$

Em geral:

$x_i = \frac{p_1p_2 \cdots p_{i-2}p_{i-1}}{q_1q_2q_3 \cdots q_{i-2}q_{i-1}q_i}x_0$

Mas, existe a condição de normalização $\sum_{i=0}^{\infty} x_i = 1$ e então:

$$x_0 + \sum_{i=1}^{\infty} x_i = 1 \Rightarrow x_0 + \sum_{i=1}^{\infty} x_0 \left[\prod_{k=0}^{i-1} \frac{p_k}{q_{k+1}}\right] = 1 \Rightarrow x_0 = \frac{1}{1 + \sum_{i=1}^{\infty} \left[\prod_{k=0}^{i-1} \frac{p_k}{q_{k+1}}\right]}$$ e $x_0 > 0$ se, e somente se, $\sum_{i=1}^{\infty} \left[\prod_{k=0}^{i-1} \frac{p_k}{q_{k+1}}\right] < \infty$. Em particular, se $p_k = p$ e $q_k = q = 1 - p$ para todo $k \geq 1$ temos:

$$\sum_{i=1}^{\infty} \left[\prod_{k=0}^{i-1} \frac{p_k}{q_{k+1}}\right] = \frac{1}{p} \sum_{i=1}^{\infty} \left(\frac{p}{q}\right)^i$$ que converge apenas quando $p < q$.

Neste caso ($p < q$) o somatório anterior reduz-se a:

$$\frac{1}{p} \sum_{i=1}^{\infty} \left(\frac{p}{q}\right)^i = \frac{1}{p}\left[\frac{(p/q)}{1-(p/q)}\right] = \frac{1}{p}\left[\frac{p}{q-p}\right] = \frac{1}{q-p}$$

e então: $x_0 = \frac{1}{1 + \sum_{i=1}^{\infty} \left[\prod_{k=0}^{i-1} \frac{p_k}{q_{k+1}}\right]} = \frac{1}{1 + \frac{1}{q-p}} = \frac{q-p}{2q} = \frac{1}{2}\left[1 - \frac{p}{q}\right]$

Logo:

$$x_k = x_0 \left(\frac{p^{k-1}}{q^k}\right) = \frac{1}{2p}\left(1 - \frac{p}{q}\right)\left(\frac{p}{q}\right)^k \quad \text{para } k = 1, 2, 3, 4, ...$$

Note que a distribuição estacionária existe quando $p < q$ (ou, de maneira equivalente, quando x_0 é estritamente maior que zero).

Lema 3.7.6.
Seja $0 < p_i < 1$ para todo $i = 0, 1, 2...$ Então:

$u_m = \prod_{i=1}^{m} (1 - p_i) \to 0$ quando $m \to \infty$

se, e somente se, $\sum_{i=1}^{\infty} p_i = \infty$.

Este lema será usado no próximo exemplo.

Exemplo 3.7.7.
Considere uma cadeia de Markov **infinita** com a seguinte matriz de transição:

$$P = \begin{bmatrix} p_0 & 1-p_0 & 0 & 0 & .... \\ p_1 & 0 & 1-p_1 & 0 & .... \\ p_2 & 0 & 0 & 1-p_2 & .... \\ & & & & .... \end{bmatrix}$$

onde $0 < p_k < 1$ para todo estados $k = 0, 1, 2...$

Todos os estados pertencem à mesma classe (todos se comunicam). Como recorrência é uma propriedade de classe, vamos ver o que acontece com o estado zero e isso nos dará uma idéia a respeito do que acontecerá com os outros estados.

Seja $R_0 = \min\{n \geq 1: X_n = 0\}$, isto é, R_0 indica o instante do primeiro retorno ao estado zero. Considere as seguintes probabilidades:

$\Pr[R_0 > 1 \mid X_0 = 0] = 1-p_0$
$\Pr[R_0 > 2 \mid X_0 = 0] = (1-p_0)(1-p_1)$
$\Pr[R_0 > 3 \mid X_0 = 0] = (1-p_0)(1-p_1)(1-p_2)$
.....
$\Pr[R_0 > K \mid X_0 = 0] = \prod_{i=0}^{k-1} (1-p_i)$

A distribuição de probabilidade do primeiro instante de retorno é:

$$f_{\infty}^{(n)} = \Pr[R_0 = n \mid X_0] = 1 - \sum_{n=1}^{k} f_{\infty}^{(n)}$$

$$\sum_{n=1}^{k} f_{\infty}^{(n)} = 1 - \Pr\left[R_0 > k \mid X_0 = 0\right] =$$

$$= 1 - \prod_{i=0}^{k-1} (1-p_i)$$

Por definição, **o estado 0 é recorrente se, e somente se**:

$$f_{\infty} = \lim_{k\to\infty} \sum_{n=1}^{k} f_{\infty}^{(n)} = 1$$

Em termos das probabilidades $p_0, p_1, p_2...$ isso é equivalente a dizer que o estado zero é recorrente se, e somente se: $\prod_{i=0}^{\infty} (1-p_i) = 0$, ou seja, se:

$$\lim_{k\to\infty} \prod_{i=0}^{k-1} (1-p_i) = 0$$

Pelo lema anterior: $\lim_{k\to\infty} \prod_{i=0}^{k-1} (1-p_i) = 0 \Leftrightarrow \sum_{i=1}^{\infty} p_i = \infty$.

Em resumo:
Nesta cadeia de Markov, o estado 0 (e então todos os estados) são recorrentes se, e somente se, $\sum_{i=1}^{\infty} p_i = \infty$.

O estado zero é **positivo recorrente** quando $m_0 = E[R_0 \mid X_0=0] < \infty$. Mas,

$$m_0 = \sum_{k=0}^{\infty} \Pr\,[R_0>k \mid X_0 = 0] = 1 + \sum_{k=1}^{\infty} \left\{ \prod_{i=0}^{k-1} (1-p_i) \right\}$$

Então, para que o estado zero seja **positivo recorrente**, precisamos da condição mais forte: $\sum_{k=1}^{\infty} \left\{ \prod_{i=0}^{k-1} (1-p_i) \right\} < \infty$

Neste caso, a probabilidade estacionária π_0 é:

$$\pi_0 = \frac{1}{m_0} = \frac{1}{1 + \sum_{k=1}^{\infty} \left\{ \prod_{i=0}^{k-1} (1-p_i) \right\}}$$

As equações para as probabilidades estacionárias são:

$\pi_1=(1-p_0)\pi_0$
$\pi_2=(1-p_1)\pi_1 = (1-p_1)(1-p_0)\,\pi_0$
$\pi_3=(1-p_2)\pi_2 = (1-p_2)(1-p_2)(1-p_0)\pi_0$

Em geral:

$$\pi_k = \pi_0 \prod_{i=0}^{k-1} (1-p_i) \text{ para } k \geq 1$$

No caso particular $p_i = p = 1- q$ para todos os estados $i = 0, 1, 2...$ então temos:

$$\prod_{i=0}^{k-1} (1-p_i) = \prod_{i=0}^{k-2} q = q^k$$

E então:

$$m_0 = 1 + \sum_{k=1}^{\infty} q^k = \frac{1}{1-q} = \frac{1}{p} < \infty \quad \text{se} \mid q \mid < 1$$

Assim:

$$\pi_0 = \frac{1}{m_0} = p$$

$$\pi_k = pq^k \text{ para } k = 0, 1, 2...$$

Nota:

Acabamos de definir m_0 como: $m_0 = \sum_{k=0}^{\infty} \Pr\,[R_0>k \mid X_0 = 0]$

Mas, a definição de m_0 era: $m_0 = E\,[R_0 \mid X_0 = 0] = \sum_{k=0}^{\infty} K \Pr\,[R_0 = k]$

Como estabelecer a igualdade entre estas duas expressões?

A demonstração deste resultado será feita apenas para $k = 0, 1, 2... N$, um número finito de estados, por simplicidade.

Seja X uma variável aleatória discreta qualquer com valores 0, 1, 2... N.

Queremos provar que: $E(X) = \sum_{k=0}^{N} k \Pr(X = k) = \sum_{k=0}^{N} \Pr(X > k)$.

Mas, $\Pr(X > k) = 1 - \Pr(X \leq k)$ e assim:

$$\sum_{k=0}^{N} \Pr(X > k) = \sum_{k=0}^{N} [1 - \Pr(X \leq k)] = \sum_{k=0}^{N} 1 - \sum_{k=0}^{N} \Pr(X \leq k) = (N+1) - \sum_{k=0}^{N} \Pr(X \leq k)$$

Falta agora calcular $\sum_{k=0}^{N} \Pr(X \leq k)$. Considere a tabela a seguir:

k	**Pr (X ≤ k)**
0	Pr (X = 0)
1	Pr (X = 0) + Pr (X = 1)
2	Pr (X = 0) + Pr (X = 1) + Pr (X = 2)
.....	.....
N	Pr (X = 0) + Pr (X = 1) + Pr (X = 2) +... + Pr (X = N)

Somando termo a termo:

$$\sum_{k=0}^{N} \Pr(X \leq k) = (N+1)\Pr(X = 0) + N\Pr(X = 1) +$$
$$+ (N-1)\Pr(X = 2) + ... + 2.\Pr(X = N-1) + \Pr(X = N)$$

Logo:

$$\sum_{k=0}^{N} \Pr\,(X \leq k) = \sum_{k=0}^{N} (N-k+1)\ \Pr(X = k) = \sum_{k=0}^{N} (N+1)\ \Pr(X = k) - \sum_{k=0}^{N} k \Pr\,(X = k)$$

$$\sum_{k=0}^{N} \Pr\,(X \leq k) = (N+1) \sum_{k=0}^{N} \Pr(X = k) - \sum_{k=0}^{N} k \Pr\,(X = k)$$

Mas, por hipótese, os valores possíveis de X são 0, 1, 2... N, e assim:

$$\sum_{k=0}^{N} \Pr\,(X = k) = 1 \quad \text{e} \quad \sum_{k=0}^{N} k \Pr\,(X = k) = E(X)$$

Logo: $\sum_{k=0}^{N} \Pr(X \leq k) = (N+1) - E(X)$

Finalmente:

$$\sum_{k=0}^{N} \Pr\,(X > k) = \sum_{k=0}^{N} [1 - \Pr\,(X \leq k)] = (N+1) - (N+1) - (-E(X)) = E(X)$$

Esta seção contém alguns dos resultados mais importantes no estudo das cadeias de Markov. Além dos teoremas 3.7.1 e 3.7.2, já apresentados, enumeramos a seguir alguns fatos cujas demonstrações serão omitidas (algu-

mas decorrem mais ou menos diretamente dos teoremas já apresentados). Os resultados a seguir também são importantes, e alguns deles podem ser até redundantes, mas é melhor pecar por excesso do que por falta!!

Teorema 3.7.8.
Se i é um estado positivo recorrente e $i \to j$ então j também é positivo recorrente.

Definição 3.7.9.
Um conjunto (não vazio) de estados C é um **conjunto fechado** se nenhum estado em C leva a um estado fora de C, ou seja, se a probabilidade de chegar eventualmente num estado $j \notin C$ partindo de um estado $i \in C$ é zero.

Definição 3.7.10.
Um conjunto de estados C é **irredutível** se todos os estados em C se comunicam.

Das definições anteriores, segue que, se C é um **conjunto irredutível e fechado** então todos os estados em C têm o mesmo comportamento, a saber:

- todos os estados em C são transientes ou
- todos os estados em C são nulo recorrentes ou
- todos os estados em C são positivo recorrentes.

Da mesma maneira, numa **cadeia de Markov irredutível**, todos os estados são:
- transientes ou
- nulo recorrentes ou
- positivo recorrentes.

Teorema 3.7.11.
Seja C um conjunto **finito, irredutível e fechado** de estados, então **todos os estados** em C são **positivo recorrentes**.

Podemos aplicar este teorema a uma cadeia **irredutível** com espaço de estados **finito**.

Teorema 3.7.12.
Todos os estados numa cadeia de Markov finita e irredutível são positivo recorrentes. Logo, uma **cadeia finita e irredutível não possui estados nulo recorrentes**.

Exemplo 3.7.13.
Considere a cadeia de Markov com matriz de transição:

$$P = \begin{array}{c} \\ 0 \\ 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{array} \begin{array}{c} \begin{array}{cccccc} 0 & 1 & 2 & 3 & 4 & 5 \end{array} \\ \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 1/4 & 1/2 & 1/4 & 0 & 0 & 0 \\ 0 & 1/5 & 2/5 & 1/5 & 0 & 1/5 \\ 0 & 0 & 0 & 1/6 & 1/3 & 1/2 \\ 0 & 0 & 0 & 1/2 & 0 & 1/2 \\ 0 & 0 & 0 & 1/4 & 0 & 3/4 \end{bmatrix} \end{array}$$

As classes são: {0}, {1,2} e {3,4,5}. O estado 0 é absorvente, e então é um estado recorrente. O conjunto {3,4,5} é um conjunto finito, irredutível e fechado, e então os estados 3,4,5 são positivo recorrentes (pelo teorema 3.7.11). Pelo mesmo teorema, 0 é um estado positivo recorrente.

Os estados 1 e 2 são transientes, e note que o conjunto {1,2} não é fechado, pois, por exemplo, $1 \to 0$, $2 \to 3$, $2 \to 5$.

A classe {3,4,5} é **positiva recorrente** e **aperiódica**, e então existem probabilidades limite dentro desta classe, e estas probabilidades limite coincidem com as probabilidades estacionárias.

Nota
As definições de **classe** e **conjunto fechado** de estados **não** são iguais.
No exemplo anterior, {0}, {1,2}, {3,4,5} são classes (conjuntos de estados que se comunicam), mas {1,2} **não é** um conjunto fechado de estados.

Teorema 3.7.14.
Seja π uma distribuição estacionária, $\pi = (\pi_0, \pi_1, \pi_2 \ldots)$. Se i é um estado **transiente** ou **nulo recorrente** então $\pi_i = 0$.

Exemplo 3.7.15.
Considere a cadeia de Markov do exemplo 3.7.13. A classe {3,4,5} tem uma distribuição de probabilidade limite, que coincide com as probabilidades estacionárias. Estas, por sua vez, devem satisfazer:

$$\pi_3 + \pi_4 + \pi_5 = 1$$

$$\pi_3 = \pi_3 P_{33} + \pi_4 P_{43} + \pi_5 P_{53}$$

$$\pi_3 = \frac{1}{6}\pi_3 + \frac{1}{2}\pi_4 + \frac{1}{4}\pi_5$$

$$\pi_4 = \pi_3 P_{34} + \pi_4 P_{44} + \pi_5 P_{54}$$

$$\pi_4 = \frac{1}{3}\pi_3$$

$$\pi_5 = \pi_3 P_{35} + \pi_4 P_{45} + \pi_5 P_{55}$$

$$\pi_5 = \frac{1}{2}\pi_3 + \frac{1}{2}\pi_4 + \frac{3}{4}\pi_5$$

A solução destas equações nos dá:

$$\pi_3 = 1/4$$

$$\pi_4 = 1/12$$

$$\pi_5 = 2/3$$

Estas probabilidades são probabilidades estacionárias, mas também correspondem aos limites:

$$\pi_3 = \lim_{n \to \infty} P_{j3}^n$$

$\pi_4 = \lim_{n\to\infty} P_{j4}^n$ para j = 0, 1, 2, 3, 4, 5

$\pi_5 = \lim_{n\to\infty} P_{j5}^n$

O diagrama a seguir serve para mostrar todos os casos possíveis numa **cadeia irredutível** (em que todos os estados estão na mesma classe).

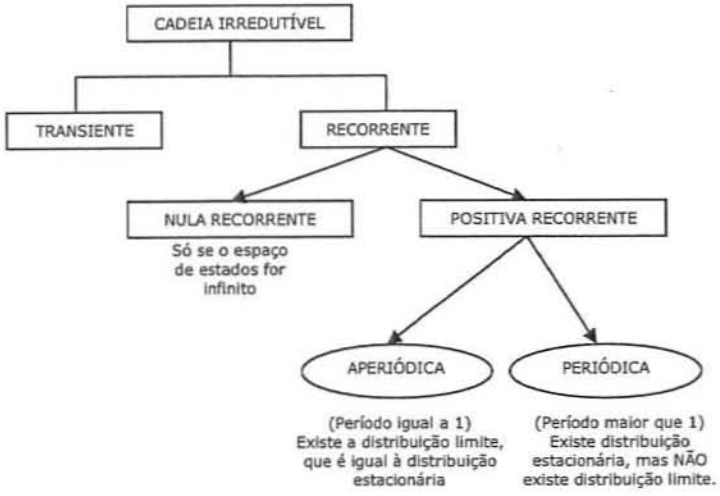

Nota:
Um estado positivo recorrente e aperiódico é chamado de estado **ergódico**. Uma cadeia é **ergódica** se todos os seus estados são positivo recorrentes e aperiódicos.

Seja $a_0, a_1, a_2...$, uma seqüência convergente de números reais, onde $\lim_{n\to\infty} a_n = a$.

Então pode-se provar que: $\lim_{n\to\infty} \frac{1}{n} \sum_{k=0}^{n-1} a_k = 1$. Ou seja, as somas parciais também convergem.

Seja i um estado **positivo recorrente** numa **classe aperiódica**. Pelo teorema 3.7.2, o limite de $P_{ii}^{(n)}$ quando $n\to\infty$ existe, e a probabilidade limite é igual à probabilidade estacionária.

Logo:

$$\pi_i = \frac{1}{m_i} = \lim_{n\to\infty} P_{ii}^{(n)} = \lim_{n\to\infty} \frac{1}{n} \sum_{k=0}^{n-1} P_{ii}^{(k)} > 0 \qquad (3.7.1)$$

Seja $M_i^{(n)}$ a variável aleatória que conta o número total de visitas ao estado i durante os instantes 0, 1, 2..., n-1. Podemos escrever:

$$M_i^{(n)} = \sum_{k=0}^{n-1} I\{X_k = i\}$$

onde $I\{X_k = i\}$ é o **indicador** do evento $\{X_k = i\}$, isto é:

$$I\{X_k = i\} = \begin{cases} 1 & X_k = i \\ 0 & X_k \neq i \end{cases}$$

Assim:

$$E\left[M_i^{(n)} \,\middle|\, X_0 = i\right] = \sum_{k=0}^{n-1} E\left[I\{X_k = i\} \,\middle|\, X_0 = i\right] = \sum_{k=0}^{n-1} P_{ii}^{(k)} \qquad \text{(Por quê?)}$$

Aplicando a expressão (3.7.1) encontramos:

$$\lim_{n\to\infty} \frac{1}{n} E\left[M_i^{(n)} \,\middle|\, X_0 = i\right] = \lim_{n\to\infty} \frac{1}{n} \sum_{k=0}^{n-1} P_{ii}^{(k)} = \pi_i = \frac{1}{m_i}$$

Logo, **no limite** quando $n\to\infty$, **o número médio de visitas ao estado i por unidade de tempo é π_i**, que é a probabilidade estacionária do estado i (e também sua probabilidade limite).

O Caso Periódico
Todos os resultados anteriores foram obtidos para cadeias de Markov aperiódicas. Suponha agora que i é um estado **recorrente** dentro de uma **classe periódica** e **irredutível** com **período d**. Pode-se mostrar que:

i) $P_{ii}^m = 0$ se m **não é múltiplo** de d, isto é, se $m \neq nd$ para algum $n \in Z^+$.

ii) $\lim_{n\to\infty} P_{ii}^{nd} = \frac{d}{m_i}$

Daí segue que, no caso **periódico**:

$\lim_{n\to\infty} \frac{1}{n} \sum_{m=0}^{n-1} P_{ii}^m = \pi_i = \frac{1}{m_i}$ e se $\mathbf{m_i < \infty}$, a cadeia é **positiva recorrente.**

A expressão anterior simplesmente diz que as **somas parciais** convergem, mas como o estado i é periódico, e então **não existe** o limite $\lim_{n\to\infty} P_{ii}^{nd}$.

A convergência das somas parciais anteriores não requer que a cadeia comece no estado i. Logo: $\lim_{n\to\infty} \frac{1}{n} \sum_{m=0}^{n-1} P_{ki}^m = \pi_i = \frac{1}{m_i}$ para todos os estados k = 0, 1, 2...

3.8. Cadeias de Markov Redutíveis

Nesta seção mostramos, através de exemplos, como analisar cadeias de Markov mais gerais, que não são irredutíveis.

Exemplo 3.8.1.

$$P = \begin{array}{c} \\ 0 \\ 1 \\ 2 \\ 3 \end{array} \begin{array}{c} \begin{array}{cccc} 0 & 1 & 2 & 3 \end{array} \\ \begin{bmatrix} 1/2 & 1/2 & 0 & 0 \\ 1/4 & 3/4 & 0 & 0 \\ 0 & 0 & 1/3 & 2/3 \\ 0 & 0 & 2/3 & 1/3 \end{bmatrix} \end{array}$$

Podemos reescrever esta matriz de transição como:

$$P = \begin{bmatrix} P_1 & 0 \\ 0 & P_2 \end{bmatrix} \text{ onde } P_1 = \begin{pmatrix} 1/2 & 1/2 \\ 1/4 & 3/4 \end{pmatrix},\ P_1 = \begin{pmatrix} 1/3 & 2/3 \\ 2/3 & 1/3 \end{pmatrix}$$

Esta cadeia tem duas classes, {0,1} e {2,3}. Além disso, estas classes são conjuntos fechados. Note que:

$$P^2 = \begin{bmatrix} 3/8 & 5/8 & 0 & 0 \\ 5/16 & 11/16 & 0 & 0 \\ 0 & 0 & 5/9 & 4/9 \\ 0 & 0 & 4/9 & 5/9 \end{bmatrix} = \begin{bmatrix} P_1^2 & 0 \\ 0 & P_2^2 \end{bmatrix}$$

Em geral:

$$P^n = \begin{bmatrix} P_1^n & 0 \\ 0 & P_2^n \end{bmatrix} \qquad n \geq 1$$

A matriz de transição é **redutível**, e reduz-se às matrizes irredutíveis P_1 e P_2. Logo,

$$\lim_{n\to\infty} P^n = \begin{bmatrix} \pi_0^{(1)} & \pi_1^{(1)} & 0 & 0 \\ \pi_0^{(1)} & \pi_1^{(1)} & 0 & 0 \\ 0 & 0 & \pi_0^{(2)} & \pi_1^{(2)} \\ 0 & 0 & \pi_0^{(2)} & \pi_1^{(2)} \end{bmatrix}$$

onde:

$$\lim_{n\to\infty} P_1^n = \begin{bmatrix} \pi_0^{(1)} & \pi_1^{(1)} \\ \pi_0^{(1)} & \pi_1^{(1)} \end{bmatrix},\ \lim_{n\to\infty} P_2^n = \begin{bmatrix} \pi_0^{(2)} & \pi_1^{(2)} \\ \pi_0^{(2)} & \pi_1^{(2)} \end{bmatrix},$$

Resolvendo para $\pi_0^{(1)}, \pi_0^{(2)}, \pi_1^{(1)}, \pi_1^{(2)}$ da maneira usual encontramos:

$$\begin{cases} \pi_0^{(1)} = \pi_0^{(1)} P_{\infty} + \pi_1^{(1)} P_{10} \\ \pi_0^{(1)} = \pi_0^{(1)}\left(\frac{1}{2}\right) + \pi_1^{(1)}\left(\frac{1}{4}\right) \\ \pi_1^{(1)} = \frac{1}{2}\pi_0^{(1)} + \frac{3}{4}\pi_1^{(1)} \\ \pi_0^{(1)} + \pi_1^{(1)} = 1 \\ \\ \Rightarrow \pi_0^{(1)} = \frac{1}{3} \\ \quad \pi_1^{(1)} = \frac{2}{3} \end{cases}$$

Analogamente:

$$\begin{cases} \pi_0^{(2)} = \frac{1}{3}\pi_0^{(2)} + \frac{2}{3}\pi_1^{(2)} \\ \pi_1^{(2)} = \frac{2}{3}\pi_0^{(2)} + \frac{1}{3}\pi_1^{(2)} \\ \pi_0^{(2)} + \pi_1^{(2)} = 1 \\ \Rightarrow \pi_0^{(2)} = \pi_1^{(2)} = \frac{1}{2} \end{cases}$$

pois a matriz de transição P_2 é **duplamente estocástica**.

O **teorema básico de limite** de cadeias de Markov se refere a **cadeias irredutíveis**. Entretanto, o **teorema se aplica igualmente a qualquer classe recorrente** e **aperiódica** numa cadeia redutível. As modificações necessárias no teorema são mostradas no resultado a seguir.

Teorema 3.8.2.
Considere uma cadeia de Markov **redutível**.

a) Sejam i e j estados dentro de uma **classe aperiódica** e **recorrente**. Então:

$$\lim_{n\to\infty} P_{ij}^{(n)} = \frac{1}{m_j} = \pi_j \geq 0$$

b) Sejam i e j estados dentro de uma classe **periódica** e **recorrente**. Então não existe limite de $P_{ij}^{(n)}$, mas as somas parciais convergem para as probabilidades estacionárias, ou seja:

$$\lim_{n\to\infty} \frac{1}{n} \sum_{m=0}^{n-1} P_{ij}^{(m)} = \frac{1}{m_j} \geq 0$$

c) Seja j um estado **transiente**. Então:

$\lim_{n\to\infty} P_{jj}^{(n)} = 0$ e

$\lim_{n\to\infty} P_{ij}^{(n)} = 0$ para todos os estados iniciais i.

Independente do estado inicial, o limite da probabilidade da cadeia estar num estado transiente é zero quando $n\to\infty$.

Exemplo 3.8.3.
Considere uma cadeia de Markov com a seguinte matriz de transição:

$$P = \begin{array}{c} \\ 0 \\ 1 \\ 2 \\ 3 \end{array} \begin{array}{c} \begin{array}{cccc} 0 & 1 & 2 & 3 \end{array} \\ \begin{bmatrix} 1/2 & 1/2 & 0 & 0 \\ 1/4 & 3/4 & 0 & 0 \\ 1/4 & 1/4 & 1/4 & 1/4 \\ 0 & 0 & 0 & 1 \end{bmatrix} \end{array}$$

Existem 3 classes: {0,1}, {2} e {3}. Os estados {0,1} e (3) são **recorrentes**, enquanto {2} é **transiente**. A partir do estado 2 a cadeia é eventualmente absorvida por uma das outras classes.

a) Quais são as probabilidades de absorção nas duas classes recorrentes se começamos no estado 2?
b) Qual o limite da matriz P^n quando $n\to\infty$.

Solução
Para achar as probabilidades de absorção procedemos como antes, através de uma análise do primeiro passo.

Seja u a probabilidade de absorção pela classe {0,1} se o processo começa no estado 2. Seja T o tempo mínimo até uma absorção.

$T = \text{mín}\{n \geq 0: X_n = 0 \text{ ou } X_n = 1 \text{ ou } X_n = 3\}$
$u = Pr\{X_T = 0 \text{ ou } X_T = 1 | X_0 = 2\}$

Condicionando ao que aconteceu na primeira transição resulta em:

$$u = \left(\frac{1}{4} + \frac{1}{4}\right)1 + \frac{1}{4}u + \frac{1}{4}(0) = \frac{1}{2} + \frac{1}{4}u$$

$u = 2/3$

Um processo que começa no estado 2 entra na classe {0,1} com probabilidade u = 2/3 e permanece na classe {0,1} indefinidamente.

A distribuição estacionária para a classe {0,1} é computada da mesma forma que no exemplo anterior:

$$\begin{cases} \frac{1}{2}\pi_0 + \frac{1}{4}\pi_1 = \pi_0 \\ \frac{1}{2}\pi_0 + \frac{3}{4}\pi_1 = \pi_1 \\ \pi_0 + \pi_1 = 1 \\ \Rightarrow \pi_0 = 1/3,\ \pi_1 = 2/3 \end{cases}$$

Em termos do limite de P^n já sabemos que:

$$\lim_{n\to\infty} P^n = \begin{bmatrix} \pi_0 & \pi_1 & 0 & 0 \\ \pi_0 & \pi_1 & 0 & 0 \\ ? & ? & ? & ? \\ 0 & 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1/3 & 2/3 & 0 & 0 \\ 1/3 & 2/3 & 0 & 0 \\ ? & ? & ? & ? \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

Como calcular os limites quando $n\to\infty$ dos elementos P_{2j}^n?

Pelo teorema 3.7.2 (parte c), $\lim_{n\to\infty} P_{22}^n = 0$ pois 2 é um estado transiente.

Para calcular $\lim_{n\to\infty} P_{20}^n$ e $\lim_{n\to\infty} P_{21}^n$ multiplicamos a probabilidade de entrar na classe {0,1} pelas probabilidades estacionárias π_0 e π_1.

Ou seja:

$$\lim_{n\to\infty} P_{20}^n = u\pi_0 = \frac{2}{3}\left(\frac{1}{3}\right) = \frac{2}{9}$$

$$\lim_{n\to\infty} P_{21}^n = u\pi_1 = \frac{2}{3}\left(\frac{2}{3}\right) = \frac{4}{9}$$

Também, a soma de qualquer linha da matriz limite é 1, e então:

$$\lim_{n\to\infty} P_{23}^n = 1 - \frac{2}{9} - \frac{4}{9} = \frac{1}{3}$$

Finalmente, a matriz limite é:

$$\begin{bmatrix} 1/3 & 2/3 & 0 & 0 \\ 1/3 & 2/3 & 0 & 0 \\ 2/9 & 4/9 & 0 & 1/3 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

Exemplo 3.8.4.
Considere a cadeia de Markov com matriz de transição:

$$P = \begin{array}{c} \\ 0 \\ 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{array} \begin{array}{c} \begin{array}{cccccc} 0 & 1 & 2 & 3 & 4 & 5 \end{array} \\ \begin{bmatrix} 1/2 & 1/2 & 0 & 0 & 0 & 0 \\ 1/3 & 2/3 & 0 & 0 & 0 & 0 \\ 1/3 & 0 & 0 & 1/3 & 1/6 & 1/6 \\ 1/6 & 1/6 & 1/6 & 0 & 1/3 & 1/6 \\ 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 1 & 0 \end{bmatrix} \end{array}$$

As classes são: $C_1 = \{0,1\}$, $C_2 = \{2,3\}$ e $C_3 = \{4,5\}$

A classe $C_3 = \{4,5\}$ é **periódica**, e então $\lim_{n\to\infty} P_{ij}^n$ **não existe** para i,j=4,5.

Entretanto, as somas parciais convergem, e $\lim_{n\to\infty} \frac{1}{n} \sum_{m=0}^{n-1} P_{ij}^{(m)} = \frac{1}{2}$.

A distribuição estacionária em C_1 é (π_0, π_1) onde:

$$\begin{cases} \pi_0 + \frac{1}{2}\pi_0 + \frac{1}{3}\pi_1 \\ \pi_1 = \frac{1}{2}\pi_0 + \frac{2}{3}\pi_1 \\ \pi_0 + \pi_1 = 1 \\ \Rightarrow \pi_0 = 2/5,\ \pi_1 = 3/5 \end{cases}$$

A classe $C_2 = \{2,3\}$ é **transiente**, e então $\lim_{n\to\infty} P_{i2}^n = \lim_{n\to\infty} P_{i3}^n = 0$.

Seja u_i a probabilidade de eventual absorção pela classe $C_1 = \{0,1\}$ partindo do estado i = 2, 3. Pela análise do primeiro passo segue que:

$$u_2 = \frac{1}{3}(1) + 0(1) + 0u_2 + \frac{1}{3}u_3 + \frac{1}{6}(0) + \frac{1}{6}(0)$$

$$u_3 = \frac{1}{6}(1) + \frac{1}{6}(1) + \frac{1}{2}u_2 + 0u_3 + \frac{1}{3}(0) + \frac{1}{6}(0)$$

$$\Rightarrow \left.\begin{array}{l} u_2 = \frac{1}{3} + \frac{1}{3}u_3 \\ u_3 = \frac{1}{3} + \frac{1}{6}u_2 \end{array}\right\} \Rightarrow u_2 = 8/17; u_3 = 7/17$$

Combinando estas respostas parciais temos:

$$\lim_{n\to\infty} P^n = \begin{array}{c} \\ 0 \\ 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{array} \begin{array}{c} \begin{array}{cccccc} 0 & 1 & 2 & 3 & 4 & 5 \end{array} \\ \begin{bmatrix} 2/5 & 3/5 & 0 & 0 & 0 & 0 \\ 2/5 & 3/5 & 0 & 0 & 0 & 0 \\ \frac{2}{5}\left(\frac{8}{17}\right) & \frac{3}{5}\left(\frac{8}{17}\right) & 0 & 0 & x & x \\ \frac{2}{5}\left(\frac{7}{17}\right) & \frac{3}{5}\left(\frac{7}{17}\right) & 0 & 0 & x & x \\ 0 & 0 & 0 & 0 & x & x \\ 0 & 0 & 0 & 0 & x & x \end{bmatrix} \end{array}$$

Acima, "x" indica que o **limite não existe**.

Para as somas parciais, o limite sempre existe, e então:

$$\lim_{\substack{n\to\infty \\ n}} \frac{1}{n} \sum_{m=0}^{n-1} P^m = \begin{array}{c} \\ 0 \\ 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{array} \begin{array}{c} \begin{array}{cccccc} 0 & 1 & 2 & 3 & 4 & 5 \end{array} \\ \begin{bmatrix} 2/5 & 3/5 & 0 & 0 & 0 & 0 \\ 2/5 & 3/5 & 0 & 0 & 0 & 0 \\ \frac{2}{5}\left(\frac{8}{17}\right) & \frac{3}{5}\left(\frac{8}{17}\right) & 0 & 0 & \frac{1}{2}\left(\frac{9}{17}\right) & \frac{1}{2}\left(\frac{9}{17}\right) \\ \frac{2}{5}\left(\frac{7}{17}\right) & \frac{3}{5}\left(\frac{7}{17}\right) & 0 & 0 & \frac{1}{2}\left(\frac{10}{17}\right) & \frac{1}{2}\left(\frac{10}{17}\right) \\ 0 & 0 & 0 & 0 & 1/2 & 1/2 \\ 0 & 0 & 0 & 0 & 1/2 & 1/2 \end{bmatrix} \end{array}$$

Note que 16/85 ≈ 0.18882, 24/85 ≈ 0.2824, 14/85 ≈ 0.1647, 21/85 ≈ 0.2471.

$$P^{20} = \begin{bmatrix} 0.4 & 0.6 & 0 & 0 & 0 & 0 \\ 0.4 & 0.6 & 0 & 0 & 0 & 0 \\ 0.1882 & 0.2824 & 0 & 0 & 0.2941 & 0.2353 \\ 0.1647 & 0.2471 & 0 & 0 & 0.2059 & 0.3824 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

este bloco da matriz P^n oscila

entre $\begin{bmatrix} 0.29 & 0.23 \\ 0.20 & 0.38 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}$ e $\begin{bmatrix} 0.23 & 0.29 \\ 0.38 & 0.39 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}$ dependendo do fato de n ser par ou ímpar e

assim **não existe** o limite da matriz P^n.

$$P^{21} = \begin{bmatrix} 0.4 & 0.6 & 0 & 0 & 0 & 0 \\ 0.4 & 0.6 & 0 & 0 & 0 & 0 \\ 0.1882 & 0.2824 & 0 & 0 & 0.2353 & 0.2941 \\ 0.1647 & 0.2471 & 0 & 0 & 0.3824 & 0.2059 \\ 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 1 & 0 \end{bmatrix}$$

$$P^{40} = \begin{bmatrix} 0.4 & 0.6 & 0 & 0 & 0 & 0 \\ 0.4 & 0.6 & 0 & 0 & 0 & 0 \\ 0.1882 & 0.2824 & 0 & 0 & 0.2941 & 0.2353 \\ 0.1647 & 0.2471 & 0 & 0 & 0.2059 & 0.3824 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

$$P^{41} = \begin{bmatrix} 0.4 & 0.6 & 0 & 0 & 0 & 0 \\ 0.4 & 0.6 & 0 & 0 & 0 & 0 \\ 0.1882 & 0.2824 & 0 & 0 & 0.2353 & 0.2941 \\ 0.1647 & 0.2471 & 0 & 0 & 0.3824 & 0.059 \\ 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 1 & 0 \end{bmatrix}$$

Exemplo 3.8.5.
Existe apenas mais um caso possível, que ocorre quando o **número de estados é infinito**. Neste caso é possível que **todos** os estados sejam **transientes** ou **nulo recorrentes**, e $\lim_{n\to\infty} P_{ij}^{(n)} = 0 \ \forall i, j$.

Por exemplo, considere a cadeia de Markov determinística descrita por $X_n = X_0 + n$. A matriz de transição é:

$$P = \begin{array}{c} \\ 0 \\ 1 \\ 2 \\ 3 \\ \cdot \end{array} \begin{array}{c} \begin{array}{ccccc} 0 & 1 & 2 & 3 & \cdots\cdots \end{array} \\ \begin{bmatrix} 0 & 1 & 0 & 0 & \cdots\cdots \\ 0 & 0 & 1 & 0 & \cdots\cdots \\ 0 & 0 & 0 & 1 & \cdots\cdots \\ 0 & 0 & 0 & 0 & \cdots\cdots \\ \cdots & \cdots & \cdots & \cdots & \cdots\cdots \end{bmatrix} \end{array}$$

Todos os estados são **transientes** e:

$$\lim_{n\to\infty} P_{ij}^{(n)} = \lim_{n\to\infty} Pr[X_n = j | X_0 = i] = 0 \quad \forall i, j$$

Nota:
Se o número de estados é **finito**, por exemplo, $M < \infty$, **não existem estados nulo recorrentes**, e **nem todos os estados podem ser transientes**.

Na verdade, como $\sum_{j=0}^{M-1} P_{ij}^{(n)} = 1$ para todo j, não pode acontecer de $\lim P_{ij}^{(n)} = 0$ para todo j.

Assim, uma cadeia de Markov com espaço de estados **finito** tem **pelo menos um** estado recorrente.

Exemplo 3.8.6.

$$P = \begin{array}{c} \\ 0 \\ 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{array} \begin{array}{c} \begin{array}{cccccc} 0 & 1 & 2 & 3 & 4 & 5 \end{array} \\ \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 1/4 & 1/2 & 1/4 & 0 & 0 & 0 \\ 0 & 1/5 & 2/5 & 1/5 & 0 & 1/5 \\ 0 & 0 & 0 & 1/6 & 1/3 & 1/2 \\ 0 & 0 & 0 & 1/2 & 0 & 1/2 \\ 0 & 0 & 0 & 1/4 & 0 & 3/4 \end{bmatrix} \end{array}$$

As classes são: {0}, {1,2}, {3,4,5}. Note que {0} é uma classe recorrente, {3,4,5} também é recorrente, mas {1,2} é transiente.

Seja $T = \text{mín}\{n \geq 0: X_T = 0 \text{ ou } X_T = 3 \text{ ou } X_T = 4 \text{ ou } X_T = 5\}$. T é o tempo mínimo até uma absorção. Seja $u_i = Pr[X_T = 0 | X_0 = i]$ para i = 1, 2, a probabilidade de absorção pelo estado zero quando o estado inicial é i (um dos estados transientes).

Pela análise do primeiro passo:

$$\left.\begin{aligned} u_1 &= \frac{1}{4} + \frac{1}{2}u_1 + \frac{1}{4}u_2 \\ u_2 &= 0 + \frac{1}{5}u_1 + \frac{2}{5}u_2 \end{aligned}\right\} \Rightarrow u_1 = 3/5; u_2 = 1/5$$

A distribuição estacionária da classe {3,4,5} é (π_3, π_4, π_5), e estas probabilidades são encontradas através da solução do sistema:

$$\begin{pmatrix} 1/6 & 1/2 & 1/4 \\ 1/3 & 0 & 0 \\ 1/2 & 1/2 & 3/4 \end{pmatrix} \begin{pmatrix} \pi_3 \\ \pi_4 \\ \pi_5 \end{pmatrix} = \begin{pmatrix} \pi_3 \\ \pi_4 \\ \pi_5 \end{pmatrix}$$

Assim:
$\pi_3 = 1/4 = 0.25$
$\pi_4 = 1/12 = 0.0833...$
$\pi_5 = 2/3 = 0.666...$
Agora defina $w_i = Pr[X_T = 3, 4 \text{ ou } 5 | X_0 = i]$ para i = 1, 2, a probabilidade de

absorção pelos estados recorrentes 3, 4 ou 5 quando o estado inicial é o estado transiente i.

$$w_1 = \frac{1}{4}(0) + \frac{1}{2}w_1 + \frac{1}{4}w_2 + 0 + 0 + 0 \Rightarrow \frac{1}{2}w_1 = \frac{1}{4}w_2 \Rightarrow 2w_1 = w_2$$

Também:

$$w_2 = 0 + \frac{1}{5}w_1 + \frac{2}{5}w_2 + \frac{1}{5} + \frac{1}{5} \Rightarrow \frac{3}{5}w_2 = \frac{1}{5}w_1 + \frac{2}{5} \Rightarrow 3w_2 = w_1 + 2$$

A solução deste sistema é: $w_1 = 2/5$, $w_2 = 4/5$.

Note que w_1 e w_2 poderiam ter sido obtidos diretamente a partir de u_1 e u_2. Especificamente: $w_1 = 1 - u_1 = 1 - 3/5 = 2/5$ e $w_2 = 1 - u_2 = 1 - 1/5 = 4/5$. A matriz de transição limite é então:

$$P^* = \lim_{n\to\infty} P^n = \begin{array}{c} \\ 0 \\ 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{array} \begin{array}{c} \begin{array}{cccccc} 0 & 1 & 2 & 3 & 4 & 5 \end{array} \\ \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ u_1 & 0 & 0 & p_{13}^* & p_{14}^* & p_{15}^* \\ u_2 & 0 & 0 & p_{23}^* & p_{24}^* & p_{25}^* \\ 0 & 0 & 0 & \pi_3 & \pi_4 & \pi_5 \\ 0 & 0 & 0 & \pi_3 & \pi_4 & \pi_5 \\ 0 & 0 & 0 & \pi_3 & \pi_4 & \pi_5 \end{bmatrix} \end{array}$$

As probabilidades p_{13}^*, p_{14}^*, p_{15}^* e p_{23}^*, p_{24}^*, p_{25}^* são dadas por:

$p_{13}^* = w_1\pi_3 = 1/10 = 0.10$
$p_{14}^* = w_1\pi_4 = 1/30 = 0.03333...$
$p_{15}^* = w_1\pi_5 = 4/15 = 0.26666...$
$p_{23}^* = w_2\pi_3 = 1/5 = 0.20$
$p_{24}^* = w_2\pi_4 = 1/15 = 0.06666...$
$p_{25}^* = w_2\pi_5 = 8/15 = 0.5333...$

Finalmente encontramos a matriz limite:

$$P^* = \lim_{n\to\infty} P^n = \begin{array}{c} \\ 0 \\ 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{array} \begin{array}{c} \begin{array}{cccccc} 0 & 1 & 2 & 3 & 4 & 5 \end{array} \\ \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0.6 & 0 & 0 & 0.1 & 0.033 & 0.267 \\ 0.2 & 0 & 0 & 0.2 & 0.067 & 0.533 \\ 0 & 0 & 0 & 0.25 & 0.083 & 0.667 \\ 0 & 0 & 0 & 0.25 & 0.083 & 0.667 \\ 0 & 0 & 0 & 0.25 & 0.083 & 0.667 \end{bmatrix} \end{array}$$

A seguir, mostramos empiricamente que esta deve ser a matriz limite, calculando recursivamente as matrizes potência P^n.

$$P^2 = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0.375 & 0.3 & 0.225 & 0.05 & 0 & 0.05 \\ 0.05 & 0.18 & 0.21 & 0.163 & 0.067 & 0.33 \\ 0 & 0 & 0 & 0.319 & 0.056 & 0.625 \\ 0 & 0 & 0 & 0.208 & 0.167 & 0.625 \\ 0 & 0 & 0 & 0.229 & 0.083 & 0.688 \end{bmatrix}$$

$$P^3 = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0.45 & 0.195 & 0.165 & 0.066 & 0.017 & 0.108 \\ 0.095 & 0.132 & 0.129 & 0.185 & 0.054 & 0.405 \\ 0 & 0 & 0 & 0.237 & 0.106 & 0.656 \\ 0 & 0 & 0 & 0.274 & 0.069 & 0.656 \\ 0 & 0 & 0 & 0.252 & 0.076 & 0.672 \end{bmatrix}$$

$$P^{60} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0.6 & 0 & 0 & 0.1 & 0.033 & 0.267 \\ 0.2 & 0 & 0 & 0.2 & 0.067 & 0.533 \\ 0 & 0 & 0 & 0.25 & 0.083 & 0.667 \\ 0 & 0 & 0 & 0.25 & 0.083 & 0.667 \\ 0 & 0 & 0 & 0.25 & 0.083 & 0.667 \end{bmatrix}$$

$$P^{65} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0.6 & 0 & 0 & 0.1 & 0.033 & 0.267 \\ 0.2 & 0 & 0 & 0.2 & 0.067 & 0.533 \\ 0 & 0 & 0 & 0.25 & 0.083 & 0.667 \\ 0 & 0 & 0 & 0.25 & 0.083 & 0.667 \\ 0 & 0 & 0 & 0.25 & 0.083 & 0.667 \end{bmatrix}$$

Empiricamente este é o valor encontrado para o limite da matriz de transição.

Exemplo 3.8.7.
Considere a cadeia de Markov descrita pela seguinte matriz de transição:

$$P = \begin{array}{c} \\ 0 \\ 1 \\ 2 \\ 4 \end{array} \begin{array}{c} \begin{array}{cccc} 0 & 1 & 2 & 3 \end{array} \\ \begin{bmatrix} 0 & 1/2 & 1/2 & 0 \\ 1/4 & 1/4 & 1/4 & 1/4 \\ 1/4 & 3/4 & 0 & 0 \\ 1/2 & 0 & 0 & 1/2 \end{bmatrix} \end{array}$$

Todos os estados se comunicam, logo a cadeia é **irredutível**. Então todos os estados são positivo recorrentes, e também são aperiódicos, e assim existe a

distribuição limite. A distribuição limite coincide com a distribuição estacionária $(\pi_0, \pi_1, \pi_2, \pi_3)$, que satisfaz:

$$\pi_0 = \frac{1}{4}\pi_1 + \frac{1}{4}\pi_2 + \frac{1}{2}\pi_3$$

$$\pi_1 = \frac{1}{2}\pi_0 + \frac{1}{4}\pi_1 + \frac{3}{4}\pi_2$$

$$\pi_2 = \frac{1}{2}\pi_0 + \frac{1}{4}\pi_1$$

$$\pi_3 = \frac{1}{4}\pi_1 + \frac{1}{2}\pi_3$$

A solução deste sistema é: $\begin{pmatrix}\pi_0\\ \pi_1\\ \pi_2\\ \pi_3\end{pmatrix} = \begin{pmatrix}9/38\\ 7/19\\ 4/19\\ 7/38\end{pmatrix} \approx \begin{pmatrix}0.2368\\ 0.3684\\ 0.2105\\ 0.1842\end{pmatrix}$

3.9. Exercícios - Capítulo 3

Problema 1
Num país existem 4 principais fabricantes de automóveis: FD, VW, GM, FT. Os "market shares" destes fabricantes são, respectivamente: 10%, 35%, 25 % e 30 %. A matriz de transição que representa a probabilidade de mudança de marca é dada a seguir:

$$P = \begin{bmatrix} P_{FD,FD} & P_{FD,VW} & P_{FD,GM} & P_{FD,FT} \\ P_{VW,FD} & P_{VW,VW} & P_{VW,GM} & P_{VW,FT} \\ P_{GM,FD} & P_{GM,VW} & P_{GM,GM} & P_{GM,FT} \\ P_{FT,FD} & P_{FT,VW} & P_{FT,GM} & P_{FT,FT} \end{bmatrix} = \begin{bmatrix} 0.6 & 0.1 & 0.2 & 0.1 \\ 0.1 & 0.7 & 0.1 & 0.1 \\ 0.15 & 0.05 & 0.75 & 0.05 \\ 0.05 & 0.35 & 0.25 & 0.35 \end{bmatrix}$$

Supondo que o instante inicial é t = 0 calcule:
a) Os market shares nos instantes t = 1 e t = 2.
b) A matriz de transição de 2, 3, 10, 20 e 30 estágios.
c) Baseado nos resultados de b), você consegue fazer alguma conjectura a respeito da existência de um limite para P^n?

Problema 2
Dois jogadores, A e B, entram num jogo de dados. A cada jogada, ganhos e perdas são calculados com base na soma de 2 dados. Se a soma dos dados é 7, nenhum jogador ganha ou perde nada. Se a soma dos dados é menor que 7, o jogador A recebe R$1 de B. Ao contrário, se a soma dos dados é maior que 7, o jogador A paga a B R$1. O jogo continua até que um dos jogadores não tenha mais dinheiro.

Inicialmente, ambos A e B possuem R$4 cada.

Seja X_n a "fortuna" do jogador A após a n-ésima jogada. Logo, 8 - X_n representa a "fortuna" do jogador B após a n-ésima jogada.

a) Escreva a matriz de transição neste processo (note que os estados 0 e 8) são absorventes.
b) Seja $p_j = Pr\ (X_0 = j)$. Note que, como o jogador A inicia o jogo com R$4 no bolso, $p_4 = 1$ e $p_j = 0$ para todo $j \neq 4$. Seja $p_j^{(n)} = Pr\ (X_n = j)$ para n = 1,2,3... Calcule estas probabilidades incondicionais $p_j^{(n)}$ para todos os estados nos instantes 1, 2, 3 e 4.

Dica: resolva isso de forma matricial!

c) Seja P a matriz de transição. Calcule P^5, P^{10}, P^{20}, P^{30} e investigue a existência de um limite para P^n.
d) Repita o item b) supondo que inicialmente (no instante t =0) o jogador A tem R$2 e o jogador B tem R$6.

Problema 3
O tempo num dia qualquer pode ser classificado como sol ou chuva. Suponha que o tempo, hoje, depende das condições dos **últimos 2 dias**. Mostre como este sistema pode ser analisado como uma cadeia de Markov. Quantos estados são necessários para esta representação?

Problema 4
Um fabricante de disquetes usa cadeias de Markov para ter uma idéia da lealdade dos consumidores a diversas marcas. Dados de uma pesquisa foram usados para estimar a seguinte matriz de transição que representa a probabilidade de mudança de marcas a cada mês. Suponha que existem 3 marcas principais, A, B e C.

$$P = \begin{bmatrix} P_{AA} & P_{AB} & P_{AC} \\ P_{BA} & P_{BB} & P_{BC} \\ P_{CA} & P_{CB} & P_{CC} \end{bmatrix} = \begin{bmatrix} 0.80 & 0.10 & 0.10 \\ 0.03 & 0.95 & 0.02 \\ 0.20 & 0.05 & 0.75 \end{bmatrix}$$

Os *market shares* das marcas A, B e C no instante inicial t = 1 são 45%, 25% e 30%.

a) Quais serão os *market shares* após 2 meses (isto é, em t = 3)?
b) Qual a previsão para os *market shares* "de equilíbrio", isto é, após um grande número de transições?

Problema 5
Compute a distribuição limite para uma cadeia de Markov com a seguinte matriz de transição:

$$P = \begin{bmatrix} 0.4 & 0.3 & 0.2 & 0.1 \\ 0 & 0.2 & 0.2 & 0.6 \\ 0 & 0 & 0.5 & 0.5 \\ 1 & 0 & 0 & 0 \end{bmatrix}$$

Problema 6
Considere um jogo como o do problema 2 e suponha que a cada jogada, a probabilidade do jogador A ganhar R$1 é 0.5. Os jogadores A e B têm, cada um, fortunas iniciais de R$100.

Simule 50 vezes 20 jogadas da moeda e veja, em cada uma, qual a fortuna do jogador A após as 20 jogadas. Plote também a trajetória das 5 simulações que você considerar mais interessantes. Baseado nestas 50 simulações você consegue fazer alguma conjectura sobre quais são os valores mais prováveis da "fortuna" de A após as 20 jogadas? Uma boa maneira de inferir sobre isso é fazer um gráfico de barras (histograma) a partir do resultado das 50 simulações.

Note que, a cada jogada, a "fortuna" de A aumenta R$1 ou diminui R$1, e assim basta simular uma variável binária, com valores + 1 e -1, e considerar a soma destas variáveis para 20 jogadas.

Problema 7
É apenas uma extensão mais trabalhosa do Problema 6. Resolva usando alguma linguagem de programação (sugiro o Matlab). Você trabalha num banco e atua no mercado de capitais administrando uma carteira de investimentos. Você acha que descobriu a forma de ganhar mais dinheiro que todo o mercado. A cada dia, o retorno do seu portfólio é de +0.2% como probabilidade 0.55 e de -0.2% com probabilidade 0.45 e o retorno obtido hoje é independente do de amanhã.

Em outras palavras, o retorno diário do seu portfólio é uma variável binária com valores + 0.2% e - 0.2% e probabilidades 0.55 e 0.45.

Você quer saber qual a "cara" do seu portfólio em 2 semanas (10 dias) e por isso decide fazer uma simulação destes retornos.

Você simula 500 vezes a trajetória dos retornos em 10 dias. Em cada uma destas simulações você vai obter o retorno nos dias 1, 2, 3..., 10.

Defina o retorno na escala do logaritmo, isto é, o retorno entre os dias t e t+1 é:

$R_{t+1} = \log\left(\frac{P_{t+1}}{P_t}\right)$ onde P_t denota o valor da sua carteira no instante t. Neste caso estamos supondo que, a cada instante de tempo t, o retorno só pode ser +0.2% ou -0.2%.

Note que:

$$R_1 + R_2 + \ldots + R_{t+1} = \log\left(\frac{P_1}{P_0}\right) + \log\left(\frac{P_2}{P_1}\right) + \ldots + \log\left(\frac{P_{t+1}}{P_t}\right) =$$

$$= \log\left\{\left(\frac{P_1}{P_0}\right)\left(\frac{P_2}{P_1}\right)\ldots\left(\frac{P_{t+1}}{P_t}\right)\right\} = \log\left(\frac{P_{t+1}}{P_0}\right)$$

Ou seja, a soma dos retornos logarítmicos é apenas o retorno computado entre o instante inicial 0 e o instante final t +1.

Suponha que, no instante inicial (zero), o seu portfólio vale P_0 = R$100. A soma dos retornos simulados entre os instantes 1 e 10 nos dá o valor simulado do seu portfólio no instante 10 (P_{10}).

Para cada uma das 500 simulações de 10 retornos, calcule o valor do portfólio simulado e faça um histograma (gráfico de barras) com os preços obtidos pela simulação. Quais são os valores mais prováveis do portfólio?

Problema 8
O órgão do governo que cuida do imposto de renda num determinado país decidiu inovar seus métodos de combate à sonegação. Por experiência dos anos anteriores, os fiscais conseguiram chegar às seguintes características para a evolução, de um ano para outro, do patrimônio dos contribuintes pessoa física.
Os contribuintes são classificados, de acordo com patrimônio, em 5 faixas ou "estados":

faixa 1 - patrimônio abaixo de 50 mil reais;
faixa 2 - patrimônio entre 51 mil e 100 mil reais;
faixa 3 - patrimônio entre 101 mil e 200 mil reais;
faixa 4 - patrimônio entre 201 mil e 400 mil reais;
faixa 5 - patrimônio acima de 401 mil reais.

A matriz de transição é:

$$P = \begin{bmatrix} 0.90 & 0.05 & 0.02 & 0.03 & 0 \\ 0.25 & 0.55 & 0.15 & 0.03 & 0.02 \\ 0.05 & 0.15 & 0.60 & 0.15 & 0.05 \\ 0 & 0.03 & 0.22 & 0.65 & 0.10 \\ 0 & 0 & 0.05 & 0.15 & 0.80 \end{bmatrix}$$

A distribuição inicial de probabilidade dos contribuintes é:
(65%, 20%, 10%, 4%, 1%), isto é, a probabilidade do patrimônio de um contribuinte estar abaixo de 50 mil reais é 65%.

Se, de um ano para o outro, um contribuinte **muda** para a faixa 5 ou para a faixa 1, ele automaticamente cai na "malha fina" e terá sua declaração verificada com maior rigor.
Supondo que o instante inicial é t = 0 calcule:
a) A distribuição dos contribuintes por faixas nos instantes t = 1 e t = 2.
b) A matriz de transição de 2, 3, 10, 20 e 30 estágios.
c) Baseado nos resultados de b), você consegue fazer alguma conjectura a respeito da existência de um limite para P^n?

Problema 9
Uma partícula se move num círculo por pontos numerados com 0, 1, 2 dispostos na ordem dos ponteiros do relógio. A cada passo há uma probabilidade p da partícula se mover para a direita e (1-p) dela se mover para a esquerda. Seja X_t a posição no círculo após t passos, onde t = 0, 1, 2... O processo $\{X_t: t = 0, 1, 2, 3...\}$ é uma cadeia de Markov.

a) Ache a matriz de transição desta cadeia.
b) Calcule as probabilidades limite.

Problema 10
Numa grande empresa os funcionários podem ocupar 3 tipos de cargos: administrativos, técnicos e gerenciais. Seja X_n o "estado" (em termos de cargo ocupado) de um funcionário, onde $X_n = 0, 1, 2$ indicam, respectivamente, cargos administrativos, técnicos e gerenciais. A cada ano, a migração entre cargos ocorre segundo uma cadeia de Markov com matriz de transição:

$$P = \begin{bmatrix} 0.60 & 0.35 & 0.05 \\ 0.05 & 0.65 & 0.30 \\ 0 & 0.20 & 0.80 \end{bmatrix}$$

a) Calcule a distribuição estacionária.
b) Suponha que, hoje, as proporções de funcionários nos cargos administrativo, técnico e gerencial são, respectivamente, 50%, 35% e 15%. Como serão estas proporções daqui a 4 anos?

Problema 11
Uma cadeia de Markov nos estados {0, 1, 2, 3} tem matriz de transição:

$$P = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 1/2 & 0 & 1/2 & 0 \\ 0 & 1/3 & 0 & 2/3 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

Os estados 0 e 3 são absorventes, e C = {1,2} é uma classe transiente e irredutível. Suponha que a cadeia está inicialmente no estado 1. Determine:

a) A probabilidade da cadeia eventualmente parar no estado zero.
b) O tempo médio necessário para sair da classe C.

Problema 12
Considere uma cadeia de Markov com espaço de estados S = {0, 1, 2..., 6} e matriz de transição:

$$P = \begin{bmatrix} 0.5 & 0 & 0.125 & 0.25 & 0.125 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0.5 & 0 & 0.5 \\ 0 & 0 & 0 & 0 & 0.5 & 0.5 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0.5 & 0.5 \end{bmatrix}$$

a) Calcule (usando o computador, é claro!) P^{20}, P^{30}, P^{31}, P^{32}.
b) Determine as classes e indique quais estados são recorrentes e quais são transientes.

Problema 13
Considere uma cadeia de Markov com espaço de estados S = {0, 1, 2..., 5} e matriz de transição:

$$P = \begin{bmatrix} 0.5 & 0.5 & 0 & 0 & 0 & 0 \\ 1/3 & 2/3 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1/8 & 0 & 7/8 & 0 \\ 1/4 & 1/4 & 0 & 0 & 1/4 & 1/4 \\ 0 & 0 & 3/4 & 0 & 1/4 & 0 \\ 0 & 1/5 & 0 & 1/5 & 1/5 & 2/5 \end{bmatrix}$$

a) Calcule (usando um computador, é claro!) P^{20}, P^{30}, P^{31}, P^{32}.
b) Determine as classes e indique quais estados são recorrentes e quais são transientes.

Problema 14
Considere uma cadeia de Markov nos estados 0, 1, 2, 3, 4. Suponha que $P_{04} = 1$ e se a cadeia está no estado i (onde $i > 0$), a probabilidade de passar para qualquer um dos estados 0, 1..., $i-1$ é igual. Encontre as probabilidades limite desta cadeia.

Problema 15
Considere uma cadeia de Markov nos estados {1, 2, 3} com matriz de transição:

$$P = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 2/3 & 1/3 \\ p & 1-p & 0 \end{bmatrix}$$

Calcule $Pr\{X_n = 2 \mid X_0 = 2\}$ e $Pr\{X_n = 3 \mid X_0 = 2\}$nos seguintes casos: p = 1/16, p = 1/12, p = ¼, p = 1/2.

Problema 16
Determine a matriz de transição para a cadeia de Markov gerada pelo seguinte experimento: N bolas brancas e N bolas pretas são colocadas em duas caixas de tal forma que cada caixa contenha N bolas. A cada passo uma bola é selecionada aleatoriamente de cada caixa e trocam-se as bolas de uma caixa para a outra. O estado do sistema é o número de bolas brancas na primeira caixa.

Problema 17
Todas as vezes que uma empresa ou governo lança papéis no mercado financeiro, é interessante que estes títulos sejam classificados por empresas independentes (agências de "rating" ou classificação de risco). A classificação (ou "rating") por uma das agências internacionais dá maior credibilidade ao papel que está sendo lançado e permite que se possa compará-lo a outros papéis, em termos de risco. As principais agências internacionais de "rating" são a Standard & Poors, Moody's e Duff & Phelps. Por exemplo, os papéis emitidos por governos dos países também estão sujeitos a este tipo de classificação, e a conseqüência de um rebaixamento ("rating" se torna menor) é um aumento da taxa de juros a ser paga pelo título, pois a percepção de que aquele papel é

arriscado aumenta, e os investidores passam a exigir maior retorno para comprar o papel. Quanto maior o "rating" (nota, ou classificação), menos arriscado é o papel ou título; e os papéis com mais alta classificação (e menor risco) são os títulos do Tesouro dos EUA. Na verdade, alguns investidores institucionais, como fundos de pensão nos EUA, só podem comprar títulos com classificação maior que algum nível pré-especificado, pois são impedidos por lei de aplicar o dinheiro de seus cotistas em investimentos excessivamente arriscados.

Suponha que uma agência classifique os títulos emitidos por países em 6 categorias: A1, A2, B1, B2, B3, C. A categoria menos arriscada é a A1 e a mais arriscada é C. Suponha que mensalmente a agência de classificação publique os "ratings" para os diversos títulos, e que o processo que rege a passagem de um estado (classificação) para outro seja uma Cadeia de Markov com a seguinte matriz de transição:

$$P = \begin{bmatrix} 0.99 & 0.01 & 0 & 0 & 0 \\ 0.02 & 0.94 & 0.04 & 0 & 0 \\ 0.01 & 0.03 & 0.90 & 0.06 & 0 \\ 0.01 & 0.01 & 0.05 & 0.87 & 0.06 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

No instante inicial t = 0, as probabilidades de um título serem classificadas como A1, A2, B1, B2, B3 e C são, respectivamente: 10%, 12%, 18%, 20%, 30% e 10%. Calcule:

a) As probabilidades em cada categoria de risco nos instantes t = 1 e t = 2.
b) A matriz de transição de 2, 3, 10, 20 e 30 estágios.
c) Baseado nos resultados de b), você consegue fazer alguma conjectura a respeito da existência de um limite para P^n?

Problema 18
Considere uma cadeia de Markov com estados 0, 1, 2 e 3 e matriz de transição dada por:

$$P = \begin{bmatrix} 0 & 3/4 & 1/4 & 0 \\ 0 & 0 & 1 & 0 \\ 1/2 & 1/4 & 1/4 & 0 \\ 1/4 & 1/4 & 1/4 & 1/4 \end{bmatrix}$$

a) Calcule a distribuição estacionária (π_0, π_1, π_2, π_3) e escreva explicitamente o limite quando n tende a infinito de P^n.
b) Calcule a distribuição de probabilidade do primeiro instante de retorno ao estado zero, isto é, calcule:

$f_{00}^{(n)} = Pr\{X_n = 0, X_v \neq 0, v = 1, 2, ..., n-1 | X_0 = 0\}$ para n = 1,2,3,4,5.
Dica: neste item você vai precisar calcular a 1ª linha (ou 1ª coluna) das matrizes P, P^2, P^3, P^4 e P^5 para computar $P_{00}^{(n)}$.

Problema 19
Considere a cadeia de Markov com a seguinte matriz de transição:

$$P = \begin{bmatrix} 1/4 & 3/4 & 0 & 0 & 0 \\ 1/2 & 1/2 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 1/4 & 0 & 1/4 & 1/4 & 1/4 \\ 0 & 1/2 & 1/4 & 1/4 & 0 \end{bmatrix}$$

a) as classes.
b) Seja T= Determine mín$\{t \geq 0: X_t = 0$ ou $X_t = 1$ ou $X_t = 2\}$.
Calcule:
- $u_3 = Pr\{X_T = 0$ ou $1 | X_0 = 3\}$
- $u_4 = Pr\{X_T = 0$ ou $1 | X_0 = 4\}$

c) Calcule $w_j = Pr\{X_T = 2 | X_0 = j\}$ para j = 3, 4
d) Calcule lim P^n (quando $n \to \infty$)

Problema 20
Uma pessoa tem r guarda-chuvas que são usados no trajeto entre a sua casa e o trabalho (em ambas as direções). Esta pessoa usará um guarda-chuva sempre que estiver chovendo e ela tiver que se deslocar de casa para o escritório (e vice versa). Ao contrário, se não estiver chovendo, a pessoa não levará um guarda-chuva.

Suponha que chova, no início ou no final do dia, com probabilidade p, independente do que ocorreu no passado.

a) Defina uma cadeia de Markov com r + 1 estados que nos permita calcular a proporção do tempo em que está pessoa tomará chuva (pois está chovendo e todos os guarda-chuvas ficaram no outro lugar).
b) Mostre que as probabilidades limite nesta cadeia são:

$$\pi_i = \begin{cases} \dfrac{1-p}{r+1-p} & \text{se } i = 0 \\ \dfrac{1}{r+1-p} & \text{se } i = 1, 2, ..., r \end{cases}$$

c) Em que proporção do tempo esta pessoa se molha com a chuva?
d) Se o número total de guarda-chuvas é 5, qual o valor de p que maximiza a proporção do tempo em que a pessoa se molha com a chuva?

Problema 21
Considere a cadeia de Markov com a seguinte matriz de transição:

$$P = \begin{bmatrix} 0 & 0 & 1/3 & 2/3 \\ 0 & 0 & 1/4 & 3/4 \\ 1/4 & 3/4 & 0 & 0 \\ 1/2 & 1/2 & 0 & 0 \end{bmatrix}$$

Calcule a distribuição estacionária e explique por que não existe distribuição limite.

Problema 22
Considere a cadeia de Markov definida nos estados 0, 1, 2, 3 com matriz de transição:

$$P = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0.6 & 0 & 0.4 & 0 \\ 0 & 0.2 & 0.1 & 0.7 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

a) Calcule a probabilidade de ruína do jogador dado que o estado inicial é i, u_i.
b) Use os u_i's encontrados no item a) para calcular o limite de P^n quando n tende a infinito. Mostre empiricamente (através de potências altas de P) que a matriz limite é a que você encontrou.
c) Calcule W_{ik} (número médio de visitas ao estado transiente k quando a cadeia partiu do estado inicial i) para k = 1, 2 e i = 0, 1, 2, 3.
d) Calcule $v_i = E\{T \mid X_0 = i\}$ para i = 0, 1, 2, 3, a duração média do "jogo" representado por esta cadeia de Markov.

Problema 23
Considere a cadeia de Markov definida nos estados 0, 1, 2, 3 com matriz de transição:

$$P = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0.3 & 0.4 & 0.3 & 0 \\ 0 & 0.2 & 0.2 & 0.6 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

a) Calcule a probabilidade de ruína do jogador dado que o estado inicial é i, u_i.
b) Use os u_i's encontrados no item a) para calcular o limite de P^n quando n tende a infinito. Mostre empiricamente (através de potências altas de P) que a matriz limite é a que você encontrou.
c) Calcule W_{ik} (número médio de visitas ao estado transiente k quando a cadeia partiu do estado inicial i) para k = 1, 2 e i = 0, 1, 2, 3.
d) Calcule $v_i = E\{T \mid X_0 = i\}$ para i = 0, 1, 2, 3, a duração média do "jogo" representado por esta cadeia de Markov.

Problema 24
Considere uma cadeia de Markov nos estados 0, 1, 2,...,9 e suponha que a matriz de transição é dada por:

$$P_{ij} = \begin{cases} 0.25 & \text{se } j = i-1 \\ 0.75 & \text{se } j = i+1 \\ 0 & \text{se } j \neq i-1, i+1 \end{cases} \quad \text{para } i = 1, 2, 3, \ldots, 8$$

e $P_{00} = P_{9,9} = 1$ (0 e 9 são estados absorventes).

a) Calcule o número médio de visitas ao estado k partindo do estado i (W_{ik}) para todo i e k um estado transiente.
b) Faça um gráfico de W_{1k}, W_{2k}, ..., W_{8k} versus k. Note que W_{0k} e W_{9k} são zero, por isso eu não pedi que você fizesse o gráfico!

c) Calcule $v_i = E\{T \mid X_0 = i\}$ para i = 1,2, ..., 8.
d) Calcule a probabilidade de ruína do jogador dado que o estado inicial é i, u_i.
e) Use os u_i's encontrados no item anterior para calcular o limite de P^n quando n tende a infinito. Mostre empiricamente (através de potências altas de P) que a matriz limite é a que você encontrou.

Problema 25
Considere uma cadeia de Markov nos estados 0, 1, 2,..., 9 e suponha que a matriz de transição é dada por:

$$P_{ij} = \begin{cases} 0.75 & \text{se } j = i-1 \\ 0.25 & \text{se } j = i+1 \\ 0 & \text{se } j \neq i-1, i+1 \end{cases} \quad \text{para } i = 1, 2, 3, \ldots, 8$$

e $P_{00} = P_{9,9} = 1$ (0 e 9 são estados absorventes).

a) Calcule o número médio de visitas ao estado k partindo do estado i (W_{ik}) para todo i e k um estado transiente.
b) Faça um gráfico de W_{1k}, W_{2k}, ..., W_{8k} versus k. Note que W_{0k} e W_{9k} são zero, por isso eu não pedi que você fizesse o gráfico!
c) Calcule $v_i = E\{T \mid X_0 = i\}$ para i = 1,2, ..., 8.
d) Calcule a probabilidade de ruína do jogador dado que o estado inicial é i, u_i.
e) Use os u_i's encontrados no item anterior para calcular o limite de P^n quando n tende a infinito. Mostre empiricamente (através de potências altas de P) que a matriz limite é a que você encontrou.

Problema 26
Determine $f_{00}^{(n)}$ e $f_{33}^{(n)}$ para n = 1,2..., 6 para a cadeia de Markov cuja matriz de transição é:

$$P = \begin{bmatrix} 0 & 0.25 & 0 & 0.75 \\ 0 & 0 & 0.25 & 0.75 \\ 0 & 0 & 0 & 1 \\ 0.5 & 0 & 0 & 0.5 \end{bmatrix}$$

Compare os valores de $f_{00}^{(n)}$, $f_{33}^{(n)}$ e os $P_{00}^{(n)}$, $P_{33}^{(n)}$ correspondentes.

Problema 27
Considere uma cadeia de Markov com espaço de estados S = {0, 1, 2..., 6} e matriz de transição:

$$P = \begin{bmatrix} 0.5 & 0.1 & 0.1 & 0.15 & 0.15 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0.9 & 0.1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0.4 & 0 & 0.6 \\ 0 & 0 & 0 & 0 & 0.5 & 0.5 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0.6 & 0.4 \end{bmatrix}$$

a) Calcule (usando o computador, é claro!) P^{20}, P^{30}, P^{31}, P^{32}.
b) Determine as classes e indique quais estados são recorrentes e quais são transientes.

Problema 28
Considere uma cadeia de Markov com espaço de estados S = {0, 1..., 5, 6, 7} e matriz de transição:

$$P = \begin{bmatrix} 0.5 & 0.3 & 0.2 & 0 & 0 & 0 & 0 & 0 \\ 0.3 & 0.4 & 0 & 0.3 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0.2 & 0 & 0.8 & 0 & 0 & 0 \\ 0.1 & 0.4 & 0 & 0 & 0.4 & 0.1 & 0 & 0 \\ 0 & 0 & 0.6 & 0 & 0.2 & 0.2 & 0 & 0 \\ 0 & 0.2 & 0 & 0.2 & 0.1 & 0.1 & 0.1 & 0.3 \\ 0.1 & 0.2 & 0.1 & 0.4 & 0.1 & 0 & 0 & 0.1 \\ 0 & 0 & 0.4 & 0 & 0 & 0.2 & 0.2 & 0.2 \end{bmatrix}$$

a) Calcule (via computador) P^{20}, P^{30}, P^{31}, P^{32}.
b) Determine as classes e indique quais estados são recorrentes e quais são transientes.
c) A partir do resultado do item c) indique quais classes têm distribuição estacionária. Existe distribuição limite?

Problema 29
Seja X_n, $n \geq 0$ uma cadeia de Markov nos estados {0, 1, 2, ...} com probabilidades de transição dadas por:

$p_{01} = 1$
$p_{i,i+1} + p_{i,i-1} = 1$
$p_{i,i+1} = \left(\frac{i+1}{i}\right)^2 p_{i,i-1}$ para $i \geq 1$.

Mostre que, se $X_0 = 0$ então a probabilidade de que $X_n \geq 1$ para todo $n \geq 1$ é $6/\pi^2$.

Problema 30
Considere uma cadeia de Markov irredutível com probabilidades de transição P_{ij} e probabilidades estacionárias π_j. Começando no estado 1, encontre o número esperado de transições até que o padrão 0, 0, 0, 1 ocorra.

CAPÍTULO 4: PROCESSOS DE POISSON

Neste capítulo apresentamos o Processo de Poisson, um processo estocástico de fácil derivação e com grande utilidade prática, que serve para modelar a ocorrência de eventos raros ou incomuns. Além disso, verificaremos que algumas importantes distribuições de probabilidade, como a Exponencial e a Gama, surgem no estudo destes processos.

O Processo de Poisson é um **processo estocástico contínuo com espaço de estados discretos**. Ou seja, se X(t) indica um processo de Poisson, t (o índice de tempos) pertence a um intervalo e para cada instante de tempo fixo t_0, $X(t_0)$ é uma variável aleatória discreta. Especificamente no caso do Processo de Poisson, X representa o número de ocorrências de um certo evento de interesse e, portanto, os valores possíveis de X são 0, 1, 2, 3... O Processo de Poisson **não é** um processo **estacionário**.

Um Processo de Poisson pode ser descrito por dois conjuntos de variáveis aleatórias, que correspondem a experiências aleatórias diferentes. O primeiro conjunto representa o **número de ocorrências** de um evento de interesse num intervalo de tempo especificado. O outro conjunto de variáveis indica o **instante de tempo** em que ocorre um evento de interesse e os instantes de tempo entre ocorrências. Estes dois conjuntos de variáveis são "complementares", pois um deles traz informações sobre o outro. Pode-se derivar o processo de Poisson dando mais ênfase a um ou outro conjunto. Aqui adotaremos o procedimento mais tradicional, em que explicitamos condições sobre o número de ocorrências.

4.1. A Distribuição Poisson

A distribuição de Poisson é usada para modelar o número de ocorrências de um evento "raro" (de probabilidade baixa) durante um intervalo de tempo especificado. Por exemplo, o número de acidentes numa estrada durante um fim de semana, o número de bactérias presentes numa solução após um certo período, o número de ataques terroristas a um país são, entre outros, eventos modelados pela distribuição de Poisson.

Além disso, (vide Capítulo 1) a distribuição de Poisson surge como um caso limite da distribuição Binomial (n, p) quando n é grande e p é pequeno (próximo de zero) e, neste contexto, é muito útil em aproximações numéricas, pois nesta situação é muito mais fácil calcular as probabilidades aproximadas Poisson que as probabilidades reais pela Binomial.

Definição 4.1.1.
Uma variável aleatória discreta X tem distribuição de Poisson com parâmetro λ, e escrevemos $X \sim$ Poisson (λ) se sua função de probabilidade é:

$$f(x) = Pr(X = x) = \frac{\lambda^x . e^{-\lambda}}{x!},\ x = 0, 1, 2, 3, \ldots \text{ e } \lambda > 0$$

Teorema 4.1.2.
Se $X \sim$ Poisson(λ) então:
$E(X) = \lambda$,
$VAR(X) = \lambda$ e

$$M(t) = E(e^{tX}) = e^{\lambda\left(e^t - 1\right)}$$

Demonstração (parcial)
O seguinte resultado é muito útil em quase todas as manipulações envolvendo a função de probabilidade Poisson:

$$e^x = \sum_{k=0}^{\infty}\left(\frac{x^k}{k!}\right) = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \ldots + \frac{x^k}{k!} + \ldots\ldots$$

Esta expressão é apenas a série de Taylor para a exponencial, e é válida para qualquer número real x. A média da variável aleatória X é, pela definição:

$$E(X) = \sum_{x=0}^{\infty}\frac{x.e^{-\lambda}.\lambda^x}{x!} = \sum_{x=1}^{\infty}\frac{x.e^{-\lambda}.\lambda^x}{x!} = e^{-\lambda}\sum_{x=1}^{\infty}\frac{\lambda^{x-1+1}}{(x-1)!} = \lambda e^{-\lambda}\sum_{x=1}^{\infty}\frac{\lambda^{x-1}}{(x-1)!} =$$

$$= \lambda.e^{-\lambda}.\sum_{k=0}^{\infty}\frac{\lambda^k}{k!} = \lambda.e^{-\lambda}.e^{\lambda} = \lambda$$

Prove os resultados para a variância e a função geradora de momentos!

Assim, para uma variável Poisson, a média e a variância são iguais entre si, e iguais a λ, o parâmetro da distribuição.

A função geradora de momentos é útil na demonstração do próximo teorema.

Teorema 4.1.3.
Sejam $X_1, X_2 \ldots, X_n$ variáveis aleatórias independentes, e suponha que $X_i \sim$ Poisson(λ_i). Seja $Y = X_1 + X_2 + \ldots + X_n$. Então Y tem distribuição Poisson com parâmetro $\lambda = \lambda_1 + \lambda_2 + \ldots + \lambda_n$.

Demonstração - faça como exercício usando as propriedade das funções geradoras de momentos de combinações lineares de variáveis independentes.

Em particular, se $X_1, X_2 \ldots, X_n$ são variáveis aleatórias independentes e

identicamente distribuídas Poisson (λ) então $Y = X_1 + X_2 + \ldots + X_n$ tem distribuição Poisson (n.λ) e E(Y) = VAR(Y) = n.λ.

Como usar a distribuição de Poisson na prática
Selecione um intervalo de tempo fixo. Conte o número de ocorrência de um certo evento de interesse neste intervalo. Este número de ocorrências é uma variável discreta com valores possíveis 0, 1, 2...

Se o evento é tal que a probabilidade do número de ocorrências no intervalo seja 0 ou 1 é "grande", então o evento pode ser na prática modelado pela distribuição de Poisson, que funciona bem para eventos "raros", isto é, que não acontecem com grande freqüência num intervalo de tempo fixo.

Por exemplo, o número de automóveis "populares" (com motores de 1000 cm^3) que entram num estacionamento no Rio de Janeiro num intervalo de uma hora certamente não é uma variável Poisson, mas o número de Ferraris que entram no estacionamento no mesmo período de tempo deve ser Poisson!

A distribuição Poisson surge também como aproximação de uma distribuição Binomial. Seja $X \sim$ Bin(n, p). Se n é grande e p está próximo de zero então probabilidades para valores de X podem ser calculadas usando-se a densidade Poisson com parâmetro λ = n.p.

A demonstração deste fato está além dos objetivos deste curso, e pode ser feita considerando-se o limite da função geradora de momentos da Binomial quando fazemos n tender a infinito e p tender a zero simultaneamente, de tal forma que o produto n.p seja mantido fixo.

Exemplo 4.1.4.
Os gráficos a seguir apresentam a aproximação Poisson para a distribuição Binomial em 2 casos:

1) Distribuição Binomial com n = 20 e p = 0.2 $\Rightarrow$ média = 4 $\Rightarrow$ compare com a distribuição Poisson com λ = 4;
2) Distribuição Binomial com n = 30 e p = 0.15 $\Rightarrow$ média = 4.5 $\Rightarrow$ compare com a distribuição Poisson com λ = 4.5;

média 4

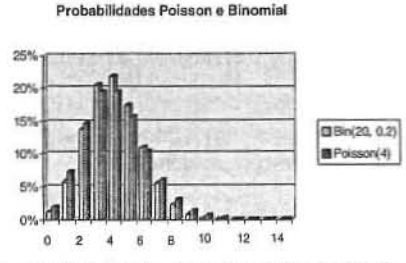

média 4.5

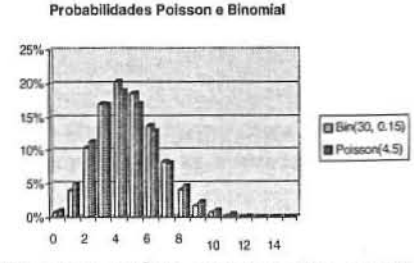

A qualidade da aproximação piora à medida que a média cresce muito, ou se o número de repetições da experiência Binomial for pequeno.

Exemplo 4.1.5.
O número de assaltos a banco numa cidade é uma variável aleatória com distribuição Poisson com média $\lambda = 3$ assaltos por mês. Calcule as seguintes probabilidades:
a) Do número de assaltos num mês ser maior que 4.
b) Do número de assaltos num mês ser menor que 2.

Solução
Seja $F(x) = Pr(X \leq x)$ a função de distribuição acumulada.
a) $Pr(X > 4) = Pr(X = 5) + Pr(X = 6) + Pr(X = 7) + \ldots =$
$1 - Pr(X \leq 4) = 1 - F(4) = 18.47\%$.
b) $Pr(X < 2) = Pr(X = 0) + Pr(X = 1) = Pr(X \leq 1) = F(1) = 19.91\%$.

Exemplo 4.1.6.
O número de enchentes numa certa cidade é uma variável aleatória Poisson. Após estudarmos os registros meteorológicos dos últimos 100 anos concluímos que, em média, ocorrem 18 enchentes a cada 5 anos, isto é, 3.6 enchentes por ano. Calcule a probabilidade de que o número de enchentes num ano seja maior que 5.

Solução
Seja X o número de enchentes num ano. Desejamos calcular:
$Pr(X > 5) = Pr(X = 6) + Pr(X = 7) + Pr(X = 8) + \ldots =$
$1 - Pr(X \leq 5) = 1 - F(5) = 1 - 0.8441 = 15.59\%$

4.2. Derivação do Processo de Poisson

Considere uma seqüência de eventos que ocorrem ao longo do tempo, como o número de carros vermelhos que pára num sinal, o número de chamadas telefônicas que chega a uma estação durante um certo intervalo de tempo, o número de erros de digitação numa página de livro etc...

Seja X_t o número de ocorrências no intervalo de tempo $[0,t]$. Claramente X_t é uma variável aleatória discreta com valores possíveis 0, 1, 2... O nosso objetivo é derivar a distribuição de probabilidade de X_t para um instante qualquer t, e assim caracterizar o que chamamos de processo de Poisson.

O processo estocástico $\{X_t: t \in T\}$ é um **processo de Poisson** se as seguintes **condições** são satisfeitas:

1) O número de ocorrências num intervalo de tempo $[t_1, t_2]$ é independente do número de ocorrências em qualquer outro intervalo de tempo disjunto;

2) O número de ocorrências num intervalo depende apenas do comprimento do intervalo;

Seja Δt um intervalo de tempo pequeno. Então:

3) A probabilidade de **exatamente uma ocorrência** em um intervalo de tempo Δt é aproximadamente $k.\Delta t$.

4) A probabilidade de **exatamente zero ocorrências** em um intervalo de tempo Δt é aproximadamente $1- k.\Delta t$.

5) A probabilidade de **duas ou mais ocorrências** em um intervalo de tempo Δt é igual a um certo
$o(\Delta t)$, onde $o(\Delta t)/\Delta t$ tende a zero à medida que Δt tende a zero.

Em outras palavras, a probabilidade de duas ou mais ocorrências em um intervalo de tempo Δt é um valor muito pequeno, e este valor decresce a zero mais rapidamente que o comprimento do intervalo Δt.

Estas premissas definem o tipo de processo estocástico que pode ser chamado de processo de Poisson.

O parâmetro k acima é um número real positivo, chamado de **taxa média de ocorrência**.

Para cada instante $t > 0$ seja:

$Pr(X_t = x) = p_X(t)$ onde $x = 0, 1, 2...$

Nosso objetivo é encontrar $p_X(t)$ para um instante genérico t. Note que, nesta notação, $p_0(t) = Pr(X_t = 0)$ e $p_0(t + \Delta t) = Pr(X_{t+\Delta t} = 0)$.

Fixando um instante qualquer t e aplicando a condição 4) acima nos dá:

$$p_0(t+\Delta t) \equiv [1 - k.\Delta t]\, p_0(t)$$

Subtraindo $p_0(t)$ de ambos os lados e dividindo o resultado por Δt leva a:

$$\frac{p_0(t+\Delta t) - p_0(t)}{\Delta t} \equiv -k.p_0(t)$$

Tomando-se o limite desta última expressão quando o comprimento do intervalo (Δt) tende a zero encontramos, do lado esquerdo, a derivada de $p_0(t)$. Isto nos dá a equação diferencial:

$$p_0'(t) = -k.p_0(t) \qquad (4.2.1)$$

Para $x > 0$ pode-se provar que as premissas resultam no seguinte sistema de equações diferenciais:

$$p_x'(t) = -k.p_x(t) + k.p_{x-1}(t) \qquad (4.2.2)$$

onde $x = 1, 2, 3...$

A solução do sistema dado por (4.2.1) e (4.2.2) é:

$$p_x(t) = \frac{(kt)^x . e^{-kt}}{x!} \quad \text{onde } x = 0, 1, 2, ... \qquad (4.2.3)$$

Para qualquer intervalo [0,t], se fixarmos t e fizermos $\lambda = k.t$ a equação acima reduz-se a:

$$Pr(X_t = x) = f(x) = \frac{\lambda^x . e^{-\lambda}}{x!} \quad \text{onde } x = 0, 1, 2, ...$$

Esta é a função de probabilidade Poisson com parâmetro $\lambda > 0$.

Também é importante ressaltar que a expressão (4.2.3) é válida para qualquer intervalo de tamanho t. Assim, para quaisquer instantes s e $t \geq 0$ temos:

$$Pr\{X_{t+s} - X_s = x\} = \frac{e^{-k.t} . (k.t)^x}{x!}$$

Em particular, se s = 0, esta última expressão torna-se (4.2.3).

Em resumo... Num processo de Poisson:

- $E\{X_t\} = \lambda.t$
- $Var\{X_t\} = \lambda.t$
- O espaço de estados é contável, o conjunto de inteiros ≥ 0
- O espaço paramétrico (instantes de tempo) é contínuo (pois $t \geq 0$)
- Se $t_0 < t_1 < t_2 < t_3 <...$ então as variáveis $\{X(t_1) - X(t_0)\}$, $\{X(t_2) - X(t_1)\}$... são independentes, e representam o número de ocorrências nos intervalos de tempo $[t_0, t_1]$, $[t_1, t_2]$...

Nota
Um processo de Poisson é um exemplo de um **processo de contagem** ("counting process", em inglês). Em geral, dizemos que um processo estocástico X(t) é um processo de contagem se X(t) representa o número total de ocorrências de um evento no intervalo [0,t]. Assim, um **processo de contagem satisfaz**:

- X(t) é inteiro ≥ 0
- Se $t_1 < t_2$ então $X(t_1) \leq X(t_2)$
- Se $t_1 < t_2$ então $X(t_2) - X(t_1)$ é o número de ocorrências no intervalo $[t_1, t_2]$

Exemplo 4.2.1.
Erros de digitação numa página de livro seguem um Processo de Poisson com taxa k = 0.5 erros por página. Queremos descobrir a probabilidade de pelo menos 10 erros em 18 páginas.

Solução
Seja X o número de erros em 18 páginas. Então X é uma variável aleatória Poisson com média $\lambda = (0.5)(18) = 9$. Assim, a probabilidade desejada é:
$Pr(X \geq 10) = 1 - Pr(X \leq 9) = 1 - F(9) = 1 - 0.5874 = 41.26\%$.

Exemplo 4.2.2.
A ocorrência de defeitos num cabo submarino segue um processo de Poisson com taxa 0.1 defeito por km.
a) Qual a probabilidade de não haver defeitos nos 2 primeiros quilômetros?
b) Dado que não houve defeito nos primeiros 2 km, qual a probabilidade condicional de não haver defeitos entre os km 2 e 3?

Solução
Seja X(t) o número de defeitos entre os quilômetros 0 e t.

a) $Pr(X(2) = 0) = \frac{e^{-0.1(2)}(0.2)^0}{0!} = e^{-0.2} = 81.87\%$

b) Como X(t) é um processo de Poisson, o número de ocorrências no intervalo de tempo [0,2] é independente do número de ocorrências em qualquer outro intervalo de tempo disjunto, por exemplo, [2,3]. Logo, a probabilidade condicional do número de ocorrências em [2,3] dado o número de ocorrências em [0,2] é igual à probabilidade incondicional em [2,3], isto é, só depende do comprimento do intervalo, e não depende do que ocorreu no passado. Em termos algébricos:

$Pr\{X(3) - X(2) = 0 \mid X(2) - X(0) = 0\} = Pr\{X(3) - X(2) = 0\} = e^{-0.1} = 90.48\%$

Exemplo 4.2.3.
A chegada de clientes numa loja segue um processo de Poisson com taxa $\lambda = 4$ clientes por hora. Dado que a loja abre às 9 horas, qual a probabilidade de que exatamente 1 pessoa tenha chegado até 9:30 **e** de que 5 pessoas tenham chegado até 11:30?

Solução
Seja t o tempo em horas a partir de 9 horas. Queremos achar a seguinte probabilidade: $Pr\{X(1/2) = 1 \text{ e } X(5/2) = 5\}$.

Mas, note que os eventos $\{X(5/2) - X(1/2) = 4\}$ e $\{X(1/2) - X(0) = 1\}$ são independentes, pois os intervalos de tempo são disjuntos. Logo:

$Pr\{X(1/2) = 1 \text{ e } X(5/2) = 5\} = Pr\{X(1/2) = 1 \text{ e } X(5/2) - X(1/2) = 4\} =$

$= Pr\{X(1/2) = 1\}. Pr\{X(5/2) - X(1/2) = 4\} = \frac{e^{-4(1/2)}(2)}{1!} . \frac{e^{-4(2)}(8)^4}{4!} = 1.5\%$

As próximas definições têm um caráter mais teórico e são importantes porque nos permitem reformular a definição de um processo de Poisson.

Definição 4.2.4.
Uma função f(.) é uma função de ordem o(h) se:

$$\lim_{h\to 0} \frac{f(h)}{h} = 0$$

Ou seja, uma função é o(h) se ela vai para zero (quando h vai para zero) mais rápido que h. Por exemplo, $f(x) = x^2, x^3, x^4...$ são todas o(x), mas $f(x) = \sqrt{x}$ **não é** o(x). Uma característica importante de funções o(h) é que combinações lineares finitas destas funções mantêm a propriedade o(h).

Logo, se $f_1, f_2..., f_n$ são todas o(h) e $c_1, c_2..., c_n$ são constantes quaisquer então $f(x) = \sum_{i=1}^{n} c_i.f_i(x)$ é também o(h). Esta afirmação pode ser facilmente verificada a partir das propriedades dos limites de funções.

Definição 4.2.5. Processo Com Incrementos Estacionários
Um processo de contagem X(t) tem **incrementos estacionários** se o número de eventos que ocorre em qualquer intervalo de tempo depende apenas do tamanho do intervalo de tempo.

Desta definição segue que, num processo com incrementos estacionários, o número de ocorrências no intervalo $[t_1 + s, t_2 + s]$ tem a mesma distribuição de probabilidade que o número de ocorrências em $[t_1, t_2]$, pois ambos os intervalos têm a mesma largura.

Na prática...

A hipótese de o processo ter incrementos estacionários é razoável quando o número de ocorrências não depende, por exemplo, do horário, isto é, não existe um efeito de "hora do rush".

Definição 4.2.6. Processo com Incrementos Independentes
Um processo de contagem X(t) tem **incrementos independentes** se os números de ocorrências em intervalos de tempo disjuntos são variáveis aleatórias independentes.

Assim, se um processo tem incrementos independentes, o número de ocorrências até o instante t (dado por X(t)) é independente do número de ocorrências entre os instantes t e t +s, isto é, X(t) é independente de {X(t +s) - X(t)}.

Exemplo 4.2.7.
Seja X(t) o número de pessoas que entra numa loja entre 9 horas e 9 + t horas. X(t) é obviamente um processo de contagem, no qual cada evento corresponde à entrada de uma pessoa na loja. A hipótese de incrementos independentes parece razoável, mas a hipótese de incrementos estacionários só é razoável se o movimento de entrada de clientes na loja não apresenta horários de "pico". Do contrário, a hipótese de incrementos estacionários é falsa.

Estas definições nos permitem reescrever um Processo de Poisson de uma maneira alternativa. No entanto, a demonstração de que a definição a seguir é equivalente às condições usadas antes para descrever um processo de Poisson foge aos nossos objetivos e será omitida.

Definição 4.2.8. Processo de Poisson
O processo de contagem $\{X(t): t \geq 0\}$ é um processo de Poisson com taxa média de ocorrência k se:

a) $X(0) = 0$;
b) O processo tem incrementos independentes;
c) O número de eventos em qualquer intervalo de duração t tem a distribuição Poisson com média k.t. Logo, para quaisquer instantes s e $t \geq 0$ temos:

$$\Pr\{X(t+s) - X(s) = x\} = \frac{(k.t)^x e^{-k.t}}{x!}, x = 0,1,2,3...$$

d) Em particular, se s = 0 na expressão acima temos:

$$\Pr\{X(t) = x\} = \frac{(k.t)^x e^{-k.t}}{x!}, x = 0,1,2,3...$$

Na prática não fica claro como fazer para determinar se a condição c) na definição acima é válida. Assim, seria interessante encontrar uma definição equivalente de um processo de Poisson, que evitasse a necessidade de verificar as condições a) a d) na definição 4.2.8.

Definição 4.2.9. Definição Alternativa de um Processo de Poisson
O processo de contagem $\{X(t): t \geq 0\}$ é um processo de Poisson com taxa média de ocorrência k se:

i) $X(0) = 0$;
ii) O processo tem incrementos estacionários e independentes;
iii) $\Pr\{X(\Delta t) = 1\} = k.\Delta t + o(\Delta t)$
iv) $\Pr\{X(\Delta t) \geq 2\} = o(\Delta t)$

Note que, pelo item iv) desta definição, a probabilidade de encontrar 2 ou mais ocorrências num intervalo de comprimento "pequeno" Δt é $o(\Delta t)$, ou seja, é também pequena.

4.3. Tempos de Espera e Tempos entre Ocorrências

Considere um Processo de Poisson $\{X(t): t \geq 0\}$. Até agora estivemos interessados em computar a probabilidade de ocorrência de eventos dentro de um intervalo de tempo especificado, sem qualquer preocupação com os instantes de tempo em que os eventos ocorriam. Ou seja, estávamos interessados em computar $\Pr\{X(t) = n\}$ para valores especificados de n e t era suposto um instante de tempo conhecido.

Agora mudamos de enfoque. Um processo de Poisson também pode ser caracterizado em termos dos tempos de chegada (instantes em que ocorrem os even-

tos) e pelos tempos entre a ocorrência de eventos. A seguir, estudamos as distribuições destas variáveis aleatórias.

Definição 4.3.1. Tempos Entre Ocorrências
Seja T_1 o instante de tempo no qual ocorre o primeiro evento. Para $n > 1$, seja T_n o tempo entre as ocorrências do (n-1)-ésimo e o n-ésimo eventos. A seqüência $\{T_n: n = 1, 2, 3...\}$ é chamada de seqüência de tempos entre ocorrências.

Por exemplo, se $T_1 = 5$, $T_2 = 7$ e $T_3 = 4$, o primeiro evento ocorreu no instante 5, o segundo evento ocorreu no instante 12 e o terceiro ocorreu no instante 16.

Qual a distribuição de probabilidade dos tempos entre ocorrências?

Note que:
1) $T_1 > t \Leftrightarrow$ não existiram eventos no intervalo (0, t};
2) $Pr\{T_1 > t\} = Pr\{X(t) = 0\} = e^{-\lambda.t}$ onde X(t) é um Processo de Poisson com taxa λ.
3) Assim, a função de distribuição acumulada da variável T_1 é:
4) $Pr\{T_1 \leq t\} = 1 - Pr\{T_1 > t\} = 1 - e^{-\lambda.t}$ e, portanto, **T_1 tem densidade Exponencial** com média $1/\lambda$.

Podemos usar o mesmo tipo de argumentos para derivar a função de distribuição de T_2. Note que: $Pr\{T_2 > t\} = E\{Pr\{T_2 > t \mid T_1\}\}$. Mas: $Pr\{T_2 > t \mid T_1 = s\}$ indica que o primeiro evento ocorreu no instante s e a ocorrência do segundo demorou mais de s+ t instantes.

Logo, **não** ocorreram eventos no intervalo (s, s + t] e assim $Pr\{T_2 > t \mid T_1 = s\}$ = Pr {0 eventos em (s, s +t] | $T_1 = s$} = Pr {0 eventos em (s, s +t]}, o que decorre do fato do processo ter incrementos independentes e estacionários.

Assim:
$Pr\{0$ eventos em (s, s +t]$\} = e^{-\lambda.t}$ e então segue que T_2 também tem distribuição Exponencial com média $1/\lambda$.

Além disso, T_1 e T_2 são independentes. Isso nos leva à seguinte proposição, que não será demonstrada.

Proposição 4.3.2.
Os **tempos entre ocorrências** $\{T_n: n = 1, 2, 3...\}$ num Processo de Poisson são variáveis aleatórias independentes e identicamente distribuídas com **densidade Exponencial** e parâmetro λ.

Note que, como os tempos entre ocorrência são iid Exponencial, **não existe memória** na distribuição dos instantes entre ocorrências. Isto segue diretamente da hipótese de incrementos estacionários e independentes, pois em termos probabilísticos estas hipóteses expressam o fato do processo de Poisson se reinicializar a cada instante.

Definição 4.3.3. Tempo de Espera
O tempo de espera S_n é definido como o instante de tempo em que ocorre o n-ésimo evento. Claramente S_n é a soma dos tempos entre ocorrências $T_1, T_2...,$

T_n. Mas, os T_i's são independentes e identicamente distribuídos com densidade Exponencial com parâmetro λ. Assim, S_n tem distribuição **Gama(n, λ)**. Note que n é um número inteiro ≥ 1, e a densidade Gama com este parâmetro inteiro é também chamada de densidade **Erlang** com parâmetros n e λ.

A densidade de S_n é:

$$f_{S_n}(u) = \frac{\lambda.e^{-\lambda.u}}{(n-1)!}(\lambda.u)^{n-1} \text{ onde } u \geq 0, \text{ n inteiro} \geq 1 \text{ e } \lambda > 0.$$

Das propriedades da distribuição Gama segue que:

$$E(S_n) = \frac{n}{\lambda} \text{ e } VAR(S_n) = \frac{n}{\lambda^2}$$

Exemplo 4.3.4.
As pessoas imigram para uma certa região seguindo um Processo de Poisson com taxa $\lambda = 1$ pessoa por dia.

a) Qual o tempo esperado até a chegada do terceiro imigrante?
b) Qual a probabilidade de que o tempo entre as chegadas do décimo e do décimo primeiro imigrantes seja maior que 2 dias?

Solução
a) $E(S_3) = 3/1 = 3$ dias.
b) $Pr\{T_{11} > 2\} = e^{-2\lambda} = e^{-2} \approx 13.5\%$

Exemplo 4.3.5.
A chegada de uma mensagem de e-mail num servidor segue um Processo de Poisson com taxa $\lambda = 5$ mensagens por minuto.

a) Qual a probabilidade de que a primeira e-mail deve demorar mais que 20 segundos para chegar?
b) Faça um gráfico da densidade do segundo tempo de espera.
c) Qual a probabilidade de que a segunda mensagem demore menos que 30 segundos para chegar?

Solução
a) O instante de chegada da primeira mensagem é uma variável Exponencial com média $1/\lambda = 1/5$ de um minuto = 12 segundos. Denote por T esta variável. Desejamos encontrar Pr (T ≥ 20 segundos) = Pr {T ≥ 1/3 minuto} = exp{-5(1/3)} = 18.9%.
b) Seja U o segundo tempo de espera. Sua densidade é Gama(2, 5), isto é:

$f_{S_n}(u) = (25\,u)\,e^{-5.u}$ para $u \geq 0$. O gráfico desejado está a seguir.

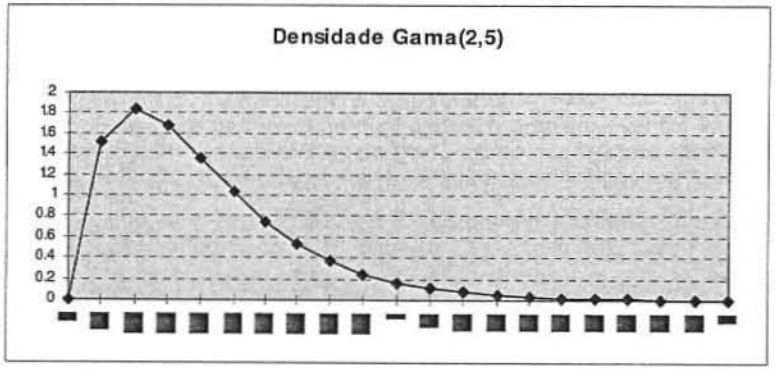

c) Queremos encontrar a probabilidade de que U, acima definido, seja menor ou igual a 30 segundos = 0.5 minuto. Isto é: Pr $\{U \le 0.5\} = \int_0^{1/2} 25.u.e^{-5u}du = 71.3\%$.

A distribuição Binomial também está relacionada ao Processo de Poisson, como mostramos a seguir.

Teorema 4.3.6.
Seja $\{X(t): t \ge 0\}$ um Processo de Poisson com taxa λ. Então, para todo instante t_1 no intervalo $(0, t_2)$ temos o seguinte resultado:

$$\Pr\{X(t_1) = k \mid X(t_2) = n\} = \binom{n}{k}\left(\frac{t_1}{t_2}\right)^k\left(1-\frac{t_1}{t_2}\right)^{n-k} \quad \text{para } k = 0, 1, 2...n$$

Isto é, dado que $X(t_2) = n$, $X(t_1)$ tem distribuição Binomial com parâmetros n e $p = t_1/t_2$.

Demonstração
Segue direto da definição de probabilidade condicional e do fato do processo ser um Processo de Poisson.

$\Pr\{X(t_1) = k \mid X(t_2) = n\} =$

$$\frac{\Pr\{X(t_1)=k, X(t_2)=n\}}{\Pr\{X(t_2)=n\}} = \frac{\Pr\{X(t_1)=k, X(t_2)-X(t_1)=n-k\}}{\Pr\{X(t_2)=n\}}$$ e como o processo é

Poisson, o que acontece no intervalo $(0, t_1)$ é independente do que ocorre no intervalo (t_1, t_2) e assim:

$$= \frac{\Pr\{X(t_1)=k\}\Pr\{X(t_2)-X(t_1)=n-k\}}{\Pr\{X(t_2)=n\}} = \frac{\frac{e^{-\lambda.t_1}(\lambda.t_1)^k}{k!}\cdot\frac{e^{-\lambda(t_2-t_1)}(\lambda.(t_2-t_1))^{n-k}}{(n-k)!}}{\frac{e^{-\lambda.t_2}(\lambda.t_2)^n}{n!}} =$$

$$= \binom{n}{k}\left(\frac{t_1}{t_2}\right)^k\left(1-\frac{t_1}{t_2}\right)^{n-k}$$

Exemplo 4.3.7.
O número de produtos que aumenta de preço num supermercado segue um Processo de Poisson com taxa $\lambda = 10$ produtos por mês (4 semanas).

Sabendo-se que 8 produtos aumentaram de preço num determinado mês, qual a probabilidade de que pelo menos 5 destes aumentos tenham ocorrido nas primeiras 3 semanas?

Solução
Neste caso $\lambda = 10$, $t_2 = 4$ semanas, $t_1 = 3$ semanas e desejamos calcular:
$\Pr\{X(3) \ge 5 \mid X(4) = 8\} = \Pr\{X(3) = 5 \mid X(4) = 8\} + \Pr\{X(3) = 6 \mid X(4) = 8\}$
$+ \Pr\{X(3) = 7 \mid X(4) = 8\} + \Pr\{X(3) = 8 \mid X(4) = 8\}$

Note que a distribuição condicional de X(3) dado X(4) = 8 é uma Binomial com parâmetros n = 8 e p = ¾ e, portanto, as probabilidades indicadas devem ser calculadas com base nesta distribuição.

$\Pr\{X(3) \ge 5 \mid X(4) = 8\} = 20.76\% + 31.15\% + 26.70\% + 10.01\% =$ **88.62%**.

Exemplo 4.3.8.
O número de transplantes por mês num grande hospital segue um Processo de Poisson com taxa $\lambda = 4$ transplantes por semana. Considere um período de 6 meses (26 semanas). Sabendo que durante estes 6 meses foram feitos 30 transplantes, calcule as probabilidades de ocorrência de 0, 1,2..., 10 transplantes durante as primeiras 8 semanas e faça um gráfico destas probabilidades.

Solução
Seja X(t) o número de transplantes realizados no intervalo [0,t]. Desejamos calcular $\Pr\{X(8) = k \mid X(26) = 30\}$, e pelo teorema 4.3.6. esta distribuição é Binomial com parâmetros n = 30 e p = 8/26= 4/13.

Logo: $\Pr(X(8) = k \mid X(26) = 30) = \binom{30}{k}\left(\frac{8}{26}\right)^k\left(\frac{18}{26}\right)^{30-k}$ para k =0, 1, 2...30 e

desejamos calcular estas probabilidades para k =0, 1,2..., 10.

x	Pr(X = x)
0	0.0%
1	0.0%
2	0.1%
3	0.6%
4	1.7%
5	4.0%
6	7.4%
7	11.3%
8	14.4%
9	15.7%
10	14.6%

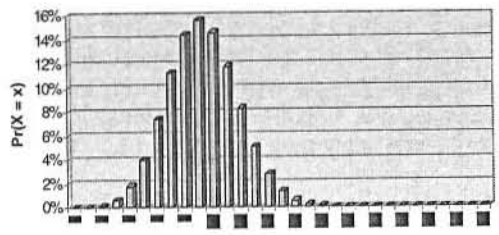

Exemplo 4.3.9.
Um componente tem uma duração aleatória cuja distribuição é Exponencial com média $1/\lambda$. Quando o componente falha, ele é imediatamente substituído por outro idêntico. Assim, as durações (T_i) dos componentes são variáveis iid com densidade Exponencial. O tempo de espera $S_n = T_1 + T_2 + ... + T_n$ indica o instante em que o n-ésimo componente falha.

Suponha que o custo de reposição de um componente é β, e que o dinheiro é descontado ao longo do tempo a uma taxa α, e assim cada real gasto no instante t vale atualmente $e^{-\alpha.t}$ reais. Então, para a n-ésima falha, o custo de reposição do componente é $\beta.\exp\{-\alpha.S_n\}$. Somando para todos os valores de n encontramos o valor presente do custo de reposição dos componentes.

Calcule o custo de reposição esperado, E(C).

Solução

$C = \sum_{n=1}^{\infty} \beta.\ e^{-\alpha.S_n} \Rightarrow E(C) = \beta \sum_{n=1}^{\infty} E\left(e^{-\alpha.S_n}\right)$ é o custo de reposição esperado.

Mas, para todo n, S_n tem distribuição Gama(n, λ) e então sua função geradora de momentos é: $E\left(e^{\tau S_n}\right) = \left(\frac{\lambda}{\lambda - \tau}\right)^n$. Podemos usar esta última expressão para calcular o custo de reposição esperado. Note que:

$$\sum_{n=1}^{\infty} E\left(e^{-\alpha.S_n}\right) = \sum_{n=1}^{\infty}\left(\frac{\lambda}{\lambda+\alpha}\right)^n = \left\{\frac{\frac{\lambda}{\lambda+\alpha}}{1-\frac{\lambda}{\lambda+\alpha}}\right\} = \left\{\frac{\frac{\lambda}{\lambda+\alpha}}{\frac{\alpha}{\lambda+\alpha}}\right\} = \frac{\lambda}{\alpha}$$

Finalmente, o custo de reposição esperado é: $E(C) = \beta.(\lambda/\alpha)$.

Distribuição condicional dos tempos de chegada
Suponha que sabemos que exatamente um evento ocorreu até o instante t. Qual a distribuição condicional do instante em que o evento ocorreu?

Um Processo de Poisson tem incrementos independentes e estacionários e assim parece razoável supor que cada intervalo de tempo com largura t tenha a mesma probabilidade de conter o evento. Ou seja, esperamos que o instante em que o evento ocorreu tenha distribuição Uniforme no intervalo [0, t].

$$\Pr\{T_1 < s \mid X(t) = 1\} =$$

$$\frac{\Pr\left[T_1 < s,\ X(t) = 1\right]}{\Pr\{X(t) = 1\}} = \frac{\Pr\{1 \text{ evento em } [0,s) \text{ e } 0 \text{ eventos em } [s,t]\}}{\Pr\{X(t) = 1\}}$$

$$= \frac{\lambda.s e^{-\lambda.s}.e^{-\lambda(t-s)}}{\lambda.t.e^{-\lambda t}} = \frac{s}{t}$$

Ou seja, a função de distribuição de T_1 condicional ao fato de um evento ter ocorrido no intervalo [0, t) é a função de distribuição correspondente à densidade Uniforme. Ou seja, dado X(t) = 1, a distribuição de T_1 é Uniforme no intervalo (0,t). Isto é: sabendo que um evento ocorreu no intervalo [0,t), a probabilidade de este evento ter ocorrido em **qualquer** subintervalo de largura L é L/t.

Este resultado será generalizado a seguir, para a distribuição condicional dada a ocorrência de n eventos no intervalo [0, t).

Teorema 4.3.10.
Sejam $S_1, S_2, ..., S_n$ os tempos de chegada num Processo de Poisson. Sabendo que X(t) = n (isto é, n eventos ocorreram no intervalo [0, t)), os S_i têm a mesma distribuição que as n estatísticas de ordem associadas a n variáveis aleatórias iid Uniforme (0,t), isto é:

$$g(s_1, s_2, ..., s_n) = \frac{n!}{t^n} \text{ se } 0 < s_1 < s_2 < .... < s_n < t$$

Demonstração

Note que $S_1 = T_1$ e para j =1, 2...n temos $S_j = \sum_{i=1}^{j} T_i$. Suponha que $S_1 = T_1 = s_1$ e assim o evento $\{S_2 = s_2\}$ é equivalente ao evento $\{T_1 + T_2 = s_2\} \Leftrightarrow T_2 = s_2 - s_1$. Para quaisquer $s_1, s_2..., s_n$ tais que $0 < s_1 < s_2 <... < s_n < t$, o evento: $\{S_1 = s_1, S_2 = s_2..., S_n = s_n, X(t) = n\}$ é equivalente ao evento $\{T_1 = s_1, T_2 = s_2 - s_1..., T_n = s_n - s_{n-1}\}$ onde $T_n > t - s_n$.

Mas, pela proposição 4.3.2., os tempos entre ocorrências T_i são iid com densidade Exponencial com parâmetro λ. Assim, a densidade conjunta **condicional** de $S_1, S_2, ..., S_n$ dado que X(t) = n é:

$$f(s_1, s_2, ..., s_n | n) = \frac{f(s_1, s_2, ..., s_n)}{\Pr\{X(t) = n\}} = \frac{\lambda.e^{-\lambda s_1}.\lambda.e^{-\lambda(s_2 - s_1)}..... \lambda.e^{-\lambda(s_n - s_{n-1})}e^{-\lambda(t-s_2}}{e^{-\lambda t}\frac{(\lambda.t)^n}{n!}}$$

$$= \frac{\lambda^n.\ e^{-\lambda.t}.n!}{(\lambda.t)^n e^{-\lambda.t}} = \frac{n!}{t^n} \text{ para } 0 < s_1 < s_2 < ... < s_n < t$$

Em palavras, o que o teorema 4.3.10. nos diz é: sabendo que n eventos ocorreram no intervalo (0, t), os instantes $S_1, S_2, ..., S_n$ em que ocorrem os eventos, quando encarados como uma amostra não ordenada, são iid Uniforme no intervalo (0, t).

O próximo resultado tem o mesmo "espírito" que o teorema 4.3.10, mas agora condicionamos à ocorrência do n-ésimo evento. Este resultado não será demonstrado.

Proposição 4.3.11.
Dado que $S_n = t$, as variáveis $S_1, S_2, ..., S_{n-1}$ são iid UniformE (0,t).

4.4. Extensões do Processo de Poisson

Seja $\{X(t): t \geq 0\}$ um Processo de Poisson com taxa λ. Suponha que cada evento possa ser classificado em 2 tipos, e que a probabilidade de um evento do tipo I é p, enquanto a probabilidade de um evento do tipo II é q = 1-p.

Por exemplo, seja X(t) o número de clientes que chega a uma loja no intervalo de tempo (0, t). Suponha que p = ½ = probabilidade de chegada de um homem = 1-p = probabilidade de chegada de uma mulher. Neste caso, o evento do tipo I é a chegada de um homem, e o do tipo II é a chegada de uma mulher.

Sejam $X_1(t)$ e $X_2(t)$ respectivamente o número de eventos do tipo I e do tipo II no intervalo (0, t). Claramente $X(t) = X_1(t) + X_2(t)$ e, portanto, o Processo de Poisson original pode ser "repartido" em dois outros processos $X_1(t)$ e $X_2(t)$, e estes processos são também Processos de Poisson, como demonstrado no próximo teorema.

Teorema 4.4.1.
Os processos $X_1(t)$ e $X_2(t)$ são processos de Poisson independentes com taxas λp e $\lambda(1-p)$ respectivamente.

Demonstração
Queremos achar a probabilidade conjunta $\Pr\{X_1(t) = n \text{ e } X_2(t) = m\}$ para quaisquer n e m inteiros ≥ 0. Mas, se condicionarmos ao evento $X(t) = k$ temos:

$$\Pr\{X_1(t) = n, X_2(t) = m\} = \sum_{k=0}^{\infty} \Pr\{X_1(t) = n, X_2(t) = m | X(t) = k\} \Pr\{X(t) = k\}$$

Mas, como $X(t) = X_1(t) + X_2(t)$, os termos do somatório acima são diferentes de zero apenas quando $k = m + n$. Logo:

$$\Pr\{X_1(t) = n, X_2(t) = m\} = \Pr\{X_1(t) = n, X_2(t) = m | X(t) = m+n\} \Pr\{X(t) = m+n\}.$$

Mas, dado que n + m eventos ocorreram e que cada evento do tipo I tem probabilidade p (e cada evento do tipo II tem probabilidade 1 - p), a probabilidade de n eventos do tipo I (e m do tipo II) é Binomial com número de repetições n + m e probabilidade de sucesso p. Assim:

$$\Pr\{X_1(t) = n, X_2(t) = m\} = \frac{(n+m)!}{n!m!} p^n (1-p)^m \frac{e^{-\lambda t}(\lambda t)^{n+m}}{(n+m)!}$$

Rearranjando os termos, leva a:

$$\Pr\{X_1(t) = n, X_2(t) = m\} = \frac{(\lambda.t.p)^n e^{-\lambda.t.p}}{n!} \frac{(\lambda.t.(1-p))^m e^{-\lambda.t.(1-p)}}{m!}$$

As probabilidades marginais são obtidas através do somatório das probabilidades conjuntas e pode-se então concluir que $\{X_1(t): t \geq 0\}$ é um Processo de

Poisson com taxa $\lambda.p$ e analogamente $\{X_2(t): t \geq 0\}$ é um Processo de Poisson com taxa $\lambda(1-p)$. Finalmente, a independência de $X_1(t)$ e $X_2(t)$ surge como conseqüência, pois para todo n, m = 0, 1, 2... a probabilidade conjunta é o produto das respectivas marginais.

Nota
O fato dos processos $X_1(t)$ e $X_2(t)$ serem Poisson parece razoável à primeira vista. O que é surpreendente é a independência dos dois processos. A nossa "intuição" pura e simples contraria esta idéia de independência, como mostramos no próximo exemplo.

O número de pessoas que chega a uma loja é um Processo de Poisson com λ = 1 pessoa por hora. A probabilidade de um homem entrar na loja é igual à probabilidade de uma mulher entrar na loja. Suponha que 100 homens entraram na loja nas primeiras 10 horas de funcionamento. Quantas mulheres esperaríamos que entrassem na loja no mesmo período? Poderíamos argumentar que, se 100 homens chegaram, e como a probabilidade de chegada de um homem é ½, o número esperado de mulheres nas primeiras 10 horas também seria 100. Mas, pelo teorema anterior este resultado está errado, pois *os dois processos são independentes!* Daí, o número esperado de mulheres é:

$\{X_2(t)\} = \lambda.p.t = (1/2).(10) = 5$, independente do número de homens que chegaram no período.

Exemplo 4.4.2.
A chegada de imigrantes a uma certa área é um Processo de Poisson com taxa λ = 10 pessoas por semana. A probabilidade de um imigrante ser descendente de italianos é 1/12. Qual a probabilidade de que nenhum descendente de italianos chegue num período de 4 semanas?

Solução
Sejam:
- evento do tipo I = descendente de italianos, com probabilidade 1/12
- evento do tipo II = descendente de "não italianos", com probabilidade 11/12

$X_1(t)$ é um Processo de Poisson com taxa $\lambda.p = 10/12$. A probabilidade desejada é $\Pr\{X_1(4) = 0\} = \exp\{-40/12\} = \exp(-10/3) = 3.6\%$.

Exemplo 4.4.3.
Um contador registra a chegada de partículas radioativas. Existem dois tipos de eventos possíveis: a partícula emitida é detectada (tipo I) ou a partícula emitida não é detectada (evento do tipo II). A probabilidade do contador não detectar uma partícula é 5%. Sabendo que o material analisado emite partículas a uma taxa de 100 partículas por segundo, pergunta-se:

a) Qual a probabilidade de que o detector tenha ignorado mais de 10 partículas num intervalo de 3 segundos?
b) Qual o número esperado de partículas não detectadas num intervalo de 3 segundos?

c)Sabendo que 12 partículas foram ignoradas em 3 segundos, qual a probabilidade de que pelo menos 8 destas tenham sido ignoradas no primeiro segundo?

Solução

Tipo I → partícula detectada → o processo $X_1(t)$ é Poisson com taxa l = (0.95)(100) = 95 partículas por segundo;

Tipo II → partícula **não** detectada → o processo $X_2(t)$ é Poisson com taxa k = (0.05)(100) = 5 partículas por segundo.

a) $\Pr\{X_2(3) > 10\} = \sum_{x=11}^{\infty} \frac{e^{-15}(15)^x}{x!} = 1 - \Pr\{X_2(3) \le 10\} = 1 - \sum_{x=0}^{10} \frac{e^{-15}(15)^x}{x!}$

= 88.15% pois $X_2(3)$ tem distribuição Poisson(15).

b) $E\{X_2(3)\} = 15$

c) $\Pr\{X_2(1) \ge 8 \mid X_2(3) = 12\}$ é calculado a partir de uma distribuição Binomial com número de repetições 12 e probabilidade de sucesso 1/3. Logo, a probabilidade desejada é: 1.88% (verifique!)

Estimando o número de ocorrências

Suponha que X(t) não é observável, mas $X_1(t)$ o é. Por exemplo, este tipo de situação ocorre quando medimos a "chegada" de partículas radioativas. Podemos dizer que as partículas do tipo I são aquelas detectadas por um contador, e as partículas do tipo II são ignoradas pelo contador. Gostaríamos de estimar o número total de partículas recebidas no intervalo (0, t] após observarmos o número de partículas efetivamente contabilizadas (isto é, detectadas pelo contador).

Sabemos que, se a probabilidade de não detecção é 1- p, então $X_1(t)$ é um Processo de Poisson com taxa $\lambda.p$ e $X_2(t)$ é um Processo de Poisson com taxa $\lambda.(1-p)$. O processo original $X(t) = X_1(t) + X_2(t)$ mede o número de partículas emitidas, e é um Processo de Poisson com taxa λ.

A distribuição condicional de X(t) dado que $X_1(t) = k$ é a mesma que a distribuição de $k + X_2(t)$, pois:

$$\Pr\{X(t)=x \mid X_1(t)=k\} = \frac{\Pr\{X(t)=x, X_1(t)=k\}}{\Pr\{X_1(t)=k\}} = \frac{\Pr\{X_1(t)+X_2(t)=x, X_1(t)=k\}}{\Pr\{X_1(t)=k\}} =$$

$$= \frac{\Pr\{X_2(t)=x-k, X_1(t)=k\}}{\Pr\{X_1(t)=k\}} = \frac{\Pr\{X_1(t)=k\}\ \Pr\{X_2(t)=x-k\}}{\Pr\{X_1(t)=k\}} = \Pr\{X_2(t)=x-k\} =$$

$$= \frac{e^{-\lambda(1-p)t}\{\lambda(1-p)t\}^{x-k}}{(x-k)!} \quad \text{para } x = k, k+1, k+2, \ldots..$$

Daí:

$$E\{X(t) \mid X_1(t)=k\} = \sum_{x=k}^{\infty} x \frac{e^{-\lambda(1-p)t}\{\lambda(1-p)t\}^{x-k}}{(x-k)!} = e^{-\lambda(1-p)t} \sum_{x=k}^{\infty} \frac{x\{\lambda(1-p)t\}^{x-k}}{(x-k)!}$$

Faça a mudança de variáveis j = x - k e o somatório torna-se:

$$E\{X(t) \mid X_1(t)=k\} = e^{-\lambda(1-p)t} \sum_{j=0}^{\infty} \frac{(j+k)\{\lambda(1-p)t\}^{j}}{(j)!}$$

Para simplificar a notação, faça $\theta = \lambda(1-p)t$. Logo:

$$E\{X(t) \mid X_1(t)=k\} = e^{-\theta} \sum_{j=0}^{\infty} \frac{(j+k)\theta^j}{(j)!} = e^{-\theta}\left\{\sum_{j=0}^{\infty} \frac{j\theta^j}{j!} + k\sum_{j=0}^{\infty} \frac{\theta^j}{j!}\right\} =$$

$$= e^{-\theta}\left\{\sum_{j=1}^{\infty} \frac{\theta^{j-1+1}}{(j-1)!} + k.e^{+\theta}\right\} = e^{-\theta}\left\{\theta\sum_{j=1}^{\infty} \frac{\theta^{j-1}}{(j-1)!} + k.e^{+\theta}\right\} = e^{-\theta}\{\theta.e^{+\theta} + k.e^{+\theta}\} = \theta + k$$

Finalmente:

$$E\{X(t) \mid X_1(t)=k\} = \lambda(1-p)t + k$$

Se λ e p são conhecidos, segue que o melhor estimador de X(t) baseado em $X_1(t)$ é: $X_1(t) + \lambda(1\text{-}p)t$. Pode-se provar (tente!) que a variância condicional de X(t) dado $X_1(t) = k$ é $\lambda(1\text{-}p)t$.

Exemplo 4.4.4.

Um material radioativo emite partículas de acordo com um Processo de Poisson com taxa λ = 100 partículas por segundo. Um contador é capaz de detectar as partículas emitidas com probabilidade 90%. Num intervalo de 5 segundos observou-se 465 partículas. Estime o número de partículas emitidas pelo material.

Solução

Das considerações acima segue que o número estimado de partículas emitidas é: $E\{X(t) \mid X_1(t)=k\} = \lambda(1-p)\,t + k = 100(0.10)5 + 465 = 515$

Exemplo 4.4.5.

Considere um sistema no qual, a qualquer instante, indivíduos estão em um dentre r estados possíveis. Suponha que um indivíduo troque de estados de acordo com uma cadeia de Markov com probabilidades de transição P_{ij} onde i, j = 1, 2..., r. Por hipótese, cada indivíduo muda de estado independentemente dos outros indivíduos.

Suponha que os números de pessoas inicialmente nos estados 1, 2..., r sejam variáveis aleatórias Poisson com médias $\lambda_1, \lambda_2..., \lambda_r$ respectivamente.

Encontre a distribuição conjunta do número de indivíduos em cada estado num instante qualquer n.

Solução
Para i um estado fixo, seja $X_j(i)$, j = 1, 2..., r o número de indivíduos inicialmente no estado i que, no instante n, estão no estado j.
Para cada i, o número de pessoas no estado j no instante n é uma variável aleatória Poisson independente de todas as outras variáveis para todos os outros indivíduos (com estado inicial i diferente). $X_j(i)$ ocorre com probabilidade P_{ij}^n, que é a probabilidade de transição de n estágios. Assim, $X_j(i)$ é uma variável Poisson com média $\lambda_i.P_{ij}^n$ para j = 1, 2..., r e estas variáveis são independentes.

A soma de variáveis independentes Poisson é também Poisson, e então o número de indivíduos no estado j no instante n, dado por $\sum_{i=1}^{r} X_j(i)$ é Poisson com média $\sum_{i=1}^{r} \lambda_i.P_{ij}^n$ para todo j, e estas variáveis são independentes.

Exemplo 4.4.6.
Considere o exemplo anterior. Suponha que existem 3 estados possíveis para a sensação de bem estar físico de um indivíduo: 1 (bem disposto), 2 (normal), 3 (cansado).
A matriz de transição para estes estados num período de uma semana é:

$$P = \begin{bmatrix} 0.4 & 0.4 & 0.2 \\ 0.2 & 0.6 & 0.2 \\ 0.1 & 0.1 & 0.8 \end{bmatrix}$$

Numa certa universidade faz-se uma experiência com o objetivo de verificar o quanto os alunos vão ficando cansados à medida que o semestre letivo progride. Suponha que os números iniciais de indivíduos nos estados 1, 2 e 3 são variáveis Poisson com médias 8, 10 e 4. Encontre a distribuição conjunta do número de indivíduos em cada estado no instante n = 12 semanas.

Solução

Note que $P^{12} = \begin{bmatrix} 0.1878 & 0.3133 & 0.4989 \\ 0.1878 & 0.3133 & 0.4989 \\ 0.1872 & 0.3117 & 0.5011 \end{bmatrix}$.

Após n = 12 semanas, o número de indivíduos cansados (estado 3) é uma variável Poisson com média $\sum_{i=1}^{3} \lambda_i.P_{i3}^{12} = \lambda_1.P_{13}^{12} + \lambda_2.P_{23}^{12} + \lambda_3.P_{33}^{12} = 8(0.4989) + 10(0.4989) + 4(0.5011) = 10.9846$.

De maneira análoga (verifique!!!), o número de indivíduos em estado normal após 12 semanas é uma variável Poisson com média 6.8862 e o número de indivíduos bem dispostos é Poisson com média 4.1292.

Agora queremos generalizar a idéia de "particionar" um Processo de Poisson em 2 processos independentes, como mostrado no início desta seção. Suponha agora que existem k tipos possíveis de eventos, e a probabilidade de um evento ser classificado como de tipo i (i =1,2..., k) é p_i, onde $\sum_{i=1}^{k} p_i = 1$. Para t um instante qualquer fixo, seja X_i (t) o número de ocorrências de eventos do tipo i no intervalo (0,t}. Então $X_1(t)$, $X_2(t)$..., $X_k(t)$ são independentes e $X_i(t)$ tem distribuição Poisson com parâmetro $\lambda.p_i.t$.

Esta idéia pode ser generalizada ainda mais. Suponha agora que existam k tipos possíveis de eventos, e a probabilidade de um evento ser classificado como de tipo i (i =1,2..., k) **depende do instante de tempo** em que ocorre o evento, isto é, para um instante de tempo qualquer t, p_i é, na verdade, um certo $p_i(t)$.

Claramente temos $\sum_{i=1}^{k} p_i(t) = 1$ para qualquer instante t.

Teorema 4.4.7.
Suponha que cada evento num Processo de Poisson possa ser classificado como de tipo i (i = 1,2..., k). Seja X_i (t), i =1,2..., k, o número de eventos do tipo i que ocorrem até o instante t. Então, os X_i (t) são variáveis aleatórias independentes com distribuição Poisson com médias: $E[X_i(t)] = \lambda \int_0^t p_i(\tau)\, d\tau$

Um caso particular importante ocorre quando os p_i's são constantes, e neste caso os X_i (t) são variáveis aleatórias independentes com distribuição Poisson com médias $\lambda.p_i.t$, como já mencionado.

Demonstração
Queremos calcular a probabilidade conjunta: Pr {X_i (t) = x_i para i = 1, 2..k}

Note que o número total de eventos é $\sum_{i=1}^{k} x_i$.

Condicionando ao valor de X(t) temos: Pr {$X_1(t) = x_1$, $X_2(t) = x_2$..., $X_k(t) = x_k$}

$$= = \Pr\left\{X_1(t) = x_1, X_2(t) = x_2, \ldots X_k(t) = x_k \;\middle|\; X(t) = \sum_{i=1}^{k} x_i\right\}.\ \Pr\left\{X(t) = \sum_{i=1}^{k} x_i\right\}$$

Considere um evento qualquer no intervalo [0, t]. Se este evento ocorreu no instante s, a probabilidade deste evento ser do tipo i é $p_i(s)$. Mas, como o processo é Poisson, este evento ocorreu em algum instante que é uniformemente distribuído em [0, t]. Logo, a probabilidade de um evento ser do tipo i é: $P_i = \int_0^t \frac{1}{t} p_i(s) ds$ independente de qualquer outro evento e então:

$\Pr\left\{X_1(t) = x_1, X_2(t) = x_2, \ldots X_k(t) = x_k \middle| X(t) = \sum_{i=1}^{k} x_i\right\}$ é uma probabilidade Multinomial de x_i ocorrências do tipo i (i = 1,2, ...,k) e com número total de ocorrências $\sum_{i=1}^{k} x_i$.

Ou seja:

$$\Pr\left\{X_1(t)=x_1, X_2(t)=x_2,\ldots X_k(t)=x_k \;\middle|\; X(t)=\sum_{i=1}^{k}x_i\right\}=\frac{\left(\sum_{i=1}^{k}x_i\right)!}{x_1!x_2!\ldots x_k!}P_1^{n1}\,P_2^{n2}\ldots P_k^{nk}$$

Assim, a distribuição conjunta incondicional é:

$$\Pr\left\{X_1(t)=x_1, X_2(t)=x_2,\ldots X_k(t)=x_k\right\}=\frac{\left(\sum_{i=1}^{k}x_i\right)!}{x_1!x_2!\ldots x_k!}P_1^{n1}\,P_2^{n2}\ldots\,P_k^{nk}\,\frac{e^{-\lambda t}(\lambda t)^{\sum x_i}}{\left(\sum_{i=1}^{k}x_i\right)!}=$$

$$=\prod_{i=1}^{k}\frac{e^{-\lambda t P_i}\,(\lambda t P_i)^{x_i}}{(x_i!)}$$

pois $e^{-\lambda t}=e^{-\lambda t P_1}.e^{-\lambda t P_2}.\ldots\ldots.e^{-\lambda t P_k}=e^{-\lambda t(P_1+P_2+\ldots+P_k)}$

Exemplo 4.4.8. Uma Fila Infinita
A chegada de clientes a uma loja segue um Processo de Poisson com taxa λ. Ao chegar, o cliente é imediatamente servido por um caixa (suponha que exista um número infinito de caixas). Supõe-se que os tempos de serviço são independentes com uma distribuição comum G. Seja X(t) o número de clientes que já foi totalmente servido até o instante t, e Y(t) o número de clientes que ainda estão sendo servidos no instante t. Qual a distribuição de X(t)? E de Y(t)?

Solução
Divida os clientes em 2 tipos:
tipo I - cliente foi totalmente servido até o instante t;
tipo II - cliente não foi totalmente servido até o instante t;

Seja Z o tempo de serviço. Por hipótese, Z é uma variável aleatória com função de distribuição G, e os Z's são independentes. Então: G(z) = Pr {Z ≤ z} e assim G(t-s) = Pr {Z ≤ t-s}.

Se um cliente entra na loja no instante s ≤ t, ele será um cliente do tipo I se o tempo de serviço for menor que t-s, do contrário ele será um cliente do tipo II. Daí segue que a probabilidade de um cliente ser do tipo I é G(t-s), e a probabilidade dele ser do tipo II é 1 - G(t-s). Seja p(s) a probabilidade de um indivíduo ser do tipo I. Então X(t), o número de indivíduos do tipo I no instante t é uma variável aleatória Poisson com média $E\{X(t)\}=\lambda\int_0^t p(s)ds=\lambda\int_0^t G(t-s)ds$.

De maneira análoga, Y(t), o número de indivíduos do tipo II no instante t é uma variável Poisson com média $E\{Y(t)\}=\lambda\int_0^t\{1-G(t-s)\}ds$.

Suponha agora que desejamos encontrar a **distribuição conjunta de Y(t) e**

Y(t+s). Classifique os eventos da seguinte maneira:
- tipo I: cliente chega antes do instante t e completa o serviço entre os instantes t e t +s.
- tipo II: cliente chega antes do instante t, mas só completa o serviço depois do instantes t +s.
- tipo III: cliente chega entre os instantes t e t +s e completa o serviço depois do instantes t +s.
- tipo IV: nenhuma das opções anteriores.

Seja y o instante de chegada de um cliente. Logo $p_i(y)$ é a probabilidade de ser um cliente do tipo i (i = 1, 2,3, 4) tendo chegado à loja no instante y. As probabilidades $p_i(y)$ são dadas por:

$$p_1(y)=\begin{cases}G(t+s-Y)-G(t-y) & \text{se } y<t\\ 0 & \text{se } y\geq t\end{cases}$$

$$p_2(y)=\begin{cases}1-G(t+s-y) & \text{se } y<t\\ 0 & \text{se } y\geq t\end{cases}$$

$$p_2(y)=\begin{cases}1-G(t+s-y) & \text{se } t<y<t+s\\ 0 & \text{se } y\geq t+s \text{ ou } y\leq t\end{cases}$$

$p_4(y) = 1 - p_1(y) - p_2(y) - p_3(y)$

Seja $N_i = N_i(t+s)$ o número de ocorrências de eventos do tipo i (i =1,2,3). Pelos resultados anteriores segue que: $E(N_i)=\lambda\int_0^{t+s}p_i(y)\,dy$. Note que:

$Y(t) = N_1 + N_2$
$Y(t+s) = N_2 + N_3$

Então, por exemplo: $COV\{Y(t), Y(t+s)\} = COV\{N_1 + N_2, N_2 + N_3\} = COV\{N_2, N_2\} = Var(N_2)$, pois N_1, N_2 e N_3 são independentes.

Assim,

$COV\{Y(t), Y(t+s)\} = Var(N_2) = E\{N_2\} =$

$=\lambda\int_0^{t+s}p_2(y)\,dy=\lambda\int_0^t\{1-G(t+s-y)\}\,dy=\lambda\int_0^t\{1-G(u+s)\}\,du$ pois N_2 é Poisson, e sua variância é igual à sua média.

A distribuição conjunta de Y(t) e Y(t +s) é mostrada a seguir.

$$\Pr\{Y(t)=i, Y(t+s)=j\}=\Pr\{N_1+N_2=i, N_2+N_3=j\}=$$

$$\sum_{k=0}^{\min(i,j)}\Pr\{N_2=k, N_1=i-k, N_3=j-k\}=\sum_{k=0}^{\min(i,j)}\Pr\{N_2=k\}.\Pr\{N_1=i-k\}\Pr\{N_3=j-k\}$$

pois N_1, N_2 e N_3 são independentes.

Exemplo 4.4.9.
Pulsos elétricos com amplitudes aleatórias chegam num contador segundo um processo de Poisson com taxa λ. A amplitude de cada pulso decresce exponencialmente, ou seja, se um certo pulso tem, ao chegar, amplitude A, a sua amplitude após t instantes é $A.\exp(-\alpha.t)$.

Suponha que as amplitudes iniciais dos pulsos são variáveis independentes com função de distribuição F. Calcule a amplitude média.

Solução
Sejam $S_1, S_2, \ldots$ os tempos de chegada dos pulsos e $A_1, A_2, \ldots$ suas amplitudes nos instantes de chegada.

Seja A(t) a amplitude no instante t. Então: $A(t) = \sum_{i=1}^{N(t)} A_i e^{-\alpha(t-s_i)}$ onde N(t) é o número de pulsos que chegaram até o instante t. A amplitude média é dada por:

$$E\{A(t)\} = \sum_{n=0}^{\infty} E\{A(t) \mid N(t)=n\} \Pr(N(t)=n) = \sum_{n=0}^{\infty} E\{A(t) \mid N(t)=n\} \frac{e^{-\lambda t}(\lambda t)^n}{n!}$$

Mas, dado o valor N(t) = n, os tempos de chegada $S_1, S_2, \ldots S_n$ são distribuídos como variáveis Uniforme (0,t) independentes. Assim, **dado** N(t) = n, A(t) tem a mesma distribuição que a variável $\sum_{j=1}^{n} A_j e^{-\alpha(t-Y_j)}$ onde os Y_j's são iid Uniforme (0,t). Daí segue que:

$$E\{A(t) \mid N(t)=n\} = E\left\{\sum_{j=1}^{n} A_j e^{-\alpha(t-Y_j)}\right\} \sum_{j=1}^{n} E\left(A_j e^{-\alpha(t-Y_j)}\right) = n.\ E(A)\ E\left(e^{-\alpha(t-Y)}\right)$$

onde E(A) é a média das amplitudes iniciais dos pulsos e Y é uma variável Uniforme no intervalo (0, t). Logo:

$$E\left(e^{-\alpha(t-Y)}\right) = \int_0^t e^{-\alpha(t-y)} \frac{1}{t} dy = \frac{1-e^{-\alpha t}}{\alpha t}$$

E assim segue que:

$$E\{A(t) \mid N(t)=n\} = n.\ E(A)\ E\left(e^{-\alpha(t-Y)}\right) = n.\ E(A)\frac{(1-e^{-\alpha t})}{\alpha t}$$

Em geral:

$$E\{A(t) \mid N(t)\} = N(t).\ E(A)\frac{(1-e^{-\alpha t})}{\alpha t}$$

Usando as propriedades do valor esperado condicional e sabendo que $E\{N(t)\} = \lambda.t$ obtemos:

$$E(A(t)) = E\{E\{A(t) \mid N(t)\}\} = E\left(N(t).\ E(A)\frac{(1-e^{-\alpha t})}{\alpha t}\right) = \lambda.t.\ E(A).\frac{(1-e^{-\alpha t})}{\alpha t} = .\frac{\lambda.E(A)(1-e^{-\alpha t})}{\alpha}$$

4.5. Processos de Poisson não Homogêneos e Processos de Poisson Compostos

Da definição de um Processo de Poisson notamos que a taxa λ do processo é a constante de proporcionalidade que aparece no cálculo da probabilidade de ocorrência de um evento num intervalo de tamanho pequeno, mas arbitrário.

Já vimos antes que, se h é um número "pequeno", a probabilidade de ocorrência de um único evento num intervalo de largura h é:

$$\Pr\{X(t+h)-X(t)=1\} = \lambda.h.e^{-\lambda h} = \lambda.h\left\{1-\lambda h+\frac{1}{2}(\lambda h)^2-\frac{1}{3}(\lambda h)^3+\ldots.\right\} = \lambda.h+o(h)$$

Em muitos casos é interessante considerar **taxas variáveis no tempo**, ou seja, a constante λ é substituída por uma função especificada $\lambda(t)$. Por exemplo, no caso de um processo que represente o número de automóveis que passa por um posto de pedágio não é razoável supor que o movimento na estrada é igual em todos os dias e horas e, portanto, deveríamos definir um processo com intensidade λ variante no tempo. Um processo de Poisson no qual $\lambda = \lambda(t)$ é chamado de **Processo de Poisson não homogêneo.**

Definição 4.5.1. Processo de Poisson Não Homogêneo
O processo de contagem $\{X(t): t \geq 0\}$ é chamado de **Processo de Poisson não homogêneo** com intensidade $\lambda(t)$ se:

i) $X(0) = 0$
ii) $\{X(t): t \geq 0\}$ tem incrementos independentes
iii) $\Pr\{X(t+h) - X(t) \geq 2\} = o(h)$
iv) $\Pr\{X(t+h) - X(t) = 1\} = \lambda(t).h + o(h)$

Seja $m(t) = \int_0^t \lambda(u)du$. Então, usando propriedades da integral segue que:

$$m(t+s)-m(t) = \int_0^{t+s}\lambda(u)du - \int_0^t \lambda(u)du = \int_t^{t+s}\lambda(u)du$$

Pode-se mostrar que:

$$\Pr\{X(t+s)-X(t)=n\} = \frac{e^{-\{m(t+s)-m(t)\}}\{m(t+s)-m(t)\}^n}{n!} \quad \text{para } n = 0,1,2,\ldots. \quad (4.5.1.)$$

Ou seja, X(t+s) - X(t) tem distribuição Poisson com média μ dada por: $\mu = m(t+s) - m(t)$. Em particular X(t) tem distribuição Poisson com média m(t), que é chamada de **função de valor médio** do processo.

Demonstração de (4.5.1).
Fixe t e defina: $P_n(s) = Pr\{X(t+s) - X(t) = n\}$. Então:

$P_0(s+h) = Pr\{X(t+s+h) - X(t) = 0\}$, o que equivale a dizer que nenhum evento ocorreu no intervalo (t, t +s) e também nenhum evento ocorreu no intervalo [t +s, t + s + h]. Como estes intervalos de tempo não têm pontos em comum pode-se escrever:

$$P_0(s+h) = Pr\{X(t+s) - X(t) = 0\}.\ Pr\{X(t+s+h) - X(t+s) = 0\} = P_0(s).\{1 - \lambda.h(t+s) + o(h)\}$$

Daí:

$\frac{P_0(s+h) - P_0(s)}{h} = -\lambda.(t+s).\ P_0(s) + \frac{o(h)}{h}$ e tomando-se o limite quando h tende a zero resulta em:

$$P_0'(s) = -\lambda.(t+s).\ P_0(s) \Rightarrow \log P_0(s) = -\int_0^s \lambda(t+u)\ du = -\int_t^{t+s} \lambda(y)\ dy = -\{m(t+s) - m(t)\}$$

e finalmente, pela definição de m(.) temos: $P_0(s) = e^{-\{m(t+s)-m(t)\}}$

Nota
A hipótese de incrementos estacionários não é necessária nos processos de Poisson não homogêneos. Assim, nestes processos é possível que alguns eventos sejam mais prováveis durante certos intervalos de tempo.

Exemplo 4.5.2.
A chegada de pacientes numa clínica segue um Processo de Poisson não homogêneo com intensidade λ(t) dada por:

$$\lambda(t) = \begin{cases} 2t, & t \in [0,1) \\ 2 \quad \text{se } t \in [1,2) \\ 4 - t, \text{ se } t \in [2,4] \end{cases}$$

onde t é medido em horas a partir da abertura da clínica.

Qual a probabilidade de que dois pacientes cheguem durante as primeiras 2 horas de funcionamento e que dois outros cheguem nas próximas 2 horas?

Solução
Os números de pacientes que chegam em intervalos de tempo disjuntos são independentes (por causa da hipótese de incrementos independentes). Assim, nas duas primeiras horas a média do processo é:

$$m(t) = \int_0^2 \lambda(t)\ dt = \int_0^1 \lambda(t)\ dt + \int_1^2 \lambda(t)\ dt = \int_0^1 2.t.dt + \int_1^2 2\ dt = 3$$

Assim: $Pr\{X(2) = 2\} = \frac{e^{-3}(3)^2}{2!} \approx 22.4\%$

Nas próximas duas horas a média do processo é:

$m(t) = \int_2^4 \lambda(t)\ dt = \int_2^4 (4 - t)\ dt = 2$ e então $Pr\{X(4) - X(2) = 2\} = \frac{e^{-2}(2)^2}{2!} \approx 27.1\%$

Processos de Poisson Compostos

Definição 4.5.3.
Sejam $Y_1, Y_2 \ldots, Y_{N(t)}$ variáveis aleatórias independentes e identicamente distribuídas. Seja $\{N(t): t \geq 0\}$ um Processo de Poisson, independente dos Y_i 's. Defina o processo estocástico $\{X(t): t \geq 0\}$ como:

$$X(t) = \sum_{i=1}^{N(t)} Y_i \text{ para } t \geq 0$$

Note que X(t) é uma **soma** de variáveis aleatórias com um **número aleatório de termos**. Por sua vez, para t fixo, o número de termos nesta soma é uma variável aleatória Poisson.

O processo estocástico $\{X(t): t \geq 0\}$ é chamado de **Processo de Poisson composto**.

Teorema 4.5.4.
Seja $X(t): t \geq 0\}$ um Processo de Poisson composto. Então:
$E\{X(t)\} = \lambda.t.E(Y_1)$
$VAR\{X(t)\} = \lambda.t.E(Y_1^2)$

Demonstração
Para achar a média e a variância do processo X(t) condicionamos a um valor qualquer de N(t), por exemplo, n. Então: $E\{X(t)\} = E\{E\{X(t) \mid N(t) = n\}\}$. Mas, o valor esperado condicional é facilmente encontrado, pois o número de termos no somatório está fixo (e igual a n). Logo:

$$E\{X(t) \mid N(t) = n\} = E\left\{\sum_{i=1}^{N(t)} Y_i \mid N(t) = n\right\} = E\left\{\sum_{i=1}^{n} Y_i \mid N(t) = n\right\} = E\left(\sum_{i=1}^{n} Y_i\right) = n.\ E(Y_1)$$

pois os Y's são iid. Então, $E\{X(t) \mid N(t)\} = N(t).\ E(Y_1)$ e como os Y's e N(t) são independentes por hipótese temos que $E\{X(t)\} = E\{E\{X(t) \mid N(t) = n\}\} = E\{N(t).\ E(Y_1)\} = E(N(t)).E(Y_1) = \lambda.t.\ E(Y_1)$.

Para calcular a variância de X(t) condicionamos novamente em N(t) e usamos a fórmula da variância condicional.

$$\text{VAR}\,(X(t)) = E\left\{\text{VAR}\left[\,X(t)\,\middle|\,N(t)\right]\right\} + \text{VAR}\left\{E\left[\,X(t)\,\middle|\,N(t)\right]\right\}$$

Mas, por argumentos análogos aos utilizados na derivação da média:

$$\text{VAR}\left\{X(t)\,\middle|\,N(t)\right\} = N(t)\,\text{VAR}\,(Y_1) \Rightarrow E\left\{\text{VAR}\left\{X(t)\,\middle|\,N(t)\right\}\right\} = E\left\{N(t)\,\text{VAR}\,(Y_1)\right\} =$$
$$= E\left\{N(t)\right\}\text{VAR}\,(Y_1) = \lambda.\,t.\,\text{VAR}\,(Y_1)$$

Também,

$$\text{VAR}\left\{E\left[X(t)\,\middle|\,N(t)\right]\right\} = \text{VAR}\left\{N(t).\,E\,(Y_1)\right\} = \left\{E\,(Y_1)\right\}^2 \text{VAR}\left\{N(t)\right\}$$ pois $E(Y_1)$ é uma constante.

Além disso, $\text{VAR}\{N(t)\} = \lambda.t$, pois N(t) é um Processo de Poisson e então: $\text{VAR}\{X(t)\} = \lambda.t.\text{VAR}(Y_1) + \lambda.t.\{E(Y_1)\}^2 = \lambda.t.\{E(Y_1^2) - (E(Y_1))^2 + (E(Y_1))^2\} = \lambda.t.\,E(Y_1^2)$

Exemplos de Processos de Poisson Compostos

1) Se $Y_i = 1$ para todo i, o processo X(t)=N(t) é apenas o Processo de Poisson usual.
2) Este é um exemplo típico da situação que gera um Processo de Poisson composto. A entrada de clientes numa loja é um Processo de Poisson. Suponha que a quantidade de dinheiro gasta por cada cliente forme um conjunto de variáveis aleatórias iid. Seja X(t) a quantidade total de dinheiro gasta pelos clientes da loja até o instante t. Então o processo $\{X(t): t \geq 0\}$ é um Processo de Poisson Composto.

Nota
Pode-se provar (faça-o!) que a função geradora de momentos de um Processo de Poisson composto é:

$M_t(u) = E\{e^{u.X(t)}\} = \exp\{\lambda.t.M_y(u) - \lambda.t\}$ onde $M_y(u)$ é a função geradora de momentos de Y_1.

Exemplo 4.5.5.
Famílias imigram para uma certa região segundo um Processo de Poisson com taxa $\lambda = 2$ famílias por semana. Suponha que o número de pessoas em cada família é independente do número de pessoas em qualquer outra família e tem como valores possíveis 1, 2, 3 ou 4 com probabilidades 1/6, 1/3. 1/3 e 1/6.

Qual o valor esperado e a variância do número de indivíduos imigrando para esta área durante um período fixo de 5 semanas?

Solução
Seja Y_i o número de pessoas na i-ésima família, Então o número médio de

pessoas numa família é: $E\,(Y_i) = 1\left(\frac{1}{6}\right) + 2\left(\frac{1}{3}\right) + 3\left(\frac{1}{3}\right) + 4\left(\frac{1}{6}\right) = \frac{5}{2}$.

Analogamente:

$$E\left(Y_i^2\right) = 1\left(\frac{1}{6}\right) + 4\left(\frac{1}{3}\right) + 9\left(\frac{1}{3}\right) + 16\left(\frac{1}{6}\right) = \frac{43}{6}$$

Seja X(5) o número de imigrantes num período de 5 semanas. Neste caso t = 5 e $\lambda = 2$ (dados). Pelos resultados desta seção:

$E\{X(5)\} = \lambda.t.E(Y_1) = 10\,(5/2) = 25$
$\text{VAR}\,\{X(t)\} = \lambda.t.E(Y_1^2) = 10\,(43/6) = 215/3$

4. 6. Exercícios - Capítulo 4

Problema 1
Os clientes chegam a uma loja a uma taxa de 20 pessoas por hora. Suponha que a probabilidade de uma pessoa comprar alguma coisa é 30%. Encontre a função de probabilidade e o número esperado de compras.

Problema 2
O número de caminhões que passa por um posto de pesagem numa estrada num intervalo de meia hora tem uma distribuição Poisson com média 25. A probabilidade de um caminhão estar carregado acima do peso máximo permitido é 40%.

a) Qual o número esperado de caminhões acima do peso num intervalo de ½ hora?
b) Qual a probabilidade de que passem mais de 12 caminhões com peso excessivo num intervalo de ½ hora?

Problema 3
O número de pessoas admitidas no setor de emergência de um grande hospital é modelado por um Processo de Poisson com taxa $\lambda = 2$ pessoas por minuto. Sabe-se que 30% das pessoas admitidas no setor de emergência estão em estado grave. Pergunta-se:

a) Qual a probabilidade de pelo menos 4 pessoas em estado grave serem admitidas num intervalo de 15 minutos?
b) Dado que 50 pessoas foram admitidas no setor de emergência em 1 hora, qual a probabilidade de 18 terem sido admitidas em estado grave durante este intervalo de tempo?

Problema 4
A cidade de Laredo fica nos EUA, na fronteira com o México.
Suponha que o número de pessoas que atravessa a fronteira com destino aos EUA é modelado por um processo de Poisson com taxa $\lambda = 2$ pessoas por minuto. Sabe-se também que 10% das pessoas que cruzam a fronteira em direção aos EUA naquele ponto são brasileiras. Pergunta-se:

a) Qual a probabilidade de passarem pelo menos 3 brasileiros em uma hora?
b) Sabendo que 20 brasileiros passaram em uma hora, qual o número esperado de pessoas que cruzaram a fronteira naquele intervalo de tempo?

Problema 5
A chegada de imigrantes a uma certa área é um Processo de Poisson com taxa $\lambda = 10$ pessoas por semana. A probabilidade de um imigrante ser descendente de italianos é 1/10 e a de não ser descendente de italianos é 9/10.
a) Qual a probabilidade de um descendente de italianos chegar durante as 5 primeiras semanas.
b) Qual a probabilidade de 0, 1, 2 ou 3 descendentes de outras nacionalidades chegarem durante as 5 primeiras semanas?
c) Qual a probabilidade de 2 ou mais descendentes de italianos chegarem durante as 5 primeiras semanas?

Problema 6
O número de erros num livro é modelado por um Processo de Poisson com taxa $\lambda = 3$ erros por página. A probabilidade de um erro ser causado por digitação é 80%, enquanto erros gramaticais ocorrem com probabilidade 20%.

a) Qual a probabilidade de encontrarmos menos de 5 erros gramaticais nas primeiras 10 páginas?
b) Qual a probabilidade de ocorrerem 20 ou mais erros de digitação nas 15 páginas iniciais?

Problema 7
Clientes chegam a um posto de gasolina de acordo com um Processo de Poisson com taxa $r = 20$ clientes por hora. A probabilidade de o cliente ser homem é 60%. Calcule a probabilidade de que, num período de 2 horas, chegarão ao posto pelo menos 4 clientes mulheres e pelo menos 3 homens.

Problema 8
A água num certo reservatório está contaminada por bactérias aleatoriamente espalhadas com taxa média de 1 bactéria a cada 10 litros. Calcule a probabilidade de que uma pessoa que bebe 2 litros de água por dia engula uma ou mais bactérias no período de uma semana.

Problema 9
Seja X_t um Processo de Poisson com taxa λ. Seja Y_t o processo definido por:

$$Y_t = \begin{cases} +1 & \text{se } X_t \text{ par} \\ -1 & \text{se } X_t \text{ ímpar} \end{cases}$$

Calcule a média e variância de Y_t.

Problema 10
Suponha que $\{X(t);\ t \geq 0\}$ seja um processo de Poisson. Encontre a distribuição condicional de $X(t)$ dado $X(t+s) = n$.

Problema 11
Defeitos ocorrem na produção de um tecido segundo um Processo de Poisson com taxa $\lambda = 1$ defeito a cada 50 metros. Encontre a probabilidade de que o quinto defeito ocorra entre 230 e 270 metros.

Problema 12
Os defeitos na produção de um certo material seguem um Processo de Poisson com média de 5 defeitos por metro quadrado. Cada defeito, independente de outros, é um defeito pequeno com probabilidade 50%, é um defeito médio com probabilidade 30% ou é um defeito grave (com probabilidade 20%). Numa peça circular deste material com raio 1 metro, encontre a probabilidade de que existirão pelo menos 2 defeitos de cada tipo.

Problema 13
O número de assaltos numa certa esquina segue um Processo de Poisson com média 1.5 ocorrências por hora. Calcule a probabilidade de que o terceiro assalto ocorra entre uma e duas horas do início da contagem.

Problema 14
Os acessos a um servidor Internet seguem um Processo de Poisson com taxa $\lambda = 5$ acessos por minuto. Calcule a média e o desvio padrão da distribuição do décimo acesso.

Problema 15
Uma fonte radioativa emite partículas de acordo com um Processo de Poisson com taxa $\lambda = 2$ partículas por segundo. Determine:
a) O tempo médio até que a 1ª partícula seja emitida;
b) O número médio de partículas emitidas no primeiro minuto;
c) A probabilidade de que mais de 2 partículas sejam emitidas no 1º segundo;
d) A probabilidade de que mais de 2 partículas sejam emitidas no 4º. segundo, sabendo que nos primeiros 3 segundos mais de 6 partículas foram emitidas.

Problema 16
O número de pessoas que entram num cassino é modelado por um Processo de Poisson com taxa $\lambda = 3$ pessoas por minuto.

Seja Y_i a quantidade de dinheiro gasta pela i-ésima pessoa no cassino. Suponha que os Y's são independentes e identicamente distribuídos com a seguinte distribuição de probabilidade:

Y	Pr ($Y_i = y$)
0	2/16
50	3/16
100	5/16
150	6/16

Seja X(t) a receita do cassino até o instante t, isto é, a soma das quantidades gastas pelo diversos jogadores até o instante t. Determine a média e variância da receita do cassino na primeira hora de funcionamento.

Problema 17
Considere uma ação negociada em bolsa de valores e suponha que o número de transações desta ação é um Processo de Poisson N(t) com taxa $\lambda = 10$ transa-

ções diárias. Seja Y_k a variação no preço da ação entre a (k-1) e a k-ésima transações e suponha que Y_1, Y_2... são variáveis aleatórias independentes com a seguinte função de probabilidade:

Y	Pr (Y_k = y)
-1	2/8
0	3/8
1	1/8
2	2/8

Seja X(t) a variação total no preço da ação até o instante t, então: $X(t) = \sum_{k=1}^{N(t)} Y_k$.

Calcule E{X(10)} e VAR{X(10)}.

Problema 18
Um Processo de Poisson tridimensional é um processo tal que:

a) Para toda região de volume V, o número de eventos na região V é uma variável X(V) com distribuição Poisson com parâmetro λ.V.
b) O número de ocorrências em regiões distintas é independente.

Para um processo definido desta forma, considere um ponto arbitrário α no espaço tridimensional. Seja R a distância entre α e o evento mais próximo. Mostre que R tem a seguinte densidade de probabilidade:

$$f(r) = 4.\lambda.\pi.r^2.\exp\left\{\frac{-4\lambda.\pi.r^3}{3}\right\} \text{ para todo } r > 0.$$

Problema 19
Considere um processo de Poisson não homogêneo {N(t): t ≥ 0} com função de valor médio $m(t) = t^2 + 3t + 1$ (para t ≥ 0).

a) Qual a probabilidade de ocorrência de n eventos entre os instantes arbitrários t e t+s?
b) Qual a probabilidade de ocorrência de n eventos entre os instantes 2 e 3?

Problema 20
Considere um processo de Poisson não homogêneo {N(t): t ≥ 0} com função de valor médio $m(t) = t^3 - t^2$ (para t ≥ 0).

a) Qual a probabilidade de ocorrência de n eventos entre os instantes arbitrários t e t+s?
b) Qual a probabilidade de ocorrência de n eventos entre os instantes 2 e 3? E entre os instantes 5 e 6?

Problema 21
Chamadas telefônicas chegam a um tronco durante um período de 8 horas. Esta situação pode ser modelada através de um processo de Poisson não homogêneo com função de valor médio $10 - 5(t-4)^2$ onde $0 \le t \le 8$.

a) Encontre o número esperado de chamadas entre as horas 3 e 6.
b) Ache a probabilidade de que, nas duas primeiras horas de operação, ocorram mais de 30 ligações.

Problema 22
O número de afogamentos numa praia num dia de sol é um processo de Poisson não homogêneo com função de valor médio $m(t) = 2.t^2 - 20.t$ onde $0 \le t \le 10$ e t representa o instante de tempo contado a partir das 8 horas da manhã.

a) Encontre o número esperado de afogamentos entre 12 e 14 horas.
b) Calcule a probabilidade de ocorrência de n afogamentos entre 15 e 18 horas.

Problema 23 Simulação de um Processo de Poisson
Sejam T_1, T_2..., T_n os tempos entre ocorrências num Processo de Poisson. Suponha que T_1, T_2..., T_n são iid com densidade Expo(1). Seja S_n o tempo de espera do n-ésimo evento, isto é, $S_n = \sum_{i=1}^{n} T_i$. Seja X(t) o Processo de Poisson correspondente.

a) Suponha que estamos interessados na evolução do processo apenas até o instante t =10. Precisamos determinar um número "grande" N tal que, com alta probabilidade, S_N (a soma de N tempos entre ocorrências) é maior ou igual a 10 com alta probabilidade (por exemplo, 99.9%). Use o fato: $S_N \sim$ Gama(N, 1) para encontrar N tal que $Pr\{S_N \ge 10\} \ge 99.9\%$.
b) Para o valor de N encontrado acima, gere 200 amostras de tamanho N da distribuição Exponencial(1). Use estas amostras para produzir 200 Processos de Poisson simulados. Faça um gráfico de X(t) versus t ($t \in [0, 10]$) para 5 destas realizações.
c) Use as simulações do item b) para gerar 200 observações de X(10) e X(5) e faça histogramas de X(10) e X(5). As freqüências relativas observadas estão de acordo com o que a teoria diz?
d) Considere as 200 observações de X(10) - X(5). Faça um histograma. As freqüências relativas observadas estão de acordo com o que a teoria diz?

CAPÍTULO 5: INTRODUÇÃO ÀS SÉRIES TEMPORAIS E AOS MODELOS ARIMA

Neste capítulo faremos uma introdução às séries temporais. O nosso objetivo aqui é puramente operacional e estaremos mais preocupados com as definições básicas e alguns exemplos simples, já que o estudo de séries temporais é tão extenso que justifica um curso em separado.

Séries Temporais não são comumente estudadas em cursos básicos de Estatística. Por quê? Pois no estudo de Séries Temporais a noção de dependência entre as observações é crucial. Ao contrário, na maioria dos procedimentos estudados em cursos elementares, supõe-se que as observações formem uma amostra aleatória, isto é, são independentes e identicamente distribuídas.

5.1. Introdução - Algumas Considerações sobre Séries Temporais

Definição 5.1.1. Série Temporal
Uma *Série Temporal* é um conjunto de observações ordenadas no tempo (não necessariamente igualmente espaçadas), e que apresentam dependência serial (isto é, dependência entre instantes de tempo). A notação usada aqui para denotar uma Série Temporal é Z_1, Z_2, Z_3..., Z_T, que indica uma série de tamanho T. O instante T geralmente indica o último instante disponível.

De uma maneira um pouco mais formal, dizemos que uma série temporal é uma **realização de um processo estocástico**.

Definição 5.1.2. Processo Ergódico
Um **processo estocástico** é dito **ergódico** se uma única realização do processo é o suficiente para caracterizá-lo. Na análise de séries temporais existe **apenas uma** realização do processo disponível e, portanto precisamos supor que o processo subjacente é ergódico, pois iremos usar apenas uma de suas realizações para caracterizá- lo.

Em geral, ao estudarmos uma Série Temporal estaremos interessados em dois aspectos:

a) **Análise e Modelagem** da Série Temporal - descrever a série, verificar suas características mais relevantes e suas possíveis relações com outras séries;
b) **Previsão** da Série Temporal - a partir de valores passados da série (e talvez de outras séries também) encontrar boas previsões (de curto prazo) de valores futuros da série. A previsão da série no instante T + k será denotada por $\hat{Z}_{T+k}$. O número de instantes à frente para o qual é feita a previsão (neste caso, k) é chamado de **horizonte de previsão**. Por exemplo, a previsão de Z_{T+1} é denotada por $\hat{Z}_{T+1}$.

A dependência serial entre os valores da série é um aspecto *essencial*, pois nos permite gerar previsões de valores futuros da série. Estas previsões seriam puro "chute" se não houvesse dependência serial. Também, diferentes séries possuem diferentes "graus" de previsibilidade; por exemplo, é freqüentemente mais fácil prever uma série de temperaturas médias mensais do que a taxa mensal de inflação. Logo, não se pode garantir que a previsão encontrada por este ou aquele método será sempre "boa", tudo depende das características da série que está sendo estudada! No entanto, um aspecto deve ser levado em conta ao fazermos previsões de séries temporais: o nível de incerteza aumenta com o horizonte de previsão – *quanto mais longe no futuro, maior é a incerteza associada à previsão*. Isto é intuitivamente razoável, é sempre mais difícil prever o futuro distante, e a nossa previsão estará cercada de incertezas!

Uma medida do "acerto" das nossas previsões é o erro de previsão k-passos à frente, definido a seguir.

Definição 5.1.3. Erro de Previsão k Passos à Frente
O erro de previsão k passos à frente no instante t (onde k é um inteiro maior ou igual a um) é definido como a diferença entre o valor real da série no instante t e a previsão deste valor feita k instantes antes, isto é:

$$e_k(t) = Z_t - \hat{Z}_{t-k}(k)$$

Um caso particular importante é o erro de previsão um passo à frente, dado por:

$$e_1(t) = Z_t - \hat{Z}_{t-1}(1)$$

Um "bom" modelo de previsão produz previsões com erro pequeno, e assim é interessante acompanhar quantidades como a soma dos quadrados dos erros de previsão, ou a soma dos valores absolutos dos erros de previsão.

E como funcionam estas ferramentas quantitativas que nos permitem prever o futuro de uma série temporal?

- Vamos utilizar o passado (dados históricos) para descrever a trajetória mais provável da série no futuro.
- **Isso não é uma bola de cristal!**
- Na maioria dos problemas o passado traz informações relevantes sobre o que irá ocorrer no futuro, pois existe "correlação" entre as variáveis em diversos instantes.
- É claro que o conhecimento do passado não nos diz exatamente como será o futuro, e então sempre existe incerteza associada às nossas previsões!
- Mas, podemos ter uma boa idéia de quais serão os valores mais prováveis no futuro!
- Ou seja, **podemos especificar previsões futuras e limites de confiança.**

Por que usar previsões quantitativas, baseadas em modelos estatísticos?

As previsões quantitativas, baseadas em modelos estatísticos, são importantes, pois podem ser reproduzidas, isto é: dois analistas diferentes chegam às mesmas conclusões se utilizarem o mesmo modelo.

Também as previsões obtidas por métodos estatísticos têm uma justificativa teórica - o resultado encontrado não é baseado apenas em argumentos do tipo: "eu acho que...", "baseado na minha experiência..." etc...

Finalmente, as previsões são obtidas a partir de um modelo, que é uma simplificação da realidade. O processo de modelagem nos leva naturalmente a considerar apenas os aspectos "essenciais" do nosso problema e por si só costuma trazer bastante informação sobre o problema que está sendo tratado.

Afinal, o que queremos ao modelar uma série temporal?

- Capturar "toda" a estrutura de dependência existente na série;
- Logo, nos resíduos não deve "sobrar" estrutura, pois ela já foi captada pelo modelo. Nota: o resíduo é apenas a diferença entre o valor real e o ajustado por um modelo qualquer. Por exemplo, seja Z_t o valor real da série no instante t, e $\hat{Z}_t$ seu valor ajustado pelo modelo. Então, o resíduo no instante t é apenas Z_t - $\hat{Z}_t$.
- Em particular, se o modelo é bom, os resíduos não devem apresentar correlação serial (isto é, correlação entre os resíduos em diferentes instantes de tempo);
- Explicar o comportamento da série com o menor número de parâmetros (parcimônia).

Dica Prática... Por onde começar

Em geral, a primeira coisa que fazemos ao estudar uma série temporal é construir um gráfico para mostrar a sua evolução ao longo do tempo. Este procedimento simples costuma ser bastante esclarecedor, e nos permite identificar como evolui a tendência da série, se existe ou não sazonalidade, se ocorrem observações aberrantes etc... Logo, a minha sugestão é: sempre comece a sua análise da maneira mais simples – faça o gráfico da série de interesse!

Séries temporais ocorrem com enorme freqüência na prática. No quadro a seguir, exibimos os gráficos de algumas séries temporais reais.

Quadro 5.1.1. - Algumas Séries Temporais

Preços Mensais Internacionais de Celulose em US$ fixos

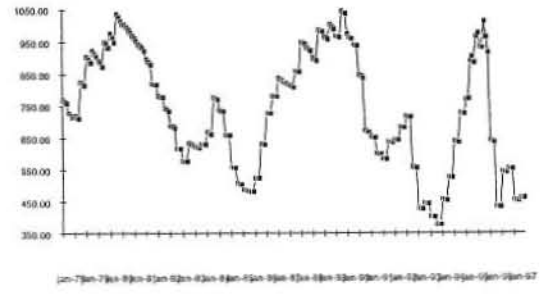

Vendas Mensais de Refrigerantes em embalagens de 290 ml

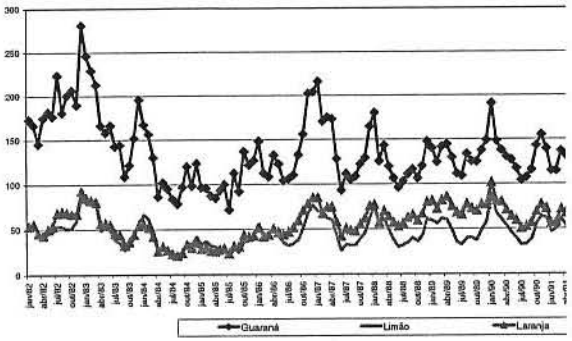

Temperatura Máxima Mensal no Rio de Janeiro (média das máximas diárias)

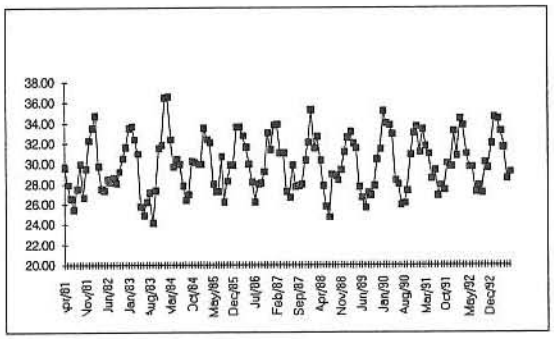

Preços de Títulos da Dívida Externa do Brasil, Argentina e México

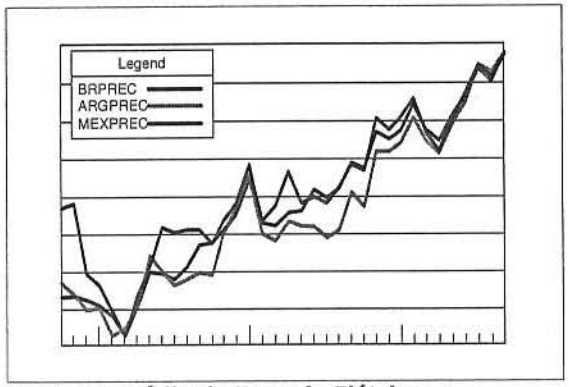

Consumo Médio de Energia Elétrica

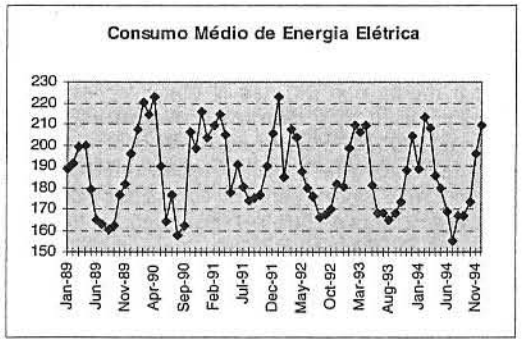

Inflação Mensal do Rio de Janeiro

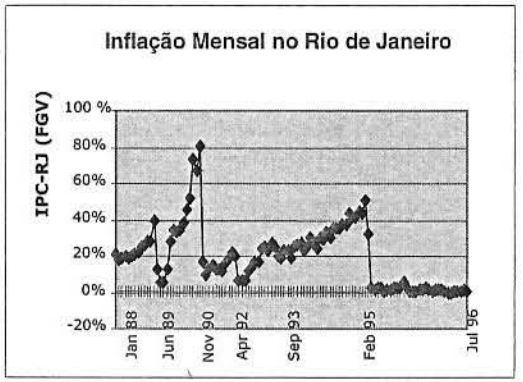

Podemos fazer uma distinção básica entre duas grandes classes de modelos:

- **Modelos Univariados**: a série temporal é explicada (prevista) apenas pelos seus valores passados;
- **Modelos Multivariados ou Causais**: a série temporal é explicada (prevista) pelos seus valores passados e também pelos valores passados de outras variáveis.

Neste capítulo consideraremos apenas modelos univariados.

Exemplo 5.1.3. Alguns Modelos Univariados

i) Naive (ingênuo)
A previsão de Z_{T+1} (valor da série no instante T +1) é apenas a última observação (Z_T). É claro que você não precisa de um "software" para ajustar isso e, em alguns casos, é o único "método" disponível. Um exemplo clássico é a

previsão do preço de uma ação - geralmente a melhor previsão para o preço de amanhã é o preço de hoje, o que certamente é frustrante!

ii) Médias móveis de tamanho N
A cada instante, a previsão é apenas a média das últimas N observações. Um dos problemas com este método é a escolha de N, o **tamanho da janela** a ser utilizado. Quanto maior o valor de N, mais "suave" é a previsão. Ao contrário, se N é pequeno, a previsão tende a ser meio "nervosa", isto é, oscila muito. Uma característica importante do método de médias móveis é: **todas as observações** usadas para o cálculo **têm o mesmo peso** (que é 1/N). Mas, na prática é razoável supor que as observações mais recentes sejam mais relevantes para a previsão dos próximos valores da série e, portanto, deveriam receber um peso maior que as observações mais antigas. Esta idéia de pesar ou ponderar as observações de acordo com as suas "idades" leva aos diversos métodos de amortecimento exponencial.

iii) Amortecimento Exponencial ("Exponencial Smoothing")
Existem inúmeras variações destes métodos, para séries sazonais e não sazonais. A idéia geral é parecida com a do método de médias móveis, mas os pesos das observações decrescem à medida que as observações estão mais longe no passado. A taxa de decréscimo do(s) peso(s) é determinada por uma ou mais constantes de amortecimento. A maior dificuldade na aplicação é escolher a(s) constante (s) de amortecimento, mas alguns softwares já ajustam os modelos de amortecimento automaticamente com constantes de amortecimento otimizadas.

Na prática, os métodos de amortecimento são os métodos de previsão mais usados no dia a dia das empresas, o que é em parte explicado pela sua facilidade de implementação e capacidade em gerar boas previsões.

iv) Modelos ARIMA de Box e Jenkins
São modelos mais sofisticados, que usam as correlações entre as observações em diversos instantes. A idéia por trás dos modelos ARIMA envolve filtros lineares e algum conhecimento de Teoria de Sistemas é útil. A identificação da estrutura do modelo é um pouco complicada, mas alguns softwares já identificam automaticamente a estrutura do modelo ARIMA, evitando o passo mais complicado da análise. Como casos particulares dos modelos ARIMA temos os processos AR (Autoregressivo) e MA (Médias móveis ou "moving average"), já estudados brevemente no capítulo 2.

Os modelos ARIMA costumam apresentar melhores resultados que os métodos de amortecimento quando a série é relativamente longa e "bem comportada".

Se a série é muito irregular, os resultados são, geralmente, inferiores aos obtidos por métodos de amortecimento.

Existem também modelos ARIMA multivariados, geralmente chamados de "modelos de função de transferência", mas eles não serão estudados aqui.

Decomposição de Uma Série Temporal

A maneira tradicional de analisar uma série temporal é através da sua decomposição nas componentes de **tendência, ciclo e sazonalidade.**

A **tendência** de uma série indica o seu comportamento "de longo prazo", isto é, se ela sobe, desce, ou permanece estável, e qual a velocidade destas mudanças. Nos casos mais comuns, trabalhamos com tendência constante, linear ou quadrática, como mostrado na próxima figura.

Quadro 5.1.2. – Tendência de uma série

Tendência Constante

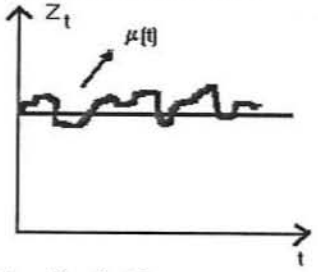

Tendência Linear

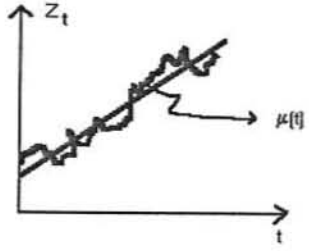

Tendência Quadrática

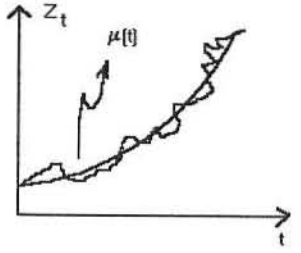

A **sazonalidade** indica a repetição de um padrão na série dentro do período de

um ano. Por exemplo, vendas de sorvete são altas no verão e baixas no inverno. No quadro 5.1.1., as séries de temperatura, consumo de energia elétrica e vendas de refrigerantes são claramente sazonais, mas não se pode dizer o mesmo das outras séries.

Os **ciclos** indicam padrões que se repetem na série em períodos superiores a um ano. Por exemplo, ciclos relacionados à atividade econômica ou ciclos meteorológicos.

Características de uma Série Temporal e Estimadores
Um processo estocástico estacionário de 2ª ordem pode ser descrito (no domínio do tempo) por sua média, variância e função de autocovariância (ou de autocorrelação). Na prática não conhecemos totalmente o processo estocástico que gerou a série que está sendo observada, e estas quantidades (média, variância, autocorrelação) devem ser estimadas a partir da série temporal, como indicado no capítulo 2.

5.2. Métodos de Amortecimento Exponencial (Séries Não Sazonais)

Existem inúmeras variações de métodos de amortecimento exponencial. Todas elas, na verdade, têm uma característica comum: a informação atual (representada pelo último valor observado) é ponderada com a informação contida nos instantes anteriores. A existência de uma ou mais constantes de amortecimento irá determinar como funciona este mecanismo de ponderação ou, em outras palavras, o quão rapidamente decai a influência das observações passadas. Os parâmetros do modelo sofrem uma atualização seqüencial, e a chegada de uma nova observação resulta numa nova estimativa dos parâmetros.

Nesta seção estudamos diversos métodos de amortecimento exponencial para séries não sazonais. A extensão destes métodos para séries sazonais é mostrada na próxima seção.

Os métodos de amortecimento exponencial são formas até certo ponto arbitrárias de representar uma série temporal, mas são muito importantes na prática, pois geralmente produzem previsões razoáveis a partir de um esforço computacional baixo. Na verdade, estes métodos são freqüentemente citados como os "favoritos" dos não especialistas em séries temporais, pela qualidade das previsões geradas e facilidade de implementação. Os métodos de amortecimento mais famosos são: Brown, Holt e Winters.

Um ponto potencialmente complicado em todos esses métodos é a escolha da(s) constante (s) de amortecimento, mas na prática isso não é mais problema, já que a maioria dos softwares de séries temporais ajusta modelos com a(s) constante (s) otimizadas.

Seja $\underline{Z_T} = (Z_1, Z_2, \ldots, Z_T)$ uma série temporal de tamanho T. Desejamos escrever um modelo geral para explicar o comportamento da série a cada instante e permitir a produção de previsões futuras.
Suponha que o modelo geral para uma observação qualquer no instante t

genérico é: $Z_t = \mu(t) + \varepsilon_t$ onde ε_t é um ruído aleatório com média zero e variância constante σ_ε^2. O termo $\mu(t)$ representa o **nível médio da série**, que é função apenas do instante de tempo.

Iremos estudar três casos particulares: $\mu(t)$ é constante, uma função linear e uma função quadrática do tempo.

A partir das propriedades da média e da variância podemos concluir que:

$$E(Z_t) = \mu(t) \text{ para todo } t = 1,2,3,\ldots. \qquad (5.2.1)$$
$$VAR(Z_t) = \sigma_\varepsilon^2 = \text{constante}$$

A seguir, derivamos estimadores para os parâmetros desconhecidos dos modelos de nível constante, linear e quadrático e encontramos as respectivas equações de previsões.

Freqüentemente iremos supor que os erros $\varepsilon_1, \varepsilon_2 \ldots, \varepsilon_T$ são independentes com uma distribuição de probabilidade conhecida (por exemplo, a Normal) com média zero e variância constante. Das equações acima é fácil ver que a estimação da variância de Z_t (que é igual à variância de ε_t) não apresenta grandes dificuldades, basta utilizar os estimadores usuais da variância de uma amostra aleatória. Por isso, na discussão a seguir, nós nos concentraremos na estimação dos parâmetros que definem o nível médio da série.

5.2.1. Modelo Constante (Horizontal)
Este é um modelo apropriado quando a série temporal apenas oscila em torno de um valor constante, sem exibir tendência de crescimento ou queda. A função **nível médio** é dada por: $\mu(t) = a_1$ para todo instante t = 1, 2, 3..., T.

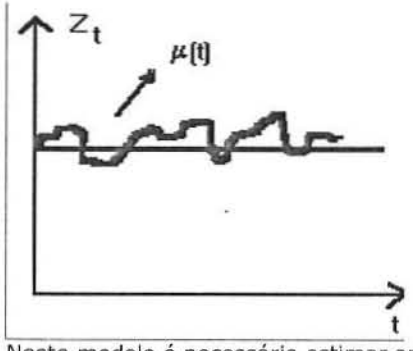

Neste modelo é necessário estimar apenas 2 parâmetros:

- a_1 (o nível médio da série) e
- σ^2 (a variância da série).

A **previsão k passos à frente** obtida no instante T é:

$$\hat{Z}_T(k) = E\{Z_{T+k} \mid \underline{Z_T}\} = E\{a_1 + \varepsilon_{T+k} \mid \underline{Z_T}\} = \hat{a}_1(T) \qquad (5.2.2)$$

Logo, se conhecermos um estimador do parâmetro a_1 poderemos encontrar as previsões pontuais para qualquer horizonte de tempo k.

E como podemos estimar a constante a_1 (nível médio da série)? Existem diversas possibilidades, mostradas a seguir.

Modelo Constante - Estimação do Nível Médio da Série

1) Estimador Ingênuo ("naive")

$\hat{a}_1(T) = Z_T$ onde Z_T indica a última observação disponível.

2) Estimador Médias Móveis de Tamanho N

O nível médio da série num certo instante é estimado como a média móvel de tamanho N usando as observações Z_T, Z_{T-1}..., Z_{T-N+1}, isto é:

$$\hat{a}_1(T) = M_T = \frac{Z_{T-N+1} + \ldots + Z_{T-1} + Z_T}{N} \qquad (5.2.3)$$

Uma questão crucial neste caso é definir qual o tamanho da "janela" a ser usada, isto é, quantas observações serão utilizadas no cálculo da média móvel. Note que, se N = 1, apenas a última observação é usada, e o método se reduz ao método ingênuo. Por outro lado, se N = T (tamanho da série), temos o chamado "método conservador", em que todas as observações disponíveis são empregadas na estimação do nível médio da série, e $\hat{a}_1(T) = \overline{Z}$, a média amostral da série.

O tamanho da janela utilizada (N) pode ser escolhido como aquele inteiro positivo que minimiza a soma de quadrados dos erros de previsão 1 passo à frente, isto é, escolhe-se N de forma a minimizar:

$$S(N) = \sum_{t=1}^{T} e_1^2(t)$$

3) Estimador pelo Método de Amortecimento Exponencial

Note que o estimador do nível da série produzido pelo método de médias móveis pode ser escrito como:

$$\hat{a}_1(T) = M_T = \frac{Z_{T-N+1} + \ldots + Z_{T-1} + Z_T}{N} = M_{T-1} + \frac{Z_T - Z_{T-N}}{N} \qquad (5.2.4)$$

Onde M_{T-1} é a média móvel de tamanho N calculada no instante anterior. Em outras palavras, o estimador do nível envolve uma informação "atual" (representada por Z_T, o último valor observado da série) e uma informação "passada" (M_{T-1} e Z_{T-N}).
O método de amortecimento exponencial estende esta idéia de ponderação da informação presente e passada. Na equação (5.2.4) substitua Z_{T-N} por M_{T-1}.

Isso nos leva ao seguinte estimador:

$$\hat{a}_1(T) = M_{T-1} + \frac{Z_T}{N} - \frac{M_{T-1}}{N} = \left(\frac{1}{N}\right) Z_T + \left(1 - \frac{1}{N}\right) M_{T-1}$$

Ou seja, este novo estimador tem a forma: (peso)*(informação atual) + (1 - peso)*(informação passada). Note que $\hat{a}_1(T)$ é a previsão do nível da série efetuada no instante atual T e podemos reescrever esta última equação como:

$$\hat{a}_1(T) = \left(\frac{1}{N}\right) Z_T + \left(1 - \frac{1}{N}\right) M_{T-1} = \left(\frac{1}{N}\right) Z_T + \left(1 - \frac{1}{N}\right) \hat{a}_1(T-1)$$

onde $\hat{a}_1(T-1)$ é a média móvel de tamanho N calculada até (inclusive) a observação T-1, ou seja, é a estimativa prévia do nível da série, Em outras palavras: a previsão atual do nível (dada por $\hat{a}_1(T)$) é baseada na ponderação do valor mais recente da série (Z_T) e da última previsão para o nível ($\hat{a}_1(T-1)$).

Uma forma mais geral de definir um estimador com esta característica de ponderação das informações passadas e presentes é:

$$\Rightarrow \hat{a}_1(T) = M_T = \alpha Z_T + (1-\alpha) M_{T-1} = \alpha . Z_T + (1-\alpha)\, \hat{a}_1(T-1) \qquad (5.2.5)$$

onde $\alpha \in [0, 1]$ é a **constante de amortecimento**, que controla a taxa de decaimento da informação.

A equação (5.2.5) apresenta algumas características interessantes:

1) é bastante econômica do ponto de vista computacional, pois é preciso guardar, a cada instante, apenas o último valor observado e a estimativa anterior do nível, isto é, não precisamos guardar todos os valores anteriores da série temporal para gerar a previsão do nível;
2) o método funciona bastante bem, desde que a série não apresente uma tendência.

Ao rearranjar os termos da equação (5.2.5) e encontramos:

$$\hat{a}_1(T) = \alpha Z_T + (1-\alpha) M_{T-1} = \hat{a}_1(T-1) + \alpha\left(Z_T - \hat{a}_1(T-1)\right) \qquad (5.2.6)$$

A expressão (5.2.6) é freqüentemente conhecida como *"forma de correção do erro"*. Nela, o mecanismo de atualização da previsão do nível fica explícito: o nível estimado num instante T é igual ao nível estimado no instante anterior mais um múltiplo do erro de previsão um passo à frente cometido no instante anterior (que é $Z_T - \hat{a}_1(T-1)$).

Seja e_{T-1} o erro de previsão um passo à frente no instante T-1, isto é:

$e_{T-1} = Z_T - \hat{a}_1(T-1)$ e então podemos rearranjar os termos e escrever: $Z_T = e_{T-1} + \hat{a}_1(T-1)$.
Se aplicarmos a equação (5.2.6) à previsão do nível no instante T + 1

encontramos:

$$\hat{a}_1(T+1) = \alpha Z_{T+1} + (1-\alpha)M_T = \hat{a}_1(T) + \alpha(Z_{T+1} - \hat{a}_1(T)) = \hat{a}_1(T) + \alpha.e_T$$

Daí:

$$Z_{T+1} - Z_T = (e_{T+1} + \hat{a}_1(T)) - (e_T + \hat{a}_1(T-1)) = e_{T+1} - e_T + (\hat{a}_1(T) - \hat{a}_1(T-1)) =$$
$$e_{T+1} - e_T + \alpha.e_T = e_{T+1} + (1-\alpha)e_T$$

Esta expressão não é útil do ponto de vista preditivo, pois o lado direito contém os "outputs" (erros de previsão um passo à frente) enquanto o lado esquerdo contém os "inputs" (observações). Mas, esta expressão é importante em termos estruturais, pois se os e's (erros de previsão um passo à frente) são substituídos por choques aleatórios, o modelo resultante é um ARIMA (0,1,1), que será estudado na próxima seção. Num modelo ARIMA(0,1,1) o método de amortecimento exponencial simples estudado aqui fornece previsões ótimas.

Por substituições sucessivas na equação (5.2.5) encontramos:

$$M_T = \alpha Z_T + \alpha(1-\alpha)\, Z_{T-1} + \alpha(1-\alpha)^2\, Z_{T-2} + \ldots + \alpha(1-\alpha)^{T-1}\, Z_1 \qquad (5.2.7)$$

Esta última equação mostra claramente como funciona o método de amortecimento exponencial: cada estimativa do nível (dada por M_T) é uma soma ponderada da observação atual (Z_T) e das observações passadas. Os pesos decrescem exponencialmente, e a taxa de decaimento dos pesos depende da constante α.

Qual o efeito da constante de amortecimento α? Note que, da equação (5.2.7), o peso da observação Z_{T-k} é $\alpha(1-\alpha)^k$ (para k = 0, 1, 2...). Logo, a razão entre os pesos da observação Z_{T-k} e da observação atual (Z_T) é $(1-\alpha)^k$. Se α é grande (próximo de 1) os pesos decaem rapidamente, e uma observação que está "longe" no passado não tem qualquer influência sobre a estimativa atual do nível, que é estimado usando quase exclusivamente as observações mais recentes. Ao contrário, se α é pequeno (por exemplo, menor que 0.3), uma observação "longe" no passado pode ainda ter uma influência considerável na estimação do nível feita hoje.

A tabela a seguir apresenta alguns valores de α e a "meia vida" das observações, isto é, quantas defasagens são necessárias até que o peso da observação se reduza à metade. A meia vida das observações é encontrada resolvendo a seguinte equação para k (o "lag"):

$$\frac{\text{peso de } Z_{T-k}}{\text{peso de } Z_T} = \frac{1}{2} \Leftrightarrow \frac{\alpha(1-\alpha)^k}{\alpha} = \frac{1}{2} \Leftrightarrow k.\log(1-\alpha) = -\log(2) \Leftrightarrow k = \frac{-\log(2)}{\log(1-\alpha)}$$

onde log(.) indica o logaritmo natural. Como k indica uma defasagem, deve-se escolher o valor k inteiro não negativo que satisfaz (aproximadamente) esta equação.

Tabela 5.2.1. – Meia Vida das Observações como Função de α

α	número de "lags" até o peso cair pela metade
0,99	0,15
0,95	0,23
0,90	0,30
0,80	0,43
0,70	0,58
0,60	0,76
0,50	1,00
0,45	1,16
0,40	1,36
0,35	1,61
0,30	1,94
0,25	2,41
0,20	3,11
0,15	4,27
0,10	6,58
0,05	13,51
0,02	34,31
0,01	68,97

Por exemplo, se α = 0,02, a observação situada há 34 "lags" contém aproximadamente metade da informação do dado atual. Se α = 0,05, são necessárias cerca de 14 defasagens até que o peso da observação caia pela metade.

Nota: Reparametrização

Em alguns livros encontra-se o método de amortecimento escrito de maneira diferente. Seja $\theta = 1-\alpha$ na equação (5.2.7). Em termos de θ esta equação torna-se:

$$M_T = (1-\theta)Z_T + \theta(1-\theta)\, Z_{T-1} + \theta^2(1-\theta)\, Z_{T-2} + \ldots + \theta^T(1-\theta)Z_1 \qquad (5.2.8)$$

Logo, o peso da observação atual é $(1-\theta)$ e o da k-ésima observação no passado é $\theta^k(1-\theta)$. Nesta parametrização, valores altos de θ indicam que a memória do processo é relativamente longa, ou seja, a influência das observações passadas demora a decair.

Exemplo 5.2.1.
A tabela a seguir exibe os primeiros valores da série temporal: $Z_t = 2 + e_t$ onde os e_t' s são ruídos iid com distribuição Normal de média 0 e desvio padrão ½. Supomos que em t = 0, $Z_0 = 0$ (apenas para permitir a inicialização do processo), e o objetivo aqui é demonstrar a estimação seqüencial de a_1 por amortecimento exponencial e médias móveis (de tamanho 2, 3 e 4). Note que, depen-

dendo da escolha da constante de amortecimento (ou da janela utilizada na média móvel), a estimativa do nível é mais ou menos "nervosa" (e oscila mais ou menos à medida que recebemos cada valor da série). Verifique os valores estimados para o nível da série. Faça (em casa) o gráfico da evolução no nível estimado ao longo do tempo para todos os métodos indicados.

Instante t	Erros (e(t))	Série (Z(t))	Estimador MM(2)	Estimador MM(3)	Estimador MM(4)	Estimador Amort. Expo. (Alfa=0.2)	Estimador Amort. Expo. (Alfa=0.3)
1	-1,512	0,488	0,244			0,098	0,147
2	0,080	2,080	1,284	0,856		0,494	0,692
3	-0,433	1,567	1,824	1,379	1,034	0,709	0,816
4	0,437	2,437	2,002	2,028	1,643	1,054	1,227
5	0,107	2,107	2,272	2,037	2,048	1,265	1,370
6	-0,025	1,975	2,041	2,173	2,021	1,407	1,478
7	-0,192	1,808	1,891	1,963	2,082	1,487	1,527
8	0,629	2,629	2,219	2,137	2,130	1,716	1,830
9	0,463	2,463	2,546	2,300	2,219	1,865	1,940
10	0,332	2,332	2,398	2,475	2,308	1,958	2,005
11	-0,469	1,531	1,931	2,109	2,239	1,873	1,830
12	0,538	2,538	2,034	2,134	2,216	2,006	2,072
13	0,277	2,277	2,408	2,115	2,170	2,060	2,087
14	0,017	2,017	2,147	2,277	2,091	2,052	2,047
15	-0,256	1,744	1,880	2,013	2,144	1,990	1,959

5.2.2. Modelo Linear

Esta estrutura é adequada quando existe uma tendência clara de crescimento (ou queda) ao longo do tempo, como indicado na próxima figura. A função **nível médio** é dada por: $\mu(t) = a_1 + a_2.t$ para todo instante t = 1, 2, 3..., T.

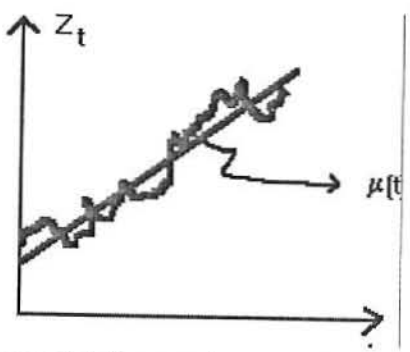

O modelo linear pode ser escrito como:

$Z_t = a_1 + a_2.t + \varepsilon_t$ onde t = 1,2,....,T e os ε_t são os erros (choques) aleatórios, supostos independentes e identicamente distribuídos com média zero e variância constante σ^2. Desta expressão (e usando as propriedades da média e variância) segue direto que:

$$E(Z_t) = a_1 + a_2.t \text{ e } VAR(Z_t) = \sigma^2 = VAR(\varepsilon_t) \qquad (5.2.9)$$

Neste modelo é necessário estimar três parâmetros: a_1 (coeficiente linear da série), a_2 (coeficiente angular da reta, ou seja, a taxa de crescimento da série) e σ^2 (a variância da série).

A **previsão k passos à frente** obtida no instante T é:

$$\hat{Z}_T(k) = E\{Z_{T+k} \mid \underline{Z_T}\} =$$
$$E\{a_1 + a_2(T+k) + \varepsilon_{T+\tau} \mid \underline{Z_T}\} = \hat{a}_1(T) + \hat{a}_2(T).(T+k) \qquad (5.2.10)$$

A previsão dada pela equação (5.2.10) pode ser escrita de uma forma ligeiramente diferente, desde que façamos uma mudança da origem.

Modelo Linear - Estimação dos parâmetros a_1 e a_2

Analogamente ao que fizemos para o modelo constante, a seguir, apresentaremos diversos estimadores para os parâmetros desconhecidos que descrevem a evolução do nível da série.

A partir dos valores estimados de a_1 e a_2 podemos encontrar a previsão de uma observação futura qualquer, apenas aplicando a equação (5.2.10).

1) Estimadores de Mínimos Quadrados Ordinários (MQO)

Nosso objetivo é encontrar a_1 e a_2 tais que a seguinte soma seja minimizada:

$$SSE = \sum_{t=1}^{T} \underbrace{[Z_t - (a_1 + a_2 t)]}_{\varepsilon_t}^2 \qquad (5.2.11)$$

SSE é chamado de soma dos quadrados dos erros (ou soma do quadrado dos resíduos). O método de mínimos quadrados é bastante geral, e se aplica à estimação de um número qualquer de parâmetros $a_1, a_2..., a_k$ (supõe-se que k é menor que o tamanho da série, para permitir a estimação). Considere, de maneira mais geral, um modelo com a seguinte estrutura:

$Z_t = f(a_1, a_2, ..., a_k, t) + \varepsilon_t$ onde f(.) é uma função (possivelmente não linear) do tempo e dos parâmetros desconhecidos. Então a soma dos quadrados dos erros é dada por:

$$SSE = \sum_{t=1}^{T} (Z_t - f(a_1, a_2, ..., a_k, t))^2 = \sum_{t=1}^{T} \varepsilon_t^2$$

O método de mínimos quadrados procura encontrar estimadores dos parâmetros desconhecidos de forma a minimizar a soma do quadrado dos erros (SSE).

Note que os estimadores por mínimos quadrados encontrados pela minimização da soma do quadrado dos erros são calculados usando a série inteira, ou seja, usamos todos os dados disponíveis de uma só vez. Ao contrário, nos métodos médias móveis e de amortecimento, a atualização dos parâmetros é seqüencial, e o recebimento de uma nova observação resulta em novos valores estimados para a_1 e a_2.

2) Estimadores pelo Método de Médias Móveis Duplas
Defina a média móvel dupla de tamanho N como:

$$M_T^{[2]} = \frac{M_T + M_{T-1} + \ldots + M_{T-N+1}}{N} \qquad (5.2.12)$$

Onde M_T é a média móvel (simples) de tamanho N calculada usando todas as observações até o instante T (inclusive).

Por que usar médias móveis duplas?
Se os dados exibem uma tendência linear, o uso de médias móveis simples para a previsão dos valores da série induz a erros sistemáticos, pois a média móvel simples segue a tendência com um certo atraso, e este efeito é amplificado quando tentamos prever valores futuros. O método de médias móveis duplas procura diminuir este efeito sistemático.

Pode-se mostrar que:

$$E\{M_T\} = a_1(T) + T.a_2(T) - \frac{N-1}{2}.a_2(T)$$

$$E\{M_T^{[2]}\} = a_1(T) + T.a_2(T) - (N-1)a_2(T)$$

Resolvendo o sistema anterior para a_1 e a_2 leva a:

$$a_1(T) = 2.E\{M_T\} - E\{M_T^{[2]}\} - T.a_2(T)$$

$$a_2(T) = \frac{2}{(N-1)}\left\{E\{M_T\} - E\{M_T^{[2]}\}\right\} \qquad (5.2.13)$$

Se substituirmos os valores esperados de M_T e $M_T^{[2]}$ na expressão (5.2.13) pelos valores efetivamente observados M_T e $M_T^{[2]}$ encontramos os estimadores de a_1 e a_2 com base na série observada até o instante T, dados por:

$$\hat{a}_1(T) = M_T + \left(M_T - M_T^{[2]}\right) - T.\hat{a}_2(T) = 2.M_T - M_T^{[2]} - T.\hat{a}_2(T)$$

$$\hat{a}_2(T) = \frac{2}{(N-1)}\left\{M_T - M_T^{[2]}\right\} \qquad (5.2.14)$$

O estimador $\hat{a}_1(T)$ é encontrado corrigindo-se a média móvel simples (M_T) pela diferença entre ela e a média móvel dupla. Se, na verdade, não existisse uma tendência linear, o fator de correção seria pequeno.
A previsão k passos à frente no instante T é:

$$\hat{Z}_{T+k} = \hat{a}_1(T) + \hat{a}_2(T).(T+k) = 2.M_T - M_T^{[2]} - T.\hat{a}_2(T) + T.\hat{a}_2(T) + k.\hat{a}_2(T) =$$

$$= 2.M_T - M_T^{[2]} + k.\hat{a}_2(T) = 2.M_T - M_T^{[2]} + k.\left\{\frac{2}{N-1}\left\{M_T - M_T^{[2]}\right\}\right\}$$

Expressão alternativa para as equações de atualização do método de médias móveis duplas

DeLurgio (1998) propõe o uso de uma versão modificada das equações de atualização (5.2.14). As novas (e mais simples) equações de atualização são:

$$\hat{a}_1(T) = M_T + \left(M_T - M_T^{[2]}\right) = 2.M_T - M_T^{[2]}$$

$$\hat{a}_2(T) = \frac{2}{(N-1)}\left\{M_T - M_T^{[2]}\right\} \qquad (5.2.15)$$

E a equação de previsão k passos à frente torna-se:

$$\hat{Z}_{T+k} = \hat{a}_1(T) + \hat{a}_2(T).(k) = 2.M_T - M_T^{[2]} + k.\hat{a}_2(T) = 2.M_T - M_T^{[2]} + k.\left\{\frac{2}{N-1}\left\{M_T - M_T^{[2]}\right\}\right\}$$

Vantagens e Desvantagens deste método

- a implementação é trivial;
- os estimadores obtidos pelo método não são muito influenciados por outliers;
- a escolha do número ótimo de "lags" a serem usados nas médias móveis simples e duplas não é trivial.

Exemplo 5.2.2.
Um ponto importante a ser lembrado quando tratamos de métodos de médias móveis é: estes procedimentos implicam um conjunto de pesos definidos para as observações passadas. Isso nos permite compará-los com os métodos de amortecimento exponencial.

Por exemplo, considere um modelo linear onde os parâmetros desconhecidos são estimados por médias móveis simples e duplas de tamanho 3. Como podemos escrever os estimadores em termos dos valores observados da série?

Note que, neste caso, para qualquer instante t maior que 3:

$$M_t = \frac{Z_t + Z_{t-1} + Z_{t-2}}{3}$$

$$M_t^{[2]} = \frac{M_t + M_{t-1} + M_{t-2}}{3}$$

E assim a previsão 1 passo à frente no instante T (com a origem transladada) é:

$$\hat{Z}_{T+1} = \hat{a}_1(T) + \hat{a}_2(T).(1) = 2M_T - M_T^{[2]} + \frac{2}{3-1}\left(M_T - M_T^{[2]}\right) =$$

$$= 2\,M_T - M_T^{[2]} + M_T - M_T^{[2]} = 3.M_T - 2.M_T^{[2]} = 3.M_T - 2\left(\frac{M_T + M_{T-1} + M_{T-2}}{3}\right) =$$

$$= \left(\frac{1}{3}\right)\left\{\frac{7}{3}M_T - 2M_{T-1} - 2M_{T-2}\right\} =$$

$$\left(\frac{1}{3}\right)\left\{\frac{7.(Z_T + Z_{T-1} + Z_{T-2})}{3} - \frac{2(Z_{T-1} + Z_{T-2} + Z_{T-3})}{3} - \frac{2(Z_{T-2} + Z_{T-3} + Z_{T-4})}{3}\right\} =$$

$$= \left(\frac{1}{3}\right)\left\{\left(\frac{7}{3}\right)Z_T + \left(\frac{5}{3}\right)Z_{T-1} + \left(\frac{3}{3}\right)Z_{T-2} + \left(\frac{-4}{3}\right)Z_{T-3} + \left(\frac{-2}{3}\right)Z_{T-4}\right\}$$

3) Método de Amortecimento Exponencial Duplo (Método de Brown)

Um método semelhante ao anterior é o método de amortecimento exponencial duplo, também conhecido como método de Brown. Nele, uma única constante de amortecimento é empregada no processo de atualização de ambos os parâmetros a_1 e a_2. Analogamente ao método de médias móveis duplas, a componente de tendência é estimada através da diferença entre um valor amortecido "simples" e um "duplo".

As equações de atualização no método de Brown são:

$$M_T = \alpha Z_T + (1-\alpha)\, M_{T-1}$$
$$M_T^{[2]} = \alpha M_T + (1-\alpha)\, M_{T-1}^{[2]} \qquad (5.2.16)$$

onde α é a constante de amortecimento.

Os estimadores de a_1 e a_2 encontrados pelo método de Brown são:

$$\hat{a}_1(T) = M_T + \left(M_T - M_T^{[2]}\right) = 2.M_T - M_T^{[2]}$$
$$\hat{a}_2(T) = \frac{\alpha}{(1-\alpha)}\left\{M_T - M_T^{[2]}\right\} \qquad (5.2.17)$$

Ou seja, estes estimadores têm a mesma forma que na equação (5.2.15). No entanto, agora M_T e $M_T^{[2]}$ **não mais** representam as médias móveis descritas no item 5.2.2., e são calculados através das equações (5.2.16).

A previsão k passos à frente no instante T é:

$$\hat{Z}_{T+k} = \hat{a}_1(T) + \hat{a}_2(T).(k) = 2.M_T - M_T^{[2]} + \frac{\alpha}{1-\alpha}\left\{M_T - M_T^{[2]}\right\} k \qquad (5.2.18)$$

Escolha dos valores iniciais
Em todos os métodos de amortecimento é necessário escolher valores iniciais

dos parâmetros de forma a inicializar as equações de atualização. Algumas escolhas possíveis são:

$$M_1 = Z_1$$
$$\hat{a}_1(1) = Z_1$$
$$\hat{a}_2(1) = \frac{(Z_2 - Z_1) + (Z_4 - Z_3)}{2}$$

Vantagens e Desvantagens do Método de Brown
- modela o nível e a tendência da série;
- é mais eficiente em termos computacionais que as médias móveis duplas;
- é menos flexível que o modelo de Holt (a seguir), que usa duas constantes de amortecimento.

4) Método de Holt (2 Parâmetros)

Este método é bastante parecido com o anterior, mas agora existem duas constantes de amortecimento diferentes, responsáveis pela "velocidade" de decaimento da informação na estimação dos coeficientes linear e angular, respectivamente.

O modelo de Holt é implementado através das seguintes equações:

$$M_T = \alpha.Z_T + (1-\alpha).(M_{T-1} + \hat{a}_2(T-1))$$

$$\hat{a}_2(T) = \beta.(M_T - M_{T-1}) + (1-\beta).\hat{a}_2(T-1) \qquad (5.2.19)$$

$$\hat{a}_1(T) = M_T$$

onde α e β são as constantes de amortecimento.

Características Importantes do Método

- As constantes de amortecimento usadas para cálculo do nível e tendência são diferentes;
- Na equação de atualização do nível, o novo nível é função de 3 variáveis: a observação mais recente (Z_T), a estimativa anterior do nível (M_{T-1}) e a taxa de crescimento estimada no instante anterior ($\hat{a}_2$ (T-1));
- A taxa de crescimento atualizada é função da taxa de crescimento no instante anterior e também depende da diferença entre os níveis nos instantes T-1 e T.

Escolha dos Valores Iniciais

Possíveis escolhas são:

$$\hat{a}_1(1) = Z_1$$
$$\hat{a}_2(1) = \frac{(Z_2 - Z_1) + (Z_4 - Z_3)}{2}$$

Vantagens e Desvantagens do Método de Holt

- modela o nível e a tendência da série;
- é mais flexível que o método de Brown, pois usa constante de amortecimento separada para o nível e a tendência;
- a contrapartida deste ganho em flexibilidade é a existência de um parâmetro adicional a ser otimizado, o que dificulta o processo de otimização.

Exemplo 5.2.3.

Considere uma série temporal puramente determinística, $Z_t = 2 + 3.t$. A tabela a seguir exibe alguns valores da série e as previsões um passo à frente de Z_t usando: 1) uma média móvel simples de tamanho 3, 2) a média móvel simples e a média móvel dupla, como na equação (5.2.15). Verifique os valores encontrados na tabela, e note que o erro da previsão um passo à frente obtida através da equação (5.2.15) é nulo em todos os instantes.

Instante t	Série Z(t) (puramente determinística)	MM (3)	Previsão 1 passo à frente de Z(t) usando MM (3)	Erro de previsão 1 passo à frente de Z(t) usando MM (3)	MM Dupla (3)	Diferença entre MM (3) e MM Dupla (3)	Previsão 1 passo à frente= MM (3) + (MM (3) - MMDup (3)) + tendência	Erro de Previsão 1 passo à frente usando MM Dupla
1	5,00							
2	8,00							
3	11,00	8,00						
4	14,00	11,00	8,00	6,00				
5	17,00	14,00	11,00	6,00	11,00	3,00		
6	20,00	17,00	14,00	6,00	14,00	3,00	20,00	0,00
7	23,00	20,00	17,00	6,00	17,00	3,00	23,00	0,00
8	26,00	23,00	20,00	6,00	20,00	3,00	26,00	0,00
9	29,00	26,00	23,00	6,00	23,00	3,00	29,00	0,00
10	32,00	29,00	26,00	6,00	26,00	3,00	32,00	0,00
11	35,00	32,00	29,00	6,00	29,00	3,00	35,00	0,00
12	38,00	35,00	32,00	6,00	32,00	3,00	38,00	0,00
13	41,00	38,00	35,00	6,00	35,00	3,00	41,00	0,00
14	44,00	41,00	38,00	6,00	38,00	3,00	44,00	0,00
15	47,00	44,00	41,00	6,00	41,00	3,00	47,00	0,00

Exemplo 5.2.4.

Considere o exemplo anterior, mas agora adicione um erro aleatório à Z_t. O modelo gerador destes dados é: $Z_t = 2 + 3.t + e_t$ onde os e_t's são ruídos aleatórios independentes Normais, com média zero e variância ¼. Refaça o exemplo anterior e note que os erros de previsão um passo à frente usando

médias móveis simples são consideravelmente maiores que os erros encontrados quando usamos a equação (5.2.15) para prever Z_t. Calcule a soma do quadrado dos erros de previsão um passo à frente segundo os dois métodos.

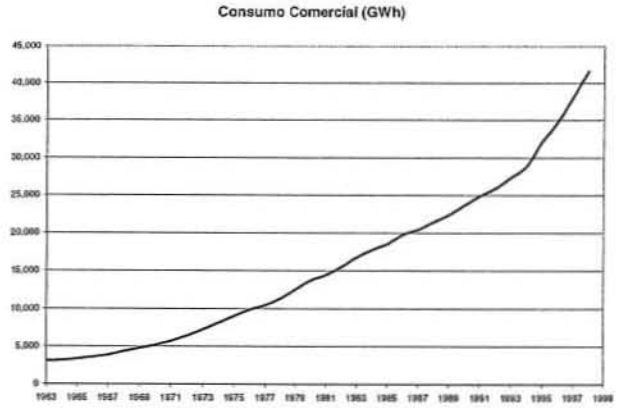

Instante t	Erros (e(t))	Série (Z(t))	MM (3)	Previsão 1 passo à frente de Z (t) usando MM (3)	Erro de previsão 1 passo à frente usando MM (3)	MM Dupla (3)	Diferença entre MM (3) e MM Dupla (3)	Previsão 1 passo à frente = MM (3) + (MM (3)- MMDup (3)) + tendência	Erro de previsão 1 passo à frente usando MM Dupla
1	-0,150	4,850							
2	-0,639	7,361							
3	0,122	11,122	7,778						
4	0,638	14,638	11,041	7,778	6,861				
5	0,599	17,599	14,453	11,041	6,559	11,090	3,363		
6	0,867	20,867	17,701	14,453	6,413	14,398	3,303	21,179	-0,31
7	-1,092	21,908	20,125	17,701	4,207	17,426	2,698	24,307	-2,40
8	-0,117	25,883	22,886	20,125	5,758	20,237	2,649	25,521	0,36
9	0,548	29,548	25,780	22,886	6,662	22,930	2,850	28,183	1,36
10	-0,543	31,457	28,962	25,780	5,677	25,876	3,086	31,479	-0,02
11	-0,345	34,655	31,886	28,962	5,693	28,876	3,010	35,135	-0,48
12	-0,845	37,155	34,422	31,886	5,268	31,757	2,665	37,907	-0,75
13	-0,923	40,077	37,295	34,422	5,654	34,535	2,761	39,752	0,32
14	-0,489	43,511	40,248	37,295	6,216	37,322	2,926	42,817	0,69
15	-0,387	46,613	43,400	40,248	6,366	40,314	3,086	46,099	0,51

Exemplo 5.2.5.
No gráfico a seguir, mostramos o consumo comercial de energia elétrica anual no Brasil no período 1963 a 1998, e os resultados do ajuste de um modelo de Holt à série.

Componente	Constante de Amortecimento	Valor Final
Nível	0.8086	41539
Tendência	0.9994	3536

As previsões geradas pelo modelo para o período 1999-2002 são indicadas a seguir, assim como os respectivos erros de previsão em 1999 e 2000.

Ano	Limite Inferior Previsão (2.5%)	Previsão	Limite Superior Previsão (97.5%)	Valor Real	Erro Percentual Absoluto de Previsão
1999	42,949	45,074	47,199	43,583	3.4%
2000	44,570	48,610	52,650	47,365	2.6%
2001	46,842	52,145	57,448		
2002	49,362	55,681	62,000		

5.2.3. Modelo Quadrático

A função **nível médio** é dada por $\mu(t) = a_1 + a_2 t + a_3 t^2$ para t = 1, 2...T. Agora existem três parâmetros a serem estimados para o nível, a_1, a_2 e a_3. Supondo que o modelo tem a forma:

$Z_t = a_1 + a_2.t + a_3.t^2 + \varepsilon_t$ onde $t = 1,2,....,T$ e $E(\varepsilon_t) = 0, VAR(\varepsilon_t) = \sigma^2$

segue que:

$E(Z_t) = \mu(t) = a_1 + a_2 t + a_3 t^2$ e $VAR(Z_t) = \sigma^2$ = constante.

O modelo quadrático se aplica a séries que têm o comportamento indicado na figura a seguir.

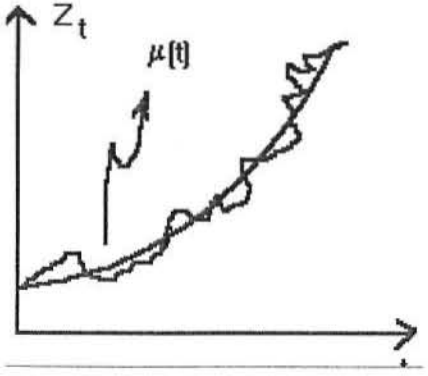

A previsão k passos à frente no instante T é dada por:

$$\hat{Z}_T(k) = E\{Z_{T+k} \mid Z_1, Z_2, ..., Z_T\} =$$
$$= E\{a_1 + a_2.k + a_3 k^2 \mid Z_1, Z_2, ..., Z_T\} \quad \text{(com a origem transladada,}$$
$$= \hat{a}_1(T) + k.\hat{a}_2(T) + k^2.\hat{a}_3(T) \quad \text{isto é, fazendo T = 0)}$$

Analogamente aos modelos constante e linear, existem diversos métodos para a estimação dos parâmetros que especificam o nível da série. Aqui, ao contrário dos casos anteriores, não iremos exibir em detalhes as equações de atualização.

1) Estimadores de Mínimos Quadrados Ordinários (MQO)

Devemos encontrar os estimadores de a_1, a_2 e a_3 que minimizem:

$$SSE = \sum_{t=1}^{T} \underbrace{[Z_t - (a_1 + a_2 t + a_3.t^2)]}_{\epsilon t}^2$$

2) Médias Móveis Triplas

Defina a média móvel tripla de tamanho N avaliada no instante T como:

$$M_T^{[3]} = \frac{M_T^{[2]} + M_{T-1}^{[2]} + ... + M_{T-N+1}^{[2]}}{N} \qquad (5.2.20)$$

Onde $M_T^{[2]}$ é a média móvel dupla de tamanho N avaliada no instante T.

Os estimadores dos parâmetros do modelo são obtidos como funções das médias móveis simples, dupla e tripla.

$$\hat{a}_i(T) = f_i[M_T, M_T^{[2]}, M_T^{[3]}]; i = 1, 2, 3$$

3) Amortecimento Exponencial

$$M_T = \alpha Z_T + (1-\alpha) M_{T-1}$$
$$M_T^{[2]} = \alpha M_T + (1-\alpha) M_{T-1}^{[2]}$$
$$M_T^{[3]} = \alpha M_T^{[3]} + (1-\alpha) M_{T-1}^{[3]}$$

Onde $\alpha \in [0,1]$ é a única constante de amortecimento usada para atualizar todas as médias móveis.

Os estimadores dos parâmetros a_1, a_2 e a_3 (correspondentes à origem transladada para o instante T) no instante T são obtidos através das equações:

$$M_T = \hat{a}_1(T) - \left(\frac{1-\alpha}{\alpha}\right)\hat{a}_2(T) + \frac{(1-\alpha)(2-\alpha)}{2.\alpha^2}\hat{a}_3(T)$$

$$M_T^{[2]} = \hat{a}_1(T) - 2\left(\frac{1-\alpha}{\alpha}\right)\hat{a}_2(T) + \frac{2(1-\alpha)(3-2\alpha)}{2.\alpha^2}\hat{a}_3(T)$$

$$M_T^{[3]} = \hat{a}_1(T) - 3\left(\frac{1-\alpha}{\alpha}\right)\hat{a}_2(T) + \frac{3.(1-\alpha)(4-3\alpha)}{2.\alpha^2}\hat{a}_3(T)$$

5.3. Métodos de Amortecimento Exponencial (Séries Sazonais)

Séries sazonais ocorrem com enorme freqüência na prática. Por exemplo, séries de temperatura média mensal e séries de consumo de energia elétrica são claramente sazonais, e exibem características que se repetem ano a ano sempre no mesmo mês (ou semana, ou trimestre...). No caso de séries de consumo de energia no Brasil, existe um nítido aumento de consumo nos meses de verão, devido às elevadas temperaturas e ao uso de ar refrigerado. Entender a sazonalidade de uma série é fundamental não apenas para gerar previsões consistentes, mas também para propor políticas governamentais ou empresariais. Por exemplo, o horário de verão no Brasil é conseqüência direta do aumento de consumo observado neste período, e tem o objetivo de reduzir o consumo e evitar blecautes cujas conseqüências econômicas poderiam ser dramáticas. A sazonalidade pode ser modelada de duas formas: através de fatores sazonais ou através de funções trigonométricas. Aqui estaremos interessados apenas na modelagem através de fatores sazonais.

As técnicas já estudadas de amortecimento exponencial podem ser estendidas para modelar séries que apresentam tendência e sazonalidade.

Um dos modelos mais utilizados na prática (especialmente em empresas) é o modelo de **amortecimento exponencial de Holt e Winters**. Este procedimento é capaz de modelar séries sazonais e gera, na maioria dos casos, boas previsões, a um custo computacional bastante baixo. O modelo de Holt e Winters utiliza a idéia de amortecimento das informações passadas três vezes para:

- estimar o nível da série;
- estimar a taxa de crescimento da série;
- estimar os fatores sazonais.

Em cada um dos passos indicados emprega-se uma constante de amortecimento diferente.

Seja S o período sazonal, por exemplo, S = 12 no caso de dados mensais, S = 4 no caso de observações trimestrais. Na discussão a seguir, iremos nos referir, com freqüência, ao "mês" t, mas todos os resultados se aplicam a períodos arbitrários, e não se referem exclusivamente a dados mensais. Denote por ρ_t o **fator sazonal correspondente** ao mês t, onde t = 1, 2...S.

Existem dois tipos de modelos para a sazonalidade: **modelos aditivos e multiplicativos**. Nos modelos aditivos, o padrão sazonal não se altera à medida que o nível da série muda. Ao contrário, nos modelos multiplicativos, a sazonalidade da série é afetada pelo nível da mesma, como indicado nos gráficos a seguir.

MODELO ADITIVO
$Z_t = \mu(t) + \rho_t + \epsilon_t$

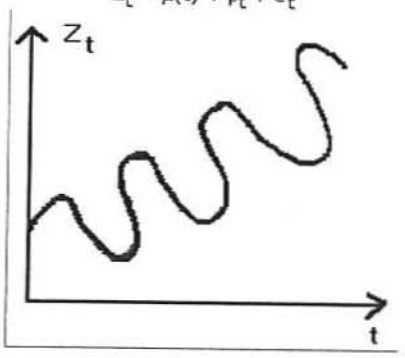

MODELO MULTIPLICATIVO
$Z_t = \mu(t).\ \rho_t.\ \epsilon_t$ ou $Z_t = \mu(t).\ \rho_t + \epsilon_t$

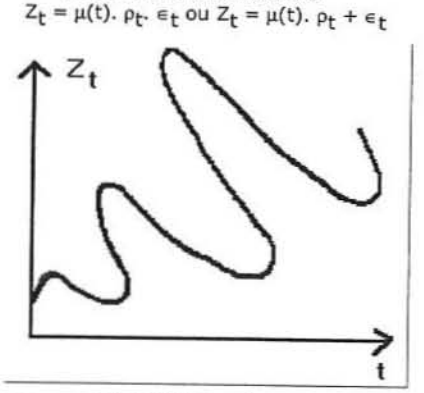

5.3.1. Modelo Horizontal (constante) Sazonal Multiplicativo

Neste caso o nível da série ($\mu(t)$) é uma constante, e a estrutura do modelo é:

$$Z_t = a_1.\ \rho_t + e_t \qquad (5.3.1)$$

Neste caso precisamos estimar o nível da série (a_1) e os fatores sazonais ρ_t para todos os "meses" t. Note que, no caso de dados mensais, precisamos estimar 12 fatores sazonais e o nível, ou seja, existem 13 parâmetros a serem estimados. No caso de dados trimestrais, existem 4 fatores sazonais (e também o nível), o que resulta na estimação de 5 parâmetros. Na verdade, se S é o período sazonal, existem S fatores sazonais a serem estimados, mas a soma destes fatores está sujeita a uma restrição, e na prática o número de fatores sazonais a serem estimados é S - 1. Logo, na prática, no modelo mensal devemos estimar 11 fatores sazonais (pois o remanescente é obtido a partir da restrição).

A previsão k passos à frente feita no instante T é dada por:

$$\hat{Z}_T(k) = E\{Z_{T+k} \mid \underline{Z}_T\} = \hat{a}_1(T).\ \hat{\rho}_{T+k}(T) \qquad (5.3.2)$$

É importante conhecer o significado dos estimadores de a_1 e ρ_t na equação (5.3.2).

$\hat{a}_1(T)$ indica o estimador do nível da série usando todas as observações até o instante T (inclusive), ou seja, é a estimativa mais atualizada do nível da série.

$\hat{\rho}_{T+k}(T)$ é o estimador do fator sazonal correspondente ao mês T + k no futuro efetuado usando todas as observações até o instante T (inclusive). Ou seja, $\hat{\rho}_{T+k}(T)$ é a estimativa mais atualizada do fator sazonal que corresponde ao mês T + k.

Os parâmetros do modelo são atualizados seqüencialmente da forma indicada a seguir. Suponha que, para um instante genérico T, as estimativas de a_1 e do fator sazonal para o instante anterior estão disponíveis (isto é, são conhecidas), ou seja, $\hat{a}_1(T-1)$ e $\hat{\rho}_{m(T)}(T-1)$ são dados, onde m(T) é o "mês" correspondente ao instante T. Então, os parâmetros atualizados no instante T são encontrados a partir das seguintes fórmulas:

$$\hat{a}_1(T) = \alpha\left[\frac{Z_T}{\hat{\rho}_{m(T)}(T-1)}\right] + (1-\alpha).\hat{a}_1(T-1) \qquad (5.3.3)$$

$$\hat{\rho}_{m(T)}(T) = \gamma\left[\frac{Z_T}{\hat{a}_1(T)}\right] + (1-\gamma).\hat{\rho}_{m(T)}(T-1) \qquad (5.3.4)$$

Note que, nas equações (5.3.3) e (5.3.4) são usadas duas constantes de amortecimento diferentes, uma para o nível e outra para o fator sazonal.

Além disso, uma característica importante da atualização do fator sazonal é: ele só muda quando recebemos uma informação referente ao "mês" m(T). Por exemplo, o fator sazonal referente ao mês de maio só é atualizado quando recebemos uma informação relativa a este mês. Ou seja:

$$\hat{\rho}_j(T) = \hat{\rho}_j(T-1) \text{ para } j = 1,2,\ldots,S \text{ e } j \neq m(T)$$

Em seguida, os fatores sazonais estimados são normalizados, de tal forma que a sua soma seja igual ao período sazonal (S). Esta condição de normalização é válida para fatores sazonais multiplicativos. No caso de fatores aditivos, sua soma (para todos os meses) é zero.

$$\sum_{j=1}^{S} \hat{\rho}_j(T) = S \qquad (5.3.5)$$

É necessário fornecer estimativas iniciais do nível e dos fatores sazonais. O procedimento de inicialização é descrito brevemente a seguir.

1º PASSO: Cálculo das Médias Anuais

Ano 1	Z_1	Z_2	...	Z_S	Média do Ano 1 →	$\bar{Z}_{(1)}$	
Ano 2	Z_{S+1}	Z_{S+2}	...	Z_{2S}	Média do Ano 2 →	$\bar{Z}_{(2)}$	
.....	.	.	...	.		.....	J = T/S
Ano J	$Z_{JS-(S-1)}$	$Z_{JS-(S-2)}$	...	Z_{JS}	Média do Ano J →	$\bar{Z}_{(J)}$	

2º PASSO: Cálculo dos fatores sazonais grosseiros C_i

$C_1 = \frac{Z_1}{\bar{Z}_{(1)}}$	...	$C_S = \frac{Z_S}{\bar{Z}_{(1)}}$
...	...	...
$C_{JS-(S-1)} = \frac{Z_{JS-(S-1)}}{\bar{Z}_{(J)}}$	...	$C_{JS} = \frac{Z_{JS}}{\bar{Z}_{(J)}}$

O fator sazonal grosseiro para o mês i é apenas a observação Z_i dividida pela média do ano correspondente. Este procedimento simples funciona bem desde que a série não apresente componente de tendência. Do contrário, se existe tendência, as estimativas dos fatores sazonais encontradas por este método irão conter componentes de tendência, e as previsões resultantes serão prejudicadas.

Note que, neste passo, encontramos J (um para cada ano em que existem dados) fatores sazonais para cada mês. No passo seguinte tomamos a média destes J fatores para obter um único fator sazonal para o mês i.

3º PASSO: Cálculo dos fatores sazonais "suaves"

Os fatores sazonais para cada um dos meses são encontrados através da média dos fatores encontrados no passo anterior, isto é:

$$C_1^* = [C_1 + C_{S+1} + \ldots + C_{JS-(S-1)}]/J$$

. . . . .

$$C_S^* = [C_S + C_{2S} + \ldots + C_{JS}]/J$$

Por exemplo, o fator sazonal correspondente ao mês 1 é a média dos fatores sazonais previamente estimados para os meses 1, 13, 25, 37...

4º PASSO: Normalização dos fatores sazonais "suaves"

A partir dos fatores sazonais "suaves" encontrados no passo anterior, calcula-se os fatores sazonais normalizados simplesmente aplicando a restrição de que a soma dos fatores sazonais deve ser igual a S (período sazonal). Ou seja, o fator sazonal normalizado correspondente ao mês i é apenas:

$$\hat{\rho}_i(0) = \frac{S}{\sum_{i=1}^{S} C_i^*}.C_i^* \text{ onde } C_i^* \text{ é o fator sazonal "suave" calculado no passo anterior.}$$

5º PASSO: Obtenção da estimativa inicial do nível

A partir dos fatores sazonais normalizados $\hat{\rho}_i(0)$ encontrados no passo anterior, e supondo que o nível inicial estimado seja igual à média do primeiro ano de dados, $\hat{a}_1(0) = \overline{Z}_{(1)}$, pode-se inicializar o processo de estimação. Em seguida usa-se as equações (5.3.3) e (5.3.4) para obter as estimativas do nível e fatores sazonais em cada instante.

5.3.2. Modelo Linear Sazonal Multiplicativo

Neste caso o nível da série ($\mu(t)$) é uma função linear, e a estrutura do modelo é:

$$Z_t = (a_1 + a_2 . t).\rho_t + e_t \qquad (5.3.6)$$

Neste caso precisamos estimar o nível da série (a_1), sua taxa de crescimento (a_2) e os fatores sazonais ρ_t para todos os "meses" t. A atualização de parâmetros é feita seqüencialmente, pelo **método de Holt-Winters** descrito a seguir.

Suponha que no instante T-1 conhecemos as estimativas do nível, taxa de crescimento e fatores sazonais dadas por: $\hat{a}_1(T-1), \hat{a}_2(T-1)$ e $\hat{\rho}_j(T-1)$. O procedimento de atualização é bem semelhante ao apresentado antes (modelo com nível constante e sazonalidade multiplicativa). A grande diferença em relação ao modelo da seção 5.3.1. é que agora temos mais uma quantidade a ser atualizada seqüencialmente, a taxa de crescimento a_2.

- Atualização do nível (a_1)

$$\hat{a}_1(T) = \alpha\left[\frac{Z_T}{\hat{\rho}_{m(T)}(T-1)}\right] + (1-\alpha)[\hat{a}_1(T-1) + \hat{a}_2(T-1)] \qquad (5.3.7)$$

Note que, do lado direito da equação (5.3.7), o termo $\frac{Z_T}{\hat{\rho}_{m(T)}(T-1)}$ representa a observação do instante T dessazonalizada.

- Atualização da tendência

$$\hat{a}_2(T) = \beta.[\hat{a}_1(T) - \hat{a}_1(T-1)] + (1-\beta).\hat{a}_2(T-1) \qquad (5.3.8)$$

A equação de atualização da tendência é exatamente igual à do método de Holt (usado para séries com tendência linear e sem sazonalidade), como indicado na expressão (5.2.19). Note que o termo $\hat{a}_1(T) - \hat{a}_1(T-1)$ é a diferença entre os níveis estimados nos instantes T e T-1.

- Atualização dos fatores sazonais $\hat{\rho}_j(T)$

$$\hat{\rho}^*_{m(T)} = \gamma\left[\frac{Z_T}{\hat{a}_1(T)}\right] + (1-\gamma)\hat{\rho}_{m(T)}(T-1) \qquad (5.3.9)$$

$$\hat{\rho}^*_j(T) = \hat{\rho}_j(T-1);\ j = 1,2,\ldots,S;\ j \neq m(T) \qquad (5.3.10)$$

A atualização dos fatores sazonais é feita apenas no mês correspondente ao fator sazonal que se procura estimar. Logo, pela equação (5.3.10) segue que o fator sazonal permanece fixo até recebermos a informação relativa ao mês atual. Quando esta informação é recebida (isto é, quando o instante T corresponde ao mês m(T)), o fator sazonal é estimado através da expressão (5.3.9). Nesta equação nota-se que o fator sazonal correspondente ao mês m(T) atualizado no instante T é uma média ponderada da estimativa feita no ano passado para o fator deste mês e também da observação sem o nível (dada por $\frac{Z_T}{\hat{a}_1(T)}$).

- Normalização (padronização) dos fatores sazonais

$$\hat{\rho}_j(T) = \left[\frac{\hat{\rho}^*_j(T)}{\sum_{j=1}^{S}\hat{\rho}^*_j(T)}\right].S$$

O objetivo desta normalização é fazer com que os fatores sazonais encontrados pela equação (5.3.9) tenham soma igual a S (período sazonal).

A previsão k passos à frente no instante T é obtida substituindo-se os parâmetros desconhecidos a_1, a_2 e ρ por suas estimativas, isto é:

$$\hat{Z}_{T+k}(T) = [\hat{a}_1(T) + k.\hat{a}_2(T)]\hat{\rho}_{m(T+k)}(T) \qquad (5.3.11)$$

- Inicialização do Método

A exemplo do que fizemos na seção anterior, aqui encontramos estimativas iniciais para o nível, taxa de crescimento e fatores sazonais.

Sejam $\overline{Z}_{(1)}, \overline{Z}_{(2)}, \ldots, \overline{Z}_{(J)}$ as médias anuais, onde J é o último ano disponível.

A estimativa inicial da taxa de crescimento é:

$$\hat{a}_2(0) = \frac{\overline{Z}_{(J)} - \overline{Z}_{(1)}}{(J-1)S}$$

A estimativa inicial do nível é:

$$\hat{a}_1(0) = \overline{Z}_{(1)} - \frac{(S+1)}{2}\hat{a}_2(0)$$

A estimativa inicial dos fatores sazonais é:

$$C_t = \left\{\frac{Z_t}{\overline{Z}_{(i)} - \left(\frac{S+1}{2} - m(t)\right).\hat{a}_2(0)}\right\}$$ onde t = 1, 2..., JS e i é o ano correspondente ao instante t.

Em seguida o procedimento é igual ao da seção anterior.

5.3.3. Modelo Linear Sazonal Aditivo

A estrutura do modelo é: $Z_t = a_1 + a_2 t + \rho_t + e_t$.

A atualização seqüencial dos parâmetros é análoga às equações (5.3.7) a (5.3.10), com pequenas modificações, mostradas abaixo.

- Atualização do nível (a_1)

$$\hat{a}_1(T) = \alpha[Z_T - \hat{\rho}_{m(T)}(T-1)] + (1-\alpha)[\hat{a}_1(T-1) + \hat{a}_2(T-1)] \qquad (5.3.12)$$

Note que, do lado direito da equação (5.3.12), o termo $Z_T - \hat{\rho}_{m(T)}(T-1)$ representa a observação do instante T dessazonalizada.

- Atualização da tendência

$$\hat{a}_2(T) = \beta.[\hat{a}_1(T) - \hat{a}_1(T-1)] + (1-\beta).\hat{a}_2(T-1) \qquad (5.3.13)$$

A equação de atualização da tendência é exatamente igual à do modelo multiplicativo e à do método de Holt (expressões (5.3.8) e (5.2.19)).

- Atualização dos fatores sazonais $\hat{\rho}_j(T)$

$$\hat{\rho}^*_{m(T)} = \gamma[Z_T - \hat{a}_1(T)] + (1-\gamma)\hat{\rho}_{m(T)}(T-1) \qquad (5.3.14)$$

$$\hat{\rho}^*_j(T) = \hat{\rho}_j(T-1);\ j = 1,2,\ldots, S;\ j \neq m(T) \qquad (5.3.15)$$

Note que, em (5.3.14), o termo $[Z_T - \hat{a}_1(T)]$ é uma medida da variação sazonal dos dados, obtida pela diferença entre a observação atual e a estimativa mais recente do nível.

Da equação (5.3.15) conclui-se que as estimativas de cada fator sazonal só são atualizadas uma vez a cada ano, quando observamos o dado correspondente àquele mês.

A previsão 1 passo à frente no instante T é obtida substituindo-se os parâmetros desconhecidos a_1, a_2 e ρ por suas estimativas, isto é:

$$\hat{Z}_{T+1}(T) = [\hat{a}_1(T) + \hat{a}_2(T)] + \hat{\rho}_{m(T+1)}(T) \qquad (5.3.16)$$

É importante lembrar que os fatores sazonais aditivos sofrem uma restrição diferente dos fatores multiplicativos. No caso dos fatores aditivos, a sua soma (para todos os meses) é zero.

- Inicialização do método

Montgomery e Johnson sugerem obter as estimativas iniciais dos parâmetros

através de um procedimento de mínimos quadrados ordinários, que permite a estimação simultânea dos S + 2 parâmetros desconhecidos.

Requisitos mínimos para usar o método de Holt e Winters

Para modelar adequadamente a sazonalidade, é necessário pelo menos 3 anos de dados mensais e 4 anos de dados trimestrais.

Exemplo 5.3.1.

O próximo gráfico exibe o nível dos reservatórios (isto é, a combinação das usinas hidrelétricas) na região Sudeste do Brasil entre Janeiro de 1989 e Agosto de 2001.

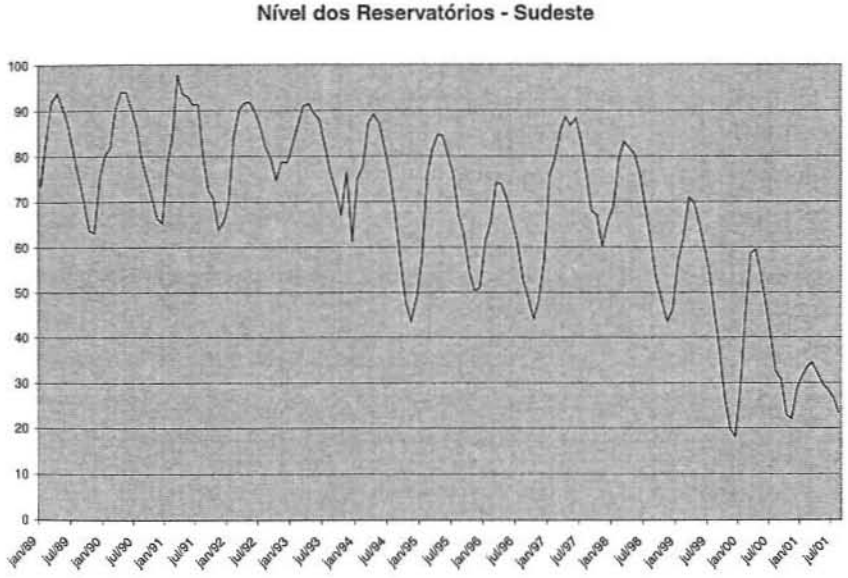

Os resultados de um modelo Holt-Winters ajustado a esta série são:

Componente	Constante Amortec.	Valor Final
Nível	0.540	25.109
Tendência	0.002	-0.179
Sazonalidade	0.529	

Os fatores sazonais multiplicativos estimados são:

Fatores Sazonais	
Jan	1.028
Fev	1.181
Mar	1.282
Abr	1.241
Mai	1.176
Jun	1.126
Jul	1.052
Ago	0.936
Set	0.877
Out	0.751
Nov	0.727
Dez	0.829

Este modelo foi então ajustado até Dezembro de 2000 e as previsões obtidas para o período entre Janeiro e Agosto de 2001 para testar sua capacidade preditiva. A próxima tabela apresenta os valores reais e ajustados no período, além dos erros percentuais de previsão.

Data	Limite Inferior do IC 95%	**Previsão**	Limite Superior do IC 95%	**Valor Real**	Erro de previsão (em %)
jan/01	24.3	**36.6**	48.9	**31.4**	-5.2
fev/01	27.4	**43.2**	59.0	**33.4**	-9.8
mar/01	28.1	**46.6**	65.1	**34.5**	-12.1
abr/01	24.6	**44.2**	63.7	**32.2**	-12.0
mai/01	20.7	**40.9**	61.2	**29.7**	-11.2
jun/01	17.2	**38.1**	59.0	**28.6**	-9.6
jul/01	13.7	**35.0**	56.3	**26.8**	-8.2
ago/01	9.4	**30.9**	52.3	**23.5**	-7.4

Os erros são bastante grandes, o que certamente é conseqüência de uma mudança no padrão de evolução dos reservatórios, que se torna nítida a partir de 2001. Note que, neste último ano, a amplitude no nível de reservatórios é bem menor que nos anos anteriores, indicando que não foi possível recuperar o nível dos reservatórios com as chuvas de verão. Portanto, (pelo menos a posteriori) é clara a necessidade de impor o racionamento de energia (iniciado em Junho de 2001).

Se agora consideramos apenas as previsões um passo à frente, a capacidade preditiva do modelo é sensivelmente melhor, como indicado na próxima tabela. Os erros, especialmente nos meses de inverno, são sensivelmente reduzidos.

Previsões um passo à frente					
Data	Limite Inferior do IC 95%	**Previsão**	Limite Superior do IC 95%	**Valor Real**	Erro de previsão (em %)
jan/01	24.3	**36.6**	48.9	**31.4**	-5.2
fev/01	24.9	**39.2**	53.5	**33.4**	-5.8
mar/01	23.3	**38.6**	53.9	**34.5**	-4.1
abr/01	20.1	**34.7**	49.3	**32.2**	-2.5
mai/01	17.5	**31.1**	44.8	**29.7**	-1.4
jun/01	15.7	**28.5**	41.3	**28.6**	0.1
jul/01	14.5	**26.4**	38.2	**26.8**	0.4
ago/01	13.0	**23.6**	34.2	**23.5**	-0.1

5.4. Modelos ARIMA de Box e Jenkins Não Sazonais

A classe de modelos ARIMA de Box e Jenkins é talvez a classe mais geral de modelos de previsão para séries temporais. Nesta seção faremos uma breve introdução a estes modelos, e iremos considerar apenas os modelos para séries **não sazonais**.

Modelos ARIMA podem ser aplicados a séries estacionárias ou não. A condição necessária para a aplicação destes modelos a séries não estacionárias é que a estacionariedade possa ser obtida através de diferenças e/ou transformações não lineares da série original (por exemplo, logaritmo ou raiz quadrada).

A abreviação ARIMA em Inglês significa "Auto-Regressive Integrated Moving Average", ou seja, auto-regressivo, integrado e médias móveis. Os termos autoregressivos correspondem a defasagens da série transformada, e os termos médias móveis ("moving averages") referem-se às defasagens dos erros aleatórios. Finalmente, o termo "integrado" refere-se ao processo de diferenciar a série original para torná-la estacionária.

Modelos "Random Walk" (passeio aleatório), autoregressivos e de amortecimento exponencial são apenas casos particulares de modelos ARIMA.

Uma série temporal $\{Z_1, Z_2..., Z_T\}$ pode ser encarada como uma realização de um processo estocástico. Para descrevermos completamente um processo estocástico precisamos especificar a distribuição conjunta do vetor $\{Z_1, Z_2..., Z_T\}$. Suponha que os Z_t 's são conjuntamente Gaussianos. Então, para conhecer a sua distribuição conjunta, basta especificar o vetor de médias $\{\mu_1, \mu_2..., \mu_T\}$ e a matriz de variância-covariância Σ. Mas, Σ é uma matriz simétrica de dimensão T, e contém $T(T+1)/2$ elementos diferentes. Logo, a completa especificação deste processo requer o conhecimento de $T + T(T+1)/2$ parâmetros. Podemos perceber claramente que inferir sobre todos estes parâmetros com base em apenas

uma realização do processo é uma tarefa impossível, e, portanto, algumas simplificações devem ser feitas. A hipótese simplificadora mais comum é **estacionariedade**.

Dizemos que um **processo** estocástico é **estacionário** se ele atingiu o equilíbrio. Em termos formais, num processo estacionário, a distribuição de probabilidade conjunta nos instantes t_1, t_2..., t_m é a mesma que a distribuição nos instantes $t_1 + k$, $t_2 + k$..., $t_m + k$ para qualquer k, ou seja, um descolamento de k unidades de tempo não afeta a distribuição de probabilidade conjunta. Note que, nesta definição, m é arbitrário. Se tomarmos m = 1 acima, segue que, num processo estacionário, a distribuição marginal de Z_t é a mesma que a distribuição marginal de Z_{t+k}. Logo, a distribuição marginal de Z_t não depende do instante de tempo escolhido e, em particular, a média e variância de Z_t são constantes para qualquer t. Analogamente, se m = 2, as distribuições de probabilidade bivariadas $p(Z_t, Z_{t+k})$ não dependem de t, e então a covariância entre Z_t e Z_{t+k} depende apenas do "lag" k.

Em resumo, a condição de estacionariedade implica:
- Média do processo é constante;
- Variância do processo é constante;
- Covariância entre Z_t e Z_{t+k} depende apenas do "lag" k.

Um processo é dito fracamente estacionário (ou estacionário de 2ª Ordem) se estas três condições são satisfeitas. Note que estas condições referem-se apenas aos dois primeiros momentos da distribuição de probabilidade dos Z_t's, o que explica a terminologia "processo estacionário de 2ª ordem". A definição de estacionariedade mais geral envolve momentos de todas as ordens (m arbitrário na definição) e é muito mais complicada de verificar que a estacionariedade de segunda ordem. Se os Z_t 's são conjuntamente Gaussianos, as duas condições (estacionariedade "estrita" e estacionariedade de 2ª ordem) são equivalentes.

Algumas das definições a seguir já foram apresentadas no capítulo 2, e estão novamente aqui apenas para relembrar o leitor!

Definição 5.4.1. Autocovariância de "lag" k
A autocovariância de "lag" k é definida como a covariância entre Z_t e Z_{t+k} isto é:

$$\gamma_k = Cov(Z_t, Z_{t+k}) = E[(Z_t - \mu)(Z_{t+k} - \mu)] \text{ para } k = 0, 1, 2... \qquad (5.4.1)$$

Note que $\gamma_0 = Var(Z_t) = \sigma^2$ pois $Cov(Z_t, Z_t) = Var(Z_t)$.

A autocovariância é uma das funções usadas na identificação da estrutura de um modelo ARIMA.

Definição 5.4.2. Autocorrelação de "lag" k
A autocorrelação de "lag" k é definida como:

$$\rho_k = \frac{Cov(Z_t, Z_{t+k})}{Var(Z_t)} = \frac{\gamma_k}{\sigma^2} \text{ para } k = 0, 1, 2... \qquad (5.4.2)$$

Note que $\rho_0 = 1$ sempre.

As definições 5.4.1. e 5.4.2. referem-se à autocovariância e autocorrelação teóricas. Na prática, apenas observamos uma série temporal, e estas funções devem ser estimadas a partir da série. A seguir, definimos a autocovariância e autocorrelações amostrais, isto é, calculadas a partir dos dados observados (ou seja, a partir da série temporal). Normalmente iremos nos referir à função de autocorrelação como ACF (do inglês, Autocorrelation Function).

Também, pela estacionariedade do processo, $\rho_k = \rho_{-k}$, e portanto basta fazer o gráfico para as autocorrelações com lags positivos. Este gráfico é chamado de **correlograma.**

Definição 5.4.3. Autocovariância Amostral de "lag" k

$$c_k = \frac{1}{T}\sum_{t=1}^{T-k}(Z_t - \overline{Z}).(Z_{t+k} - \overline{Z}_z) \qquad (5.4.3)$$

Note que, para o lag zero, esta expressão torna-se:

$$c_0 = \frac{1}{T}\sum_{t=1}^{T}(Z_t - \overline{Z})^2$$

que é a variância amostral da série.

Definição 5.4.4. Autocorrelação Amostral de "lag" k

$$r_k = \frac{c_k}{c_0} = \frac{\sum_{t=1}^{T-k}(Z_t - \overline{Z}).(Z_{t+k} - \overline{Z})}{\sum_{t=1}^{T}(Z_t - \overline{Z})^2} \qquad (5.4.4)$$

Da expressão (5.4.4) segue que $r_0 = 1$ sempre!

Essas estimativas são assintoticamente não-tendenciosas quando T (o tamanho da série) $\to \infty$. Em geral deve-se ter $T \geq 50$ (e $k \leq T/4$).

Fórmula de Bartlett
Sob a hipótese $\rho_k = 0$ para todo lag $k > U$ (onde U indica um lag "grande") segue que:

$$cov(r_k, r_{k-s}) \approx \frac{1}{T}\sum_{i=-U+s}^{U}\rho_i\rho_{i-s}$$

Valores sucessivos de r_k podem exibir altas correlações e portanto as autocorrelações estimadas podem levar a conclusões errôneas.

Fazendo s = 0 na equação anterior leva a:

$$Var(r_k) \approx \frac{1}{T}\sum_{i=-U}^{U}\rho_i^2$$

Para T grande e sob a hipótese $\rho_k = 0$, a distribuição de r_k é *aproximadamente Normal* com média zero e variância $\frac{1}{T}\sum_{i=-U}^{U}\rho_i^2$. Na prática substitui-se as correlações (desconhecidas) na expressão acima por seus estimadores r_k e então:

$$\text{Var}(r_k) \approx \frac{1}{T}\left(1+2\sum_{i=1}^{U} r_i^2\right)$$

Esta fórmula será usada para obter intervalos de confiança para r_k. Também, se o tamanho (T) da série é grande, r_k é aproximadamente Normal com média zero, e os intervalos de confiança podem ser construídos a partir desta distribuição.

Justificativa Teórica para os Modelos ARMA e ARIMA

A família ARIMA (p, d, q) é uma classe de modelos não-sazonais, cujas propriedades dependem dos inteiros não-negativos p, d, q, responsáveis por determinar a ordem do modelo dentro da classe. Um modelo ARMA é apenas um caso particular de um ARIMA. Nesta notação, p é o número de termos autoregressivos, d é o número de diferenças (se d=0, um ARIMA se reduz a um ARMA) e q é o número de termos médios móveis.

Alguns casos particulares importantes do modelo ARIMA (p, d, q) são:

ARIMA(0,1,0)	passeio aleatório ("random walk")
ARIMA(1,1,0)	modelo auto-regressivo de ordem 1 aplicado à série diferenciada
ARIMA(0,1,1) sem termo constante	amortecimento exponencial simples
ARIMA(0,1,1) com termo constante	amortecimento exponencial simples com crescimento

Seja $\{a_1, a_2..., a_T\}$ uma seqüência de variáveis independentes e identicamente distribuídas com média zero e variância constante, isto é, os a_t's são um ruído branco. Considere uma outra seqüência $\{w_1, w_2..., w_T\}$, que representa um processo estocástico estacionário. Note que os w's exibem dependência serial. A Teoria Geral de Sistemas nos permite gerar a seqüência dos w's a partir de uma combinação linear infinita de ruídos brancos. Esquematicamente temos:

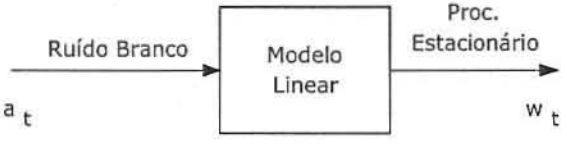

Ou seja,

$$w_t = a_t - \psi_1 a_{t-1} - \psi_2 a_{t-2} - \ldots \text{ (memória infinita)} \qquad (5.4.5)$$

A próxima definição nos permite escrever de maneira conveniente os polinômios que aparecem na modelagem ARIMA de Box e Jenkins.

Definição 5.4.5. Operador de Atraso, "Backward Shift Operator"

O operador de atraso B é definido como: $B.w_t = w_{t-1}$. Também, suas potências são dadas por:

$$B^k w_t = w_{t-k}.$$

Logo, a expressão (5.4.5) pode ser reescrita em termos de um polinômio infinito envolvendo o operador de atraso como:

$$w_t = a_t - \Psi_1 a_t B - \Psi_2 a_t B^2 - \ldots.$$

$$w_t = (1 - \Psi_1 B - \Psi_2 B^2 - \ldots)\, a_t = \Psi(B) a_t$$

A expressão anterior pode ser invertida, e a seqüência $\{a_t\}$ pode ser expressa em termos dos w_t's como:

$$a_t = \underbrace{\Psi(B)^{-1}}_{\pi(B)} w_t$$

onde: $\pi(B) = 1 - \pi_1 B - \pi_2 B^2 \ldots$ (5.4.6)

Na prática, as representações (5.4.5) e (5.4.6) **não são** implementáveis, pois os respectivos polinômios em B são de grau infinito, e precisaríamos estimar um número infinito de coeficientes. Box e Jenkins propuseram uma representação equivalente, na qual o polinômio infinito $\Psi(B)$ é substituído pelo quociente de dois polinômios de graus finitos.

Um exemplo elementar deste argumento é dado pela série Geométrica. O polinômio infinito $\Psi(B) = 1 + B + B^2 + B^3 + \ldots$ é igual a $1/(1-B)$ (se $|B| < 1$) e portanto é igual à razão de dois polinômios (um numerador constante e um denominador de grau um).

Exemplo 5.4.6.

Considere o modelo: $w_t = a_t - \theta.a_{t-1} = (1-\theta.B).a_t$ onde $|\theta| < 1$ e os a_t's formam uma seqüência de ruídos brancos. Neste caso, $\psi(B) = 1-\theta.B$ e o polinômio $\pi(B)$ pode ser encontrado facilmente:

$$\pi(B) = \{\Psi(B)\}^{-1} = \frac{1}{1-\theta.B} = 1 + \theta.B + \theta^2.B^2 + \theta^3.B^3 + \ldots\ldots$$

Box e Jenkins propõem escrever $\psi(B)$ como a razão de dois polinômios em B, ou seja:

$$\Psi(B) = \frac{\theta(B)}{\phi(B)} \qquad (5.4.7)$$

Onde:

$\theta(B) = 1 - \theta_1 B - \theta_2 B^2 \ldots - \theta_q B^q$ é um polinômio de grau q, chamado de Polinômio MA(q), e

$\phi(B) = 1 - \phi_1 B - \phi_2 B^2 \ldots - \phi_p B^p$ é denominado polinômio AR(p).

Substituindo (5.4.7) em (5.4.5) leva a:

$$w_t = \Psi(B)a_t = \frac{\theta(B)}{\phi(B)}.a_t \Leftrightarrow \theta(B)a_t = \phi(B)w_t$$

Isto é:

$$\phi(B)w_t = \theta(B)a_t \qquad (5.4.8)$$

O modelo (5.4.8) é chamado de **ARMA(p,q)**. Note que o parâmetro p indica a ordem do polinômio $\phi(B)$ (polinômio AR), enquanto q é o grau do polinômio $\theta(B)$ (polinômio MA).

Exemplo 5.4.7. Modelo AR(p)

Os modelos AR(p) (ou modelos autoregressivos de ordem p) já foram apresentados no capítulo 2, e são apenas um caso particular do ARMA(p, q) fazendo q = 0. A estrutura do modelo AR(p) é:

$$\phi(B)w_t = a_t \Rightarrow \left(1 - \phi_1.B - \phi_2.B^2 - .... - \phi_p.B^p\right)w_t = a_t \qquad (5.4.9)$$
$$\Rightarrow w_t = \phi_1.w_{t-1} + \phi_2.w_{t-2} + ... + \phi_p.w_{t-p} + a_t$$

Um caso particular importante é o modelo AR(1), dado por: $w_t = \phi_1.w_{t-1} + a_t$.

Exemplo 5.4.8. Modelo MA(q)

O modelo MA(q) (modelo médias móveis (ou "moving average" de ordem q) é apenas um modelo ARMA(p, q) no qual p = 0. Pela equação (5.4.8) temos a seguinte estrutura:

$$w_t = \theta(B)a_t \Rightarrow w_t = \left(1 - \theta_1.B - \theta_2.B^2 - .... - \theta_q.B^q\right)a_t \qquad (5.4.10)$$
$$\Rightarrow w_t = a_t + \theta_1.a_{t-1} + \theta_2.a_{t-2} + ... + \theta_q.a_{t-q}$$

O modelo MA(1) é escrito como: $w_t = a_t + \theta_1.a_{t-1}$.

Exemplo 5.4.9. Modelo ARMA(1,1)

Nesta caso p = q = 1 na equação (5.4.8) e o modelo é:
$(1 - \phi_1 B)w_t = (1 - \theta_1 B)a_t$ e então:

$$w_t - \phi_1 w_{t-1} = a_t - \theta_1 a_{t-1}$$

Ou seja:

$$w_t = \phi_1 w_{t-1} + a_t - \theta_1 a_{t-1}$$

Exemplo 5.4.10. Modelo ARMA(2,2)

A equação do modelo é:

$(1 - \phi_1 B - \phi_2 B^2)w_t = (1 - \theta_1 B - \theta_2 B^2)a_t$ e então:

$$w_t - \phi_1 w_{t-1} - \phi_2 w_{t-2} = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2}$$

Ou seja:

$$w_t = \phi_1 w_{t-1} - \phi_2 w_{t-2} + a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2}$$

Condições de Estacionariedade e Inversibilidade dos Modelos ARMA (p,q)

Num processo ARMA(p,q) como o da equação (5.4.8) precisamos verificar quais as condições a serem impostas sobre os coeficientes ψ_i's (ou π_i's, ϕ_i's e θ_i's) para garantir a estacionariedade e a inversibilidade do processo w_t.

Existem dois tipos de condições de interesse:
1) Condição de estacionariedade
2) Condição de inversibilidade

Examinaremos inicialmente a condição de estacionariedade.

Se a entrada de um filtro linear como (5.4.5) é um ruído branco (que é sempre estacionário) então a saída do filtro (w_t) só pode ser não estacionária se houver alguma instabilidade no comportamento do filtro. Isso nos permite encontrar as restrições necessárias sobre os parâmetros do filtro (isto é, as condições que devem ser aplicadas aos φ_i 's e θ_j 's) para garantir a estacionariedade da série de saída w_t.

Pode-se mostrar que se $w_t = \psi(B)a_t$ então a função de autocovariância do processo $\{w_t\}$ é:

$$\gamma_k = \mathrm{Cov}(w_t, w_{t-k}) = \sigma^2 \sum_{j=0}^{\infty} \psi_j.\psi_{j-k}$$

Em particular, a variância de w_t é dada por:

$\mathrm{VAR}(w_t) = \sigma^2 \sum_{j=0}^{\infty} \psi_j^2$ onde $\psi_0 = 1$ e σ^2 é a variância de a_t. Logo, a variância de w_t é finita apenas quando:

$$\left|\sum_{i=1}^{\infty} \Psi i^2\right| < \infty$$

Logo, a variância do processo de saída não vai convergir para uma constante se os pesos ψ_0, ψ_1... não decaírem para zero rapidamente. Ou seja, o processo $\{w_t\}$ é não estacionário se a soma $\sum_{i=1}^{\infty} \Psi i^2$ for infinita. Isso implica a necessidade de restringir os pesos ψ_i para que o filtro seja estável e, conseqüentemente, o processo de saída seja estacionário.

Box e Jenkins mostram que a série $\Psi(B) = \sum_{j=0}^{\infty} \Psi_j.B^j$ converge se $|B| \leq 1$.

Ou seja:

> O processo $\{w_t\}$ é estacionário se os zeros de $\psi(B) = 0$ estiverem dentro do círculo unitário

A idéia de inversibilidade está relacionada com a possibilidade de escrevermos a série de ruído branco como saída de um filtro linear cuja entrada é a série estacionária $\{w_t\}$. Em linhas gerais, o processo $\{w_t\}$ é inversível se podemos escrever a expressão (5.4.6), isto é, se:

$$a_t = \underbrace{\Psi(B)^{-1}}_{\pi(B)} w_t$$

$$a_t = \pi(B).w_t$$

onde $\pi(B) = 1 - \pi_1 B - \pi_2 B^2 ...$

Note que $\pi(B) = \psi^{-1}(B)$ e então os coeficientes π_I 's podem ser encontrados a partir dos ψ_I's e vice versa. A condição de inversibilidade é aplicada aos coeficientes π_I, e é totalmente independente da condição de estacionariedade.

Dizemos que **o processo $\{w_t\}$ é inversível** se $\sum_{i=0}^{\infty} |\pi_i| < \infty$, o que implica a convergência da série dentro do círculo unitário. Note que a condição de inversibilidade é análoga à condição de estacionariedade, mas a primeira é aplicada ao polinômio $\pi(B)$, enquanto a segunda refere-se ao polinômio $\psi(B)$.

A seguir, examinaremos as condições de estacionariedade e inversibilidade para processos ARMA escritos na forma (5.4.8), ou seja:

$$w_t = \Psi(B).a_t = \frac{\theta(B)}{\phi(B)}.a_t \Leftrightarrow \theta(B).a_t = \phi(B).w_t$$

O polinômio $\pi(B)$ pode ser escrito em termos dos polinômios MA e AR como:

$$\pi(B) = \frac{\phi(B)}{\theta(B)} = \phi(B).\theta^{-1}(B)$$

Exemplo 5.4.11. Estacionariedade dos Modelos AR(1)
Considere o modelo AR(1) dado por:

$$w_t = \frac{1}{\phi(B)}.a_t = \frac{1}{1-\varphi_1.B}.a_t$$

Neste caso $\Psi(B) = \frac{1}{1-\varphi_1.B} = 1 + \varphi_1.B + (\varphi_1.B)^2 + ...$ (5.4.11)

Para garantir a estacionariedade do processo precisamos que $\psi(B)$ convirja para $|B| \leq 1$. Mas, por (5.4.11), esta série converge apenas quando $|\phi_1| < 1$. Como a raiz $\phi(B) = 1 - \phi_1.B$ é $B = 1/\phi_1$, segue que $|\phi_1| < 1$ implica uma raiz deste polinômio situada fora do círculo unitário.

Logo, a condição "raiz de $\psi(B)$ **dentro** do círculo unitário" é equivalente à condição "raiz de $\phi(B)$ **fora** do círculo unitário", e assim, a estacionariedade estará garantida se a raiz do polinômio $\phi(B) = 1 - \phi_1.B$ estiver for a do círculo, ou seja, se $|\phi_1| < 1$.

Exemplo 5.4.12. Estacionariedade dos Processos AR(p)
Considere um processo AR(p) dado pela equação:

$$w_t = \frac{1}{\phi(B)}.a_t = \frac{1}{1-\varphi_1.B-\varphi_2.B^2-...-\varphi_p.B^p}.a_t$$

Note que $\varphi(B)$ pode ser escrito como:

$$\varphi(B) = (1-G_1.B)(1-G_2.B)...(1-G_p.B)$$

onde $1/G_1$, $1/G_2$..., $1/G_p$ são as raízes de $\varphi(B) = 0$.

Se expandirmos $1/\varphi(B)$ em frações parciais obtemos:

$$w_t = \frac{1}{\phi(B)}.a_t = \sum_{i=1}^{o} \frac{k_i}{1-G_i.B}.a_t$$

Para garantir a estacionariedade do processo $\{w_t\}$ precisamos que o polinômio $\psi(B) = \phi^{-1}(B)$ convirja quando $|B| \leq 1$, o que implica:

$|G_i| < 1$, isto é, $|1/G_i| > 1$ para i = 1, 2...p, isto é, as raízes de $\varphi(B) = 0$ estão **fora** do círculo unitário.

> **Em resumo:**
>
> **Um processo AR(p) é estacionário se as raízes do polinômio $\varphi(B) = 0$ estão *fora* do círculo unitário.**

Exemplo 5.4.13. Estacionariedade dos Processos AR(2)
O processo AR(2) pode ser escrito como:

$$w_t = \frac{1}{\phi(B)}.a_t = \frac{1}{1-\varphi_1.B-\varphi_2.B^2}.a_t$$

Para garantir a estacionariedade, as raízes do polinômio: $\varphi(B) = 1 - \varphi_1.B - \varphi_2.B^2$ precisam estar fora do círculo unitário. Isto implica que os parâmetros φ_1 e φ_2 precisam estar na região triangular:

$$\varphi_2 + \varphi_1 < 1$$
$$\varphi_2 - \varphi_1 < 1$$
$$-1 < \varphi_2 < 1$$

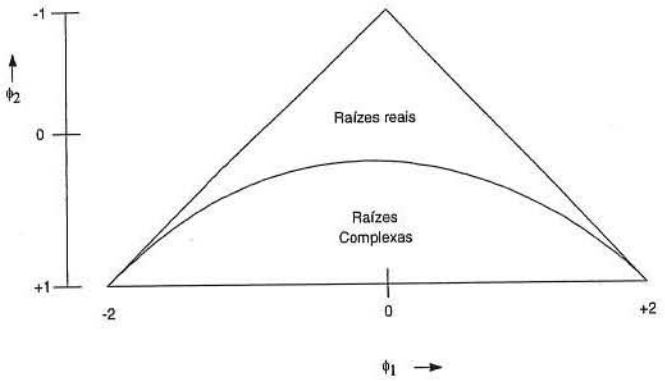

Exemplo 5.4.14. Estacionariedade dos Processos AR(2)

Em todos os casos a seguir, verifique se as condições de estacionariedade são satisfeitas.

Processo	ϕ_1	ϕ_2	Estacionário?
$w_t = 0.7w_{t-1} + 0.4w_{t-2}+a_t$	+0.7	+0.4	**Não**
$w_t = 0.7w_{t-1} + 0.2w_{t-2}+a_t$	+0.7	+0.2	Sim
$w_t = -0.4w_{t-1} + 0.8w_{t-2}+a_t$	-0.4	+0.8	**Não**
$w_t = +0.4w_{t-1} + 0.8w_{t-2}+a_t$	+0.4	+0.8	**Não**
$w_t = 0.8w_{t-1} - 0.4w_{t-2}+a_t$	+0.8	-0.4	Sim

Exemplo 5.4.15. Estacionariedade dos Processos MA(q)

Considere um processo MA(q) dado por:

$$w_t = \theta(B)a_t \Rightarrow w_t = \left(1 - \theta_1.B - \theta_2.B^2 - \ldots. - \theta_q.B^q\right)a_t$$
$$\Rightarrow w_t = a_t + \theta_1.a_{t-1} + \theta_2.a_{t-2} + \ldots. + \theta_q.a_{t-q}$$

Neste caso $\psi(B) = \theta(B)$ é um polinômio finito de grau q, e portanto a convergência é trivial. Logo, um modelo MA(q) é sempre estacionário!

Exemplo 5.4.16. Estacionariedade de um Processo ARMA(p,q)

A equação geral do processo é:

$\phi(B).w_t = \theta(B).a_t$

Podemos representar este processo esquematicamente como:

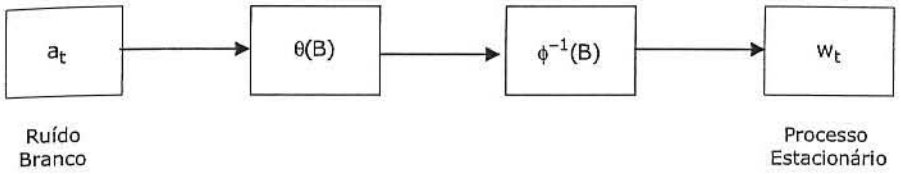

Seja $b_t = \theta(B).a_t$. O processo b_t é a saída de um modelo MA(q), e portanto é um processo estacionário.

Para garantir que $\{w_t\}$ seja estacionário basta que $\varphi(B)$ satisfaça as condições de estacionariedade de um processo AR(p).

Logo, um modelo ARMA(p, q) é estacionário se as raízes do polinômio $\varphi(B) = 0$ estão *fora* do círculo unitário.

Exemplo 5.4.17. Inversibilidade dos Processos AR(p)

Seja o processo AR(p) dado por:

$$\phi(B).w_t = a_t \qquad (5.4.12)$$

Note que, nesta equação o ruído é escrito explicitamente como função da série estacionária w_t e portanto (5.4.12) já define um processo inversível. Também, o polinômio AR tem grau finito e assim segue que **um processo AR(p) é trivialmente inversível.**

Neste caso, $\pi(B) = \varphi(B)$, que é um polinômio de grau finito p.

Exemplo 5.4.18. Inversibilidade de um MA(1)

Considere um processo MA(1):

$w_t = (1-\theta.B)a_t$

Logo:

$$a_t = \frac{1}{1-\theta.B}w_t = \frac{\left(1+\theta.B+\theta^2.B^2+\ldots+\theta^k.B^k\right)}{1-\theta^{k+1}.B^{k+1}}w_t$$

Ou seja, escrevendo w_t em termos de seus valores passados e de a_t encontramos:

$$w_t = -\theta.w_{t-1} - \theta^2.w_{t-2} - \ldots. - \theta^k.w_{t-k} + a_t - \theta^{k+1}.a_{t-k} \qquad (5.4.13)$$

Nesta expressão, os coeficientes π_j do polinômio $\pi(B)$ são os $-\theta^j$.

Não importa qual o valor de θ, o processo w_t será estacionário, pois é um processo MA(1), e estes são trivialmente estacionários. Mas, se $|\theta| \geq 1$, o valor atual de w_t depende dos valores passados w_{t-1}, $w_{t-2}...w_{t-k}$ com **pesos crescentes** à medida que o lag aumenta. Podemos evitar esta situação se forçarmos $|\theta| < 1$, e neste caso dizemos que o processo é inversível.
Na expressão (5.4.13) se supormos $|\theta| < 1$ e tomarmos o limite quando k tende a infinito teremos:

$$w_t = -\theta.w_{t-1} - \theta^2.w_{t-2} - \theta^3.w_{t-3} - .... + a_t$$

Ou seja, o processo w_t (um MA(1) inversível) pode ser escrito como um AR de ordem infinita e estacionário (pois $|\theta| < 1$ por hipótese).

Este resultado é, na verdade, mais geral do que se possa supor à primeira vista:

MA(q) = AR(∞) e
AR(p) = MA(∞)

Note que a condição de inversibilidade é, neste caso $|\theta| < 1$ e equivale à condição: raiz de $\theta(B) = (1-\theta.B) = 0$ fora do círculo unitário.

Exemplo 5.4.19. Inversibilidade de um Modelo MA(2)
A condição de inversibilidade de um modelo MA(2) é completamente análoga à condição de estacionariedade de um processo AR(2). Para garantir a inversibilidade, precisamos que a seguinte condição seja satisfeita: raízes de $\theta(B) = 0$ **fora** do círculo unitário. Em termos dos coeficientes que definem o processo estas condições podem ser escritas como:

$\theta_2 + \theta_1 < 1$
$\theta_2 - \theta_1 < 1$
$-1 < \theta_2 < 1$

E a região de inversibilidade do processo é indicada na figura a seguir.

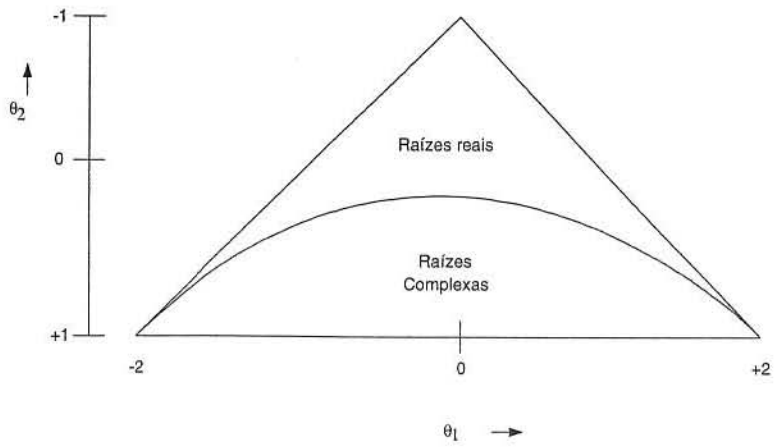

Exemplo 5.4.20. Inversibilidade de um Modelo ARMA(p,q)
A inversibilidade do modelo ARMA(p,q) só depende da parte MA do modelo, pois a parte AR é trivialmente inversível. O modelo ARMA(p,q) será inversível se as raízes de $\theta(B) = 0$ estiverem fora do círculo unitário.

Exemplo 5.4.21. Estacionariedade e Inversibilidade de um Modelo ARMA (1,1)
Como já mencionado, as condições de estacionariedade e inversibilidade são independentes. Também, para garantirmos a estacionariedade precisamos olhar apenas para a parte AR(1) do modelo, e a inversibilidade é assegurada olhando-se só para a parte MA(1) do modelo. Assim, para garantir que o modelo ARMA(1,1) seja estacionário e inversível precisamos das seguintes condições:

- Estacionariedade: $|\phi_1| < 1$
- Inversibilidade: $|\theta_1| < 1$

O processo será estacionário e inversível se os parâmetros ϕ_1 e θ_1 estiverem na região abaixo:

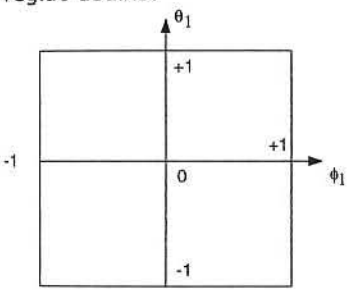

Definição 5.4.22. Função de Autocorrelação Parcial (PACF)
A função de autocorrelação parcial mede a dependência linear entre w_t e w_{t+k}, eliminando o efeito das variáveis intermediárias w_{t+1}, $w_{t+2}...$, w_{t+k-1}. A função de autocorrelação parcial é usada para identificar a ordem de um modelo AR(p). Note que é necessário usar uma outra função, além da ACF, para identificar a ordem de um modelo AR, pois todos os modelos AR têm uma ACF que decresce exponencialmente, e portanto apenas o correlograma não traz informação sobre o grau p do polinômio autoregressivo na representação ARMA.

Considere um modelo AR(p).
Uma maneira de definir a PACF é através da regressão linear de w_{t+k} em $w_{t+k-1}...w_t$, ou seja:

$$w_{t+k} = \phi_{k1}\, w_{t+k-1} + \phi_{k2}\, w_{t+k-2} + ... + \phi_{kk}\, w_t + e_{t+k}$$

Multiplicando ambos os lados da equação acima por w_{t+k-j} e tomando o valor esperado tem-se:

$$E[w_{t+k}.w_{t+k-j}] = \phi_{k1}.E[w_{t+k-1}.w_{t+k-j}] + \phi_{k2}.E[w_{t+k-2}.w_{t+k-j}] + \dots$$
$$+ \phi_{kk}.E[w_t.w_{t+k-j}] + E[e_{t+k}.w_{t+k-j}]$$

Fazendo $j = 1, 2..., k$ e levando em conta que $\rho_k = \rho_{-k}$ obtemos o seguinte sistema de k equações com k incógnitas ($\phi_{k1}, \phi_{k2} \cdots, \phi_{kk}$):

$$\begin{pmatrix} \rho_0 & \rho_1 \cdots & \rho_{k-1} \\ \rho_1 & \rho_0 \cdots & \rho_{k-2} \\ . & . & . \\ . & . & . \\ \rho_{k-1} & \rho_{k-2} \cdots & \rho_0 \end{pmatrix} \begin{pmatrix} \phi_{k1} \\ \phi_{k2} \\ . \\ . \\ \phi_{kk} \end{pmatrix} = \begin{pmatrix} \rho_1 \\ \rho_2 \\ . \\ . \\ \rho_k \end{pmatrix} \qquad (5.4.14)$$

As equações (5.4.14) são conhecidas como **equações de Yule-Walker**. Elas fornecem um algoritmo simples para determinar a ordem de um processo AR. Na prática, os ρ_j 's na equação acima são substituídos por seus estimadores r_j.

A resolução do sistema (5.4.14) para todo k fornece as autocorrelações parciais de lag 1, 2... Pela regra de Cramer aplicada ao sistema anterior temos:

$$\phi_{kk} = \frac{\det \begin{bmatrix} 1 & \rho_1 & \rho_2 & \cdots & \rho_1 \\ \rho_1 & 1 & \rho_2 & \cdots & \rho_2 \\ & & \cdots & & \\ \rho_{k-1} & \rho_{k-2} & \rho_{k-3} & \cdots & \rho_k \end{bmatrix}}{\det \begin{bmatrix} 1 & \rho_1 & \rho_2 & \cdots & \rho_{k-1} \\ \rho_1 & 1 & \rho_2 & \cdots & \rho_{k-1} \\ & & \cdots & & \\ \rho_{k-1} & \rho_{k-2} & \rho_{k-3} & \cdots & 1 \end{bmatrix}} \qquad (5.4.15)$$

Ou seja, a matriz no numerador em (5.4.15) é a mesma que a matriz no denominador, exceto pela última coluna, que é substituída por $[\rho_1, \rho_2 \dots, \rho_k]^t$.

Em particular, $\phi_{11} = \rho_1$ sempre, e $\phi_{22} = \dfrac{\det \begin{bmatrix} 1 & \rho_1 \\ \rho_1 & \rho_2 \end{bmatrix}}{\det \begin{bmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{bmatrix}} = \dfrac{\rho_2 - \rho_1^2}{1 - \rho_1^2}$

Pode-se provar que, num processo AR(p), as autocorrelações parciais são nulas para todos os lags maiores que p. Logo, o gráfico da PACF nos permite identificar o grau do polinômio AR, pois a partir de um certo lag todas as autocorrelações parciais são nulas.
Por exemplo, veja Box, Jenkins e Reinsel (1994), página 66.

Exemplo 5.4.23. Comportamento da ACF e PACF para o Modelo AR(p)
Considere um modelo AR(p), cuja equação é:
$(1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p).w_t = a_t$

Isto é:
$w_t = \phi_1 w_{t-1} + \phi_2 w_{t-2} + \dots + \phi_p w_{t-p} + a_t$

Multiplicando por w_{t-k} e tirando o valor esperado, lembrando que $E(w_t.w_{t-k}) = \gamma_k$, obtém-se:

$E(w_t.w_{t-k}) = \phi_1.E(w_{t-1}.w_{t-k}) + \phi_2.E(w_{t-2}.w_{t-k}) + \dots + \phi_p.E(w_{t-p}.w_{t-k}) + E(a_t.w_{t-k})$

$\Rightarrow \gamma_k = \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2} + \dots + \phi_p \gamma_{k-p}$

Como $\rho_k = \gamma_k / \gamma_0$, obtém-se finalmente:

$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2} + \phi_p \rho_{k-p}$

Ou seja, as autocorrelações de um processo AR(p) satisfazem a equação: $\phi(B).\rho_k = 0$.

A ACF do modelo AR(p) é obtida por uma equação de diferenças de ordem p, cuja solução é formada por uma mistura de exponenciais e/ou senóides amortecidas.

Em resumo:
para um AR(p) tem-se:

ACF: ρ_k x k $\Rightarrow$ exponenciais e/ou senóides amortecidas

PACF: ϕ_{kk} x k $\Rightarrow$ corte brusco no lag k = p

Exemplo 5.4.24. ACF e PACF de um Modelo AR(1)
Considere um modelo AR(1) estacionário, isto é: $(1-\phi_1,B)Z_t = a_t$ onde $|\phi_1| < 1$. Então a autocorrelação de lag k é $\rho_k = \phi_1^k$. As autocorrelações parciais são:

$\phi_{11} = \rho_1 = \phi_1$

$$\phi_{22} = \frac{\det \begin{bmatrix} 1 & \rho_1 \\ \rho_1 & \rho_2 \end{bmatrix}}{\det \begin{bmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{bmatrix}} = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2} = \frac{\phi_1^2 - \phi_1^2}{1 - \phi_1^2} = 0$$

e $\phi_{kk} = 0$ para k = 3, 4, 5...

Os gráficos da ACF teórica são mostrados a seguir.

$\rho_k = \phi_1^k$

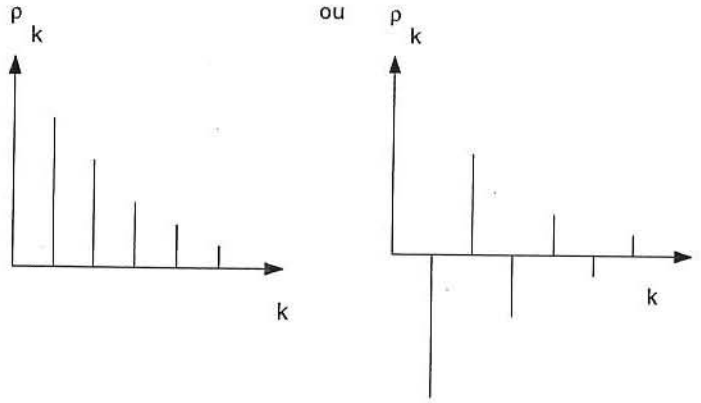

A PACF só é diferente de zero no lag 1, e exibe um corte brusco após este lag. Logo, num processo AR(1) apenas a primeira autocorrelação parcial é não nula, e o gráfico da PACF versus o lag exibe um corte brusco.

Resultado 5.4.25. Intervalo de Confiança para a PACF – Fórmula de Quenouille

Seja $\hat{\phi}_{kk}$ o estimador da autocorrelação parcial de lag k, encontrado pela substituição dos ρ_i pelos seus estimadores r_i nas equações de Yule-Walker.

Então:

$\text{Var}\left(\hat{\phi}_{kk}\right) \approx \frac{1}{T}$ onde T é o tamanho da série.

Para T grande, $\hat{\phi}_{kk}$ tem aproximadamente a distribuição Normal.

Exemplo 5.4.26. ACF e PACF do Modelo MA(q)

Considere um modelo MA(q), isto é:

$w_t = \theta(B)a_t \Rightarrow w_t = (1 - \theta_1 B - \theta_2 B^2 \ldots \theta_q B^q)a_t$

$w_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \ldots - \theta_q a_{t-q}$

Multiplicando a equação anterior por w_{t-k} e tomando o valor esperado leva a:

$E(w_t . w_{t-k}) = E[(a_t - \theta_1 a_{t-1} - \ldots - \theta_q a_{t-q})(a_{t-k} - \theta_1 a_{t-k-1} - \ldots - \theta_q a_{t-k-q})]$

Ou seja, a autocovariância de lag k é:

$\gamma_k = (-\theta_k + \theta_1\theta_{k+1} + \theta_{q-k}\theta_q)$ onde k = 1, 2..., q e $\gamma_k = 0$ para lags maiores que q.
Como $\rho_k = \gamma_k / \gamma_0$ conclui-se que:

$$\rho_k = \frac{(-\theta_k + \theta_1\theta_{k+1} + \ldots + \theta_{q-k}\theta_q)}{(1 + \theta_1^2 + \ldots + \theta_q)^2} \qquad k = 1, 2, \ldots, q \quad e$$

$\rho_k = 0$ se $k > q$

Ou seja, num processo MA(q) a ACF tem um corte brusco a partir do lag q+1.

Pela propriedade de inversibilidade, um modelo MA(q) equivale a um AR(∞) e então a regressão de w_{t+k} nos w's anteriores (que é usada para definir a PACF) indica que ϕ_{kk} não possuirá a propriedade de corte brusco; decaindo com k.

Em resumo:

Num modelo MA(q) tem-se:

ACF: apresenta um corte brusco no lag k = q

PACF: tem o comportamento de exponenciais e/ou senóides amortecidas, e então não apresenta corte brusco.

Exemplo 5.4.27. Modelo MA(1)

$w_t = (1 - \theta_1 B)a_t$

O processo é trivialmente estacionário, e é inversível quando $|\theta_1| < 1$. A variância do processo é dada por: $\gamma_0 = \text{Var}(w_t) = \sigma_a^2(1 + \theta_1^2)$, e as autocorrelações são: $\rho_1 = \frac{-\theta_1}{1 + \theta_1^2}$ e $\rho_k = 0$ se $k > 1$.

A k-ésima autocorrelação parcial é (vide Box, Jenkins e Reinsel (1994), pág. 73):

$$\phi_{kk} = \frac{-\theta_1^k(1 - \theta_1^2)}{(1 - \theta_1^{2k+2})}$$

Como $|\phi_{kk}| < \theta_1^k$, a função de autocorrelação parcial é dominada por uma exponencial amortecida. Se ρ_1 for positivo (e então θ_1 é negativo), as PACFs têm sinais alternantes. Ao contrário, se ρ_1 for positivo, as autocorrelações parciais são todas negativas.

Existe uma dualidade no comportamento das funções ACF e PACF para os modelos AR(p) e MA(q), ou seja, o aspecto da PACF de um processo AR tem um corte brusco (assim como a ACF de um MA), e a ACF de um AR tem a "cara" da PACF de um MA (senóides amortecidas e/ou decréscimo exponencial).

Exemplo 5.4.28. Modelo ARMA(p,q)
A estrutura do modelo é: $\phi(B).w_t = \theta(B).a_t$

Box, Jenkins e Reinsel (1994, página 79) mostram que a função de autocorrelação tem a forma:

$$\rho_k = \phi_1\rho_{k-1} + \phi_2\rho_{k-2} + ... + \phi_p\rho_{k-p} \quad \text{para } k = q+1, q+2, q+3, ... \text{ e} \qquad (5.4.16)$$

$$\rho_k = \phi_1\rho_{k-1} + \phi_2\rho_{k-2} + ... + \phi_p\rho_{k-p} - \frac{\sigma_a^2}{\gamma_0}\left(\theta_k\psi_0 + \theta_{k+1}\psi_1 + ... + \theta_q\psi_{q-k}\right)$$

para $k = 0, 1, ... q$

onde usamos a convenção: $\theta_0 = -1$, γ_0 é a variância do processo w_t e os ψ_i 's são os coeficientes do polinômio $\Psi(B)$ na expansão $w_t = \Psi(B).a_t$.

A variância do processo w_t é dada por:

$$\gamma_0 = \phi_1\gamma_1 + \phi_2\gamma_2 + ... + \phi_p\gamma_p + \sigma_a^2\left(1 - \theta_1\psi_1 - .... - \theta_q\psi_q\right)$$

Esta expressão precisa ser resolvida em conjunto com as equações (5.4.16) para k = 1, 2...p para obter $\gamma_0, \gamma_1 ..., \gamma_p$.

A função de autocorrelação parcial é infinita, e eventualmente se comporta como a PACF de um processo MA puro, sendo dominada por uma mistura de exponenciais amortecidas e/ou senóides, dependendo da ordem do polinômio MA e de seus parâmetros.

Exemplo 5.4.29. Processo ARMA(1,1)
A estrutura do modelo é:

$(1 - \phi_1.B).w_t = (1 - \theta_1.B).a_t$

A função de autocorrelação é encontrada pelas equações:

$$\gamma_0 = Var(w_t) = \phi_1.\gamma_1 + \sigma_a^2(1 - \theta_1.\psi_1)$$
$$\gamma_1 = \phi_1.\gamma_0 - \sigma_a^2(\theta_1)$$
$$\gamma_2 = \phi_1.\gamma_{k-1} \quad \text{para } k = 2, 3, 4, ...$$

onde $\psi_1 = \phi_1 - \theta_1$

Se resolvermos as duas primeiras equações para γ_0 e γ_1, a função de autocovariância do processo torna-se:

$$\gamma_0 = \frac{1 + \theta_1^2 - 2\phi_1\theta_1}{1 - \phi_1^2}\sigma_a^2 \qquad (5.4.17)$$

$$\gamma_1 = \frac{(1 - \phi_1\theta_1)(\phi_1 - \theta_1)}{1 - \phi_1^2}\sigma_a^2 \qquad (5.4.18)$$

$$\gamma_k = \phi_1.\gamma_{k-1} \quad \text{para } k = 2, 3, 4... \qquad (5.4.19)$$

Da equação (5.4.19) segue que as autocorrelações a partir do lag 2 têm a forma: $\rho_k = \phi_1.\rho_{k-1}$ e como $\rho_2 = \phi_1.\rho_1$ segue que $\rho_k = \phi_1^{k-1}.\rho_1$ para k = 2, 3, 4... Logo, a autocorrelação decresce exponencialmente a partir do valor inicial ρ_1 que, por sua vez, depende dos parâmetros ϕ_1 e θ_1.

A primeira autocorrelação do processo pode ser escrita como:

$$\rho_1 = \frac{(1 - \phi_1\theta_1)(\phi_1 - \theta_1)}{1 - 2\phi_1.\theta_1 + \theta_1^2}$$

A função de autocorrelação parcial de um processo ARMA(1,1) consiste num único valor inicial $\phi_{11} = \rho_1$ e a partir do lag 2 comporta-se como a PACF de um processo MA(1), sendo dominada por uma exponencial.

A seguir, exibimos um quadro resumo contendo as principais características dos modelos AR, MA e ARMA.

Quadro resumo das características principais dos modelos AR(p), MA(q) e ARMA(p,q)

	AR(p)	MA(q)	ARMA(p,q)
Estrutura do modelo	$\phi(B)Z_t = a_t$	$Z_t = \theta(B).a_t$	$\phi(B)Z_t = \theta(B).a_t$
Condição de estacionariedade	Raízes de $\phi(B) = 0$ fora do círculo unitário	Sempre Estacionário	Raízes de $\phi(B) = 0$ fora do círculo unitário
Condição de inversibilidade	Sempre inversível	Raízes de $\theta(B) = 0$ fora do círculo unitário	Raízes de $\theta(B) = 0$ fora do círculo unitário
Função de Autocorrelação ρ_k	Infinita (Exponenciais e/ou senóides amortecidas)	Finita (corte após o lag "q")	Infinita (Exponenciais e/ou senóides amortecidas após o lag "q-p")
Função de Autocorrelação Parcial ϕ_{kk}	Finita (corte após o lag p)	Infinita (Exponenciais e/ou senóides amortecidas)	Infinita (Exponenciais e/ou senóides amortecidas após o lag "p-q")

Mas... NA PRÁTICA, NEM TUDO FUNCIONA COMO PREVISTO!!!!

A seguir, exibimos a ACF e PACF de séries simuladas a partir dos processos AR(1) e MA(1) indicados. Note que, para séries curtas é difícil identificar os padrões teóricos descritos acima. Na verdade é freqüente encontrar valores "espúrios" para autocorrelações e autocorrelações parciais estimadas em séries curtas, o que dificulta o processo de identificação da ordem dos polinômios AR e MA.

Exemplo 5.4.30. Processo AR(1) com $\varphi_1 = +0.8$
Geramos duas séries que seguem processos AR(1) com parâmetro $\varphi_1 = + 0.8$. A primeira série tem 50 observações, e a segunda, 300 observações. A ACF e PACF estimadas para as duas séries estão no próximo quadro.

Série 1 – 50 observações de um processo AR(1) com parâmetro + 0.8

ACF

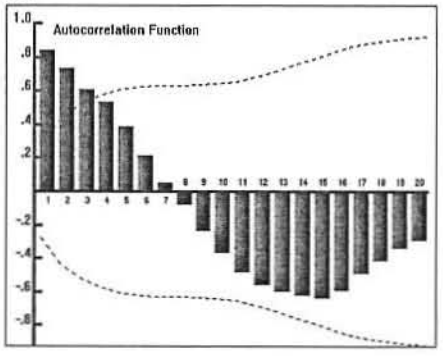

PACF

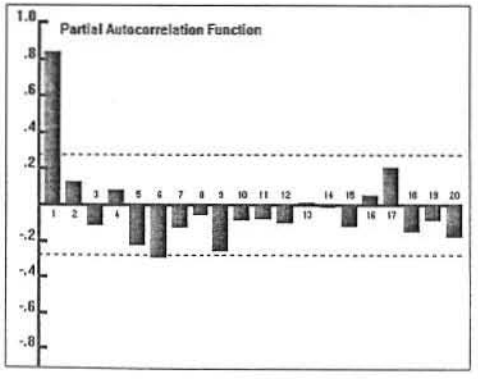

Série 2 – 300 observações de um processo AR(1) com parâmetro + 0.8

ACF

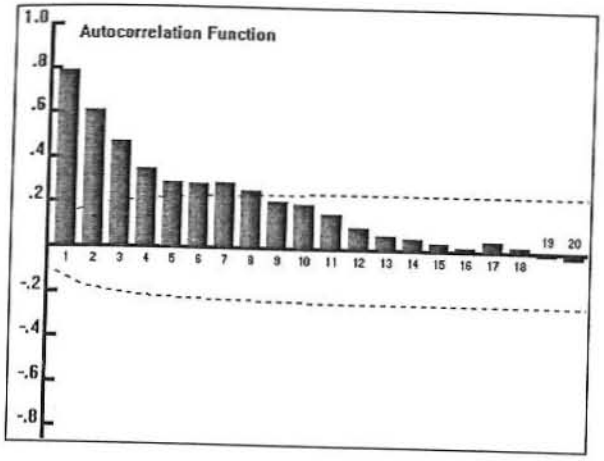

Exemplo de uma função de autocorrelação

PACF

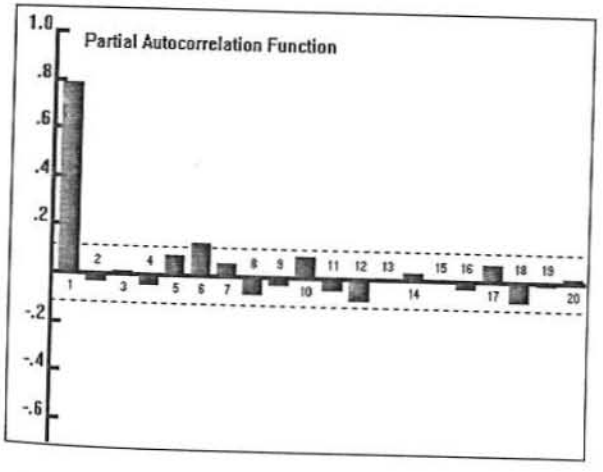

Exemplo 5.4.31. Processo AR(1) com $\varphi_1 = - 0.8$
Geramos duas séries que seguem processos AR(1) com parâmetro $\varphi_1 = - 0.8$. A primeira série tem 50 observações, e a segunda, 300 observações. A ACF e PACF estimadas para as duas séries estão no próximo quadro.

Série 1 – 50 observações de um processo AR(1) com parâmetro - 0.8

ACF

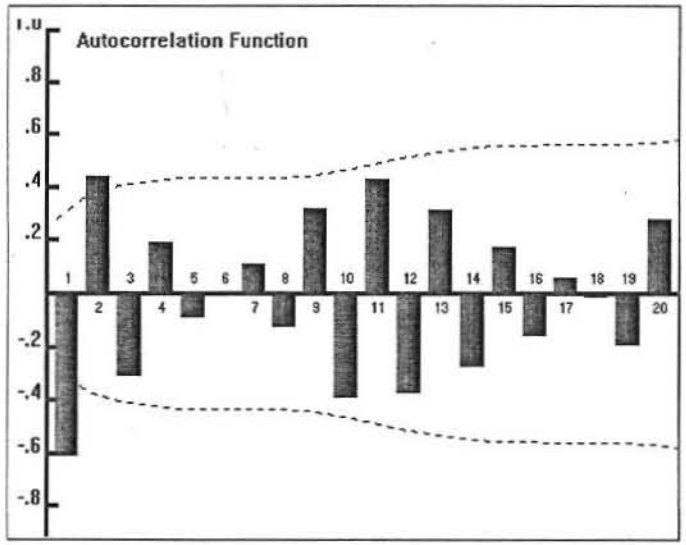

PACF

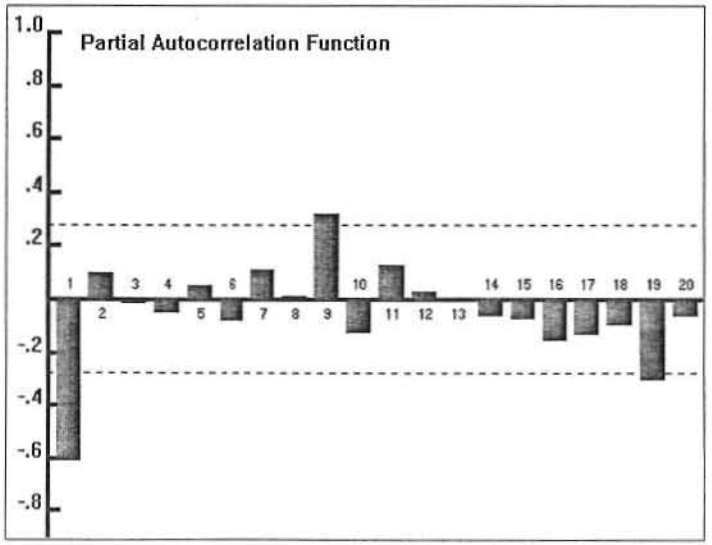

Série 2 – 300 observações de um processo AR(1) com parâmetro - 0.8

ACF

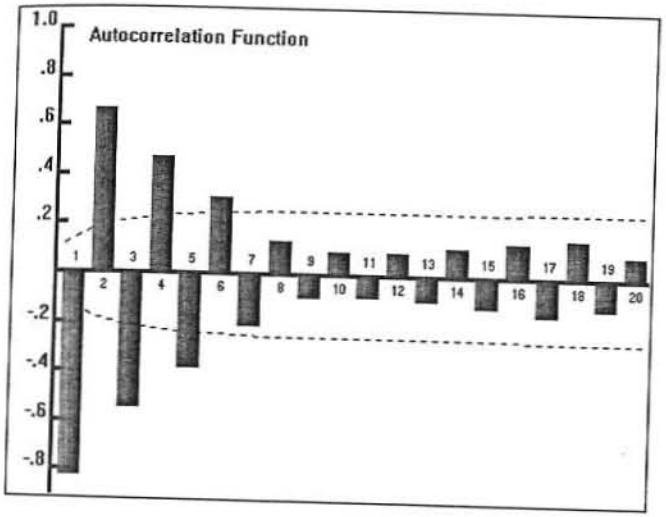

quando o gráfico cai suavemente tem cara de auto-regressivo

PACF

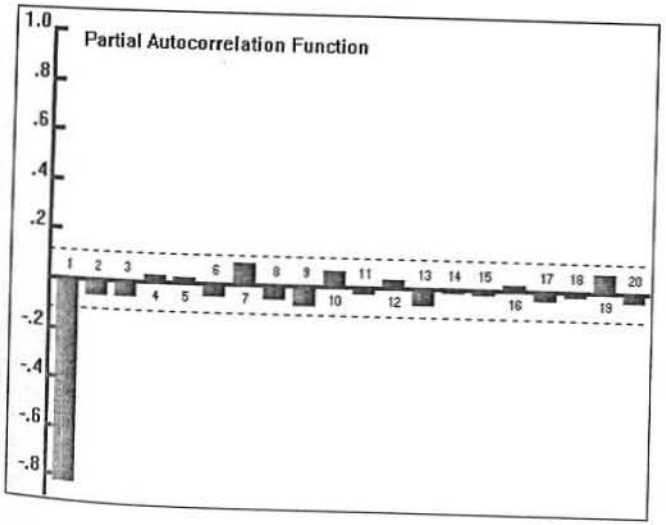

Exemplo 5.4.32. Processo MA (1) com $\theta_1 = +0.8$

Geramos duas séries que seguem processos MA(1) com parâmetro $\theta_1 = +0.8$. A primeira série tem 50 observações, e a segunda, 300 observações. A ACF e PACF estimadas para as duas séries estão no próximo quadro.

Série 1 – 50 observações de um processo MA (1) com parâmetro +0.8

ACF

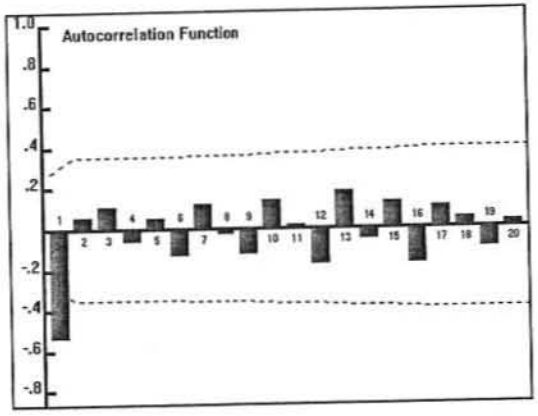

PACF

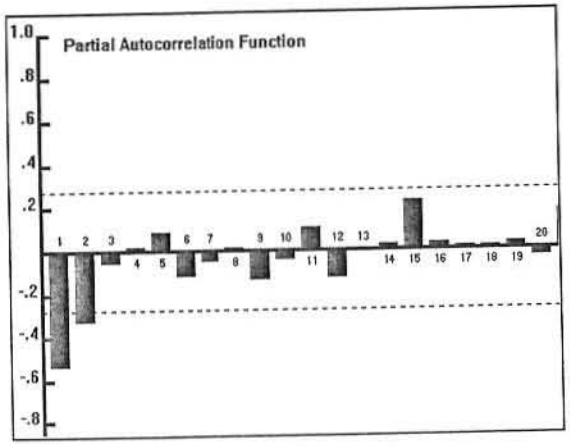

Série 2 – 300 observações de um processo MA(1) com parâmetro +0.8

ACF

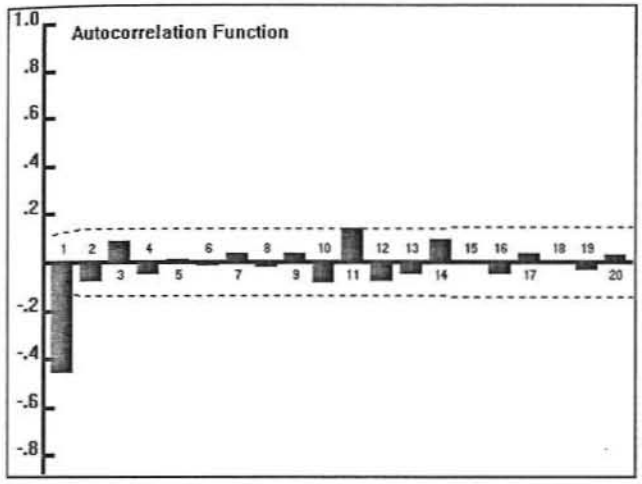

mais rápido.
no MA, a auto correlação já' fornece a ordem do modelo.

PACF

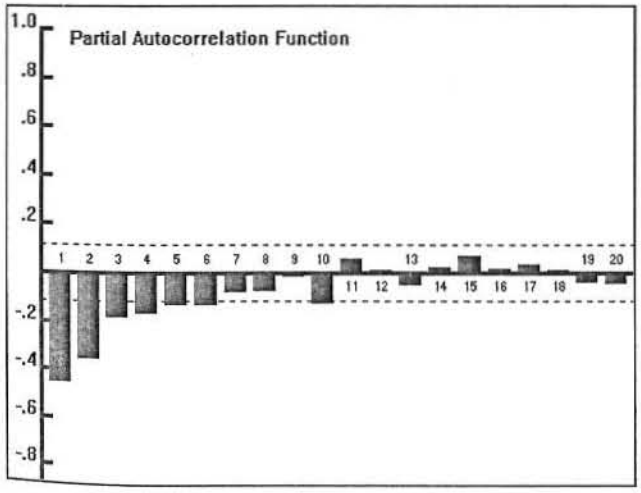

é o inverso da auto correlação

Exemplo 5.4.33. Processo MA (1) com θ_1 = - 0.8

Geramos duas séries que seguem processos MA(1) com parâmetro θ_1 = - 0.8. A primeira série tem 50 observações, e a segunda, 300 observações. A ACF e PACF estimadas para as duas séries estão no próximo quadro.

Série 1 – 50 observações de um processo MA (1) com parâmetro - 0.8

ACF

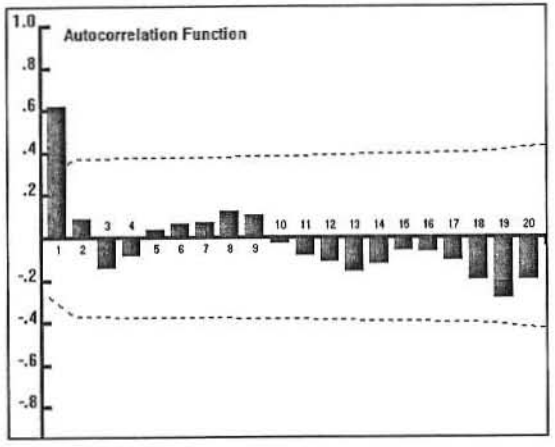

PACF

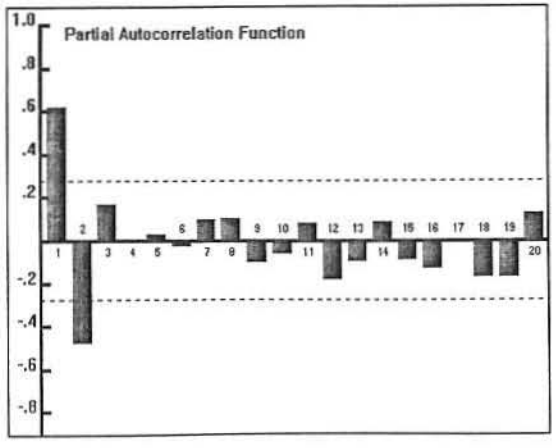

Série 2 – 300 observações de um processo MA(1) com parâmetro - 0.8

ACF

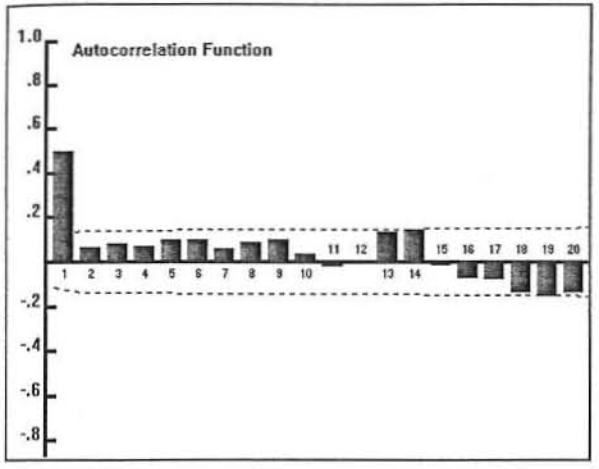

PACF

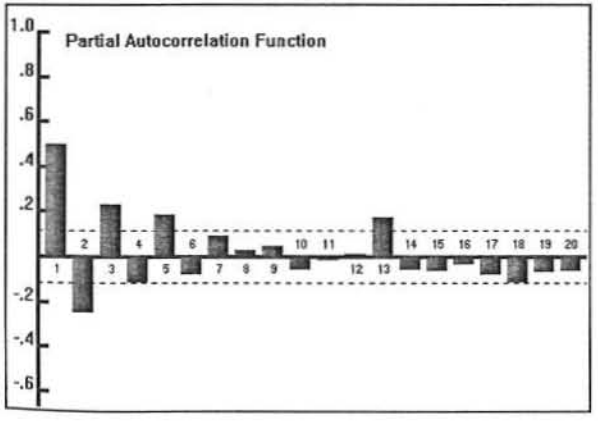

Note que o sinal da autocorrelação parcial de lag 1 no modelo MA(1) é o oposto do sinal do coeficiente θ_1, ou seja, se o parâmetro θ_1 é positivo (negativo), a autocorrelação parcial de lag 1 é negativa (positiva).

Exemplo 5.4.34. Modelo AR(2) com $\phi_1 = +0.3$ e $\phi_2 = +0.5$
A seguir, exibimos o gráfico da ACF e PACF estimadas (a partir de uma série de tamanho 300) de um processo AR(2) estacionário com $\phi_1 = +0.3$ e $\phi_2 = +0.5$. Note que as autocorrelações decrescem exponencialmente e as autocorrelações parciais são diferentes de zero apenas nos dois primeiros lags.

300 observações de um processo AR(2) com $\phi_1 = +0.3$ e $\phi_2 = +0.5$

ACF

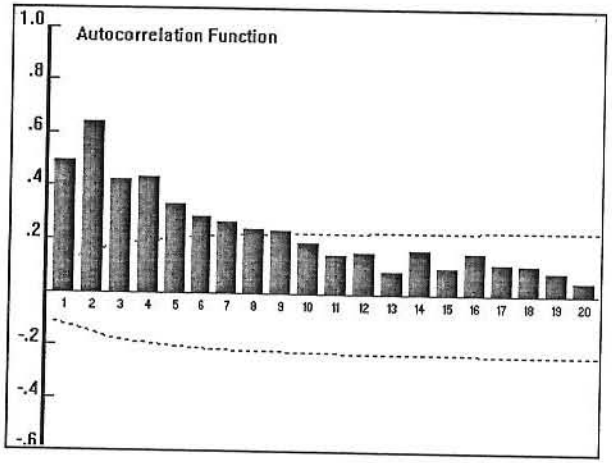

PACF

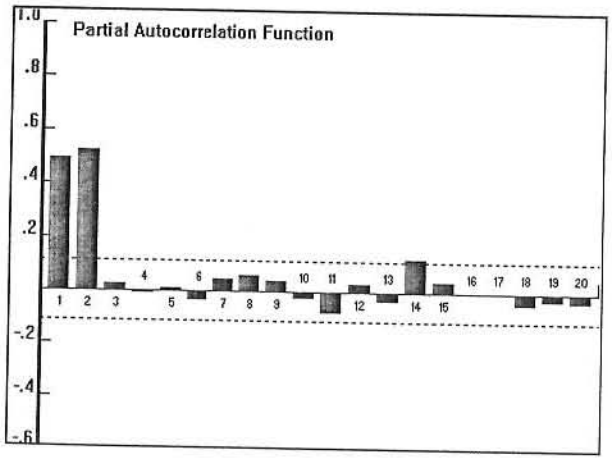

Exemplo 5.4.35. Modelo AR(2) com $\phi_1 = +0.3$ e $\phi_2 = -0.5$
A seguir, exibimos o gráfico da ACF e PACF estimadas (a partir de uma série de tamanho 300) de um processo AR(2) estacionário com $\phi_1 = +0.3$ e $\phi_2 = -0.5$

300 observações de um processo AR(2) com $\phi_1 = +0.3$ e $\phi_2 = -0.5$

ACF

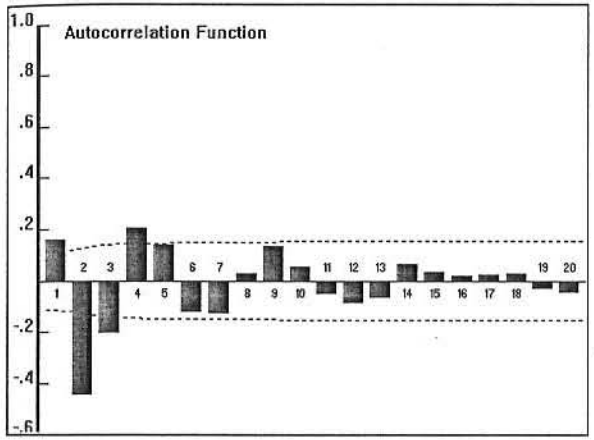

PACF

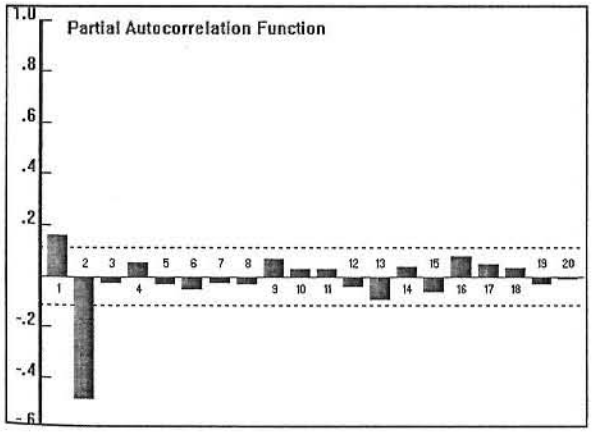

As autocorrelações se alternam em sinal e decrescem para zero e apenas as duas primeiras autocorrelações parciais são não nulas.

Exemplo 5.4.36. Modelo MA(2) com $\theta_1 = +0.3$ e $\theta_2 = +0.5$
A seguir, exibimos o gráfico da ACF e PACF estimadas (a partir de uma série de tamanho 300) de um processo MA(2) com $\theta_1 = +0.3$ e $\theta_2 = +0.5$.

300 observações de um processo MA(2) com $\theta_1 = +0.3$ e $\theta_2 = +0.5$

ACF

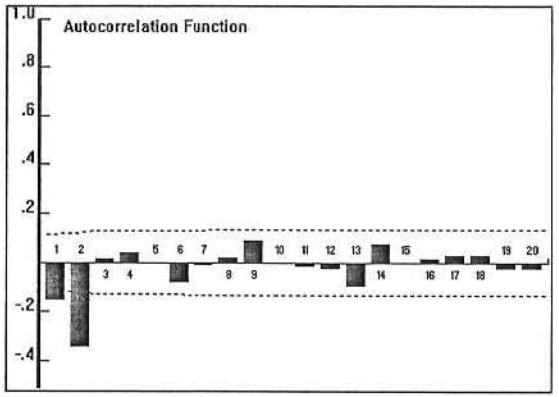

PACF

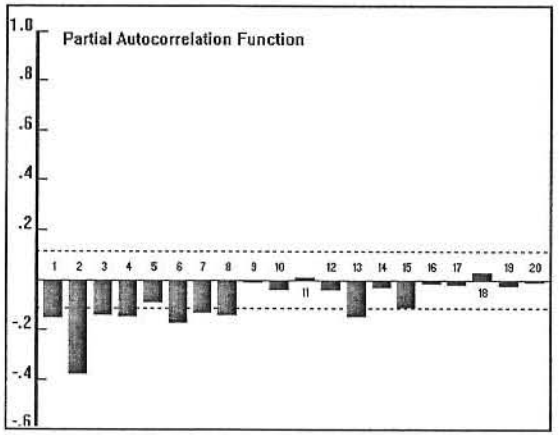

As autocorrelações parciais decrescem exponencialmente, e as autocorrelações são não nulas apenas nos dois primeiros lags, sofrendo um corte brusco após o segundo lag, o que permite identificar claramente a estrutura MA(2).

Exemplo 5.4.37. Modelo MA(2) com $\theta_1 = +0.3$ e $\theta_2 = -0.5$
A seguir, exibimos o gráfico da ACF e PACF estimadas (a partir de uma série de tamanho 300) de um processo MA(2) com $\theta_1 = +0.3$ e $\theta_2 = -0.5$

300 observações de um processo MA(2) com $\theta_1 = +0.3$ e $\theta_2 = -0.5$

ACF

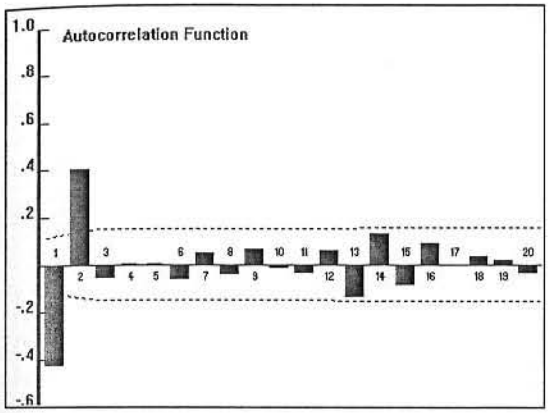

PACF

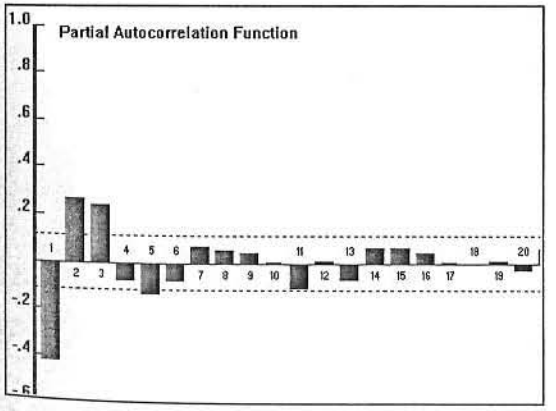

Note a significância das duas primeiras autocorrelações e o decréscimo das PACFs (com alternância de sinais).

Exemplo 5.4.38. Modelo ARMA(1,1) com $\phi_1 = +0.7$ e $\theta_1 = +0.4$

300 observações de um processo ARMA(1,1) com $\phi_1 = +0.7$ e $\theta_1 = +0.4$

ACF

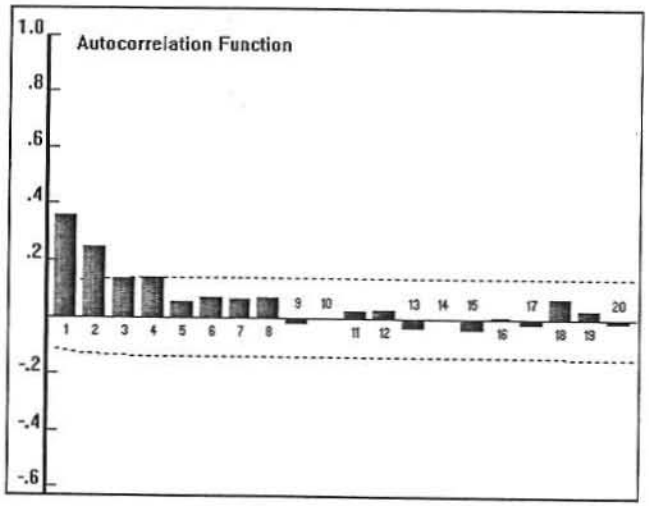

PACF

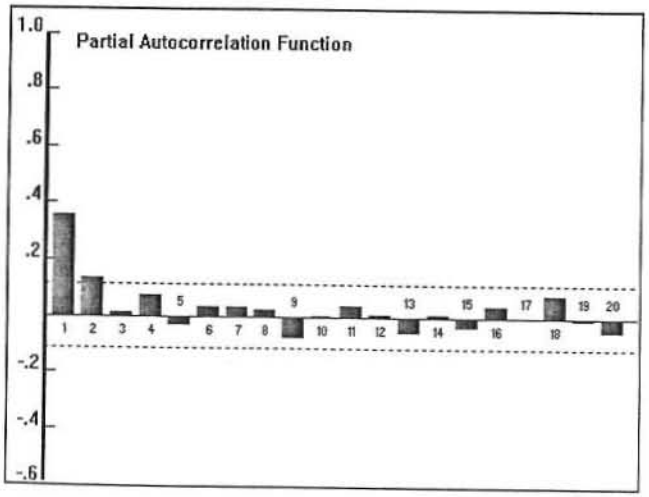

Exemplo 5.4.39. Modelo ARMA(1,1) com $\phi_1 = +0.7$ e $\theta_1 = -0.4$

300 observações de um processo ARMA(1,1) com $\phi_1 = +0.7$ e $\theta_1 = -0.4$

ACF

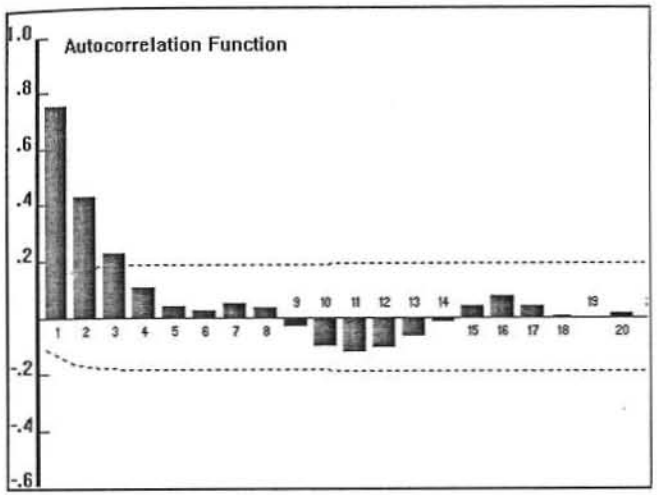

PACF

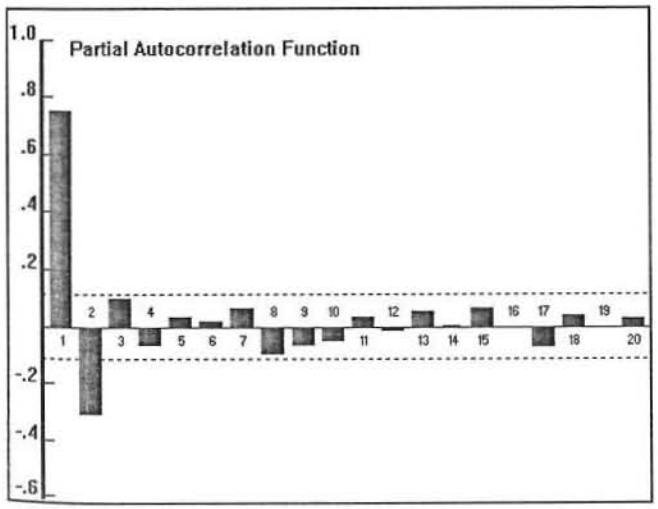

Exemplo 5.4.40. Modelo ARMA(1,1) com $\phi_1 = -0.7$ e $\theta_1 = -0.4$

300 observações de um processo ARMA(1,1) com $\phi_1 = -0.7$ e $\theta_1 = -0.4$

ACF

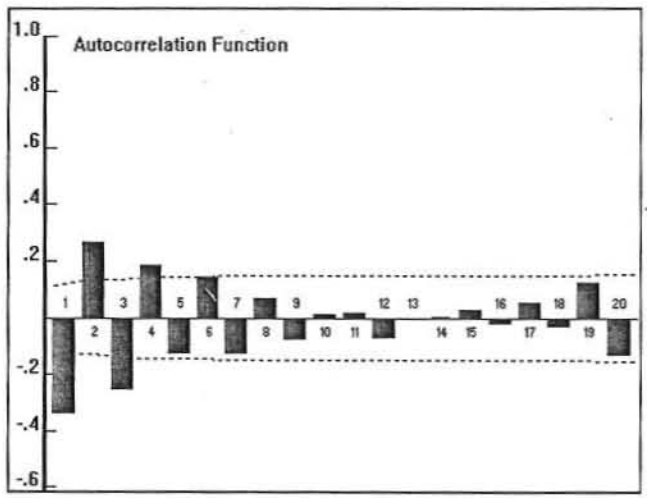

PACF

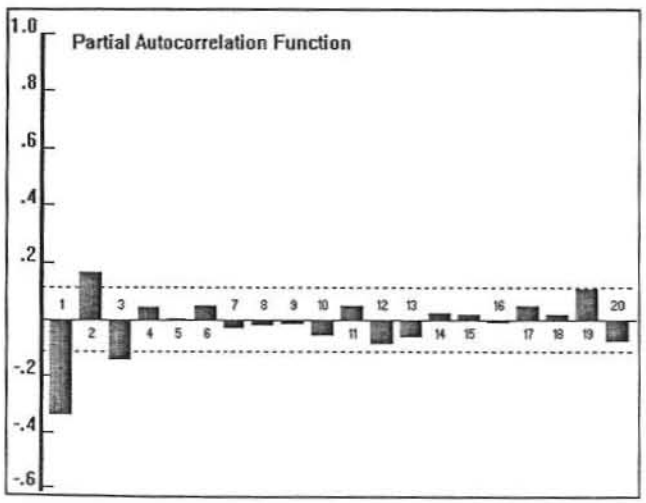

Exemplo 5.4.41. Modelo ARMA(1,1) com $\phi_1 = -0.7$ e $\theta_1 = +0.4$

300 observações de um processo ARMA(1,1) com $\phi_1 = -0.7$ e $\theta_1 = +0.4$

ACF

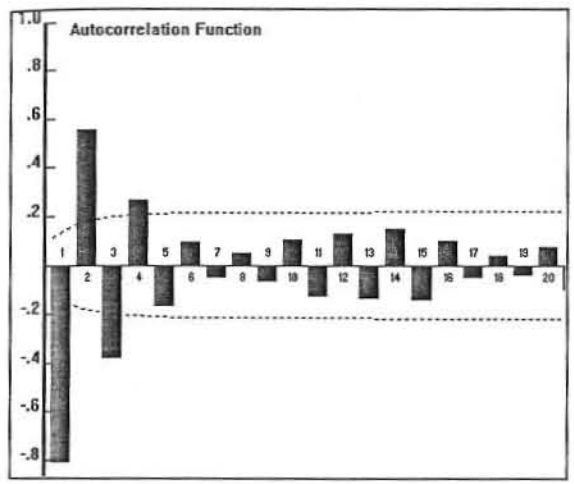

PACF

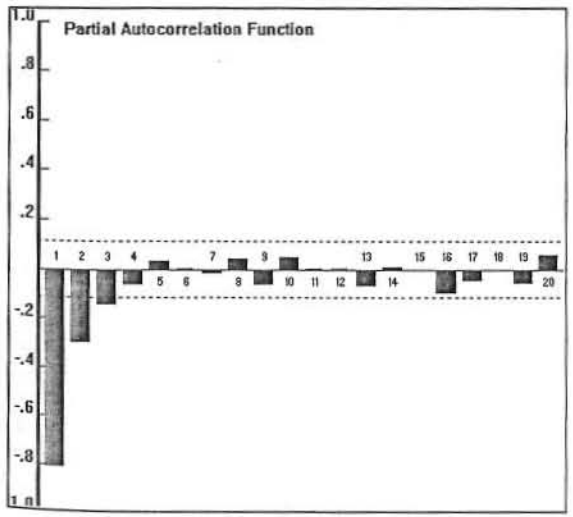

Modelos ARIMA(p,d,q)

Na prática estaremos freqüentemente interessados em modelar séries não estacionárias na média, isto é, séries que exibem uma tendência. A metodologia ARMA pode ser estendida para lidar com certo tipo de séries não estacionárias, conhecidas na literatura como "NÃO-ESTACIONÁRIA HOMOGÊNEA", conforme ilustrado a seguir:

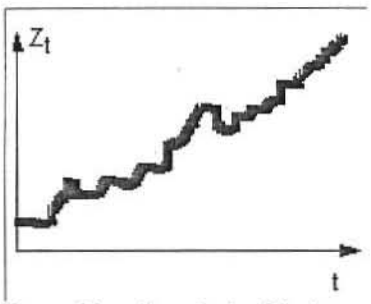

Uma série não-estacionária homogênea pode se tornar estacionária através da aplicação de diferenças sucessivas, como definido a seguir.

Definição 5.4.42. Operador Diferença

Seja Z_t uma série qualquer. O operador diferença aplicado a esta série é: $\nabla Z_t = (1\text{-}B) Z_t = Z_t - Z_{t-1}$.

A série diferenciada é $w_t = Z_t - Z_{t-1}$. $\nabla = (1\text{-}B)$ é conhecido como **operador diferença.**

Se w_t ainda não é estacionário, tenta-se uma outra diferença:

$$Y_t = w_t - w_{t-1} = (1 - B)w_t = (1 - B)^2 Z_t = \nabla^2 Z_t$$

Em geral, deve-se aplicar tantas diferenças quanto necessário até produzir uma série estacionária na média (isto é, com nível constante). Genericamente, a série w_t estacionária é obtida pela aplicação de "d" (d = 0, 1, 2...) diferenças na série original:

$$\boxed{w_t = \nabla^d Z_t}$$

Em seguida, modela-se a série estacionária w_t usando a modelagem ARMA(p,q) já estudada. Neste caso diz-se que a série original (não estacionária) Z_t segue um modelo ARIMA(p,d,q). ARIMA, em inglês, significa "Autoregressive **Integrated** Moving Average" e o termo "Integrated" refere-se às d diferenças necessárias para tornar a série original estacionária. O parâmetro d na notação ARIMA(p,d,q) indica o grau de diferenciação da série original e p, q são, como sempre, os graus dos polinômios AR e MA respectivamente.

Exemplo 5.4.43. Modelo ARIMA(0,1,0)

Neste caso, p = q = 0 e d = 1 e a estrutura do modelo é:

$$\nabla Z_t = a_t \Leftrightarrow Z_t - Z_{t-1} = a_t \Leftrightarrow Z_t = Z_{t-1} + a_t$$

Note que este é apenas o modelo **"random walk"** (passeio aleatório) descrito no capítulo 2 (note que é apenas um processo AR(1) não estacionário com parâmetro ϕ =1). As próximas figuras apresentam o gráfico de uma série random walk simulada (com tamanho T = 300) e sua ACF e PACF.

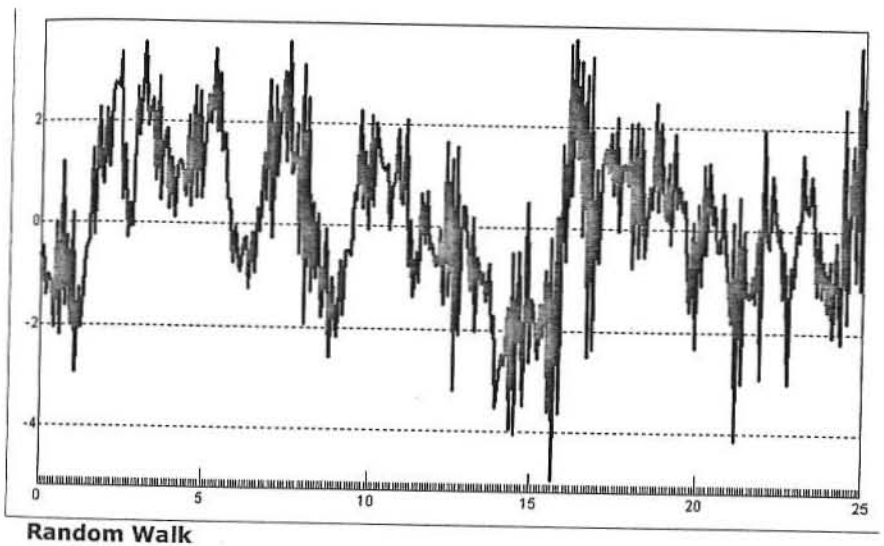

Random Walk

ACF

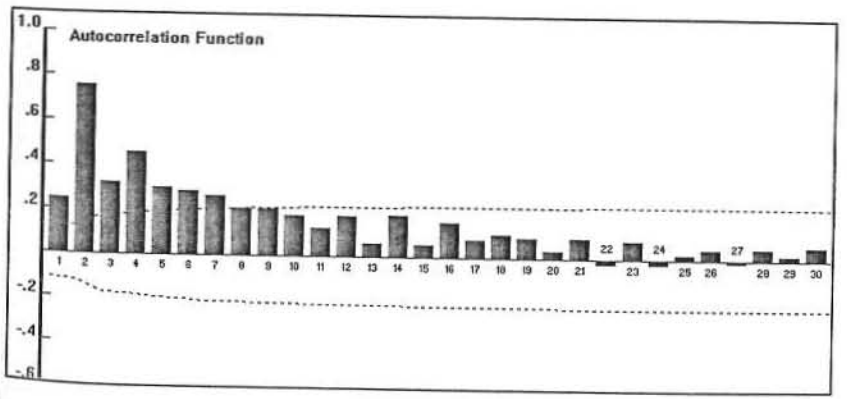

PACF

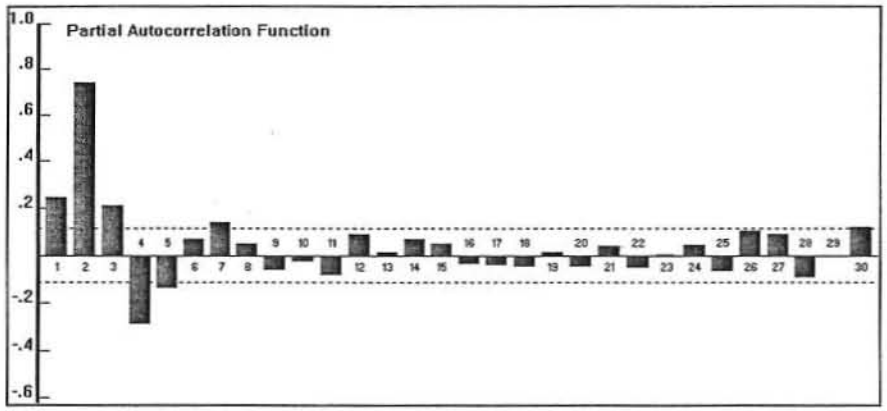

Exemplo 5.4.44. Modelo ARIMA(0,1,1)
Neste caso, p = 0, d = q = 1 e a estrutura do modelo é:

$$\nabla Z_t = (1-\theta_1 B)a_t \Leftrightarrow Z_t - Z_{t-1} = a_t - \theta_1 a_{t-1} \Leftrightarrow Z_t = Z_{t-1} + a_t - \theta_1 a_{t-1}$$

A seguir, exibimos uma série simulada a partir deste modelo (com $\theta_1 = 0.8$), e sua ACF e PACF (antes e depois da diferenciação).

Série Original

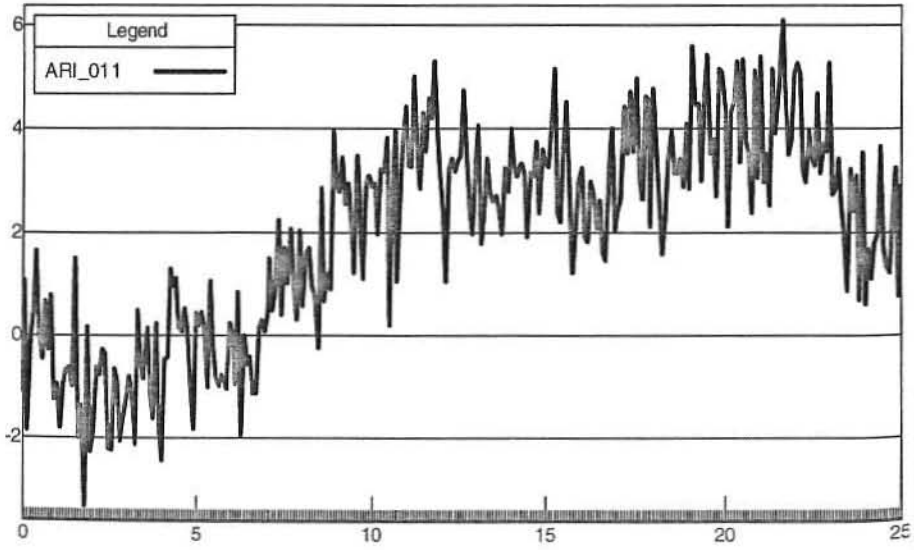

ACF e PACF da Série Original

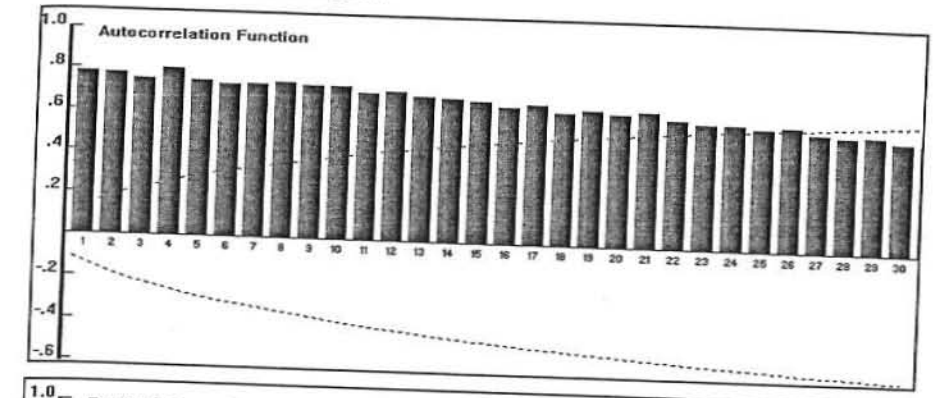

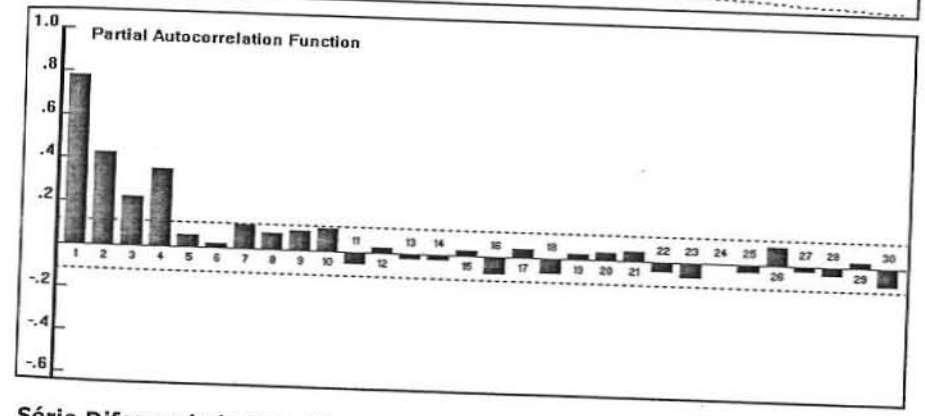

Série Diferenciada Uma Vez

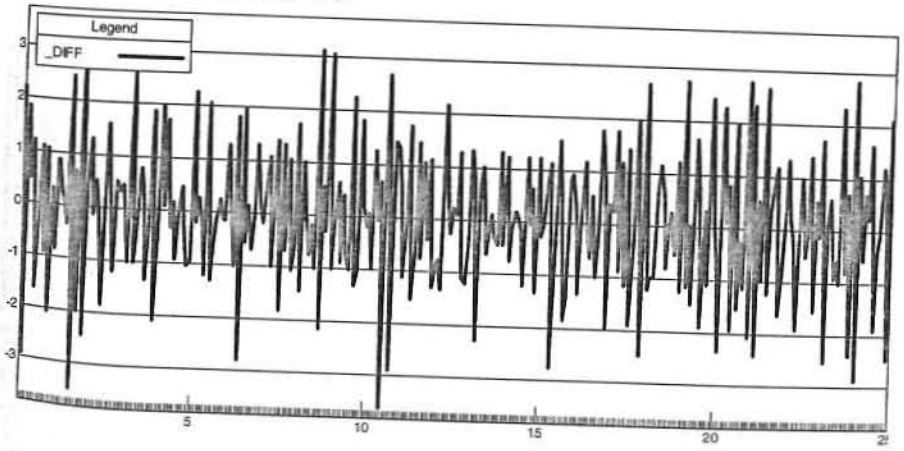

ACF e PACF da Série Diferenciada

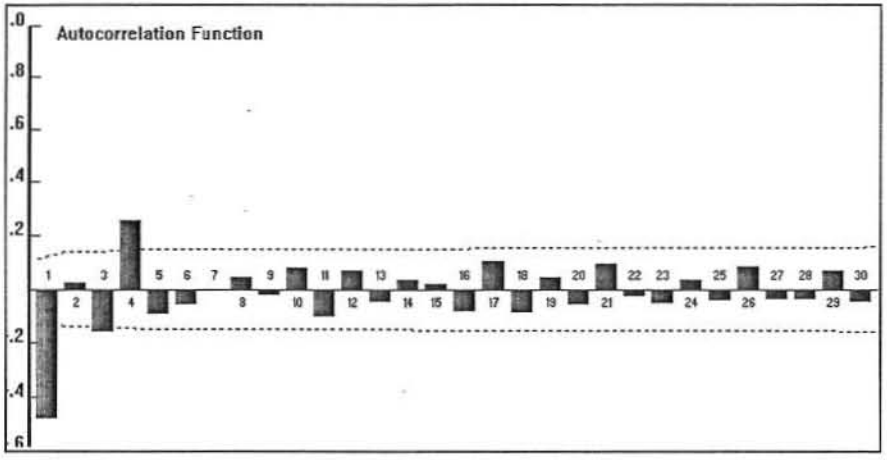

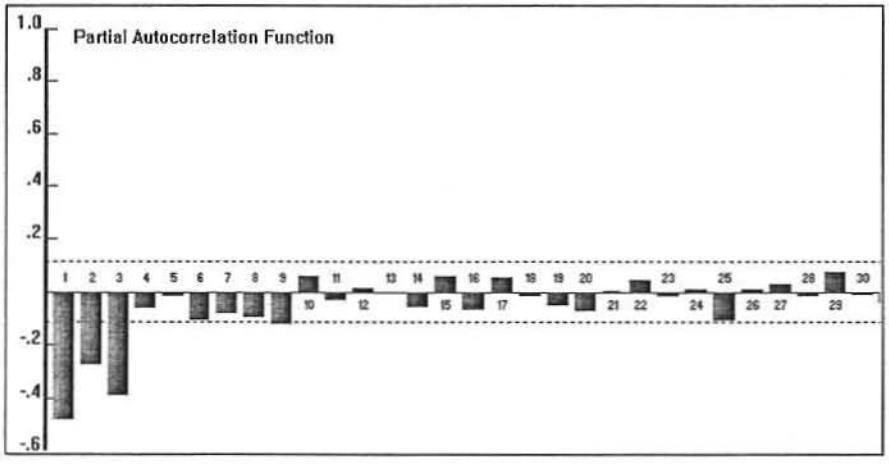

Note as "enormes" autocorrelações na série original, que justificam a diferenciação.

Exemplo 5.4.45. Modelo ARIMA(1,1,0)
Neste caso, p = d = 1 e q = 0 e a estrutura do modelo é:

$$(1-\phi_1 B)\underbrace{(1-B)Z_t}_{w_t} = a_t$$

$$[1-(1+\phi_1)B+\phi_1 B^2]Z_t = a_t$$

$$Z_t = (1+\phi_1)Z_{t-1} - \phi_1 Z_{t-2} + a_t$$

A seguir, exibimos o gráfico de uma série simulada com ϕ_1=+0.8, sua autocorrelação e a ACF e PACF para a série diferenciada.

Gráfico da Série Original

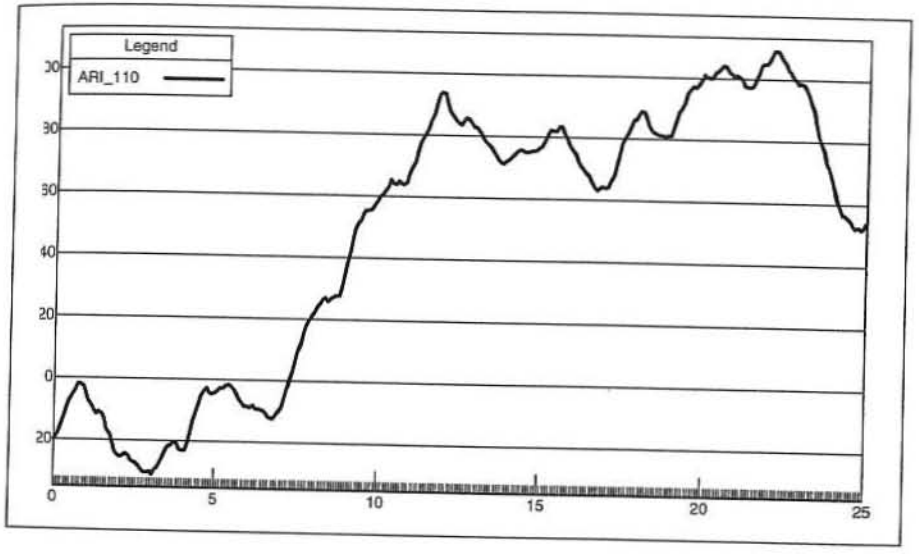

ACF da Série Original

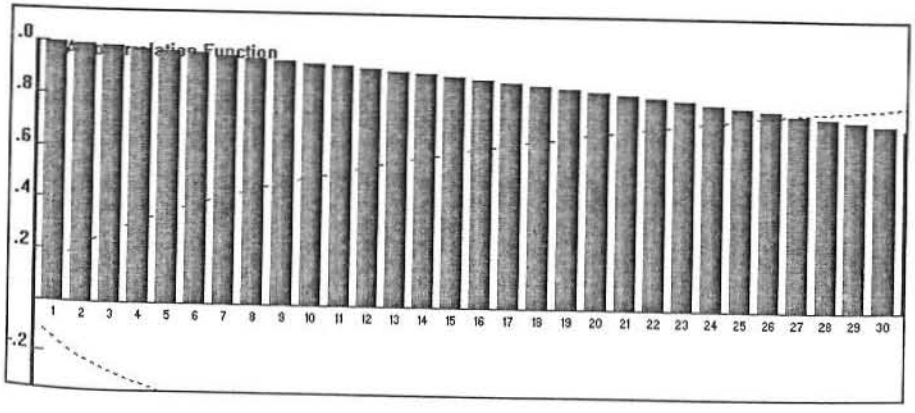

Gráfico da Série Diferenciada

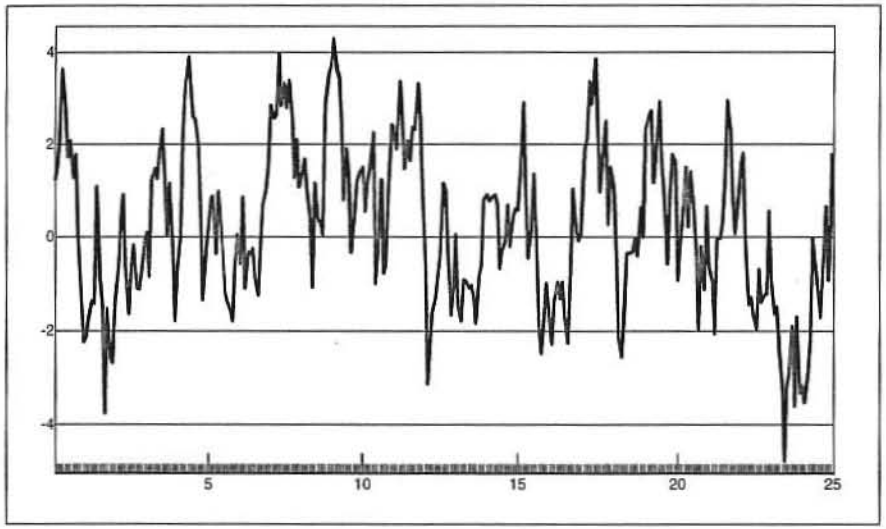

ACF e PACF da Série Diferenciada

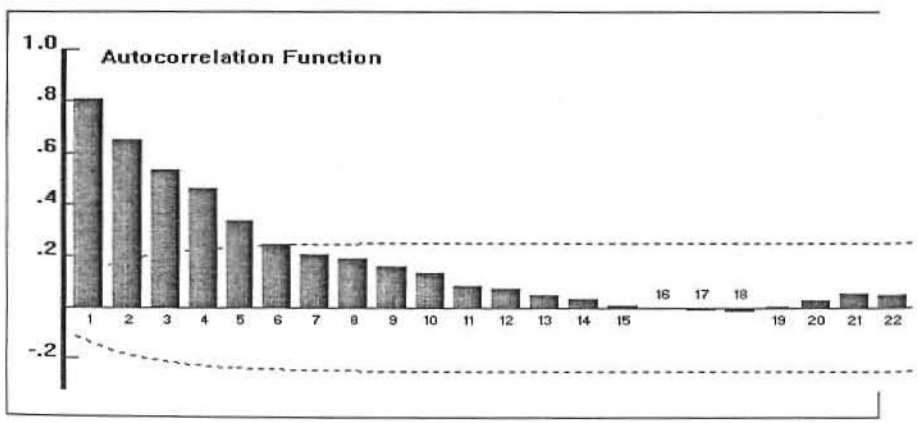

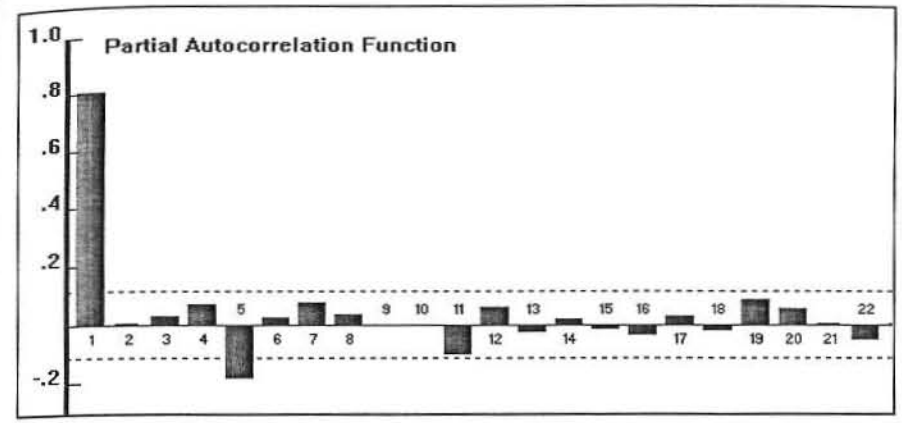

Exemplo 5.4.46. Modelo ARIMA(1,1,1)

Aqui p = d = q = 1 e a estrutura do modelo é:

$$(1-\phi_1 B)\underbrace{(1-B)Z_t}_{w_t} = (1-\theta_1 B)a_t$$

$$[1-(1+\phi_1)B+\phi_1 B^2]Z_t = (1-\theta_1 B)a_t$$

$$Z_t = (1+\phi_1)Z_{t-1} - \phi_1 Z_{t-2} + a_t - \theta_1 . a_{t-1}$$

Notas:

A aplicação do operador diferença d vezes (i.e. ∇^d) equivale a considerar "d" zeros no círculo unitário na parte AR do modelo, já que $\nabla = 1 - B$.

Uma extensão dos modelos ARIMA tradicionais consiste em considerar d como fracionário (por exemplo, d = 0.5; 0.2; - 0.3 etc..), o que dá origem aos modelos conhecidos como "**fracionais**" ou de "**memória longa**".

Deve-se notar que $\nabla^d = (1-B)^d$ é diferente de $(1-B^d) = Z_t - Z_{t-d}$.

O diagrama a seguir exibe os passos necessários para o ajuste de modelos ARIMA de Box e Jenkins.

METODOLOGIA BOX & JENKINS

Fluxograma Operacional

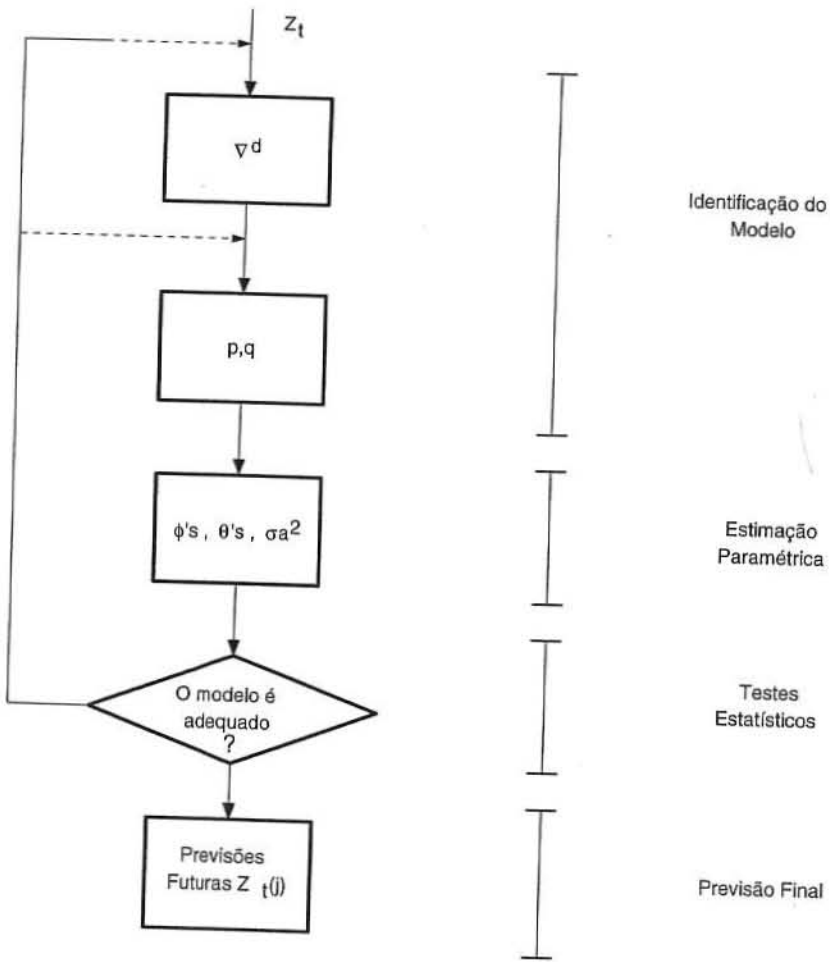

A seguir, descrevemos os passos necessários na implementação da metodologia.

Passo 1 – Identificação

Diferencia-se a série original Z_t até encontrar uma série com média constante. Note que, a princípio, as diferenciações sucessivas de Z_t não servem para "estacionarizar" séries não estacionárias na variância (por exemplo, como séries de retornos de ações).

Exemplo 5.4.47.

No gráfico a seguir, apresentamos uma série não estacionária, para a qual são necessárias duas diferenças até encontrar uma série estacionária.

Série Original

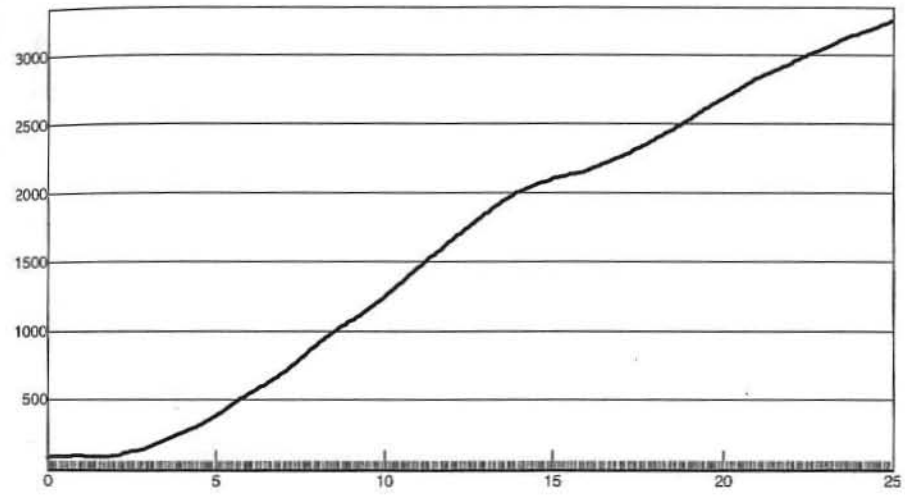

ACF da Série Original

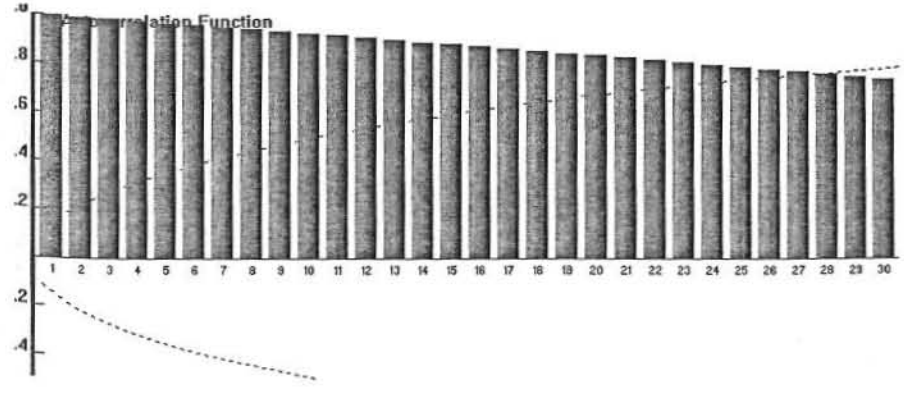

Gráfico da Primeira Diferença da Série

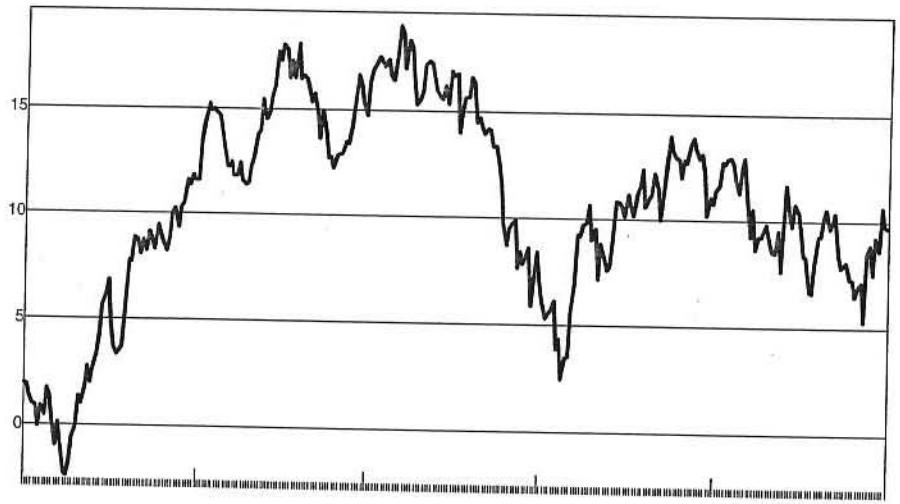

ACF da Série Diferenciada

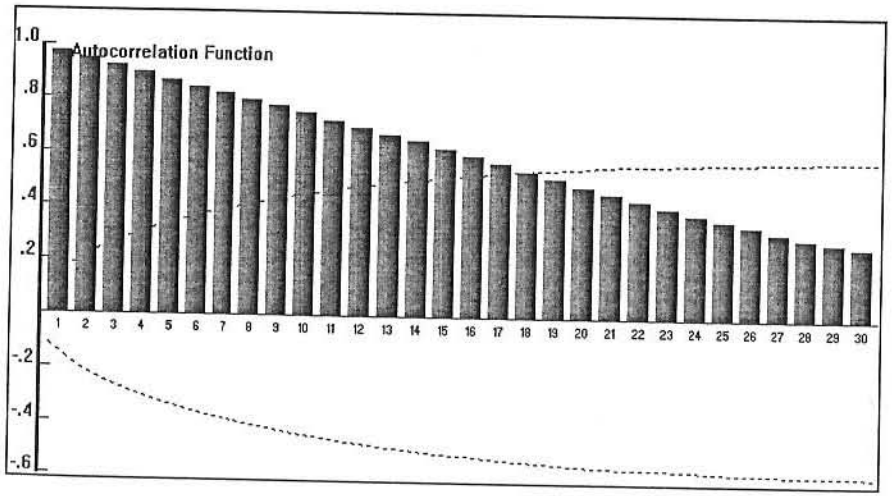

Note que as autocorrelações ainda permanecem muito grandes em lags altos, e portando uma nova diferenciação da série é necessária.

Gráfico da Segunda Diferença da Série

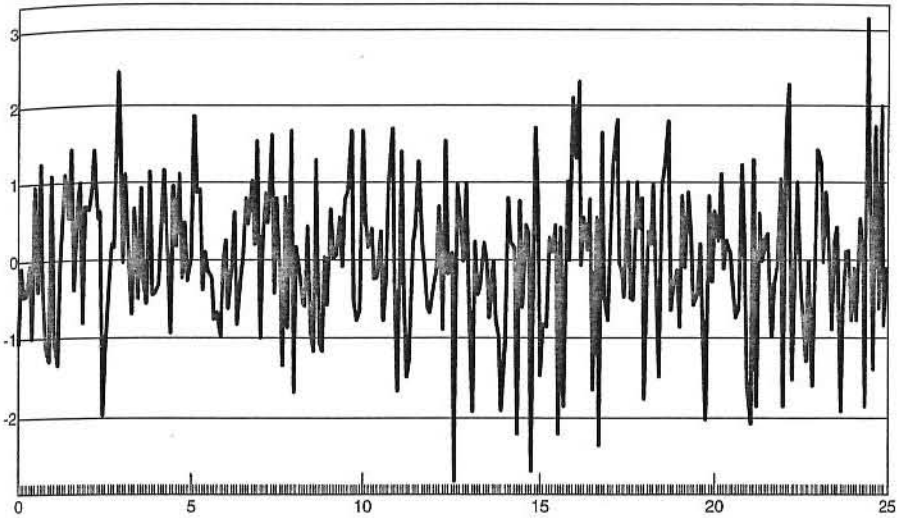

ACF da Série de Segunda Diferença

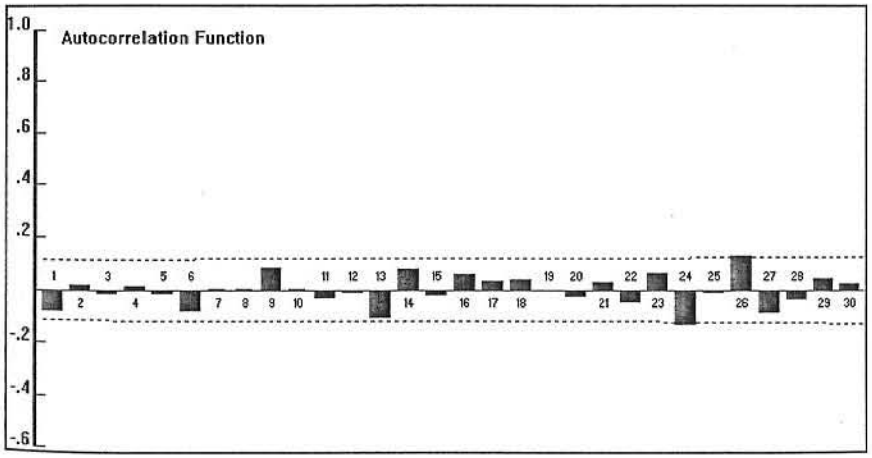

Atenção: no gráfico anterior, as autocorrelações da série de 2as. diferenças são todas zero, pois (por construção) a série de 2as. diferenças era apenas um ruído branco. Isso não é necessariamente verdade no caso geral, isto é, geralmente "sobram" autocorrelações e autocorrelações parciais não nulas na série após d diferenças; o que justificará o ajuste de um modelo ARMA a esta série diferenciada d vezes.

No passo de identificação de um modelo ARIMA (também chamado de *identificação estrutural*) procuramos encontrar procedimentos que permitem identificar a estrutura do modelo, isto é, conhecer os valores "p", "d" e "q" que caracterizam a estrutura do modelo ARIMA para a série temporal em estudo.

Um ponto importante na identificação do modelo ARIMA é **parcimônia**, ou seja, deve-se buscar o modelo com melhor ajuste e menor número possível de parâmetros. Em outras palavras, dados dois modelos com ajustes igualmente bons, escolha aquele com menor número de parâmetros. Existem duas justificativas para isso: i) simplicidade na estrutura identificada, o que permite uma melhor compreensão do processo subjacente e ii) em geral modelos superparametrizados são ruins em termos preditivos, pois se ajustam bem ao que acontece dentro da amostra mas não conseguem "generalizar" o comportamento da série.

Na verdade, o princípio da parcimônia é geral, e deve ser aplicado em qualquer problema de modelagem estatística, e não apenas na modelagem ARIMA.

O primeiro passo na identificação de um modelo ARIMA para representar uma série temporal é a escolha da ordem de diferenciação, ou seja, quantas diferenças são necessárias para transformar a série original numa série estacionária.

Em geral, o número correto de diferenças é a **menor** ordem de diferenciação tal que a série resultante flutue ao redor de um valor "médio" bem definido e cuja função de autocorrelação decaia a zero rapidamente. Se, após a diferenciação, o gráfico da ACF da série ainda exibir valores significantes em defasagens altas, é necessário diferenciar a série mais vezes.

Um modelo com d = 0 supõe que a série original é estacionária. Se a ordem de diferenciação é 1, a série original tem uma tendência constante, enquanto nos modelos em que d é maior ou igual a 2, a série original tem uma tendência variante no tempo.

O processo de diferenciação da série tende a introduzir correlações negativas. Se a série original exibe altas autocorrelações positivas, então uma diferença não sazonal irá reduzir as autocorrelações e talvez até levar a autocorrelação de lag 1 a ter um valor negativo. A aplicação de uma segunda diferença não sazonal muitas vezes torna a autocorrelação de lag 1 ainda mais negativa.

Deve-se tomar cuidado para não diferenciar a série original mais do que o necessário para torná-la estacionária. Alguns indícios de sobrediferenciação podem ser obtidos a partir da ACF ou do próprio gráfico da série. Uma série sobrediferenciada pode parecer aleatória à primeira vista, mas geralmente percebe-se a existência de alguns padrões suspeitos, por exemplo: autocorrelação de lag 1 "muito" negativa (entre −0.6 e −1), trocas de sinal entre

uma observação e a próxima, indicando a existência de um padrão repetitivo do tipo "para cima, para baixo; para cima, para baixo..."

(i) Identificação de "d"

Verifica-se pelo gráfico das séries diferenciadas $\nabla^d \underset{\sim}{Z}^t$; d = 0, 1, 2... o valor de "d" que "estacionarizou" (ou seja, "horizontalizou") a série.

(ii) Identificação de "p" e "q"

Feita através da comparação dos estimadores da ACF e PACF com os correspondentes padrões teóricos. Na prática, **raramente é necessário ajustar modelos com p e q maiores que 2**. Note que, num modelo ARMA(p,q) existem p + q + 1 parâmetros desconhecidos (os ϕ_i´s, os θ_j´s e a variância do erro, σ_a^2).

Passo 2 – Estimação dos parâmetros do modelo

Após a identificação do número de diferenças (d) e dos graus dos polinômios AR e MA (p e q, respectivamente), estima-se os parâmetros. Atualmente esta etapa não causa grande preocupação ao usuário "comum", pois é feita automaticamente pelos softwares especializados em séries temporais.

Suponha que a ordem (p, d, q) de um modelo ARIMA já foi identificada, isto é, já sabemos qual o grau de diferenciação (d) e os graus dos polinômios AR e MA. O próximo passo é estimar os parâmetros desconhecidos do modelo, isto é, encontrar os ϕ_i´s e θ_j´s.

Na estimação dos parâmetros desconhecidos procuramos minimizar a soma do quadrado dos erros, ou seja, no caso de uma ARIMA(p,d,q) buscamos minimizar: $S(\underset{\sim}{\xi}) = \sum_{t=1}^{T} a_t^2$ onde $a_t = \theta^{-1}(B).\phi(B).\nabla^d Z_t$

Por causa das defasagens presentes nos polinômios $\phi(B)$ e $\theta(B)$ é freqüentemente impossível calcular a soma do quadrado dos erros como descrita acima, pois ela dependeria de observações inexistentes (Z_0, Z_{-1}, Z_{-2}...). Box e Jenkins sugerem um procedimento conhecido como "backforecasting", que gera previsões para estes valores iniciais desconhecidos. Se supormos a normalidade dos erros podemos escrever a função de verossimilhança sem muita dificuldade, e proceder à estimação dos parâmetros por máxima verossimilhança. Os resultados obtidos pela aplicação deste método são equivalentes aos encontrados pela minimização da soma do quadrado dos erros. A estimação por máxima verossimilhança possui uma grande vantagem: a distribuição assintótica (quando T tende a infinito) dos estimadores é conhecida e pode-se encontrar facilmente o erro padrão destes estimadores, o que permite estabelecer a significância dos parâmetros.

Existem diferentes métodos para a estimação dos parâmetros do modelo, e em geral todos produzem estimativas semelhantes, mas podem existir diferenças quanto à eficiência de cada método de estimação. De maneira geral, durante a etapa de estimação de parâmetros usa-se algum algoritmo para minimização (ou maximização). Alguns dos possíveis métodos são: máxima verossimilhança aproximada, máxima verossimilhança aproximada com "backforecasting" e máxima verossimilhança exata. O primeiro é o mais rápido, e deve ser usado em séries muito longas (com mais de 30000 observações). O método de máxima verossimilhança exata não é eficiente para modelos sazonais quando o período sazonal é grande (por exemplo dados diários). De maneira geral os métodos aproximados servem pelo menos para produzir estimativas iniciais dos parâmetros de interesse e, em seguida, pode-se refinar estas estimativas através do método de máxima verossimilhança exata. As estimativas dos parâmetros são acompanhadas de seus erros padrão assintóticos, o que nos permite acessar a significância dos parâmetros estimados.

Passo 3 – Testes Estatísticos

Nesta etapa procuramos responder à questão: o modelo identificado é adequado e capaz de bem representar a série observada? Existem diversos testes para tentar responder a esta pergunta. A grande maioria dos testes baseia-se nos resíduos dos modelos.

Lembre-se que, ao ajustarmos um modelo ARIMA, estamos buscando capturar "toda" a estrutura de dependência serial presente na série. Logo, o que "sobra" (isto é, os resíduos do modelo) não deve apresentar qualquer tipo de dependência no tempo, pois se ainda existe dependência nos resíduos é sinal de que esta dependência deveria ter sido capturada e incorporada no modelo. Logo, num modelo ARIMA bem ajustado, os erros de previsão um passo à frente (os resíduos) devem ser uma seqüência de ruídos brancos, ou seja, **não devem** exibir autocorrelações (e autocorrelações parciais) significantes.

O que é um "bom" modelo?

Em geral, um bom modelo deve:

- Produzir previsões suficientemente próximas da realidade (mas não exatamente iguais aos valores observados!);
- Ter resíduos independentes com média zero e variância constante, e então o correlograma dos resíduos não deve revelar a existência de dependência serial;
- Ser parcimonioso, isto é, apresentar um número relativamente pequeno de parâmetros.

Testes de Sobrefixação

A idéia por trás dos testes de sobrefixação é ajustar um modelo "maior" (aumentando os graus dos polinômios AR e MA) para verificar se os parâmetros

extras são significantes. Por exemplo, se o modelo identificado é um MA(1) (ARIMA(0,0,1)) pode-se testar os modelos MA(2) e ARMA(1,1) e verificar se a inclusão dos novos parâmetros resultou em algum ganho adicional.

Critérios Baseados nos Resíduos do Modelo

Conforme já mencionado, num "bom" modelo, os resíduos não devem exibir qualquer estrutura de dependência. Em particular, a média dos resíduos deve ser zero e a variância deve ser constante. Também, a ACF não deve ser significante em qualquer "lag". A existência de autocorrelações nos resíduos sugere que o modelo não foi corretamente especificado.

Um teste muito usado para verificar a existência de autocorrelações nos resíduos é o **teste de Ljung e Box**, ou **teste Portmanteau**, descrito a seguir.

No teste de Ljung e Box desejamos testar a hipótese de que as k primeiras autocorrelações dos resíduos são nulas, isto é: H_0: $\rho_1^{(a)} = \rho_2^{(a)} = \ldots = \rho_k^{(a)} = 0$ onde os $\rho_i^{(a)}$ são as autocorrelações dos resíduos.

A estatística do teste é:

$$Q = T(T+2).\sum_{i=1}^{k} \frac{\hat{\rho}_i^{(a)2}}{(T-i)}$$

onde T é o tamanho da série. A regra de decisão deste teste é: se o valor da estatística Q for grande rejeita-se a hipótese de que as k primeiras autocorrelações dos resíduos sejam nulas. Mas, quão grande Q deve ser? Deve-se compará-lo aos pontos percentuais de uma variável Qui-Quadrado com k – (p+q+1) graus de liberdade, onde k é o número de autocorrelações sendo testadas e p e q são os graus dos polinômios AR e MA respectivamente.

Quantas autocorrelações devem ser testadas em conjunto, isto é, qual o valor de k? Uma escolha usual é fazer k aproximadamente igual a $\sqrt{T}$, onde T é o tamanho da série.

Critérios de Seleção de Modelos

Estes critérios permitem a comparação de diferentes modelos para a série, e a conseqüente escolha do "melhor" modelo. Este é o que minimiza a variância dos resíduos e, simultaneamente, sofre uma penalidade pela inclusão de mais parâmetros. Note que esta penalização pelo número de parâmetros é coerente com o princípio da parcimônia pois, em geral a inclusão de mais parâmetros leva a uma melhora do ajuste do modelo, mas paga-se um preço, que é o próprio excesso na parametrização. Os principais critérios são:

Critério de Akaike (ou AIC, AKAIKE INFORMATION CRITERION)

Se "m" é o número de parâmetros do modelo estimado, o critério de AKAIKE estabelece que o modelo ótimo para uma mesma série é aquele que minimiza a quantidade AIC, dada por:

$$AIC = T.\left(\log\left(\hat{\sigma}_a^2 \right) \right) + 2.\ m$$

O critério AIC tende a superestimar a ordem do polinômio AR, o que motivou a criação do critério BIC mostrado a seguir.

Critério BIC (BAYESIAN INFORMATION CRITERION)

É um refinamento do critério AIC em que se procura contornar um problema existente no AIC, que é, a tendência a escolher modelos com polinômio AR de grau alto. O preço pago é a maior complexidade na fórmula do cálculo da estatística.

$$BIC = T.\left(\log\left(\hat{\sigma}_a^2 \right) \right) - (T-m).\log\left(1 - \frac{m}{T} \right) + m.\ \log(T) + m.\ \log\left[\frac{\left(\frac{\hat{\sigma}_z^2}{\hat{\sigma}_a^2} - 1 \right)}{m} \right]$$

CRITÉRIO DE SCHWARTZ (SBC CRITERION)

Foi sugerido por Schwartz em 1978, e é uma simplificação do critério BIC acima, que tem a mesma eficiência no que diz respeito à superestimação de p pelo critério AIC. É dado por:

$$SBC = T.\left(\log\left(\hat{\sigma}_a^2 \right) \right) + m.\ \log(T)$$

Note que, nem sempre os três critérios irão concordar quanto ao "melhor" modelo dentro de uma classe de modelos em consideração, mas em geral as diferenças entre os resultados dos três critérios serão pequenas.

Exemplo 5.4.48.

Considere novamente a série de consumo anual de energia elétrica (classe comercial) do Exemplo 5.2.5.. Iremos ajustar um modelo da classe ARIMA a esta série, e comparar as previsões obtidas com as encontradas pelo modelo de Holt.

A autocorrelação e PACF da série original são:

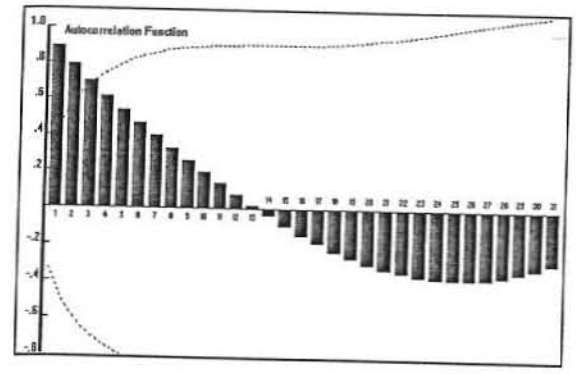

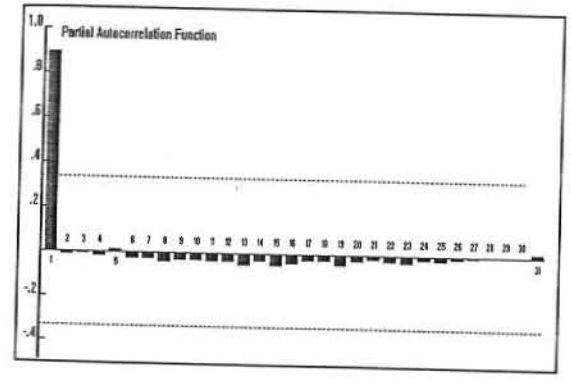

Após uma diferença, a ACF e PACF tornam-se:

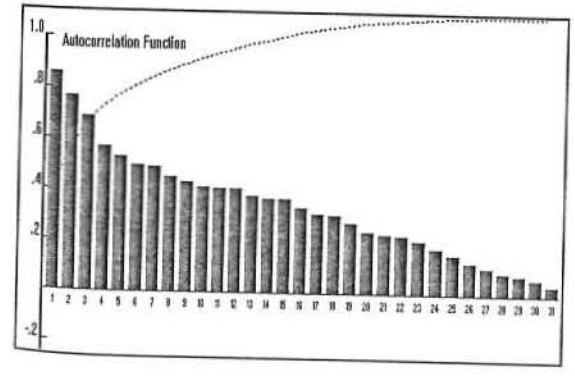

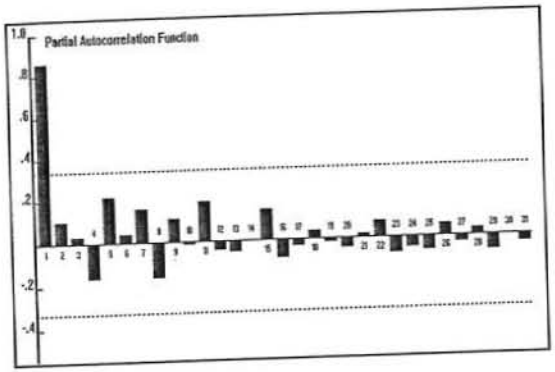

E após duas diferenças:

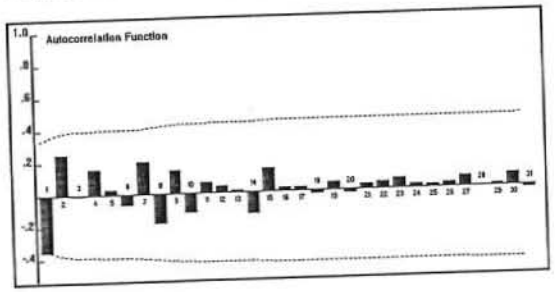

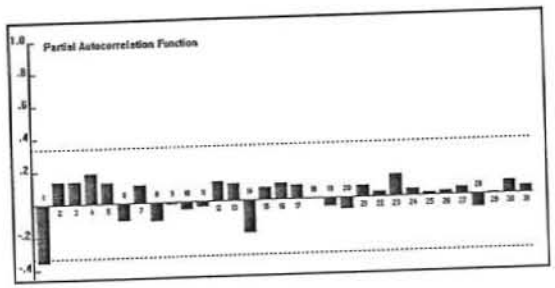

Nitidamente foram necessárias duas diferenças da série original para torná-la estacionária, pois após uma única diferenciação a autocorrelação ainda decaía de forma muito lenta. Logo, deve-se partir de um modelo ARIMA com d = 2, e resta agora identificar p e q, as ordens dos polinômios AR e MA respectivamente.

O gráfico da autocorrelação parcial (da série duplamente diferenciada) sugere que a ordem p =1 deve ser apropriada. Testamos as estruturas ARIMA(1,2,0) e ARIMA(1,2,1) (teste de sobrefixação) e nesta última o coeficiente do termo MA

não foi significante, portanto a estrutura escolhida é a ARIMA (1,2,0), com as características mostradas a seguir.

Termo	Coeficiente	Erro Padrão	Estatística t	Significância
AR(1)	-0.366	0.160	-2.287	97.1%

As previsões encontradas a partir deste modelo são:

Ano	Limite Inferior Previsão (2.5%)	Previsão	Limite Superior Previsão (97.5%)	Valor Real	Erro Percentual Absoluto de Previsão
1999	44,277	45,066	45,855	43,583	3.4%
2000	47,042	48,553	50,065	47,365	2.5%
2001	49,605	52,029	54,452		
2002	52,053	55,508	58,963		

As previsões são bastante semelhantes às produzidas pelo método de Holt, mas os intervalos de confiança são mais estreitos que os do exemplo 5.2.5.

Passo 4 – Previsão

As previsões j passos à frente são obtidas diretamente a partir da equação do modelo ARIMA escolhido nos passos anteriores.

Seja $Z_t(j)$ a previsão de Z_{t+j} obtida no instante t. A equação de previsão é apenas a equação obtida da própria expressão do modelo para Z_t, escrita para o instante de interesse t + j.

A idéia por trás das previsões é substituir os z's e a's por suas médias condicionais, ou seja, as médias dada a série já observada $z_1, z_2..., z_{t-1}, z_t$.

As médias condicionais são:

$$E(a_{t+j}|z_t, z_{t-1}, z_{t-2}, \ldots, z_1) = \begin{cases} a_{t+j} & \text{se } j = \ldots, -3, -2, -1, 0 \\ 0 & \text{se } j = 1, 2, 3, \ldots. \end{cases}$$

$$E(z_{t+j}|z_t, z_{t-1}, z_{t-2}, \ldots, z_1) = \begin{cases} z_{t+j} & \text{se } j = \ldots, -3, -2, -1, 0 \\ \hat{z}_{t+j} & \text{se } j = 1, 2, 3, \ldots. \end{cases}$$

Ou seja, para encontrarmos as previsões basta:
1) Substituir os valores esperados passados da série pelos valores efetivamente observados da série (isto é, os z_{t+j} com j negativo);
2) Substituir os valores esperados futuros da série pelas suas previsões (ou seja, os $\hat{z}_{t+j}$);

3) Substituir os valores esperados futuros dos erros por zero;
4) Substituir os valores passados dos erros a_{t-j} por $z_{t-j} - z_{t-j-1}$.

Exemplos deste procedimento são mostrados a seguir.

Exemplo 5.4.49. Previsão no Modelo AR(1)
Considere o modelo AR(1):

$Z_t - \phi_1.Z_{t-1} = a_t$

A equação do modelo escrita para o instante t +j é:

$Z_{t+j} - \phi_1.Z_{t-+j1} = a_{t+j}$

A previsão de Z_{t+j} feita no instante t é:

$$\hat{Z}_t(j) = \phi_1.E(Z_{t+j-1}|Z_1, Z_2, \ldots, Z_t) + E(a_{t+j}|Z_1, Z_2, \ldots, Z_t)$$

Para j = 1 (previsão um passo à frente) temos:

$$\hat{Z}_t(1) = \phi_1.E(Z_t|Z_1, Z_2, \ldots, Z_t) + E(a_{t+1}|Z_1, Z_2, \ldots, Z_t) = \phi_1.Z_t + 0 = \phi_1.Z_t$$

Para j = 2 (previsão dois passos à frente feita no instante t):

$$\hat{Z}_t(2) = \phi_1.E(Z_{t+1}|Z_1, Z_2, \ldots, Z_t) + E(a_{t+2}|Z_1, Z_2, \ldots, Z_t) =$$
$$\phi_1.\hat{Z}_t(1) + 0 = \phi_1(\phi_1.Z_t) = \phi_1^2.Z_t$$

Em geral, a previsão j passos à frente é:
$\hat{Z}_t(j) = \phi_1^j.Z_t$ e como o processo é suposto estacionário (e então $|\phi_1| < 1$) esta previsão tende à zero à medida que o horizonte de previsão aumenta. Note também que zero é a média do processo, e assim as previsões em horizontes longos tenderão à média.

Exemplo 5.4.50. Previsão no Modelo MA(1)
Considere o processo MA(1) dado por:

$Z_t = a_t - \theta_1.a_{t-1}$

A equação do modelo aplicada ao instante t +j fornece:

$Z_{t+j} = a_{t+j} - \theta_1.a_{t-+j-1}$

A previsão j passos à frente é dada por:

$$\hat{Z}_t(j) = E(a_{t+j}|Z_1, Z_2, \ldots, Z_t) - \theta_1.E(a_{t+j-1}|Z_1, Z_2, \ldots, Z_t)$$

Para j = 1 temos:

$$\hat{Z}_t(1) = E(a_{t+1}|Z_1, Z_2, \ldots, Z_t) - \theta_1.E(a_t|Z_1, Z_2, \ldots, Z_t) =$$
$$0 - \theta_1.(Z_t - Z_{t-1}) = -\theta_1.(Z_t - Z_{t-1})$$

Para j = 2:

$$\hat{Z}_t(2) = E(a_{t+2}|Z_1, Z_2, \ldots, Z_t) - \theta_1.E(a_{t+1}|Z_1, Z_2, \ldots, Z_t) = 0 - \theta_1.0 = 0$$

Em geral, para j ≥ 2 a previsão será zero (que é a média do processo), pois o processo tem memória de dois períodos apenas, e a equação de previsão dependerá de $E(a_{t+j}|Z_1, Z_2, \ldots, Z_t)$, que é zero para j ≥1.

Exemplo 5.4.51. Previsão para o ARIMA (1,1,1)
Considere o modelo ARIMA(1,1,1) aplicado a Z_t. A equação do modelo é:

$$(1 - \phi_1 B)(1 - B)Z_t = (1 - \theta_1 B)a_t$$
$$[1 - (1 + \phi_1)B + \phi_1 B^2]Z_t = (1 - \theta_1 B)a_t$$
$$Z_t = (1 + \phi_1)Z_{t-1} + \phi_1 Z_{t-2} + a_t - \theta_1 a_{t-1}$$

No instante t + j teremos:

$$Z_{t+j} = (1 + \phi_1)Z_{t+j-1} + \phi_1 Z_{t+j-2} + a_{t+j} - \theta_1 a_{t+j-1}$$

A previsão j passos à frente é dada por:

$$Z_t(j) = (1 + \phi_1)\, E\left(Z_{t+j-1} \mid Z_1, Z_2, \ldots Z_t\right) + \phi_1 E\left(Z_{t+j-2} \mid Z_1, Z_2, \ldots Z_t\right) +$$
$$+ E\left(a_{t+j} \mid Z_1, Z_2, \ldots Z_t\right) - \theta_1 E\left(a_{t+j-1} \mid Z_1, Z_2, \ldots Z_t\right)$$

Assim, a previsão 1 passo à frente é:

$$Z_t(1) = (1 + \phi_1)Z_t + \phi_1 Z_{t-1} - \theta_1(Z_t - Z_{t-1})$$

A previsão 2 passos à frente é (lembre-se que o valor esperado condicional dos erros futuros é zero):

$$Z_t(2) = (1 + \phi_1)Z_t(1) + \phi_1 Z_t$$

E, em geral, a previsão j passos à frente (para j > 2) é:

$$Z_t(j) = (1 + \phi_1)Z_t(j-1) + \phi_1 Z_t(j-2)$$

5.5. Exercícios

Problema 1
Considere o modelo constante: $Z_t = \mu + \varepsilon_t$ onde t = 1,2..., T.
Suponha que o nível da série é estimado através de uma média móvel de tamanho 4. Suponha também que, num instante genérico t observamos: Z_t = 20, Z_{t-1} = 18, Z_{t-2} = 21, Z_{t-3} = 16. Encontre:
a) A previsão para os instantes t +1 e t+2.
b) Se Z_{t+1} = 19 encontre a previsão atualizada para os instantes t + 2 e t +3.

Problema 2
Considere a seguinte série temporal com 10 valores observados:

16,80
12,89
18,98
23,11
22,79
24,93
9,27
17,06
22,38
13,65

Suponha um modelo constante. Encontre:

a) As previsões 1 passo à frente usando o modelo naive.
b) As previsões 1 passo à frente usando uma média móvel com 3 observações. Inicie as previsões em t = 3.
c) As previsões 1 passo à frente usando amortecimento exponencial com constante de amortecimento $\alpha = 0.2$.
d) As previsões 1 passo à frente usando amortecimento exponencial com constante de amortecimento $\alpha = 0.1$.
e) As previsões 1 passo à frente usando amortecimento exponencial com constante de amortecimento $\alpha = 0.8$.
f) Em todos os casos acima calcule a raiz do erro quadrático médio (root mean squared error, ou RMSE) definido como:

$$RMSE = \sqrt{\sum_{t=0}^{9}\left(\hat{Z}_{t+1}(1) - Z_{t+1}\right)^2} \quad \text{onde } \hat{Z}_{t+1}(1) \text{ é a previsão 1 passo à frente de } Z_{t+1}.$$

Suponha, neste cálculo, que Z_0 (valor inicial da série) é 17. Qual dos modelos exibe o menor RMSE?

Problema 3
Suponha o modelo constante. Qual a razão entre os pesos das 6 observações mais recentes (t = T, T −1..., T − 5) e os pesos das seis observações anteriores (t = T −6... T − 11) quando:

a) A constante de amortecimento é $\alpha = 0.1$.
b) A constante de amortecimento é $\alpha = 0.3$.
c) A constante de amortecimento é $\alpha = 0.1$.

Problema 4
Suponha que uma série temporal segue o modelo linear puramente determinístico (não está sujeito a erros aleatórios) $Z_t = 40 + 20.t$.

a) Use o método de amortecimento exponencial com $\alpha = 0.1$ e valor inicial $Z_0 = 40$ para prever os 15 primeiros períodos.
b) Repita o item a) com $\alpha = 0.4$.
c) Faça o gráfico da série e das previsões um passo à frente geradas pelos dois métodos.
d) O que você conclui a respeito da capacidade do modelo de amortecimento exponencial em acompanhar a tendência claramente linear neste caso? O que acontece se aumentamos o valor da constante de amortecimento?

Problema 5
Suponha que uma série temporal segue o modelo linear puramente deteminístico $Z_t = 40 + 20.t$.

a) Use o método de médias móveis duplas de tamanho 3 com valor inicial $Z_0 = 40$ para prever os 15 primeiros períodos.
b) Use o método de médias móveis duplas de tamanho 5 com valor inicial $Z_0 = 40$ para prever os 15 primeiros períodos.
c) Repita o item a) usando o método de Brown com constante de amortecimento $\alpha = 0.1$.
d) Repita o item a) usando o método de Brown com constante de amortecimento $\alpha = 0.4$.
e) Repita o item a) usando o método de Holt com constantes de amortecimento $\alpha = 0.1$ e $\beta = 0.1$.
f) Repita o item a) usando o método de Holt com constantes de amortecimento $\alpha = 0.4$ e $\beta = 0.1$.
g) Repita o item a) usando o método de Holt com constantes de amortecimento $\alpha = 0.1$ e $\beta = 0.2$.
h) Repita o item a) usando o método de Holt com constantes de amortecimento $\alpha = 0.4$ e $\beta = 0.2$.
i) Faça o gráfico da série e das previsões um passo à frente geradas pelos métodos nos itens a) a h).
j) Calcule o RMSE (vide problema 2) para os erros de previsão gerados em cada um dos métodos. Qual método apresenta menor RMSE?

Problema 6
A renda per capita em certo país evolui anualmente como mostrado na tabela abaixo.

t	Renda(t)	t	Renda(t)	t	Renda(t)
1	3977,86	11	4421,15	21	4797,75
2	4078,06	12	4436,03	22	4822,18
3	4119,37	13	4483,05	23	4853,75
4	4149,46	14	4520,14	24	4900,30
5	4212,47	15	4584,66	25	4946,89
6	4215,16	16	4609,69	26	4989,29
7	4281,42	17	4661,44	27	5037,10
8	4331,80	18	4702,02	28	5077,57
9	4336,69	19	4739,91	29	5110,67
10	4390,65	20	4766,80	30	5140,09

a) Faça o gráfico da série ao longo do tempo.
b) Use o método de médias móveis duplas de tamanho 3 com valor inicial Z_0 = 3950 para prever os 15 primeiros períodos.
c) Use o método de médias móveis duplas de tamanho 5 com valor inicial Z_0 = 3950 para prever os 15 primeiros períodos.
d) Repita o item b) usando o método de Brown com constante de amortecimento α =0.15.
e) Repita o item b) usando o método de Brown com constante de amortecimento α =0.45.
f) Repita o item b) usando o método de Holt com constantes de amortecimento α =0.15 e β = 0.1.
g) Repita o item b) usando o método de Holt com constantes de amortecimento α =0.45 e β = 0.1.
h) Repita o item b) usando o método de Holt com constantes de amortecimento α =0.15 e β = 0.25.
i) Repita o item b) usando o método de Holt com constantes de amortecimento α =0.45 e β = 0.25.
j) Faça o gráfico da série e das previsões um passo à frente geradas pelos métodos nos itens b) a i).
k) Calcule o RMSE para os erros de previsão gerados em cada um dos métodos. Qual método apresenta menor RMSE?

Problema 7
O consumo médio de energia (em kWh) de uma família de classe média evolui como mostrado na próxima tabela.

Instante	Consumo	Instante	Consumo	Instante	Consumo
1	283,67	11	513,08	21	673,65
2	418,13	12	458,80	22	662,22
3	371,71	13	558,60	23	670,47
4	372,81	14	555,39	24	673,22
5	404,48	15	568,06	25	727,87
6	410,78	16	534,92	26	750,61
7	392,99	17	608,91	27	729,26
8	501,85	18	604,00	28	735,58
9	501,44	19	553,90	29	719,51
10	503,10	20	627,71	30	735,61

a) Faça o gráfico da série ao longo do tempo.
b) Use o método de médias móveis duplas de tamanho 4 com valor inicial Z_0 = 350 para prever os 15 primeiros períodos.
c) Use o método de médias móveis duplas de tamanho 6 com valor inicial Z_0 = 350 para prever os 15 primeiros períodos.
d) Repita o item b) usando o método de Brown com constante de amortecimento α =0.2.
e) Repita o item b) usando o método de Brown com constante de amortecimento α =0.5.

f) Repita o item b) usando o método de Holt com constantes de amortecimento α =0.2 e β = 0.1.
g) Repita o item b) usando o método de Holt com constantes de amortecimento α =0.5 e β = 0.1.
h) Repita o item b) usando o método de Holt com constantes de amortecimento α =0.2 e β = 0.3.
i) Repita o item b) usando o método de Holt com constantes de amortecimento α =0.5 e β = 0.3.
j) Faça o gráfico da série e das previsões um passo à frente geradas pelos métodos nos itens b) a i).
k) Calcule o RMSE para os erros de previsão gerados em cada um dos métodos. Qual método apresenta menor RMSE?
l) Calcule as previsões 1 e 2 passos à frente nos instantes 28, 29 e 30 usando todos os métodos.

Problema 8
A série mensal de temperaturas máximas num certa estação meteorológica no Rio de Janeiro no período janeiro de 1982 a dezembro de 1991 está no arquivo **dados_cap_5_problema_8.xls**.
a) Ajuste um modelo de Holt-Winters com tendência constante e comente sobre os resultados encontrados.
b) Faça as previsões da temperatura para o período entre janeiro e dezembro de 1992.
c) Utilizando a série apenas até dezembro de 1990, faça as previsões para o ano de 1991 e compare-as com os valores observados. Calcule o erro quadrático médio, usando o somatório dos quadrados dos desvios entre os valores reais e as previsões (encontradas usando como última observação o mês de dezembro de 1990, ou seja, a previsão para dezembro de 1991 é uma previsão 12 passos à frente).
d) Repita o item c) calculando o RMSE baseado nas previsões um passo à frente. Note que será necessário "rodar" o modelo 12 vezes (com o final da série em dezembro de 1990, em janeiro de 1991..., em novembro de 1991). Compute o erro quadrático médio e verifique se houve redução substancial em relação ao RMSE calculado no item c) acima.
e) Faça um gráfico dos fatores sazonais estimados no modelo do item b).
f) Altere as constantes de amortecimento estimadas no modelo do item b), arrendondando-as para a próxima casa decimal. Ajuste o modelo com as novas constantes de amortecimento. Como o BIC e o AIC se alteram?

Problema 9
A série mensal de consumo médio mensal de energia elétrica num certa área do Brasil no período janeiro de 1989 a dezembro de 1994 está no arquivo "dados_cap_5_problema_9.xls".

g) Ajuste um modelo de Holt-Winters **aditivo** com **tendência linear** e comente sobre os resultados encontrados.
h) Faça as previsões da temperatura para o período entre Janeiro e Dezembro de 1995.

i) Utilizando a série apenas até dezembro de 1993, faça as previsões para o ano de 1994 e compare-as com os valores observados. Calcule o erro quadrático médio, usando o somatório dos quadrados dos desvios entre os valores reais e as previsões (encontradas usando como última observação o mês de dezembro de 1994, ou seja, a previsão para dezembro de 1995 é uma previsão 12 passos à frente).
j) Repita o item c) calculando o RMSE baseado nas previsões um passo à frente. Note que será necessário "rodar" o modelo 12 vezes (com o final da série em Dezembro de 1993, em janeiro de 1994..., em novembro de 1994). Compute o erro quadrático médio e verifique se houve redução substancial em relação ao RMSE calculado no item c) acima.
k) Faça um gráfico dos fatores sazonais estimados no modelo do item b).
l) Altere as constantes de amortecimento estimadas no modelo do item b), arrendondando-as para a próxima casa decimal. Ajuste o modelo com as novas constantes de amortecimento. Como o BIC e o AIC se alteram?

Problema 10
Repita o problema 9 usando um modelo Holt-Winters multiplicativo.

Problema 11
Repita o problema 10 (modelo linear multiplicativo) usando os dados do arquivo "dados_cap_5_problema_11.xls". Estes dados referem-se às vendas mensais de um produto de limpeza no período janeiro de 1989 a dezembro de 1994.

Problema 12
Mostre que, num processo AR(1), as autocorrelações decaem exponencialmente com o "lag".

Problema 13
Considere o processo AR(2) dado por: $w_t = w_{t-1} - 0.1w_{t-2} = a_t$.

a) Escreva a equação de diferenças que relaciona as autocorrelações nos diversos lags.
b) Calcule ρ_1.
c) Encontre a expressão geral para ρ_k em função de ρ_1 e use-a para calcular os valores para k = 1, 2...10

Problema 14
Considere o seguinte processo AR(1): $w_t = 0.5w_{t-1} + a_t$. Encontre a representação MA deste processo.

Problema 15
Considere o seguinte processo MA(1): $w_t = a_t - 0.5a_{t-1}$. Encontre a representação AR deste processo.

Problema 16
Considere o processo $(1 - 0.3B)w_t = (1-0.9B)a_t$

a) Encontre a função de autocorrelação.
b) Encontre a função de autocorrelação parcial para k = 1, 2,3.

Problema 17
Nos modelos a seguir, escreva os polinômios AR e MA e verifique as condições de estacionariedade e inversibilidade:

a) $w_t - a_t = 0.3.(a_{t-1} + a_{t-2})$
b) $w_t + w_{t-2} = a_t + 2.(z_{t-1} - a_{t-1})$

Problema 18
Considere as séries no arquivo **dados_cap_5_problema_18.xls**. Selecione 6 séries e identifique, através da ACF e PACF, a estrutura do modelo ARIMA. As séries são simuladas e têm tamanho 200, para facilitar a identificação.

Problema 19
O arquivo **dados_cap_5_problema_19.xls** contém os retornos logarítmicos diários do IBOVESPA entre janeiro de 1996 e novembro de 1997. Ajuste um modelo ARIMA para os dados? Você consegue identificar algum modelo "melhor" que a random walk?

Problema 20
Nos modelos descritos a seguir, escreva a expressão geral para a previsão j passos à frente.

a) $\left(1 - \phi_1 B - \phi_2 B^2\right) Z_t = a_t$

b) $(1 - \phi_1 B)(1 - B) Z_t = a_t$

c) $(1 - \phi_1 B)(1 - B) Z_t = (1 - \theta_1 B) a_t$

d) $(1 - B)^2 Z_t = (1 - \theta_1 B) a_t$

Problema 21
O arquivo **dados_cap_5_problema_21.xls** contém o consumo total anual de energia elétrica no Brasil entre 1963 e 2000.

a) Ajuste um modelo de Holt para os dados usando a série até 1998.
b) Ajuste um modelo ARIMA para os dados até 1998.
c) Compare os erros de previsão obtidos segundo os dois modelos em 1999 e 2000.
d) Use os dois modelos para produzir previsões até 2005 do consumo total de energia.

CAPÍTULO 6 - CRESCIMENTO POPULACIONAL, PROCESSOS DE RAMIFICAÇÃO ("BRANCHING PROCESSES")

6.1. Introdução e Exemplos

Pode-se pensar em um processo de ramificação como um processo estocástico para a evolução de uma população de indivíduos ou partículas. Estes indivíduos iniciais se reproduzem, de tal forma que o número de "filhos" produzido por um único "pai" em qualquer instante de tempo é independente da história do processo e também de outros indivíduos existentes naquele momento.

No instante inicial $t = 0$ existem X_0 "partículas", e cada uma se divide num número aleatório de descendentes, que constituem a primeira geração. Cada um destes, por sua vez, também se dividem num número aleatório de descendentes, e o processo continua desta forma.

O número de descendentes produzido por um único ancestral em qualquer instante de tempo é independente da história do processo, e das outras partículas (ou indivíduos) presentes no mesmo instante de tempo.

Alguns **exemplos** de processos de ramificação:

1) **Reação em Cadeia no Núcleo de um Átomo**
Um núcleo é dividido por uma colisão aleatória com um nêutron. A fissão resultante produz um número aleatório de novos nêutrons. Cada um destes nêutrons pode atingir outros núcleos produzindo um número aleatório de nêutrons adicionais e o processo continua assim.

2) **Surtos Epidêmicos**
Processos de ramificação podem ser usados como modelos para surtos epidêmicos. Por exemplo, suponha que uma característica de interesse (neste caso, uma doença), numa certa população, seja transmitida a alguns membros de uma população a partir de um instante inicial de tempo. Os indivíduos que adquiriram a doença então a transmitem, segundo uma distribuição de probabilidade, aos membros de outros grupos. A nova "geração" espalha a mesma característica novamente e o processo continua até a extinção ou até que a população inteira adquira a característica (doença).

3) **Sobrevivência de Sobrenomes**
Galton (1873) e Watson (1874) estudaram o problema da extinção de sobrenomes após um certo número de gerações. Este é um fenômeno bastante comum, em especial na nobreza.

O sobrenome de uma família é passado adiante apenas pelos filhos homens. Suponha que cada indivíduo tem probabilidade p_K de ter K filhos homens. A partir de um indivíduo resultam a 1ª, 2ª..., n-ésima... geração de descendentes. Podemos investigar a distribuição destas variáveis aleatórias como o número de descendentes na n-ésima geração e computar a probabilidade de que o sobrenome da família seja eventualmente extinto.

Em geral, seja X_0 o tamanho da população inicial (zero-ésima geração). Cada indivíduo gera K novos indivíduos com probabilidade p_K, **independente** de outros indivíduos.

A totalidade de descendentes diretos da população inicial constitui a 1ª geração, cujo tamanho é X_1.

Em geral, a n-ésima geração é formada pelos descendentes da (n-1)ésima geração.

Supõe-se também que qualquer membro de uma dada geração produz k descendentes com probabilidade p_K (k = 0, 1, 2...) e esta probabilidade é **independente** do número de descendentes de qualquer outro indivíduo.

O tamanho da população na n-ésima geração é denotado por X_n.

Mas, $\{X_n, n = 0, 1, 2...\}$ é uma **cadeia de Markov** cujo espaço de estados é o conjunto de interior não negativos.

$P_{ij} = Pr[X_{n+1} = j | X_n = i]$

O **estado 0 é absorvente**, pois é claro que $P_{\infty} = 1$. (Se não há ninguém numa certa geração, não haverá descendentes!!).

Seja p_0 a probabilidade de um certo indivíduo não ter "filhos". Suponha $p_0 > 0$. Neste caso, todos os outros estados são transientes, pois:

$P_{i0} = p_0^i > 0$

já que, para sair do estado i (i indivíduos numa geração) e ir para o estado zero na próxima geração, é preciso que todos os indivíduos não tenham deixado descendentes.

Para descrever a relação entre X_n e X_{n+1} (número de indivíduos na n-ésima e (n+1) ésima gerações) introduzimos uma matriz infinita de variáveis aleatórias **independentes e identicamente distribuídas** Z_{ij} (i = 1, 2, 3... e j = 0, 1, 2...) onde Z_{ij} é o **número de descendentes do i-ésimo indivíduo na j-ésima geração.**

Suponha que o tamanho inicial da população é $X_0 = 1$. Então:

Z_{10} = nº de descendentes do primeiro (e único) indivíduo da "zero-ésima" geração.

Seja $Pr[Z_{10} = k] = p_K$ para k = 0, 1, 2...

Sejam: $E(Z_{10}) = \mu$ e $VAR(Z_{10}) = \sigma^2$

A evolução do processo de ramificação é descrita recursivamente por:

$$X_{n+1} = \sum_{i=1}^{X_n} Z_{in} \quad \text{para } n = 0, 1, 2...$$

Esta soma tem um **número aleatório de termos** X_n, onde X_n é o número de indivíduos na n-ésima geração.

Se n = 0 só existe um termo na soma, Z_{10}. Também, se $X_n = 0$, $X_{n+1} = 0$ e a população foi extinta. Procuramos uma relação recursiva entre os dois primeiros momentos de gerações consecutivas.

$$E(X_{n+1}) = E\left[\sum_{i=1}^{X_n} Z_{in}\right] = \sum_j E\left[\sum_{i=1}^{X_n} Z_{in} \,\middle|\, X_n = j\right] Pr[X_n = j]$$

Mas, **dado $X_n = j$**, a população X_{n+1} é a soma de j variáveis aleatórias, cada uma com média μ.

$$\Rightarrow E(X_{n+1}) = \sum_j j\mu Pr[X_n = j] = \mu \sum_j j Pr[X_n = j]$$

$$E(X_{n+1}) = \mu E(X_n) \qquad n = 0,1,2,...$$

Como $E(X_0) = 1$ segue que:

$E(X_1) = \mu$

$E(X_2) = \mu^2$

$E(X_n) = \mu^n, \qquad n = 0,1,2,...$

Logo, o tamanho médio da população aumenta geometricamente quando $\mu > 1$, decresce geometricamente quando $\mu < 1$ e permanece constante quando $\mu=1$. Note também que μ **não é** necessariamente um número inteiro.

Também, **dado $X_n = j$**, X_{n+1} é a soma de j variáveis aleatórias independentes e identicamente distribuídas. Logo:

$$VAR(X_{n+1} | X_n = j) = j\sigma^2$$

Assim:

$$E(X_{n+1}^2 \mid X_n = j) = VAR(X_{n+1} \mid X_n = j) + \{E\{X_{n+1} \mid X_{n=j}\}\}^2 = j\sigma^2 + (j\mu)^2 = j\sigma^2 + j^2\mu^2$$

O valor esperado **incondicional** de X_{n+1}^2 é

$$E(X_{n+1}^2) = \sum_j E[X_{n+1}^2 | X_n = j].\ Pr[X_n = j] = \sum_j \{j\sigma^2 + j^2\mu^2\}\ Pr[X_n = j]$$

$$= \sigma^2 \sum_j j.\ Pr[X_n = j] + \mu^2 \sum_j j^2\ Pr[X_n = j] = \sigma^2 E(X_n) + \mu^2 E(X_n^2)$$

A variância **incondicional** de X_{n+1} é:

$$VAR\ (X_{n+1}) = E\ (X_{n+1}^2) - \{E\ (X_{n+1})\}^2 = \sigma^2 E\ (X_n) + \mu^2\ E\ (X_n^2) - \mu^2 \{E\ (X_n)\}^2$$

$$VAR\ (X_{n+1}) = \sigma E\ (X_n) + \mu^2 - [E\ (X_n^2) - \{E\ (X_n)\}^2] = \sigma^2\ E\ (X_n) + \mu^2\ VAR\ (X_n)$$

Mas, $E(X_n) = \mu^n$

$VAR(X_n)$ ainda deve ser determinado.

$$VAR\ (X_{n+1}) = \sigma^2 \mu^n + \mu^2\ VAR\ (X_n), \qquad n = 0,\ 1,\ 2,...$$

Como $X_0 = 1 \Rightarrow VAR(X_0) = 0$ e então:

$$VAR(X_1) = \sigma^2 \mu_0 = \sigma^2$$

$$VAR(X_2) = \sigma^2 \mu + \sigma^2 \mu^2 = \sigma^2 \mu (1 + \mu) = \sigma^2 \mu \frac{(\mu^2 - 1)}{(\mu - 1)}$$

$$VAR(X_3) = \sigma^2 \mu^2 + \mu^2 \sigma^2 \mu (1 + \mu) = \sigma^2 \mu^2 \left[\frac{\mu^3 - 1}{\mu - 1}\right]$$

Pode-se provar por indução que:

$$VAR\ (X_n) = \begin{cases} \sigma^2 \mu^{n-1} \dfrac{(\mu^n - 1)}{\mu - 1} & \mu \neq 1 \\ n\sigma^2 & \mu = 1 \end{cases}$$

para n = 1, 2, 3...

O comportamento assintótico da média e variância de X_n é mostrado a seguir:

i) $\mu < 1$
$E(X_n) \to 0$ quando $n \to \infty$
$VAR(X_n) \to 0$

ii) $\mu = 1$
$E(X_n) = 1$ para todo n
$VAR(X_n) \to \infty$ quando $n \to \infty$

ii) $\mu > 1$
$E(X_n) \to \infty$
$VAR(X_n) \to \infty$ quando $n \to \infty$

Nota:
Como já mencionamos antes, se $\mathbf{p_0 > 0}$, todos os outros estados são transientes.

Mas, como qualquer conjunto **finito** {1, 2..., n} de estados **transientes** será visitado apenas um número finito de vezes, então no limite quando $n \to \infty$ (o número de gerações cresce), **a população será extinta ou então seu tamanho cresce sem limite.**

6.2. Probabilidades de Extinção num Processo de Ramificação

A extinção da população ocorre quando o tamanho da população se reduz a zero.

O instante (aleatório) em que ocorre a extinção, N, é o primeiro instante n para o qual $X_n = 0$, e então segue que $X_K = 0$ para todo instante $k \geq n$.

O estado zero é **absorvente**, e podemos calcular a probabilidade de extinção da população através de uma análise do primeiro passo.

Seja $u_n = Pr\ [N \leq n] = Pr\ [X_n = 0]$

u_n é a *probabilidade de extinção* na n-ésima geração ou antes dela, dado que $X_0 = 1$.

Suponha que o antepassado original $X_0 = 1$ tenha $Z_{10} = k$ descendentes. Cada um destes descendentes gera uma população de seus próprios descendentes, e se a população total é extinta em n gerações, cada uma destas k linhas de descendência deve ser extinta em, no máximo, n-1 gerações.

Mas, as k subpopulações geradas pelos descendentes do ancestral original são **independentes**, e têm as mesmas propriedades estatísticas da população original. Assim, por definição, a **probabilidade de extinção de qualquer das subpopulações em n-1 gerações é u_{n-1}.**

A probabilidade de que todas as k subpopulações sejam extintas em n-1 gerações é $(u_{n-1})k$ pois as subpopulações são independentes.

Ponderando estes termos pela probabilidade de deixar k descendentes e somando para todos os valores de k temos:

$$u_n = \sum_{K=0}^{\infty} p_K (u_{n-1})^K \qquad n = 1,\ 2,...$$

$u_0 = 0$

$u_1 = p_0$ = probabilidade de que o ancestral original não tenha descendentes.

Exemplo 6.2.1.
Suponha que um indivíduo não deixe descendentes com probabilidade ¼ e tenha 2 descendentes com probabilidade 3/4. Então: $p_0 = 1/4$, $p_2 = ¾$ e $p_K = 0$ se $k \neq 0,2$.

A recursão acima torna-se:

$$u_n = \frac{1}{4} + \frac{3}{4}(u_{n-1})^2 \qquad n = 1,\ 2,...$$

onde $u_0 = 0$.

Logo:

$u_1 = 0.2500$ $u_6 = 0.3313$
$u_2 = 0.2969$ $u_7 = 0.3323$
$u_3 = 0.3161$ $u_8 = 0.3328$
$u_4 = 0.3249$ $u_9 = 0.3331$
$u_5 = 0.3292$ $u_{10} = 0.3332$

Estas probabilidades de extinção aparentemente tendem a um limite (1/3?). Veremos a seguir como calcular este limite e quando existe o limite.

Exemplo 6.2.2.

Suponha $p_0 = \frac{1}{3}$, $p_1 = \frac{1}{3}$, $p_2 = \frac{1}{3}$, e $p_K = 0$ para todo $k \neq 0,1,2$. Calcule as probabilidades de extinção u_n para n = 1, 2..., 10.

Solução

$u_0 = 0$

$u_n = p_0 + p_1 u_{n-1} + p_2 u_{n-1}^2$

$u_n = \frac{1}{3}\left[1 + u_{n-1} + u_{n-1}^2\right]$

$u_1 = 1/3$ $u_6 = 0.7121$
$u_2 = 0.4815$ $u_7 = 0.7398$
$u_3 = 0.5711$ $u_8 = 0.7623$
$u_4 = 0.6324$ $u_9 = 0.7812$
$u_5 = 0.6775$ $u_{10} = 0.7971$

Neste caso, aparentemente as probabilidades de extinção não tendem a qualquer limite **menor que 1.**

Aparentemente, o $\lim_{n\to\infty} u_n = 1$,

ou, seja, a extinção é certa após um número grande de gerações. Verificaremos se esta conjectura é verdadeira, mas antes disso precisamos introduzir alguns conceitos novos.

6.3. Funções Geradoras de Probabilidades

Seja Y uma variável aleatória com valores inteiros e não negativos, cuja função de probabilidade é: $Pr[Y = k] = p_K$ para k = 0, 1, 2...

A **função geradora de probabilidade** $\varphi(s)$ associada à variável aleatória Y é definida por:

$$\varphi(s) = E[S^Y] = \sum_{K=0}^{\infty} p_K S^K \qquad \forall\, 0 \le S < 1$$

A relação entre a função geradora de probabilidade e a distribuição de probabilidade é biunívoca, no sentido de que conhecer uma delas é equivalente a conhecer a outra. Uma outra maneira de pensar nisso é: a função geradora de probabilidade determina unicamente a função de probabilidade.

Teorema 6.3.1. Relação Entre a Função de Probabilidade e a Função Geradora de Probabilidade

Seja Y uma variável aleatória discreta com valores inteiros não negativos, e $p_K = Pr[Y = k]$ para k = 0, 1, 2...Seja

$$\varphi(s) = E[s^Y] = \sum_{K=0}^{\infty} p_K s^K \qquad 0 \le s \le 1$$

Então:

$$p_K = \frac{1}{K!}\frac{d^K \varphi(S)}{ds^K}\bigg|_{s=0} \quad \forall\, K = 0,1,2,\ldots \qquad \text{e}$$

$p_0 = \varphi(0)$

Demonstração

$$\varphi(s) = \sum_{K=0}^{\infty} p_K s^K = p_0 + p_1 s + p_2 s^2 + \ldots$$

$\Rightarrow \varphi(0) = 0_0$

$$\frac{d\varphi(s)}{ds} = p_1 + 2p_2 s + \ldots \Rightarrow p_1 = \frac{d\varphi(s)}{ds}\bigg|_{s=0}$$

e assim sucessivamente para p_2, p_3...

Nota

A função geradora de probabilidades é "parecida" com a função geradora de momentos (fgm). A definição de fgm é (para uma variável aleatória discreta Y com valores não negativos):

$$M_Y(t) = E(e^{ttY}) = \sum_{K=0}^{\infty} p_K e^{tK}$$

ou seja, a definição é praticamente a mesma da função geradora de probabilidades, com **s** substituído por $\mathbf{e^t}$.

Também, é um fato conhecido que a função geradora de momentos determina unicamente a densidade (ou função de probabilidade), e então não é de se espantar que a função geradora de probabilidades também faça isso.

Note que a função geradora de momentos gera momentos, ou seja, gera $E(Y^K)$. Na verdade, analogamente ao teorema 6.3.1 temos:

$$E(Y^K) = \frac{d^K M_Y(t)}{dt^K}\bigg|_{t=0} \qquad \text{e} \qquad I = M_Y(0).$$

Teorema 6.3.2.
Sejam Y_1, Y_2..., Y_n variáveis aleatórias independentes, discretas e não negativas com funções geradoras de probabilidade $\varphi_1(s)$, $\varphi_2(s)$..., $\varphi_n(s)$,

Seja $Y = Y_1 + Y_2 + \ldots + Y_n$.

A função geradora de probabilidade de Y é apenas o produto das funções geradoras de probabilidade de Y_1, Y_2..., Y_n, ou seja:
$\varphi_1(s) = \varphi_1(s).\varphi_2(s)\ldots \varphi_n(s)$.

Nota
Os momentos da variável aleatória Y também podem ser obtidos a partir de sua função geradora de probabilidades (e suas derivadas).

Teorema 6.3.3.
Seja Y uma variável aleatória discreta com valores inteiros não negativos e função geradora de probabilidades $\varphi(s)$. Então:

$$E(Y) = \frac{d\varphi(s)}{ds}\bigg|_{s=1}, \quad E(Y^2) = \frac{d^2\varphi(s)}{ds^2}\bigg|_{s=1} + \frac{d\varphi(s)}{ds}\bigg|_{s=1}$$

Demonstração

$$\frac{d\varphi(s)}{ds}\bigg|_{s=1} = p_1 + 2p_2 + 3p_3 + \ldots = \sum_{j=0}^{\infty} j p_j = E(Y)$$

pela definição da média E(Y)

$$\frac{d\varphi(s)}{ds}\bigg|_{s=1} = 2p_2 + 3(2)p_3 + 4(3)p_4 + \ldots = \sum_{K=2}^{\infty} K(K-1)p_K = E[Y(Y-1)] = E(Y^2) - E(Y)$$

$$\Rightarrow E(Y^2) = \frac{d^2\varphi(s)}{ds^2}\bigg|_{s=1} + E(Y) = \frac{d^2\varphi(s)}{ds^2}\bigg|_{s=1} + \frac{d\varphi(s)}{ds}\bigg|_{s=1}$$

Exemplo 6.3.4.
Seja Y uma variável aleatória com função de probabilidade uniforme discreta nos pontos 0, 1, 2..., n-1. Calcule a função geradora de probabilidades de Y, e E(Y), VAR(Y).

Solução
A função de probabilidade de Y é:

$$p_k = Pr[Y = K] = \begin{cases} \frac{1}{n} & \text{se } K = 0,1,2,\ldots,n-1 \\ 0 & K \neq 0,1,2,\ldots,n-1 \end{cases}$$

$$\varphi(s) = \sum_{K=0}^{\infty} p_K s^K = \sum_{K=0}^{n-1} \frac{1}{n} s^K = \frac{1}{n}[1 + s + s^2 + s^3 + \ldots + s^{n-1}]$$

$$\varphi'(s) = \frac{1}{n}[1 + 2s + 3s^2 + 4s^3 + \ldots + (n-1)s^{n-2}]$$

$$\varphi''(s) = \frac{1}{n}[2 + 3(2)s + 4(3)s^2 + 5(4)s^3 + \ldots + (n-1)(n-2)s^{n-3}]$$

$$E(Y) = \varphi'(s)\bigg|_{s=1} = \frac{1}{n}[1 + 2 + 3 + 4 + \ldots + (n-1)]$$

$$E(Y) = \frac{1}{n}\sum_{i=1}^{n-1} i = \frac{1}{n}\left[\frac{(n-1)n}{2}\right] = \frac{n-1}{2}$$

$$\varphi''(s)\bigg|_{s=1} = \frac{1}{n}[2 + 3(2) + 4(3) + 5(4) + \ldots + (n-1)(n-2)]$$

$$= \frac{1}{n}\sum_{i=1}^{n-2} i(i+1) = \frac{1}{n}\left\{\sum_{i=1}^{n-2} i^2 + \sum_{i=1}^{n-2} i\right\} = \frac{1}{n}\left[\frac{(n-2)(n-1)}{2} + \frac{(n-2)(n-1)[2n-4+1]}{6}\right]$$

$$\varphi''(s)\bigg|_{s=1} = \frac{(n-2)(n-1)}{2n}\left[1 + \frac{2n-3}{3}\right] = \frac{(n-1)(n-2)(2n)}{2n}\frac{(2n)}{3} = \frac{(n-1)(n-2)}{3}$$

Logo:

$$E(Y^2) = \varphi''(s)\bigg|_{s=1} + \varphi'(s)\bigg|_{s=1}$$

$$E(Y^2) = \frac{(n-1)(n-2)}{3} + \frac{(n-1)}{2} = \frac{(n-1)}{6}[2(n-2)+3)]$$

$$E(Y^2) = \frac{(n-1)(2n-1)}{6}$$

$$VAR(Y) = E(Y^2) - \{E(Y)\}^2 = \frac{(n-1)(2n-1)}{6} - \frac{(n-1)^2}{4} = \frac{(n-1)}{12}[4n-2-3n+3]$$

$$VAR(Y) = \frac{(n-1)(n+1)}{12} = \frac{(n^2-1)}{12}$$

Exemplo 6.3.5.
Seja Y uma variável aleatória com função de probabilidade Poisson (λ). Calcule a função geradora de probabilidade ($\varphi(s)$), E(Y) e VAR(Y).

Solução

$$p_K = Pr[Y = K] = \frac{\lambda^K e^{-\lambda}}{K!} \qquad K = 0, 1, 2, \ldots$$

$$\varphi(s) = \sum_{K=0}^{\infty} p_K s^K = \sum_{K=0}^{\infty} \frac{e^{-\lambda}\lambda^K s^K}{K!} = e^{-\lambda} \sum_{K=0}^{\infty} \frac{(\lambda s)^K}{K!}$$

$$\varphi(s) = e^{-\lambda} e^{\lambda s} = e^{-\lambda(1-s)} \qquad \text{para } |s| < 1$$

$$\frac{d\varphi(s)}{ds} = e^{-\lambda}(\lambda e^{\lambda s}) \Rightarrow \left.\frac{d\varphi(s)}{ds}\right|_{s=1} = \lambda = E(Y)$$

$$\frac{d^2\varphi(s)}{ds^2} = \lambda e^{-\lambda}(\lambda e^{\lambda s}) = \lambda^2 e^{-\lambda} e^{\lambda s}$$

$$\left.\frac{d^2\varphi(s)}{ds^2}\right|_{s=1} = \lambda^2 \Rightarrow E(Y^2) = \lambda^2 + \lambda$$

$$VAR(Y) = E(Y^2) - \{E(Y)\}^2 = \lambda^2 + \lambda - \lambda^2 = \lambda$$

O nosso objetivo agora é relacionar a função geradora de probabilidades com as distribuições que ocorrem nos processos de ramificação, de forma a tentar descobrir como se calcula o limite das probabilidades de extinção u_n.

Considere um processo de ramificação no qual o tamanho da população na n-ésima geração é X_n.

Seja $p_K = Pr[Y = k]$ a **distribuição de probabilidade do número de descendentes**, e suponha que a função geradora de probabilidades correspondente é:

$$\varphi(s) = E(s^Y) = \sum_K p_K s^K.$$

Seja $u_n = Pr[X_n=0]$ a **probabilidade de extinção da população na n-ésima geração**. Já vimos que u_n satisfaz a fórmula recursiva:

$$u_n = \sum_{K=0}^{\infty} p_K (u_{n-1})^K = \varphi(u_{n-1})$$

Logo, se conhecemos a função geradora de probabilidades $\varphi(s)$ podemos calcular sucessivamente as probabilidades de extinção u_n partindo de $u_0 = 0$ e fazendo $u_1 = \varphi(u_0)$, $u_2 = \varphi(u_1)$ etc...

Exemplo 6.3.6.
Considere o exemplo 6.2.1, onde $p_0 = 1/4$, $p_2 = 3/4$. A função geradora de probabilidades é:

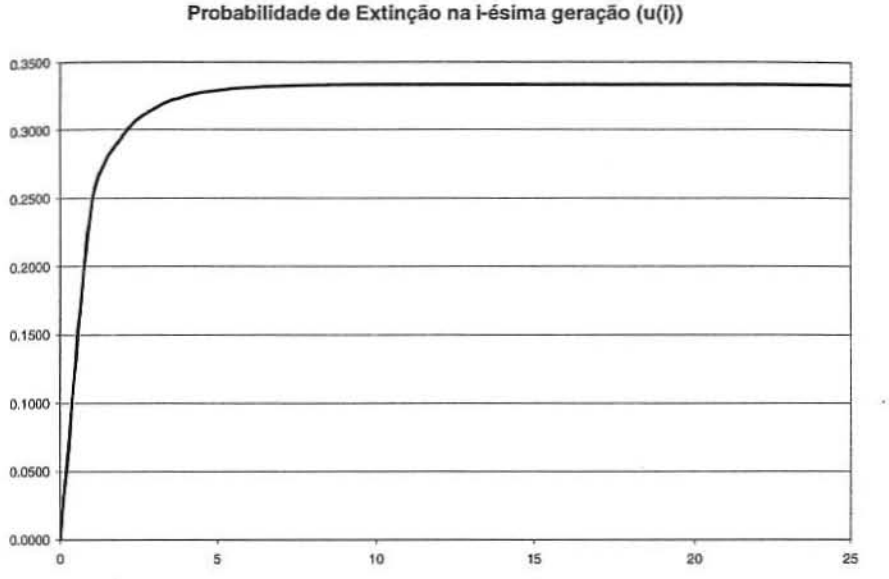

$$\varphi(s) = \frac{1}{4} + \frac{3}{4}s^2.$$

Do gráfico podemos ver que as probabilidades de extinção convergem para um valor, 1/3, que é a menor solução positiva da equação $u = \varphi(u)$. Isto é verdade no caso geral.

Seja u_∞ a menor solução da equação $u = \varphi(u)$, u_∞ denota a **probabilidade da população ser extinta num instante finito**.

Alternativamente, a população cresce indefinidamente com probabilidade $1- u_\infty$.

Neste exemplo, u_∞ é a menor solução de:

$$u = \varphi(u) = \frac{1}{4} + \frac{3}{4}u^2$$

Esta equação tem soluções 1/3 e 1. Logo, $u_\infty = 1/3$, o que concorda com o limite conjeturado no exemplo 6.2.1.

Exemplo 6.3.7.
Considere o exemplo 6.2.2, onde $p_0 = p_1 = p_2 = 1/3$. A função geradora de probabilidades é:

$$\varphi(s) = \frac{1}{3} + \frac{1}{3}s + \frac{1}{3}s^2$$

Fazendo: $u = \varphi(u) \Rightarrow (u-1)^2 = 0 \Rightarrow u = 1$.Logo,
$u_\infty = \lim_{n\to\infty} u_n = 1$, como suspeitávamos no exemplo 6.2.2.

Exemplo 6.3.8.
Suponha que $p_0 = 3/4$, $p_2 = 1/4$.

$$u = \varphi(u) = \frac{3}{4} + \frac{1}{4}u^2$$

$u^2 - 4u + 3 = 0 \Rightarrow u = 1$ ou $3 \Rightarrow u_\infty = 1$ é a probabilidade de eventual extinção.

Em geral, o comportamento de u_∞ pode ser obtido diretamente a partir da função geradora de probabilidades da seguinte maneira:

Verifique se $\varphi(s)$ cruza a reta com inclinação 45%.
Este fato pode ser determinado a partir do coeficiente angular:

$$\varphi'(1) = \left.\frac{d\varphi(s)}{ds}\right|_{s=1}$$

Se $\varphi'(1) \leq 1$ então $\varphi(s)$ **não cruza a reta,** e a probabilidade de eventual extinção é $u_\infty = 1$.

Se $\varphi'(1) > 1$, a equação $u = \varphi(u)$ tem uma solução menor que 1, e $u_\infty < 1$.

Mas, $E(Y) = \varphi'(1)$ (pelo teorema 6.3.3), onde Y é a variável aleatória que representa a distribuição dos descendentes. Logo,

→ Se o tamanho médio do nº de descendentes, $E(Y) \leq 1$, então $u_\infty = 1$, e a extinção da população é certa.

→ Se $E(Y) > 1$, então $u_\infty < 1$ e a população pode crescer indefinidamente com uma probabilidade positiva.

→ Se $E(Y) = 1$, então $E(X_n | X_0 = 1) = 1$ para todo n, e o tamanho médio da população é constante. No entanto, pela discussão acima, sabemos que **certamente a população será extinta**. Logo, apenas o tamanho da população não descreve completamente o comportamento da população.

Exemplo 6.3.9.
Parzen (1962) em seu livro de processos estocásticos menciona um exemplo dado por Lotka (1931) sobre a probabilidade de extinção de sobrenomes nos EUA.

Suponha que a função geradora de probabilidades para homens brancos nos EUA em 1920 é dada por:

$$\varphi(u) = \frac{0.482 - 0.041u}{1 - 0.559u}$$

A partir desta função geradora de probabilidades, calcule a probabilidade de eventual extinção.

Solução
$u = \varphi(u) \Leftrightarrow u - 0.559u^2 = 0.482 = 0.041u$

$\Leftrightarrow -0.559u^2 + 1.041u - 0.482 = 0$
$0.559u^2 - 1.041u + 0.482 = 0$

$$u = \begin{cases} 0.8623 \\ 1 \end{cases}$$

Logo, $u_\infty = 0.8623$ é a probabilidade de extinção de um sobrenome (dado que havia um único ancestral original).

6.4. Funções Geradoras de Probabilidades e Somas de Variáveis Aleatórias Independentes

Teorema 6.4.1.
Sejam X e Y variáveis aleatórias **independentes** com funções geradoras de probabilidade $\varphi_X(s)$ e $\varphi_Y(s)$. Seja $Z = X + Y$. Então, a função geradora de probabilidade de Z é:

$$\varphi_Z(s) = \varphi_X(s).\varphi_Y(s).$$

A função geradora de probabilidades da soma de 2 variáveis aleatórias independentes é o produto das funções geradoras de probabilidade originais.

Demonstração
Por definição, $\varphi_Z(s) = \sum_{K=0}^{\infty} Pr[Z = K].s^K = \sum_{K=0}^{\infty} r_K s^K$ onde $r_K \equiv Pr[Z = K]$.

Sejam $\varphi_X(s) = \sum_{K=0}^{\infty} p_K s^K$, $\varphi_Y(s) = \sum_{K=0}^{\infty} q_K s^K$.

Então:

$$\varphi_X(s).\varphi_Y(s) = \left(\sum_{K=0}^{\infty} p_K s^K\right)\left(\sum_{K=0}^{\infty} q_q s^K\right)$$

e o coeficiente de s^K é:

$$p_K q_0 + p_{K-1} q_1 + p_0 q_K \qquad (6.4.1)$$

Mas,

$$r_K = Pr[Z = K] = \sum_{i=0}^{K} Pr[Z = K|Y = i].Pr[Y = i] = \sum_{i=0}^{K} Pr[X = K - i].Pr[Y = i] = \sum_{i=0}^{K} p_{K-i}.q_i$$

e esta é exatamente a expressão (6.4.1) acima, o que demonstra o teorema.

O próximo resultado é uma extensão deste teorema para o caso de mais de duas variáveis aleatórias.

Corolário 6.4.2.
Sejam X_1, X_2..., X_n variáveis aleatórias inteiras, não negativas, **independentes** e **identicamente distribuídas** com função geradora de probabilidade $\varphi(s)$.

Seja $Z = \sum_{i=1}^{n} X_i$

A função geradora de probabilidades de Z é:

$$\varphi_Z(s) = [\varphi(s)]^n$$

Note que Z é a soma de um número **fixo** (não aleatório) de termos. A seguir, estendemos este resultado para o caso de uma soma de variáveis aleatórias com número aleatório de termos.

Teorema 6.4.3.
Sejam $\{X_i, i = 1, 2, 3...\}$ variáveis aleatórias inteiras, não negativas, independentes e identicamente distribuídas com função geradora de probabilidade $\varphi(s) = \sum_{K=0}^{\infty} p_K s^K$.

Seja N uma variável aleatória inteira não negativa, **independente dos X_i's** e com função geradora de probabilidade g(s) onde:

$$g(s) = \sum_{n=0}^{\infty} Pr[N = n].s^n = \sum_{n=0}^{\infty} g_n.s^n$$

Defina a soma aleatória:

$$S_N = X_1 + X_2 + ... + X_N$$

onde $S_N = 0$ se $N = 0$

A função geradora de probabilidade de S_N é:

$$h(s) = \sum_{j=0}^{\infty} h_j s^j = g[\varphi(s)]$$

A função geradora de probabilidade de uma soma aleatória de variáveis aleatórias é a composição das funções geradoras de probabilidades g(.) e φ(.).

Demonstração

$$h(s) = \sum_{j=0}^{\infty} Pr[S_N = j].s^j = \sum_{j=0}^{\infty} h_j.s^j$$

$$= \sum_{j=0}^{\infty} \left[\sum_{n=0}^{\infty} Pr[S_N = j \mid N = n].\ Pr[N = n] \right] s^j$$

$$= \sum_{j=0}^{\infty} \left[\sum_{n=0}^{\infty} Pr[X_1 + X_2 + ... + X_{n=j}].\ Pr[N = n] \right] s^j$$

pois N é independente dos X_i's.

$$= \sum_{j=0}^{\infty} \left[\sum_{n=0}^{\infty} Pr[X_1 + X_2 + ... + X_{n=j}].Pr[N = n] \right] s^j$$

Mudando-se a ordem dos somatórios:

$$= \sum_{n=0}^{\infty} \left\{ \sum_{j=0}^{\infty} Pr[X_1 + X_2 + ... + X_n = j].s^j \right\} Pr\{N = n\}$$

E pelo corolário anterior concluímos que esta última expressão é:

$$= \sum_{n=0}^{\infty} [\varphi(s)]^n.Pr[N = n] = g[\varphi(s)]$$

pela definição de função geradora de probabilidade de N.

Este resultado é muito útil ao calcularmos probabilidade num processo de ramificação. Seja X_{n+1} o tamanho da população na (n+1)-ésima geração. Logo:

$$X_{n+1} = Z_{1n} + Z_{2n} + ... + Z_{X_n,n}$$

onde Z_{in} é o número de descendentes do i-ésimo indivíduo na n-ésima geração.

Note que existe um número aleatório (X_n) de termos nesta soma. Podemos reescrever esta expressão de maneira conveniente através de função geradora de probabilidade

Seja $\varphi_n(s) = E[s^{X_n}]$ a função geradora de probabilidade do tamanho da população na n-ésima geração. Suponha que $X_0 = 1$. Então:

$$\varphi_0(s) = E(s^1) = s$$

$$\varphi_1(s) = E(s) = E[s^Z]$$

Para obter a expressão geral, usamos o teorema anterior e a expressão que relaciona X_{n+1} e Z_{in} e encontramos

$$\varphi_{n+1}(s) = \varphi_n[\varphi(s)] = \varphi[\varphi_n(s)]$$

Ou seja, a função geradora de probabilidade do nº de indivíduos na n-ésima geração com argumento $\varphi(s)$ em vez de s. (Analogamente para $\varphi(\varphi_n(s))$. Para encontrar a função geradora de probabilidade do tamanho da população X_n na n-ésima geração (dado que $X_0 = 1$) substituímos repetidamente na expressão da função geradora de probabilidade

Exemplo 6.4.4.
Suponha que a função geradora de probabilidade de um indivíduo na população é $\varphi(s) = q+ps$ onde $p+ q = 1$ e $0 < p < 1$. Ou seja, um indivíduo qualquer deixa 0 ou 1 descendente com probabilidades q e p respectivamente.

Calcule $\varphi_n(s)$, a função geradora de probabilidade do tamanho da n-ésima geração, dado que $X_0 = 1$.

Solução
$\varphi_0(s) = s$

$\varphi_1(s) = \varphi(s) = q+ps$

$$\varphi_2(s) = \varphi[\varphi(s)] = s = q+p[\varphi(s)]$$
$$= q + p(q+ps)$$
$$= q+pq + p^2s$$
$$= q(1+p)+p^2s$$

$$\varphi_2(s) = (1+p)(1-p) + p^2s = (1-p^2) + p^2s$$

$$\varphi_3(s) = q+p\,\varphi_2(s) = q+p(1-p^2) + p(p^2s)$$
$$= (1-p) + p(1-p)(1+p) + p^3s$$
$$= (1-p)[1 + p(1+p)] + p^3s$$
$$= (1-p)[1 + p + p^2] + p^3s$$
$$= (1 + p + p^2 - p - p^2 + p^3) + p^3s$$
$$= (1-p^3) + p^3s$$

Em geral:

$$\varphi_n(s) = (1-p^n) + p^ns$$

Se o tamanho inicial da população é $X_0 = K$, a função geradora de probabilidade é:

$$\sum_{j=0}^{\infty} Pr[X_n = j \mid X_0 = K].s^K = [\varphi_n(s)]^K$$

Note que esta função geradora de probabilidade é a mesma do que no caso de K subpopulações independentes, cada uma com um único ancestral original. Assim, o processo de ramificação evolui como a soma de K processos de ramificação independentes, um para cada um dos K ancestrais originais.

Exemplo 6.4.5.
Considere o exemplo 6.4.4, mas suponha agora que o tamanho da população original é K. A função geradora de probabilidade do tamanho da n-ésima geração é:

$$[\varphi_n(s)]^K = [1-p^n + p^ns)]^K$$

A distribuição de probabilidade do tempo de extinção é:

$$Pr[T = n|X_0 = K] = Pr[X_n = 0|X_0 = K]$$
$$- Pr[X_{n-1} = 0|X_0 = K]$$

$$= [\varphi_n(0)]^K - [\varphi_{n-1}(0)]^K = (1-p^n)^K - (1-p^{n-1})^K$$

Exemplo 6.4.6.
Considere um processo de ramificação no qual $X_0 = 1$. Cada indivíduo deixa 0 ou 1 descendente com probabilidades q e p respectivamente. Mostre que a probabilidade de extinção na n-ésima geração é $1-p^n$ e some a série geométrica para mostrar que a probabilidade de eventual extinção é $q/(1-p)$. Encontre o mesmo resultado através da resolução de $u = \varphi(u)$.

Solução
A função geradora de probabilidades é, neste caso:

$\varphi(s) = q + os$

A fórmula recursiva para as probabilidades de extinção torna-se:

$$u_n = \sum_{K=0}^{\infty} p_K(u_{n-1})^K$$

$u_n = q+p(u_{n-1})$

$u_0 = 0$

$u_1 = q$

$u_2 = q + pu_1 = q + pq = q\,(1+p) = 1 - p^2$

$u_3 = q + pu_2 = q + p\,(q + pq) = q + pq + p^2q$

$= q\,(1 + p + q^2) = q\dfrac{[1-p^3]}{1-p} = 1 - p^3$

$u_4 = q + p\,(u_3) = q + p\,(1-p^3) = (1-p) + p\,(1-p^3)$

$= 1 - p + p - p^4 = 1 - p^4$

Em geral, suponha $u_K = 1\text{-}p^K$ $(K \geq 1)$ e então:

$u_{K+1} = q + pu_K = q + p(1-p^K) = (1-p) + p(1-p^K)$

$= 1 - p^{K+1}$.

$\lim\limits_{n\to\infty} u_n = \lim\limits_{n\to\infty}(1-p^n) = \lim\limits_{n\to\infty} q\dfrac{(1-p^n)}{q} =$

$= \lim\limits_{n\to\infty}\left\{q\dfrac{(1-p^n)}{1-p}\right\} = q\lim\limits_{n\to\infty}\left\{\dfrac{1-p^n}{1-p}\right\}$

$= q\,.\lim\limits_{n\to\infty}\left[1 + p + p^2 + \ldots + p^{n-1}\right] = \dfrac{q}{1-p}$ se $0 < p < 1$

Logo, $u_\infty = \dfrac{q}{1-p}$ se $p \in (0,1)$

Isso pode ser provado através da equação $u = \varphi(u)$, isto é:

$u = \varphi(u) = q + pu \Leftrightarrow (1-p)u = q$

$\Leftrightarrow u_\infty = \dfrac{q}{1-p}$ se $p \in (0,1)$.

Mas, é claro que $q = 1\text{-}p$ e então $u_\infty = 1$ e eventualmente a população será extinta.

Exemplo 6.4.7.
Um processo de ramificação é chamado de **fissão binária** se um indivíduo deixa zero ou dois descendentes, com probabilidades q e p respectivamente,

onde $q + p = 1$ e $0 < p < 1$. Suponha $X_0 = 1$. Ache o valor esperado e a variância do tamanho da população na n-ésima geração.

Solução

$\varphi(s) = q + ps^2$

Pelos resultados da seção 6.4.:

$$\Pr[Z_{10} = K] = \begin{cases} q \text{ se } K = 0 \\ p \text{ se } K = 2 \end{cases}$$

$E(Z_{10}) = q(0) + p(2) = 2p = \mu$

$E(Z_{10}^2) = q(0)^2 + p(2)^2 = 4p$

$VAR(Z_{10}) = E(Z_{10}^2) - \{E(Z_{10})\}^2$

$= 4p - 4p^2 = 4p(1-p) = 4pq = \sigma^2$

Novamente usando os resultados da seção 6.4. concluímos que:

$E\,(X_n) = \mu^n = (2p)^n$

$VAR\,(X_n) = \sigma^2\mu^{n-1}\dfrac{(\mu^n - 1)}{\mu - 1} = 4pq(2p)^{n-1}\dfrac{((2p)^n - 1)}{(2p-1)}$

$= 2^{n+1}p^nq\dfrac{[(2p)^n - 1]}{(2p-1)}$ se $\mu = 2p \neq 1 \Leftrightarrow p \neq 1/2$

$VAR\,(X_n) = n\sigma^s = 4npq$ se $p = q = 1/2$

6.5. Exercícios - Capítulo 6

Problema 1
Considere um processo de ramificação no qual $X_0 = 1$ e as probabilidades de um indivíduo ter 0, 1, 2 ou 3 descendentes são todas iguais a ¼.
a) Calcule $u_0, u_1, \ldots, u_5$, as probabilidades de extinção na geração 0, 1, 2, 3, 4, 5.
b) Calcule a probabilidade de eventual extinção u_∞.

Problema 2
Considere um processo de ramificação no qual um indivíduo deixa 0 ou 3 descendentes com probabilidades 2/5 e 3/5 respectivamente. Suponha que $X_0 = 1$ e

seja u_n (n = 1, 2, 3, ...) a probabilidade de extinção na n-ésima geração.
a) Calcule u_n para n =1, 2, 3, 4, 5, 6.
b) Calcule a probabilidade de eventual extinção u_∞.

Problema 3
Seja $\varphi(s) = a.s^2 + b.s + c$ onde a, b, c são positivos e $\varphi(1) = 1$. Seja u_∞ a probabilidade de extinção e suponha que $0 < u_\infty < 1$. Prove que $u_\infty = c/a$ e indique claramente porque esta é a única solução válida.

Problema 4
Você decide começar uma "corrente" via e-mail. Você manda um e-mail para 6 amigos instruindo-os a passar a carta para 6 amigos de cada um deles. Suponha que cada pessoa que recebe a mensagem segue as instruções (e continua a corrente) com probabilidade p, e "quebra" a corrente com probabilidade 1-p.
a) Para que valores de p você tem certeza de que a "corrente" será extinta.
b) Se p = 0.1 qual o número esperado de e-mails enviadas (incluindo as 6 mensagens originais)

Problema 5
Considere uma família em que o pai é médico. Esta profissão vai ser preservada na família até que nenhum dos indivíduos numa certa geração decida seguir esta carreira (isto é, não se admite que o avô e o neto possam ser médicos, sem que alguém na geração intermediária o seja). Suponha que nesta família, a cada geração pode haver 0, 1 ou 2 filhos médicos, com probabilidades iguais a 3/12, 7/12 e 2/12 respectivamente. Calcule a probabilidade de extinção desta carreira na família.

Problema 6
Os sobrenomes numa população são passados de geração a geração através dos indivíduos do sexo masculino. Logo, um sobrenome "passado adiante" por um certo ancestral sobreviverá até que, numa geração, não existam filhos homens. Suponha que, numa dada população, o número de filhos homens para um indivíduo qualquer é 2 (com probabilidade p), 1 (com probabilidade q) ou zero (com probabilidade 1 - p - q). Isto é, para simplificar o problema assumimos que nenhum homem poderá deixar mais de 2 descendentes do sexo masculino.

Suponha que um imigrante do sexo masculino introduz um novo sobrenome num país. Determine a probabilidade de que este sobrenome não sobreviva se:
a) p =1/4 e q = 1/2
b) p = 1/3 e q = 1/2
c) p = 2/3 e q = 1/6

CAPÍTULO 7 - PROCESSOS ESTOCÁSTICOS EM FINANÇAS

7.1. Um Modelo para o Comportamento do Preço de Ações

A seguir, derivamos um processo estocástico contínuo com espaço de estados contínuo para representar a evolução do preço de ações. Uma aproximação a tempo discreto deste processo também será mostrada. O material nesta seção está quase integralmente baseado nos capítulos 9 e 10 de Hull (1993).

Para que serve um modelo de evolução dos preços de ações?
Basicamente, o modelo pretende representar a relação entre os preços atual e futuro de uma ação. A questão fundamental é: existe uma relação entre estes preços? Ou, alternativamente, é possível usar a informação do passado para prever os preços futuros?

7.1.1. A Propriedade Markoviana
Um processo estocástico é chamado de "Markoviano" se apenas o valor atual do processo é relevante para a previsão de valores futuros. Ou seja, dados o passado e o presente, apenas a informação contida no presente é "útil".

Imagine que o preço de ações (ou, de forma mais geral, outro ativo financeiro arriscado) é regido por um processo Markoviano. Então, dado o preço atual da ação, basicamente não interessa o "caminho percorrido" até chegarmos a este preço, isto é, só devemos nos importar com o preço atual, e os preços de uma semana atrás ou um ano atrás são irrelevantes.

A propriedade Markoviana tem um forte impacto sobre as previsões de preços futuros: se os preços formam um processo Markoviano, então a distribuição de probabilidade dos preços de amanhã é função apenas do preço de hoje, que é a única informação relevante. Em particular, a melhor previsão do preço de amanhã é o preço de hoje. A propriedade Markoviana é consistente com a hipótese de eficiência dos mercados financeiros. Esta hipótese afirma que **toda** a informação sobre preços contida no passado está expressa através do preço atual da ação. Se a hipótese de eficiência não fosse válida, investidores poderiam consistentemente ter lucro "fazendo apostas" baseadas em previsões que levam em conta a história dos preços passados, por exemplo, através de médias móveis de preços passados. Ao contrário, em mercados eficientes, esta possibilidade de lucro não parece existir, e isto é uma conseqüência da competição, ou seja, do grande número de investidores presentes no mercado e da inexistência de "inside information" e/ou manipulação do mercado.

7.1.2. Processos de Wiener ou Movimento Browniano
Um processo de Wiener (ou movimento Browniano) é um tipo especial de

processo Markoviano. Suas origens estão na Física, pois este processo descreve o movimento de partículas sujeitas a choques aleatórios, por exemplo o movimento de uma partícula "pesada" suspensa no meio de partículas "leves". O nome "movimento Browniano" é uma homenagem ao botânico inglês Robert Brown que, em 1827, descreveu pela primeira vez o comportamento incomum que uma pequena partícula apresentava, quando imersa num líquido ou gás. A primeira explicação para este fenômeno foi dada por Einstein em 1905. Ele mostrou matematicamente que o movimento Browniano poderia ser explicado se assumíssemos que a partícula estava sendo continuamente bombardeada pelas moléculas do meio em que estava imersa. Mais tarde, em 1918, Norbert Wiener publicou uma definição precisa e obteve muitas das propriedades matemáticas deste processo.

Seja W uma variável aleatória que segue um processo de Wiener, e suponha que Δt indica um pequeno intervalo de tempo, e seja ΔW a variação em W durante este pequeno intervalo de tempo.

ΔW segue um **processo de Wiener** se satisfaz as seguintes propriedades:

1) $\Delta W = Z.\sqrt{\Delta t}$ (7.1.1)

onde Z é uma variável aleatória com distribuição Normal de média zero e variância 1. Pelas propriedades do valor esperado e variância segue que ΔW é uma variável Normal com média zero e variância Δt.

2) Os valores de ΔW em dois intervalos de tempo pequenos e diferentes são independentes. Desta propriedade segue que W é um processo Markoviano.

Agora suponha que examinamos o comportamento dos preços ao longo de um intervalo de tempo T relativamente longo. A variação de preços neste intervalo de tempo é W(T) - W(0), e pode ser interpretada como a soma das variações em N intervalos de tempo "pequenos", de duração Δt, onde $N = T/\Delta t$. Daí segue que:

$W(T) - W(0) = \sum_{i=1}^{N} Z_i\sqrt{\Delta t}$ onde os Z_i's são iid N(0,1). A independência dos Z_i's decorre da propriedade 2 acima.

Novamente empregando as propriedades do valor esperado e variância segue que W(T) - W(0) é uma variável Normal com média zero e variância $T = N.\Delta t$, onde por definição, T é o comprimento do intervalo de tempo. Ou seja, a incerteza aumenta à medida que consideramos intervalos de tempo mais longos. Por exemplo, suponha que W siga um processo de Wiener e que W(0) = 10 e o tempo é medido em meses. A variação de W em 1 mês é uma variável N(0,1) e então W(1) é N(10, 1). Mas, a variação de W em 9 meses é agora uma variável Normal com média zero e variância 9 e assim W(9) é N(10, 9). Ou seja, em termos dos respectivos desvios padrões a incerteza cresceu de 1 para 3 quando passamos de um horizonte de 1 mês para um horizonte de 9 meses no futuro!

A notação usada aqui sugere, a exemplo do que fazemos em Cálculo, que tomemos o limite quando a largura do intervalo (Δt) tende a zero. Mas, qual a diferença entre o exposto aqui e o Cálculo usual que você aprendeu no início da universidade? É a presença da variável aleatória Z, com distribuição Normal! No entanto, isto não impede que tomemos o limite quando Δt tende a zero, o que fornece a versão limite da equação (7.1.1):

$dW = Z.\sqrt{dt}$ (7.1.2)

onde Z é uma variável N(0,1).

O processo de Wiener dado por (7.1.2) pode ser generalizado. Podemos definir uma variável X descrita pela seguinte equação:

$dX = a.dt + b.dW$ (7.1.3)

onde a e b são constantes.

O processo descrito por (7.1.3) é chamado de "processo de Wiener generalizado" ou "movimento browniano geométrico".

Para entender (7.1.3) é conveniente separar as partes determinística e aleatória do lado direito da expressão. Se ignorarmos a parte aleatória (que envolve dW), a equação (7.1.3) reduz-se a dX = a.dt, ou seja: dX/dt = a, que é uma equação diferencial de 1ª ordem cuja solução geral é $X = X_0 + a.t$, onde X_0 é o valor de X no instante zero.

O termo b.dW em (7.1.3) representa a adição de uma componente aleatória, que traz uma variabilidade adicional à trajetória seguida por X.

A versão discreta de (7.1.3) é:

$\Delta X = a.\Delta t + b.\Delta W$ (7.1.4)

E substituindo (7.1.1) em (7.1.4) leva a:

$\Delta X = a.\Delta t + b.Z.\sqrt{\Delta t}$ (7.1.5)

Por (7.1.5) concluímos que ΔX é uma variável Normal com média $a.\Delta t$ e variância $b^2.\Delta t$.

Considere agora um intervalo de tempo T, não necessariamente pequeno. A aplicação de (7.1.5) a este intervalo nos leva a concluir que a variação de preços entre os instantes 0 e T, dada por X(T) - X(0) é uma variável Normal com média a.T e variância $b^2.T$.

A constante a é chamada de **deslocamento esperado** ou deslocamento médio por unidade de tempo ("**expected drift**") e b^2 é a variância por unidade de tempo.

Uma outra **generalização de um processo de Wiener** pode ser obtida fazendo-se a e b em (7.1.3) funções de X e do tempo t. O processo resultante é chamado de **processo de Itô**, escrito algebricamente como:

$dX = a(X,t).dt + b(X,t).dW$

Neste caso, ambos o deslocamento médio e a variância por unidade de tempo podem variar à medida que o processo evolui.

Pode-se supor que o preço de ações segue o processo de Wiener generalizado (7.1.3), mas esta hipótese não é muito realista porque o processo (7.1.3) não captura uma das características essenciais do preço das ações, que é: o retorno esperado pelo investidor é independente do preço atual das ações. Por exemplo, o investidor "quer" 10% de retorno ao ano, não importa se o preço da ação é R$5 ou R$500!

Logo, a hipótese de deslocamento médio por unidade de tempo ("expected drift") constante é falsa. Pode-se substituir esta hipótese por outra, mais realista, em que o "expected drift" é uma proporção constante do preço da ação. Com esta modificação, o processo (7.1.3) toma a forma:

$$dX = a.X.dt + b.dW = a.X.dt + b.Z.\sqrt{dt} \qquad (7.1.6)$$

Imagine agora que a componente aleatória de (7.1.6) está ausente. O processo (7.1.6) se reduz a: $dX = a.X.dt$ ou, equivalentemente:

$$\frac{dX}{X} = a.dt \Rightarrow \int\frac{dX}{X} = a\int dt \Rightarrow X = X_0.e^{at}.$$

Mas, esta última expressão é apenas a que relaciona os valores futuro (após t instantes de tempo) e presente de uma ação sujeita a uma "taxa de juros" a% computada continuamente (vide o Apêndice A deste capítulo).

Na prática, o preço de uma ação está sujeito a variações aleatórias. Uma hipótese razoável é a de que, num intervalo de tempo "curto" Δt, a variância do retorno percentual é independente do preço. Ou seja, um investidor tem a mesma incerteza sobre o **retorno percentual** da ação quando o preço da ação é R$10 ou R$50. A implicação desta hipótese é que, num intervalo de tempo "pequeno" Δt, b^2. Δt representa a variância do retorno e $b^2.X^2.\Delta t$ indica a variância dos preços (X) durante Δt.

Assim, a equação (7.1.6) deve ser modificada, com b. Z. $\sqrt{dt}$ substituído por b. X. Z. $\sqrt{dt}$.

Finalmente escrevemos o **processo estocástico para os preços de ações** como:

$$dX = a.X.dt + b.X.dW = a.X.dt + b.X.Z.\sqrt{dt} \qquad (7.1.7)$$

A notação usual faz X = S = preço da ação, a = μ, b = σ (volatilidade) e o processo (7.1.7) torna-se:

$$dS = \mu.S.dt + \sigma.S.dW = \mu.S.dt + \sigma.S.Z.\sqrt{dt} \qquad (7.1.8)$$

Ou seja, os preços seguem um processo de Itô com $a(S,t) = \mu.S$ e $b(S,t) = \sigma.S$, o que é uma coisa meio complicada! Mas, o problema pode ser simplificado se pensarmos no processo para os **retornos ao invés dos preços**. Dividindo os dois lados de (7.1.8) por S leva a:

$$\frac{dS}{S} = \mu.dt + \sigma.dW = \mu.dt + \sigma.Z.\sqrt{dt} \qquad (7.1.9)$$

A versão discreta de (7.1.9) é:

$$\frac{\Delta S}{S} = \mu.\Delta t + \sigma.\Delta W = \mu.\Delta t + \sigma.Z.\sqrt{\Delta t} \qquad (7.1.10)$$

Mas, note que $\Delta S/S$ é apenas a variação percentual dos preços num intervalo de tempo Δt, isto é, o retorno no intervalo Δt. Por (7.1.9) concluímos que **os retornos** (e não os preços!!) **seguem um movimento browniano geométrico** (ou processo de Wiener generalizado).

O modelo (7.1.9) ou (7.1.10) é um dos modelos mais utilizados para explicar o comportamento do preço de ações. A constante positiva **σ** é geralmente chamada de **volatilidade** do preço da ação, enquanto μ é a **taxa de retorno esperada instantânea**. Ambos μ e σ dependem da unidade empregada para medir o tempo. Geralmente utiliza-se o tempo em anos, representado por 365 dias ou, às vezes, 250 dias, que é uma aproximação mais realista do número de dias úteis no ano, em que há negociação de ativos. É importante ressaltar que o modelo discute apenas o que acontece em intervalos de tempo muito curtos.

Os valores "típicos" de μ e σ no mercado acionário dos EUA estão na faixa de 16% ao ano (a.a) para o "drift" e 20 a 40% a.a. para a volatilidade. Em termos de mercado acionário brasileiro (e em outros mercados emergentes), a volatilidade costuma ser bem maior. Intuitivamente, volatilidade é uma medida da intensidade das flutuações de preços. Um ativo muito volátil é aquele que oscila muito - um pouco volátil apresenta variações de preços mais brandas. Logo, quanto mais volátil um ativo, maior a incerteza sobre o seu valor no futuro, e mais "imprevisível" será o ativo.

A necessidade de estimar a volatilidade para obter o "preço justo" de uma opção levou à criação de modelos bastante interessantes, como os GARCH e suas extensões. Os desenvolvimentos nesta área são tão importantes que o apenas o estudo destes modelos já justifica um curso em separado.

Uma forma simples (mas não muito eficiente) de estimar σ é através dos retornos passados. Isto nos leva à estimativa comumente chamada de "volatilidade histórica".

Seja R = ΔS/S o retorno no intervalo de tempo Δt. Note que Z em (7.1.10) é uma variável aleatória N(0,1) e assim o retorno é também uma variável Normal, com média $\mu.\Delta t$ e variância $\sigma^2.\Delta t$. Isto tem grandes implicações em termos de simulação de Monte Carlo, pois indica que os retornos são simulados facilmente, usando-se a distribuição Normal. Uma conseqüência é: dado um preço inicial e estimativas de μ e da volatilidade pode-se simular a trajetória dos preços através da equação (7.1.10).

Note que o retorno num intervalo de tempo Δt é $N(\mu.\Delta t, \sigma^2\Delta t)$. Por exemplo, suponha que o retorno esperado numa ação é 12% ao ano, e a volatilidade é 25% ao ano. Considere um período de tempo Δt = 5 dias = 5/365 ano. O essencial para que possamos simular um movimento Browniano geométrico é que o intervalo Δt seja pequeno. Assim, o retorno neste período é uma variável Normal com média 0.1644% e volatilidade 0.3425% ao ano (medida pelo desvio padrão). Logo: $R \sim N(0.1644\%, \sigma^2 = (0.3425\%)^2)$

O próximo gráfico exibe o histograma de 50 retornos gerados a partir desta densidade.

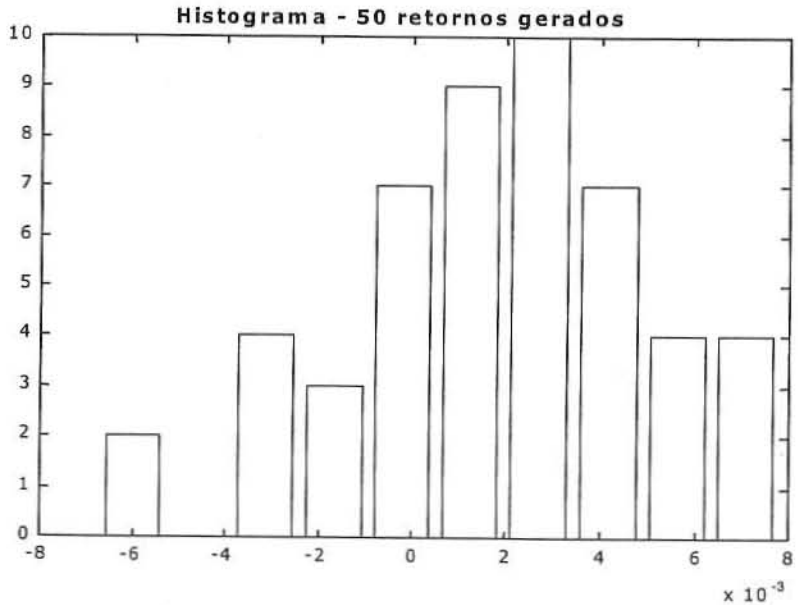

Note que este é o histograma dos retornos, e não dos preços. Como gerar preços? Suponha que o preço inicial é conhecido, por exemplo, R$100. Os 10 primeiros retornos gerados a partir da densidade $N(0.1644\%, (0.3425\%)^2)$ e os preços correspondentes são mostrados a seguir.

Instante t	Preço	Retorno (%)
0	100	
1	100.56	0.56
2	100.94	0.38
3	101.13	0.19
4	101.42	0.28
5	101.35	-0.07
6	102.11	0.75
7	102.29	0.18
8	103.09	0.78
9	103.35	0.25
10	103.82	0.46

O próximo gráfico apresenta os preços calculados a partir dos 50 retornos gerados.

Note que, neste exemplo, os preços crescem ao longo do tempo (50 "dias"). Entretanto, isto não é uma característica geral. Nos próximos gráficos exibimos mais 5 simulações de preços gerados a partir de retornos com a **mesma** distribuição Normal. Podemos notar que a trajetória dos preços é diferente em cada caso, mas em todos os casos o comportamento dos preços é bastante parecido com a evolução de preços reais. Um ponto fundamental aqui é: os preços gerados podem variar livremente, ou seja, eles não apresentam qualquer tendência de "volta" para um nível "médio" ou "de equilíbrio".

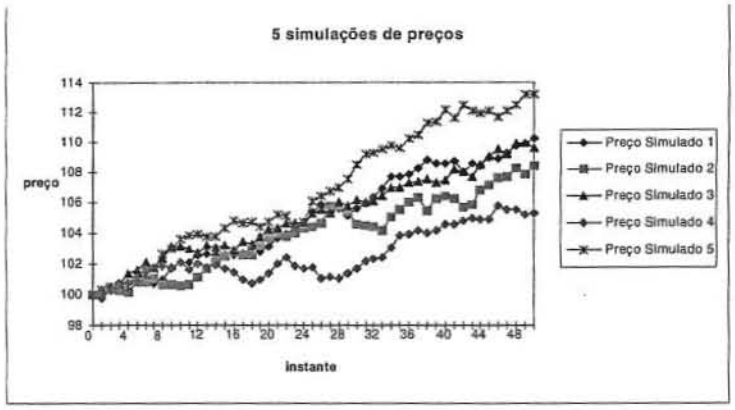

Em termos dos preços finais, existe uma razoável dispersão. Os 5 preços simulados no instante t = 50 são:

110.28	108.41	109.62	105.30	113.19

Os retornos calculados na simulação correspondem à expressão: $R = \Delta S/S$ onde ΔS é a variação nos preços num intervalo Δt. Freqüentemente usaremos o retorno logarítmico, definido como: $R_{(2)} = \log(S_t/S_{t-\Delta t})$. Os valores de R e $R_{(2)}$ são próximos se os retornos são pequenos em termos percentuais, o que normalmente ocorre quando o intervalo de tempo considerado é também pequeno.
O retorno logarítmico apresenta algumas vantagens sobre o retorno usual. Em particular, o uso do retorno logarítmico leva a uma distribuição de preços lognormal, como veremos posteriormente.

7.2. Introdução aos Derivativos

O que são derivativos?

Para muitas pessoas, a palavra "derivativos" indica uma coisa misteriosa! No entanto, os fundamentos sobre derivativos são bastante fáceis de entender, e você provavelmente já viu (ou usou) um "derivativo" (mesmo que tenha se referido a ele usando outro nome!).

A definição é bastante genérica: um derivativo é qualquer instrumento financeiro cujo preço depende do valor de um outro ativo subjacente. Logo, o retorno de um derivativo depende do retorno de um outro instrumento financeiro, o ativo objeto (por exemplo, uma ação). Em outras palavras, um derivativo é um contrato entre duas partes que especifica condições (por exemplo, datas, valores finais, fluxos de pagamentos) a serem obedecidas pelas partes envolvidas. Existe uma infinidade de instrumentos derivativos e inúmeras estratégias para seu uso, e aqui iremos nos concentrar nas variedades "triviais": contratos a termo, contratos futuros e opções.

E para que servem derivativos?

Existem dois usos típicos:
- Proteção ("hedge") contra variações desfavoráveis das condições do mercado;
- Alavancagem – possibilidade de "amplificar" ganhos (e também perdas, como muitos exemplos recentes mostram!).

Alguns exemplos de derivativos na vida real...

- Uma apólice de seguro de automóvel – ao contratar um seguro você faz uma seqüência de pagamentos para garantir a cobertura no caso de perda do bem subjacente (o próprio carro). Quando você compra uma apólice de seguro está comprando, na terminologia deste capítulo, uma **opção,** que lhe dá o direito de receber o valor do automóvel caso este tenha um acidente sério ou seja roubado.
- Um plano de aposentadoria – você paga uma quantia mensal para, numa data futura (por exemplo, aos 65 anos), receber de volta uma pensão.

Note que o pagamento de um derivativo é "contingente" (dependente) da ocorrência de um evento. Por exemplo, no caso do seguro de automóvel você só receberá o dinheiro se seu carro for roubado ou destruído.

Os derivativos existem há muito tempo, mas a grande "explosão" no seu uso decorreu do lançamento de derivativos puramente financeiros, em que os contratos referem-se a preços de ações, índices de ações, taxas de câmbio, taxas de juros etc... O mundo financeiro atual é um lugar arriscado, e o crescimento do uso dos derivativos surge à medida que são necessárias estratégias mais sofisticadas para enfrentar o risco nos diversos mercados.

Os ativos objeto que estão "por baixo" dos derivativos mais comuns (isto é, os ativos cujos preços afetam o preço dos derivativos usuais) podem ser colocados em quatro principais categorias:

- commodities,
- ações e índices de ações,
- instrumentos de renda fixa e
- moedas (e a relação entre elas, isto é, as diferentes taxas de câmbio)

Freqüentemente, no processo de análise de um derivativo é importante conhecer como os preços do ativo objeto evoluem. No caso de ações e índices de ações, uma hipótese usual é a de que os preços seguem um passeio aleatório. No caso de commodities, as regras que governam os preços são geralmente mais complexas, e muitas vezes é necessário olhar para o comportamento da demanda e oferta do produto para ganhar algum "insight" sobre o comportamento dos preços. No caso de instrumentos de renda fixa, embora os preços no curto prazo exibam grande incerteza, no "longo prazo" existe o retorno para um valor pré-definido no vencimento do título.

Mesmo que você não tenha a intenção de trabalhar no mercado financeiro, conhecer alguma coisa sobre derivativos é importante para o seu futuro profissional numa grande empresa. Na verdade, muitas operações com derivativos são feitas por grandes empresas, na busca por proteção ou lucros adicionais.

Por exemplo, a subsidiária financeira da General Electric perdeu US$ 1.2 bilhões em operações com derivativos no primeiro trimestre de 2001, enquanto o Citigroup e a IBM ganharam US$ 992 milhões e US$ 507 milhões, respectivamente (Jornal Gazeta Mercantil, 28 de maio de 2001). A IBM opera com 40 moedas diferentes, e apura seus resultados em dólares, e assim precisa estar protegida contra variações desfavoráveis destas 40 taxas de câmbio.

Fica patente a necessidade de desenvolver estratégias financeiras sofisticadas para lidar com os riscos a que estão sujeitas as empresas globais. Recentemente no Brasil, a crise energética criou oportunidades inéditas para empresas não financeiras, que poderão ser capazes de comercializar a energia elétrica excedente aos preços do MAE (mercado atacadista de energia). Em alguns casos, esta possibilidade torna-se mais lucrativa do que o próprio "core business" da empresa. As perdas e ganhos com derivativos nas empresas americanas têm sido divulgadas recentemente, como uma resposta à necessidade de maior transparência em seus balanços, demandada por novas regras da SEC (Securities and Exchange Comission, o "xerife" do mercado americano).

No Brasil, o mercado de derivativos é bastante desenvolvido e sofisticado, mas ainda existem restrições em termos de liquidez e do tamanho de mercado. Em especial, os mercados de câmbio e juros são relevantes (inclusive pelas sinalizações sobre comportamento futuro da economia), mas o mercado de opções tem sofrido uma certa redução nos últimos anos.

A grande maioria dos derivativos pode ser inserida em uma das seguintes categorias genéricas:

- contratos a termo;
- contratos futuros;
- opções;
- swaps.

Estes 4 tipos compõem os "tijolos" que servem para construir derivativos mais complicados, e todos os produtos mais novos podem ser encarados como adaptações dos 4 tipos básicos.

Um ponto importante acerca de derivativos é: eles são um jogo de "soma zero", ou seja, lucros e prejuízos totais para todas as partes envolvidas são zero, isto é, a soma de todos os lucros e prejuízos é zero.

A cada dia, novos derivativos (ou estratégias para seu uso) são inventados, e este processo é comumente chamado de Engenharia Financeira. Mas, como veremos neste capítulo, inventar derivativos pode ser uma tarefa fácil, mas precificá-los não é!

As perdas e lucros fantásticos observados nos últimos anos em mercados de derivativos têm sido amplamente divulgados na imprensa e em artigos técnicos. O leitor interessado pode consultar, por exemplo, Jorion (1996).

Posição Longa (Comprada)
Dizemos que estamos "comprados" num ativo quando nós o temos efetivamente. Note que só vale a pena estar comprado em algum ativo quando temos a expectativa de que seu preço vai subir.

Posição Vendida, Venda a Descoberto ("Short Sales")
Um ativo é vendido a descoberto quando são tomados emprestados e vendidos. O ato de "tomar emprestado" um ativo é um procedimento absolutamente legal, e paga-se por ele. Qual a sua expectativa quando você está vendido? Você vai ganhar dinheiro quando o preço do ativo cair.

Na venda a descoberto, é necessário devolver os ativos que foram tomados emprestado numa data futura.

Como funciona uma venda a descoberto?
1) Você toma emprestado (na verdade, paga um aluguel) a um investidor A que é o legítimo "dono" do ativo.
2) Em seguida, você pega os ativos que "pegou emprestado" e vende-os para o investidor B.
3) Em algum instante futuro, você precisará encerrar a sua posição vendida e devolver os ativos para o investidor A.

Uma maneira fácil de descrever um derivativo é através de um diagrama de "pay-off", no qual o eixo horizontal contém o preço do ativo objeto e o eixo vertical apresenta o valor do derivativo. Nesta seção apresentaremos os diagramas de "pay-off" para diversas estratégias com derivativos.

Um problema importante quando falamos em derivativos é: como encontrar seu preço justo? Para isso é fundamental dispor de ferramentas teóricas que nos permitam calculá-lo. Além disso, em qualquer estratégia envolvendo derivativos é fundamental determinar qual o risco envolvido, pois a possibilidade de ocorrência de catástrofes é real, como a prática tem mostrado nos últimos anos.

Nesta seção apresentaremos os tipos mais comuns de derivativos, e faremos uma breve introdução às estratégias mais comuns que os utilizam.

Definição 7.2.1. Contrato a Termo

Um contrato a termo ("forward contract") é um acordo em que duas partes se comprometem a comprar ou vender um determinado ativo numa data futura.

Em geral as partes envolvidas num contrato a termo são instituições financeiras, e estes contratos são customizados **("taylor-made")** de forma a satisfazer as necessidades das partes envolvidas. Normalmente contratos a termo não são negociados em bolsa, dadas as suas características específicas (não padronizadas), e portanto **em geral existe risco de crédito**, isto é, o risco de que a contraparte no contrato não efetue o pagamento acordado.

O "pay-off" de um contrato a termo é a diferença entre o preço do ativo objeto na data de entrega e o preço acordado entre as partes. No início do contrato, o preço na entrega é especificado de tal forma que o valor presente do contrato a termo é zero.

Num contrato a termo, uma das partes assume uma posição longa (comprada) e concorda em comprar o ativo objeto numa data futura especificada por um preço especificado. A outra parte assume uma posição vendida ("short") e se compromete a vender o ativo numa data futura especificada pelo preço acordado no contrato.

Deve-se notar que, na data inicial do contrato, o preço de entrega é escolhido de tal forma que o valor do contrato a termo seja zero para ambas as partes envolvidas, e assim não custa absolutamente nada tomar uma posição (comprada ou vendida) num contrato a termo.

Definição 7.2.2. Preço a Termo, "Forward Price"
A qualquer momento durante a "vida" do contrato, o preço de liquidação que faria o valor presente do contrato a termo igual a zero é chamado de preço a termo ("forward price"). No início do contrato (e possivelmente apenas nesta data) o preço de liquidação (exercício) e o preço a termo são iguais.

Logo, no início de um contrato a termo, o preço a termo (F) é exatamente igual ao preço de entrega da mercadoria (K). À medida que o tempo passa, o preço a termo se altera, enquanto K permanece fixo. Em geral, um aumento no preço à vista (preço spot) é acompanhado por um aumento no preço a termo.

É importante **diferenciar** o **preço** a termo do **valor** de um contrato a termo. Um contrato a termo é especificado de tal forma que o seu **valor**, no **instante inicial** seja **zero**. Seja T o instante em que o contrato a termo expira. Então, o valor de um contrato a termo na data T é: $S_T - K$.

Em qualquer instante t (menor ou igual a T), a relação entre o preço spot e o preço a termo é:

$$F = S.\ e^{r(T-t)} \qquad (7.2.1)$$

Onde:
- F é o preço a termo no instante t;
- S é o preço no mercado spot no instante t;
- r é a taxa de juros livre de risco com capitalização contínua.

Deve-se notar que, no Brasil, raramente usamos a taxa com capitalização contínua, portanto é preciso converter as taxas de juros compostos usuais para capitalização contínua (isto é, aquela em que os intervalos de tempo entre capitalizações são infinitesimais).

Ou seja, a equação (7.2.1) simplesmente diz que o preço a termo em qualquer instante é o preço spot no mesmo instante capitalizado à taxa r durante o intervalo de tempo que falta até o vencimento do contrato.

A partir de (7.2.1) e usando argumentos de arbitragem pode-se concluir (veja Hull, 1993) que o valor de um contrato a termo em qualquer instante t (anterior ao vencimento) é:

$$S - K.e^{-r(T-t)} \qquad (7.2.2)$$

Em particular, no instante de vencimento: $S = S_T$ e o valor do contrato a termo é $S_T - K$, como já mencionado. Também, no instante inicial o valor do contrato é zero, e então o preço a termo F é escolhido de forma a satisfazer esta condição. Assim, aplicando a equação (7.2.2) no instante inicial concluímos que $F = S.\ e^{r(T-t)}$, que é apenas a equação (7.2.1).

Logo, pela equação (7.2.1) concluímos que o preço a termo é completamente determinado pelos seguintes fatores:

- Preço do ativo objeto;
- Tempo até o final do contrato;
- Taxa de retorno livre de risco;

O preço a termo, dado pela equação (7.2.1), tem um uso importante: serve como sinalizador do movimento dos preços ao longo do tempo, ou seja, funciona como uma "lanterna" que aponta na direção do futuro. Freqüentemente (em especial nos mercados de energia), há uma grande volatilidade dos preços spot, mas os preços futuros são relativamente "bem comportados".

O "pay-off" de um contrato a termo na data de vencimento é:

Posição comprada: $S_T - K$
Posição vendida: $K - S_T$

Onde S_T é o preço spot do ativo na data de vencimento do contrato e K é o preço de entrega especificado no contrato.

Note que, como não custa nada entrar num contrato a termo, o ganho (ou perda) total do investidor é igual ao "pay-off".

Pay-off (Posição Comprada)

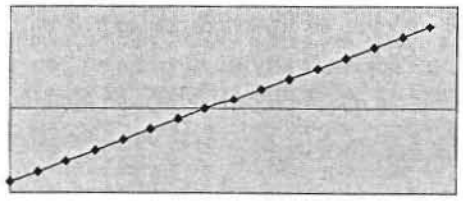

Pay-off (Posição Vendida)

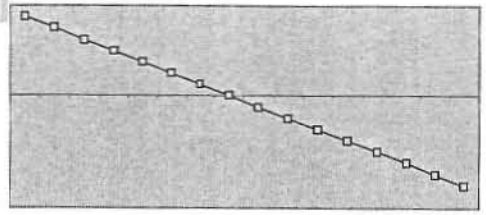

Definição 7.2.3. Contrato Futuro
Contratos futuros são semelhantes aos contratos a termo, mas existem diferenças importantes: são padronizados, negociados em bolsa e as diferenças (ganhos ou perdas financeiras) são apuradas diariamente. Também, nos contratos futuros existe um intermediário, a bolsa de futuros, e o risco de crédito é reduzido por causa da exigência do pagamento de margens de garantia.

É importante notar que, embora o valor total dos pagamentos efetuados nos contratos futuros e a termo seja o mesmo, o fluxo destes pagamentos é diferente, pois as diferenças são contabilizadas (e cobradas) diariamente no caso dos futuros, e apenas no vencimento do contrato (no caso de contratos a termo).

No caso de contratos futuros e a termo existe a **obrigação de ambas as partes**, e não existe como se livrar desta obrigação, a não ser que você repasse o contrato para alguém (o que é muito mais fácil no caso de contratos futuros, devido à sua padronização).

Especificação de um Contrato Futuro
Um contrato futuro é um instrumento padronizado, em que estão especificados:
- O ativo base em que é baseado o contrato;
- O tamanho do contrato;
- A qualidade do ativo a que se refere o contrato (muito importante no caso de commodities);
- Datas de vencimento;
- Local e data de entrega da mercadoria;
- Procedimentos de entrega da mercadoria;

- Limites de oscilação diária (impostos pela bolsa, para garantir que as margens depositadas pelos participantes sirvam como garantia).

Exemplo 7.2.4. Hedge com Contrato Futuro de Câmbio
Uma empresa americana adquiriu mercadorias de um fornecedor inglês valendo 1 milhão de libras, a serem pagas em 2 meses. O risco da empresa é a libra subir muito em relação ao dólar até a data de pagamento da mercadoria. A solução trivial para evitar este risco seria comprar 1 milhão de libras agora e "sentar em cima" do dinheiro. Mas, esta solução pode não ser viável, pois a empresa pode não ter 1 milhão de libras agora. Além disso, se a libra cai em relação ao dólar daqui a 2 meses a empresa poderia ter pago mais barato pelas mercadorias. A solução "inteligente" para reduzir o risco de flutuação da taxa de câmbio é comprar contratos futuros de libras. Desta forma, a empresa está protegida contra uma variação desfavorável da taxa de câmbio (protege-se se a libra subir em relação ao dólar) e esta proteção é obtida a um custo menor.

Exemplo 7.2.5. Hedge Usando Contrato Futuro de Índice de Ações)
Suponha que você administre uma grande carteira de ações, das quais não pretende se desfazer. Este é o caso típico de grandes investidores, como fundos de pensão. Imagine que a conjuntura política e econômica do país é incerta, e você teme que o preço das ações caia substancialmente. O que você faz? Se você não fizer nada, e apenas mantiver as ações em carteira, corre o risco de uma grande desvalorização do seu patrimônio. Como se proteger? Venda índice futuro de ações (o IBOVESPA futuro). O que acontece neste caso? Parte das suas perdas no mercado à vista são compensadas por ganhos no mercado futuro (lembre-se que você assumiu uma posição **vendida** no futuro).

Mercado de Opções
Os contratos de opções exibem uma diferença fundamental em relação aos contratos futuros ou a termo: nas opções existe uma **assimetria**, pois uma das partes tem direitos, a outra parte tem obrigações. A ponta compradora da opção detém o direito (e pagou por ele um prêmio), enquanto a ponta vendedora da opção tem a obrigação. Esta assimetria entre as duas "pontas" (compradora e lançadora da opção) leva a um fato interessante: enquanto não custa nada entrar num contrato futuro ou a termo, paga-se por um direito (ou recebe-se por uma obrigação assumida) no caso de uma opção. É importante observar que a ponta compradora da opção tem um direito, e pode ou não exercê-lo!

Deve-se notar que, em qualquer opção, o **preço de exercício** é especificado, e representa o preço pelo qual o ativo subjacente deve ser comprado ou vendido. Também, uma opção tem uma "vida" limitada, e expira numa data pré-especificada, a partir da qual os direitos que o comprador da opção detinha (e as respectivas obrigações do lançador da opção) não são mais válidas. Esta é a **data de vencimento** ou **data de exercício** da opção.

O **prêmio de uma opção** é o valor pago pelo comprador para assegurar o direito representado pela opção. Note que os prêmios de opções são geralmente

valores muito menores que os preços de exercício, e então, com relativamente poucos recursos é possível assumir posições neste mercado. Isto produz imensa capacidade de alavancar lucros, mas o risco envolvido é alto.

Definição 7.2.6. Opção de Compra
Uma opção de compra (*call*) dá ao seu comprador o direito de comprar um ativo por um preço especificado. O vendedor (ou lançador) da *call* tem a obrigação, na data de vencimento da opção (ou a qualquer momento, no caso de opções americanas) de entregar o ativo pelo preço especificado na opção (**preço de exercício da opção**).

Definição 7.2.7. Opção de Venda
Uma opção de venda (*put*) dá ao seu comprador o direito de vender um ativo por um preço especificado (preço de exercício), e o lançador (vendedor) da *put* tem a obrigação de comprar o ativo objeto pelo preço acordado.

Definição 7.2.8. Opção Européia
Uma opção européia pode ser exercida apenas na data de vencimento.

Definição 7.2.9. Opção Americana
Uma opção americana pode ser exercida a qualquer momento, e geralmente são mais difíceis de analisar que as opções européias.

Definição 7.2.10. Opções "in the money", "at the money" e "out of the money"

No caso de opções de compra:

- Uma opção está "in the money" se o preço atual do ativo é maior que o preço de exercício. Logo, neste caso, o comprador teria um ganho imediato se exercesse a opção. Por exemplo, suponha que você comprou uma call sobre uma ação com preço de exercício R$50. Se o preço da ação à vista hoje é R$60 você poderia exercer a opção (isto é, fazer com que a outra parte entregasse a ação por R$50) e poderia vender esta mesma ação à vista por R$60 e realizar um lucro imediato de R$10. Este é um exemplo excessivamente simplificado, não estamos considerando o valor do dinheiro no tempo e estamos supondo que a opção poderia ser exercida a qualquer momento.
- Uma *call* está "at the money" se o preço à vista é igual o preço de exercício da opção.
- Uma *call* está "out of the money" se o preço à vista é superior ao preço de exercício. Neste caso, no instante atual não valeria a pena, para o comprador, exercer a opção agora.

No caso de opções de venda:

- A opção está "in the money" se vale a pena para o comprador exercê-la agora, isto é, o preço à vista do ativo subjacente é menor que o preço de exercício. Por exemplo, o preço à vista é R$40, o preço de exercício da opção é R$50. Se você comprou uma *put* tem o direito de vender as ações por R$50, e se fizer isso, garantirá um lucro imediato de R$10 por ação, pois poderá exercer o direito (vender por R$50 uma ação que vale hoje R$40).

- A opção de venda está "at the money" se o preço à vista e o preço de exercício coincidem.
- A opção está "out of the money" se **não vale** a pena para o comprador exercê-la agora, isto é, no caso de uma *put*, o preço à vista está acima do preço de exercício.

Resultado 7.2.11. Paridade Entre o Preço de Uma *put* e o de Uma "Call"

A paridade entre os preços de uma *call* e de uma *put* (put-call parity) é uma equação que mostra a relação entre os preços de opções européias de compra e venda com exatamente as mesmas características. Esta relação pode ser derivada a partir da construção de um portfólio que contém uma *put* européia, o ativo objeto e no qual toma-se dinheiro emprestado. Pode-se mostrar que o "pay-off" deste portfólio é exatamente igual ao de uma *call* com a mesma data de vencimento e preço de exercício que a *put*.

Esta relação é importante do ponto de vista prático pois nos permite usar opções de compra e venda para criar posições sintéticas (por exemplo, uma posição vendida sintética). Uma posição sintética é um portfólio que reproduz as características de um instrumento financeiro de interesse. Por exemplo, no Brasil é às vezes difícil encontrar *puts* com as características desejadas pelo usuário. Logo, em vez de procurar uma *put* no mercado, cria-se uma sinteticamente.

A relação entre o preço de uma *put* e o de uma *call* (ambas **européias**) com as mesmas características (mesmo preço e data de exercício) é:

$$C - P = S - K.e^{-r(T-t)} \qquad (7.2.3)$$

Onde:

C = prêmio da *call*;
P = prêmio da *put*;
r = taxa de juros livre de risco com capitalização contínua;
S = preço à vista do ativo objeto hoje;
K = preço de exercício da opção;
t = instante atual;
T = instante de vencimento da opção.

A expressão (7.2.3) é encontrada usando argumento de arbitragem. A idéia básica é criar duas carteiras e deduzir que elas devem ter o mesmo preço para impedir oportunidades de ganhos livres de qualquer risco. O leitor interessado deve consultar Hull (1993).

Atenção:
A paridade entre *puts* e *calls* só é válida para opções européias. No caso de opções americanas é possível usar argumentos de arbitragem para encontrar limites inferiores e superiores para os seus prêmios.

A equação (7.2.3) deve ser modificada no caso da ação pagar dividendos durante a "vida" das opções. Seja D o valor atual dos dividendos esperados durante a "vida" da opção. Então a paridade entre opções de compra e de venda torna-se:

$$C - P = S - K.e^{-r(T-t)} - D \qquad (7.2.4)$$

Uma conseqüência imediata da equação (7.2.3) é: podemos criar uma opção de venda a partir de uma *call* com preço de exercício e vencimento idênticos, através de: $P = C + K.e^{-r(T-t)} - S$. Ou seja, uma *put* sintética é criada através da soma de 3 operações: 1) compra de uma *call*, 2) venda do ativo subjacente, 3) compra de K reais num título que renda a taxa livre de risco.

Posições em opções podem ser combinadas com posições no ativo objeto para criar hedges. Por exemplo, a estratégia que consiste em comprar o ativo objeto e vender uma "call" é chamada de "*call* coberta".
O efeito desta estratégia é semelhante à venda de um seguro. Uma outra estratégia (parecida com a compra de um seguro) é a "*put* protegida". Nela compra-se o ativo objeto e também uma put, de forma a obter um "hedge" contra queda no preço à vista.

Também podemos a relação entre "puts" e "calls" para verificar qual a taxa livre de risco que está sendo usada pelo Mercado para determinar o preço de opções. Para fazer isso basta resolver a equação (7.2.3) para r. Pares diferentes de "puts" e "calls" deveriam ter a mesma taxa livre de risco.

Talvez a implicação mais importante da paridade entre *puts* e *calls* seja o seu significado para determinar o preço de opções. Se olharmos com atenção para (7.2.3) podemos perceber que os únicos fatores determinantes da **diferença entre os preços** de *calls* e *puts* idênticas são:

- O preço atual do ativo objeto (S);
- O preço de exercício das opções (K);
- O tempo até o vencimento (T – t);
- A taxa livre de risco (r).

Embora possam existir outros fatores que determinem os preços de opções, estes fatores precisam afetar o preço de *calls* e *puts* na mesma direção e pela mesma quantidade. Por exemplo, a volatilidade certamente afeta o preço das opções, mas da relação de paridade entre *calls* e *puts* segue que. Qualquer aumento de volatilidade (que aumenta o valor da *call*) deve também aumentar o valor da *put* pela mesma magnitude.

Touros e Ursos (Bulls e Bears)
Na maioria dos livros americanos você vai encontrar referências a "bulls" e "bears", e estratégias classificadas como "bullish" e "bearish". O que isso quer dizer? Refere-se às perspectivas dos participantes do mercado. Você é um "bull" se aposta na subida dos preços, e é um "bear" se acredita na queda. Para lembrar que comportamento está associado a qual animal, pense na forma como touros e ursos atacam: um urso ("bear") move a pata de cima para baixo (daí o movimento de queda associado a ele), enquanto um touro ("bull") ataca movendo seus chifres de baixo para cima (movimento de alta). Como curiosidade, na porta da maior bolsa em Nova Iorque existe uma imensa estátua de um touro!

Estratégias Com Opções
A seguir, apresentamos algumas estratégias com opções, e o **gráfico do "pay-off"** (resultado) da estratégia **no vencimento** como função do preço do ativo objeto. Existem inúmeras outras estratégias, e as indicadas aqui são apenas as mais comuns.

A notação utilizada aqui e os valores usados para gerar os gráficos são:
S = preço da ação (ativo subjacente)
K = preço de exercício = R$100
C = prêmio da call = R$2
P = prêmio da *put*= R$2

Exemplo 7.2.12. Compra de Call

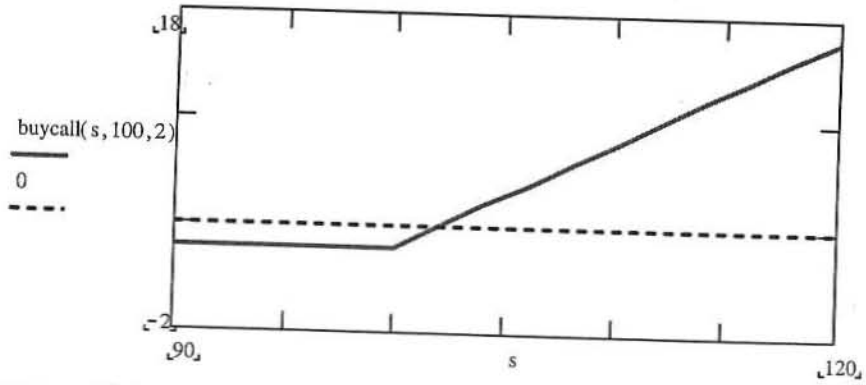

O "pay-off" da compra de uma *call* como função do preço do ativo objeto é:

Preço da Ação Objeto	Resultado da Compra da Call(K, C)
S <= K	-C (prêmio pago)

S > K	S – K – C

Note que nesta estratégia a perda potencial é limitada, e igual ao prêmio pago pela opção (C).

E quais seriam alguns dos motivos que levariam um investidor a comprar uma "call"?

- **Obter maior retorno (alavancar ganhos), pois com a mesma quantidade de dinheiro pode-se geralmente comprar um número de opções que corresponde a uma quantidade de ações bem maior que o mesmo volume de recursos poderia comprar no mercado à vista;**
- **Fixar o preço futuro de uma ação ou mercadoria.**

Exemplo 7.2.13. Venda de Call

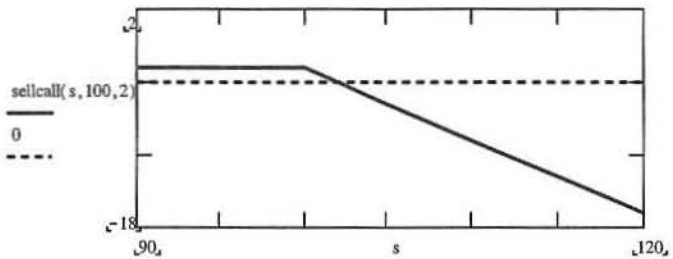

Ao lançarmos uma "call" o ganho potencial é limitado (e igual ao prêmio recebido pela opção) e a perda potencial é ilimitada. O "pay-off" da venda de uma *call* como função do preço do ativo objeto é:

Preço da Ação Objeto	Resultado da Venda da Call(K, C)
S <= K	+C (prêmio recebido)
S > K	K + C - S

Exemplo 7.2.14. (Compra de Put)

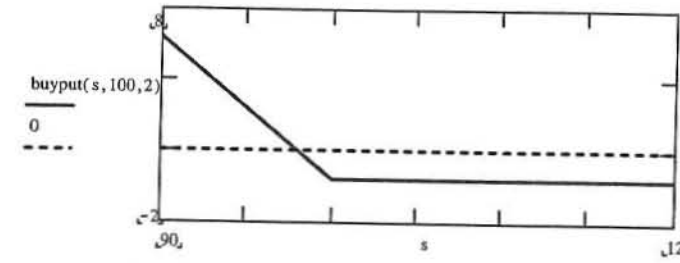

Na compra de uma *put* a perda potencial é limitada (e igual o prêmio pago pela opção) e o ganho potencial é ilimitado (e ocorre quando o preço do ativo objeto cai).

O "pay-off" da compra de uma *put* como função do preço do ativo objeto é:

Preço da Ação Objeto	Resultado da Compra da *Put*(K, P)
S <= K	K – S - P
S > K	- P (prêmio pago)

Exemplo 7.2.15. Venda de *Put*

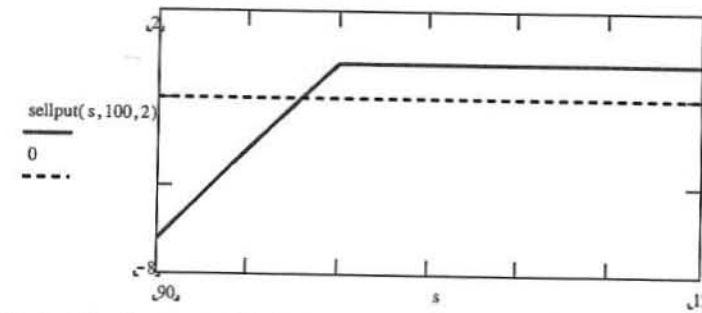

Na venda (lançamento) de uma *put*, o ganho potencial é limitado (e igual ao prêmio recebido pela opção) e a perda potencial é ilimitada, e ocorre quando há redução no preço do ativo objeto.

O "pay-off" da venda de uma *put* como função do preço do ativo objeto é:

Preço da Ação Objeto	Resultado da Compra da *Put*(K, P)

S <= K	- K + S + P
S > K	+ P (prêmio recebido)

Dos exemplos anteriores podemos concluir que:
- Na compra de uma opção existe um potencial de perda limitado e de ganhos ilimitados;
- Na venda (lançamento) de uma opção existe um potencial ilimitado de perdas e os ganhos são limitados (e iguais ao prêmio recebido).

Nos dois próximos exemplos exibimos estratégias que combinam posições no mercado à vista (ou seja, compra ou venda do ativo objeto) e no mercado de opções.

Exemplo 7.2.16. *Call* Coberta

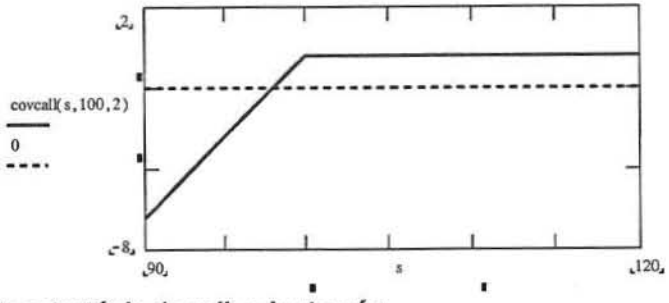

Na estratégia de *call* coberta nós:
- Compramos o ativo objeto;
- Lançamos uma *call*.

O diagrama de "pay-off" mostrado anteriormente indica que os lucros desta estratégia são iguais aos da estratégia de venda de uma *put*. Esta estratégia só resulta em lucro se a opção lançada for exercida, ou seja, deve ser aplicada quando mercado está em alta, ou quando o mercado começa a baixar e quer-se reduzir o custo das ações existentes na carteira.

Exemplo 7.2.17. *Put* Protegida

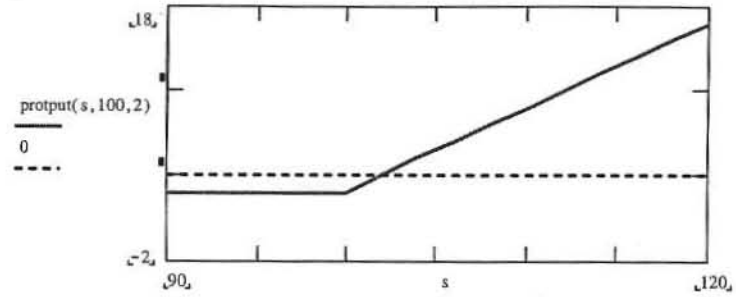

Para montar esta estratégia nós:
- Compramos o ativo objeto;
- Compramos uma *put*.

Se o preço do ativo objeto cai bruscamente, as perdas agora são limitadas pela compra da *put*.

Note que o "pay-off" desta estratégia é igual ao da compra de uma *call*.

Definição 7.2.18. "Spreads" ou Travas
Travas (ou "spreads") são estratégias que envolvem a tomada de posição em duas ou mais opções do mesmo tipo (isto é, duas ou mais *calls* ou duas ou mais *puts*). Nos "spreads" o investidor está comprado numa opção e vendido na outra, e as opções são idênticas em todos os sentidos, exceto no preço de exercício ou no tempo até o vencimento. Só o primeiro caso (diferentes preços de exercício) será considerado aqui.

Travas têm o efeito de reduzir substancialmente as perdas potenciais, mas também reduzem os lucros potenciais.

Existem dois tipos básicos de "spreads", mostrados a seguir.

Definição 7.2.19. Trava de Alta ou "Bull Spread"
Numa trava de alta, o investidor tem a expectativa de que os preços a vista subirão, mas quer uma perda limitada caso esta expectativa não se realize e o preço caia abruptamente.

A trava de alta ("bull spread") consiste em:
- Comprar (por R$C1) uma *call* com preço de exercício K1 e
- Vender (por R$C2) uma *call* com preço de exercício K2 *maior* que K1.

Ambas as opções usadas têm a mesma data de vencimento.

***Por que usar esta estratégia?* Suponha que você acredite que o preço do**

ativo objeto vai subir, mas quer limitar sua perda caso este preço caia. A compra de uma *call* serviria para fornecer algum tipo de proteção, mas se você imaginar que o preço da ação vai subir, mas não muito, todo o "upside" (possibilidade de lucro se a ação subir muito) que você poderia ter por comprar a *call* é pouco provável, de acordo com a sua avaliação. Logo, você poderia abrir mão destes ganhos extremos (e pouco prováveis na sua opinião). Você pode fazer isso através da venda de uma *call* com preço de exercício maior do que a *call* que foi comprada. Você ainda sofrerá perdas, pois a *call* comprada é mais cara que a vendida, mas sua perda (se o preço da ação cair) será reduzida por causa do prêmio recebido com a venda de uma *call*.

Note que nesta estratégia existe um desembolso inicial de dinheiro, pois a *call* que é comprada é mais cara que a *call* vendida, isto é, C1 é maior que C2.

A próxima tabela apresenta o resultado desta estratégia em detalhes.

Preço da Ação Objeto	Resultado da Compra da *Call* (K1, C1)	Resultado da Venda da *Call* (K2, C2)	Resultado Total da Estratégia "bull spread"
S <= K1	- C1	C2	-C1 + C2 (negativo!)
K1 < S < K2	S - K1 - C1	C2	S - K1 - C1 + C2
S > = K2	S - K1 - C1	K2 - S + C2	K2- K1 - C1 + C2

O diagrama de "pay-off" desta estratégia é mostrado a seguir. No gráfico supomos que a "call" comprada tem preço de exercício R$100, a "call" vendida tem preço de exercício R$105 e os prêmios destas opções são, respectivamente, R$6 e R$3.

A tabela de resultados para este exemplo é:

Preço da Ação Objeto	Resultado da Compra da Call(K1, C1)	Resultado da Venda da *Call* (K2, C2)	Resultado Total da Estratégia "bull spread"
S <= 100	- 6	+3	-3
100 < S < 105	S - 100 - 6	+3	S - 103
S > = 105	S - 100 - 6	105 - S + 3	+2

O diagrama de "pay-off" correspondente é:

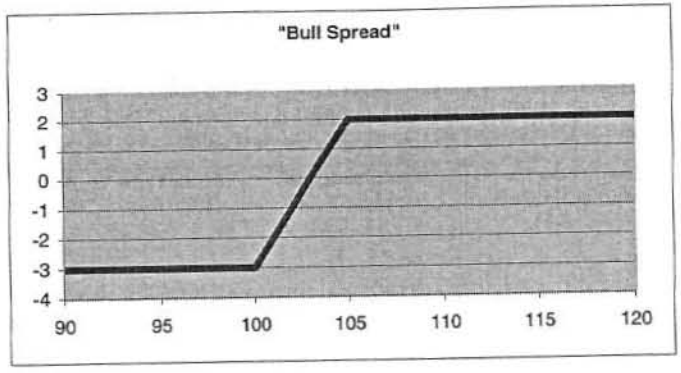

O resultado de um "bull spread" pode ser mais ou menos agressivo pela escolha dos preços de exercício das duas "call". Se S < K1 < K2, as duas opções estão "out of the money", e a construção do "spread" custa pouco (mas também tem menor chance de lucro). Se K1 < K2 < S, ambas as opções estão "in the money" e o spread custa mais caro (mas também tem maior probabilidade de lucro).

Pode-se também criar uma trava de alta usando *puts*. A estratégia é:
- Comprar *put*com preço de exercício K1, cujo prêmio é P1.
- Vender *put* com preço de exercício K2 maior que K1. O prêmio desta opção é P2, maior que P1.

Nesta estratégia lucra-se quando o preço da ação sobe, mas este lucro é limitado (assim como a perda). A estratégia "bull spread" usando opções de venda gera um recebimento inicial, ao contrário da trava de alta usando "calls" (que gera um desembolso inicial).

Definição 7.2.20. Trava de Baixa ou "Bear Spread"

Um investidor que usa a estratégia "bear spread" tem a expectativa de que o preço da ação objeto caia, e nesta situação ele realizará um lucro limitado. Mas, se o preço da ação subir, sua perda será também limitada.

A trava de baixa usando opções de compra consiste em:
- Comprar uma *call* com preço de exercício K2;
- Vender uma *call* com preço de exercício K1 < K2.

Ambas as *calls* referem-se à mesma data de exercício.
O prêmio da opção que está sendo comprada é menor do que o da opção que está sendo lançada, e portanto há um recebimento de dinheiro ao montar esta

operação. A única diferença entre esta estratégia e a trava de alta usando *calls* é que aqui o preço de exercício da opção que está sendo vendida é menor do que o preço de exercício da opção que está sendo comprada.

Lucra-se se o preço do ativo objeto cair, mas o lucro é limitado (assim como a perda potencial). A próxima tabela contém o resultado desta operação.

Preço da Ação Objeto	Resultado da Compra da *Call* (K2, C2)	Resultado da Venda da *Call* (K1, C1)	Resultado Total da Estratégia "bear spread"
S <= K1	- C2	+C1	C1 – C2 (positivo)
K1 < S < K2	-C2	+K1 + C1 - S	K1 + C1 –S - C2
S >= K2	S – K2 – C2	+K1 + C1 - S	K1 + C1 – K2 – C2

O gráfico a seguir exibe o resultado desta estratégia usando a compra de uma call (K2, C2) = (105, 3) e a venda de uma call (K1, C1) = (100,6).

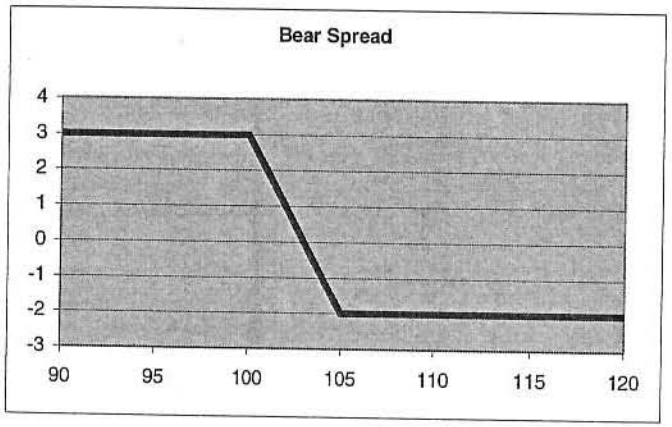

Pode-se também montar uma trava de baixa usando "puts". A idéia é comprar uma *put* com preço de exercício K1 e vender uma *put* com preço de exercício K2 maior que K1. A opção que está sendo comprada tem maior prêmio (P1) que aquela sendo vendida (P2), portanto há um desembolso inicial de dinheiro na montagem da estratégia. Analogamente à trava de baixa com "calls", lucra-se quando o preço do ativo objeto cai, mas os lucros e perdas são limitados.

Definição 7.2.21. "Butterfly"
Um spread "butterfly" é uma estratégia formada pelo uso de 3 *calls* com o mesmo vencimento e preços de exercício diferentes. Nesta estratégia existe um pequeno desembolso inicial, e as perdas ocorrem se existe variação significativa do preço do ativo objeto em qualquer direção. Logo, é uma estratégia apropriada apenas em momentos de baixa volatilidade no mercado.

A estratégia é criada através das seguintes operações:

- Compra de *call* com preço de exercício K1 relativamente baixo.
- Venda de duas *calls* com preço de exercício K2 > K1. Este preço de exercício K2 geralmente é próximo do preço atual do ativo objeto (S).
- Compra de *call* com preço de exercício K3 > K2 > K1.

Preço da Ação Objeto	Resultado da Compra da *Call* (K1, C1)	Resultado da Venda das 2 *Calls* (K2, C2)	Resultado da Compra da *Call* (K3, C3)	Resultado Total da Estratégia "butterfly spread"
S <= K1	- C1	+ 2. C2	- C3	2.C2 - C1 – C3
K1 < S < K2	S – K1 – C1	+2.C2	- C3	S – K1 – C1 +2.C2 – C3
K2 <= S < K3	S – K1 – C1	2.(K2+ C2 – S)	- C3	-S + 2.K2 – K1 + 2.C2 – (C1+C3)
S >= K3	S – K1 – C1	2.(K2+ C2 – S)	S – K3 – C3	2.K2 – (K1 + K3) +2.C2 – (C1+C3)

Exemplo 7.2.22. "Pay-off" de uma Estratégia "Butterfly"
Suponha que, numa certa data, montamos uma estratégia butterfly com as seguintes opções.

- Comprar *call* com preço de exercício 100 e prêmio 10;
- Vender 2 *calls*, ambas com preço de exercício 105 e prêmio 7;
- Comprar call com preço de exercício 110 e prêmio 5;

O "pay-off" desta estratégia no vencimento das opções é:

Preço da Ação Objeto	Resultado da Compra da *Call* (K1, C1)	Resultado da Venda das 2 *Calls* (K2, C2)	Resultado da Compra da *Call* (K3, C3)	Resultado Total da Estratégia "butterfly spread"
S <= 100	- 10	+14	- 5	-1
100 < S < 105	S – 10 - 100	+14	-5	S - 101
105 <= S < 110	S – 10 - 100	210 -2. S + 14	-5	109 - S
S > 110	S -10 – 100	210 – 2.S + 14	S – 5 - 110	-1

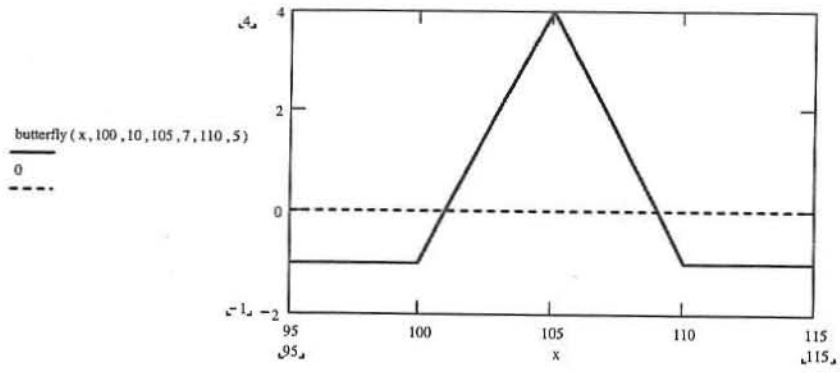

Estratégias Envolvendo "Puts" e "Calls" Simultaneamente (Combinações)
Em vez de comprar e vender *calls* (ou *puts*) pode-se criar estratégias que combinam os dois tipos de opções. Estas estratégias são chamadas de **combinações**. Se a *call* e a *put* têm o mesmo preço de exercício, esta estratégia é chamada de **"straddle"**. Se os preços de exercício da *call* e da *put* são diferentes, a estratégia é um **"strangle"**. Estas duas estratégias são apropriadas quando o investidor acredita que o preço do ativo objeto pode sofrer variações consideráveis, mas não consegue prever em que direção, ou seja, use um "straddle" ou um "strangle" quando você acreditar que a volatilidade do mercado permanecerá alta.

Outras posições (straps, strips, butterfly, condor, box etc...) envolvem mais de duas opções e seus pay-offs têm bastante flexibilidade.

Definição 7.2.23. "Straddle"
Um "straddle" é uma estratégia que envolve opções de compra e venda simultaneamente. Esta estratégia consiste em:
- Comprar uma *call* com preço de exercício K1;
- Comprar uma *put* com a mesma data de vencimento e preço de exercício.

O "straddle" é uma estratégia em que se lucra quando existem variações grandes de preço, ou seja, em momentos de alta volatilidade.

Preço da Ação Objeto	Resultado da Compra da *Call* (K1, C1)	Resultado da Compra da Put (K1, P1)	Resultado Total da Estratégia "straddle"
S <= K1	- C1	K1 - S - P1	K1 - (S + C1 + P1)
S > K1	S - K1 - C1	- P1	S - (K1 + C1 + P1)

O "pay-off" desta estratégia é mostrado a seguir, supondo que o preço de exercício é K1 = 102 e os prêmios da "call" e *put* são, respectivamente, 2 e 1.8.

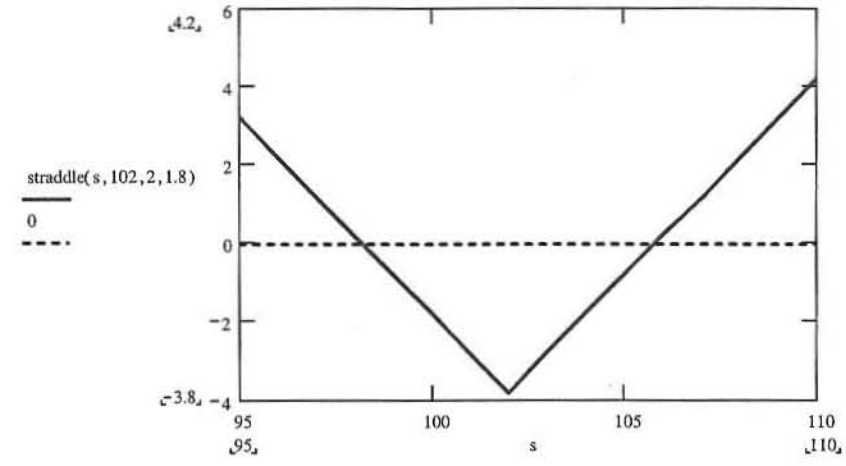

A estratégia mostrada acima é também chamada de "bottom straddle". Um "top straddle" é a estratégia reversa, onde o investidor vende ambas as opções com o mesmo preço de exercício. O "top straddle" é uma estratégia extremamente arriscada, onde o lucro é obtido se o preço do ativo objeto no vencimento for muito próximo do preço de exercício das opções vendidas.

Definição 7.2.24. "Strangle"

Um "strangle" é uma estratégia semelhante a um "straddle". O investidor acredita que os preços estão sujeitos a altas variações, mas não sabe em qual direção. O preço da ação tem que variar mais num "strangle" que num "straddle" para garantir o lucro do investidor, mas também a perda potencial de um "strangle" é menor que a do "straddle" se os preços não variam muito em relação ao preço de exercício usado na montagem da estratégia.

Monta-se um "strangle" da seguinte forma:

- Compra-se uma *call* com preço de exercício K1;
- Compra-se uma *put* com a mesma data de vencimento mas com um preço de exercício diferente, K2, **menor que K1.**

O grau de proteção contra mudanças desfavoráveis nos preços (isto é, baixa volatilidade) depende da proximidade entre os preços de exercício K1 e K2. Quanto mais longe um do outro estão estes preços, menor a perda potencial, mas também maior é a variação no preço do ativo objeto necessária para que a estratégia seja lucrativa.

Preço da Ação Objeto	Resultado da Compra da Call (K1, C1)	Resultado da Compra da Put (K2, P2)	Resultado Total da Estratégia "strangle"
S <= K2	- C1	K2 - S - P2	K2 - (S + C1 + P2)
K2 < S <= K1	- C1	- P2	- C1 - P2
S > K1	S - K1 - C1	- P2	S - (K1 + C1+ P2)

O "pay-off" desta estratégia é mostrado a seguir, supondo que o preço de exercício da *call* é K1 = 105, o preço de exercício da *put* é K2 = 100 e os prêmios da *call* e *put* são, respectivamente, 2 e 1.5.

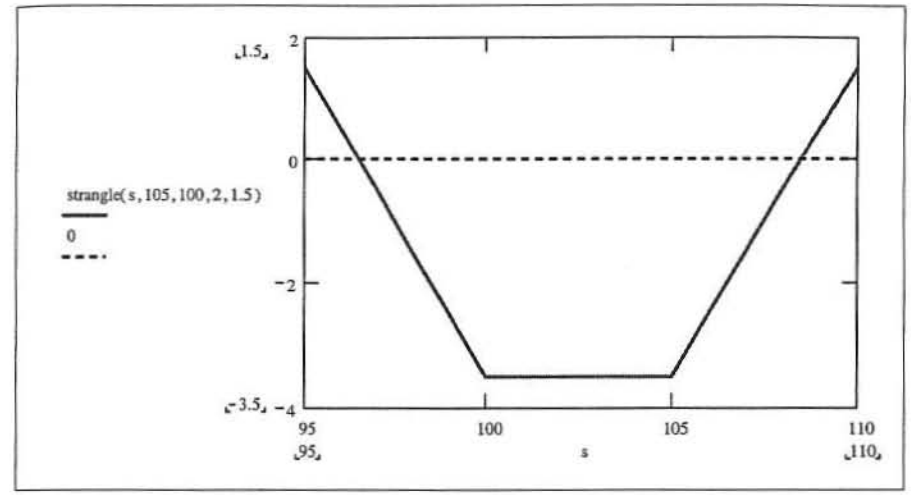

Definição 7.2.25. "Strap"
Um "strap" é semelhante a um "straddle" - a diferença é que no straddle utilizamos apenas uma *call*, enquanto no "strap" compramos **duas *calls*** e **uma *put*** com o mesmo vencimento e preço de exercício que a *call*. Logo, a estratégia "strap" consiste em:

- Comprar **duas** *calls* com preço de exercício K1;
- Comprar **uma** *put* com a mesma data de vencimento e preço de exercício.

O "strap" (como o "straddle") é uma estratégia que gera lucros quando existem variações grandes de preço em ambas as direções. Mas, ao optar por um "strap", o investidor acredita que um aumento no preço do ativo objeto é mais provável que uma queda.

Preço da Ação Objeto	Resultado da Compra das duas *Calls* (K1, C1)	Resultado da Compra da *Put* (K1, P1)	Resultado Total da Estratégia "strap"
S <= K1	- 2.C1	(K1 - S - P1)	K1 - (S + 2.C1 + P1)
S > K1	2.(S - K1 - C1)	- P1	2.(S - K1 - C1) - P1

O "pay-off" desta estratégia é mostrado a seguir, supondo que o preço de exercício é K1 = 102 e os prêmios da *call* e *put* são, respectivamente, 2 e 1.8. Compare-o com o resultado do "straddle" com os mesmos parâmetros.

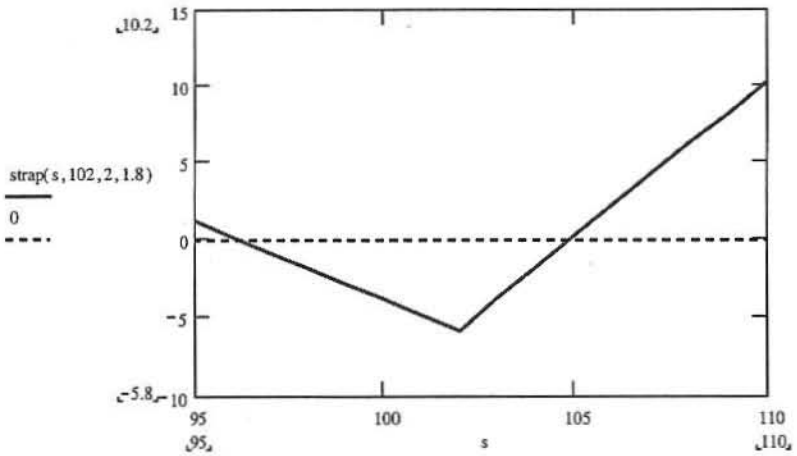

Definição 7.2.26. "Strip"
Um "strip" é semelhante a um "straddle" – a diferença é que o straddle utiliza apenas uma *put*, enquanto no "strip" compramos uma *call* e compramos também **duas** *puts* com mesmo vencimento e preço de exercício que a *call*. Logo, a estratégia "strip" consiste em:

- Comprar uma *call* com preço de exercício K1;
- Comprar **duas** *put* com a mesma data de vencimento e preço de exercício.

O "strip" (como o "straddle") é uma estratégia em que se lucra quando existem variações grandes de preço, ou seja, em momentos de alta volatilidade. No entanto, ao optar por um "strip", o investidor acredita que uma queda no preço do ativo objeto é mais provável que um aumento.

Preço da Ação Objeto	Resultado da Compra da *Call* (K1, C1)	Resultado da Compra das duas *Puts* (K1, P1)	Resultado Total da Estratégia "strip"
S <= K1	- C1	2.(K1 - S - P1)	2.K1 - (2.S + C1 + 2.P1)
S > K1	S - K1 - C1	- 2.P1	S - K1 - C1 - 2.P1

O "pay-off" desta estratégia é mostrado a seguir, supondo que o preço de exercício é K1 = 102 e os prêmios da "call" e *put* são, respectivamente, 2 e 1.8. Compare-o com o resultado do "straddle" com os mesmos parâmetros.

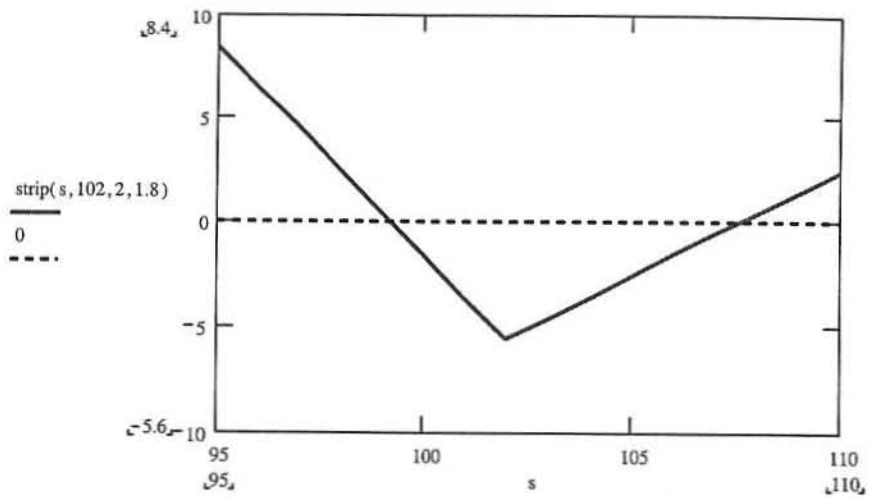

No gráfico a seguir, apresentamos os resultados de um "straddle", um "strip" e um "strap" com os mesmos parâmetros, para efeito de comparação.

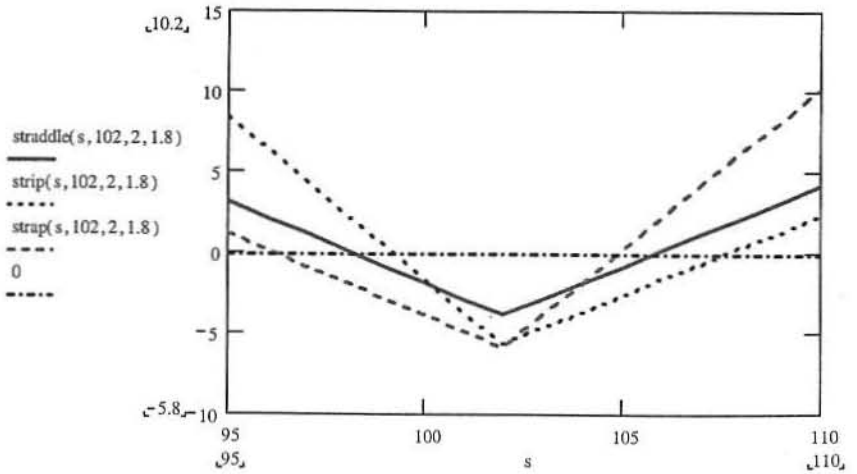

Definição 7.2.27. "Box 4"
Um "box fechado" ou "box 4" é uma combinação de opções que tem o efeito de transformar renda variável em fixa. Nesta estratégia usamos opções com dois preços de exercício diferentes, e o "box 4" equivale a uma trava de alta usando *calls* somada à uma trava de baixa usando *puts*. Para criar a estratégia "box 4" devemos:

- Comprar uma *call* com preço de exercício K1 (e prêmio C1);
- Vender uma *call* com preço de exercício K2 (e prêmio C2) onde K2 > K1;
- Comprar uma *put* com preço de exercício L1 (e prêmio P1);
- Vender uma *put* com preço de exercício L2 (e prêmio P2), onde L2 < L1.

Existe um desembolso de dinheiro na montagem da operação, pois C1 > C2 e P1 > P2 mas o retorno da operação é retorno é fixo.

Quando se deve usar esta estratégia? Quando a taxa de juros obtida na operação (que equivale a uma operação de renda fixa) for superior à taxa de juros livre de risco vigente no mercado.

Para simplificar o diagrama de "pay-off" consideramos a seguir uma estratégia "box 4" com apenas 2 preços de exercício, K1 e K2. Logo, o box 4 torna-se:

- Comprar uma *call* com preço de exercício K1 (e prêmio C1);
- Vender uma *call* com preço de exercício K2 (e prêmio C2) onde K2 > K1;
- Comprar uma *put* com preço de exercício K2 (e prêmio P1);
- Vender uma *put* com preço de exercício K1 (e prêmio P2).

Preço da Ação Objeto	Resultado da Compra da Call (K1, C1)	Resultado da Venda da Calls (K2, C2)	Resultado da Compra da *Put* (K2, P1)	Resultado da Venda da *Put*(K1, P2)	Resultado Total da Estratégia "Box 4"
S <= K1	- C1	+ C2	K2 - S - P1	S + P2 - K1	(C2 - C1) + (K2 - K1) + (P2 - P1)
K1 < S < K2	S - K1 - C1	+C2	K2 - S - P1	+ P2	(C2 - C1) + (K2 - K1) + (P2 - P1)
S >= K2	S - K1 - C1	(K2 + C2 - S)	- P1	+ P2	(C2 - C1) + (K2 - K1) + (P2 - P1)

Note que o resultado da estratégia no vencimento é um valor fixo, que não depende do preço da ação objeto.

O "pay-off" do "box 4" é mostrado a seguir, supondo que os preços de exercício são K1 = 98, K2 = 113, C1 = 1.5, C2 = 0.5, P1 = 14 e P2 = 10.

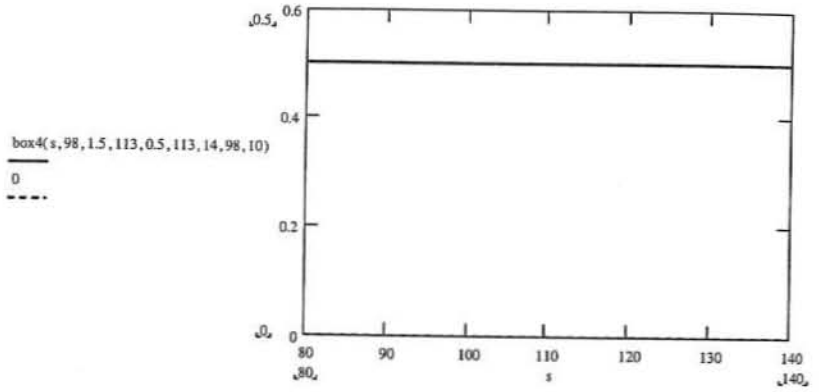

Limites para os preços de opções

Nas próximas seções iremos encontrar o "preço justo" de uma opção usando modelos estatísticos. No entanto, muitos resultados importantes a respeito destes preços podem ser derivados a partir de argumentos simples de arbitragem, sem recorrer a qualquer modelo específico. A partir destes argumentos de arbitragem podemos encontrar limites superiores e inferiores para C e P. A seguir, exibimos alguns dos limites existentes para preços de opções; esta lista não é exaustiva e certamente pode-se derivar muitos outros resultados. O leitor interessado na derivação pode consultar Benninga (1998) ou Hull (1993).

Proposição 1 (limite inferior para o preço de uma "call")

$$C \geq \max\left(S - K.e^{-r(T-t)}, 0\right)$$

onde C é o prêmio da *call* com preço de exercício K, que vence no instante T e cujo ativo objeto tem hoje o preço S.

Proposição 2
O exercício antecipado de uma opção de compra americana que se refere a uma ação que não paga dividendos não é ótimo. Ou seja, é melhor um investidor manter sua *call* americana em carteira do que exercê-la antecipadamente.

Proposição 3 - Limite Inferior Para o Preço de uma *put* Americana

$$P \geq \max\left(K.e^{-r(T-t)} - S, 0\right)$$

O que afeta o preço de uma opção?

Existem 5 variáveis que afetam o preço de uma opção:

1) O preço do ativo objeto;
2) O preço de exercício da opção;
3) O tempo até o vencimento da opção;
4) A taxa livre de risco no mercado;
5) A volatilidade do ativo objeto.

Dentre estas variáveis, o efeito mais difícil de mensurar talvez seja o do tempo até o vencimento, pois ele também afeta indiretamente a volatilidade e a taxa livre de risco.

E como são os efeitos de cada uma destas variáveis sobre o preço das opções? Suponha, na discussão a seguir, que apenas uma variável é alterada, e as outras são mantidas fixas.

- Efeito do preço do ativo objeto
  - Se o preço do ativo objeto aumenta, o valor da *call* aumenta e o da *put* diminui.
- Efeito do preço de exercício
  - Quanto maior o preço de exercício, menor o valor da *call* e maior o valor da *put*.
- Efeito da volatilidade
  - Aumentos de volatilidade aumentam os valores da opções.

O efeito de cada uma destas variáveis será estudado em mais detalhes na seção 7.5., quando apresentarmos o modelo de Black e Scholes.

7.3. O Lema de Itô

Um dos resultados matemáticos mais usados em Finanças é o Lema de Itô. O matemático japonês Itô derivou este resultado na década de 50, mas este modelo só ganhou notoriedade na literatura financeira a partir de 1973, quando Black e Scholes descobriram que ele poderia ser usado para encontrar o preço justo de uma opção.

Vamos tentar descrever o Lema de Itô de uma forma bastante simplificada e sem grande formalismo matemático. Uma idéia básica aqui é expandir uma função em série de Taylor.

Considere o caso mais simples, em que F(x) é uma função de apenas uma variável, e suponha que expandimos F(.) numa série de Taylor em torno do ponto x_0. Então F(x) pode ser escrita como:

$$F(x) = F(x_0) + (x - x_0)\frac{dF(x)}{dx}\bigg|_{x = x_0} + \frac{1}{2}(x - x_0)^2 \frac{d^2F(x)}{dx^2}\bigg|_{x = x_0} + \ldots.$$

Sejam $\Delta x = x - x_0$ e $\Delta F = F(x) - F(x_0)$. Então a expressão anterior nos diz que:

$\Delta F = \Delta x.(dF/dx) + (1/2).\ \Delta x^2.(d^2\ F/dx^2) + \ldots.$ onde as derivadas são avaliadas em x_0.

No limite quando x tende a x_0 (isto é, Δx tende a zero) encontramos:

$$dF = dx\left(\frac{dF}{dx}\right) + \frac{1}{2}\left(\frac{d^2F}{dx^2}\right)(dx)^2 + \ldots. \qquad (7.3.1)$$

Suponha agora que F é uma função de duas variáveis, X e t. Então, o análogo bidimensional da equação (7.3.1) é:

$$dF = dX\left(\frac{\partial F}{\partial X}\right) + dt\left(\frac{\partial F}{\partial t}\right) + \frac{1}{2}\left(\frac{\partial^2 F}{\partial X^2}\right)(dX)^2 + \frac{1}{2}\left(\frac{\partial^2 F}{\partial t^2}\right)(dt)^2 + \left(\frac{\partial^2 F}{\partial X \partial t}\right)(dX.dt)\ldots. \qquad (7.3.2)$$

Mas, **se k é uma potência maior que 1 então dt^k tende a zero**. Daí, em (7.3.2) temos $(dt)^2 \to 0$, $(dX)^2 \to 0$ e $(dX.dt) \to 0$ e a expressão (7.3.2) se reduz a:

$$dF = dX\left(\frac{\partial F}{\partial X}\right) + dt\left(\frac{\partial F}{\partial t}\right) \qquad (7.3.3)$$

A expressão (7.3.3) é usualmente conhecida como "Teorema Fundamental do Cálculo".

No cálculo "usual" (não estocástico) todas as variáveis são determinísticas, ou seja, quando falamos sobre um valor em particular de X, sabemos exatamente quem é este valor. No cálculo estocástico não podemos mais falar sobre um valor em particular para X, ou seja, precisamos pensar num conjunto de valores possíveis de X.

Agora suponha que **X é estocástico e segue um processo de Itô, isto é: $dX = a(X,t).dt + b(X,t).dW$** onde W é um processo de Wiener, $dW = Z.\sqrt{dt}$ e Z é uma variável N(0,1). Ambos o deslocamento médio a(X,t) e a variância por unidade de tempo b^2 (X,t) se alteram à medida que o processo evolui.

Suponha que estamos interessados numa função "bem comportada" de X e t, onde agora X é estocástico (na verdade, X é o processo de Itô descrito acima) e t é determinístico. Como se comporta a expansão de Taylor de F? Note que o limite de $(dt)^2$ é ainda zero pois t não é estocástico. Mas, $(dX)^2$ não é mais zero pois dW é uma variável Normal com média zero e variância dt, e assim $(dW)^2 = (dt).Z^2$ onde Z^2 é uma variável aleatória com distribuição Qui-Quadrado com 1 grau de liberdade.

Note que o termos $(dW)^2$ **não vai para zero** quando tomamos o limite, e esta é uma das diferenças fundamentais entre o resultado obtido a partir do cálculo determinístico usual e do cálculo estocástico. A média de $(dW)^2 = (dt).Z^2$ é dt (pois $E(Z^2) = 1$) e a variância de $(dW)^2$ tem ordem $(dt)^2$ (e vai para zero no limite) e portanto o termo $(dW)^2$ torna-se não estocástico e igual ao seu valor esperado (dt) no limite. Também, o limite de dX.dt é zero pois o limite de dW.dt é zero.

$$dF = dX\left(\frac{\partial F}{\partial X}\right) + dt\left(\frac{\partial F}{\partial t}\right) + \frac{1}{2}(dX)^2\left(\frac{\partial^2 F}{\partial X^2}\right) \qquad (7.3.4)$$

A expressão (7.3.4) é a forma mais simples do Lema de Itô.

Além disso, $(dX)^2 = (a(X,t))^2.(dt)^2 + (b(X,t))^2.(dW)^2 + 2.a(X,t).b(X,t).\ dt.dW =$ $= (a(X,t))^2.(dt)^2 + (b(X,t))^2.(dt) + + 2.a(X,t).b(X,t).\ dt.dW$, pois $(dW)^2 = dt$. Também $dt.dW = Z.(dt)^{3/2}$ e este termo vai a zero no limite. Assim, no limite, $(dX)^2$ se reduz a $(b(X,t))^2.(dt)$.

Combinando estes resultados com a expressão (7.3.4) encontramos:

$$dF = dX\left(\frac{\partial F}{\partial X}\right) + dt\left(\frac{\partial F}{\partial t}\right) + \frac{1}{2}(b(X,t))^2\left(\frac{\partial^2 F}{\partial X^2}\right)(dt) \qquad (7.3.5)$$

A expressão (7.3.5) é conhecida como Lema de Itô, e é às vezes chamada de Teorema Fundamental do Cálculo Estocástico!

Note que (7.3.5) pode ser comparada à regra de cadeia no cálculo usual, e neste contexto devemos observar que (7.3.5) contém um termo extra, dado por: $\frac{1}{2}(b(X,t))^2\left(\frac{\partial^2 F}{\partial X^2}\right)(dt)$.

Podemos substituir as expressões para dX na expressão (7.3.5), o que leva a:

$$dF = (a(X,t)dt + b(X,t)dW)\left(\frac{\partial F}{\partial X}\right) + dt\left(\frac{\partial F}{\partial t}\right) + \frac{1}{2}(b(X,t))^2\left(\frac{\partial^2 F}{\partial X^2}\right)(dt) = \qquad (7.3.6)$$

$$= dt\left(\frac{\partial F}{\partial t} + a.\frac{\partial F}{\partial X} + \frac{1}{2}b^2.\frac{\partial^2 F}{\partial X^2}\right) + dW\left(b.\frac{\partial F}{\partial X}\right)$$

Onde a = a(X,t) e b = b(X,t).

Note que a expressão (7.3.6) nos diz uma coisa **importante**: F é também um processo de Itô, mas agora o deslocamento médio é:

$$\frac{\partial F}{\partial t} + a.\frac{\partial F}{\partial X} + \frac{1}{2}b^2.\frac{\partial^2 F}{\partial X^2}$$

e a variância por unidade de tempo é $b^2\left(\frac{\partial F}{\partial X}\right)^2$.

Por que esta expressão é importante na prática? Suponha que X indica o preço de uma ação. Então (7.3.6) no permite encontrar o processo estocástico que rege qualquer função do preço da ação. Note também que F e X são afetados pela mesma "fonte" de incerteza, a saber, o processo de Wiener dW. Na prática, F(X,t) representa o preço de um derivativo, que é uma função do tempo (t) e do preço do ativo objeto (X). Se o preço do ativo objeto evolui de acordo com um processo de Itô, então o preço de qualquer derivativo também segue um processo de Itô.

Mas, na prática ainda precisamos de alguns truques para podermos precificar um derivativo. A idéia básica é remover a incerteza representada por dW através da criação de um portfólio contendo opções e o ativo objeto. Isso nos permite transformar a equação (7.3.6) numa equação de derivadas parciais não estocástica, que muitas vezes tem uma solução fechada.

O lema de Itô é, na verdade, muito mais geral do que o que foi mostrado aqui, e pode ser derivado no caso de múltiplas variáveis estocásticas correlacionadas. O leitor interessado pode consultar alguma das referências sobre processos estocásticos em Finanças apresentadas na bibliografia.

Exemplo 7.3.1.
Suponha que o preço de uma ação, S, seja modelado pelo processo de Itô dado pela equação (7.1.8), isto é:
$dS = \mu.S.dt + \sigma.S.dW = \mu.S.dt + \sigma.S.Z.\sqrt{dt}$

Considere o preço a termo F, dado por:
$F = S.e^{r(T-t)}$

onde T é a data de vencimento.
Então:

$$\frac{\partial F}{\partial S} = e^{r(T-t)},\ \frac{\partial^2 F}{\partial S^2} = 0,\ \frac{\partial F}{\partial t} = -r.S.e^{r(T-t)}$$

Do lema de Itô concluímos que F segue o processo:

$$dF = dt\left(\frac{\partial F}{\partial t} + \mu.S.\frac{\partial F}{\partial S} + \frac{1}{2}\sigma^2.S^2.\frac{\partial^2 F}{\partial S^2}\right) + dW\left(\sigma.S.\frac{\partial F}{\partial S}\right) =$$
$$= dt\left(-r.S.e^{r(t-t)} + \mu.S.e^{r(t-t)} + 0\right) + dW\left(\sigma.S.e^{r(t-t)}\right) =$$
$$= dt\left(-r.F + \mu.F\right) + dW\left(\sigma.F\right) =$$
$$= (\mu - r)Fdt + \sigma.F.dW$$

Ou seja, da mesma maneira que S, F também segue um processo de Itô, mas agora a taxa de crescimento esperada é $(\mu - r)$ em vez de μ.

7.4. Modelo Binomial

O modelo binomial talvez possa ser considerado como a maneira mais flexível, intuitiva e popular de precificar uma opção. Este modelo é construído a partir de uma hipótese básica: num único período de tempo (por exemplo, entre os instantes t e t + Δt) o preço do ativo objeto pode se mover do valor atual para apenas dois valores possíveis.

Dentre outras virtudes, o modelo binomial inclui as hipóteses de inexistência de possibilidades de arbitragem. Na verdade, a fórmula de Black e Scholes pode ser pensada como um caso particular do modelo binomial com um número infinito de períodos aplicado às opções européias.

Existem inúmeros usos de modelos binomiais em Finanças, e descobrir o preço "justo" de uma opção, ou determinar a sensibilidade de uma opção às variações dos fatores que afetam este preço (taxa de juros, tempo, preço do ativo objeto etc...) são apenas algumas das aplicações possíveis. Na verdade, quanto mais complicado o problema, maiores as vantagens do uso do modelo binomial, pois no final das contas basta "apenas" calcular o valor das quantidades de interesse em cada ponto (que corresponde a um preço do ativo objeto). Uma outra maneira de encarar o problema de precificação de uma opção através do modelo binomial é considerar o problema inverso, ou seja, em vez de assumir que a volatilidade do ativo objeto é conhecida a priori, construa os movimentos na árvore binomial a partir dos preços atuais de opções existentes, e use-os para estimar as probabilidades de "subir" e "descer" no modelo binomial. O modelo binomial é uma representação discreta do modelo contínuo para evolução dos preços de ações descrito anteriormente.

Considere a evolução do preço de uma ação durante um pequeno intervalo de tempo Δt. No instante inicial t, o preço da ação é S, e no instante t + Δt, existem dois preços possíveis, S.u (maior que S) e S.d (menor que S). O preço S.u é alcançado com probabilidade p, enquanto o outro preço, S.d, ocorre com probabilidade q = 1- p. Em termos esquemáticos, a evolução dos preços em um intervalo de tempo Δt é:

As variáveis u, d e p devem ser escolhidas de tal forma que, para um pequeno intervalo de tempo Δt, o retorno esperado da ação no intervalo seja $\mu . \Delta t$ e a variância deste retorno seja $\sigma^2 . \Delta t$.

Note que o retorno da ação no intervalo Δt é (pelas propriedades da distribuição Binomial):

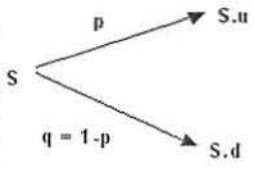

$$p.(S.u) + (1-p).(S.d) \qquad (7.4.1)$$

A variância deste retorno é:

$$p.(S.u)^2 + (1-p).(S.d)^2b - \{p.(S.u) + (1-p).(S.d)\}^2 =$$
$$(S.u)^2.\{p - p^2\} + (S.d)^2.\{q - q^2\} - 2.S.u.S.d.p \qquad (7.4.2)$$

Igualando (7.4.1) a $\mu . \Delta t$ e (7.4.2) a $\sigma^2 . \Delta t$ leva a:

$$\mu . \Delta t = p.(S.u) + (1-p).(S.d)$$
$$\sigma^2 . \Delta t = p.(S.u)^2 + (1-p).(S.d)^2 - \{\mu . \Delta t\}^2.$$

Resolvendo para u e d temos:

$$u = e^{\sigma.\sqrt{\Delta t}}$$
$$d = \frac{1}{u} \qquad (7.4.3)$$

Daí segue que:

$$p = \frac{e^{\mu.\Delta t} - d}{u - d} \qquad (7.4.4)$$

No limite quando Δt tende a zero este modelo para o movimento dos preços se reduz ao movimento Browniano geométrico já descrito antes.

Exemplo 7.4.1.
Considere uma ação cujo preço atual é R$100 e cujo retorno esperado é 10% ao ano, e com volatilidade 40% ao ano. Suponha que o modelo binomial seja usado para representar os movimentos do preço num período de uma semana (aproximadamente 1/50 ano). Nesta caso:

$\mu = 0.12$
$\sigma = 0.40$
$\Delta t = 1/50 = 0.02$
e os valores de u, d e p são:

$$u = e^{0.40\sqrt{0.02}} = 1.0582$$

$$d = \frac{1}{u} = 0.9450$$

$$p = \frac{e^{0.12.(0.02)} - 0.9450}{1.0582 - 0.9450} = 0.6371$$

$$q = 1 - p = 0.3629$$

Logo, após uma semana, o preço evolui para 105.82 com probabilidade 63.71% ou vai para 95.50 com probabilidade 36.29%.

E como podemos usar este modelo para a evolução em dois períodos? É fácil, basta a mesma estrutura a partir dos preços S.u e S.d encontrados no instante t + Δt. Ou seja, a partir do preço S.u no instante t + Δt podemos evoluir para o preço S.u.u com probabilidade p, ou então para o preço S.u.d com probabilidade 1 - p. Analogamente, saindo do preço S.d no instante t + Δt, podemos ira para o preço S.d.u = S.u.d com probabilidade p ou então para S.d.d. com probabilidade 1-p. A árvore binomial com dois períodos é então:

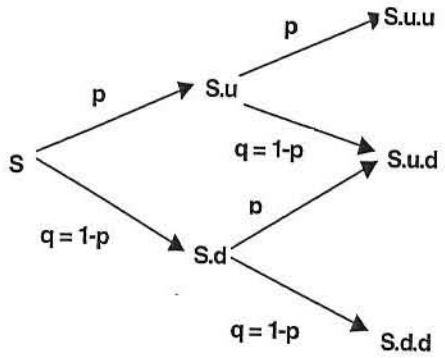

Logo, após dois intervalos de tempo Δt os preços possíveis e suas probabilidades são:

Preço	Probabilidade
$S.u^2$	p^2
S.u.d	2.p.q
$S.d^2$	q^2

Isso pode ser estendido de maneira trivial para n períodos. Após n intervalos de tempo Δt, os preços possíveis do ativo objeto serão: $S.u^n$, $S.u^{n-1}.d$..., $S.d^n$ e suas probabilidades poderão ser calculadas através da distribuição Binomial como:

$$\text{Prob(Preço no instante } t + n.\Delta t = S.u^j.d^{n-j}) = \binom{n}{j}. p^j.q^{n-j} \qquad (7.4.5)$$

Onde j = 0, 1, 2...,n indica o número de passos (ou intervalos) em que o preço subiu (e obviamente, o preço desceu nos outros n - j intervalos).

Exemplo 7.4.2.
Usando os parâmetros do exemplo 7.4.1. e a expressão (7.4.5) descreva quais os preços possíveis e suas probabilidades após n = 4 semanas.

Preço	Probabilidade
$S.u^4$	p^4
$S.u^3.d$	$4.p^3.q$
$S.u^2.d^2$	$6.p^2.q^2$
$S.u.d^3$	$4.p.q^3$
$S.d^4$	q^4

Substituindo os valores de u, d, p, q encontrados no exemplo 7.4.1. resulta em:

Preço	Probabilidade
125,39	16.47%
111.98	37.54%
100,00	32.08%
89,30	12.18%
79,75	1.74%

Precificação de opções usando o modelo Binomial

Considere o modelo Binomial com apenas um período. Qual será o preço C (no instante t) de uma *call* com preço de exercício K e vencimento no instante t + Δt?

A resposta é bastante fácil de encontrar, pois existem apenas dois preços possíveis (S.d e S.u) para o ativo objeto no instante t + Δt. Então, se o ativo objeto vale u.S, o preço da *call* é C_u = máx(0, S.u - K). Analogamente, se o ativo objeto vale d.S, o preço da *call* é C_d = máx(0, S.d - K).

Podemos criar um portfólio livre de risco a partir da *call* e do ativo objeto. A criação deste portfólio é exatamente do que precisamos para encontrar o valor da *call* em função de C_u e C_d definidos no parágrafo acima.

Crie um portfólio Π livre de risco no intervalo Δt, ou seja, o valor do portfólio é o mesmo não importando se o preço do ativo objeto é S.u ou S.d. O portfólio Π é obtido combinando-se Δ unidades do objeto com uma *call*. Neste portfólio estamos "longos" (comprados) no ativo objeto e "short" (vendidos) na *call*. Como Π é suposto livre de risco, no instante t + Δt o seu valor é o mesmo, independente do preço do ativo objeto. Logo, neste instante:

$$-C_u + \Delta.(u.S) = -C_d + \Delta.(d.S) \qquad (7.4.6)$$

A equação (7.4.6) nos permite encontrar a razão de hedge Δ necessária para criar um portfólio livre de risco. Resolvendo (7.4.6) para Δ nos dá:

$$\Delta = \frac{C_u - C_d}{S(u-d)} \qquad (7.4.7)$$

Mas, como o portfólio Π é livre de risco, no intervalo Δt ele pode render apenas a taxa livre de risco (r), senão existiria a possibilidade de arbitragem. O valor inicial do portfólio (no instante t) é: $- C + \Delta.S$, e no instante $t + \Delta t$ é $-C_u + \Delta.(u.S)$.

Então:

$$-C_u + \Delta.(u.S) = \{- C + \Delta.S\}.e^{r.\Delta t} \qquad (7.4.8)$$

A equação (7.4.8) simplesmente diz que o valor do portfólio no instante $t + \Delta t$ é o valor inicial do mesmo portfólio capitalizado no período pela taxa livre de risco. Resolvendo (7.4.8) para C leva a:

$$C = e^{-r.\Delta t}\left\{\frac{e^{r\Delta t} - d}{u-d}.C_u + \frac{u - e^{r\Delta t}}{u-d}.C_d\right\} \qquad \textbf{(7.4.9)}$$

Logo, o preço da opção no instante inicial t é determinado pelo seus preços futuros C_u e C_d, pelos valores u e d (que especificam o preço do ativo objeto no futuro) e pela taxa livre de risco.

Defina agora:

$$p = \frac{e^{r.\Delta t} - d}{u-d} \qquad \textbf{(7.4.10)}$$

p assim definido é chamado de "probabilidade neutra ao risco". Note que as expressões (7.4.4) e (7.4.10) são diferentes – num caso μ aparece no expoente, e no outro é a taxa livre de risco (r) que multiplica Δt no expoente.

Supondo que p seja definido como em (7.4.10), o preço da "call" no instante t toma uma forma bastante simplificada:

$$C = e^{-r.\Delta t}\{p.C_u + (1-p).C_d\} \qquad \textbf{(7.4.11)}$$

A interpretação de (7.4.11) é bastante simples: o preço da *call* no instante t é apenas o valor esperado (usando a probabilidade "risk neutral") do preço da call no instante $t + \Delta t$ trazido a valor presente usando a taxa livre de risco r.

Para precificarmos opções com mais de um período até o vencimento, estendemos estas idéias para a árvore binomial com n períodos.

Por exemplo, defina como um estado na árvore qualquer ponto possível nela e use a seguinte notação:

(i, j) indica um ponto na árvore situado i passos a partir do instante inicial (e

então estamos no instante $t + i.\Delta t$) no qual existira j movimentos "para cima" no preço do ativo objeto. Logo, o preço do ativo objeto no ponto (i, j) é $S.u^j.d^{i-j}$ e o preço da opção será $C_{i,j}$.

O preço da opção no vencimento é:

$$C_{n,j} = \text{máx}(0, S_{n,j} - K) \qquad (7.4.12)$$

Por argumentos análogos aos empregados no caso de apenas um período até o vencimento, o preço da opção no ponto (i,j) da árvore é:

$$C_{i,j} = e^{-r.\Delta t}\left\{ p.C_{i+1,j+1} + (1-p).C_{i+1,j} \right\} \qquad (7.4.13)$$

Usando as equações (7.4.12) e (7.4.13) podemos percorrer a árvore "para trás", começando no instante de vencimento da opção e deduzindo os preços em cada um dos instantes anteriores. Este procedimento fornece o valor de uma opção americana em cada ponto da árvore.

Todos os resultados aqui foram derivados para uma opção de compra. No caso de uma *put* basta mudar as condições do "pay-off" no vencimento para C_u = máx(0, K - S.u) e C_d = máx(0, K - S.d).

7.5. O Modelo de Black e Scholes Para o Preço de uma Opção

O que é o modelo de Black e Scholes?
É um modelo que nos permite obter o preço "justo" de um derivativo (por exemplo, no caso mais simples, uma opção européia).

O modelo de Black e Scholes não apareceu de uma hora para outra! Na verdade, o modelo proposto por eles é uma versão melhorada de um modelo originalmente proposto por A. James Boness em sua tese de doutorado na Universidade de Chicago. No início da década de 70, Black e Scholes obtiveram uma equação diferencial que deve ser satisfeita pelo preço de qualquer derivativo que depende de uma ação, e usaram esta equação para encontrar o preço de *puts* e *calls* européias.

Que fatores afetam o preço de uma opção?

- Preço do ativo objeto (S);
- Volatilidade do ativo objeto (σ);
- Tempo até o vencimento da opção (T – t);
- Taxa de juros livre de risco (r);
- Preço de exercício da opção (K).

Logo, o "resultado final" do modelo de Black e Scholes é uma fórmula que produz o prêmio de uma opção (por exemplo, C, no caso de uma *call*) como função de 5 variáveis: S, K, σ, T- t e r.

Note que, dentre as variáveis que afetam o preço de uma opção, apenas a volatilidade não é observada diretamente no mercado, e deve ser estimada. Existem diversos métodos para a estimação da volatilidade, e muita discordância sobre qual a melhor maneira de estimá-la!

Um ponto importante aqui é: podemos resolver a equação de Black e Scholes ao contrário! Supondo que os preços praticados no mercado são "justos" podemos resolver para σ em função das outras variáveis (C, S, K, T- t, r). A volatilidade encontrada desta forma é chamada de **volatilidade implícita**, e reflete as expectativas dos agentes do mercado com relação à variabilidade do preço do ativo objeto.
As hipóteses básicas do modelo são enunciadas a seguir. Estas hipóteses representam óbvias simplificações da realidade, e são mais ou menos questionáveis em diversas situações.

- A ação não paga dividendos durante o prazo de duração da opção.
- Os preços da ação seguem o movimento browniano geométrico descrito anteriormente.
- É possível estar vendido a descoberto nas ações, em qualquer quantidade.
- Não existem custos de transação.
- Não existem oportunidades de arbitragem livres de risco.
- As transações ocorrem podem ocorrer continuamente, isto é, não existem intervalos de tempo em que as transações não podem ocorrer.
- A taxa de juros livre de risco (r) é constante para qualquer prazo.

Suponha que o preço de uma ação segue o processo dado pela equação (7.1.8), isto é:
$dS = \mu.S.dt + \sigma.S.dW = \mu.S.dt + \sigma.S.Z.\sqrt{dt}$

Seja F o preço de um derivativo baseado em S. Então F é função do preço da ação objeto (S) e do tempo (t). Pelo lema de Itô, o processo dF é descrito pela equação (7.3.6):

$$dF = dt\left(\frac{\partial F}{\partial t} + a.\frac{\partial F}{\partial S} + \frac{1}{2}b^2.\frac{\partial^2 F}{\partial S^2}\right) + dW\left(b.\frac{\partial F}{\partial S}\right) =$$

(7.5.1)

$$= dt\left(\frac{\partial F}{\partial t} + \mu.S.\frac{\partial F}{\partial S} + \frac{1}{2}\sigma^2.S^2.\frac{\partial^2 F}{\partial S^2}\right) + dW\left(\sigma.S.\frac{\partial F}{\partial S}\right)$$

Um ponto importante aqui é:
A componente aleatória que afeta o processo dF (ou seja, dW, um processo de Wiener), e é a mesma fonte de incerteza que afeta o preço da ação objeto S! Logo, pode-se construir um portfólio combinando F e S de forma a eliminar toda

a componente aleatória (dW). O portfólio construído desta maneira não está sujeito a qualquer variação aleatória, e deve receber apenas a taxa livre de risco no período.

E como construir este portfólio?
Suponha que criamos o portfólio com −1 unidades do derivativo e $\frac{\partial F}{\partial S}$ unidades da ação. Então, o portfólio está "vendido" no derivativo e "comprado" na ação. Logo, o valor desta carteira é:

$$P = -F + S.\frac{\partial F}{\partial S}$$

A variação no preço da carteira é:

$$dP = -dF + dS\left(\frac{\partial F}{\partial S}\right) \qquad (7.5.2)$$

Substituindo (7.5.1) em (7.5.2) e supondo que S segue o processo (7.1.8) leva a:

$$dP = -dt\left(\frac{\partial F}{\partial t} + \mu.S.\frac{\partial F}{\partial S} + \frac{1}{2}\sigma^2.S^2.\frac{\partial^2 F}{\partial S^2}\right) - dW\left(\sigma.S.\frac{\partial F}{\partial S}\right) + \left(\mu.S.dt + \sigma.S.dW\right)\left(\frac{\partial F}{\partial S}\right) =$$

$$= -dt\left(\frac{\partial F}{\partial t} + \mu.S.\frac{\partial F}{\partial S} + \frac{1}{2}\sigma^2.S^2.\frac{\partial^2 F}{\partial S^2} - \mu.S.\frac{\partial F}{\partial S}\right) - dW\left(\sigma.S.\frac{\partial F}{\partial S} - \sigma.S.\frac{\partial F}{\partial S}\right) = \qquad (7.5.3)$$

$$= dt\left(-\frac{\partial F}{\partial t} - \frac{1}{2}\sigma^2.S^2.\frac{\partial^2 F}{\partial S^2}\right) - dW\,(0) =$$

$$= dt\left(-\frac{\partial F}{\partial t} - \frac{1}{2}\sigma^2.S^2.\frac{\partial^2 F}{\partial S^2}\right)$$

Note que a variação do portfólio dada pela equação (7.5.3) não depende de dW (ou seja, não é aleatória) e por argumentos de arbitragem, o portfólio é sem risco e deve ser remunerado apenas com a taxa livre de risco (r).

Portanto, a variação no preço do portfólio no intervalo de tempo dt deve ser apenas:

$$dP = r.P.dt \qquad (7.5.4)$$

Igualando (7.5.3) a (7.5.4) e lembrando que o processo que descreve S é dado pela equação (7.1.8) temos:

$$dP = r.P.dt = dt\left(-\frac{\partial F}{\partial t} - \frac{1}{2}\sigma^2.S^2.\frac{\partial^2 F}{\partial S^2}\right)$$

$$\Rightarrow dt\left(r.(-F) + r.\left(S.\frac{\partial F}{\partial S}\right)\right) = dt\left(-\frac{\partial F}{\partial t} - \frac{1}{2}\sigma^2.S^2.\frac{\partial^2 F}{\partial S^2}\right) \qquad (7.5.5)$$

$$\Rightarrow +\frac{\partial F}{\partial t} + \frac{1}{2}\sigma^2.S^2.\frac{\partial^2 F}{\partial S^2} + r.S.\frac{\partial F}{\partial S} = r.F$$

A equação (7.5.5) é a equação de Black e Scholes para o preço de um derivativo. Note que existem inúmeras soluções, dependendo das características do derivativo e das condições de contorno que ele deve obedecer, que especificam os valores de F para determinados valores de S e t.

Por exemplo, numa call européia, a condição de contorno é:
F = máx(S(T) - K, 0) no instante t = T, onde T é o instante de exercício, S(T) é o preço da ação objeto neste instante e K é o preço de exercício da opção.

Analogamente, para uma opção de venda européia, a condição de contorno é: F = máx(K - S(T), 0) no instante t = T.

É importante notar que soluções analíticas de (7.5.5) só são possíveis em situações muito especiais (por exemplo, opções de compra e de venda européias) e para derivativos mais complicados é fundamental encontrar soluções numéricas eficientes que nos forneçam F.

Também, deve-se ressaltar que o portfólio P criado na derivação de Black e Scholes não é permanentemente sem risco, esta propriedade é válida apenas em intervalos infinitesimais de tempo. Logo, para obter um portfólio livre de risco baseado em F e S é necessário rebalancear continuamente as quantidades do derivativo e da ação, pois à medida que S e t se alteram, ∂F/∂S também muda.

Derivação do preço de uma *call* européia
Seja S o preço de uma ação hoje. Supondo um mundo neutro ao risco, o valor esperado de uma call européia no vencimento é:

$$E\{\max(S(T) - K, 0)\}$$

Trazendo este valor para hoje através da taxa de juros livre de risco produz:

$$C = e^{-r(T-t)}.E\{\max(S(T) - K, 0)\}$$

Note que:

$$E\{\max(S(T) - K, 0)\} = E(S(T) - K).\ Pr\{S(T) > K\}$$

Se os preços seguem um movimento Browniano geométrico, então a distribuição do logaritmo do preço no vencimento S(T) é uma distribuição Normal com média:
$\log(S) + \left(r - \frac{\sigma^2}{2}\right)(T - t)$ e variância $\sigma^2(T - t)$.

Assim, depois de uma certa quantidade de álgebra encontramos:

$$C = S.\Phi(d_1) - K.e^{-r(T-t)}.\Phi(d_2) \qquad (7.5.6)$$

Onde:

$$d_1 = \frac{\log\left(\frac{S}{K}\right) + \left(r + \frac{\sigma^2}{2}\right)(T - t)}{\sigma\sqrt{T - t}} \qquad (7.5.7)$$

$$\text{e } d_2 = \frac{\log\left(\frac{S}{K}\right) + \left(r - \frac{\sigma^2}{2}\right)(T - t)}{\sigma\sqrt{T - t}} = d_1 - \sigma\sqrt{T - t} \qquad (7.5.8)$$

E Φ(.) indica a função de distribuição da N(0,1).

Preço de uma *put* européia
A paridade entre *puts* e *calls* nos permite deduzir o preço de uma *put* européia a partir de uma call com mesmo exercício e data de vencimento. Especificamente, a relação de paridade (7.2.3) fornece:

$P = C - S + K.e^{-r(T-t)}$ e combinando esta expressão com (7.5.6) leva a:

$$P = S.\Phi(d_1) - K.e^{-r(T-t)}.\Phi(d_2) - S + K.e^{-r(T-t)} = S.(\Phi(d_1) - 1) - K.e^{-r(T-t)}.(\Phi(d_2) - 1) =$$

$$= -S(1 - \Phi(d_1)) + K.e^{-r(T-t)}.(1 - \Phi(d_2)) = -S.\Phi(-d_1) + K.e^{-r(T-t)}.(\Phi(-d_2)) =$$

$$K.e^{-r(T-t)}.(\Phi(-d_2)) - S.\Phi(-d_1) \qquad (7.5.9)$$

Não existe fórmula analítica para uma *put* americana.

Nos próximos exemplos examinamos o efeito dos diversos inputs sobre o preço das opções dado pela fórmula de Black e Scholes.

Exemplo 7.5.1. Efeito do Preço da Ação Objeto
Na tabela a seguir, exibimos os preços de opções européias segundo a fórmula de Black e Scholes. O preço de exercício, taxa livre de risco, volatilidade e tempo até o vencimento são mantidos fixos, e apenas variamos o preço corrente da ação. A volatilidade e a taxa livre de risco estão expressas em valores anuais, e o tempo até o vencimento é 1 mês, isto é, 1/12 = 0.083 anos. Note que o prêmio da call aumenta quando o preço do ativo objeto cresce, e o oposto ocorre para uma *put*.

preço da ação (S)	28	30	32	34	36	38	40	42
preço de exercício (K)	**40**	**40**	**40**	**40**	**40**	**40**	**40**	**40**
taxa livre de risco (r)	20.0%	20.0%	20.0%	20.0%	20.0%	20.0%	20.0%	20.0%
volatilidade	30.0%	30.0%	30.0%	30.0%	30.0%	30.0%	30.0%	30.0%
tempo até exercício	0.167	0.167	0.167	0.167	0.167	0.167	0.167	0.167
d1	-2.5788	-2.0155	-1.4886	-0.9936	-0.5269	-0.0854	0.3334	0.7318
d2	-2.7013	-2.1380	-1.6110	-1.1160	-0.6493	-0.2079	0.2109	0.6093
Prêmio da Call	**0.01**	**0.03**	**0.11**	**0.33**	**0.79**	**1.55**	**2.65**	**4.05**
Prêmio da *Put*	**10.69**	**8.72**	**6.80**	**5.02**	**3.47**	**2.24**	**1.34**	**0.74**

Exemplo 7.5.2. Efeito da Volatilidade

Repetimos o exemplo anterior, mas o nosso interesse agora é verificar a sensibilidade do preço das opções às variações na volatilidade. Exibimos duas tabelas, com preços da ação R$42 e R$38 respectivamente. No primeiro caso a call está "in the money" e a *put* "out of the money". O oposto ocorre na 2ª tabela.

Tabela 1 – preço da ação > preço de exercício

preço da ação (S)	42	42	42	42	42	42
preço de exercício (K)	40	40	40	40	40	40
taxa livre de risco (r)	20.0%	20.0%	20.0%	20.0%	20.0%	20.0%
Volatilidade	**10.0%**	**15.0%**	**20.0%**	**25.0%**	**30.0%**	**35.0%**
tempo até exercício	0.083	0.083	0.083	0.083	0.083	0.083
d1	2.2819	1.5333	1.1626	0.9431	0.7991	0.6984
d2	2.2531	1.4900	1.1049	0.8709	0.7125	0.5973
Prêmio da Call	**2.67**	**2.71**	**2.81**	**2.95**	**3.12**	**3.30**
Prêmio da *Put*	**0.00**	**0.05**	**0.15**	**0.29**	**0.46**	**0.64**

Tabela 2 – preço da ação < preço de exercício

preço da ação (S)	38	38	38	38	38	38
preço de exercício (K)	40	40	40	40	40	40
taxa livre de risco (r)	20.0%	20.0%	20.0%	20.0%	20.0%	20.0%
volatilidade	**10.0%**	**15.0%**	**20.0%**	**25.0%**	**30.0%**	**35.0%**
tempo até exercício	0.083	0.083	0.083	0.083	0.083	0.083
d1	-1.1851	-0.7780	-0.5709	-0.4437	-0.3565	-0.2922
d2	-1.2139	-0.8213	-0.6286	-0.5159	-0.4431	-0.3932
Prêmio da Call	**0.06**	**0.20**	**0.38**	**0.57**	**0.77**	**0.98**
Prêmio da *Put*	**1.40**	**1.54**	**1.72**	**1.91**	**2.11**	**2.32**

Em ambos os casos nota-se que **o aumento da volatilidade produz um aumento do preço da opção (para *calls* e também para *puts*)**. O argumento por trás disso é: quanto maior a volatilidade, maior a probabilidade de exercício da opção, e portanto maior deve ser o prêmio.

Exemplo 7.5.3. Efeito do Tempo até o Vencimento

Nas próximas tabela examinamos o efeito do tempo até o vencimento da opção. Consideramos os seguintes tempos de vencimento: ¼ de mês, ½ mês, 1 mês, 2 meses, 4 meses e 6 meses.

Na tabela 3 a seguir, a call está in the money (e a *put* out of the money). Na tabela 4, ambas as opções estão at the money, e na tabela 5, a call está out of the money e a *put* in the money.

Tabela 3 – preço da ação > preço de exercício

preço da ação (S)	45	45	45	45	45	45
preço de exercício (K)	40	40	40	40	40	40
taxa livre de risco (r)	20.0%	20.0%	20.0%	20.0%	20.0%	20.0%
volatilidade	30.0%	30.0%	30.0%	30.0%	30.0%	30.0%
tempo até exercício	**0.021**	**0.042**	**0.083**	**0.167**	**0.333**	**0.500**
d1	2.8380	2.0901	1.5958	1.2951	1.1515	1.1327
d2	2.7947	2.0289	1.5092	1.1726	0.9783	0.9206
Prêmio da Call	**5.17**	**5.35**	**5.76**	**6.58**	**8.10**	**9.48**
Prêmio da *Put*	**0.00**	**0.02**	**0.09**	**0.27**	**0.52**	**0.68**

Se S > K, o aumento do tempo até o vencimento se reflete num aumento dos prêmios de *calls* e *puts*. Em outras palavras, **à medida que o tempo passa e a data de vencimento se aproxima, o valor das *calls* e *puts* decresce.**

Tabela 4 – preço da ação = preço de exercício

preço da ação (S)	40	40	40	40	40	40
preço de exercício (K)	40	40	40	40	40	40
taxa livre de risco (r)	20.0%	20.0%	20.0%	20.0%	20.0%	20.0%
volatilidade	30.0%	30.0%	30.0%	30.0%	30.0%	30.0%
tempo até exercício	**0.021**	**0.042**	**0.083**	**0.167**	**0.333**	**0.500**
d1	0.1179	0.1667	0.2358	0.3334	0.4715	0.5775
d2	0.0746	0.1055	0.1491	0.2109	0.2983	0.3653
Prêmio da Call	**0.78**	**1.15**	**1.73**	**2.65**	**4.16**	**5.47**
Prêmio da *Put*	**0.61**	**0.82**	**1.06**	**1.34**	**1.58**	**1.66**

Se a opção está "at the money", a passagem do tempo (redução do tempo que falta até o momento do exercício) provoca uma redução do prêmio, tanto para *calls* quanto para puts.

Tabela 5 – preço da ação < preço de exercício

preço da ação (S)	35	35	35	35	35	35
preço de exercício (K)	40	40	40	40	40	40
taxa livre de risco (r)	20.0%	20.0%	20.0%	20.0%	20.0%	20.0%
volatilidade	30.0%	30.0%	30.0%	30.0%	30.0%	30.0%
tempo até exercício	**0.021**	**0.042**	**0.083**	**0.167**	**0.333**	**0.500**
d1	-2.9659	-2.0139	-1.3061	-0.7569	-0.2994	-0.0520
d2	-3.0092	-2.0751	-1.3927	-0.8794	-0.4726	-0.2641
Prêmio da Call	**0.00**	**0.02**	**0.13**	**0.52**	**1.47**	**2.45**
Prêmio da *Put*	**4.83**	**4.69**	**4.47**	**4.21**	**3.89**	**3.64**

Neste caso, à medida que o vencimento se aproxima, o prêmio da *call* se reduz (pois ela não está em condições de ser exercida agora) e o preço da *put* aumenta. Note que aqui a sensibilidade de *calls* e *puts* é diferente, o que não ocorria nos outros casos!

Exemplo 7.5.4. Efeito da Taxa de Juros Livre de Risco

preço da ação (S)	45	45	45	45	45	45
preço de exercício (K)	40	40	40	40	40	40
taxa livre de risco (r)	**5.0%**	**10.0%**	**15.0%**	**20.0%**	**25.0%**	**30.0%**
volatilidade	30.0%	30.0%	30.0%	30.0%	30.0%	30.0%
tempo até exercício	0.083	0.083	0.083	0.083	0.083	0.083
d1	1.4515	1.4996	1.5477	1.5958	1.6439	1.6920
d2	1.3649	1.4130	1.4611	1.5092	1.5573	1.6054
Prêmio da Call	**5.30**	**5.45**	**5.60**	**5.76**	**5.91**	**6.06**
Prêmio da Put	**0.13**	**0.12**	**0.11**	**0.09**	**0.08**	**0.08**

O aumento da taxa de juros leva a um aumento do prêmio da call e uma redução do prêmio da *put*. Esta relação vale para qualquer relação entre S e K, isto é, não importa se as opções estão in the money ou out of the money.

Exemplo 7.5.5. Cálculo da Volatilidade Implícita

Neste exemplo resolvemos a equação de Black e Scholes "ao contrário", isto é, dado o preço de uma *call*, qual a volatilidade apontada pelo modelo? Este cálculo pode ser feito numericamente no Excel usando o Solver. A próxima tabela contém volatilidades implícitas para alguns prêmios de *calls*.

preço da ação (S)	45	45	45
preço de exercício (K)	40	40	40
taxa livre de risco (r)	20.0%	20.0%	20.0%
volatilidade	**27.23%**	**36.05%**	**40.74%**
tempo até exercício	0.167	0.167	0.167
Prêmio da Call	**6.500**	**6.800**	**7.000**

Note o quanto a relação entre volatilidade e prêmio da call é não linear. Variações relativamente pequenas no preço da call resultam em grandes variações na volatilidade implícita.

7.6. Parâmetros de Hedge

Seja F o preço de um derivativo. É importante medir a sensibilidade de F em relação às variáveis que o afetam. A seguir, definimos diversos parâmetros que medem estas sensibilidades. Estes parâmetros são freqüentemente chamados de "gregas" das opções.

Definição 7.6.1. Delta
É a sensibilidade de F em relação às variações no preço do ativo objeto, isto é:

$$\Delta = \frac{\partial F}{\partial S} \qquad (7.6.1)$$

Muitas vezes um portfólio contém diversas opções, todas referentes ao mesmo ativo objeto. O delta do portfólio mede a sua sensibilidade em relação a pequenas variações no preço do ativo objeto. O importante, neste caso, é saber que a seguinte simplificação é válida: o delta da carteira é calculado como a média ponderada dos deltas das opções existentes no portfólio. Esta propriedade aditiva se aplica também ao Gama, definido a seguir.

Uma aplicação do delta do portfólio é a construção de carteiras com opções que são quase insensíveis aos movimentos de preço do ativo objeto. Estes portfólios "delta-neutros" são úteis quando se quer evitar, através da montagem de uma carteira contendo opções, perdas decorrentes de movimentos desfavoráveis do preço do ativo objeto.

Nota:

O delta de uma *call* é sempre ≥ 0;
O delta de uma *put* é sempre ≤ 0.

O delta de uma posição em dinheiro é zero, pois esta posição é insensível às mudanças de preço de uma ação.

Por exemplo, suponha que o delta de uma opção é 0.4. Isto indica que, se o preço do ativo objeto se altera em R$x, o preço da opção se altera em 40% de

x. Como usar isso para fazer hedge? Suponha que um investidor vendeu *calls* sobre 5000 ações. A posição deste investidor pode ser protegida se ele compra 5000*(0.4) = 2000 ações. A seguir, apresentamos o valor do portfólio após pequenas variações no preço do ativo objeto. Suponha que o preço da ação hoje é R$100 e o prêmio de cada call vendida é R$10.

Suponha que o preço da ação sobe para R$101. O prêmio de cada opção tenderá a subir R$0.40. Então, o investidor tem um ganho de R$2000 na ação objeto e uma perda de 0.4(5000) = R$2000 devida à venda de opções.

Alternativamente, se o preço da ação cai para R$99, há uma perda de R$2000 na ação objeto, que é compensada por um ganho igual nas opções. Em qualquer caso, o valor total do portfólio não se altera.

Este procedimento de hedging é conhecido como "delta-hedging" e é o procedimento usado na derivação da equação de Black e Scholes para construir um portfólio imune às variações do preço objeto. O portfólio assim construído é chamado de portfólio delta neutro.
É importante observar que o delta de uma opção não permanece fixo ao longo do tempo, e também muda de acordo com o preço do ativo objeto. Logo, a manutenção de um portfólio delta neutro envolve constantes alterações nas posições do ativo objeto e das opções, e este procedimento necessário para manter o portfólio delta neutro é chamado de rebalanceamento.

Delta de opções européias
O delta de uma call européia é: $\Delta = \Phi(d_1)$ onde d_1 foi definido na equação (7.5.7). Note que o delta da call é sempre positivo, pois $\Phi(.)$ é um valor entre zero e um.
O delta de uma *put* européia é $\Delta = \Phi(d_1) - 1$, ou seja, sempre negativo. Note que isto faz sentido, pois aumentos do preço da ação objeto levam a uma queda do preço da *put*.

Exemplo 7.6.2. Cálculo do Delta

preço da ação (S)	36	38	40	42	44	46	48
preço de exercício (K)	40	40	40	40	40	40	40
taxa livre de risco (r)	20.0%	20.0%	20.0%	20.0%	20.0%	20.0%	20.0%
volatilidade	30.0%	30.0%	30.0%	30.0%	30.0%	30.0%	30.0%
tempo até exercício	0.167	0.167	0.167	0.167	0.167	0.167	0.167
d1	-0.5269	-0.0854	0.3334	0.7318	1.1116	1.4746	1.8221
d2	-0.6493	-0.2079	0.2109	0.6093	0.9891	1.3521	1.6996
Prêmio da Call	0.79	1.55	2.65	4.05	5.69	7.50	9.39
Prêmio da Put	3.47	2.24	1.34	0.74	0.38	0.18	0.08
Delta da Call	**0.299**	**0.466**	**0.631**	**0.768**	**0.867**	**0.930**	**0.966**
Delta da Put	**-0.701**	**-0.534**	**-0.369**	**-0.232**	**-0.133**	**-0.070**	**-0.034**

Os gráfico a seguir exibem a sensibilidade dos deltas de *calls* e *puts* em relação ao preço do ativo objeto.

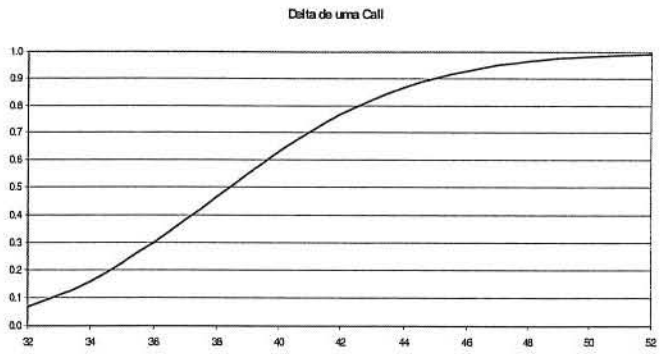

Definição 7.6.3. Gama
Mede a sensibilidade do Delta em relação às variações no preço do ativo objeto.

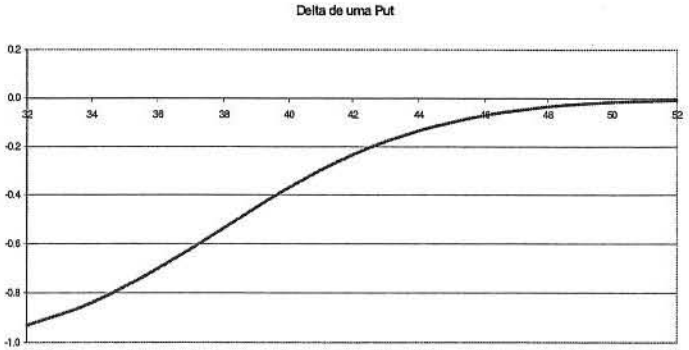

Numa analogia com a Física, o Gama é uma medida da "aceleração" no preço de um derivativo, ou seja:

$$\Gamma = \frac{\partial^2 F}{\partial S^2} \qquad (7.6.2)$$

Se o Gama é pequeno, as variações do preço da ação objeto implicam pequenas variações no Delta da opção (e assim não é necessário fazer grandes alterações num portfólio para mantê-lo Delta-neutro). Ao contrário, se o Gama é grande, pequenas variações no ativo objeto implicam grandes alterações no Delta da opção.

Da fórmula de Black e Scholes segue que o Gama de uma call ou *put* européia é:

$$\Gamma = \frac{\varphi(d_1)}{S.\sigma.\sqrt{T-t}} \qquad (7.6.3)$$

Onde $\varphi(.)$ é a densidade Normal padrão.

Note que Γ é sempre positivo, e sua sensibilidade ao preço do ativo objeto é mostrada no gráfico e tabela a seguir.

preço da ação (S)	30	32	34	36	38	40	42	44	46
preço de exercício (K)	40	40	40	40	40	40	40	40	40
taxa livre de risco (r)	20.0%	20.0%	20.0%	20.0%	20.0%	20.0%	20.0%	20.0%	20.0%
volatilidade	30.0%	30.0%	30.0%	30.0%	30.0%	30.0%	30.0%	30.0%	30.0%
tempo até exercício	0.167	0.167	0.167	0.167	0.167	0.167	0.167	0.167	0.167
d1	-2.0155	-1.4886	-0.9936	-0.5269	-0.0854	0.3334	0.7318	1.1116	1.4746
d2	-2.1380	-1.6110	-1.1160	-0.6493	-0.2079	0.2109	0.6093	0.9891	1.3521
Gama	**0.014**	**0.034**	**0.058**	**0.079**	**0.085**	**0.077**	**0.059**	**0.040**	**0.024**

Definição 7.6.4. Theta

O theta de uma opção é definido como a sensibilidade em relação ao tempo, isto é:

$$\Theta = \frac{\partial F}{\partial t}$$

Para uma opção de compra européia:

$$\Theta = -\frac{S.\varphi(d_1).\sigma}{2\sqrt{T-t}} - r.K.e^{-r(T-t)}.\Phi(d_2) \qquad (7.6.4)$$

Para uma *put* européia temos:

$$\Theta = -\frac{S.\varphi(d_1).\sigma}{2\sqrt{T-t}} + r.K.e^{-r(T-t)}.\Phi(-d_2) \qquad (7.6.5)$$

Θ é negativo na maioria das vezes, pois em geral à medida que o tempo de vencimento se aproxima, o valor da opção decresce. A exceção é uma *put* européia "in the money" (veja a tabela 5 do exemplo 7.5.3).

Relação entre Gama e Theta num portfólio Delta Neutro

Considere um portfólio Delta neutro:

P = + S.Δ - F onde F indica o derivativo, S o preço da ação objeto, e Δ é o número de ações necessário para manter o portfólio "hedgeado" (imune às variações de preço do ativo objeto).

Então, a variação de preço do portfólio é dada por:

$$\Delta P = \frac{\partial P}{\partial S}.\Delta S + \frac{\partial P}{\partial t}.\Delta t + \frac{1}{2}\frac{\partial^2 P}{\partial S^2}.\Delta S^2 + \frac{1}{2}\frac{\partial^2 P}{\partial t^2}.\Delta t^2 + \frac{\partial^2 P}{\partial S \partial t}.\Delta S.\Delta t + \ldots.$$

Como o portfólio é Delta-neutro, a sensibilidade do portfólio às variações em S é nula. Ignorando os termos de ordem maior que Δt leva a:

$$\Delta P = \frac{\partial P}{\partial t}.\Delta t + \frac{1}{2}\frac{\partial^2 P}{\partial S^2}.\Delta S^2 = \Theta.\Delta t + \frac{1}{2}\Gamma.\Delta S^2$$

Logo, se a variação nos preços do ativo objeto e Γ forem grandes, o portfólio Delta-neutro pode ainda estar sujeito a substanciais variações de preço.

Relação entre Delta, Gama e Theta num portfólio qualquer

Podemos reescrever a equação de Black e Scholes (7.5.5) em termos das sensibilidades, isto é:

$$+\frac{\partial F}{\partial t} + \frac{1}{2}\sigma^2.S^2.\frac{\partial^2 F}{\partial S^2} + r.S.\frac{\partial F}{\partial S} = r.F$$

$$\Leftrightarrow \Theta + \frac{1}{2}\sigma^2.S^2.\Gamma + r.S.\Delta = r.F$$

Num portfólio delta-neutro, $\Delta = 0$ e esta equação naturalmente se reduz a:

$$\Theta + \frac{1}{2}\sigma^2.S^2.\Gamma = r.F$$

Definição 7.6.5. Rô

Mede a sensibilidade de uma opção às variações na taxa livre de risco, isto é:

$$\rho = \frac{\partial F}{\partial r}$$

Da fórmula de Black e Scholes segue que:

- Para uma call européia: $\rho = K.e^{-r(T-t)}(T-t)\Phi(d_2)$ (7.6.6)
- Para uma *put* européia: $\rho = -K.e^{-r(T-t)}(T-t)\Phi(-d_2)$ (7.6.7)

O rô de uma call é sempre positivo, e o de uma *put* é sempre negativo. Isso reflete o fato (vide exemplo 7.5.3) de um aumento da taxa de juros levar a um aumento do prêmio da call e uma redução do prêmio da *put*.

Definição 7.6.6. Vega ou Lambda

É a sensibilidade do preço do derivativo às variações na volatilidade. No modelo Black-Scholes supõe-se que a volatilidade é constante, mas na prática esta varia durante a vida da opção.

O vega de uma opção européia (call ou *put*) é dado por:

$$\Lambda = \frac{\partial F}{\partial \sigma} = S.\varphi(d_1)\sqrt{T-t} \qquad (7.6.8)$$

Note que o vega é sempre positivo, indicando que aumentos na volatilidade se refletem em aumentos dos preços das opções.

Apêndice: Alguns Comentários Sobre o Valor do Dinheiro no Tempo

Para quem (como eu!) viveu num país onde a inflação mensal chegou a mais de 80%, a idéia de que o dinheiro tem um valor diferente dependendo de qual instante está sendo considerado é de uma obviedade absoluta! Nesta situação, o dinheiro guardado embaixo do colchão terminaria o mês valendo apenas 20% de seu valor inicial!

Entretanto, em países de inflação baixa, a noção do dinheiro que perde valor ao longo do tempo não é tão dramaticamente real.

Na verdade, um ponto bastante fácil de entender, e que parece absolutamente hermético quando olhamos pela primeira vez para modelos envolvendo preços de ativos financeiros é a questão do dinheiro ao longo do tempo, representada nas equações por termos da forma e^{-rt} ou e^{+rt}. Qual a idéia por trás disso? É apenas um caso limite de juros compostos que, por sua vez, são apenas uma progressão geométrica. Então, cabe olhar para os juros compostos em primeiro lugar.

Exemplo A.1.

Suponha que você tem R$100 numa aplicação no banco, e esta aplicação rende

6% ao ano, a serem recebidos no final de um ano. Daqui a um ano você terá R$106 na sua aplicação. Como encontrar este valor?

Faça $FV = PV(1 + r)^n$ (A.01)

onde:
FV = valor no futuro do seu dinheiro;
PV = valor atual do seu dinheiro;
r = taxa de juros;
n = número de períodos.

Neste caso, PV = 100, r = 6% = 0.06 e n = 1 ano.

E se você receber uma taxa de 6% ao ano, mas em vez de receber tudo de uma vez daqui a um ano, você receberá os juros em 2 parcelas, daqui a 6 e 12 meses. Intuitivamente, isto é melhor negócio para você (se a taxa de juros for a mesma!) pois você terá mais dinheiro disponível para aplicar daqui a 6 meses, em vez de receber tudo no final. E quanto você deverá receber?

Faça $FV = PV(1 + r/p)^p$ onde:
p = número de períodos em que os juros serão computados (neste caso, p = 2 vezes ao ano). Na situação do exemplo; $FV = PV(1 + 0.06/2)^2 = PV(1.03)^2 = PV(1.0609) = 100(1.0609) = 106.09$. Isto é, a taxa de 6% ao ano computada semestralmente equivale a 6.09% computada anualmente!

A coisa funciona também "ao contrário". Imagine que, em vez de juros, estamos considerando a inflação. Suponha que uma mercadoria vale R$100 hoje. Se a taxa de inflação hoje é 10% ao mês, daqui a 1 mês esta mesma mercadoria valerá R$110 isto é, os R$110 do mês que vem são equivalentes aos R$100 de hoje.

Considere novamente a fórmula (A.01). O que acontece com ela quando o número de períodos em que os juros são calculados cresce infinitamente, isto é, adiciona-se os juros mensalmente, quinzenalmente, semanalmente, diariamente, a cada 2 horas etc...? Intuitivamente, a taxa anual equivalente deve crescer. E como comparar todas estas taxas? A próxima tabela exibe algumas taxas de juros anuais e número de períodos por ano em que os juros são creditados.

TAXAS DE JUROS EQUIVALENTES							
r	**continuamente**	**mensal**	**2 meses**	**3 meses**	**6 meses**	**9 meses**	**anualmente**
6.00%	6.18%	6.17%	6.15%	6.14%	6.09%	6.04%	6.00%
10.00%	10.52%	10.47%	10.43%	10.38%	10.25%	10.12%	10.00%
15.00%	16.18%	16.08%	15.97%	15.87%	15.56%	15.27%	15.00%
20.00%	22.14%	21.94%	21.74%	21.55%	21.00%	20.48%	20.00%
25.00%	28.40%	28.07%	27.75%	27.44%	26.56%	25.75%	25.00%

r = taxa anual
p = número de períodos em que os juros serão computados

Note que a taxa anual de 6.00% equivale a 6.09% quando os juros são computados semestralmente, como já mencionado. Esta mesma taxa equivale a 6.17 % anuais se os juros são computados mensalmente. Como passar de uma taxa para outra? Faça $(1 + r/p)^p = (1 + i)$ onde r é a taxa anual, p_1 é o números de períodos em que os juros são computados e i é a taxa anual equivalente a r. Por exemplo, a taxa trimestral equivalente a 15% ao ano é encontrada através de:

$$\left(1+\frac{0.15}{4}\right)^4 = 1+i \Rightarrow (1+i) = (1.0375)^4 = 1.15865 \Rightarrow i = 15.865\%$$

Qual o limite de $(1 + r/p)^p$ quando p tende a infinito? Por Cálculo encontramos e^r como o limite, e isto nos dá a taxa de juros continuamente compostos. Logo, a expressão que relaciona um valor atual (PV) a um valor daqui a t períodos no futuro (FV) utilizando uma taxa de juros continuamente compostos r é:

$$FV = (PV).e^{rt} \qquad (A.02)$$

ou, alternativamente:

$$PV=(FV).e^{-rt} \qquad (A.03)$$

Estas duas expressões aparecem inúmeras vezes nas fórmulas de precificação de opções, e na análise de Black e Scholes supõe-se juros continuamente compostos. Na verdade, fora do Brasil costuma-se trabalhar com juros continuamente compostos, o que causa certa dificuldade ao tentar "tropicalizar" produtos e estratégias estrangeiras.

O ponto fundamental ao trabalhar com valores financeiros é: lembre-se que o valor de R$10 hoje não é o mesmo que daqui a 1 ano, e por isso é importante colocar todas as quantias que estão sendo consideradas "na mesma base", ou seja, no mesmo instante de tempo. A escolha de qual será o instante de tempo em que iremos olhar para o dinheiro é, até certo ponto, irrelevante, e geralmente ao comparar dois valores (ou fluxos de caixa, fluxos de dinheiro) escolhe-se o instante atual, e calcula-se o valor presente (ou valor atual, PV) dos fluxos.

Exemplo A.2.

Uma pessoa planeja se aposentar daqui a 20 anos e decide colocar uma quantia x no banco pelos próximos 240 meses de tal forma que, após este período, ela poderá retirar R$1000 por mês pelos 360 meses subseqüentes. Supondo uma taxa de juros de 6% ao ano computados mensalmente, qual o valor de x que deverá ser poupado a cada mês?

Solução

A taxa de juros mensal é r = 6%/12 = 0.5%. O primeiro passo é calcular o valor presente da quantia a ser poupada nos próximos 240 meses, que é:

$$x + x\left(\frac{1}{1+r}\right) + x\left(\frac{1}{1+r}\right)^2 + \ldots\ldots + x\left(\frac{1}{1+r}\right)^{239} =$$

$$x\left\{1+\left(\frac{1}{1+r}\right)+\ldots.+\left(\frac{1}{1+r}\right)^{239}\right\} = x\left\{\frac{1-\left(\frac{1}{1+r}\right)^{240}}{1-\left(\frac{1}{1+r}\right)}\right\}$$

O valor presente da quantia a ser resgatada nos meses 240, 241..., 599 é:

$$1000\left(\frac{1}{1+r}\right)^{240} + 1000\left(\frac{1}{1+r}\right)^{241} + \ldots\ldots + 1000\left(\frac{1}{1+r}\right)^{599} =$$

$$1000\left(\frac{1}{1+r}\right)^{240}\left\{1+\left(\frac{1}{1+r}\right)+\ldots.+\left(\frac{1}{1+r}\right)^{359}\right\} =$$

$$1000\left(\frac{1}{1+r}\right)^{240}\left\{\frac{1-\left(\frac{1}{1+r}\right)^{360}}{1-\left(\frac{1}{1+r}\right)}\right\}$$

Obviamente estes dois valores atuais devem ser iguais, e assim:

$$x\left\{\frac{1-\left(\frac{1}{1+r}\right)^{240}}{1-\left(\frac{1}{1+r}\right)}\right\} = 1000\left(\frac{1}{1+r}\right)^{240}\left\{\frac{1-\left(\frac{1}{1+r}\right)^{360}}{1-\left(\frac{1}{1+r}\right)}\right\}$$

Resolvendo algebricamente com r = 0.5% leva a x = R$360,99.

Exemplo A.3. Taxa Interna de Retorno

A taxa interna de retorno de um investimento é a taxa de juros que torna o valor atual do fluxo de caixa igual ao pagamento inicial. A definição é mais facilmente entendida através de um exemplo. Suponha que você compra um título hoje por R$100, com a promessa de receber R$60 daqui a um ano e R$60 daqui a dois anos. Qual a taxa interna de retorno (em inglês, "internal rate of return" ou "yield") deste título?

Precisamos achar r (a taxa de juros) tal que:

$$100 = \frac{60}{1+r} + \frac{60}{(1+r)^2}$$

Seja x = 1/(1 + r). A equação acima é, em termos de x:

$$100 = 60x + 60x^2 \Rightarrow 60x^2 + 60x - 100 = 0$$

Como $x > 0$ segue que: $x \equiv 0.8844$ e então $r = 13.1\%$ (verifique).

Se agora o título paga R$60 daqui a 1 ano, 2 anos, 3 anos..., n anos, a taxa interna de retorno é encontrada através da equação:

$$100 = \frac{60}{1+r} + \frac{60}{(1+r)^2} + \ldots\ldots + \frac{60}{(1+r)^n} = 60x + 60x^2 + \ldots + 60x^n$$

Esta é uma equação de grau n que deve ser resolvida (em geral numericamente) para x.

A extensão destes argumentos para um título que paga valores diferentes a cada período é trivial. Suponha que você paga hoje R$c por um título, e irá receber b_1, b_2..., b_n ao final dos períodos 1, 2..., n. Então, o yield deste título é o valor $r > -1$ tal que:

$$c = \frac{b_1}{1+r} + \frac{b_2}{(1+r)^2} + \ldots + \frac{b_n}{(1+r)^n} \Leftrightarrow -c + \sum_{j=1}^{n} \frac{b_j}{(1+r)^j} = 0$$

O valor de r encontrado é único se b_1, b_2..., $b_n \geq 0$ e $c > 0$. Mas, se os sinais de um ou dos b_j's forem negativos, pode não existir solução única, o que é problemático!
O tipo mais simples de título que se pode construir é o **"zero-coupon bond"**, em que existe apenas um pagamento, no final do período. Para este título a determinação do "yield" é trivial, e a vantagem destes "zero-coupon bonds" é que títulos mais complicados podem ser encarados como somas de zero-coupons.

Num "zero coupon bond" investe-se hoje uma quantia x esperando receber uma quantia y daqui a n períodos. A taxa interna de retorno deste título é o valor r que satisfaz:

$$y = x(1+r)^n$$

Exemplo A.4.
Qual deve ser o preço justo de um título que pagará R$100 000 daqui a 6 meses sabendo que a taxa de juros atual é de 10% ao ano?

Solução
A taxa de 10% ao ano equivale a 5% em 6 meses. O valor "justo" do título é x tal que:

$$100000 = x(1+0.05)^1 \Rightarrow x = \frac{100000}{1.05} = \text{R\$ } 95.238{,}10$$

7.7. Exercícios – Capítulo 7

Problema 1
Suponha que X(t) é um movimento Browniano geométrico com parâmetros $\mu = 0.01$ e $\sigma = 0.3$. Suponha que o valor inicial é $X(0) = 80$. Calcule:

a) $E(X(10))$
b) $Pr\{X(10) > 80\}$
c) $Pr\{X(10) < 90\}$

Problema 2
Repita o problema 1 supondo que o parâmetro de volatilidade é $\sigma = 0.5$.

Problema 3
Refaça o exemplo A.2. supondo que a taxa de juros é 12% ao ano computada mensalmente.

Problema 4
Você acabou de fazer 20 anos de idade e pretende poupar mensalmente uma quantia para a sua aposentadoria, que irá ocorrer aos 65 anos de idade. Suponha uma taxa de juros de 6% ao ano computada mensalmente.

a) Quanto você deverá poupar, a cada mês, para garantir uma renda vitalícia de R$1000 por mês a partir dos 65 anos?
b) Como este valor da poupança mensal muda se agora você decide começar a poupar a partir dos 30 anos?
c) Repita o item b) supondo que você começa sua poupança a partir dos 40 anos.
d) Repita o item a) supondo que a taxa de juros é 10% ao ano computada mensalmente.
e) Refaça o item b) usando a taxa de juros de 10% ao ano computada mensalmente.

Problema 5
Qual a taxa de juros anual que equivale a 0.1% ao dia? Suponha que existem 252 dias num ano, o que é uma aproximação para o número de dias úteis existentes no ano.

Problema 6
Qual a taxa diária equivalente a 15% ao ano?
a) Considere 252 dias no ano.
b) Considere 365 dias no ano.

Problema 7
Você compra hoje, por R$98750,00 um título que pagará R$100000,00 daqui a 6 meses. Qual a taxa semestral implícita neste título? Qual a taxa anual equivalente?

Problema 8
Suponha que o preço de uma ação, S, seja modelado pelo processo de Itô dado pela equação (7.1.8), isto é:

$$dS = \mu.S.dt + \sigma.S.dW = \mu.S.dt + \sigma.S.Z.\sqrt{dt}$$

Use o lema de Itô para mostrar que o processo que rege $Y = \log(S)$, onde $\log(.)$ denota o logaritmo natural é:

$$dY = \left(\mu - \frac{\sigma^2}{2}\right)dt + \sigma.dZ$$

Ou seja, se μ e σ são constantes, Y segue um processo de Wiener generalizado. Em particular conclui-se que a variação em Y entre os instantes t e T (T > t) tem distribuição Normal com média:

$\left(\mu - \frac{\sigma^2}{2}\right)(T-t)$ e variância $\sigma^2(T-t)$.

Portanto, o retorno da ação entre os instantes t e T, que é $\log\{S(T)\} - \log\{S(t)\}$ tem a distribuição Normal indicada acima:

$\left(\mu - \frac{\sigma^2}{2}\right)(T-t)$ e variância $\sigma^2(T-t)$.

Como S(t) (o preço no instante inicial) é dado, segue que o logaritmo do preço no instante T tem distribuição Normal com média $\log\{S(t)\} + \left(\mu - \frac{\sigma^2}{2}\right)(T-t)$ e variância $\sigma^2(T-t)$.

Problema 9
Use o resultado do problema anterior para encontrar a distribuição de probabilidade de log S(T) onde T = 6 meses, o preço inicial da ação é S(t) = R$20, μ = 8% ao ano, σ = 36% ao ano. A partir desta distribuição encontre os preços m e M tais que Pr (S(T) < m) = 2.5% e Pr (S(T) > M) = 2.5%.

Problema 10
Use o resultado do problema 8 para mostrar que:

a) S(T) tem distribuição lognormal;

b) $E\{S(T)\} = S(t).\left\{e^{\mu(T-t)}\right\}$

c) $VAR\{S(T)\} = (S(t))^2\left\{e^{2\mu(T-t)}\right\}\left\{e^{\sigma^2(T-t)} - 1\right\}$

Dica: nos itens b) e c) lembre-se que a função geradora de momentos de uma variável Normal com média a e variância b^2 é: $M(t) = E(e^{tx}) = \exp\{a.t + b^2.t^2/2\}$.

Problema 11
Use o resultado do problema 10 para encontrar a média e variância de S(T) do problema 9.

Problema 12
Uma certa ação está sendo negociada hoje a R$140,80.

A próxima tabela exibe os prêmios para *call* com diversos preços de exercício e mesma data de vencimento.

Call 1	*Call* 2	*Call* 3	*Call* 4	*Call* 5	*Call* 6
K = 180	K = 170	K = 160	K = 150	K = 140	K = 130
0.20	0.50	1.45	3.90	8.40	15.50

a) Descreva o resultado (através de uma tabela ou gráfico) de uma trava de alta usando as *calls* 1 e 6.
b) Repita o item a) para a trava com as *calls* 2 e 5.
c) Repita o item a) para a trava com as *calls* 3 e 4.
d) Repita o item a) para a trava com as *calls* 1 e 3.
e) Repita o item a) para a trava com as *calls* 5 e 6.
f) Descreva o resultado (através de uma tabela ou gráfico) de uma trava de baixa usando as *calls* 1 e 6.
g) Repita o item f) para a trava de baixa usando as *calls* 3 e 4.

Problema 13
Escreva o "pay-off" no vencimento de uma estratégia "butterfly" montada da seguinte maneira:
- Comprar call com preço de exercício 80 e prêmio 22;
- Vender 2 *calls*, ambas com preço de exercício 85 e prêmio 18;
- Comprar call com preço de exercício 90 e prêmio 9;

Problema 14
Escreva o "pay-off" no vencimento de um "strangle" montado da seguinte maneira:
- Comprar call com preço de exercício 47.33 e prêmio 0.01;
- Compra-se uma *put* com o mesmo vencimento, preço de exercício 45.33 e prêmio 6.84.

Problema 15
Repita o problema 14 supondo agora que a call comprada tem preço de exercício 51.33 e o mesmo prêmio.

Problema 16
Escreva o "pay-off" no vencimento de um "strap" montado da seguinte maneira:
- Comprar duas *calls* com preço de exercício 45.33 e prêmio 0.01;
- Comprar uma *put* com o mesmo vencimento, preço de exercício e prêmio 6.84.

Problema 17
Calcule o prêmio e delta de uma opção de compra "at the money" cujo preço de exercício é R$50 sabendo que a taxa livre de risco é 15% a.a., a volatilidade da ação objeto é 25% a.a. e que faltam 2 meses para o vencimento. Como estes valores se modificam se agora faltam apenas 3 semanas (3/4 de um mês) para o vencimento?

Problema 18
Repita o problema 17 para uma *put*.

BIBLIOGRAFIA

- ABRAHAM, B. e LEDOLTER, J. (1983) – Statistical Methods for Forecasting, Wiley, New York.
- BARROS, M. (1999) - Probabilidade: Um curso Introdutório, 1ª edição revista, Editora Papel Virtual, Rio de Janeiro.
- BENNINGA, S. (1998) – Financial Modeling, MIT Press, Cambridge.
- BESSADA, O. (1994) - O Mercado Futuro e de Opções, 3ª. edição, Editora Record, Rio de Janeiro.
- BOX, G. E. P., JENKINS, G. M. e REINSEL, G. C. (1994) – Time Series Analysis – Forecasting and Control, 3rd. edition, Prentice-Hall, New York.
- CHRISS, N. A. (1997) - Black-Scholes and Beyond: Option Pricing Models. Irwin Professional Publishing, Chicago.
- ÇINLAR, E. (1975) – Introduction to Stochastic Processes, Prentice-Hall, New York.
- CLEWLOW, L. e STRICKLAND, C. (1998) – Implementing Derivatives Models, John Wiley & Sons, London.
- COX, D.R. e MILLER, H.D. (1965) – The Theory of Stochastic Processes, Chapman & Hall, London.
- DeLURGIO, S. A. (1998) – Forecasting Principles and Applications, McGraw-Hill, New York.
- FORTUNA, E. (1999) – Mercado Financeiro: Produtos e Serviços, 13ª. edição, Qualitymark Editora, Rio de Janeiro.
- GAMERMAN, D. (1997) - Markov Chain Monte Carlo - Stochastic simulation for Bayesian inference, Chapman & Hall, London.
- GAMERMAN, D. e MIGON, H.S. (1993) - Inferência Estatística: uma abordagem integrada - Coleção: textos de métodos matemáticos - número 27 - Instituto de Matemática - Universidade Federal do Rio de Janeiro.
- GAYNOR, P. E. e KIRKPATRICK, R.C. (1994) – Introduction to Time-Series Modeling and Forecasting in Business and Economics, McGraw-Hill, New York.

- HULL, J. C. (1993) - Options, Futures and Other Derivative Securities, 2nd. Edition, Prentice-Hall, New York.

- HULL, J. C. (2000) - Options, Futures and Other Derivative Edition, Prentice-Hall, New York.

- JORION, P. (1997) – Value at Risk: the new benchmark for controlling market risk. Irwin, Chicago.

- KARLIN, S. e TAYLOR, H. (1975) – A First Course in Stochastic Processes, 2nd. Edition, Academic Press, New York.

- MAKRIDAKIS, S.G., WHEELWRIGHT, S.C. e McGEE, V.E. (1983) – Forecasting: Methods and Applications, 2nd. Edition, John Wiley & Sons, New York.

- MARINS, A. (2004) – Time Mercados Derivativos e Análise de Risco, Vols. 1 e 2, MAS Editora, Rio de Janeiro.

- MILLS, T. C. (1996) – Time Series Techniques for Economists, Cambridge University Press, Cambridge.

- MONTGOMERY, D. C., JOHNSON, L. A. e GARDINER, J. S. (1990) – Forecasting and Time Series Analysis, 2nd. Edition, McGraw-Hill, New York.

- PARZEN, E. (1972) – Procesos Estocasticos, Paraninfo, Madrid.

- ROSS, S.M. (1996) - Stochastic Processes, 2nd. Edition.

- ROSS, S.M. (1999) – An Introduction to Mathematical Finance – Options and Other Topics, Cambridge University Press, Cambridge.

- ROSS, S.M. (2000) – Introduction to Probability Models, 7th. Edition, Academic Press, New York.

- SHIMKO, D.C. (1992) – Finance in Continuous Time, A Primer. Kolb Publishing Company, Miami.

- SMITHSON, C. W. (1998) – Managing Financial Risk: A guide to derivative products, financial engineering and value maximization, 3rd. edition, McGraw-Hill, New York.

- SILVA NETO, L. A. (1998) – Derivativos: Definições, Emprego e Risco, 2ª edição, Editora Atlas, São Paulo.

- SOUZA, R.C. e CAMARGO, M. E. (1996) – Análise e Previsão de Séries Temporais: Os Modelos ARIMA, Sedigraf, Santa Maria.

- TAYLOR, H. M. e KARLIN, S. (1984) – An Introduction to Stochastic Modeling, Academic Press, New York.

- TUCKWELL, H. C. (1988) – Elementary Applications of Probability Theory – Chapman and Hall.

- WILMOTT, P., HOWISON, S. e DeWYNNE, J. (1995) - The Mathematics of Financial Derivatives, Cambridge University Press, Cambridge.

Para encomendar este livro entre em contato com:

Papel Virtual Editora
Rua Conde de Lages 44 sala 402
Glória, Rio de Janeiro, RJ, CEP: 20241-900
Tel: 21-2221-1121

E-mail: editor@papelvirtual.com.br
Endereço eletrônico: www.papelvirtual.com.br