

PART 2 OF SYSTEM IDENTIFICATION EXERCISE LIST 1

Due by October 03, 2026

Name: Eduardo Ribeiro dos Santos

Student ID (I): 5

Questão 1 - Probabilidade e Estatística

Detalhes Iniciais e de Entrada atividade:

- Como o Student ID é 5 e conforme a Tabela 1 do exercício, as 8 cidades referência serão:

Tabela 1

Número da coluna	Índice (Tabela de capitais)	Cidade
#1	9	Salvador (BA)
#2	24	Sao Paulo (SP)
#3	23	Rio de Janeiro (RJ)
#4	26	Porto Alegre (RS)
#5	14	Teresina (PI)
#6	8	Maceió (AL)
#7	18	Goiânia (GO)
#8	6	Boa Vista (RR)

- Para facilitar a manipulação dos dados de entrada do arquivo “Dados-municipais.xlsx” (seria muito lento ler a planilha inteira via MATLAB/Octave), foi criado a partir da planilha um arquivo csv chamado “dados_co2_municipios.csv” contendo apenas os 8 anos de interesse (no caso, 1990, 2000, 2010, 2020, 2021, 2022, 2023 e 2024). Esse csv foi gerado a partir do “Consulta Ranking” da própria planilha que já possuía uma tabela dinâmica pronta com o total de CO2 por município nos exatos 8 anos pedidos.
- Como a leitura/extração dos dados do arquivo “dados_co2_municipios.csv” é comum para alguns scripts da Questão 1, foi criado uma function que prepara e retorna os dados a serem lidos e extraídos desse arquivo.


Resolução dos Itens da Questão:

- Item 1.1: Com as informações do total de CO2 os anos 1990, 2000, 2010, 2020, 2021, 2022, 2023 e 2024, obteve-se:
 - Média Populacional e Desvio Padrão: O cálculo da média usando a função nativa “mean” e o desvio padrão usando a função nativa “std” para cada ano. O resultado obtido está contido na Tabela 2:

Tabela 2

Ano	Média (tCO ₂)	Desvio Padrão (tCO ₂)
1990	386839,15	1578778,08
2000	450694,85	1959811,52
2010	334668,30	1289590,86
2020	442193,81	1939135,61
2021	477798,65	2171954,16
2022	488373,60	2093745,34
2023	459474,07	1601932,86
2024	382666,01	1337854,71

- Histograma: A distribuição de emissão por município é muito assíncrona em escala linear: poucos municípios emitem dezenas de milhões de tCO₂/ano enquanto a maioria permanece na casa dos milhares. Em log₁₀, conforme observado na Figura 1, a distribuição se aproxima à normal, confirmando que o fenômeno tem natureza multiplicativa/log-normal, não aditiva.

Figura 1 - Histogramas de log₁₀(CO₂) por ano (todos os municípios)

- Item 1.2: Conforme discutido e analisando o material das aulas administradas na disciplina, é de conhecimento que o processo estocástico estacionário é definido quando a distribuição conjunta de $\{ X(t_1), X(t_2), \dots, X(t_n) \}$ é a mesma de $\{ X(t_{1+k}), X(t_{2+k}), \dots, X(t_{n+k}) \}$, e, portanto, a média e a variância do processo são as mesmas para todos o instante t , sendo que a função de autocovariância só depende do lag $k=t_2-t_1$. Para o caso do item 1.1, foi calculado média populacional e desvio padrão populacional para cada ano, usando todos os municípios, o que significa que não foi um cálculo da média temporal. O cálculo foi relacionado a $E[X(t)]$ e $\text{Var}[X(t)]$, ou seja, a média de **ensemble** em cada instante t , sendo estes o primeiro e o segundo momento do processo de cada t . Segundo a definição descrita, para ser fortemente

estacionário, $E[X(t)]$ e $Var[X(t)]$ deveriam ser constantes ao longo do tempo, mas conforme a Tabela 2 já é observado que isso não ocorre. Então a conclusão é que a série **não pode ser considerada fortemente estacionária** dado que já viola esse princípio básico.

- Item 1.3: Usando os 8 municípios específicos para o $I=5$ descritos na Tabela 1, com fórmulas amostrais e intervalo de confiança de 95% via distribuição Z, conforme o material da disciplina:

Tabela 3

Ano	Média	Mediana	Desvio	CV(%)	IC 95% Inf.	IC 95% Sup.
1990	853482,48	441907,31	95462,65	111,81	192212,21	1514752,76
2000	1352086,28	605263,04	1512948,10	111,90	303666,74	2400505,83
2010	4495578,72	2291970,02	5127145,16	114,05	942648,39	8048509,05
2020	4866479,60	2569018,60	5062941,70	104,04	1358040,00	8374919,20
2021	5104705,00	2366644,70	5666829,94	111,01	1177792,20	9031617,80
2022	5081385,26	2279167,30	5589367,48	110,00	1208151,20	8954619,31
2023	5139834,72	2283121,75	5760480,53	120,08	1148025,37	9131644,07
2024	5210750,22	2458441,14	5647666,43	108,38	1297117,06	9124383,89




Figura 2 - Histogramas da emissão de CO2 das 8 capitais, por ano (4 classes, regra de Sturges).




Figura 3 - Box-plot da emissão das 8 capitais por ano

O coeficiente de variação está sempre acima de 100%, ou seja, o desvio padrão amostral supera a própria média. Analisando os gráficos, em todos os anos, 6 das 8 capitais ficam concentradas na classe mais baixa do histograma (75% da amostra), enquanto São Paulo e Rio de Janeiro aparecem isolados na classe mais alta, surgindo como outliers estatísticos no box-plot (acima de $Q3 + 1,5 \cdot IQR$). A amostra não é homogênea e sim bimodal porque há seis capitais de porte médio e duas metrópoles de emissão muito superior.

- Item 1.4: Considerando o intervalo de confiança de 98% e erro $< 10.000 \text{ tCO}_2/\text{ano}$ e usando a fórmula $n_0 = (z \cdot \sigma / E)^2$, com σ obtido da população de cada ano (Item 1.1):

Tabela 4

Ano	$\sigma(\text{tCO}_2/\text{ano})$	n_o (sem correção)	n_{fpc} (com correção)
1990	1578778	134889	5383
2000	1959812	207855	5459
2010	1289591	89999	5278
2020	1989136	203493	5456
2021	2171954	255290	5486
2022	2093745	237236	5477
2023	1601933	138874	5389
2024	1337855	96862	5300

Nota-se que em todos os anos, n_o ultrapassa o número total de municípios existentes ($N=5606$). Por exemplo, em 2024, $n_o = 96862$, que é dezessete vezes a população total. Aplicando a correção de população finita, n_{fpc} fica em torno de 5300-5490 municípios (94-98% da população total) em todos os anos. Ou seja, seria necessário amostrar praticamente todos os municípios para atingir essa precisão.

- Item 1.5: Realizando o teste de hipótese ($H_0: \mu_{\text{amostra}} = \mu_{\text{população}}$ $H_1: \mu_{\text{amostra}} \neq \mu_{\text{população}}$), Teste Z para uma amostra (σ populacional conhecido do item 1.1):

$$z = (\bar{x} - \mu) / (\sigma / \sqrt{n})$$

Resultado:

- $\mu = 382.666,01 \text{ tCO}_2$ ($N=5.606$);
- $\bar{x} = 5.210.750,22 \text{ tCO}_2$ ($n=8$);
- erro padrão = $473.003,07 \text{ tCO}_2 \rightarrow z = 10,2073$, $p \sim 0$.

Com valor crítico $|Z|=1,96$ ($\alpha=0,05$), rejeita-se H_0 : há evidência estatisticamente forte de que a média de emissão das 8 capitais difere da média geral dos municípios brasileiros em 2024. A média amostral é $\sim 13,5$ vezes maior que a média populacional.

Questão 2 - Processos Estocásticos, Séries Temporais, e Identificação de Sistemas usando Função de Autocorrelação

Detalhes da atividade:

- Como o Student ID é 5 o código para gerar um processo estocástico obteve o gráfico da Figura 4:




Figura 4 - Série Temporal para l=5

Resolução dos Itens da Questão:

- Item 2.1: Para plotar a função de autocorrelação, existem duas possibilidades:
 - Usando as funções nativas *xcorr/autocorr* que dependem de toolbox
 - Usando o **coeficiente de correlação de lag k** apresentada nos materiais de aula, especificamente do livro *Processos Estocásticos por Mônica Barros*, definição 5.4.4, que é uma função que tem comportamento de decaimento ligada à ordem do modelo ARMA de Box-Jenkins:

$$r(k) = \frac{\sum_{t=1}^{T-k} (z_t - \bar{z})(z_{t-k} - \bar{z})}{\sum_{t=1}^T (z_t - \bar{z})^2}$$

Além disso temos o **intervalo de confiança de Bartlett** onde os valores de $r(k)$ são considerados estatisticamente diferentes de zero se caírem fora de:

$$\left[-\frac{2}{\sqrt{n}}, \frac{2}{\sqrt{n}} \right]$$

Então o limite de Bartlett é aproximadamente **+/-0,0448**.

O script criado para resolver a questão foi implementado utilizando a função fornecida pelo material de aula e o resultado do plot da função é apresentado na Figura 5




Figura 5 - Gráfico função de autocorrelação (FAC)

- Item 2.2: Conforme pedido na questão, a série estocástica foi realizada a tentativa de divisão em blocos de 20 para 100 observações. Aqui temos a mesma lógica do “Teste de Estacionariedade” descrito nas notas de aula (media x amplitude/dispersão de subconjuntos). Neste caso, os subconjuntos são blocos de observações consecutivas de uma única relação. A Figura 6 apresenta os resultados:




Figura 5 - Resultado do “Teste de Estacionariedade”

Observe que as médias por bloco (painel esquerdo) oscilam em torno de uma linha central próxima de zero, sem apresentar nenhuma tendência determinística de crescimento ou decrescimento ao longo dos blocos. Além disso a Dispersão e a Correlações Cruzadas (painéis central e direito), nota-se que o gráfico de média vs amplitude mostra uma correlação linear quase nula (~ 0.03) e o gráfico de média vs desvio mostra uma correlação fraca (~ 0.09). Portanto, como não há indícios de tendências temporais ou oscilações de amplitude, conclui-se que o processo estocástico gerado da série $y(k)$ é **estacionário no sentido amplo (WSS - Wide-Sense Stationary)**

- Item 2.3: Conforme identificado no item 2.1 e mostrado no gráfico da Função de Autocorrelação da Figura 5, nota-se claramente que os primeiros coeficientes de autocorrelação para $k=1$, $k=2$ e $k=3$ ultrapassam de forma significativa os limites de confiança de Bartlett. A partir de $k=3$ em diante, os valores de $r(k)$ entram na faixa de ruído e flutuam dentro dos limites aceitáveis. Da mesma forma, apenas como comparação, também foi plotado o gráfico da Função de Autocorrelação Parcial descrita em 5.4.14 do livro *Processos Estocásticos por Mônica Barros*, ao lado da Função de Autocorrelação conforme observado na Figura 7.




Figura 7 - Comparação dos gráficos da Função de Autocorrelação e da Função de Autocorrelação Parcial

Como os padrões apresentados são cortes abruptos ou decaimentos característicos após um número finito de lags associados à parte de média móvel, combinados com a estrutura do problema, é identificado um modelo do tipo **ARMA(p,q)**. Baseado nos lags iniciais significativos, confirma-se a ordem **ARMA(3,2)**. Contudo, pela teoria de identificação de Box-Jenkins, quando a Função de Autocorrelação corta abruptamente para zero após o lag q , a série temporal é identificada como um modelo de média móvel de ordem q , ou seja **MA(q)**. Logo, a ordem identificada é **MA(2)**.

Sobre os parâmetros, com a ordem foi identificada como MA(2), o mesmo é dado por $y(k) = \bar{y} + e(k) + b_1 e(k-1) + b_2 e(k-2)$. E sabemos que a média da série ($\bar{y}$) é:

$$\bar{y} \sim 0,012$$

Além disso, utilizando os valores lidos no gráfico da FAC ($r(1) \sim 0,18$ e $r(2) \sim 0,11$) através do sistema de equações da autocorrelação teórica de um MA(2):

$$r(1) = \frac{b_1 + b_1 b_2}{1 + b_1^2 + b_2^2} \sim 0,18$$

$$r(2) = \frac{b_2}{1 + b_1^2 + b_2^2} \sim 0,11$$

Resolvendo empiricamente para os dados da FAC:

- $\hat{b}_1 \sim 0,17$
- $\hat{b}_2 \sim 0,11$

Finalmente, sabemos que o desvio padrão é $\sigma_y \sim 0,32$. Portanto, a variância da série $\sigma_y^2 \sim (0,32)^2 \sim 0,1024$. Logo, a variância do ruído (σ_e^2) é:

$$\sigma_e^2 = \frac{\sigma_y^2}{1+b_1^2+b_2^2} \sim \frac{0,1024}{1+0,17^2+0,11^2} \sim 0,098$$

- Item 2.4: Primeiramente, como $l=5$, temos que:

- $a_1 = 1/(l)^{1/2} = 1/(5)^{1/2} \sim 0,4472$
- $b_1 = 1/l = 1/(5) = 0,2$

Sabe-se que a equação do processo ARMA pode ser escrita em termos do operador de atraso/backshift B (onde $B^i y(k) = y(k-i)$). Portanto:

- Polinômio AR: $\phi(B) = 1 - a_1 B - a_2 B^2 - a_3 B^3$, sendo $\phi(B)y(k) = \theta(B)e(k)$
- Polinômio MA: $\theta(B) = 1 + b_2 B + b_1 B^2$
- Invertibilidade (MA(2)): usando a mesma região triangular do Exemplo 5.4.19 do livro *Processos Estocásticos por Mônica Barros*, onde $\theta(B) = 1 - \theta_1 B - \theta_2 B^2$, ou seja, $\theta_1 = -b_2$, $\theta_2 = -b_1$. Conforme discutido em aula, para garantir invertibilidade, as raízes de $\theta(B)=0$ devem estar fora do círculo unitário. Portanto

$$-1 < b_1 < 1, b_2 < 1 + b_1, b_2 > -1 - b_1$$

Como $b_1 = 0,2$ já satisfaz automaticamente a primeira condição, temos que a condição efetiva é:

$$-1,2 < b_2 < 1,2$$

- Estacionaridade (AR(3)): Aqui temos três variáveis a_1 , a_2 e a_3 . Ao encontrar as raízes aqui gerou-se o sistema de equações abaixo:

$$a_2 + a_3 < 1 - a_1 = 0,5528$$

$$a_2 < 0,5528 - a_3 \quad (I)$$

$$a_2 < 1 + a_1 + a_3 = 1,4472 + a_3$$

$$a_2 < 1,4472 + a_3 \quad (II)$$

Somando as equações (I) e (II), temos:

$$a_2 + a_2 < 0,5528 - a_3 + 1,4472 + a_3$$

$$2a_2 < 2$$

$$|a_2| < 1$$

- Condição sobre p : Sabe-se que $e(k)$ é Bernoulli(p). Portanto $E[e(k)] = p$ e $\text{Var}[e(k)] = p(1-p)$. Conforme discutido em aula e pela definição do ruído branco, a autocovariância nula para $k \neq 0$, vale para qualquer sequência i.i.d, não só para média zero. $e(k)$ é um ruído branco válido para qualquer p .

Então, única condição real é $0 < p < 1$ (excluindo os casos que $\text{Var}[e(k)] = 0$, pois o processo deixa de ser genuinamente aleatório).

- Item 2.5.1: Usando a teoria da probabilidade e considerando o processo estacionário, temos

- Item a: Considerando estacionariedade equivalente a $\bar{y}$ constante, temos:

$$\bar{y} = (a_1 + a_2 + a_3)\bar{y} + (1 + b_1 + b_2)p$$

$$\bar{y} = \frac{p(1 + b_1 + b_2)}{(1 + a_1 + a_2 + a_3)}$$

- Item b: Como $e(k)$ é i.i.d: $\gamma_e(k) = p(1 - p)$ se $k = 0$, e $\gamma_e(k) = 0$ se $k \neq 0$.

Para $\gamma_y(k)$, usou-se o mesmo método discutido em aula (multiplicar a recursão por $y(t - k) - \bar{y}$ e aplicar $E[\cdot]$), estendido para o caso ARMA misto como o livro *Processos Estocásticos por Mônica Barros* define. Então, fazendo $x(k) = y(k) - \bar{y}$ e $u(k) = e(k) - p$:

Para $\tau > 2$, os termos cruzados com u desaparecem (causalidade: $u(k)$ é independente de $x(k - \tau)$ para $\tau > 0$ exceto pela sobreposição finita do MA), restando a recursão pura tipo Yule-Walker:

$$\gamma_y(\tau) = a_1 \gamma_y(\tau - 1) + a_2 \gamma_y(\tau - 2) + a_3 \gamma_y(\tau - 3), \tau > 2$$

Para $\tau = 0, 1, 2$ entram os termos cruzados com $u(k)$, $u(k - 1)$, $u(k - 2)$, que exigem os primeiros pesos ψ_j da representação $\text{MA}(\infty)$ de $x(k) = \psi(B)u(k)$ conforme descrito no livro *Processos Estocásticos por Mônica Barros*, equação 5.4.13, usada para checar invertibilidade. Casando coeficientes:

$$\psi_0 = 1, \psi_1 = a_1 + b_2, \psi_2 = a_1 \psi_1 + a_2 + b_1$$

Portanto, $\gamma_y(0), \gamma_y(1), \gamma_y(2)$ saem de um sistema de 3 equações.

- Item 2.6: Conforme requisitado pelo enunciado, vamos considerar o motor dc da lista 1.1. Ou seja, para o I=5, temos:

$$r_a = 0.4$$

$$l_a = 0.05$$

$$k_b = 2.5$$

$$j_m = 10.0$$

$$k = 0.4$$

$$b = 0.5$$

Além disso, também conforme o enunciado, vamos considerar o mesmo sinal PRBS gerado na lista 1.1 e representado na Figura 8:




Figura 8 - Sinal PRBS

- Item 2.6.1: Aqui foi calculado $r_{uu}(k)$ e $r_{uy}(k)$ usando as fórmulas fornecidas nas notas de aula embutidas nos scripts para confirmar que $r_{uu}(k) \sim 0$ para $k \neq 0$ (propriedade do PRBS) e então usar a fórmula simplificada $\hat{h}(k) = r_{uy}(k)/r_{uu}(0)$. O Código gera o seguinte gráfico representado na Figura 9 para este caso:




Figura 9 - Resposta ao Impulso - Método da Autocorrelação

A curva verde representa o impulso real do sistema de referência, enquanto as curvas azul (sem ruído) e vermelha pontilhada (com ruído) representam as estimativas obtidas das funções de correlação cruzada e autocorrelação. Observa-se que o formato geral da curva estimada acompanha de perto o decaimento exponencial da resposta ao impulso real, indicando que o método capturou com sucesso a dinâmica principal do sistema. Nota-se um pequeno desvio e uma sobreposição quase perfeita entre os casos “com ruído” e “sem ruído”, demonstrando a robustez do método estatístico baseado em correlação frente à adição de ruído aditivo.

- Item 2.6.2: Neste caso usou-se Wiener-Khinchin ($S = \text{FFT}(r)$) para estimar $H(\omega) = S_{uy}(\omega)/S_{uu}(\omega)$, no mesmo grid de frequência do exercício equivalente na lista 1.1 para comparação direta. A Figura 10 mostra o resultado deste caso:




Figura 10 - Resposta em Frequência - Método da Autocorrelação/PSD

Aqui a curva verde (real) mostra o perfil de ganho do sistema no domínio da frequência, característico de um filtro passa-baixa (maior ganho nas frequências próximas a 0 Hz e atenuação progressiva em direção a 0,5 Hz). As curvas estimadas em azul (Estimado (sem ruído)) e vermelho (Estimado (com ruído)) refletem a estimativa obtida pela razão entre a Densidade Espectral Cruzada (S_{yu}) e a Densidade Espectral de Potência da entrada (S_{uu}).

O estimador reproduz com fidelidade a tendência de atenuação em altas frequências, embora apresente uma ligeira subestimação em comparação com a curva real. Novamente, a robustez do método fica evidente pelo fato de as curvas com e sem ruído se manterem praticamente idênticas.

Portanto, a conclusão obtida é que o método da autocorrelação degradou menos com o ruído.

OBS.: Em caso de dúvidas sobre o código utilizado, consulte o código no link: https://github.com/esantos-798/UFES/tree/main/Mestrado/Segundo_Semestre/Identificacao_de_Sistemas/Avaliacao/Exercicios/Lista1.2